



*Asociación Profesional del Cuerpo Superior
de Sistemas y Tecnologías de la Información
de la Administración del Estado*

Temas Específicos para la preparación de la Oposición al Cuerpo
Superior de Sistemas y Tecnologías de la Información de la
Administración del Estado.

TEMAS ESPECÍFICOS II: Tecnología básica

Tema 52. Sistemas de altas prestaciones. Grid Computing. Mainframe.

Editado por ASTIC en 2017 a partir de los temas numerados anteriormente como:

- **Tema 45. Sistemas de altas prestaciones. Grid Computing.
Mainframe.**
AUTOR: Juan Guevara
Actualización 2014
- **Tema 55. Los sistemas operativos y el soporte lógico de base I.
Sistemas de altas prestaciones**
AUTOR: Rafael Gómez Lago
Actualización 2003

Índice


1	Introducción	3
2	Sistemas Multiprocesador.....	4
2.1	Taxonomía de Flynn.....	4
2.1.1	SISD (Single Instruction stream, Single Data stream)	4
2.1.2	SIMD (Single Instruction stream, Multiple Data streams)	5
2.1.3	MISD (Multiple Instruction streams, Single Data stream)	6
2.1.4	MIMD (Multiple Instruction streams, Multiple Data streams).....	6
2.2	Clasificación de Tanenbaum	6
2.2.1	SMP (Symmetric MultiProcessor)	7
2.2.2	MPP (Massively Parallel Processor)	8
2.3	Ejemplos de sistemas de altas prestaciones Multiprocesador.....	8
2.3.1	Superordenadores.....	8
2.3.2	Mainframes	9
3	Sistemas Multicomputador	13
3.1	Arquitectura Clúster.....	13
3.1.1	Componentes	14
3.1.2	Servicios de Middleware.....	15
3.2	Arquitectura Grid	16
3.2.1	Características principales	17

1 Introducción

Un sistema de altas prestaciones se puede definir como un ordenador multiusuario/tarea/proceso de muy altas capacidades de cómputo, orientado al procesamiento de grandes volúmenes de información, tanto en ámbito de la gestión como en el del cálculo científico-técnico

Existen dos aproximaciones principales a la hora de diseñar un sistema de altas prestaciones. Se engloba dentro de la categoría de **Multiprocesadores** si se basa en una única máquina de mucha potencia de cálculo y elementos compartidos. Por otro lado, la categoría de **Multicomputadores** se compone por los sistemas cuyo diseño se apoya en múltiples máquinas que, manteniendo su independencia, suman sus potencias

Para cada una de estas categorías existen subdivisiones según el detalle concreto del diseño. En el presente tema se analizarán en más detalle, si bien se presentan en el gráfico siguiente:



Para los sistemas Multiprocesador se partirá de la taxonomía de Flynn, de amplia divulgación, con alguna incorporación adicional. En el caso de los sistemas Multicomputador se analizarán las dos maneras de conseguir que múltiples ordenadores trabajen de manera coordinada: diseño Grid y diseño Clúster.

2 Sistemas Multiprocesador


Es una familia de sistemas de altas prestaciones que se basa en una sola máquina de mucha potencia de cálculo y elementos compartidos.

2.1 Taxonomía de Flynn

Se trata de una clasificación clásica de computadores en función de su arquitectura, publicada por Flynn por primera vez en 1966 y por segunda vez en 1970. Esta taxonomía se basa en el flujo que siguen los datos dentro de la máquina y de las instrucciones sobre esos datos.

Se define como flujo de instrucciones al conjunto de instrucciones secuenciales que son ejecutadas por un único procesador y como flujo de datos al flujo secuencial de datos requeridos por el flujo de instrucciones.


Con estas consideraciones, Flynn clasifica los sistemas en **cuatro categorías**:



2.1.1 SISD (Single Instruction stream, Single Data stream)

Los sistemas de este tipo se caracterizan por tener un único flujo de instrucciones sobre un único flujo de datos, es decir, se ejecuta una instrucción detrás de otra. Este es el concepto de arquitectura serie de Von Neumann donde, en cualquier momento, sólo se ejecuta una única instrucción.

Las SISD tienen, pues, la característica de procesar una instrucción por cada ciclo de reloj



En la figura podemos observar que la zona de memoria del computador se divide en dos módulos:

- Un módulo reservado para el conjunto de **instrucciones** a ejecutar, que forman el programa almacenado.

- Un módulo que contiene los **datos** sobre los que va a ejecutarse dichas instrucciones.

La **unidad de procesamiento (PU)** es el módulo encargado de realizar las operaciones matemáticas necesarias para ejecutar las instrucciones del programa. Como mínimo, esta unidad tendrá capacidad de sumar y de realizar operaciones lógicas.

Las soluciones SISD NO presentan capacidades de concurrencia ni paralelización. En todo caso, podemos llegar a una simulación de estas capacidades, por medio de la segmentación.

La **segmentación** es una técnica de solapamiento de instrucciones mediante la división de su ejecución en etapas o segmentos. Consiste en descomponer la ejecución de cada instrucción en varias etapas para poder empezar a procesar una instrucción diferente en cada una de ellas y trabajar con varias a la vez. La segmentación incrementa la productividad de instrucciones de la CPU, pero no disminuye el tiempo de ejecución de cada instrucción, que permanece inalterado.


Ejemplos de este paradigma de arquitectura: S36 de IBM, AS400 de IBM, Sun Enterprise

2.1.2 SIMD (Single Instruction stream, Multiple Data streams)

Estos sistemas tienen un único flujo de instrucciones que operan sobre múltiples flujos de datos. Ejemplos de estos sistemas los tenemos en las máquinas vectoriales con hardware escalar y vectorial.

El procesamiento es síncrono, la ejecución de las instrucciones sigue siendo secuencial como en el caso anterior, todos los elementos realizan una misma instrucción, pero sobre una gran cantidad de datos. Por este motivo existirá concurrencia real de operación, es decir, esta clasificación es el origen de la máquina paralela.

El funcionamiento de este tipo de sistemas es el siguiente. La Unidad de Control manda una misma instrucción a todas las unidades de proceso. Las unidades de proceso operan sobre datos diferentes, pero con la misma instrucción recibida.



Existen dos alternativas distintas que aparecen después de realizarse esta clasificación:


- Arquitectura **Vectorial** con segmentación: una CPU única particionada en unidades funcionales independientes trabajando sobre flujos de datos concretos
- Arquitectura **Matricial** (matriz de procesadores): varias ALUs idénticas a las que el procesador de instrucciones asigna una única instrucción, pero trabajando sobre diferentes partes del programa.

Ejemplos de este paradigma de arquitectura: ILLIAC IV, CRAY monoprocesador, CYBER 205, FUJITSU, NEC SUPERCOMPUTERS, IBM 390 VF, IBM 9000 VF, ALLIANT FX/1 Y CONVEX C-1

2.1.3 MISD (Multiple Instruction streams, Single Data stream)

Los sistemas MISD se contemplan de dos maneras distintas:

- Varias instrucciones operando simultáneamente sobre un único dato.
- Varias instrucciones operando sobre un dato que se va convirtiendo en un resultado que será la entrada para la siguiente etapa. Se trabaja de forma segmentada, todas las unidades de proceso pueden trabajar de forma concurrente.




Tiene un serio inconveniente, la latencia de los datos. Se trata de arquitecturas experimentales.

Ejemplos de estos tipos de sistemas son los arrays sistólicos (el movimiento de avance del dato es el 'latido' del sistema) o arrays de procesadores. También podemos encontrar aplicaciones de redes neuronales en máquinas masivamente paralelas.

2.1.4 MIMD (Multiple Instruction streams, Multiple Data streams)

Sistemas con un flujo de múltiples instrucciones que operan sobre múltiples datos. Estos sistemas empezaron a utilizarse a principios de los 80.

Se trata de sistemas basados en un único bus multiplexado, de altas prestaciones, a través del cual podamos transmitir simultáneamente más de una instrucción y más de un dato.



2.2 Clasificación de Tanenbaum

Dentro del grupo MIMD se fueron identificando estructuras nuevas que no se ajustaban a la clasificación de Flynn. Andrew Tanenbaum realizó una clasificación más precisa, basada en el **acoplamiento** entre procesadores.

En función de la manera de compartir la memoria, podemos distinguir dos categorías dentro de estos sistemas:

- SMP (Symmetric MultiProcessor) o MMC (Multiprocesador de Memoria Compartida).

- MPP (Massively Parallel Processor) o MMD (Multiprocesador de Memoria Distribuida).

2.2.1 SMP (Symmetric MultiProcessor)

Son sistemas fuertemente acoplados, en los que los procesadores dependen unos de otros, dado que comparten memoria. También se denominan MMC (Multiprocesador de Memoria Compartida).


Se dispone de una única memoria compartida donde se encuentran almacenadas todas las instrucciones del programa y los datos necesarios para ejecutar dichas instrucciones. Con respecto a estos datos, podemos distinguir **dos tipos de memoria en función de su alcance**:

- Datos de alcance **global**, almacenados en la memoria compartida y que pueden ser utilizados por cualquiera de las unidades de procesamiento.
- Datos de alcance **local**, almacenados por un determinado procesador en una memoria caché propia, y visibles únicamente en el ámbito de dicho procesador.

En estos sistemas existe un cuello de botella en el acceso a la memoria compartida por parte de los procesadores para acceder a datos globales o a instrucciones del programa. Se plantean **dos alternativas para gestionar la memoria compartida** en este tipo de sistemas:

- **UMA** (Acceso uniforme a memoria).


La memoria compartida es donde cada procesador tiene acceso a toda la memoria, se dan tiempos de acceso a memoria uniformes, pues llegan a memoria mediante un bus en común y tienen las mismas latencias de lectura y escritura; además tienen el mismo sistema operativo.



Sin embargo este tipo de memoria cuenta con la desventaja del acceso simultáneo a memoria de parte de todos los nodos, además de la poca escalabilidad, debido a que, si se agregan múltiples CPUs extra, puede generarse un cuello de botella.

- **NUMA** (Acceso no uniforme a memoria).

Se introducen criterios de preferencia en el acceso a la memoria compartida. Estos criterios pueden estar basados, por ejemplo, en la disposición física de los procesadores, o en una distribución de prioridades dada.



2.2.2 MPP (Massively Parallel Processor)

Son sistemas débilmente acoplados, en los que existe poca interacción entre los diferentes procesadores que forman el sistema, dado que disponen de memoria propia. También se conocen como MMD (Multiprocesador de Memoria Distribuida).

Estos sistemas surgen para solucionar la carencia de los anteriores, en cuanto a los accesos a la memoria compartida.

En estos sistemas no existe un módulo de memoria compartida propiamente dicho, sino que ésta se encuentra distribuida en submódulos de memoria en cada uno de los procesadores individuales. Además, se añade un submódulo de E/S a los procesadores, que permita gestionar los accesos al submódulo de memoria interno.

Esta arquitectura nos permite reducir considerablemente los accesos al bus para recuperar datos, siempre que aseguremos que las instrucciones del programa y los datos se encuentran distribuidos en los submódulos de memoria, agrupados de forma que en cada submódulo tengamos almacenados un grupo de instrucciones y todos los datos necesarios para ejecutarlas.

Para conseguir este tipo de 'distribución' del programa y los datos en los submódulos de memoria, son necesarios algoritmos de una elevada complejidad.

2.3 Ejemplos de sistemas de altas prestaciones Multiprocesador

Existen 2 familias de sistemas de altas prestaciones dentro del diseño basado en multiprocesador: los superordenadores, orientados a ofrecer una altísima capacidad de cálculo, y los sistemas centrales o mainframes, más orientados a altos requisitos de entrada y salida

2.3.1 Superordenadores

Un superordenador es aquella con capacidades de cálculo muy superiores a las computadoras corrientes y de escritorio y que son usadas con fines específicos.

De muy alto coste (de decenas de millones de euros en adelante), existen actualmente menos de un millar en el mundo, y son gestionados por personal muy especializado. Su uso está limitado a organismos gubernamentales, militares y científicos, y actualmente alcanzan velocidades de centenas de teraFLOPs (10¹² operaciones en coma flotante por segundo).

A continuación se enumeran los cinco superordenadores de mayor potencia en septiembre de 2014, de la lista TOP500 de superordenadores

Rank	Lugar	Sistema	Núcleos	TFlop/seg
1	National Super Computer Center in Guangzhou China	Tianhe-2 (MilkyWay-2) TH-IVB-FEP Cluster, Intel Xeon E5-2692 12C 2.200GHz, TH Express-2, Intel Xeon Phi 31S1PNUDT	3,120,000	33,862.7
2	DOE/SC/Oak Ridge National Laboratory United States	Titan Cray XK7, Opteron 6274 16C 2.200GHz, Cray Geminiinterconnect, NVIDIA K20x - Cray Inc.	560,640	17,590.0
3	DOE/NNSA/LLNL United States	Sequoia BlueGene/Q, Power BQC 16C 1.60 GHz, Custom- IBM	1,572,864	17,173.2
4	RIKEN Advanced Institute for Computational Science (AICS) Japan	K computer, SPARC64 VIIIfx 2.0GHz, Tofu interconnect - Fujitsu	705,024	10,510.0
5	DOE/SC/Argonne National Laboratory United States	Mira BlueGene/Q, Power BQC 16C 1.60GHz, Custom - IBM	786,432	

2.3.2 Mainframes

Son equipos dedicados a gestión, por lo que admiten gran cantidad de trabajos simultáneos, como por ejemplo controlar una red de terminales en las sucursales de una empresa, o una red de cajeros automáticos de un banco

Hoy día el término mainframe se utiliza para referirse a sistemas de la serie IBM System/360 (cuya primera versión apareció en 1965) y compatibles. La mayor parte de los grandes computadores desde 1960 seguían la arquitectura y filosofía de los mainframes, hasta la aparición de la web y los servidores en la década de los 90s.


Características principales de los mainframes son la fiabilidad, la disponibilidad, la integridad y la tolerancia a fallos. Desde los primitivos equipos que trabajaban con tarjetas perforadas y cintas magnéticas hasta los actuales mainframes, todos ellos han enfocado su diseño y arquitectura para estar funcionando durante muchos años sin interrupción, con reparaciones y actualizaciones de hardware y software teniendo lugar siempre en operación normal.

La mayoría de los mainframes actuales pueden ejecutar múltiples sistemas operativos, y ofrecen varios niveles de virtualización. Son equipos diseñados además para gestionar un elevado número de operaciones de entrada/salida, para lo que disponen de procesadores específicos.

Aunque tanto supercomputadores como mainframes utilizan procesamiento paralelo, los mainframes están más enfocados a resolver problemas que requieran un alto número de entradas y salidas de datos externos, mientras que los supercomputadores están más enfocados a resolver problemas que requieren una alta velocidad de cálculo. Por otro lado, los supercomputadores son máquinas diseñadas para un propósito muy específico, con un diseño hecho a medida para cumplir su objetivo, mientras que los mainframes son máquinas más generalistas que forman parte de una línea de productos concreta de las empresas que los diseñan.

Originalmente el término “mainframe” se aplicaba para referirse al armario metálico sobre el que se instalaba la unidad central de proceso de los grandes sistemas, pero con el tiempo el término se extendió para incluir a todo el sistema central, incluyendo al procesador, a las unidades de disco y a diversos canales de entrada/salida de los sistemas centralizados. Sólo los fabricantes más importantes ofrecían este nivel de prestaciones y disponibilidad: capacidad para atender simultáneamente a miles de terminales y de procesar miles o millones de transacciones en línea, ingentes cantidades de almacenamiento secundario, sistemas constantemente monitorizados y capaces de recuperarse de forma automática, una disponibilidad sin igual. Aun así, incluir el mainframe dentro de la denominación HPC quizás pueda parecer inapropiado para algunos que identifican el alto rendimiento con los sistemas paralelos o con el cálculo científico. Sin embargo, según la definición que ofrecíamos al comienzo del tema del concepto HPC; un mainframe actual es un HPS de pleno derecho.

Aunque existen varios fabricantes de mainframes, este tipo de sistemas se atribuyen habitualmente al gigante azul. Y actualmente, hablar de mainframe IBM es hacerlo de z/OS, OS/390 y MVS. En realidad se trata de la evolución de un único sistema operativo: MVS



(*Multiple Virtual Storage*) empezó ¹ su andadura en 1974 con la arquitectura 370 de mainframes de IBM; en 1995 cambió su nombre por OS/390 y se introdujo toda una nueva serie de servicios y herramientas adaptadas de UNIX; finalmente en el año 2001 el sistema operativo fue migrado a 64 bits y volvió a ser renombrado para acomodarse a su comercialización ² como z/OS.

La forma habitual de trabajar con el sistema es bien a través de un interfaz de proceso batch denominado JCL (*Job Control Language*), bien mediante un interfaz interactivo de tiempo compartido llamado TSO (*Time Sharing Option*). También existe un sistema basado en TSO, pero al que se puede acceder mediante una serie de menús y pantallas; se trata de ISPF. Para la gestión de la interactividad, existe un sistema denominado CICS.

La forma tradicional de acceso a un mainframe suele ser el terminal 3270 (o una emulación equivalente), aunque actualmente existen diversos servicios accesibles mediante la web como *CICS Web Support*. El terminal 3270 es un sistema de pantallas en el que intercambian bloques de datos en el que están mezclados texto y formato. También existe una emulación para PC y una versión adaptada de Telnet que permite acceder a los sistemas desde diversas estaciones de trabajo.

El elemento que sustenta toda la infraestructura software de zOS es el programa básico de control (BCP). El BCP es el núcleo del sistema operativo.

El sistema soporta un sistema de direccionamiento mixto de 24, 31 y 64 bits lo que permite virtualmente extender el espacio de direcciones accesibles hasta 16 Exabytes (18·10¹⁸). Los programas con direccionamiento de 24 o 31 bits funcionan sin cambios en el sistema; estas direcciones se dice que están por debajo de la barra y son las únicas direcciones que pueden ser utilizadas por el código ejecutable o por el sistema operativo. Por encima de los 32 bits, el espacio está reservado para los datos que manejan las aplicaciones de usuario; tanto el código de los programas como el código y datos del sistema operativo no pueden utilizar las

¹ En realidad MVS es a su vez descendiente de una línea de sistemas operativos que remontan hasta la antigua línea del OS/360 que se remonta a los años 60.

² La publicidad indica que la “z” de la serie indica “zero downtime” (siempre de servicio).

direcciones superiores de la memoria. Los programas de usuario empiezan a recibir memoria de la zona que existe entre las direcciones 2^{32} y $2^{41}-1$ desde la parte inferior de la memoria hacia la parte superior de la misma; la memoria que se coge como memoria compartida se coge desde la parte superior del espacio ($2^{50}-1$).

La traducción dinámica de direcciones es el proceso por el que se mapean las páginas³ de memoria virtual en marcos de memoria física. Esta traducción la realiza el componente Gestor de Almacenamiento Virtual (VSM) que utiliza una tabla de segmentos por cada⁴ espacio de direcciones y hasta 2048 tablas de páginas. El sistema de traducción se realiza en tres niveles; el número real de niveles que son necesarios dependen del direccionamiento real necesario. Estos niveles se denominan tablas de región y van numerados en orden inverso. Así, el primer nivel (R3T) ofrece direcciones hasta los 4 Tbytes; el segundo nivel (R2T) se hace necesario cuando se necesita direccionar un espacio virtual por encima de los 4 Tbytes y por debajo de los 8 Pbytes; el tercer y último nivel (R1T) se hace necesario para direccionar memoria por encima de los 8 Pbytes.

El sistema permite controlar el tamaño máximo de memoria física y espacio de paginación que un trabajo puede pedir, para controlar la carga del sistema. Esto se puede realizar de varias maneras: parámetros MEMLIMIT de los JCL y parámetros SMF de la instalación.

Hace mucho tiempo que quedó atrás el nexo entre las palabras “mainframe” y términos normalmente asociados exclusivamente a la informática empresarial como COBOL o IMS. El entorno mainframe de hoy en día es bastante diferente del de sus predecesores. En la actualidad, el mainframe es capaz de alojar todas o las partes más importantes de muchas aplicaciones de nueva generación. Nuevas tecnologías como los servicios web y Java son cada vez más neutrales con respecto a la plataforma y las iniciativas tecnológicas como Linux en S/390 y zSeries desdibujan aún más la diferencia entre plataformas, permitiendo a las tradicionales aplicaciones UNIX y las plataformas distribuidas beneficiarse de los tradicionales puntos fuertes del mainframe. Hoy por hoy, cualquier entorno mainframe moderno permite desarrollar en prácticamente cualquier lenguaje moderno presente en otros sistemas (incluyendo C++, Ada, Java, e incluso Prolog o LISP) así como con cualquier estándar de acceso a datos de la industria (incluyendo SQL, XML, ficheros indexados, etc.)

La tecnología de cluster de Sysplex paralelo se construye sobre la base de la plataforma zSeries y S/390 y la extiende para conseguir agregar varios sistemas zOS y OS/390 con compartición de recursos y datos. Además tiene facilidades para balancear la carga de trabajo de forma adecuada entre los procesadores disponibles “al vuelo”, permitiendo añadir y eliminar servidores de forma dinámica sin detener el sistema operativo. Esta tecnología permite redirigir trabajos entre nodos del cluster ya sea desde o hacia tráfico SNA, TCP/IP, transacciones CISC, programas batch o sistemas de mensajes MQ.

Que el mercado del mainframe tiene buena salud, lo demuestra la entrada de fabricantes que, tradicionalmente, se dirigían a otros segmentos. Es el caso de Sun Microsystems con su Fire 15K, sistema que utilizando Solaris actualmente se comercializa en versiones con hasta 72 procesadores y casi 300 Gbytes de memoria. Solaris SPARC es la versión de 64 bits del tradicional UNIX de la compañía californiana. Como no podía ser de otra forma, además de las características habituales de los sistemas operativos de 64 bits, el sistema de Sun tiene una importante integración Java, incluyendo soporte para este entorno de programación. No obstante la línea de HPC para computación de alto rendimiento va más en la línea de la especialización, con sistemas de almacenamiento en red (SAN) especializados para las necesidades de la computación científica y la computación con clusters.

En cualquier caso, los mainframes no son sistemas baratos. Son la esencia de las altas prestaciones en las organizaciones más importantes. En la Administración Pública, organizaciones como la Agencia Tributaria o la Agencia de la Seguridad Social han confiado tradicionalmente sus procesos más importantes en este tipo de sistemas y máquinas. Como

³ El tamaño de las páginas es de 4 Kbytes.

⁴ Tanto zOS como su predecesor OS/390 admiten más de un espacio de direcciones que permiten la escalabilidad horizontal del sistema.

diría M. Twain, las noticias sobre la muerte del mainframe, han sido muy exageradas. Sin embargo, existen formas de entrar en la HPC que requieren presupuestos mucho menores.

3 Sistemas Multicomputador

Los sistemas multicomputadores se pueden ver como un computador paralelo en el cual cada procesador tiene su propia memoria local. En estos sistemas la memoria se encuentra distribuida y no compartida como en los sistemas multiprocesador.

El diagrama de bloques de un sistema multicomputador coincide con el visto para los sistemas MPP o MMD, la diferencia viene dada porque la red de interconexión no permite un acceso directo entre memorias, sino que la comunicación se realiza por paso de mensajes.

La transferencia de los datos se realiza a través de la red de interconexión que conecta un subconjunto de procesadores (un computador en sí) con otro subconjunto (otro computador). La transferencia de unos procesadores a otros se realiza por tanto por múltiples transferencias entre procesadores conectados dependiendo del establecimiento de dicha red.

Dado que la memoria está distribuida entre los diferentes elementos de proceso, estos sistemas reciben el nombre de distribuidos. Por otra parte, estos sistemas son débilmente acoplados, ya que los módulos funcionan de forma casi independiente unos de otros.

En función del grado de distribución o ámbito de estos sistemas, podemos hablar de multicomputación de ámbito local (los computadores se encuentran conectados entre sí por medio de un medio físico o cable, cuyo ancho de banda habrá que maximizar) o multicomputación de ámbito global (los computadores se encuentran dispersos geográficamente, conformando una red)

Pero la **clasificación** más habitual para los sistemas multicomputador es qué principio premian, si paralelización o distribución de tareas.

- Si la solución premia la **paralelización** de tareas antes que la distribución, más habitual en el ámbito local, estamos ante una solución **CLUSTER**
- Si la solución premia la **distribución** de tareas antes que la paralelización, más habitual en ámbito global, estamos ante una solución **GRID**

3.1 Arquitectura Clúster


Un Clúster es un tipo de sistema de procesamiento paralelo o distribuido, que consiste en un grupo de computadores independientes trabajando unidas como si fueran un único recurso computacional integrado.

Es un tipo de arquitectura hardware **paralela y distribuida**, en un ámbito local, en la que premia la paralelización, y a continuación la distribución. El conjunto de ordenadores independientes e interconectados de la forma más eficiente posible (medio físico o cable de alto ancho de banda) consiguen operar de forma conjunta, dando como resultado un único recurso computacional virtual.

Cada uno de los nodos del clúster podrá ser un sistema mono o multiprocesador (PCs, estaciones de trabajo, SMPs...) con memoria, gestión de I/O y sistema operativo propios.

Los nodos del clúster podrán estar dispuestos en un mismo armario o estar físicamente distribuidos, separados e interconectados por medio de una red de área local (LAN).

Un clúster de nodos interconectados en una LAN podrá ser utilizado por usuarios y aplicaciones como si fuera un sistema virtual único. Sistemas de este tipo proporcionan un medio eficiente en coste para conseguir características y beneficios (servicios rápidos y de confianza) que históricamente sólo se habían podido conseguir por medio de sistemas más caros y propietarios de memoria compartida.



3.1.1 Componentes

Los componentes principales de un clúster son los mostrados en la tabla

Componente del clúster	Descripción
Nodo	Los nodos de un clúster podrán ser un grupo heterogéneo de sistemas, cada uno de ellos con un sistema operativo distinto, siempre que esté disponible para cada una de las parejas tipo de máquina/sistema operativo el correspondiente driver del clúster (en caso de SSI a nivel de Aplicación). Cada uno de los nodos del clúster podrá operar colectivamente, como un recurso computacional integrado, o podrá operar como un recurso individual. No existe por tanto dedicación exclusiva de los nodos, si bien no se podrá controlar en ninguno de los nodos el porcentaje de procesamiento que se dedica al clúster y el porcentaje dedicado al procesamiento individual. Las distintas tareas compiten por recursos en el scheduling de tareas del sistema operativo
Red de interconexión de altas prestaciones	Las necesidades de comunicación de las aplicaciones distribuidas son muy variadas, y van desde la comunicación fiable punto a punto a la difusión no fiable. Se deberán soportar diversos protocolos para implementar todos los tipos de comunicación necesarios. Por un lado, se proporcionan los servicios de comunicación básicos, necesarios para transportar la información administrativa y de usuarios del clúster. Estos servicios determinarán importantes parámetros de calidad del servicio del clúster, tales como la latencia, el ancho de banda, la fiabilidad o la tolerancia a fallos. Los servicios de red se diseñan típicamente en forma de una pila de protocolos. En sistemas divididos en capas de este tipo, cada capa de protocolo de la pila proporciona una serie de servicios a las capas superiores, utilizando los servicios que le proporciona la capa inmediatamente inferior. El ejemplo clásico de esta arquitectura de red es la torre de siete capas ISO OSI y la arquitectura de protocolos TCP/IP.

Componente del clúster	Descripción
Middleware del clúster	Si un grupo de computadores interconectados se disponen para dar la apariencia de un recurso unificado, decimos que este grupo tiene una imagen de recurso único, Single System Image (SSI). La SSI de un clúster es generada por la capa de middleware que se dispone entre el sistema operativo y el entorno de usuario. Además, esta capa middleware se encarga, por medio de la System Availability Infrastructure, de gestionar una serie de servicios que aseguran la alta disponibilidad del clúster, tales como la recuperación automática tras errores y el balanceo de carga.

3.1.2 Servicios de Middleware

Los servicios de middleware (SSI y System Availability Infrastructure) pueden ser proporcionados por una o varias de las siguientes capas:

- **SSI Hardware:** La capa lógica de gestión del clúster se encuentra implementada por medio de una representación única de circuitos hardware. Estas implementaciones son las que consiguen mayor eficiencia y velocidad, pero son altamente costosas, propietarias y nada escalables.
- **SSI a nivel de Kernel del Sistema Operativo:** El/los sistema/s operativo/s instalado/s en los nodos del clúster se modifica para que, dentro de las rutinas internas de su kernel, incluya los procesos de virtualización del clúster. Algunas de las actividades que se deben añadir al kernel, propias de la gestión a bajo nivel del clúster, son:
 - Gang scheduling: algoritmo que distribuye el trabajo entre los distintos nodos del clúster, de forma que el resultado sea equitativo
 - Gestión de usuarios del clúster.
 - Administración de recursos del clúster
 - Seguridad y autenticación.

Esta implementación es escalable, y menos costosa que la anterior. Ejemplos: Scyld Beowulf, Solaris MC, Windows Server 2003.

- **SSI a nivel de Aplicación:** Una vez tenemos todos los nodos que van a formar el clúster cada uno con su sistema operativo instalado y configurado, instalamos en cada uno de ellos un módulo software que añade la lógica y las rutinas necesarias para formar el SSI, de forma que podamos virtualizar el clúster. Para poder utilizar esta opción, será necesario que tengamos el módulo software adecuado a cada pareja tipo de procesador/sistema operativo presente en los nodos del clúster a formar.

Esta es la solución menos eficiente, pero la más escalable y barata de todas

Ejemplo: Iniciativa Kimberlite, módulo adicional de Linux Virtual Server, Windows Cluster Server (para nodos WINTEL, sobre W2K Server Advanced Server o Datacenter Server).

Lo más normal es comenzar con un clúster basado en SSI a nivel de Aplicación e ir introduciendo poco a poco nodos con SSI a nivel de Sistema Operativo (la migración puede hacerse en tiempo de ejecución, para el funcionamiento del clúster no cambia nada, a excepción de la eficiencia).

Ejemplo: Google


Componente del clúster	Descripción
Elección HW	Microprocesador: iTanium o Xeon Memoria: 256 MB (si hay + 1 micro, se va doblando la memoria) Almacenamiento: HD SCSI, solución RAID (RAID-5) Conexión: GigaEthernet
Comunicaciones	2 vías de comunicación, diferente canal para información de datos y de procesamiento (1 bus para SCSI y otro para GigaEthernet, que es lo relacionado con el funcionamiento de clúster)
Software	SO: Linux Red Hat MiddleWare: Cluster Google

3.2 Arquitectura Grid

Arquitectura **distribuida y paralela**, de ámbito extenso geográficamente, en la que se premia la distribución, y a continuación la paralelización. Sus creadores fueron Ian Foster y Carl Kesselman. Su nombre proviene del paradigma de la red eléctrica (power grid).

Se basa en la compartición, selección y agregación de forma dinámica y en tiempo de ejecución de recursos autónomos, distribuidos geográficamente, dependiendo de criterios como la disponibilidad del hardware, la capacidad transaccional, el rendimiento que se pueda aportar a la solución final, el coste y los criterios de calidad del servicio que el demandante pueda proporcionar y exigir.

De esta forma, la red está formada por un conjunto de ordenadores independientes e interconectados que ponen a disposición de la red los excedentes de su procesamiento individual, es decir, los ciclos de reloj de sus CPUs no aprovechados por ellos mismos, sin poder superar un determinado porcentaje de dedicación configurado individualmente en cada nodo. A partir del porcentaje proporcionado por cada nodo, se virtualiza un recurso computacional único.



Mientras que las soluciones basadas en clúster pueden servir para ofrecer servicios de alta disponibilidad y productividades pico, los sistemas basados en grid computing están indicados para atender productividades sostenidas y sostenibles, sin poder nunca superar un determinado umbral.

En estos sistemas se garantiza la escalabilidad como un criterio parametrizable. Es posible definir con qué criterio añadimos cada nuevo nodo a la solución final.

Actualmente, el único criterio que se tiene en cuenta es la capacidad de procesamiento, pero en el futuro, será posible tener en cuenta criterios más finos, referidos a la calidad del servicio.

Además, estos sistemas están dotados de un comportamiento dinámico, según el cual, un determinado programa en ejecución en el sistema puede modificar en tiempo real el dimensionamiento de la grid para adaptarlo a sus necesidades.

3.2.1 Características principales

Las principales **características** de un sistema grid son las siguientes

- Podemos conseguir un máximo aprovechamiento de los nodos (100% de utilización de la CPU).
- Los nodos no tienen que estar dedicados. Además, al contrario que en el caso del clúster, nos aseguramos de que la aportación al Grid no va a sobrepasar un determinado porcentaje de tiempo de procesamiento en cada nodo.
- Son sistemas heterogéneos, en los que podemos encontrar diversos HW y SW.
- La escalabilidad parametrizable es la característica más potente de esta arquitectura.


Arquitectura

Habitualmente se describe la arquitectura del Grid en términos de "capas", ejecutando cada una de ellas una determinada función. Como es habitual en este tipo de enfoque, las capas más altas están más cerca del usuario, en tanto que las capas inferiores lo están de las redes de comunicación.

Empezando por los cimientos, nos encontramos con la capa de red, responsable de asegurar la conexión entre los recursos que forman el Grid.

En la parte más alta está la capa de recursos, constituida por los dispositivos que son parte del Grid: ordenadores, sistemas de almacenamiento, catálogos electrónicos de datos e incluso sensores que se conecten directamente a la red.

En la zona intermedia está la capa de "middleware", encargada de proporcionar las herramientas que permiten que los distintos elementos (servidores, almacenes de datos, redes, etc.) participen de forma coordinada en un entorno Grid unificado.



El middleware, es el auténtico "cerebro" del Grid y se ocupa de las siguientes funciones:

- Encontrar el lugar conveniente para ejecutar la tarea solicitada por el usuario.
- Optimiza el uso de recursos que pueden estar muy dispersos.
- Organiza el acceso eficiente a los datos.
- Se encarga de la autenticación de los diferentes elementos.
- Se ocupa de las políticas de asignación de recursos.
- Ejecuta las tareas.
- Monitoriza el progreso de los trabajos en ejecución.
- Gestiona la recuperación frente a fallos.
- Avisa cuando se haya terminado la tarea y devuelve los resultados.

El ingrediente fundamental del middleware son los metadatos (datos sobre los datos), que contienen, entre otras cosas, toda la información sobre el formato de los datos y dónde se almacenan (a veces en varios sitios distintos).

El middleware está formado por muchos programas software. Algunos de esos programas actúan como agentes y otros como intermediarios, negociando entre sí, de forma automática, en representación de los usuarios del Grid y de los proveedores de recursos.

Los agentes individuales presentan los metadatos referidos a los usuarios, datos y recursos. Los intermediarios se encargan de las negociaciones entre máquinas (M2M) para la autenticación y autorización de los usuarios y se encargan de definir los acuerdos de acceso a los datos y recursos y, en su caso, el pago por los mismos. Cuando queda establecido el acuerdo, un intermediario planifica las tareas de cómputo y supervisa las transferencias de datos necesarias para acometer cada trabajo concreto. Al mismo tiempo, una serie de agentes supervisores especiales optimizan las rutas a través de la red y monitorizan la calidad del servicio.

Por supuesto, todo esto ocurre en un intervalo de tiempo muchísimo menor que el que llevaría a los seres humanos realizar las mismas tareas manualmente.

En la capa superior de este esquema está la capa de aplicación donde se incluyen todas las aplicaciones de los usuarios, portales y herramientas de desarrollo que soportan esas aplicaciones. Esta es la capa que ve el usuario.

Además, en las arquitecturas más comunes del Grid, la capa de aplicación proporciona el llamado "serviceware", que recoge las funciones generales de gestión tales como la contabilidad del uso del Grid que hace cada usuario. (El serviceware está en la capa superior al ser un elemento con el que interactúa el usuario, mientras que el middleware está en una capa "oculta" de la que no debe preocuparse).

Para poder hacer todo lo anterior, las aplicaciones que se desarrollen para ser ejecutadas en un PC concreto tendrán que adaptarse para poder invocar los servicios adecuados y utilizar los protocolos correctos. Igual que las aplicaciones que inicialmente se crearon para funcionar aisladamente se adaptan para poder ser ejecutadas en un navegador Web, el Grid requerirá que los usuarios dediquen cierto esfuerzo a "GRIDizar" sus aplicaciones.

Sin embargo, una vez adaptadas al Grid, miles de usuarios podrán usar las mismas aplicaciones, utilizando las capas de middleware para adaptarse a los posibles cambios en el tejido del Grid.

Como **aplicaciones** que pueden sacar el máximo partido de este tipo de soluciones podemos citar a modo de ejemplo:

- Localización dinámica de recursos (máquinas con excedente).
- Optimización del acceso a datos, mapeando las estructuras de datos en cachés temporales locales (directorios).
- Autenticación del usuario (usr/pwd, certificados...).
- Monitorización de tareas y procesos desde cualquier nodo de la red, siempre que el usuario tenga permisos.
- Las máquinas se encuentran en situación paritaria.
- Si es posible, se paraleliza. Lo fundamental es la distribución de procesos débilmente acoplados.

A continuación, se muestran **ejemplos de las soluciones Grid** más importantes a nivel mundial, ordenadas por capacidad de computación. Como se parecía, los valores alcanzados no distan mucho de los expuestos anteriormente para los superordenadores del TOP500, siendo valores sostenidos y medios

Rank	Sistema	TFlop/seg
1	Folding@home	11.400
2	BOINC	9.200
3	MilkyWay@Home	1.600
4	SETI@Home	730
5	Einstein@Home	210