

Temario para la preparación
de la Oposición al Cuerpo Superior
de Sistemas y Tecnologías
de la Información
de la Administración del Estado.

TEMAS ESPECÍFICOS – BLOQUE B

II. Tecnología básica

Tema 70. Inteligencia Artificial: Finalidad y clasificación:
Machine Learning, deep learning, NLP, visión artificial,
sistemas expertos, robótica, y agentes inteligentes.
Aspectos éticos

AUTORA: Beatriz Puerta Hoyas

REVISORA: Meritxell Maider Díaz Coque

Creación: Junio 2026

ÍNDICE

1	INTELIGENCIA ARTIFICIAL: CONCEPTO, EVOLUCIÓN Y FINALIDAD Y RELEVANCIA ACTUAL	6
1.1	CONCEPTO Y DEFINICIONES DE INTELIGENCIA ARTIFICIAL	6
1.2	ANTECEDENTES Y EVOLUCIÓN HISTÓRICA	6
1.2.1	ANTECEDENTES Y NACIMIENTO DE LA DISCIPLINA	6
1.2.2	PRIMERA ETAPA: IA SIMBÓLICA Y OPTIMISMO FUNDACIONAL.....	6
1.2.3	SEGUNDA ETAPA: SISTEMAS EXPERTOS Y PRIMEROS INVIERNOS DE LA IA	7
1.2.4	TERCERA ETAPA: RESURGIMIENTO DEL <i>MACHINE LEARNING</i> (APRENDIZAJE AUTOMÁTICO) Y DE LAS REDES NEURONALES	7
1.2.5	CUARTA ETAPA: <i>DEEP LEARNING</i> E IA GENERATIVA	7
1.3	FINALIDAD Y RELEVANCIA ACTUAL DE LA INTELIGENCIA ARTIFICIAL	8
1.4	RESUMEN DEL APARTADO.....	8
2	CLASIFICACIÓN Y ENFOQUES DE LA INTELIGENCIA ARTIFICIAL	10
2.1	CLASIFICACIÓN POR CAPACIDADES: INTELIGENCIA ARTIFICIAL DÉBIL Y FUERTE	10
2.2	CLASIFICACIÓN POR ENFOQUES: SIMBÓLICO, ESTADÍSTICO Y CONEXIONISTA ...	10
2.3	CLASIFICACIÓN POR ÁMBITOS DE APLICACIÓN	11
2.4	PRINCIPALES RAMAS DE ESTUDIO DE LA INTELIGENCIA ARTIFICIAL	11
2.5	RESUMEN DEL APARTADO.....	12
3	<i>MACHINE LEARNING</i>	13
3.1	DIFERENCIACIÓN ENTRE ALGORITMO Y MODELO DE <i>MACHINE LEARNING</i>	14
3.2	CICLO DE VIDA DEL <i>MACHINE LEARNING</i>	14
3.2.1	PASO 1: OBTENCIÓN DE DATOS	15
3.2.2	PASO 2: LIMPIEZA, PREPARADO Y MANIPULADO DE LOS DATOS	16
3.2.2.1	TRATAMIENTO DE DATOS FALTANTES	17
3.2.2.2	ELIMINACIÓN DE DUPLICADOS.....	17
3.2.2.3	DETECCIÓN DE ANOMALÍAS	18
3.2.2.4	CODIFICACIÓN DE VARIABLES	18
3.2.2.5	SELECCIÓN DE CARACTERÍSTICAS	19
3.2.2.6	NORMALIZACIÓN DE DATOS	19
3.2.3	PASO 3: ENTRENAMIENTO DEL MODELO	19
3.2.3.1	CLASIFICACIÓN DE TIPOS DE <i>MACHINE LEARNING</i>	20
3.2.3.1.1	Aprendizaje supervisado.....	20
3.2.3.1.2	Aprendizaje no supervisado.....	21
3.2.3.1.3	Aprendizaje semi-supervisado	21
3.2.3.1.4	Aprendizaje por refuerzo	22
3.2.3.2	ALGORITMOS DE <i>MACHINE LEARNING</i>	22
3.2.3.2.1	Regresión lineal.....	22
3.2.3.2.2	SVM (<i>Support Vector Machines</i> o Máquinas de Vector Soporte)	23
3.2.3.2.3	kNN (<i>k-Nearest Neighbors</i> o K vecinos más cercanos)	24
3.2.3.2.4	kMedias (<i>k-Means</i>)	25
3.2.3.2.5	<i>k-medoids</i>	25
3.2.3.2.6	DBSCAN (<i>Density-Based Spatial Clustering of Applications with Noise</i>)	26

3.2.3.2.7	Modelos de mezclas gaussianas (<i>Gaussian Mixture Model</i> – GMM).....	26
3.2.3.2.8	Algoritmos genéticos	26
3.2.3.2.9	<i>Naive Bayes</i>	26
3.2.3.2.10	Regresión logística	27
3.2.3.2.11	Árbol de decisión (<i>Decision Tree</i>).....	27
3.2.3.2.12	Métodos de combinación	28
3.2.3.2.12.1	<i>Random Forest</i>	28
3.2.3.2.12.2	<i>ExtraTree (Extremely Randomized Trees)</i>	29
3.2.3.2.12.3	<i>GBM (Gradient Boosting Machine)</i>	29
3.2.3.2.13	Elección del algoritmo de ML.....	29
3.2.3.3	CONSIDERACIONES A LA HORA DE ENTRENAR.....	30
3.2.3.3.1	Ajuste de hiperparámetros	30
3.2.3.3.2	<i>Overfitting, underfitting</i> y regularización.....	31
3.2.4	PASO 4: TESTING O EVALUACIÓN DEL MODELO	32
3.2.4.1	TESTING EN APRENDIZAJE SUPERVISADO	32
3.2.4.2	TESTING EN CLASIFICACIÓN	33
3.2.4.3	TESTING EN REGRESIÓN	34
3.2.4.4	TESTING EN APRENDIZAJE NO SUPERVISADO.....	35
3.2.5	PASO 5: MEJORA CONTINUA	36
3.3	RESUMEN DEL APARTADO.....	36
4	REDES NEURONALES Y DEEP LEARNING	38
4.1	LA NEURONA Y EL PERCEPTRÓN.....	38
4.1.1	APRENDIZAJE DEL PERCEPTRÓN	39
4.1.2	FUNCIONES DE ACTIVACIÓN.....	40
4.2	ARQUITECTURAS DE REDES NEURONALES.....	41
4.2.1	REDES NEURONALES MULTICAPA	41
4.2.2	REDES NEURONALES CONVOLUCIONALES	42
4.2.3	REDES NEURONALES RECURRENTES	43
4.2.4	TRANSFORMADORES	45
4.2.5	ARQUITECTURAS DE IA GENERATIVA	47
4.2.5.1	VARIATIONAL AUTOENCODERS, VAE.....	47
4.2.5.2	REDES ADVERSARIAS GENERATIVAS, GAN.....	48
4.2.5.3	MODELOS DE DIFUSIÓN	48
4.3	RESUMEN DEL APARTADO.....	49
5	PROCESAMIENTO DEL LENGUAJE NATURAL	51
5.1	CONCEPTOS RELEVANTES	52
5.2	FORMAS DE REPRESENTACIÓN LINGÜÍSTICA Y SEMÁNTICA EN EL PLN	52
5.3	TÉCNICAS DE PROCESAMIENTO DEL LENGUAJE NATURAL	53
5.3.1	LLMs	54
5.3.1.1	GENERACIÓN AUMENTADA POR RECUPERACIÓN (RAG)	55
5.4	RESUMEN DEL APARTADO.....	56
6	SISTEMAS EXPERTOS	57
6.1	RESUMEN DEL APARTADO.....	58
7	ROBÓTICA	59
7.1	RESUMEN DEL APARTADO.....	59

8	AGENTES INTELIGENTES	60
8.1	INTELIGENCIA ARTIFICIAL DISTRIBUIDA.....	61
8.2	SISTEMAS MULTIAGENTE	61
8.3	INTELIGENCIA ARTIFICIAL AGÉNTICA	63
8.4	RESUMEN DEL APARTADO.....	64
9	VISIÓN ARTIFICIAL.....	65
9.1	RESUMEN DEL APARTADO.....	66
10	REGLAMENTO EUROPEO DE INTELIGENCIA ARTIFICIAL (RIA)	67
10.1	ÁMBITO OBJETIVO	67
10.2	ÁMBITO SUBJETIVO	67
10.3	DEFINICIONES	68
10.4	REGULACIÓN SISTEMAS DE IA.....	69
10.4.1	PRÁCTICAS DE IA PROHIBIDAS	69
10.4.2	SISTEMAS DE IA DE ALTO RIESGO	70
10.4.3	SISTEMAS DE IA DE RIESGO LIMITADO	72
10.4.4	SISTEMAS DE IA DE RIESGO MÍNIMO.....	73
10.5	REGULACIÓN MODELOS DE IA DE USO GENERAL	73
10.6	GOBERNANZA.....	74
10.7	RÉGIMEN SANCIONADOR.....	75
10.8	RESUMEN DEL APARTADO.....	75
11	IA EN LAS ADMINISTRACIONES PÚBLICAS	77
11.1	EL PAPEL DE LA IA EN LA TRANSFORMACIÓN DEL SECTOR PÚBLICO: CASOS DE USO Y APLICACIONES.....	77
11.2	POLÍTICAS PÚBLICAS.....	78
11.2.1	MARCO EUROPEO.....	79
11.2.2	MARCO NACIONAL	79
11.2.2.1	ESTRATEGIA DE INTELIGENCIA ARTIFICIAL 2024.....	79
11.2.2.2	GOBERNANZA INSTITUCIONAL DE LA IA EN ESPAÑA	80
11.3	RESUMEN DEL APARTADO.....	80
12	ASPECTOS ÉTICOS.....	82
12.1	SESGOS EN INTELIGENCIA ARTIFICIAL	83
12.2	RESUMEN DEL APARTADO.....	84
13	RESUMEN ESQUEMÁTICO	85
14	GLOSARIO	91
15	TEST	95
15.1	PREGUNTAS DE TEST.....	95
15.2	SOLUCIONES A LAS PREGUNTAS DE TEST	98

16	BIBLIOGRAFÍA BÁSICA	99
16.1	BIBLIOGRAFÍA BÁSICA	99
16.2	BIBLIOGRAFÍA PARA AMPLIAR EL TEMA.....	99

1 INTELIGENCIA ARTIFICIAL: CONCEPTO, EVOLUCIÓN Y FINALIDAD Y RELEVANCIA ACTUAL

1.1 Concepto y definiciones de Inteligencia Artificial

La Inteligencia Artificial (IA) es una disciplina orientada al diseño de sistemas capaces de realizar tareas que requieren un tratamiento complejo de la información, como reconocer patrones, aprender a partir de datos, generar contenidos, formular recomendaciones o apoyar decisiones. Se trata de un campo interdisciplinar, en el que confluyen principalmente la informática, las matemáticas, la lógica y la estadística.

En el plano internacional, una de las definiciones hoy más aceptadas es la de la **OCDE** (Organización para la Cooperación y el Desarrollo Económicos), según la cual un sistema de Inteligencia Artificial es un sistema basado en máquinas que, para objetivos explícitos o implícitos, infiere a partir de la entrada que recibe cómo generar salidas, como predicciones, contenidos, recomendaciones o decisiones, que pueden influir en entornos físicos o virtuales. La OCDE añade que los distintos sistemas de IA varían en sus niveles de autonomía y en su capacidad de adaptación tras el despliegue.

Esta definición pone de relieve dos ideas esenciales. La primera es que la Inteligencia Artificial no se identifica con una única técnica, sino que abarca enfoques muy diversos. La segunda es que su rasgo distintivo es la capacidad de inferir y producir resultados útiles a partir de datos, reglas o modelos.

En sentido amplio, por tanto, la Inteligencia Artificial puede entenderse como el conjunto de métodos y técnicas que permiten construir sistemas capaces de percibir información, extraer conocimiento y generar resultados útiles con cierto grado de autonomía. Su finalidad no es reproducir exactamente la mente humana, sino desarrollar herramientas eficaces para resolver problemas en contextos muy diversos.

1.2 Antecedentes y evolución histórica

La evolución histórica de la Inteligencia Artificial no ha seguido una línea recta, sino una sucesión de etapas en las que han cambiado tanto las técnicas dominantes como las expectativas sobre sus posibilidades. No existe una única periodización oficial, pero sí puede distinguirse, de forma bastante aceptada, una secuencia que va desde los antecedentes teóricos y la IA simbólica hasta el *Machine Learning*, el *deep learning* y la IA generativa. La propia OCDE resume esta trayectoria como un paso desde la IA simbólica basada en lógica y reglas, pasando por el “invierno de la IA” de los años setenta y por hitos como Deep Blue, hasta los avances recientes del *Machine Learning*.

1.2.1 Antecedentes y nacimiento de la disciplina

Los antecedentes inmediatos de la Inteligencia Artificial se sitúan en la primera mitad del siglo XX, cuando comenzaron a desarrollarse las bases matemáticas de la computación y los primeros intentos de representar formalmente procesos de razonamiento y aprendizaje. En este contexto destaca el trabajo de **McCulloch y Pitts** de 1943, considerado uno de los primeros modelos matemáticos de red neuronal artificial. También resulta decisiva la aportación de **Alan Turing**, que en 1950 formuló la conocida pregunta sobre si las máquinas pueden pensar y propuso el criterio práctico que después se conocería como **test de Turing**.

El nacimiento formal de la disciplina suele situarse en 1956, con la **Dartmouth Summer Research Project on Artificial Intelligence**, organizada por **John McCarthy**. Ese encuentro se considera el punto de partida institucional del campo, porque en él se consolidó el uso del término *artificial intelligence* y se formuló la idea de que los distintos aspectos de la inteligencia podrían describirse con suficiente precisión como para ser simulados por una máquina.

1.2.2 Primera etapa: IA simbólica y optimismo fundacional

Durante las décadas de 1950 y 1960 predominó la llamada **IA simbólica** o **clásica**, basada en la idea de que la inteligencia podía reproducirse mediante símbolos, reglas lógicas y procedimientos de inferencia. En esta etapa se desarrollaron algunos de los primeros programas emblemáticos de la disciplina, como **Logic Theorist**, presentado en 1956 por **Newell, Simon y Shaw**, y **General Problem**

Solver (GPS), cuyo desarrollo comenzó en 1957. Ambos buscaban resolver problemas mediante procedimientos heurísticos y razonamiento formal.

En paralelo, el enfoque conexionista avanzó con el **perceptrón** de **Frank Rosenblatt**, investigado desde 1957. Este trabajo fue importante porque mostró que una red sencilla podía aprender ciertos patrones a partir de ejemplos, aunque todavía con limitaciones notables. En conjunto, esta primera etapa estuvo marcada por un gran optimismo: se pensó que la inteligencia humana podría reproducirse en un plazo relativamente corto, algo que más tarde se reveló excesivamente ambicioso.

1.2.3 Segunda etapa: sistemas expertos y primeros inviernos de la IA

A medida que se comprobó que los problemas reales eran mucho más complejos de lo previsto, la investigación se fue orientando hacia dominios más concretos. Surgieron así los **sistemas expertos**, que constituyeron una de las aplicaciones más exitosas de la IA en las décadas de 1960, 1970 y 1980. Entre ellos destacan **DENDRAL**, iniciado en 1965 para el análisis de compuestos químicos, y **MYCIN**, cuyo desarrollo comenzó en 1972 para apoyar el diagnóstico de infecciones. Ambos demostraron que una máquina podía producir resultados valiosos si disponía de una base de conocimientos bien construida y de reglas de inferencia adecuadas.

Sin embargo, junto a esos avances aparecieron también límites claros: altos costes de desarrollo, dificultad para mantener y ampliar la base de conocimiento, fragilidad fuera del dominio previsto y resultados más modestos de lo que se había prometido. Estas dificultades, unidas a unas expectativas excesivas, dieron lugar a los conocidos “**inviernos de la IA**”, es decir, etapas de menor financiación y de enfriamiento del entusiasmo inicial. La OCDE sitúa expresamente esta fase en la evolución histórica de la disciplina.

1.2.4 Tercera etapa: resurgimiento del *Machine Learning* (aprendizaje automático) y de las redes neuronales

El siguiente gran cambio vino del avance del **Machine Learning (aprendizaje automático)** y del resurgir de las **redes neuronales**. Frente a los sistemas basados principalmente en reglas explícitas, estos nuevos enfoques se apoyaron cada vez más en datos y en modelos capaces de ajustar sus parámetros a partir de ejemplos. Un hito esencial fue el trabajo de **Rumelhart, Hinton y Williams** de **1986** sobre la **retropropagación del error**, que permitió entrenar redes multicapa con mucha mayor eficacia y abrió la puerta al desarrollo posterior del *deep learning*.

En los años noventa, la Inteligencia Artificial volvió a atraer una gran atención pública con **Deep Blue**, el sistema de IBM que en 1997 derrotó a Garry Kasparov en un match de seis partidas y se convirtió en la primera máquina en vencer a un campeón mundial de ajedrez bajo controles de tiempo estándar de torneo. Aunque se trataba de un sistema muy especializado, su victoria tuvo un gran valor simbólico y mostró hasta qué punto los sistemas computacionales podían superar a expertos humanos en tareas estratégicas bien definidas.

1.2.5 Cuarta etapa: *deep learning* e IA generativa

La etapa contemporánea se inició en la década de 2010 con el auge del **aprendizaje profundo** o *deep learning*. Este avance fue posible por la combinación de grandes volúmenes de datos, mayor capacidad de cómputo y nuevas arquitecturas neuronales. Un momento especialmente importante fue **AlexNet** en 2012, trabajo que mostró un salto notable en clasificación de imágenes y se convirtió en referencia del despegue moderno de las redes neuronales profundas.

Un nuevo cambio de gran alcance se produjo en **2017** con la arquitectura **Transformer**, presentada en el artículo *Attention Is All You Need*. Su importancia fue decisiva para el procesamiento del lenguaje natural y para el desarrollo posterior de los grandes modelos fundacionales. Sobre esta base se construyó la expansión reciente de la **IA generativa**, que alcanzó una difusión masiva en **2022** con el lanzamiento de **ChatGPT**. Desde entonces, la Inteligencia Artificial ha pasado a ocupar un lugar central en el debate económico, jurídico, educativo y administrativo.

Desde 2023, esta etapa se ha caracterizado por la rápida expansión de los **modelos fundacionales**, por la generalización de sistemas **multimodales** y por el avance de la llamada **IA agéntica**, orientada a ejecutar secuencias de acciones para alcanzar objetivos complejos. El *AI Index 2025* destaca, además, tres tendencias especialmente relevantes en 2024 y comienzos de 2025: la mejora muy rápida del rendimiento en nuevos *benchmarks*, el acercamiento de los modelos de pesos abiertos a los

modelos cerrados más avanzados y la creciente convergencia entre los sistemas de frontera desarrollados por distintos proveedores. Desde 2024 se observa una fase de consolidación institucional y regulatoria, especialmente en la Unión Europea: el **Reglamento de IA o AI Act**¹ entró en vigor el 1 de agosto de 2024, comenzó a aplicarse parcialmente en 2025 y prevé su aplicabilidad general el 2 de agosto de 2026, con reglas específicas para modelos de propósito general y para la transparencia de determinados contenidos generados por IA.

1.3 Finalidad y relevancia actual de la Inteligencia Artificial

La finalidad general de la Inteligencia Artificial es dotar a los sistemas informáticos de capacidad para tratar información compleja y producir resultados útiles en contextos en los que una programación rígida resulta insuficiente. En la práctica, la IA permite reconocer patrones, detectar eventos, realizar predicciones, apoyar la interacción entre personas y máquinas, optimizar decisiones y razonar sobre situaciones complejas. La **OCDE** incluye expresamente entre las tareas características de los sistemas de IA el reconocimiento, la detección de eventos, la predicción, el soporte a la interacción, la optimización orientada a objetivos y el razonamiento con estructuras de conocimiento.

Desde una perspectiva funcional, la Inteligencia Artificial persigue varias finalidades concretas. En primer lugar, **automatizar tareas cognitivas** que antes requerían intervención humana, como clasificar documentos, interpretar imágenes o responder consultas. En segundo lugar, **inferir o predecir resultados** a partir de datos históricos o de información del entorno. En tercer lugar, **apoyar la toma de decisiones**, ofreciendo recomendaciones, prioridades o escenarios posibles. En cuarto lugar, **optimizar procesos y recursos**, por ejemplo, mediante asignación de medios, secuenciación de tareas o búsqueda de la mejor solución disponible. Finalmente, la IA permite también **generar contenidos**, como texto, imagen, audio o código, en respuesta a instrucciones o a un contexto previo.

La relevancia actual de la Inteligencia Artificial deriva de su carácter transversal. La OCDE señala que la IA está transformando economías y sociedades, y que promete generar ganancias de productividad, mejorar el bienestar y ayudar a afrontar retos globales. **En consecuencia, ya no puede considerarse una tecnología experimental o restringida a la investigación, sino una capacidad incorporada a productos, servicios y procesos de muy distinta naturaleza.**

A esa dimensión tecnológica se une una creciente relevancia institucional y regulatoria. En la Unión Europea, la aprobación del **Reglamento de IA** pone de manifiesto que la Inteligencia Artificial no es hoy solo una cuestión técnica, sino también jurídica, organizativa y ética.

1.4 Resumen del apartado

Concepto Inteligencia Artificial: La IA es la disciplina que crea sistemas capaces de tratar información compleja y generar resultados útiles con cierto grado de autonomía. Puede: reconocer patrones, aprender de datos, predecir, recomendar, decidir y/o generar contenidos.

¹ Aunque a veces se traduzca de forma divulgativa como “**Ley de Inteligencia Artificial de la UE**”, en rigor se trata del **Reglamento (UE) 2024/1689**, por lo que es preferible hablar de **Reglamento de IA o AI Act**. Además, no debe confundirse con el reglamento como norma del ordenamiento jurídico español, ya que se trata de un **reglamento de la Unión Europea**, con naturaleza y posición propias en el sistema de fuentes.

Etapa	Fechas	Idea clave	Hitos
Antecedentes	1943-1950	Bases teóricas de la IA	McCulloch y Pitts (1943), Turing (1950)
Nacimiento de la IA	1956	Inicio formal de la disciplina	Dartmouth (1956)
IA simbólica	años 1950-1960	Inteligencia basada en reglas, lógica y símbolos	Logic Theorist (1956), GPS (1957), perceptrón (1957)
Sistemas expertos e inviernos	años 1960-1980	Aplicación a dominios concretos; crisis por límites técnicos	DENDRAL (1965), MYCIN (1972), inviernos de la IA (años 70 y 80)
<i>Machine Learning</i> y redes neuronales	años 1980-1990	Aprendizaje a partir de datos	retropropagación (1986), Deep Blue (1997)
<i>Deep learning</i> e IA generativa	2010-actualidad	Redes profundas, <i>transformers</i> y modelos generativos	AlexNet (2012), Transformer (2017), ChatGPT (2022)
Expansión y regulación	2023-2026	Modelos fundacionales, multimodalidad, IA agéntica y regulación	<i>AI Act</i> : vigor (2024), aplicación parcial (2025), general (2026)

Tabla 1. Evolución de la IA

2 CLASIFICACIÓN Y ENFOQUES DE LA INTELIGENCIA ARTIFICIAL

Una vez expuestos el concepto, la evolución y la finalidad de la Inteligencia Artificial, resulta necesario abordar sus fundamentos y principales criterios de clasificación. Esta aproximación permite ordenar un campo muy amplio y heterogéneo, en el que conviven enfoques teóricos distintos, técnicas diversas y aplicaciones orientadas a problemas muy diferentes. Clasificar la Inteligencia Artificial no solo facilita su estudio, sino que también ayuda a comprender mejor el alcance real de sus capacidades y sus límites actuales.

2.1 Clasificación por capacidades: Inteligencia Artificial débil y fuerte

La Inteligencia Artificial suele clasificarse, desde un punto de vista teórico, en Inteligencia Artificial débil e Inteligencia Artificial fuerte. La Inteligencia Artificial débil, también denominada IA estrecha o especializada, es aquella diseñada para realizar tareas concretas dentro de un ámbito limitado, como el reconocimiento de voz, la recomendación de contenidos, la detección de fraude o la traducción automática. Su funcionamiento puede ser muy eficaz e incluso superar al ser humano en tareas específicas, pero carece de comprensión general, conciencia y capacidad autónoma para transferir su conocimiento a cualquier problema fuera del dominio para el que ha sido desarrollada.

Por el contrario, la Inteligencia Artificial fuerte, también llamada Inteligencia Artificial general, alude a un sistema hipotético capaz de reproducir de forma amplia las capacidades cognitivas humanas, comprendiendo, razonando, aprendiendo y adaptándose a contextos muy diversos con un grado de autonomía comparable al de una persona. Este concepto implicaría no solo resolver tareas concretas, sino también entender su significado, aplicar conocimiento adquirido en un ámbito distinto y desenvolverse de manera flexible ante situaciones nuevas. Aunque constituye una referencia frecuente en la reflexión filosófica y tecnológica sobre la IA, en la actualidad no existe ningún sistema que pueda considerarse verdadera Inteligencia Artificial fuerte.

En consecuencia, el estado actual de la disciplina se corresponde con el desarrollo de sistemas de Inteligencia Artificial débil, cada vez más potentes, versátiles y capaces de integrarse en múltiples ámbitos de actividad. Incluso los modelos más avanzados de aprendizaje profundo y los grandes modelos de lenguaje, pese a su elevada capacidad de generación y adaptación aparente, siguen siendo sistemas especializados que operan a partir de patrones aprendidos en los datos y no manifestaciones de una inteligencia general plena. Esta distinción resulta relevante, tanto desde el punto de vista técnico como ético, porque permite diferenciar entre las capacidades reales de la tecnología disponible y las expectativas futuras asociadas a su evolución.

2.2 Clasificación por enfoques: simbólico, estadístico y conexionista

La Inteligencia Artificial puede clasificarse también en función del enfoque utilizado para representar el conocimiento y resolver problemas. Desde esta perspectiva, suele distinguirse entre enfoque simbólico, enfoque estadístico y enfoque conexionista. Esta clasificación resulta especialmente útil porque permite entender que la IA no ha seguido una única vía de desarrollo, sino que ha evolucionado a través de paradigmas distintos, cada uno con sus propios fundamentos, ventajas y limitaciones.

- El **enfoque simbólico** fue el predominante en las primeras etapas de la Inteligencia Artificial y se basa en representar explícitamente el conocimiento mediante símbolos, reglas lógicas y relaciones formales. En este paradigma, el sistema opera manipulando conceptos definidos de antemano, siguiendo estructuras del tipo “si... entonces...”, ontologías o motores de inferencia. Su principal fortaleza radica en la explicabilidad y en la facilidad para comprender cómo se alcanza una conclusión, lo que lo hizo especialmente adecuado para sistemas expertos y entornos bien estructurados. Sin embargo, presenta dificultades para desenvolverse en contextos ambiguos, cambiantes o con gran volumen de datos no estructurados.
- El **enfoque estadístico**, por su parte, se centra en extraer patrones a partir de los datos y en modelar la incertidumbre mediante métodos probabilísticos y técnicas de aprendizaje automático. En lugar de depender exclusivamente de reglas definidas a mano, estos sistemas

aprenden regularidades observando ejemplos y ajustando sus modelos conforme a la información disponible. Este paradigma ha impulsado el desarrollo del *Machine Learning* moderno y ha resultado especialmente eficaz en tareas de clasificación, predicción, recomendación y análisis de datos.

Finalmente, el enfoque **conexionista**, estrechamente ligado a las redes neuronales artificiales, trata de imitar de forma simplificada el funcionamiento del cerebro mediante estructuras formadas por nodos interconectados que aprenden ajustando sus pesos internos. Este enfoque constituye la base del *deep learning* y ha permitido avances muy significativos en visión artificial, procesamiento del lenguaje natural, reconocimiento de voz e IA generativa. En la práctica, los sistemas actuales suelen combinar elementos de estos tres enfoques, aprovechando sus fortalezas de manera complementaria.

2.3 Clasificación por ámbitos de aplicación

La Inteligencia Artificial también puede clasificarse según el ámbito en el que se aplica, ya que sus técnicas y herramientas se orientan a resolver problemas muy distintos en función del contexto de uso. Esta clasificación resulta útil porque permite apreciar el carácter transversal de la IA y su capacidad para integrarse en sectores muy diversos, desde la actividad empresarial hasta los servicios públicos. Aunque en la práctica muchos sistemas combinan varios ámbitos a la vez, pueden señalarse, entre otros, los siguientes:

- **Ámbito industrial y logístico:** incluye aplicaciones relacionadas con la automatización de procesos, el mantenimiento predictivo, el control de calidad, la optimización de rutas, la gestión de almacenes y la planificación de la producción.
- **Ámbito sanitario:** comprende sistemas de apoyo al diagnóstico, análisis de imágenes médicas, predicción de riesgos, descubrimiento de fármacos, monitorización de pacientes y asistencia clínica.
- **Ámbito económico y financiero:** agrupa usos como la detección de fraude, la evaluación de riesgos, la concesión de crédito, la predicción de mercados, la automatización de operaciones y la atención al cliente.
- **Ámbito educativo:** abarca la personalización del aprendizaje, los sistemas de tutoría inteligente, la corrección automática, la analítica del aprendizaje y la generación de recursos didácticos.
- **Ámbito administrativo y de los servicios públicos:** incluye la automatización de expedientes, la asistencia a la ciudadanía, el análisis documental, la ayuda a la toma de decisiones y la mejora de la eficiencia en la gestión pública.
- **Ámbito de la seguridad y la defensa:** engloba aplicaciones en ciberseguridad, videovigilancia inteligente, detección de amenazas, análisis de riesgos y apoyo a operaciones complejas.
- **Ámbito del lenguaje y la comunicación:** comprende traductores automáticos, asistentes virtuales, *chatbots*, sistemas de resumen, análisis de sentimientos y generación automática de texto.
- **Ámbito de la visión artificial y la percepción:** se refiere al reconocimiento de imágenes, detección de objetos, identificación biométrica, conducción autónoma y análisis de vídeo.
- **Ámbito de la robótica y los sistemas autónomos:** integra robots industriales, robots de servicio, drones, vehículos autónomos y otros sistemas capaces de percibir su entorno y actuar sobre él.

Esta clasificación pone de manifiesto que la Inteligencia Artificial no constituye una tecnología limitada a un único sector, sino un conjunto de técnicas aplicables a problemas muy variados. Precisamente por ello, su estudio debe completarse no solo con una visión técnica, sino también con una reflexión sobre sus efectos organizativos, sociales, jurídicos y éticos en cada uno de los ámbitos en los que se despliega.

2.4 Principales ramas de estudio de la Inteligencia Artificial

La Inteligencia Artificial comprende diversas ramas de estudio que, aunque pueden distinguirse con fines didácticos, mantienen una relación constante entre sí y suelen combinarse en los sistemas reales. Cada una de estas ramas aborda un tipo particular de problema o desarrolla una capacidad específica, como aprender a partir de datos, razonar con reglas, comprender el lenguaje, interpretar imágenes o

actuar en el mundo físico. Entre las principales ramas de la Inteligencia Artificial pueden destacarse las siguientes:

- **Machine Learning o aprendizaje automático:** rama centrada en el desarrollo de algoritmos capaces de aprender patrones a partir de los datos sin que sea necesario programar explícitamente todas las reglas de decisión. Permite resolver problemas de clasificación, regresión, predicción, segmentación o recomendación.
- **Redes neuronales y Deep Learning:** subcampo del aprendizaje automático inspirado, de manera simplificada, en la estructura de las neuronas biológicas. Utiliza capas de neuronas artificiales para aprender representaciones complejas de los datos y constituye la base de muchos avances recientes en lenguaje, imagen, voz e IA generativa.
- **Procesamiento del Lenguaje Natural (PLN o NLP):** rama orientada a que las máquinas puedan analizar, comprender, interpretar y generar lenguaje humano, tanto escrito como hablado. Incluye tareas como traducción automática, resumen, extracción de información, análisis de sentimientos y asistentes conversacionales.
- **Visión por computador o visión artificial:** disciplina que persigue que los sistemas puedan obtener información útil a partir de imágenes, vídeos y otras señales visuales. Comprende tareas como clasificación de imágenes, detección de objetos, segmentación, reconocimiento facial, inspección industrial y apoyo al diagnóstico médico por imagen.
- **Sistemas expertos:** rama clásica de la Inteligencia Artificial basada en la representación explícita del conocimiento mediante reglas y en la aplicación de motores de inferencia que emulan el razonamiento de especialistas humanos en dominios concretos.
- **Robótica:** ámbito que integra Inteligencia Artificial con sensores, control y actuación física, permitiendo que máquinas y dispositivos perciban el entorno, planifiquen acciones y ejecuten tareas en el mundo real de forma autónoma o semiautónoma.
- **Agentes inteligentes:** rama que estudia sistemas capaces de percibir su entorno, razonar sobre él y actuar de forma orientada a objetivos. Se trata de una noción central para entender asistentes autónomos, sistemas multiagente, planificación automática y aprendizaje por refuerzo.

No obstante, estas ramas no deben entenderse como compartimentos estancos, ya que en la práctica interactúan de forma continua y se refuerzan mutuamente. Así, un robot puede incorporar visión por computador para percibir su entorno, redes neuronales para procesar la información captada, aprendizaje automático para mejorar su comportamiento y procesamiento del lenguaje natural para comunicarse con las personas. Del mismo modo, los sistemas actuales más avanzados suelen integrar varias de estas ramas a la vez, lo que pone de manifiesto que la Inteligencia Artificial es un campo interdisciplinar, dinámico y profundamente interconectado.

A continuación, en este tema vamos a profundizar en las distintas ramas.

2.5 Resumen del apartado

Clasificación y enfoques de la IA:

- IA fuerte e IA débil.
- Enfoque simbólico, estadístico y conexionista.
- Ámbitos de aplicación: Industria, sanitario, económico, educativo, AAPP, etc.
- Ramas de estudio:
 - *Machine Learning*.
 - Redes neuronales.
 - NLP.
 - Visión artificial.
 - Sistemas expertos.
 - Robótica.
 - Agentes inteligentes.

3 MACHINE LEARNING

El **aprendizaje automático o Machine Learning** es una rama dentro de la Inteligencia Artificial dedicada a replicar la forma de aprendizaje humano a base de práctica, ensayo y error, de manera que puede reconocer ciertos patrones en los datos de entrada gracias a su observación, crear modelos para hacer predicciones futuras en nuevos datos o tomar decisiones sin ser explícitamente programadas para ello. Así, se permite un alto nivel de adaptabilidad a nuevas situaciones de manera independiente, es decir, ir aprendiendo de la experiencia. Posiblemente una de las mejores definiciones la introdujo Arthur Samuel en 1959 estableciendo que “*el aprendizaje automático es el campo de estudio que da a los ordenadores la habilidad de aprender sin ser programados de forma explícita*”, lo que supone combinar ciencias de la computación con la Inteligencia Artificial para el aprendizaje autónomo de las máquinas, muy estrechamente ligado a la identificación y detección de patrones.

El objetivo es que los programas sean capaces de aprender a realizar diversas operaciones y tareas, con determinadas prestaciones, a partir de la experiencia, para adquirir el conocimiento propio de un dominio concreto. Para ello, se emplean distintos mecanismos, denominados algoritmos, combinados con modelos estadísticos que permiten procesar los datos de entrada para su análisis, realizar inferencias e identificar comportamientos recurrentes que faciliten la toma de decisiones. Para evaluar la calidad del proceso de inferencia y del reconocimiento de patrones, es necesario medir los resultados, aunque para ello sigue siendo necesaria la intervención humana.




Figura 1: Ejemplo de sistema de Machine Learning. Elaboración propia.

Las tareas más habituales son: clasificación, regresión, predicción y agrupamiento.




Figura 2: Diagrama de relación entre aprendizaje automático y aprendizaje profundo. Elaboración propia.

3.1 Diferenciación entre algoritmo y modelo de *Machine Learning*

Conviene diferenciar entre algoritmo y modelo de *Machine Learning*, ya que ambos conceptos están estrechamente relacionados, pero no significan lo mismo. El algoritmo es el procedimiento o método matemático que se utiliza para aprender a partir de los datos, es decir, la técnica que indica cómo debe ajustarse el sistema durante el entrenamiento; por ejemplo, un árbol de decisión, una regresión logística o una red neuronal. El modelo, en cambio, es el resultado concreto de aplicar ese algoritmo a un conjunto de datos determinado, de modo que constituye la representación ya entrenada capaz de realizar predicciones sobre nuevos casos. En otras palabras, el algoritmo es el método de aprendizaje, mientras que el modelo es el producto final obtenido tras ese aprendizaje.

3.2 Ciclo de vida del *Machine Learning*

El desarrollo de un sistema de *Machine Learning* no consiste únicamente en seleccionar un algoritmo y entrenarlo con unos datos, sino en seguir un proceso ordenado que permita transformar un problema real en un modelo útil, evaluable y capaz de generalizar a situaciones nuevas. Por ello, suele hablarse del ciclo de vida del *Machine Learning* para referirse al conjunto de fases que abarcan desde la obtención y preparación de los datos hasta el entrenamiento, la evaluación y la mejora continua del modelo. Este enfoque resulta esencial, ya que la calidad del sistema final no depende solo del algoritmo elegido, sino también de la adecuación de los datos, del rigor del preprocesado y de la corrección con la que se mida su rendimiento.

De forma general, este ciclo de vida comprende cinco grandes etapas. En primer lugar, la **obtención de los datos**, donde se define el problema, se identifica la variable objetivo y se recopila la información necesaria a partir de fuentes internas o externas. En segundo lugar, la **limpieza, preparación y manipulación de los datos**, fase en la que se corrigen errores, se tratan valores faltantes, se codifican variables y se adaptan los datos para que puedan ser utilizados eficazmente por los algoritmos. A continuación, tiene lugar el **entrenamiento del modelo**, momento en el que se seleccionan técnicas y algoritmos adecuados y se ajustan sus parámetros a partir de los datos disponibles. Posteriormente se realiza el **testing o evaluación del modelo**, con el fin de comprobar hasta qué punto generaliza correctamente sobre datos no vistos. Finalmente, el proceso culmina con la **mejora continua**, que implica monitorizar el comportamiento del sistema, revisar sus errores y actualizarlo cuando cambian los datos, el contexto o los requisitos del problema.



Figura 3: Ciclo de vida *Machine Learning*. Elaboración propia.

Conviene destacar que este ciclo no debe entenderse como una secuencia rígida y lineal, sino como un proceso iterativo. En la práctica, los resultados obtenidos en la evaluación pueden poner de manifiesto deficiencias en la selección de variables, problemas de calidad en los datos o limitaciones del algoritmo empleado, lo que obliga a retroceder y replantear fases anteriores. Así, el *Machine Learning* comparte con la estadística aplicada una idea fundamental: los modelos no se construyen de una vez y para siempre, sino mediante sucesivas revisiones y mejoras orientadas a obtener predicciones cada vez más robustas, útiles y fiables.

3.2.1 Paso 1: Obtención de datos

La obtención de datos constituye la primera fase del ciclo de vida del *Machine Learning* y una de las más determinantes para la calidad del modelo final. En esta etapa se define con precisión qué problema se desea resolver, qué variable objetivo se pretende predecir y qué información puede resultar útil para ello. En consecuencia, no se trata simplemente de reunir datos de forma masiva, sino de seleccionar aquellos que guarden una relación significativa con la tarea planteada y que permitan representar de manera adecuada la realidad sobre la que va a operar el sistema. Una definición imprecisa del problema o una recogida deficiente de la información pueden comprometer todas las fases posteriores, por muy sofisticado que sea el algoritmo utilizado.

Las fuentes de datos pueden ser muy diversas. En unos casos proceden de sistemas internos de información, bases de datos corporativas, formularios, registros administrativos, historiales de actividad o aplicaciones de negocio; en otros, pueden provenir de sensores, dispositivos IoT, servicios web, APIs públicas, repositorios abiertos, procesos de *web scraping* o plataformas digitales. Del mismo modo, los datos pueden almacenarse y organizarse en formatos muy distintos, tales como tablas estructuradas, series temporales, texto, imágenes, audio, vídeo, datos geoespaciales o grafos. Esta diversidad obliga a identificar desde el inicio no solo qué datos están disponibles, sino también en qué formato se presentan, con qué calidad se han recogido y hasta qué punto son adecuados para el objetivo del modelo.

En esta fase resulta esencial distinguir entre la **variable objetivo** (también denominada *target* o etiqueta) y las **características** o *features*. La variable objetivo es aquello que el modelo debe predecir, mientras que las características son las variables de entrada a partir de las cuales el sistema tratará de inferir esa predicción. Así, si se quiere construir un modelo que anticipe si un estudiante aprobará una asignatura, la variable objetivo podría ser “Aprobado”, mientras que entre las características relevantes podrían encontrarse las horas de estudio, la asistencia a clase, las calificaciones previas o incluso comentarios cualitativos expresados en lenguaje natural.

A su vez, las variables que forman parte del *dataset* pueden adoptar distintos tipos de datos, lo que influirá posteriormente en su tratamiento y preprocesado. De forma general, pueden distinguirse las siguientes categorías:

- **Variables numéricas**, que expresan cantidades medibles y pueden ser continuas, como la temperatura o la renta, o discretas, como el número de compras o de incidencias.
- **Variables categóricas**, que representan clases o etiquetas, como “sí/no”, “alto/medio/bajo” o “aprobado/suspenso”.
- **Variables ordinales**, en las que existe un orden entre categorías, aunque no una distancia numérica exacta entre ellas, como niveles de satisfacción o grados de prioridad.
- **Variables de texto**, que contienen lenguaje natural libre, como comentarios de usuarios, correos electrónicos o descripciones.
- **Variables temporales**, vinculadas a fechas y horas, muy frecuentes en series cronológicas, registros de actividad o monitorización.
- **Variables multimedia**, como imágenes, audio o vídeo, especialmente relevantes en visión artificial, reconocimiento de voz o análisis multimodal.

En muchos problemas reales, el *dataset* combina varios de estos tipos de variables, lo que incrementa la riqueza de la información disponible, pero también la complejidad del tratamiento posterior. Por ello, una parte esencial de esta fase consiste en comprender la naturaleza de cada variable y su posible utilidad para el problema de predicción planteado.

Horas de Estudio	Asistencia a Clases (%)	Feedback del Estudiante	Aprobado
2	90	"El examen fue fácil."	Sí
1.5	85	"No entendí el tema."	No
3	95	"Me preparé bien."	Sí
2.5	80	"Necesito más tiempo."	No
4	92	"Estudié mucho."	Sí
3.5	88	"Confío en mi trabajo."	Sí

Figura 4: *Dataset* de ejemplo. Elaboración propia.

En este punto resulta especialmente útil incorporar un ejemplo sencillo de conjunto de datos. Así, en la tabla superior puede mostrarse un pequeño *dataset* orientado a predecir si un estudiante aprobará una asignatura. En dicho ejemplo, cada fila representa un caso histórico y cada columna una variable del problema. La columna "Aprobado" actúa como variable objetivo, mientras que "Horas de estudio", "Asistencia a clases" y "Feedback del estudiante" desempeñan la función de características o variables predictoras. Este tipo de representación permite entender de forma clara cómo se estructura la información que después utilizará el modelo para aprender a partir de ejemplos ya conocidos.

No obstante, la obtención de datos no debe entenderse únicamente como una tarea técnica de recopilación, sino también como una cuestión de calidad estadística y de representatividad. El conjunto de datos disponible constituye, en realidad, una muestra de una población más amplia de situaciones posibles, por lo que conviene preguntarse desde el inicio si esa muestra refleja adecuadamente la casuística real del problema o si deja fuera perfiles, contextos o escenarios relevantes. Si los datos son escasos, sesgados, incompletos o poco variados, el modelo aprenderá una visión parcial de la realidad y tendrá mayores dificultades para generalizar correctamente cuando se enfrente a nuevos casos.

Por ello, una buena obtención de datos no consiste solo en reunir mucha información, sino en reunir información **pertinente, fiable, variada y suficientemente representativa**. En última instancia, la calidad del modelo de *Machine Learning* dependerá en gran medida de la calidad del conjunto de datos sobre el que se construya, lo que justifica que esta primera fase sea considerada uno de los pilares fundamentales de todo el proceso.

3.2.2 Paso 2: Limpieza, preparado y manipulado de los datos

La limpieza, preparado y manipulado de los datos constituye la segunda gran fase del ciclo de vida del *Machine Learning* y tiene como finalidad transformar el conjunto de datos obtenido en la etapa anterior en un material adecuado para el entrenamiento del modelo. En la práctica, los datos brutos rara vez se encuentran listos para ser utilizados directamente, ya que suelen contener errores, valores ausentes, duplicidades, formatos heterogéneos, anomalías o variables expresadas de forma poco apropiada para los algoritmos. Por ello, esta etapa no debe entenderse como una labor accesorio, sino como una fase central del proceso, de cuya calidad dependerá en gran medida la capacidad posterior del modelo para aprender patrones útiles y generalizar correctamente.

La importancia de esta fase se explica por una idea básica del aprendizaje automático: el modelo aprende a partir de ejemplos, de modo que la calidad, coherencia y representatividad de esos ejemplos condicionan directamente el resultado final. Si el *dataset* contiene ruido excesivo, errores sistemáticos o una estructura inadecuada, el sistema tenderá a incorporar esos problemas a su aprendizaje. En cambio, cuando los datos se revisan, depuran y adaptan correctamente, se facilita que el algoritmo identifique relaciones relevantes, reduzca el sesgo inducido por defectos del conjunto de datos y mejore su robustez frente a nuevos casos. En este sentido, esta fase conecta de manera directa con el razonamiento estadístico, ya que antes de modelar resulta necesario comprender cómo son realmente los datos con los que se va a trabajar.

Antes de aplicar transformaciones concretas, suele ser conveniente realizar una exploración descriptiva inicial del conjunto de datos. Esta revisión permite detectar distribuciones desequilibradas, categorías poco frecuentes, valores imposibles, formatos inconsistentes o posibles observaciones atípicas. A partir

de ese diagnóstico previo, se aplican las técnicas de preparación más adecuadas a cada caso, entre las que destacan el tratamiento de datos faltantes, la eliminación de duplicados, la detección de anomalías, la codificación de variables, la selección de características, la normalización de datos y, en problemas de clasificación, el balanceo de clases y el muestreo. En los subapartados siguientes se examinan estas operaciones, que constituyen el núcleo del preprocesado de datos en *Machine Learning*.

3.2.2.1 Tratamiento de datos faltantes

Es habitual que un conjunto de datos presente valores ausentes o incompletos, ya sea por errores en la captura de la información, fallos de sensores, formularios no cumplimentados o problemas en la integración de distintas fuentes. Su tratamiento es importante porque los datos faltantes pueden dificultar el entrenamiento del modelo, distorsionar el análisis previo e introducir sesgos si no se gestionan correctamente.

Antes de decidir cómo actuar, conviene analizar cuántos valores faltan, en qué variables aparecen y si su ausencia sigue algún patrón. En algunos casos, cuando el número de ausencias es reducido, puede optarse por eliminar las filas afectadas; de igual modo, si una variable presenta demasiados valores faltantes, puede resultar preferible descartarla. No obstante, estas decisiones deben adoptarse con prudencia para no perder información relevante ni alterar la representatividad del conjunto de datos.

Entre las principales técnicas de tratamiento de datos faltantes pueden señalarse las siguientes:

- **Eliminación de filas incompletas**, cuando el número de casos afectados es pequeño y su supresión no altera de forma significativa el conjunto de datos.
- **Eliminación de variables**, cuando una columna presenta un volumen muy elevado de valores ausentes y su conservación aporta poco valor al modelo.
- **Imputación simple con media**, adecuada en variables numéricas con pocos valores faltantes y distribuciones relativamente estables.
- **Imputación simple con mediana**, recomendable en variables numéricas con valores atípicos o distribuciones sesgadas.
- **Imputación con moda**, utilizada en variables categóricas, sustituyendo los huecos por la categoría más frecuente.
- **Indicadores de ausencia**, útiles cuando el hecho de que falte un dato puede ser en sí mismo una información relevante para el modelo.
- **Imputación basada en modelos**, apropiada en problemas más complejos, cuando interesa estimar los valores ausentes a partir de la relación con otras variables mediante técnicas como *k*-NN, regresión o árboles.

En definitiva, el objetivo no es solo “rellenar huecos”, sino hacerlo de manera que el *dataset* siga siendo coherente, representativo y útil para el aprendizaje del modelo.

3.2.2.2 Eliminación de duplicados

La eliminación de duplicados consiste en identificar y suprimir registros repetidos dentro del conjunto de datos. Estos duplicados pueden aparecer por errores en la captura de la información, integraciones defectuosas entre distintas fuentes, problemas en procesos de importación o registros almacenados varias veces. Su tratamiento es necesario porque la presencia de observaciones repetidas puede distorsionar el aprendizaje del modelo, al otorgar más peso del debido a ciertos casos y alterar la distribución real de los datos.

El problema de los duplicados no se limita a una cuestión de orden o limpieza formal, sino que puede afectar directamente a la calidad del modelo. Si una misma observación aparece varias veces, el algoritmo tenderá a interpretarla como un patrón más frecuente de lo que realmente es, lo que puede sesgar las probabilidades, ocultar casos menos comunes y afectar al equilibrio entre clases. Este riesgo resulta especialmente relevante en problemas de clasificación, donde una repetición excesiva de determinados ejemplos puede reforzar artificialmente una clase frente a otras.

La detección de duplicados puede realizarse de forma exacta, cuando varias filas coinciden completamente, o de forma aproximada, cuando los registros son muy similares, pero presentan pequeñas diferencias de formato, codificación o escritura. En consecuencia, antes de eliminarlos conviene verificar si se trata realmente de repeticiones no deseadas o de observaciones distintas que

solo parecen similares. En definitiva, eliminar duplicados permite depurar el *dataset*, preservar mejor la representatividad de la muestra y evitar que el modelo aprenda una visión distorsionada de la realidad.

3.2.2.3 Detección de anomalías

La detección de anomalías, también denominada detección de *outliers* o valores atípicos, consiste en identificar observaciones que se apartan de forma significativa del comportamiento habitual de los datos. Estas anomalías pueden deberse a errores de medición, fallos en sensores, problemas durante la adquisición o integración de la información, o bien a casos reales poco frecuentes. Por ello, su detección constituye una fase importante del preprocesado, ya que estos valores pueden distorsionar el análisis descriptivo previo, influir de manera desproporcionada en el entrenamiento y dificultar la capacidad del modelo para generalizar correctamente.

No obstante, conviene actuar con prudencia, ya que no todo valor extremo es necesariamente erróneo. En algunos problemas, los casos raros pueden corresponder a situaciones reales y relevantes, por lo que eliminarlos sin un análisis previo podría empobrecer el conjunto de datos o reducir la sensibilidad del modelo ante escenarios poco frecuentes pero importantes. En consecuencia, la detección de anomalías no debe entenderse como una eliminación automática de valores extremos, sino como un proceso orientado a revisar, interpretar y decidir si esas observaciones deben corregirse, excluirse o conservarse.

Entre las principales técnicas de detección de anomalías pueden señalarse las siguientes:

- **Métodos estadísticos básicos**, basados en medias, desviaciones típicas o puntuaciones *z*, adecuados cuando las variables siguen distribuciones relativamente regulares.
- **Método del rango intercuartílico (IQR)**, útil para detectar valores alejados de la distribución central sin depender tanto de la normalidad de los datos.
- **Análisis visual**, mediante histogramas, diagramas de caja o dispersiones, que permite localizar de forma intuitiva posibles observaciones atípicas.
- **Métodos basados en distancia o densidad**, que identifican puntos aislados respecto al resto de observaciones, como ocurre con técnicas del tipo *Local Outlier Factor*.
- **Métodos basados en aislamiento**, como *Isolation Forest*, que detectan anomalías al comprobar qué observaciones resultan más fáciles de separar del conjunto.
- **Métodos específicos de una clase**, como *One-Class SVM*, empleados cuando se desea modelar qué comportamiento puede considerarse normal y marcar como anómalas las desviaciones.

En definitiva, la detección de anomalías permite depurar el *dataset* y comprender mejor su estructura antes de entrenar el modelo. Su finalidad no es solo eliminar errores, sino también decidir con criterio qué observaciones reflejan ruido o fallos de captura y cuáles representan casos reales que conviene preservar.

3.2.2.4 Codificación de variables

La codificación de variables consiste en transformar aquellas variables que no se encuentran en formato numérico en representaciones que puedan ser procesadas por los algoritmos de *Machine Learning*. Esta operación es necesaria porque la mayoría de los modelos trabajan con números y requieren calcular distancias, similitudes, probabilidades o combinaciones lineales entre variables. Por ello, cuando el conjunto de datos contiene categorías, textos, fechas u otros formatos no numéricos, resulta imprescindible convertir esa información a una forma adecuada sin perder, en la medida de lo posible, su significado.

Esta fase no debe entenderse como una simple conversión mecánica, ya que una codificación inadecuada puede introducir relaciones artificiales entre los datos y perjudicar el aprendizaje del modelo. Así, no es lo mismo codificar una variable categórica sin orden, como el color de un producto, que una variable ordinal, como el nivel de prioridad o satisfacción, donde sí existe una jerarquía entre categorías. Del mismo modo, variables temporales o textuales requieren transformaciones específicas que permitan conservar la información relevante que contienen. En consecuencia, la elección de la técnica de codificación depende del tipo de variable y del uso que vaya a hacerse de ella en el modelo.

3.2.2.5 Selección de características

En muchos problemas de *Machine Learning*, el conjunto de datos disponible contiene un número elevado de variables, pero no todas contribuyen de la misma forma a la predicción. Algunas aportan información útil, otras resultan redundantes y otras apenas añaden valor o incluso introducen ruido. La selección de características consiste precisamente en identificar qué variables deben conservarse para entrenar el modelo y cuáles conviene descartar.

La importancia de esta fase radica en que un exceso de variables no garantiza un mejor rendimiento. Al contrario, cuando el modelo trabaja con información irrelevante o repetitiva, puede aumentar la complejidad del entrenamiento, dificultarse la interpretación de los resultados y crecer el riesgo de sobreajuste. Por ello, seleccionar adecuadamente las características permite reducir la dimensionalidad del problema, simplificar el conjunto de datos y favorecer que el algoritmo aprenda patrones más claros y generalizables.

Conviene señalar, además, que esta operación no equivale a transformar las variables originales en otras nuevas, sino a escoger un subconjunto de las ya existentes.

3.2.2.6 Normalización de datos

La normalización de datos consiste en reescalar las variables numéricas para que queden expresadas en magnitudes comparables. Esta operación resulta importante porque, en muchos conjuntos de datos, unas variables pueden tomar valores muy grandes y otras moverse en escalas mucho más reducidas. Si no se corrige esta diferencia, ciertos algoritmos tenderán a dar más peso a las variables de mayor magnitud, no porque sean más relevantes, sino simplemente por la escala en la que están medidas.

Así, por ejemplo, una variable expresada en miles de euros puede dominar sobre otra medida entre 0 y 1, aunque esta última sea igual o más importante para la predicción. La normalización evita este problema y facilita que el modelo trate las distintas características de forma más equilibrada. Su utilidad es especialmente clara en métodos basados en distancias, similitudes o gradientes, donde la escala de las variables influye directamente en el funcionamiento del algoritmo.

En términos generales, normalizar implica transformar los valores para que se sitúen dentro de un rango común, habitualmente entre 0 y 1, o bien alrededor de una media y una dispersión controladas. Con ello no se altera el significado esencial de la variable, pero sí se adapta su representación para favorecer el aprendizaje del modelo. En consecuencia, la normalización constituye una fase de preparación técnica que, aunque aparentemente simple, puede tener un efecto muy significativo sobre la estabilidad, la rapidez y el rendimiento final del entrenamiento.

3.2.3 Paso 3: Entrenamiento del modelo

Una vez obtenidos y preparados los datos, se alcanza la fase central del ciclo de vida del *Machine Learning*: el entrenamiento del modelo. En esta etapa, el algoritmo seleccionado analiza los ejemplos disponibles con el fin de identificar regularidades, ajustar sus parámetros internos y construir una función capaz de realizar predicciones o clasificaciones sobre casos nuevos. Dicho de otro modo, el modelo “aprende” a partir de los datos, no memorizando simplemente ejemplos concretos, sino tratando de generalizar patrones que puedan resultar útiles fuera del conjunto de entrenamiento.

Esta fase exige, en primer lugar, determinar qué tipo de aprendizaje resulta más adecuado para el problema planteado. No es lo mismo predecir una etiqueta conocida a partir de ejemplos previamente clasificados que descubrir agrupaciones sin etiquetas o diseñar un sistema que aprenda por interacción con un entorno. Del mismo modo, también es necesario decidir qué familia de algoritmos puede adaptarse mejor a la naturaleza de los datos y a la tarea que se pretende resolver. A partir de ahí, el entrenamiento consiste en ajustar el comportamiento del modelo mediante sucesivas iteraciones, minimizando una función de error que mida la diferencia entre las predicciones obtenidas y los resultados esperados.

Conviene subrayar que un buen entrenamiento no depende únicamente de ejecutar un algoritmo, sino de controlar varios aspectos que condicionan su rendimiento posterior. Entre ellos destacan la elección del modelo, el ajuste de hiperparámetros y la prevención de problemas como el *overfitting* y el *underfitting*. Por ello, esta fase no debe entenderse como una operación automática, sino como un proceso de ajuste y validación en el que se busca un equilibrio entre capacidad de aprendizaje y generalización. En los subapartados siguientes se examinan, por tanto, los principales tipos de

aprendizaje, los criterios de elección de algoritmos y las consideraciones fundamentales que deben tenerse en cuenta durante el entrenamiento.

3.2.3.1 Clasificación de tipos de *Machine Learning*

En función de cómo aprende el modelo a partir de los datos, suele distinguirse entre cuatro grandes tipos de *Machine Learning*: aprendizaje supervisado, cuando existen ejemplos etiquetados; aprendizaje no supervisado, cuando el sistema debe descubrir patrones sin etiquetas previas; aprendizaje semi-supervisado, cuando se combinan unos pocos datos etiquetados con una cantidad mayor de datos no etiquetados; y aprendizaje por refuerzo, cuando el modelo aprende mediante interacción con un entorno a partir de recompensas y penalizaciones.

3.2.3.1.1 Aprendizaje supervisado

El aprendizaje supervisado es el tipo de *Machine Learning* en el que el modelo se entrena a partir de ejemplos ya etiquetados. Esto significa que, para cada caso del conjunto de datos, se dispone tanto de las variables de entrada como de la respuesta correcta que se desea predecir. A partir de esa información, el algoritmo aprende la relación existente entre unas y otra, de manera que después pueda aplicar ese conocimiento a nuevos casos no vistos. Se trata, por tanto, de un aprendizaje guiado, en el que el modelo ajusta sus parámetros comparando continuamente sus predicciones con los resultados reales.

Este enfoque puede entenderse de forma intuitiva como un proceso similar al aprendizaje con ejemplos y soluciones. Del mismo modo que una persona mejora cuando practica ejercicios de los que conoce la respuesta correcta, el modelo va corrigiéndose progresivamente a medida que observa más casos etiquetados. Su objetivo es construir una función que generalice adecuadamente, es decir, que no se limite a memorizar los ejemplos de entrenamiento, sino que sea capaz de acertar también cuando reciba datos nuevos.

Dentro del aprendizaje supervisado suelen distinguirse dos grandes tipos de problemas. Por un lado, la **clasificación**, en la que la variable objetivo pertenece a una categoría o clase, como ocurre al decidir si un correo es spam o no, o si un paciente presenta o no una determinada enfermedad. En este tipo de problemas, el modelo suele estimar una probabilidad o puntuación de pertenencia a cada clase, y la predicción final se obtiene seleccionando la clase más probable o aplicando una regla de decisión, como un umbral. Por otro lado, la **regresión**, en la que la salida esperada es un valor numérico continuo, como el precio de una vivienda, la demanda prevista de un producto o la temperatura del día siguiente. En ambos casos, la lógica de fondo es la misma: aprender, a partir de ejemplos previos, una regla que permita predecir correctamente el resultado en situaciones futuras.

El aprendizaje supervisado es uno de los enfoques más utilizados en la práctica, debido a que ofrece una evaluación clara del rendimiento del modelo al poder comparar directamente sus predicciones con las respuestas reales. No obstante, su principal limitación reside en la necesidad de disponer de datos etiquetados, cuya obtención puede resultar costosa, lenta o requerir intervención experta. A pesar de ello, constituye la base de numerosas aplicaciones actuales, como la detección de fraude, la clasificación documental, la predicción de precios, el diagnóstico asistido o los sistemas de recomendación.




Figura 5: Ejemplo clasificación. Elaboración propia.

3.2.3.1.2 Aprendizaje no supervisado

El aprendizaje no supervisado es aquel en el que el modelo trabaja con datos que no están previamente etiquetados. A diferencia de lo que ocurre en el aprendizaje supervisado, aquí no se dispone de una respuesta correcta que sirva de guía durante el entrenamiento. El objetivo no es predecir una variable conocida, sino descubrir regularidades, estructuras internas o relaciones ocultas dentro del propio conjunto de datos. En este sentido, el algoritmo trata de encontrar por sí mismo cómo se organizan las observaciones y qué patrones de similitud o diferencia existen entre ellas.

Este enfoque resulta útil cuando se dispone de gran cantidad de información, pero no de etiquetas que permitan clasificarla de antemano. Así, puede emplearse para agrupar clientes con comportamientos parecidos, identificar documentos similares, detectar segmentos de usuarios o resumir información compleja en un número menor de dimensiones. El modelo no “sabe” de antemano qué grupos existen ni qué significado tienen, simplemente detecta estructuras coherentes que luego deben ser interpretadas por la persona analista o por el contexto del problema.



Figura 6: Ejemplo *clustering*. Elaboración propia.

Entre sus aplicaciones más habituales destacan el *clustering* o agrupamiento, que busca formar grupos de observaciones semejantes; la reducción de dimensionalidad, que permite condensar la información conservando los patrones más relevantes; y la detección de anomalías, orientada a identificar casos que se apartan del comportamiento habitual. Por ello, el aprendizaje no supervisado constituye una herramienta muy valiosa para la exploración de datos, el descubrimiento de patrones y la generación de conocimiento preliminar sobre problemas en los que todavía no existe una clasificación definida.

3.2.3.1.3 Aprendizaje semi-supervisado

El aprendizaje semi-supervisado constituye un enfoque intermedio entre el aprendizaje supervisado y el no supervisado. Se utiliza cuando solo una parte reducida del conjunto de datos está etiquetada, mientras que el resto carece de una respuesta conocida. En estas situaciones, el objetivo es aprovechar simultáneamente ambos tipos de información: los ejemplos etiquetados sirven para orientar el aprendizaje inicial del modelo y los no etiquetados ayudan a captar mejor la estructura general de los datos.

Este enfoque resulta especialmente útil en problemas reales en los que obtener datos es relativamente sencillo, pero etiquetarlos exige tiempo, coste o intervención experta. Así ocurre, por ejemplo, en clasificación de textos, imágenes, voz o documentos, donde puede disponerse de miles de ejemplos, aunque solo una pequeña parte haya sido revisada y clasificada manualmente. El aprendizaje semi-supervisado permite extraer valor de todo ese volumen de información sin depender exclusivamente del reducido subconjunto etiquetado.

En términos generales, el proceso suele comenzar entrenando un modelo con los datos etiquetados. A partir de ahí, ese modelo se utiliza para extraer información de los datos no etiquetados, ya sea asignándoles etiquetas provisionales o aprovechando la estructura y proximidad entre observaciones. De este modo, los ejemplos sin etiqueta actúan como apoyo para mejorar la generalización del sistema. No obstante, este enfoque también exige cautela, ya que, si el modelo introduce errores en esa fase intermedia, dichos errores pueden propagarse y afectar negativamente al resultado final. Aun así, cuando se aplica correctamente, el aprendizaje semi-supervisado ofrece una solución muy valiosa en contextos donde los datos abundan, pero las etiquetas son escasas.



Figura 7: Ejemplo aprendizaje semi-supervisado. Elaboración propia.

3.2.3.1.4 Aprendizaje por refuerzo

El aprendizaje por refuerzo es un tipo de *Machine Learning* en el que un agente aprende a tomar decisiones mediante su interacción con un entorno. A diferencia del aprendizaje supervisado, aquí no se parte de ejemplos con respuestas correctas previamente dadas, sino que el sistema actúa, observa las consecuencias de sus acciones y recibe una recompensa o una penalización en función del resultado obtenido. A partir de esa retroalimentación, el agente va ajustando su comportamiento para maximizar la recompensa acumulada a lo largo del tiempo.

La lógica de este enfoque se basa, por tanto, en un proceso de prueba y error. En cada momento, el agente se encuentra en un determinado estado del entorno, elige una acción posible y, como consecuencia, pasa a un nuevo estado recibiendo una recompensa asociada. Con la repetición de este proceso, el sistema aprende qué decisiones son más convenientes en cada situación y acaba construyendo una política de actuación, es decir, una estrategia que le indica qué acción debe elegir para obtener el mejor resultado posible a largo plazo.




Figura 8: Esquema de aprendizaje por refuerzo. Fuente: [Wikipedia](https://es.wikipedia.org/wiki/Aprendizaje_por_refuerzo).

3.2.3.2 Algoritmos de *Machine Learning*

Se presenta una relación no exhaustiva de algoritmos de Inteligencia Artificial en continua innovación y desarrollo:

3.2.3.2.1 Regresión lineal

La regresión lineal es un método de aprendizaje supervisado utilizado para modelar la relación entre una variable dependiente y una o varias variables independientes. Su finalidad es estimar cómo cambia

la variable objetivo a partir de las variables de entrada mediante una función lineal. De forma general, puede expresarse mediante la ecuación:

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$$

Donde Y representa la variable dependiente, $X_1, X_2, \dots, X_n$ las variables independientes, y $\beta_0, \beta_1, \dots, \beta_n$ los coeficientes del modelo. Estos coeficientes son los parámetros que se estiman durante el entrenamiento con el objetivo de obtener la recta o hiperplano que mejor se ajuste a los datos observados.

La regresión lineal se emplea principalmente en problemas de predicción de valores continuos, como la estimación de precios, demanda, producción, rendimiento agrícola o evolución de determinadas variables económicas o sanitarias. Se trata de un modelo sencillo, interpretable y ampliamente utilizado, aunque presenta sensibilidad frente a valores atípicos y su rendimiento depende de que la relación entre las variables pueda aproximarse razonablemente mediante una función lineal.




Figura 9: Ejemplo de regresión lineal simple. Fuente: [Wikipedia](#).

Cuando el modelo utiliza una única variable independiente, se habla de **regresión lineal simple**, cuya representación corresponde a una recta. En cambio, cuando intervienen varias variables independientes, se denomina **regresión lineal múltiple**, y el modelo se formula de manera matricial o mediante una combinación lineal de todas ellas.

La calidad del ajuste se valora a partir del error de predicción. La diferencia entre el valor real y el valor predicho por el modelo se denomina **residuo**. El conjunto de residuos permite medir hasta qué punto la recta ajustada representa adecuadamente los datos. Para estimar los coeficientes del modelo y minimizar el error, pueden emplearse distintas técnicas, entre las que destacan las siguientes:

- Método de los mínimos cuadrados.** Es el procedimiento clásico para ajustar una regresión lineal. Consiste en estimar los coeficientes β de forma que la suma de los cuadrados de los residuos sea mínima. De este modo, se obtiene la recta que mejor se ajusta globalmente al conjunto de puntos observados.
- Descenso por gradiente.** Es una técnica iterativa de optimización que ajusta progresivamente los coeficientes del modelo para reducir la función de coste. En cada iteración, los parámetros se actualizan en la dirección que más disminuye el error, de acuerdo con una tasa de aprendizaje previamente definida. El proceso continúa hasta alcanzar un valor mínimo o una convergencia suficiente.

3.2.3.2.2 SVM (Support Vector Machines o Máquinas de Vector Soporte)

Las máquinas de vectores de soporte son algoritmos de aprendizaje supervisado utilizados principalmente en problemas de clasificación, aunque también pueden aplicarse a regresión. Su idea fundamental consiste en encontrar una frontera de decisión que separe las clases de la forma más adecuada posible. En problemas de clasificación lineal, esa frontera es un hiperplano que divide el espacio de características en regiones asociadas a cada clase.

A diferencia de otros métodos que simplemente buscan una separación entre clases, las SVM tratan de encontrar el hiperplano que maximiza el margen, es decir, la distancia entre la frontera de decisión y los ejemplos más próximos de cada clase. Estos ejemplos más cercanos reciben el nombre de

vectores de soporte, ya que son los que determinan la posición del hiperplano óptimo. De este modo, el modelo no depende de todos los puntos del conjunto de datos por igual, sino especialmente de aquellos que se encuentran más cerca de la frontera entre clases.

La clasificación de nuevas observaciones se realiza en función de la posición del dato respecto al hiperplano de separación. Además, el modelo incorpora un parámetro de regularización, habitualmente denotado por C , que permite controlar el equilibrio entre maximizar el margen y tolerar ciertos errores de clasificación en los datos de entrenamiento. Un valor alto de C penaliza más los errores y fuerza una separación más estricta, mientras que un valor menor permite un margen más flexible y una mayor tolerancia al ruido, lo que puede favorecer la capacidad de generalización.




Figura 10: Hiperplano H3 como vector de soporte máximo. Fuente: [Wikipedia](#).

En muchos problemas reales, los datos no son linealmente separables en el espacio original de características. En estos casos, las SVM pueden recurrir al denominado **kernel trick** o truco del núcleo, que permite trabajar implícitamente en un espacio de mayor dimensión donde la separación entre clases puede resultar más sencilla. Gracias a este mecanismo, el modelo puede construir fronteras de decisión no lineales en el espacio original sin necesidad de transformar explícitamente todos los datos.

Entre las funciones kernel más utilizadas se encuentran el **kernel lineal**, el **kernel polinómico** y el **kernel de base radial gaussiana** o **RBF** (*Radial Basis Function*). La elección del kernel depende de la estructura de los datos y del tipo de frontera que se desea modelar. Así, mientras que el kernel lineal resulta adecuado cuando las clases pueden separarse aproximadamente mediante un hiperplano, los kernels no lineales permiten capturar relaciones más complejas entre las variables.

Además de su uso en clasificación, las SVM también pueden adaptarse a problemas de regresión mediante una variante conocida como **SVR** (*Support Vector Regression*). En este caso, el objetivo no es separar clases, sino estimar una función que se ajuste a los datos con el menor error posible, manteniendo al mismo tiempo una buena capacidad de generalización. De este modo, las máquinas de vectores de soporte constituyen una familia de modelos versátil y sólida, especialmente útil en problemas con datos estructurados y espacios de características de dimensión media o alta.

3.2.3.2.3 kNN (*k*-Nearest Neighbors o *K* vecinos más cercanos)

El algoritmo *k*-NN es un método de aprendizaje supervisado utilizado principalmente en problemas de clasificación, aunque también puede emplearse en regresión. Su funcionamiento se basa en un criterio de proximidad: para clasificar una nueva observación, el modelo analiza los k ejemplos más cercanos del conjunto de entrenamiento y asigna la clase más frecuente entre ellos. A diferencia de otros métodos, *k*-NN no construye explícitamente un modelo previo ni una frontera de decisión durante el entrenamiento, sino que basa la predicción en la comparación directa con los datos ya conocidos.

Los principales elementos que determinan su comportamiento son el valor de k , la métrica de distancia utilizada (habitualmente la distancia euclídea) y, en algunos casos, la ponderación asignada a cada vecino, de manera que los puntos más próximos tengan mayor influencia en la decisión final. La elección de k resulta especialmente importante, ya que condiciona la sensibilidad del algoritmo. Valores pequeños hacen que el modelo sea más sensible a variaciones locales y al ruido, mientras que valores más altos suavizan la clasificación, aunque también pueden hacer que la predicción quede más influida por la clase mayoritaria del entorno.




Figura 11: Ejemplo del algoritmo k-NN. Fuente: [Wikipedia](#).

En el ejemplo representado, el punto que se desea clasificar es el círculo verde. Si se toma $k = 3$, la clase asignada es la de los triángulos, ya que entre los tres vecinos más cercanos aparecen dos triángulos y un cuadrado. En cambio, si se considera $k = 5$, la clasificación pasa a ser la de los cuadrados, puesto que entre los cinco vecinos más próximos hay tres cuadrados y dos triángulos. De este modo, el algoritmo asigna la categoría en función de las relaciones de cercanía entre la nueva observación y los ejemplos previamente etiquetados.

3.2.3.2.4 kMedias (*k-Means*)

k-Means es un algoritmo de aprendizaje no supervisado utilizado para agrupar datos en k **clústeres**. Su objetivo es dividir el conjunto de datos en grupos de forma que cada observación quede asociada al centroide más cercano, siendo el centroide el valor medio de los puntos que forman cada clúster. Sus principales parámetros son el número de grupos k , el número máximo de iteraciones y la medida de distancia, habitualmente la euclídea.

El procedimiento comienza con la selección inicial, generalmente aleatoria, de k **centroides**. A continuación, cada punto se asigna al centroide más próximo, generando una primera agrupación. Después, se recalcula el centroide de cada grupo a partir de la media de los puntos asignados. Este proceso de asignación y actualización se repite sucesivamente hasta que no se producen cambios en los clústeres o se alcanza el máximo de iteraciones fijado.

Se trata de un algoritmo sensible a la elección inicial de los centroides, por lo que distintas inicializaciones pueden dar lugar a resultados diferentes y afectar tanto a la convergencia como a la calidad final de la agrupación.




Figura 12: Proceso de ejecución algoritmo *k-Means*. Fuente: [Wikipedia](#).

3.2.3.2.5 *k-medoids*

k-medoids es un algoritmo de aprendizaje no supervisado utilizado principalmente para el agrupamiento de datos. También se conoce como **Partición Alrededor de Medoides** (*Partitioning Around Medoids*, PAM). Su planteamiento es similar al de k-Means, aunque, en lugar de representar cada grupo mediante un centroide, utiliza un **medoide**, es decir, un punto real del conjunto de datos cuya distancia total al resto de elementos de su grupo es mínima.

El procedimiento es iterativo. En primer lugar, se seleccionan k **medoides** iniciales entre los datos disponibles. A continuación, cada observación se asigna al medoide más cercano según la distancia escogida. Después, se evalúa si conviene sustituir alguno de los medoides por otro punto del conjunto de datos para reducir el coste total de la agrupación, entendido como la suma de las distancias entre

los puntos y su medoide correspondiente. Este proceso se repite hasta que no se producen cambios o se alcanza la convergencia.

Se trata de un método fácil de interpretar y menos sensible a los valores atípicos que k-Means, ya que trabaja con puntos reales del conjunto de datos en lugar de medias. Sin embargo, su coste computacional suele ser mayor y puede no resultar la mejor opción en conjuntos de datos muy grandes

3.2.3.2.6 DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*)

DBSCAN es un algoritmo de aprendizaje no supervisado basado en densidad, utilizado para agrupar datos en función de la concentración de puntos en el espacio. Su idea principal consiste en identificar regiones con alta densidad de observaciones y considerarlas clústeres, mientras que los puntos que quedan en zonas poco densas pueden tratarse como ruido o anomalías.

El algoritmo se apoya en dos parámetros fundamentales: ϵ (*epsilon*), que define el radio de vecindad alrededor de un punto, y **minPts**, que establece el número mínimo de puntos que debe haber dentro de ese entorno para considerar que existe una región densa. A partir de estos criterios, DBSCAN distingue entre puntos núcleo, puntos frontera y puntos ruido. Un **punto núcleo** es aquel que tiene al menos **minPts** vecinos dentro de una distancia ϵ ; a partir de él pueden expandirse los clústeres incorporando puntos densamente conectados.

Una de las principales ventajas de DBSCAN es que permite detectar grupos de forma arbitraria sin necesidad de fijar previamente el número de clústeres. Además, resulta especialmente útil cuando el conjunto de datos contiene ruido, ya que puede identificar observaciones aisladas que no pertenecen claramente a ningún grupo. Por ello, es uno de los algoritmos de agrupamiento más empleados cuando se trabaja con estructuras no lineales o distribuciones espaciales complejas.

3.2.3.2.7 Modelos de mezclas gaussianas (*Gaussian Mixture Model – GMM*)

Los modelos de mezclas gaussianas son métodos probabilísticos de aprendizaje no supervisado utilizados para agrupar datos. Se consideran una generalización de k-Means, ya que permiten representar clústeres con distintas formas, tamaños y orientaciones. Suponen que los datos proceden de una combinación de varias distribuciones gaussianas, cada una asociada a un grupo y ponderada según su relevancia. Cada componente gaussiana representa un clúster y se define por parámetros como la media y la varianza. Gracias a ello, los GMM permiten no solo identificar grupos, sino también estimar la probabilidad de pertenencia de cada observación a cada clúster.

3.2.3.2.8 Algoritmos genéticos

Los algoritmos genéticos son métodos de optimización inspirados en los mecanismos de la evolución biológica. Su funcionamiento parte de un conjunto de soluciones posibles al problema, denominado población, en el que cada solución se representa mediante una codificación llamada cromosoma, habitualmente expresada como una cadena de valores, a menudo binarios. Los elementos que componen esa cadena se denominan genes. A lo largo de un proceso iterativo, las soluciones evolucionan a través de sucesivas generaciones. En cada una de ellas, los individuos de la población se evalúan mediante una función de aptitud, que mide la calidad de cada solución. A partir de esa evaluación, se generan nuevas soluciones aplicando de forma repetida operadores genéticos como la selección, el cruce, la mutación y el reemplazo, con el objetivo de obtener individuos cada vez mejor adaptados al problema planteado.

Los algoritmos genéticos resultan especialmente útiles en problemas de optimización complejos, sobre todo cuando la función objetivo no es derivable, presenta una derivación difícil de calcular o contiene numerosos óptimos locales. En estos contextos, permiten explorar amplios espacios de búsqueda sin depender de métodos analíticos clásicos. No obstante, su aplicación no garantiza necesariamente la obtención del óptimo global, sino de soluciones suficientemente buenas dentro de un proceso heurístico. Además, pueden requerir un número elevado de iteraciones y un ajuste cuidadoso de sus parámetros. Por ello, suelen emplearse principalmente en problemas de búsqueda y optimización, mientras que no son, en general, la opción más habitual para tareas de clasificación o para situaciones en las que se necesita una convergencia rápida y altamente precisa.

3.2.3.2.9 Naive Bayes

Naive Bayes es un algoritmo de aprendizaje supervisado utilizado principalmente en problemas de clasificación, por lo que sus variantes suelen denominarse **clasificadores Naive Bayes**. Su fundamento matemático se basa en el **teorema de Bayes**, que permite estimar la probabilidad de que una observación pertenezca a una determinada clase a partir de los valores de sus atributos. Se trata

de un método sencillo, eficiente y especialmente útil en tareas como clasificación de texto, filtrado de spam o análisis documental.

$$P(A|R) = \frac{P(R|A)P(A)}{P(R)}$$

- P(A): Probabilidad de A
- P(R|A): Probabilidad de que se de R dado A
- P(R): Probabilidad de R
- P(A|R): Probabilidad posterior de que se de A dado R

Figura 13: Teorema de Bayes ($P(A)$ y $P(B)$ se les llama también probabilidades marginales). Fuente: [Medium](#).

La característica que define a este algoritmo es el supuesto de **independencia condicional** entre las variables predictoras dado el valor de la clase. Esto significa que, una vez conocida la clase, el modelo asume que cada atributo aporta información de forma independiente respecto a los demás. Aunque este supuesto rara vez se cumple de forma estricta en problemas reales, el algoritmo suele ofrecer buenos resultados en la práctica. La estimación de sus parámetros se realiza habitualmente a partir de los datos de entrenamiento, empleando frecuencias observadas o técnicas como la máxima verosimilitud, en función de la variante concreta utilizada.

Conviene no confundir *Naive Bayes* con las **redes bayesianas**. Aunque ambos enfoques pertenecen al ámbito de los modelos probabilísticos y se basan en el teorema de Bayes, no son equivalentes. Las redes bayesianas son modelos probabilísticos gráficos que representan variables aleatorias y sus relaciones de dependencia condicional mediante un **grafo acíclico dirigido**, mientras que Naive Bayes constituye un caso mucho más simplificado, en el que se asume independencia condicional entre los atributos dada la clase.

3.2.3.2.10 Regresión logística

La regresión logística es un algoritmo de aprendizaje supervisado utilizado principalmente para problemas de clasificación. Su finalidad consiste en estimar la probabilidad de que una observación pertenezca a una determinada clase a partir de un conjunto de variables predictoras. Para ello, el modelo parte de una combinación lineal de las características de entrada y transforma ese resultado mediante la **función logística** o **sigmoide**, de modo que la salida quede acotada entre 0 y 1 y pueda interpretarse como una probabilidad.

En su forma más habitual, la regresión logística binaria modela la probabilidad de pertenencia a una de dos clases posibles. La relación entre las variables predictoras y la probabilidad no es lineal en la salida, aunque sí se construye a partir de una combinación lineal de los predictores. Los parámetros del modelo se estiman normalmente mediante **máxima verosimilitud**², buscando los valores que mejor explican los datos observados.

Una vez calculada la probabilidad, esta puede compararse con un umbral predefinido para asignar la observación a una clase u otra. Aunque se utiliza sobre todo en problemas binarios, también existen extensiones para clasificación multiclase, como la **regresión logística multinomial**. Por ello, la variable objetivo es categórica, ya sea con dos categorías o con varias clases posibles.

La regresión logística se emplea con frecuencia en aplicaciones como la detección de spam, el diagnóstico asistido, la concesión de crédito o la predicción de abandono de clientes. Entre sus principales ventajas destacan su simplicidad, su interpretabilidad y su eficiencia computacional, especialmente en conjuntos de datos estructurados. No obstante, su rendimiento depende de la calidad de las variables utilizadas y de que la relación entre los predictores y la variable objetivo pueda modelarse adecuadamente.

3.2.3.2.11 Árbol de decisión (*Decision Tree*)

Un árbol de decisión es un modelo de aprendizaje supervisado utilizado en problemas de **clasificación** y **regresión**. Su estructura se organiza de forma jerárquica mediante una sucesión de decisiones que dividen el conjunto de datos en subconjuntos cada vez más homogéneos respecto a la variable objetivo. Cada decisión se representa mediante un **nodo interno**, desde el cual parten distintas ramas según el valor o la condición evaluada. El proceso comienza en el **nodo raíz**, que contiene la primera partición, continúa a través de nodos intermedios y finaliza en los **nodos hoja**, que representan la predicción final del modelo.

² Verosimilitud: medida de qué tan probable sería observar los datos disponibles para unos determinados valores de los parámetros del modelo.

La construcción de un árbol de decisión se realiza de forma recursiva, seleccionando en cada paso la variable y el punto de corte que mejor separan los datos según un criterio de pureza o impureza. En clasificación, el objetivo es que los ejemplos de cada subconjunto pertenezcan, en la medida de lo posible, a una misma clase; en regresión, se busca que los valores dentro de cada partición sean lo más similares posible. Entre sus principales ventajas destacan su facilidad de interpretación, su capacidad para trabajar con relaciones no lineales y su utilidad con variables tanto numéricas como categóricas. No obstante, también pueden ser sensibles a pequeñas variaciones en los datos y tender al sobreajuste si no se controlan adecuadamente.




Figura 14: Árbol de decisión de tipo binario. Fuente: [Wikipedia](#).

En función del número de ramas que puede generar cada nodo, los árboles pueden ser **binarios**, cuando cada partición produce dos ramas, o **no binarios**, cuando una misma decisión puede dar lugar a más de dos ramas. Entre los algoritmos más conocidos para su construcción se encuentra **ID3**, que utiliza la entropía y la ganancia de información para seleccionar las divisiones; **C4.5**, que extiende el anterior e incorpora, entre otros aspectos, la razón de ganancia; y **CART** (*Classification and Regression Trees*), que construye árboles binarios y emplea habitualmente la **impureza de Gini** en clasificación y el error cuadrático en regresión como criterios de partición.

3.2.3.2.12 Métodos de combinación

Los métodos de combinación, también conocidos como **ensemble methods**, son técnicas de aprendizaje automático que integran varios modelos con el fin de obtener una única predicción final. Su propósito es mejorar el rendimiento respecto al que ofrecería un modelo individual, ya sea aumentando la precisión, la robustez o la capacidad de generalización. La idea básica consiste en aprovechar que distintos modelos pueden cometer errores diferentes; al combinarlos adecuadamente, es posible compensar parte de esas limitaciones y obtener resultados más estables. Estos métodos pueden aplicarse tanto a problemas de clasificación como de regresión y constituyen una de las estrategias más utilizadas para construir modelos predictivos sólidos. No obstante, suelen implicar un mayor coste computacional y una menor interpretabilidad que los modelos simples.

3.2.3.2.12.1 Random Forest

Random Forest es un método de aprendizaje supervisado basado en la combinación de múltiples árboles de decisión, y puede utilizarse tanto en clasificación como en regresión. Cada árbol se entrena a partir de una muestra aleatoria de los datos, obtenida normalmente mediante **bootstrap**³, y en cada división se considera solo un subconjunto aleatorio de las variables predictoras. Esta aleatoriedad reduce la correlación entre los árboles y favorece que el conjunto del modelo sea más robusto que un único árbol aislado. La predicción final se obtiene agregando las predicciones de todos los árboles: en clasificación, mediante votación mayoritaria, y en regresión, mediante el promedio de sus salidas.

Una de sus principales ventajas es que suele ofrecer un buen rendimiento predictivo, incluso en problemas complejos y con relaciones no lineales. Además, reduce significativamente la varianza respecto a un árbol de decisión individual y suele ser menos propenso al sobreajuste que este último, aunque no lo elimina por completo. También permite estimar la importancia relativa de las variables.

³ *Bootstrap*: técnica de remuestreo que consiste en generar nuevas muestras a partir del conjunto original, seleccionando observaciones al azar con reemplazo.

Como limitaciones, presenta una menor interpretabilidad que un árbol simple y puede perder eficacia cuando existen variables muy correlacionadas o cuando el ajuste de sus parámetros no es adecuado.

3.2.3.2.12.2 ExtraTree (*Extremely Randomized Trees*)

Extra Trees, también conocido como ***Extremely Randomized Trees***, es un método de combinación estrechamente relacionado con *Random Forest*. Al igual que este, construye un conjunto de árboles de decisión y combina sus resultados para obtener una predicción final más robusta. La principal diferencia es que introduce un mayor grado de aleatoriedad durante el proceso de construcción de los árboles. En lugar de buscar siempre el mejor punto de corte entre un subconjunto de variables, selecciona de forma aleatoria los puntos de división candidatos, lo que incrementa la diversidad entre árboles.

Este aumento de aleatoriedad puede contribuir a reducir la varianza del modelo y, en algunos casos, mejorar la capacidad de generalización. Además, suele ofrecer un entrenamiento más rápido que otros métodos basados en árboles, precisamente porque reduce la búsqueda exhaustiva de divisiones óptimas. Sin embargo, como ocurre con otros *ensembles*, su interpretabilidad es limitada en comparación con un único árbol de decisión, y su rendimiento depende del problema concreto y del ajuste de sus hiperparámetros.

3.2.3.2.12.3 GBM (*Gradient Boosting Machine*)

GBM es un método de aprendizaje supervisado basado en ***boosting***⁴ que puede utilizarse tanto en problemas de clasificación como de regresión. Su funcionamiento consiste en construir el modelo de forma secuencial, añadiendo sucesivos árboles de decisión simples que corrigen progresivamente los errores cometidos por los anteriores. A diferencia de otros métodos basados en árboles, estos no se generan de forma independiente, sino que cada nuevo árbol se ajusta a los residuos o errores del modelo previo. Este proceso iterativo permite optimizar una función de pérdida diferenciable y mejorar gradualmente la capacidad predictiva del conjunto. Por ello, GBM destaca por su flexibilidad y por ofrecer, en muchos casos, un alto rendimiento predictivo, aunque también puede ser sensible al sobreajuste si no se ajustan adecuadamente sus hiperparámetros. Entre sus variantes más conocidas se encuentran **XGBoost** y **LightGBM**.

3.2.3.2.13 Elección del algoritmo de ML

La elección del algoritmo de *Machine Learning* no depende de que exista un único método “mejor”, sino del problema que se quiere resolver, del volumen y calidad de los datos, de si estos están etiquetados o no, y del equilibrio buscado entre precisión, interpretabilidad y coste computacional. Como criterio general, una buena forma de orientarse es partir de tres preguntas: qué tarea se desea realizar (clasificación, regresión, agrupamiento u optimización), qué tipo de datos se tiene disponible, y si se necesita un modelo fácilmente interpretable o se prioriza el rendimiento predictivo.

A modo de guía inicial, puede utilizarse la siguiente tabla orientativa:

Algoritmo	Tipo de ML	Tipo de problema en que suele usarse	Datos con los que suele funcionar mejor
Regresión lineal	Supervisado	Regresión, predicción de valores continuos	Datos numéricos, estructurados y con relaciones aproximadamente lineales
SVM	Supervisado	Clasificación y regresión	Datos estructurados, de tamaño pequeño o medio, con fronteras de decisión complejas
k-NN	Supervisado	Clasificación y regresión simple	Datos estructurados, pocos o medianos, con variables normalizadas y relaciones de proximidad
k-Means	No supervisado	Agrupamiento	Datos numéricos con grupos compactos y relativamente bien separados

⁴ *Boosting*: técnica de ensamblado que construye modelos de forma secuencial, haciendo que cada nuevo modelo se centre en corregir los errores cometidos por los anteriores.

Algoritmo	Tipo de ML	Tipo de problema en que suele usarse	Datos con los que suele funcionar mejor
k-medoids	No supervisado	Agrupamiento	Datos numéricos o estructurados con presencia de valores atípicos, donde se busca más robustez que en k-Means
DBSCAN	No supervisado	Agrupamiento y detección de anomalías	Datos espaciales o numéricos con ruido y grupos de forma arbitraria
GMM	No supervisado	Agrupamiento probabilístico	Datos numéricos con grupos solapados o con distinta forma, tamaño u orientación
Algoritmos genéticos	No supervisado / optimización	Optimización y búsqueda de soluciones	Problemas complejos de optimización, funciones no derivables o espacios de búsqueda amplios
Naive Bayes	Supervisado	Clasificación	Datos de texto, conteos o problemas con muchas variables y cálculo probabilístico
Regresión logística	Supervisado	Clasificación, especialmente binaria	Datos estructurados, con variables numéricas o categóricas codificadas
Árbol de decisión	Supervisado	Clasificación y regresión	Datos tabulares, numéricos y categóricos, cuando interesa interpretabilidad
Random Forest	Supervisado	Clasificación y regresión	Datos tabulares y problemas no lineales, cuando se busca robustez y buena capacidad predictiva
ExtraTree	Supervisado	Clasificación y regresión	Datos tabulares, especialmente cuando interesa rapidez y diversidad en los árboles
GBM	Supervisado	Clasificación y regresión	Datos tabulares complejos, cuando se prioriza la precisión predictiva

Tabla 2. Resumen algoritmos ML

No obstante, durante la fase de entrenamiento se suelen probar diferentes algoritmos para valorar su funcionamiento.

3.2.3.3 Consideraciones a la hora de entrenar

Durante el entrenamiento no basta con elegir un algoritmo y proporcionarle datos, sino que es necesario tener en cuenta diversas cuestiones que condicionan directamente el rendimiento y la capacidad de generalización del modelo. Entre ellas destacan, por un lado, el ajuste de los hiperparámetros, que determina cómo aprende el algoritmo y con qué configuración lo hace, y, por otro, la necesidad de controlar problemas como el *overfitting* y el *underfitting*, que reflejan, respectivamente, un aprendizaje excesivamente ajustado a los datos de entrenamiento o un aprendizaje insuficiente para captar sus patrones relevantes.

3.2.3.3.1 Ajuste de hiperparámetros

Los **hiperparámetros** son configuraciones que se fijan antes de comenzar el entrenamiento y que determinan cómo va a aprender el modelo. A diferencia de los parámetros internos, que el algoritmo ajusta automáticamente a partir de los datos, los hiperparámetros son establecidos por la persona que diseña el sistema. Entre ellos pueden encontrarse, por ejemplo, la profundidad máxima de un árbol de decisión, el número de árboles de un *random forest*, la tasa de aprendizaje de una red neuronal o el tamaño del lote con el que se procesa la información.

Su importancia radica en que influyen de forma decisiva en el comportamiento del modelo y en su capacidad para generalizar. Una configuración inadecuada puede hacer que el modelo sea demasiado simple y no aprenda suficientemente los patrones relevantes, o, por el contrario, que se vuelva excesivamente complejo y tienda a ajustarse en exceso a los datos de entrenamiento. Por ello, el ajuste de hiperparámetros consiste en buscar la combinación de valores que ofrezca el mejor equilibrio posible entre rendimiento y generalización.

Este ajuste suele realizarse comparando distintas configuraciones mediante un conjunto de validación o a través de validación cruzada, sin utilizar para ello el conjunto de prueba final. Entre las estrategias más conocidas se encuentran la búsqueda en rejilla (*grid search*), que prueba de forma sistemática todas las combinaciones definidas previamente, y la búsqueda aleatoria (*random search*), que explora combinaciones seleccionadas al azar dentro de determinados rangos. En definitiva, el ajuste de hiperparámetros constituye una fase esencial del entrenamiento, ya que permite adaptar el algoritmo al problema concreto y aumentar la probabilidad de que el modelo funcione correctamente cuando se enfrente a datos nuevos.

3.2.3.3.2 Overfitting, underfitting y regularización

Durante el entrenamiento de un modelo de *Machine Learning* pueden aparecer dos problemas opuestos que afectan a su capacidad de generalización: el **underfitting** y el **overfitting**. El primero se produce cuando el modelo es demasiado simple o no ha aprendido lo suficiente como para captar los patrones relevantes de los datos. En esta situación, el rendimiento suele ser bajo tanto en el conjunto de entrenamiento como en el de validación, ya que el sistema no logra ajustarse adecuadamente ni siquiera a los ejemplos con los que ha sido entrenado.

El **overfitting**, por el contrario, aparece cuando el modelo aprende en exceso los detalles particulares del conjunto de entrenamiento, incluyendo ruido, anomalías o patrones poco representativos. Como consecuencia, puede alcanzar un rendimiento muy alto sobre los datos ya vistos, pero comportarse peor cuando se enfrenta a casos nuevos. En este caso, el sistema no está generalizando, sino memorizando. La detección de ambos fenómenos suele basarse en la comparación entre el comportamiento del modelo en entrenamiento y en validación: si falla en ambos casos, probablemente exista *underfitting*; si funciona muy bien en entrenamiento, pero claramente peor en validación, lo más probable es que exista *overfitting*.




Figura 15: Ejemplo *underfitting* y *overfitting*. Elaboración propia.

Para reducir este último problema se emplean técnicas de regularización, cuyo objetivo es limitar la complejidad del modelo y favorecer que aprenda patrones más generales y robustos. Entre las medidas más habituales se encuentran la regularización L1 y L2, la poda en árboles de decisión, el *dropout* en redes neuronales o la detención temprana del entrenamiento (*early stopping*). En conjunto, estas técnicas buscan evitar que el modelo dependa en exceso de detalles concretos del conjunto de entrenamiento y mejorar así su comportamiento ante datos no vistos.

3.2.4 Paso 4: *Testing* o Evaluación del modelo

Una vez entrenado el modelo, es necesario comprobar cómo se comporta ante datos que no ha visto previamente. Esta fase, denominada *testing*, tiene como finalidad estimar hasta qué punto el sistema será capaz de generalizar correctamente cuando se aplique en situaciones reales. No se trata, por tanto, de verificar si el modelo funciona bien con los ejemplos con los que ya ha aprendido, sino de medir su rendimiento sobre un conjunto independiente que permita obtener una evaluación más honesta y fiable.

La importancia de esta etapa radica en que un buen resultado durante el entrenamiento no garantiza por sí mismo un buen comportamiento futuro. Un modelo puede ajustarse de forma aparente al conjunto de datos disponible y, sin embargo, fallar cuando se enfrenta a nuevos casos. Por ello, el *testing* constituye la comprobación final del proceso de aprendizaje y debe realizarse evitando fugas de información entre los distintos subconjuntos de datos. En particular, el conjunto de prueba no debe utilizarse para entrenar, ajustar hiperparámetros ni tomar decisiones de diseño, ya que su función es servir como referencia final de evaluación.

Además, la forma de evaluar el modelo dependerá del tipo de problema abordado, como se puede apreciar a continuación.

3.2.4.1 *Testing* en aprendizaje supervisado

En el aprendizaje supervisado, la evaluación del modelo resulta más directa que en otros enfoques, ya que se dispone de ejemplos en los que la respuesta correcta es conocida. Esto permite comparar de forma explícita las predicciones generadas por el sistema con los valores reales del conjunto de prueba y, a partir de esa comparación, obtener una estimación de su rendimiento. La idea fundamental consiste en reservar una parte de los datos para evaluar el modelo una vez finalizado el entrenamiento, de forma que esa evaluación refleje cómo podría comportarse ante casos nuevos.

La técnica más habitual para ello es la partición del conjunto de datos en subconjuntos con funciones distintas. Así, una parte se utiliza para entrenar el modelo, otra puede destinarse a validación (especialmente cuando se ajustan hiperparámetros) y una última se reserva para el test final. Este procedimiento, conocido como *hold-out*, permite mantener un conjunto de prueba independiente que no intervenga en el aprendizaje del modelo y que proporcione una medida más honesta de su capacidad de generalización. En la práctica, pueden utilizarse particiones como 80/20 para entrenamiento y prueba, o bien 60/20/20 cuando se distingue también un conjunto específico de validación.




Figura 16: División de datos para *testing* en ML⁵. Elaboración propia.

Para que esta evaluación sea fiable, la división de los datos debe ser representativa. En problemas de clasificación, cuando las clases están desbalanceadas, suele recurrirse a particiones estratificadas, de manera que cada subconjunto mantenga una proporción similar de ejemplos de cada clase. En otros casos, como los datos agrupados por cliente, sesión o dispositivo, resulta necesario separar por grupos

⁵ En la práctica, el conjunto de entrenamiento suele dividirse a su vez en entrenamiento propiamente dicho y validación, utilizada para ajustar el modelo y seleccionar hiperparámetros. El conjunto de *testing* se reserva como evaluación final independiente, aunque en algunos esquemas también puede distinguirse entre validación y prueba dentro de la parte no usada para entrenar directamente.

para evitar fugas de información. De forma análoga, en series temporales no debe mezclarse pasado y futuro, sino respetar el orden cronológico, entrenando con datos anteriores y probando con datos posteriores.

No obstante, una única partición puede dar lugar a resultados poco estables si, por azar, el reparto entre entrenamiento y prueba no resulta suficientemente representativo. Para reducir este problema se emplea la validación cruzada, que consiste en dividir el conjunto de datos en varios bloques o *folds* y repetir el entrenamiento varias veces, utilizando en cada iteración una partición distinta como validación y el resto como entrenamiento. Al promediar los resultados obtenidos en todas las iteraciones, se logra una estimación más robusta del rendimiento del modelo y se reduce la dependencia de una sola división de los datos. De este modo, el *testing* en aprendizaje supervisado no se limita a calcular una métrica final, sino que exige diseñar correctamente el protocolo de evaluación para obtener una medida fiable de la capacidad real de generalización del modelo.




Figura 17: Ejemplo validación cruzada. Fuente: [Wikipedia](#).

3.2.4.2 Testing en clasificación

Una vez realizada la separación de los datos disponibles en los conjuntos de entrenamiento, validación y test, y tras evaluar el rendimiento de cada modelo, necesitamos obtener métricas que nos permitan comparar cómo se comportan distintos modelos. En los problemas de clasificación, la herramienta por excelencia para obtener esas métricas es la matriz de confusión:

		Clase predicha	
		Positiva	Negativa
Clase real	Positiva	TP	FN
	Negativa	FP	TN

Figura 18: Matriz de confusión binaria. Fuente: [Wikipedia](#).

A partir de esta matriz de confusión se obtienen las siguientes métricas:

- **Accuracy (Exactitud):** Importante para evaluar el rendimiento general del modelo en problemas de clasificación cuando todas las clases tienen la misma importancia. $Accuracy = \frac{\text{Predicciones correctas (TP+TN)}}{\text{Predicciones totales (TP+TN+FP+FN)}}$
- **Recall (Sensibilidad):** Importante en aplicaciones médicas para detectar enfermedades, donde la detección de casos positivos es crucial. $Recall = \frac{TP}{TP+FN}$

- **Precision (Precisión):** Importante en pruebas de seguridad, como detección de intrusiones, donde minimizar los falsos positivos es esencial para evitar alarmas innecesarias. $Precision = \frac{TP}{TP+FP}$
- **F1 score:** Métrica de compromiso entre *recall* y *precision*. $F1\ Score = \frac{2 \times Recall \times Precision}{Recall + Precision}$

3.2.4.3 Testing en regresión

En regresión queremos comprobar, con datos nunca vistos, qué tan bien acierta el modelo al predecir números (precio, demanda, temperatura...). La calidad se juzga por el tamaño de los errores y por su comportamiento. No basta con un único número: conviene mirar la dispersión de los errores (residuos), si el modelo sesga sistemáticamente por arriba o por abajo, y si falla más en ciertos rangos (por ejemplo, valores altos) o en ciertos segmentos del negocio.




Figura 19: Distancia respecto a la línea en la regresión lineal. Fuente: [Wikipedia](#).

Podemos ver a continuación las principales métricas utilizadas en regresión:

- **Error cuadrático medio, mean square error (MSE):** Calcula el promedio de los errores cuadrados entre las predicciones y los valores reales. El MSE penaliza de manera significativa los errores grandes, lo que lo hace útil para identificar modelos con predicciones muy alejadas de los valores reales.

$$MSE = \left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Error absoluto medio, mean absolute error (MAE):** se define como la diferencia en valor absoluto entre el valor real y el valor predicho. El MAE es fácil de interpretar y proporciona una medida de la magnitud promedio de los errores, lo que lo hace útil cuando se requiere una comprensión intuitiva del error.

$$MAE = \left(\frac{1}{n}\right) \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Raíz del error cuadrático medio, root mean square error (RMSE):** se obtiene como la raíz cuadrada del error cuadrático medio. Al igual que el MSE, penaliza en mayor medida los errores grandes, pero presenta la ventaja de expresarse en las mismas unidades que la variable objetivo, lo que facilita su interpretación. Por ello, resulta especialmente útil cuando se desea valorar de forma más intuitiva la magnitud típica del error de predicción.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Coefficiente de determinación, R^2 :** mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo. Su valor suele estar comprendido entre 0 y 1, donde valores más próximos a 1 indican un mejor ajuste. No obstante, en ciertos casos puede

tomar valores negativos si el modelo predice peor que una referencia muy simple, como la media de los valores observados. Esta métrica resulta útil para evaluar la capacidad explicativa global del modelo, aunque conviene interpretarla junto con otras medidas de error.

$$R^2 = 1 - \left(\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \right)$$

3.2.4.4 *Testing* en aprendizaje no supervisado

En el aprendizaje no supervisado, a diferencia de lo que ocurre en el aprendizaje supervisado, no disponemos de una respuesta correcta previamente etiquetada con la que comparar directamente las predicciones del modelo. Por ello, el *testing* no consiste en medir si el sistema “acierta” una clase o un valor numérico, sino en comprobar si la estructura descubierta en los datos es coherente, estable y útil para el objetivo que perseguimos.

Esto hace que la evaluación en aprendizaje no supervisado sea, en general, menos directa. El modelo puede encontrar grupos, relaciones o patrones interesantes, pero eso no significa automáticamente que dichos patrones sean correctos o relevantes para el problema real. Por tanto, el *testing* debe combinar criterios cuantitativos con criterios cualitativos y de negocio.

Una primera idea importante es la estabilidad. Si al aplicar el mismo método sobre distintas muestras del *dataset*, o sobre particiones diferentes, aparecen estructuras parecidas, tendremos una señal de que el modelo está captando regularidades reales y no simples casualidades de una muestra concreta. En cambio, si pequeñas variaciones en los datos producen resultados completamente distintos, el modelo será poco fiable.

Otra idea fundamental es la coherencia interna. En muchos problemas no supervisados, especialmente en *clustering*, se espera que los elementos de un mismo grupo sean similares entre sí y que, al mismo tiempo, estén razonablemente separados de los elementos de otros grupos. De esta forma, aunque no haya etiquetas verdaderas, sí podemos medir si la estructura encontrada tiene sentido desde el punto de vista geométrico o estadístico.

En la práctica, el *testing* en aprendizaje no supervisado suele apoyarse en las siguientes estrategias:

- **Métricas internas de calidad:** evalúan la estructura descubierta usando únicamente los propios datos. En *clustering*, por ejemplo, se utilizan métricas como el coeficiente de *silhouette*, que mide si los puntos están bien agrupados y separados, el índice Davies-Bouldin, que penaliza grupos poco compactos o muy solapados, y el índice Calinski-Harabasz, que valora la separación entre grupos y la cohesión interna de cada uno.
- **Evaluación de estabilidad:** consiste en repetir el proceso con distintas particiones o semillas aleatorias para comprobar si los resultados se mantienen. Esta estrategia es especialmente útil cuando varios modelos obtienen métricas parecidas y queremos saber cuál es más robusto.
- **Validación externa:** en algunos casos puede existir conocimiento adicional que no se ha usado para entrenar el modelo, como etiquetas aproximadas, criterio experto o información histórica. Aunque el aprendizaje siga siendo no supervisado, esta referencia externa puede emplearse como verificación complementaria para comprobar si los patrones descubiertos son razonables.
- **Utilidad práctica para el negocio o la tarea:** un modelo no supervisado puede producir grupos estadísticamente correctos, pero poco útiles en la práctica. Por ejemplo, en una segmentación de clientes no basta con que los grupos estén bien separados, también deben ser interpretables y permitir tomar decisiones distintas en marketing, atención al cliente o diseño de productos.

En los problemas de *clustering*, el *testing* se centra sobre todo en la calidad de los grupos obtenidos. Se busca que cada grupo sea internamente homogéneo y externamente diferente a los demás. Además, conviene revisar si el número de grupos elegido tiene sentido y si los *clusters* encontrados pueden interpretarse con claridad. Un agrupamiento con muy buena métrica interna, pero imposible de explicar o sin aplicación práctica, tendrá poco valor real.

En reducción de dimensionalidad, la evaluación persigue comprobar si la proyección conserva la información importante del *dataset* original. En métodos lineales como PCA suele analizarse la cantidad de varianza explicada por las nuevas dimensiones. También puede estudiarse si la proyección preserva vecindades o relaciones entre observaciones, algo especialmente relevante cuando el objetivo es visualizar los datos en dos o tres dimensiones sin perder su estructura esencial.

En detección de anomalías no supervisada, el *testing* consiste en analizar si los casos marcados como anómalos realmente parecen raros o problemáticos. Como no suele haber una etiqueta previa de “anomalía” para todos los ejemplos, la evaluación se apoya mucho en revisión manual, conocimiento experto y utilidad operativa. Por ejemplo, si un sistema detecta demasiadas falsas alarmas, aunque encuentre *outliers* desde el punto de vista matemático, puede resultar poco útil en producción.

Por todo ello, en aprendizaje no supervisado no conviene elegir un modelo únicamente por una métrica numérica aislada. Lo adecuado es combinar varias evidencias: calidad interna, estabilidad, interpretabilidad y utilidad para la tarea concreta. El objetivo final no es solo encontrar patrones en los datos, sino descubrir patrones que sean consistentes y que aporten valor real.

Como buena práctica general, también aquí conviene fijar el protocolo de evaluación antes de analizar los resultados, documentar las particiones y semillas empleadas, y justificar por qué se selecciona un modelo frente a otro. De este modo, aunque no existan etiquetas verdaderas, la evaluación seguirá siendo rigurosa, reproducible y orientada a obtener conclusiones fiables.

3.2.5 Paso 5: Mejora continua

La mejora continua es la fase del ciclo de vida del *Machine Learning* en la que, una vez desplegado el modelo en producción, se supervisa su comportamiento para mantener y mejorar su rendimiento con el paso del tiempo. Esta etapa no consiste únicamente en modificar el algoritmo, sino también en revisar los datos, incorporar nuevas fuentes de información, mejorar el etiquetado, ajustar el preprocesado y recalibrar umbrales o probabilidades cuando sea necesario. En la práctica, este proceso se apoya en la monitorización de métricas técnicas y de negocio, en la detección de posibles cambios en los datos y en el análisis de errores para identificar las causas de una eventual degradación del modelo.

Su importancia radica en que los modelos pueden perder eficacia a medida que cambian los datos, el contexto o las necesidades de uso. Por ello, la mejora continua permite actualizar el sistema, reducir riesgos técnicos y operativos, y mantener su utilidad en el tiempo. Además, favorece la trazabilidad, la revisión periódica del modelo y una evaluación más rigurosa de su comportamiento, de modo que los resultados no se entiendan como definitivos, sino como susceptibles de revisión y perfeccionamiento continuo.

3.3 Resumen del apartado

El *Machine Learning* es una rama de la Inteligencia Artificial que permite a los sistemas **aprender a partir de datos** para realizar predicciones, clasificaciones o agrupamientos, sin necesidad de programar explícitamente todas las reglas. Su desarrollo sigue un **ciclo de vida iterativo**, en el que la calidad de los datos y la correcta evaluación del modelo son tan importantes como el algoritmo elegido.

Elemento clave	Idea principal
Finalidad	Aprender patrones a partir de datos para predecir, clasificar o tomar decisiones
Algoritmo	Método de aprendizaje utilizado
Modelo	Resultado entrenado que se aplica a nuevos datos
Base del proceso	Datos de calidad, entrenamiento, evaluación y mejora continua

Tabla 3. Resumen conceptos clave

Fase del ciclo de vida	Contenido esencial
Obtención de datos	Recoger datos relevantes y representativos
Preparación de datos	Limpiar, transformar y seleccionar variables
Entrenamiento	Elegir tipo de aprendizaje y ajustar el modelo
Evaluación	Medir el rendimiento con datos no vistos
Mejora continua	Revisar, corregir y actualizar el modelo

Tabla 4. Fases del ciclo de vida

Tipos de aprendizaje	Característica básica
Supervisado	Usa datos etiquetados
No supervisado	Busca patrones sin etiquetas
Semi-supervisado	Combina pocos datos etiquetados con muchos sin etiquetar
Por refuerzo	Aprende mediante recompensas y penalizaciones

Tabla 5. Tipos de aprendizaje

Aspectos críticos	Importancia
Calidad del dato	Condiciona directamente el resultado
Hiperparámetros	Influyen en el rendimiento del modelo
<i>Overfitting / underfitting</i>	Deben evitarse para mejorar la generalización
Elección del algoritmo	Depende del problema y del tipo de datos

Tabla 6. Aspectos críticos ML

4 REDES NEURONALES Y *DEEP LEARNING*

Las redes neuronales son un tipo de modelo de aprendizaje automático inspirado en el funcionamiento de las neuronas biológicas. Su importancia radica en que permiten aprender patrones complejos directamente a partir de los datos, sin necesidad de definir manualmente todas las reglas o características relevantes. Gracias a ello, resultan especialmente útiles en problemas como el reconocimiento de imágenes, el procesamiento del lenguaje natural, la voz o el análisis de secuencias temporales.

Cuando estas redes cuentan con múltiples capas y una gran capacidad de representación, hablamos de *deep learning* o aprendizaje profundo. En este apartado se estudiarán primero la neurona artificial y el perceptrón como base conceptual, para después analizar el papel de las funciones de activación y las principales arquitecturas de redes neuronales, como las redes multicapa, convolucionales, recurrentes y los transformadores, junto con otras variantes de interés actual.

4.1 La neurona y el perceptrón

Las redes neuronales están formadas por unidades básicas llamadas neuronas artificiales. Estas unidades toman inspiración, de manera muy simplificada, en el funcionamiento de las neuronas biológicas. En un sistema nervioso, una neurona recibe señales de otras neuronas, las integra y, si se supera un determinado umbral, transmite un impulso hacia las siguientes. En las redes neuronales artificiales ocurre algo parecido: cada neurona recibe una serie de valores de entrada, los combina mediante una operación matemática y produce una salida que puede ser utilizada por otras neuronas de la red. Por tanto, la neurona constituye el bloque elemental a partir del cual se construyen modelos más complejos.




Figura 20: Diagrama de una neurona. Fuente: [Wikipedia](#).

En una neurona artificial, cada entrada representa una característica del problema que se quiere resolver. Estas entradas pueden corresponder, por ejemplo, a valores numéricos, píxeles de una imagen, medidas de un sensor o palabras previamente transformadas en vectores. Cada una de esas entradas se multiplica por un peso, que indica la importancia que tiene dentro de la decisión de la neurona. Si un peso es alto y positivo, esa entrada tendrá una influencia mayor sobre el resultado; si es negativo, actuará en sentido contrario. Además, la neurona incorpora un término adicional llamado sesgo o bias, que permite desplazar la decisión y aporta mayor flexibilidad al modelo. La combinación de entradas, pesos y sesgo da lugar a un valor intermedio sobre el que después se aplica una función para obtener la salida final de la neurona.

De forma simplificada, puede decirse que la neurona artificial realiza tres pasos. Primero, recibe las entradas. Después, calcula una suma ponderada de esas entradas junto con el sesgo. Finalmente, transforma ese resultado en una salida. Esta salida puede interpretarse como una señal que se transmite a otras neuronas o, en algunos casos, como la predicción final del sistema. Lo importante es que los pesos y el sesgo no se fijan manualmente, sino que se ajustan durante el entrenamiento para que la neurona aprenda a responder cada vez mejor a los ejemplos que se le presentan.

A partir de esta idea básica surge el perceptrón, que puede entenderse como la forma más sencilla de red neuronal. El perceptrón utiliza una única neurona para tomar una decisión a partir de varias entradas. Recibe los valores de entrada, los multiplica por sus pesos, suma también el sesgo y produce una

salida que permite clasificar el ejemplo en una categoría u otra. Por ello, el perceptrón puede verse como un clasificador elemental capaz de aprender reglas simples a partir de datos de entrenamiento.




Figura 21: Diagrama de un perceptrón con cinco señales de entrada. Fuente: [Wikipedia](#).

La importancia histórica del perceptrón radica en que fue uno de los primeros modelos que mostró que una máquina podía aprender ajustando automáticamente sus parámetros. Su aprendizaje consiste en comparar la salida obtenida con la respuesta correcta y modificar los pesos cuando se ha cometido un error. De este modo, tras muchas iteraciones, el perceptrón va corrigiéndose y mejora progresivamente su capacidad de clasificación. Este proceso de ajuste constituye una de las bases del aprendizaje en redes neuronales más avanzadas.

Sin embargo, el perceptrón también presenta limitaciones. Al estar formado por una única neurona, solo puede resolver problemas relativamente simples, especialmente aquellos en los que las clases pueden separarse mediante una frontera lineal. Cuando el problema exige capturar relaciones más complejas entre las variables, es necesario conectar varias neuronas y varias capas, dando lugar a redes neuronales multicapa. Aun así, estudiar el perceptrón sigue siendo fundamental, porque permite comprender de manera sencilla la lógica básica sobre la que se construyen las redes neuronales modernas: recibir información, combinarla, producir una salida y ajustar sus parámetros para aprender de la experiencia.

4.1.1 Aprendizaje del perceptrón

El aprendizaje del perceptrón consiste en ajustar los pesos de sus conexiones y el sesgo con el objetivo de corregir los errores de clasificación cometidos durante el entrenamiento. Para ello, se utilizan ejemplos previamente conocidos: el modelo recibe unas entradas, calcula una salida y la compara con el valor esperado. Si la predicción es correcta, no se modifican los parámetros; si es incorrecta, los pesos y el sesgo se actualizan para favorecer una respuesta adecuada en iteraciones posteriores. De este modo, el aprendizaje puede entenderse como un proceso iterativo de predicción, comparación y corrección.

En el perceptrón clásico, este ajuste se realiza mediante una regla de aprendizaje sencilla: los parámetros se modifican únicamente cuando el modelo comete un error. La magnitud de dicha corrección viene determinada por la tasa de aprendizaje, un parámetro que regula la intensidad de cada ajuste. Si la tasa de aprendizaje es demasiado alta, el proceso puede volverse inestable; si es demasiado baja, la convergencia resulta más lenta. Por ello, su elección es importante para lograr un entrenamiento eficaz.

Este procedimiento se repite durante varias épocas, es decir, varios recorridos completos por el conjunto de entrenamiento, hasta que el perceptrón encuentra una frontera de decisión adecuada para separar las clases, siempre que el problema sea linealmente separable. En consecuencia, la idea fundamental del aprendizaje del perceptrón es que el modelo mejora corrigiendo de forma progresiva los errores cometidos. Este principio constituye una base conceptual importante para comprender el funcionamiento de redes neuronales más complejas.

4.1.2 Funciones de activación

Las funciones de activación son el mecanismo que permite a una neurona artificial transformar la combinación lineal de sus entradas en una salida útil para la red. Después de multiplicar cada entrada por su peso correspondiente y sumar el sesgo, la neurona obtiene un valor intermedio. Sin embargo, si la red se limitara a encadenar únicamente estas combinaciones lineales, su capacidad de aprendizaje sería muy reducida, ya que, aunque se añadieran muchas capas, el resultado seguiría siendo esencialmente lineal. Por ello, la función de activación introduce **no linealidad**, haciendo posible que la red aprenda relaciones complejas entre las variables de entrada y la salida esperada.

La importancia de estas funciones radica en que condicionan directamente el comportamiento de la red neuronal. Determinan cómo responde una neurona ante distintos valores, influyen en la estabilidad del entrenamiento y afectan a la velocidad con la que el modelo aprende. Además, no todas las funciones de activación son adecuadas para cualquier situación. Algunas resultan más apropiadas en capas ocultas, otras en la capa de salida, y su elección depende del tipo de problema que se quiera resolver, como clasificación binaria, clasificación multiclase o regresión. En consecuencia, seleccionar correctamente la función de activación constituye una decisión relevante en el diseño de una red neuronal.

Entre las funciones de activación más utilizadas destacan la **sigmoide**, la **tangente hiperbólica**, la **ReLU** y la **softmax**. La sigmoide transforma cualquier valor en un resultado comprendido entre 0 y 1, por lo que resulta especialmente útil cuando se desea interpretar la salida del modelo como una probabilidad. La tangente hiperbólica produce valores entre -1 y 1 y presenta la ventaja de estar centrada en cero, lo que en algunos casos facilita el aprendizaje. La función ReLU, por su parte, se ha convertido en una de las más empleadas en capas ocultas debido a su sencillez computacional y a su buen comportamiento en redes profundas. Finalmente, la función softmax se utiliza habitualmente en problemas de clasificación multiclase, ya que convierte un conjunto de valores en probabilidades cuya suma total es 1.

Conviene subrayar, como idea básica para su estudio, que las funciones de activación no son un elemento accesorio, sino una pieza esencial para que las redes neuronales puedan aprender patrones complejos. En términos generales, puede recordarse que **la sigmoide y la softmax se asocian con salidas probabilísticas**, que **la tangente hiperbólica ofrece una salida centrada en cero** y que **la ReLU destaca por su simplicidad y eficacia en capas internas**. De este modo, el análisis de estas funciones permite comprender mejor por qué una red neuronal puede adaptarse a problemas muy diferentes y cómo cada una de sus neuronas decide cuánto debe activarse ante la información recibida.

Función de activación	Fórmula	Ventajas	Desventajas	Dónde se suele usar
Sigmoide	$\sigma(x) = \frac{1}{1 + e^{-x}}$	Devuelve valores entre 0 y 1; fácil de interpretar como probabilidad; suave y continua	Puede saturarse en valores extremos; favorece el problema del gradiente desvanecido; no está centrada en cero	Capa de salida en clasificación binaria y problemas multietiqueta
Tangente hiperbólica (tanh)	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	Devuelve valores entre -1 y 1; está centrada en cero; suele aprender mejor que la sigmoide en algunos casos	También puede saturarse; puede sufrir gradiente desvanecido en redes profundas	Capas ocultas en redes sencillas o poco profundas
ReLU	$\text{ReLU}(x) = \max(0, x)$	Muy simple y rápida de calcular; reduce el problema del gradiente desvanecido en la parte positiva; funciona bien en redes profundas	Puede provocar neuronas muertas si la salida queda siempre en 0 para valores negativos	Capas ocultas en redes multicapa y redes profundas
Softmax	$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$	Convierte varias salidas en probabilidades cuya suma es 1; adecuada para elegir una clase entre varias	No se usa en capas ocultas; supone clases mutuamente excluyentes; sensible a valores extremos	Capa de salida en clasificación multiclase

Tabla 7. Funciones de activación

4.2 Arquitecturas de redes neuronales

Las redes neuronales no constituyen una única estructura, sino una familia amplia de arquitecturas diseñadas para adaptarse a la naturaleza de los datos y al tipo de problema que se desea resolver. Aunque todas comparten la misma idea general de aprender a partir de ejemplos ajustando sus conexiones internas, no todas procesan la información del mismo modo. Algunas están especialmente preparadas para trabajar con datos espaciales, como las imágenes; otras resultan más adecuadas para datos secuenciales, donde el orden de los elementos es esencial; y otras han sido concebidas para capturar relaciones complejas a gran escala y permitir tareas avanzadas de comprensión y generación. Precisamente por ello, el estudio de las arquitecturas resulta fundamental, ya que muestra cómo una misma base teórica puede dar lugar a soluciones muy distintas según las necesidades del problema.

4.2.1 Redes neuronales multicapa

Las redes neuronales multicapa surgen como una ampliación del perceptrón simple para superar sus limitaciones. Frente a una única neurona o una sola capa de decisión, estas redes incorporan varias capas de neuronas conectadas entre sí, lo que les permite aprender relaciones mucho más complejas entre los datos de entrada y la salida esperada. Gracias a esta estructura, pueden modelar problemas no lineales y construir representaciones internas cada vez más elaboradas a medida que la información avanza por la red.

En una red neuronal multicapa pueden distinguirse las siguientes capas:

- **Capa de entrada:** es la encargada de recibir los datos iniciales del problema. Cada neurona de esta capa representa una variable de entrada, como puede ser un valor numérico, un píxel de una imagen o cualquier característica relevante del caso que se desea analizar.
- **Capas ocultas:** son las capas intermedias situadas entre la entrada y la salida. En ellas se realiza el procesamiento principal de la información, combinando los valores recibidos mediante pesos, sesgos y funciones de activación. Su importancia radica en que permiten a la red aprender patrones intermedios y representaciones cada vez más abstractas.
- **Capa de salida:** es la capa final de la red y proporciona el resultado del modelo. Según el tipo de problema, puede devolver una clase, una probabilidad o un valor numérico.




Figura 22: Red neuronal con sus capas de entrada, ocultas y de salida. Fuente: [Wikipedia](#).

El aprendizaje de estas redes se realiza mediante la técnica de **backpropagation** o **retropropagación del error**. Primero se produce una propagación hacia delante, en la que la información atraviesa la red desde la capa de entrada hasta la capa de salida. Después, la predicción obtenida se compara con la respuesta correcta y se calcula el error cometido. A continuación, ese error se propaga hacia atrás por la red para determinar en qué medida ha contribuido cada conexión al resultado incorrecto. De este modo, los pesos se ajustan gradualmente, normalmente mediante descenso por gradiente, para reducir el error en sucesivas iteraciones. Gracias a este procedimiento, las redes multicapa pueden aprender de manera progresiva y constituyen la base del aprendizaje profundo.

4.2.2 Redes neuronales convolucionales

Las redes neuronales convolucionales son un tipo de red neuronal artificial especialmente diseñada para el análisis de imágenes y otras tareas de visión por computador. Su funcionamiento se basa en operaciones matemáticas denominadas convoluciones, aplicadas sobre matrices que representan los datos de entrada. Estas redes permiten identificar patrones visuales, clasificar imágenes y segmentar elementos dentro de una escena.

En una red neuronal convolucional, las neuronas artificiales se organizan de forma que cada una procesa una región concreta de la entrada, conocida como campo receptivo, de manera similar a lo que ocurre en la corteza visual primaria de los sistemas biológicos. Este enfoque permite extraer características relevantes de forma jerárquica, desde rasgos simples, como bordes o texturas, hasta estructuras más complejas.

Las redes convolucionales trabajan habitualmente con matrices bidimensionales, lo que las hace especialmente adecuadas para tareas como la clasificación y segmentación de imágenes. Durante el entrenamiento, la red ajusta parámetros aprendibles, como pesos y sesgos, para optimizar su capacidad de reconocimiento. Debido a la elevada carga computacional de este proceso, es habitual utilizar unidades de procesamiento gráfico (GPU), que aceleran significativamente los cálculos.

Entre sus principales aplicaciones se encuentran la detección de objetos, la clasificación de imágenes, el reconocimiento facial y la segmentación semántica.

Estas redes se componen, principalmente, de las siguientes capas:

- **Capa convolucional:** en ella se aplican filtros o núcleos de convolución sobre los datos de entrada para extraer características relevantes.
- **Capa de agrupamiento o *pooling*:** reduce la dimensionalidad de la representación interna, normalmente mediante operaciones como el máximo o la media. Aunque este proceso implica cierta pérdida de información, contribuye a disminuir la complejidad computacional y el riesgo de sobreajuste.
- **Capas completamente conectadas:** se sitúan habitualmente al final de la red y se encargan de realizar la clasificación final a partir de las características extraídas por las capas anteriores.




Figura 23: Red neuronal convolucional. Fuente: [Wikipedia](https://en.wikipedia.org/wiki/Convolutional_neural_network).

4.2.3 Redes neuronales recurrentes

A diferencia de otras arquitecturas neuronales, las redes neuronales recurrentes están específicamente diseñadas para el tratamiento de datos secuenciales. Su rasgo distintivo radica en que, al procesar cada elemento de la secuencia, no consideran únicamente la información presente en ese instante, sino también parte del contexto previamente procesado. Gracias a ello, resultan especialmente adecuadas para tareas en las que el orden de los datos desempeña un papel esencial, como el procesamiento del lenguaje, el análisis de señales de audio o el estudio de series temporales.

Desde un punto de vista funcional, una red recurrente procesa la secuencia de manera progresiva, de modo que la información obtenida en cada paso influye en el tratamiento del siguiente. Así, cada elemento no se analiza de forma aislada, sino en relación con los anteriores. Esta característica constituye la principal diferencia con respecto a otros modelos que tratan cada entrada como una observación independiente, sin incorporar de forma explícita la dependencia temporal o contextual.




Figura 24: Red neuronal recurrente. Fuente: [Wikipedia](#).

Una red neuronal recurrente, o **RNN** (*Recurrent Neural Network*), puede definirse como una arquitectura que, además de recibir una entrada en cada instante, mantiene un estado interno que se actualiza de manera sucesiva a lo largo de la secuencia. Dicho estado actúa como un mecanismo de memoria, ya que conserva información relevante de los pasos anteriores y la incorpora al procesamiento del paso actual. De este modo, las RNN pueden modelar secuencias en las que existen relaciones de dependencia entre elementos separados en el tiempo o en la posición.

Este enfoque resulta especialmente útil en problemas donde intervienen componentes temporales o dependencias contextuales de distinta longitud. Sin embargo, las RNN clásicas presentan limitaciones cuando deben capturar relaciones a largo plazo, debido a que la información relevante puede debilitarse progresivamente a medida que avanza la secuencia. Para paliar este problema surgieron arquitecturas más avanzadas, como **LSTM** (*Long Short-Term Memory*) y **GRU** (*Gated Recurrent Unit*), que incorporan mecanismos de compuertas capaces de regular el flujo de información y facilitar la conservación de dependencias durante un mayor número de iteraciones.




Figura 25: Arquitectura LSTM. Fuente: [Wikipedia](#).

4.2.4 Transformadores

Los transformadores constituyen la arquitectura que supuso un punto de inflexión en el procesamiento del lenguaje natural y, de forma más amplia, en la evolución reciente de la Inteligencia Artificial. Su formulación fue presentada en 2017 por Vaswani y sus colaboradores en el artículo [Attention Is All You Need](#), y desde entonces se han convertido en la base de muchos de los sistemas más avanzados de comprensión y generación de texto. Su importancia radica en que ofrecieron una alternativa mucho más eficaz que las arquitecturas secuenciales anteriores para modelar relaciones complejas dentro de una secuencia.

La principal ventaja de los transformadores frente a las redes recurrentes reside en que no procesan la información palabra a palabra de manera estrictamente secuencial, sino que pueden analizar la secuencia completa al mismo tiempo. Esto permite, en primer lugar, un entrenamiento mucho más eficiente gracias al paralelismo computacional. En segundo lugar, facilita captar dependencias de largo alcance entre elementos muy alejados dentro de una oración o un texto, algo que resultaba más difícil en arquitecturas anteriores, donde la información podía debilitarse a medida que avanzaba la secuencia. Además, los transformadores escalan especialmente bien cuando se entrenan con grandes volúmenes de datos y una elevada capacidad de cálculo, razón por la cual han servido de base para los grandes modelos de lenguaje actuales. A ello se añade su versatilidad, ya que la misma idea arquitectónica se ha extendido también a visión por computador, audio y sistemas multimodales.

El elemento central que explica esta eficacia es el **mecanismo de atención**. La atención permite que, al procesar una palabra concreta, el modelo pueda valorar qué otras palabras de la secuencia son más relevantes para interpretarla correctamente. En lugar de depender solo de los elementos inmediatamente anteriores, cada posición del texto puede “mirar” al resto y asignar distintos grados de importancia a cada palabra. Así, si en una oración una palabra depende semánticamente de otra situada mucho antes, el modelo puede relacionarlas de forma directa. Este mecanismo hace posible construir representaciones más ricas del contexto y resolver mejor problemas como la ambigüedad, la concordancia o la referencia entre términos alejados.

Desde un punto de vista más técnico, la atención se implementa a partir de tres componentes llamados **query** (consulta), **key** (clave) y **value** (valor). Cada palabra se transforma en estas tres representaciones y el modelo compara la consulta de una palabra con las claves de todas las demás para medir su afinidad. Cuanto mayor sea esa afinidad, mayor peso tendrá la información de esa

palabra en la representación final. El resultado es una combinación ponderada de valores que resume qué partes del texto son más importantes en cada caso. En los transformadores se utiliza, además, la llamada **autoatención**, porque cada elemento de la secuencia se relaciona con los demás elementos de la propia secuencia. Habitualmente este proceso se realiza mediante varias cabezas de atención en paralelo, lo que permite captar distintos tipos de relación al mismo tiempo.

En cuanto a su arquitectura, el transformador clásico se organiza en dos grandes bloques: un **codificador** y un **decodificador**. El codificador recibe la secuencia de entrada y genera una representación contextualizada de ella. El decodificador utiliza esa representación para producir la secuencia de salida, token a token. Antes de entrar en estos bloques, cada palabra o subpalabra se convierte en un **embedding**, es decir, en un vector numérico. Como el transformador no procesa los datos secuencialmente, es necesario añadir también una **codificación posicional**, que introduce información sobre el orden de los elementos en la secuencia.




Figura 26: Arquitectura transformadores. Fuente: [Arxiv](#).

Cada bloque del codificador contiene, de forma simplificada, dos partes principales. La primera es una capa de **autoatención multi-cabeza**, que permite que cada palabra tenga en cuenta a todas las demás. La segunda es una **red neuronal feed-forward**, que transforma la información obtenida en cada posición. Ambas partes están acompañadas de conexiones residuales y procesos de normalización, que ayudan a estabilizar y facilitar el entrenamiento. El decodificador presenta una estructura similar, pero añade una diferencia importante: incorpora una **atención enmascarada**, para evitar que durante la generación una palabra pueda “ver” las que todavía no se han producido, y una **atención cruzada**, mediante la cual consulta la representación generada por el codificador.

Gracias a esta arquitectura, los transformadores pueden comprender el contexto de forma muy precisa y generar texto coherente manteniendo dependencias complejas a lo largo de secuencias extensas. Esta capacidad explica que se hayan convertido en la base de modelos actuales de traducción automática, resumen, clasificación de textos, respuesta a preguntas y, especialmente, de los grandes

modelos de lenguaje. En consecuencia, los transformadores no solo representan una mejora técnica respecto a arquitecturas anteriores, sino también el fundamento sobre el que se ha construido buena parte de la Inteligencia Artificial contemporánea.

4.2.5 Arquitecturas de IA Generativa

La **Inteligencia Artificial Generativa** no se limita a reconocer patrones en los datos, sino que busca aprender su estructura para producir ejemplos nuevos y verosímiles. Así, un modelo entrenado con imágenes puede generar imágenes plausibles, y uno entrenado con audio puede producir sonidos realistas. Cuando esta generación se guía mediante una instrucción concreta, se habla de **generación condicionada**. En todos los casos, la idea fundamental es la misma: el modelo aprende a partir de numerosos ejemplos y utiliza ese aprendizaje para crear nuevas salidas coherentes con los datos originales.

Esta capacidad se apoya principalmente en **redes neuronales**, que aprenden representaciones internas de los datos y las utilizan para generar nuevos contenidos. En lenguaje, los modelos basados en transformadores producen texto de manera secuencial; en visión, otras arquitecturas permiten crear o modificar imágenes a partir de descripciones. En lugar de memorizar ejemplos aislados, estos sistemas aprenden una representación compacta de los rasgos esenciales de los datos, lo que les permite generar variaciones consistentes.

Una forma útil de comprender este proceso es el concepto de **espacio latente**, entendido como una representación interna donde se organizan los rasgos relevantes de los datos. Esta idea está presente en distintas arquitecturas generativas. En los **VAE**, el modelo aprende a codificar los datos en ese espacio y a reconstruirlos; en los **GAN**, un generador produce ejemplos a partir de puntos aleatorios mientras un discriminador evalúa su realismo; y en los **modelos de difusión**, el proceso parte del ruido y aprende a transformarlo progresivamente en una muestra nítida. Aunque cada enfoque sigue una estrategia distinta, todos comparten un mismo objetivo: representar adecuadamente los datos y generar nuevos ejemplos de forma controlada.

4.2.5.1 Variational Autoencoders, VAE

Un **VAE** (*Variational Autoencoder*) consta de dos partes principales: un **codificador**, que transforma un dato real en una representación dentro del **espacio latente**, y un **decodificador**, que reconstruye el dato original a partir de dicha representación. Durante el entrenamiento, el modelo no solo aprende a reconstruir correctamente los ejemplos, sino también a organizar el espacio latente de forma coherente, de modo que puntos cercanos representen casos similares. Este equilibrio es esencial, ya que un exceso de atención a la reconstrucción puede conducir a la memorización, mientras que una excesiva regularización del espacio latente puede empobrecer la calidad de las reconstrucciones.

Para generar nuevos datos con un VAE, se selecciona un punto del espacio latente y se utiliza el decodificador para transformarlo en una nueva muestra. Además, es posible realizar **generación condicionada**, incorporando información adicional tanto en el codificador como en el decodificador. Por ejemplo, en generación de imágenes, puede indicarse una clase determinada, para orientar la salida hacia una categoría concreta.





Figura 27: Esquema VAE. Fuente: [Wikipedia](https://es.wikipedia.org/wiki/Variational_Autoencoder).

Los VAE destacan por la **estabilidad de su entrenamiento** y por proporcionar un **espacio latente estructurado**, útil para tareas como la compresión, la interpolación o la modificación de rasgos. Su limitación más habitual es que las muestras generadas, especialmente en imágenes, pueden resultar algo difusas o poco nítidas. Por ello, suelen emplearse cuando interesa disponer de una representación interna ordenada y manipulable, más que maximizar el realismo visual extremo.

4.2.5.2 Redes Adversarias Generativas, GAN

Una **GAN** (*Generative Adversarial Network*) se entrena mediante la interacción entre dos redes neuronales con objetivos opuestos. Por un lado, el **generador** produce ejemplos sintéticos a partir de ruido aleatorio; por otro, el **discriminador** trata de distinguir entre ejemplos reales y generados. Durante el entrenamiento, ambos modelos mejoran de forma conjunta: el generador aprende a crear muestras cada vez más realistas, mientras que el discriminador se vuelve más preciso al detectarlas. Este proceso competitivo es el que permite a la GAN refinar progresivamente la calidad de sus resultados.

A race toward photorealism



SOURCE: K. SEELIGER ET AL / NEUROIMAGE 2018

KNOWABLE MAGAZINE

Figura 28: Esquema GAN. Fuente: [Knowable Magazine](#).

Una vez entrenada, la generación de nuevos datos se realiza introduciendo un vector de ruido en el generador, que lo transforma en una muestra sintética no presente en el conjunto original. La principal fortaleza de las GAN es su elevada **fidelidad visual**, especialmente en tareas de generación de imágenes, donde pueden producir resultados muy nítidos y realistas.

No obstante, las GAN presentan también dificultades importantes. Su entrenamiento puede resultar inestable y aparece con frecuencia el problema del **colapso de modos**, en el que el generador produce un número reducido de variantes de alta calidad, pero con escasa diversidad. A pesar de ello, siguen siendo una opción especialmente adecuada cuando se prioriza el realismo visual y se dispone del tiempo y los recursos necesarios para ajustar cuidadosamente el proceso de entrenamiento.

4.2.5.3 Modelos de difusión

Los **modelos de difusión** parten de una idea sencilla: aprenden a invertir un proceso gradual de destrucción de la información. Durante el entrenamiento, a los datos originales, por ejemplo, imágenes, se les añade ruido de forma progresiva hasta convertirlos en una señal casi irreconocible. El modelo aprende entonces el proceso inverso, es decir, a eliminar ese ruido paso a paso hasta reconstruir una muestra coherente. Para ello, se le presentan ejemplos parcialmente degradados y se le entrena para

predecir una versión menos ruidosa. Repetido muchas veces, este procedimiento permite al modelo aprender cómo recuperar la estructura de los datos originales.




Figura 29: Modelo de difusión. Fuente: [Wikipedia](#).

Una vez entrenado, el proceso de generación comienza a partir de ruido puro. A lo largo de múltiples pasos sucesivos, el modelo va refinando esa señal inicial hasta transformarla en una muestra nítida y verosímil. Además, este proceso puede condicionarse mediante información adicional, como texto, etiquetas o imágenes de referencia. En los sistemas de generación texto a imagen, esta guía suele integrarse mediante mecanismos de atención, que permiten al modelo utilizar la descripción textual para orientar progresivamente la creación del contenido visual.

Los modelos de difusión destacan por ofrecer una combinación especialmente sólida de **calidad, diversidad y estabilidad de entrenamiento**. Frente a otras arquitecturas generativas, suelen producir resultados de gran nivel manteniendo una amplia variedad de muestras. Su principal inconveniente reside en el coste computacional del proceso de generación, ya que requiere múltiples iteraciones para eliminar el ruido de forma gradual. Por ello, suelen ser especialmente adecuados cuando se busca un equilibrio robusto entre realismo y diversidad, especialmente en tareas de generación condicionada compleja.

4.3 Resumen del apartado

Las redes neuronales son modelos inspirados en el funcionamiento de las neuronas biológicas que permiten aprender patrones complejos a partir de los datos. Cuando estas redes incorporan múltiples capas ocultas, se habla de **deep learning**, técnica especialmente eficaz en tareas como visión artificial, procesamiento del lenguaje, voz e Inteligencia Artificial generativa. La base de estos sistemas está en la **neurona artificial**, el **perceptrón**, el ajuste de **pesos** durante el aprendizaje y el uso de **funciones de activación** para introducir no linealidad.

Elemento clave	Idea principal
Neurona artificial	Unidad básica que combina entradas, pesos y sesgo
Perceptrón	Modelo elemental de clasificación
Funciones de activación	Permiten modelar relaciones no lineales
Deep learning	Redes con múltiples capas capaces de aprender representaciones complejas

Tabla 8. Conceptos clave

Las arquitecturas principales de redes neuronales se diferencian por el tipo de problema que resuelven:

Arquitectura	Aplicación principal
Multicapa	Clasificación y predicción general
Convolutacional (CNN)	Imágenes y visión artificial
Recurrente (RNN)	Secuencias y series temporales
Transformadores	Lenguaje natural e IA generativa

Tabla 9. Principales arquitecturas neuronales

En el ámbito de la **IA generativa** sobresalen tres arquitecturas:

Arquitectura generativa	Rasgo esencial
VAE	Generación a partir de espacios latentes
GAN	Competencia entre generador y discriminador
Difusión	Generación progresiva desde ruido

Tabla 10. Arquitecturas IA generativa

5 PROCESAMIENTO DEL LENGUAJE NATURAL

El **Procesamiento del Lenguaje Natural (PLN)** es la rama de la Inteligencia Artificial que estudia y desarrolla técnicas para que las máquinas puedan trabajar con el lenguaje humano, tanto en su forma escrita como hablada. Su finalidad es que un sistema informático sea capaz de **reconocer, comprender, analizar y generar lenguaje** de manera útil para resolver problemas reales. Se trata de un campo especialmente relevante, ya que el lenguaje constituye uno de los principales medios de comunicación, organización del conocimiento e interacción entre las personas. Por ello, el PLN ocupa una posición central dentro de la Inteligencia Artificial moderna.

Las principales categorías de tareas que abarca el PLN son las siguientes:

- **Reconocimiento del lenguaje:** comprende las tareas relacionadas con la captación inicial del lenguaje de entrada. Su función es transformar señales lingüísticas en una forma procesable por el sistema. Tareas concretas: reconocimiento de voz, transcripción de audio a texto, detección de texto en documentos.
- **Comprensión del lenguaje:** incluye los procesos orientados a interpretar el contenido del lenguaje y convertirlo en representaciones internas que la máquina pueda manejar. En esta categoría se sitúan las tareas que buscan extraer significado, contexto y relaciones entre palabras o fragmentos de texto. Tareas concretas: análisis sintáctico, análisis semántico, tokenización, representación vectorial del texto.
- **Tareas sobre el lenguaje:** engloba las aplicaciones prácticas que se apoyan en la comprensión previa del texto para obtener información útil o resolver una necesidad concreta. Tareas concretas: resumen automático, detección de entidades, clasificación de textos, análisis de sentimientos, traducción automática, respuesta a preguntas.
- **Generación del lenguaje:** se refiere a la producción automática de nuevas salidas lingüísticas en forma de texto o voz. Su objetivo es que el sistema no solo interprete información, sino que también sea capaz de elaborar respuestas coherentes y adaptadas al contexto. Tareas concretas: generación de texto, *chatbots* y asistentes conversacionales, síntesis de voz, redacción automática de contenidos.




Figura 30: Tareas PLN. Elaboración propia.

En consecuencia, el Procesamiento del Lenguaje Natural no debe entenderse como una única técnica, sino como un conjunto amplio de métodos y tareas que cubren todo el ciclo del lenguaje: desde su reconocimiento inicial hasta su comprensión, análisis y generación final. Esta amplitud explica que el PLN tenga aplicaciones en ámbitos muy diversos, como los buscadores, los traductores automáticos, los asistentes virtuales, el análisis documental o los grandes modelos de lenguaje que se estudiarán en este apartado. Nótese que la aplicación por excelencia del PLN son los *chatbots*, ya que abarcan todos los tipos de tareas del PLN.

5.1 Conceptos relevantes

Antes de profundizar en las técnicas y modelos propios del Procesamiento del Lenguaje Natural, conviene definir algunos conceptos básicos que aparecen de forma frecuente en este ámbito. Estos términos permiten comprender mejor cómo se procesa el lenguaje, con qué unidades trabajan los modelos y sobre qué tipo de información se entrenan. Entre los más importantes destacan los siguientes:

- **Chatbot:** es un sistema informático diseñado para interactuar con las personas mediante lenguaje natural, ya sea por escrito o, en algunos casos, por voz. Su finalidad es simular una conversación y proporcionar respuestas útiles a preguntas, instrucciones o peticiones del usuario. Los *chatbots* pueden ser muy simples, funcionando mediante reglas predefinidas, o mucho más avanzados, apoyándose en técnicas de Procesamiento del Lenguaje Natural y en modelos de lenguaje capaces de comprender mejor el contexto y generar respuestas más flexibles. Actualmente se utilizan en atención al cliente, asistencia virtual, soporte técnico y entornos educativos, entre otros.
- **Token:** es la unidad mínima en la que un sistema divide el texto para poder procesarlo. En función del modelo y de la técnica empleada, un token puede corresponder a una palabra completa, a una parte de una palabra, a un signo de puntuación o incluso a un carácter. La tokenización es, por tanto, el proceso mediante el cual un texto se fragmenta en tokens. Esta operación es fundamental, porque los modelos de lenguaje no trabajan directamente con frases completas tal como las escribe una persona, sino con secuencias de estas unidades básicas, que después se transforman en representaciones numéricas para que la máquina pueda operar con ellas.
- **Corpus de documentos:** es el conjunto organizado de textos o documentos que se utiliza como base para analizar, entrenar o evaluar sistemas de Procesamiento del Lenguaje Natural. Un corpus puede estar formado por libros, artículos, páginas web, conversaciones, noticias, correos electrónicos o cualquier otra fuente textual relevante para el problema que se desea abordar. Su importancia radica en que la calidad, variedad y representatividad de ese conjunto de documentos condicionan directamente el rendimiento del sistema. En otras palabras, un modelo de lenguaje aprenderá en gran medida a partir del corpus con el que haya sido entrenado, por lo que la selección de este resulta una cuestión esencial.

5.2 Formas de representación lingüística y semántica en el PLN

Para que una máquina pueda trabajar correctamente con una oración no basta con identificar las palabras que la componen de forma aislada. También necesita captar aspectos fundamentales del lenguaje, como la **gramática**, la **sintaxis** y la **semántica**. La gramática permite reconocer la forma correcta de las expresiones. La sintaxis indica cómo se organizan las palabras dentro de la oración y qué relaciones mantienen entre sí. Por último, la semántica aporta el significado de los términos y del enunciado en su conjunto. En consecuencia, si un sistema quiere comprender el lenguaje, debe disponer de algún modo de representar no solo palabras sueltas, sino también sus relaciones, sus funciones dentro de la oración y el significado que transmiten. Precisamente por ello resultan necesarias las distintas formas de representación del conocimiento lingüístico.

En el ámbito del Procesamiento del Lenguaje Natural, las principales formas de representar el conocimiento del lenguaje son las siguientes:

- **Representación lógica:** consiste en expresar el conocimiento mediante reglas, hechos y relaciones formulados en un lenguaje formal. Permite describir con precisión conceptos y conexiones entre ellos, así como realizar inferencias lógicas. Su principal ventaja es la claridad y la capacidad de razonamiento explícito, aunque resulta menos flexible ante ambigüedades o significados difusos propios del lenguaje natural.
- **Redes semánticas:** representan el conocimiento como un conjunto de nodos y relaciones. Los nodos suelen corresponder a conceptos o entidades, mientras que las conexiones indican vínculos entre ellos, como pertenencia, propiedad o asociación. Este enfoque facilita visualizar cómo se relacionan los significados y permite organizar el conocimiento de forma estructurada.
- **Frames:** son estructuras que representan objetos, situaciones o conceptos mediante un conjunto de atributos o ranuras. Cada *frame* agrupa la información relevante de una entidad en una especie de esquema organizado. Por ejemplo, un *frame* sobre una persona podría incluir

nombre, edad, profesión o nacionalidad. Esta forma de representación resulta útil para describir situaciones típicas y conocimiento estructurado.

- **Ontologías:** son representaciones formales que definen los conceptos de un dominio, sus propiedades y las relaciones que existen entre ellos. Su finalidad es ofrecer un vocabulario común y bien definido que permita organizar el conocimiento de manera precisa y compartible entre sistemas. Las ontologías son especialmente útiles cuando se necesita interoperabilidad, coherencia semántica y capacidad de razonamiento más rigurosa.
- **Embeddings:** constituyen una representación numérica y distribuida del lenguaje, en la que palabras, frases o documentos se transforman en vectores dentro de un espacio continuo. La idea fundamental es que elementos con significados similares queden cerca entre sí en ese espacio. Esta forma de representación **es la base de muchos sistemas modernos** de PLN, ya que permite capturar semejanzas semánticas y trabajar con el lenguaje de forma flexible a gran escala.

En conjunto, estas formas de representación pueden agruparse en dos grandes enfoques. Por un lado, las representaciones **simbólicas**, como la lógica, las redes semánticas, los *frames* y las ontologías, que describen el conocimiento de manera explícita y estructurada. Por otro, las representaciones **distribuidas**, como los *embeddings*, que codifican el significado en forma numérica y permiten aprovechar técnicas modernas de aprendizaje automático. Ambas perspectivas son relevantes en el Procesamiento del Lenguaje Natural, ya que responden a necesidades distintas y, en muchos casos, pueden complementarse.

5.3 Técnicas de Procesamiento del Lenguaje Natural

El Procesamiento del Lenguaje Natural reúne un conjunto de técnicas cuyo objetivo es permitir que una máquina pueda analizar, interpretar y generar lenguaje humano. Estas técnicas actúan sobre distintos niveles del lenguaje, desde su preparación inicial hasta su comprensión semántica y su generación automática. Su relevancia se debe a que el lenguaje natural presenta ambigüedad, dependencia del contexto y gran complejidad estructural, por lo que es necesario aplicar procedimientos específicos para transformarlo en una forma procesable.

Las principales técnicas de Procesamiento del Lenguaje Natural son las siguientes:

- **Tokenización:** consiste en dividir el texto en unidades mínimas de procesamiento, llamadas tokens. Estas unidades pueden ser palabras, partes de palabras, signos de puntuación o caracteres, según el modelo empleado.
- **Normalización del texto:** agrupa las operaciones destinadas a unificar y limpiar el texto para facilitar su tratamiento. Incluye, por ejemplo, la conversión a minúsculas, la eliminación de caracteres innecesarios o la corrección de ciertas variaciones formales.
- **Análisis morfológico:** estudia la estructura interna de las palabras, identificando elementos como raíces, prefijos, sufijos, género, número o tiempo verbal. Permite comprender mejor cómo se forman y varían las palabras.
- **Análisis sintáctico:** se centra en la estructura gramatical de la oración y en las relaciones entre sus componentes. Su finalidad es determinar cómo se organizan las palabras y qué función desempeña cada una dentro del enunciado.
- **Análisis semántico:** busca interpretar el significado de las palabras, expresiones y oraciones. Esta técnica resulta fundamental para resolver ambigüedades y captar el sentido global del mensaje.
- **Representación vectorial del lenguaje:** transforma palabras, frases o documentos en vectores numéricos, de forma que puedan ser procesados matemáticamente por algoritmos y modelos de aprendizaje automático. En este ámbito destacan los *embeddings*.
- **Clasificación de textos:** permite asignar un texto a una o varias categorías predefinidas. Se utiliza, por ejemplo, en filtrado de spam, análisis de sentimientos, clasificación temática o detección de intenciones.
- **Extracción de información:** consiste en localizar y extraer datos relevantes dentro de un texto. Entre sus aplicaciones más habituales se encuentran la detección de entidades, fechas, lugares, organizaciones o relaciones entre conceptos.

- **Resumen automático:** tiene como objetivo generar una versión reducida de un texto conservando la información esencial. Puede ser extractivo, si selecciona fragmentos del texto original, o abstractivo, si genera un resumen nuevo.
- **Traducción automática:** permite transformar un texto de una lengua a otra manteniendo, en la medida de lo posible, su significado original.
- **Respuesta a preguntas:** engloba las técnicas orientadas a localizar o generar respuestas adecuadas a partir de una pregunta formulada en lenguaje natural.
- **Generación automática de texto:** consiste en producir contenido nuevo en lenguaje natural, como respuestas, informes, resúmenes o diálogos, a partir de una entrada previa o de una instrucción dada al sistema.
- **Reconocimiento y síntesis de voz:** aunque se sitúan en la frontera entre el procesamiento del lenguaje y el tratamiento de señales, estas técnicas permiten transformar voz en texto y texto en voz, respectivamente, facilitando la interacción hablada con los sistemas.

En conjunto, estas técnicas muestran que el Procesamiento del Lenguaje Natural no se reduce a una única operación, sino que abarca un conjunto amplio de procedimientos complementarios. Algunas se centran en la preparación y análisis del lenguaje, mientras que otras permiten extraer información, interpretar significados o generar nuevas respuestas. Sobre esta base han surgido sistemas cada vez más avanzados capaces de integrar muchas de estas técnicas en un único modelo, como ocurre con los **grandes modelos de lenguaje o LLMs**, cuyo estudio se aborda a continuación.

5.3.1 LLMs

Los **LLMs** (*Large Language Models* o grandes modelos de lenguaje) son modelos de Inteligencia Artificial diseñados para comprender y generar lenguaje natural a gran escala. Su objetivo fundamental es aprender los patrones, regularidades y relaciones presentes en grandes cantidades de texto, de forma que puedan producir respuestas coherentes, redactar contenidos, resumir documentos, traducir, responder preguntas o mantener una conversación. Su importancia dentro del Procesamiento del Lenguaje Natural radica en que integran en un mismo sistema muchas de las capacidades que antes se abordaban mediante técnicas separadas, combinando comprensión y generación de lenguaje en un único modelo.

Desde el punto de vista técnico, los LLMs se apoyan en la arquitectura de los **transformadores**, especialmente en su mecanismo de atención, que les permite relacionar palabras y fragmentos de texto, aunque estén muy alejados entre sí dentro de una secuencia. Gracias a ello, pueden captar mejor el contexto y generar respuestas más precisas y coherentes que arquitecturas anteriores. Además, su rendimiento depende en gran medida de la escala: se entrenan con enormes corpus de documentos y cuentan con un número muy elevado de parámetros, lo que les permite almacenar regularidades lingüísticas, conocimientos generales y patrones de uso del lenguaje. En términos generales, un LLM aprende inicialmente mediante **preentrenamiento**, a partir de grandes volúmenes de texto, y posteriormente puede adaptarse a tareas concretas mediante técnicas como el ajuste fino o el aprendizaje mediante instrucciones.




Figura 31: Arquitectura de transformadores, GPT y BERT. Elaboración propia.

La imagen anterior permite comprender la relación entre la arquitectura transformadora original y algunos de los modelos más conocidos. El **transformador completo** se compone de un **encoder** y un **decoder**. El *encoder* procesa la secuencia de entrada para construir una representación contextualizada de ella, mientras que el *decoder* utiliza dicha representación para generar la salida. A partir de esta arquitectura general se desarrollaron variantes específicas. Los modelos de la familia **GPT** emplean una arquitectura **decoder-only**, es decir, utilizan únicamente el bloque decodificador y generan el texto de forma autorregresiva, palabra a palabra, a partir del contexto previo. Por su parte, los modelos de la familia **BERT** utilizan una arquitectura **encoder-only**, centrada en comprender el contexto completo del texto de entrada, lo que los hace especialmente adecuados para tareas de análisis y comprensión, como clasificación o detección de entidades.

Entre las principales capacidades de los LLMs se encuentran la **generación de texto**, la **respuesta a preguntas**, el **resumen automático**, la **traducción**, la **clasificación de contenidos**, la **extracción de información** y la **asistencia conversacional**. Sin embargo, también presentan limitaciones. Pueden generar respuestas erróneas o inventadas, fenómeno conocido como **alucinación**, y su comportamiento depende de la calidad de los datos con los que fueron entrenados, así como del modo en que se formula la instrucción de entrada. Por ello, aunque constituyen una de las técnicas más avanzadas del Procesamiento del Lenguaje Natural actual, deben entenderse como herramientas muy potentes, pero no infalibles, cuyo uso exige evaluación, supervisión y criterio.

En consecuencia, los LLMs representan la culminación de muchas de las técnicas de PLN estudiadas previamente: parten de la tokenización, de las representaciones vectoriales del lenguaje y de la arquitectura transformadora para construir sistemas capaces de operar con el lenguaje de forma generalista. Por esta razón, se han convertido en uno de los desarrollos más influyentes de la Inteligencia Artificial contemporánea y en la base de numerosos asistentes conversacionales y aplicaciones avanzadas de lenguaje.

5.3.1.1 Generación Aumentada por Recuperación (RAG)

La técnica **RAG** (*Retrieval-Augmented Generation* o **Generación Aumentada por Recuperación**) es una arquitectura que combina un **LLM** con un sistema de **recuperación de información** para mejorar la calidad y fiabilidad de las respuestas. Su finalidad es que el modelo no responda únicamente con el conocimiento aprendido durante el entrenamiento, sino también apoyándose en documentos externos relevantes recuperados en el momento de la consulta. De este modo, RAG permite trabajar con información más **actualizada**, **específica** y **trazable**, reduciendo el riesgo de alucinaciones y facilitando que la respuesta quede fundamentada en fuentes concretas.

El funcionamiento de RAG puede entenderse en dos fases. La primera es la **preparación del índice documental**. En esta fase, los documentos de referencia se dividen en **fragmentos** o *chunks*, normalmente con cierto solape para no perder contexto, y cada fragmento se transforma en un **vector**

mediante un modelo de **embeddings**. Estos vectores, junto con sus metadatos, se almacenan en una **base de datos vectorial**. La segunda fase es la **consulta**. Cuando el usuario formula una pregunta, esa consulta también se convierte en un vector con el mismo modelo de **embeddings** y se compara con los vectores almacenados para localizar los fragmentos más próximos en significado. Los fragmentos recuperados se incorporan entonces al *prompt* del LLM, que genera la respuesta final utilizando ese contexto adicional.




Figura 32: Esquema RAG. Fuente: [Wikipedia](#).

La principal ventaja de esta arquitectura es que convierte un modelo generalista en un sistema capaz de responder sobre un **corpus documental propio**, como normativa, manuales, bases de conocimiento, expedientes o documentación interna de una organización. Además, su mantenimiento resulta más sencillo que el ajuste fino, ya que para actualizar el conocimiento no es necesario reentrenar el modelo, sino volver a indexar los documentos modificados. No obstante, su rendimiento depende en gran medida de varias decisiones técnicas, especialmente del modo en que se fragmentan los documentos, del modelo de *embeddings* empleado y del mecanismo utilizado para ordenar y seleccionar los resultados recuperados. En consecuencia, RAG se ha convertido en una de las arquitecturas más importantes para construir asistentes documentales, buscadores semánticos y sistemas de pregunta-respuesta apoyados en información fiable y verificable.

5.4 Resumen del apartado

El **Procesamiento del Lenguaje Natural (PLN)** es la rama de la IA que permite a las máquinas **analizar, comprender y generar lenguaje humano**. Para ello, utiliza técnicas de preparación, análisis y representación del texto, así como métodos de clasificación, extracción de información, resumen, traducción y generación automática.

Conceptos importantes:

- LLM: Modelos de lenguaje a gran escala capaces de comprender y generar texto.
- RAG: Combina un LLM con recuperación de información para mejorar precisión y fiabilidad.

6 SISTEMAS EXPERTOS

Un sistema experto es un programa informático que utiliza la Inteligencia Artificial para resolver un problema concreto simulando el razonamiento de un ser humano de manera que imitan la toma de decisiones de un experto en la temática a resolver. Estos sistemas son capaces de razonar con eficiencia y precisión sobre un dominio de conocimiento almacenado lo que les proporciona un alto nivel de experiencia para resolver problemas sin tasa de errores.

Su creación data de a finales de los años 50 y se consideran uno de los primeros sistemas de IA utilizados con éxito pudiéndose considerar los precursores de los sistemas IA actuales, del aprendizaje profundo y del aprendizaje automático. Se pasó del procesamiento de datos a la comprensión del problema enfocándose en el conocimiento. La madurez se alcanzó en los años 80 y 90.

Se pueden clasificar de la siguiente manera:

1. **Basados en reglas (*Rule Based Reasoning* - RBO):** Se establecen reglas previas que abordan el problema teniendo en cuenta ciertos requisitos. Estas reglas son usadas de manera determinística para la obtención de resultados, generando nuevas reglas en el dominio que a su vez pasan a incorporarse en conjunto total de reglas del sistema. La regla consta de condición (clausula SI) y de deducción (clausula ENTONCES).
2. **Basados en casos (*Case Based Reasoning* - CBR):** Enfocan la resolución del problema mediante casos o soluciones preexistentes y haciendo una analogía de problemas anteriores.
3. **Basados en Redes de Bayes:** Utilizan fundamentos estadísticos para deducir la solución del problema, combinando un conjunto de variables conocidas y su interdependencia probabilística. Permite modelar la incertidumbre en el dominio dentro del sistema, realizando decisiones en base al conocimiento acumulado.
4. **Basados en lógica difusa:** En vez de operar con valores de certeza (verdadero o falso), permite trabajar con todos los valores de certeza se expresan con números reales dentro del intervalo entre 0 y 1, permitiendo una escala variable y alto grado de veracidad.
5. **Basados en árboles:** Se parte de una situación inicial y se tienen en cuenta todas las situaciones posibles y se crea un árbol de alternativas en base a los hechos y deducciones permitiendo la clasificación de los datos, siendo el nodo final el que representa la solución.

Los elementos habituales que componen un sistema experto son:

1. **Base de conocimientos (BC):** Representa el repositorio que contiene el conjunto de reglas heurísticas de tipo "Si-Entonces" asociadas al dominio particular del sistema experto.
2. **Base de hechos o memoria de trabajo:** Incluye el conjunto de datos iniciales (hechos) de entrada al sistema. Según se suceden diferentes nuevas situaciones y se obtienen nuevas deducciones, se actualiza con nuevos hechos mientras se mantenga activo el motor de inferencia. Se puede considerar el componente de aprendizaje y el que acumula experiencia.
3. **Motor de inferencia:** Se considera el cerebro del sistema experto. Es el componente con inteligencia que procesa los datos de entrada o hecho en base a la interpretación de las reglas y ejecuta procesos de inferencia para obtener conclusiones orientadas a la solución del dominio. Realiza deducciones generando recomendaciones o conclusiones. También pueden incluir una explicación sobre cómo el sistema experto llegó a una conclusión particular y habilidades de depuración.
4. **Subsistema de adquisición de conocimiento:** Es la acumulación, transferencia y transformación de la experiencia para resolver problemas de una fuente de conocimiento a un programa de ordenador para construir o expandir la base de conocimiento
5. **Interfaz de usuario:** Es un componente opcional que permite explotar el motor de inferencia.




Figura 33: Estructura de un sistema experto. Fuente: https://www.palermo.edu/ingenieria/pdf2014/13/CyT_13_24.pdf.

Se puede deducir la capacidad de cierto nivel de aprendizaje en los sistemas expertos, lo que les permite mejorar el rendimiento inicial y aprovechar las inferencias previas. En general destacan por una potente capacidad analítica y deductiva frente al ser humano, que supone un importante ahorro de tiempo y de costes puesto que su reutilización es infinita sin obsolescencia. Otras grandes ventajas son su alta disponibilidad, un riesgo reducido, un importante conocimiento permanente y una respuesta rápida. Como gran inconveniente se encuentran muy limitados por la escasa capacidad de proporcionar soluciones creativas o posibilidad innovación con nuevas ideas, más propias de los seres humanos, así como la integración con otros sistemas.

Sus principales usos están orientados a tareas como la interpretación de volúmenes de datos complejos y con cierto nivel de ruido, diagnóstico, supervisión y análisis en tiempo real de sistemas críticos, planificación y predicción. Los principales campos de aplicación de los sistemas expertos se concentran en aplicaciones de medicina orientados al diagnóstico de enfermedades, la toma de decisiones en el mundo de las finanzas, la gestión y optimización de almacenes logísticos. Otros campos de utilización son: monitorización y control de procesos, gestión de horarios en transporte, evaluación del desempeño de empleados, entre muchos otros.

Algunos ejemplos de sistemas expertos son:

- Dendral: Recopilación de múltiples reglas que describían las interacciones de los compuestos químicos para su análisis. Fue el primer sistema experto desarrollado.
- CaDet: Sistema de apoyo clínico que podría identificar el cáncer en etapas tempranas.
- MYCIN: Uno de los primeros sistemas expertos basados en el encadenamiento hacia atrás, orientado a la elaboración de diagnósticos.
- PXDES: Sistema para la medicina moderna. Puede determinar fácilmente el tipo y el grado de cáncer de pulmón en un paciente a través de un análisis de datos.

6.1 Resumen del apartado

Los **sistemas expertos** son programas de IA que **imitan el razonamiento de un especialista humano** para resolver problemas concretos dentro de un dominio determinado. Fueron de las primeras aplicaciones exitosas de la IA y destacan por su **capacidad de análisis, rapidez y precisión**, aunque tienen limitaciones en **creatividad e innovación**.

Tipos de sistemas expertos:

- Basados en reglas.
- Basados en casos.
- Redes de Bayes.
- Lógica difusa.

Componentes principales de los sistemas expertos:

- Base de conocimientos.
- Base de hechos.
- Motor de inferencia.

7 ROBÓTICA

La **robótica** es un campo interdisciplinar que integra, entre otros ámbitos, la **ingeniería mecánica**, la **electrónica**, el **control**, la **percepción** y las **ciencias de la computación** para diseñar, construir y operar robots capaces de percibir su entorno, tomar decisiones y ejecutar acciones en el mundo físico. En la actualidad, la robótica ya no se limita a los manipuladores industriales clásicos, sino que abarca también **robots móviles**, **robots autónomos**, **cobots** o robots colaborativos, y una nueva generación de **robots humanoides y cuadrúpedos** impulsados por avances en Inteligencia Artificial, percepción y control autónomo. La Federación Internacional de Robótica destaca precisamente entre las tendencias actuales la combinación de **IA y autonomía**, el crecimiento de los **robots colaborativos** y la expansión de la robótica a nuevos sectores más allá de la fabricación tradicional.

Desde el punto de vista de las tecnologías de la información y las comunicaciones, la automatización no siempre adopta la forma de un robot físico. En este contexto destaca la **Automatización Robótica de Procesos (RPA)**, que consiste en el uso de **robots software** para automatizar tareas repetitivas de oficina o de gestión, imitando las acciones que una persona realiza sobre aplicaciones informáticas. Estas soluciones permiten automatizar operaciones como la manipulación de ficheros, la introducción de datos, la apertura y tratamiento de correos, la ejecución de aplicaciones o la interacción con sistemas externos. Sus principales beneficios son el aumento de la **eficiencia**, la reducción de **errores** y la liberación de tiempo para que las personas puedan dedicarse a tareas de mayor valor añadido. Un ejemplo de RPA en las AAPP es el servicio SAI-RPA de la AEAD. Es un servicio gestionado de forma centralizada que pretende facilitar la adopción de la tecnología de Automatización Robotizada de Procesos a los diferentes organismos de la AGE, enfocándose en alcanzar los objetivos de negocio de los procesos a automatizar.

Conviene precisar, no obstante, que **no toda RPA es Inteligencia Artificial**. La RPA clásica se basa, sobre todo, en reglas definidas previamente y en la automatización de tareas estructuradas. Sin embargo, cuando se combina con técnicas de **Machine Learning**, visión artificial, procesamiento del lenguaje natural o grandes modelos de lenguaje, puede evolucionar hacia formas de **automatización inteligente** más flexibles, capaces de clasificar documentos, extraer información, interpretar texto o apoyar la toma de decisiones. Por ello, en la práctica actual resulta más adecuado hablar de **automatización inteligente** que de una supuesta identificación automática entre robot software e IA.

En términos generales, un proceso de automatización eficiente suele seguir las siguientes fases:

1. **Identificación de procesos susceptibles de automatización:** se seleccionan tareas repetitivas, de alto volumen, basadas en reglas claras y con baja necesidad de intervención humana.
2. **Estructuración y normalización de los datos de entrada:** se prepara la información necesaria para que el sistema pueda operar de forma consistente.
3. **Definición de la lógica del proceso:** se modelan las reglas, validaciones e integraciones necesarias mediante desarrollo software o herramientas de automatización.
4. **Ejecución y supervisión del proceso automatizado:** la automatización se programa para ejecutarse de forma puntual, periódica o continua, incorporando mecanismos de seguimiento, trazabilidad y control.

En la actualidad, la robótica constituye un campo en **pleno desarrollo**, impulsado por la convergencia entre mecánica avanzada, sensórica, Inteligencia Artificial y computación de alto rendimiento. Entre las empresas más destacadas se encuentra **Boston Dynamics**, con plataformas como **Spot** para inspección industrial y **Atlas** orientado al trabajo industrial humanoide, y **Unitree**, muy relevante por su expansión en robots cuadrúpedos y humanoides de propósito general. Estas compañías reflejan bien la tendencia actual del sector: una robótica cada vez más orientada no solo a la automatización industrial clásica, sino también a la **movilidad autónoma**, la **interacción en entornos reales**.

7.1 Resumen del apartado

La **robótica** diseña robots capaces de **percibir, decidir y actuar** en el mundo físico. Hoy incluye **robots industriales, móviles, autónomos, cobots, humanoides y cuadrúpedos**. En el ámbito digital destaca la **RPA**, que automatiza tareas repetitivas mediante **robots software**. La **RPA clásica** se basa en reglas, pero al combinarse con **IA** da lugar a una **automatización inteligente** más flexible.

8 AGENTES INTELIGENTES

Los **agentes inteligentes** son sistemas capaces de **percibir su entorno, procesar la información recibida y actuar sobre ese entorno con el fin de alcanzar un objetivo**. Esta idea constituye uno de los enfoques fundamentales de la Inteligencia Artificial, ya que permite describir de forma general cómo un sistema puede comportarse de manera autónoma en situaciones cambiantes. A diferencia de un programa que solo ejecuta instrucciones fijas, un agente inteligente debe interpretar lo que ocurre a su alrededor y decidir qué acción resulta más adecuada en cada momento.




Figura 34: Esquema Agente Inteligente. Fuente: [Researchgate](https://www.researchgate.net/publication/312111111).

El funcionamiento de un agente inteligente puede entenderse como un ciclo continuo entre **percepción, decisión y acción**. En primer lugar, el agente recibe información del entorno a través de **sensores** o mecanismos equivalentes de entrada. Esa información puede proceder de cámaras, micrófonos, sensores de proximidad, registros del sistema o datos proporcionados por otros programas. A continuación, el agente procesa esas percepciones y selecciona una respuesta en función de sus objetivos, de sus reglas internas o de lo que haya aprendido previamente. Finalmente, ejecuta una acción mediante **actuadores** o mecanismos de salida, que le permiten modificar el entorno, desplazarse, emitir una respuesta, activar un dispositivo o realizar cualquier otra intervención.

Un aspecto esencial de los agentes inteligentes es que su comportamiento está orientado a metas. Esto significa que no actúan de manera arbitraria, sino buscando la acción que mejor contribuya a cumplir un objetivo determinado. En algunos casos, esta toma de decisiones se basa en reglas predefinidas; en otros, el agente puede incorporar técnicas de aprendizaje automático o aprendizaje por refuerzo, lo que le permite mejorar su comportamiento a partir de la experiencia. Por ello, un agente inteligente puede ir más allá de la simple reacción automática y mostrar cierta capacidad de adaptación ante nuevas situaciones.

Los agentes inteligentes pueden clasificarse de distintas maneras. Existen agentes **reactivos**, que responden directamente a los estímulos del entorno sin mantener una representación compleja de este; agentes **basados en objetivos**, que seleccionan acciones en función de una meta concreta; y agentes **basados en utilidad**, que comparan distintas opciones y eligen la que consideran más conveniente según un criterio de valor. También pueden distinguirse agentes individuales y sistemas multiagente, en los que varios agentes cooperan o compiten entre sí para resolver un problema.

Este enfoque tiene aplicaciones muy amplias dentro de la Inteligencia Artificial. Los agentes inteligentes aparecen en robots autónomos, asistentes virtuales, videojuegos, vehículos autónomos, control industrial y muchas otras áreas. En todos estos casos, la idea común es la misma: construir sistemas capaces de observar, decidir y actuar de manera autónoma en un entorno. Por ello, el concepto de agente inteligente resulta especialmente útil como marco general para comprender cómo la Inteligencia Artificial puede trasladarse desde el tratamiento de datos hasta la actuación efectiva en el mundo real.

8.1 Inteligencia Artificial Distribuida

La **Inteligencia Artificial Distribuida (IAD)** es una rama de la Inteligencia Artificial que estudia cómo resolver problemas complejos mediante la cooperación de varios sistemas o agentes que trabajan de forma distribuida. A diferencia de los enfoques centralizados, en la IAD el conocimiento, los datos y la capacidad de decisión no se concentran en un único sistema, sino que se reparten entre varios nodos o agentes que interactúan entre sí. De este modo, cada uno aporta una parte de la información o de la capacidad de cálculo necesaria para alcanzar una solución conjunta.

El interés de este enfoque radica en que muchos problemas reales no pueden resolverse de forma eficaz desde un único punto de control. En entornos distribuidos, dinámicos o con gran volumen de información, resulta más adecuado repartir tareas, procesar datos en paralelo y coordinar distintas decisiones locales. Por ello, la Inteligencia Artificial Distribuida aprovecha ventajas propias de la computación distribuida, como la **escalabilidad**, la **robustez**, la **tolerancia a fallos**, la **distribución de recursos** y la capacidad de adaptación ante cambios en el entorno o en los datos disponibles.

La IAD se ocupa, principalmente, de los siguientes problemas:

1. **Cómo descomponer un problema complejo** en subtarefas que puedan ser resueltas por distintos agentes o nodos.
2. **Cómo asignar esas subtarefas** de forma eficiente entre los distintos elementos del sistema.
3. **Cómo coordinar la comunicación** entre agentes para intercambiar información relevante.
4. **Cómo garantizar la coherencia global** de las decisiones tomadas de forma distribuida.
5. **Cómo integrar las soluciones parciales** obtenidas por distintos agentes en una solución final.
6. **Cómo diseñar arquitecturas y metodologías** que permitan desarrollar sistemas distribuidos inteligentes de manera eficaz.

Para que un sistema de Inteligencia Artificial Distribuida funcione adecuadamente, suelen ser necesarios varios elementos básicos:

1. **Una infraestructura distribuida**, formada por nodos o agentes débilmente acoplados y capaces de operar de forma autónoma.
2. **Mecanismos de comunicación y coordinación**, que permitan compartir información y sincronizar actuaciones.
3. **Datos o percepciones distribuidas**, sobre las que los distintos agentes puedan razonar, aprender o actuar.
4. **Reglas, protocolos o estrategias de cooperación**, que permitan mantener un comportamiento global coherente.

Históricamente, la IAD dio lugar a dos grandes enfoques. El primero es la **resolución distribuida de problemas**, centrada en dividir un problema entre varios nodos, asignar subtarefas y recomponer después el resultado final. En este enfoque suele existir una coordinación más estructurada y, en algunos casos, un elemento central que distribuye o supervisa el trabajo. El segundo enfoque es el de los **sistemas multiagente**, en los que varios agentes autónomos interactúan, cooperan o negocian entre sí para alcanzar objetivos individuales o comunes. Este segundo enfoque es el que ha tenido mayor desarrollo posterior y constituye hoy la forma más representativa de la Inteligencia Artificial Distribuida.

En la actualidad, la Inteligencia Artificial Distribuida ha cobrado nueva relevancia gracias a la expansión de sistemas conectados, entornos IoT, robótica distribuida, vehículos autónomos, redes inteligentes y arquitecturas basadas en agentes apoyadas en modelos avanzados de IA. Por ello, no debe entenderse como un enfoque histórico superado, sino como una base conceptual muy importante para diseñar sistemas inteligentes capaces de actuar de forma cooperativa en entornos complejos y descentralizados.

8.2 Sistemas Multiagente

Un **Sistema Multiagente (SMA)** es un sistema compuesto por varios **agentes inteligentes** que interactúan entre sí y con su entorno para resolver problemas que resultarían demasiado complejos, costosos o ineficientes para un único sistema centralizado. Cada agente dispone de cierto grado de autonomía, capacidad de percepción y decisión, pero ninguno suele poseer por sí solo toda la información ni el control completo del problema. La inteligencia del sistema surge, por tanto, de la **interacción, coordinación y cooperación** entre los distintos agentes.

Cada agente puede definirse como una entidad, física o software, capaz de **percibir su entorno, procesar información, tomar decisiones y actuar** de forma orientada a objetivos. En un sistema multiagente, estos agentes pueden colaborar, competir, negociar o repartirse tareas según el tipo de problema y la arquitectura adoptada. Este enfoque resulta especialmente útil en entornos distribuidos, dinámicos o abiertos, donde diferentes actores deben actuar de forma parcialmente independiente, pero manteniendo cierta coherencia global.

Entre las características más relevantes de los agentes en un sistema multiagente destacan las siguientes:

1. **Autonomía:** capacidad para actuar sin intervención externa continua.
2. **Visión local:** cada agente dispone normalmente de información parcial del entorno.
3. **Racionalidad:** capacidad para seleccionar acciones orientadas a objetivos.
4. **Sociabilidad:** capacidad para comunicarse e interactuar con otros agentes o con personas.
5. **Reactividad:** capacidad para responder a cambios en el entorno.
6. **Proactividad:** capacidad para iniciar acciones orientadas al logro de metas.
7. **Adaptabilidad:** capacidad para modificar su comportamiento en función de la experiencia o del aprendizaje.

Los agentes pueden clasificarse de varias maneras. Una primera clasificación distingue entre:

1. **Agentes reactivos**, que responden directamente a estímulos del entorno y suelen ser más simples, rápidos y robustos.
2. **Agentes deliberativos**, que disponen de una representación interna del problema, pueden razonar, planificar y tomar decisiones más complejas.

También puede distinguirse entre:

1. **Agentes cooperativos**, diseñados para colaborar con otros en la consecución de un objetivo común.
2. **Agentes de interfaz o asistenciales**, orientados a ayudar al usuario, anticipar necesidades o simplificar el uso de aplicaciones.
3. **Agentes móviles**, capaces de desplazarse entre distintos entornos o nodos de red para ejecutar tareas.
4. **Agentes estáticos**, que permanecen en un entorno concreto realizando funciones definidas.

Para que un sistema multiagente funcione correctamente, la comunicación y la coordinación son esenciales. Esta interacción puede realizarse mediante distintos mecanismos, entre los que destacan:

1. **Espacios compartidos o pizarra**, donde varios agentes depositan información en una estructura común accesible al resto.
2. **Intercambio de mensajes**, mediante comunicación directa entre agentes.
3. **Protocolos de negociación y cooperación**, utilizados para repartir tareas, resolver conflictos o coordinar decisiones.
4. **Redes de contratos**, en las que un agente plantea una tarea y otros agentes presentan propuestas para ejecutarla, seleccionándose después la más adecuada.

El principal reto de los sistemas multiagente no es solo que cada agente actúe correctamente de forma individual, sino que el conjunto del sistema logre un comportamiento coordinado, eficiente y coherente. Por ello, estos sistemas deben diseñarse prestando especial atención a aspectos como la cooperación, la asignación de tareas, la resolución de conflictos, la sincronización y la consistencia de la información compartida.

Las aplicaciones de los sistemas multiagente son muy amplias. Se utilizan en **robótica cooperativa, redes de transporte, gestión energética, monitorización distribuida, comercio electrónico, simulación de fenómenos sociales, gestión de redes, vehículos autónomos** y, más recientemente, en arquitecturas de **IA agéntica**, donde varios agentes software especializados colaboran para resolver tareas complejas. En consecuencia, los sistemas multiagente constituyen una de las formas más relevantes de materializar la Inteligencia Artificial Distribuida en problemas reales.

8.3 Inteligencia Artificial Agéntica

La **Inteligencia Artificial agéntica** puede entenderse como una evolución reciente del concepto de agente inteligente, impulsada en gran medida por el desarrollo de los **grandes modelos de lenguaje (LLMs)**. Mientras que en los enfoques clásicos un agente actuaba a partir de reglas, estados y objetivos bien definidos, en la IA agéntica el sistema incorpora modelos capaces de comprender instrucciones en lenguaje natural, razonar sobre tareas complejas, planificar varios pasos y utilizar herramientas externas. De este modo, el agente ya no se limita a reaccionar ante estímulos del entorno, sino que puede interpretar objetivos expresados de forma flexible, descomponerlos en subtareas y coordinar acciones para alcanzar un resultado.

Desde esta perspectiva, un sistema agéntico suele combinar varios elementos. En primer lugar, un **modelo de lenguaje** actúa como núcleo de razonamiento e interpretación, permitiendo comprender la petición del usuario y generar decisiones intermedias. En segundo lugar, el sistema dispone de **memoria** o de acceso al contexto, lo que le permite mantener información relevante durante la ejecución de una tarea. En tercer lugar, incorpora **herramientas externas**, como motores de búsqueda, bases de datos, calendarios, sistemas de correo, intérpretes de código o APIs, que amplían su capacidad de actuación. Finalmente, todo ello se integra en un ciclo de **planificación, ejecución, observación y corrección**, de manera que el agente puede revisar los resultados obtenidos y decidir los siguientes pasos.

En la actualidad existen distintos tipos de agentes y plataformas agénticas, tanto de propósito general como especializadas. Entre los ejemplos más representativos se encuentran agentes integrados en asistentes conversacionales, como ChatGPT Agent, Claude Cowork o Gemini Enterprise; agentes orientados al entorno empresarial, como Microsoft 365 Copilot y Copilot Studio; agentes especializados en programación y desarrollo de software, como Codex, Claude Code, Devin, Cursor o GitHub Copilot; y marcos de desarrollo para construir sistemas multiagente, como LangGraph, CrewAI, AutoGPT, Semantic Kernel u OpenAI Agents SDK. Estos ejemplos muestran que la IA agéntica no constituye una única tecnología cerrada, sino un conjunto de enfoques que combinan modelos generativos, herramientas, memoria, planificación y capacidad de ejecución en distintos contextos de uso.

La característica diferencial de la Inteligencia Artificial agéntica es, por tanto, su capacidad para abordar tareas **complejas, abiertas y de varios pasos**. Por ejemplo, un sistema agéntico puede recibir una instrucción como organizar un viaje, analizar información de distintas fuentes, comparar alternativas, redactar un resumen y ejecutar ciertas acciones en herramientas conectadas. De forma similar, en entornos empresariales puede consultar documentación, responder preguntas, generar informes, lanzar procesos automáticos o asistir en flujos de trabajo. En todos estos casos, el valor del agente no reside únicamente en generar texto, sino en su capacidad para **actuar de forma orientada a objetivos** apoyándose en razonamiento, contexto y herramientas.

No obstante, este enfoque también plantea desafíos importantes. La IA agéntica hereda algunas limitaciones de los LLMs, como la posibilidad de cometer errores, generar información incorrecta o interpretar mal una instrucción ambigua. Además, al estar conectada con herramientas externas, introduce retos relacionados con la **seguridad, la supervisión, la fiabilidad y la gobernanza**, ya que una mala decisión puede tener consecuencias más allá de la simple generación de texto. Por ello, aunque la Inteligencia Artificial agéntica representa una de las líneas más avanzadas y prometedoras de la IA actual, su desarrollo exige combinar autonomía con control, de manera que los agentes puedan actuar con utilidad real sin perder trazabilidad ni seguridad.

8.4 Resumen del apartado

Idea clave	Resumen muy breve
Qué son los Agentes Inteligentes	Sistemas que perciben el entorno, procesan información y actúan para lograr un objetivo.
Funcionamiento básico	Siguen un ciclo de percepción → decisión → acción .
Inteligencia Artificial Distribuida	Estudia cómo varios sistemas o componentes inteligentes cooperan para resolver problemas.
Sistemas multiagente	Conjunto de agentes que interactúan, colaboran o compiten en un mismo entorno.
IA agéntica	Evolución reciente orientada a agentes con mayor autonomía, planificación y ejecución de tareas complejas aplicando LLMs.

Tabla 11. Conceptos clave

9 VISIÓN ARTIFICIAL

La **visión artificial** es una rama de la Inteligencia Artificial que desarrolla métodos para adquirir, procesar, analizar e interpretar imágenes y vídeo con el fin de extraer información útil para la automatización y la toma de decisiones. En su estado actual, ya no se limita al reconocimiento básico de patrones, sino que abarca tareas como la **clasificación de imágenes**, la **detección de objetos**, la **segmentación**, el **seguimiento de objetos**, la **estimación de pose**, el **OCR** y la **comprensión multimodal** de imágenes, vídeo y lenguaje. En este sentido, la visión artificial moderna permite que un sistema no solo “vea”, sino que también relacione lo percibido con instrucciones, contexto y conocimiento adicional.

Esta comprensión se apoya en disciplinas como la geometría, la óptica, la estadística, la física y el aprendizaje automático. El elemento básico de la imagen digital sigue siendo el **pixel**, pero el enfoque actual ya no se basa principalmente en diseñar manualmente características sobre cada píxel, sino en que el propio modelo aprenda automáticamente las representaciones visuales más relevantes a partir de grandes volúmenes de datos. Para ello se emplean sobre todo **redes neuronales convolucionales**, **transformadores aplicados a visión** y, cada vez con mayor frecuencia, **modelos fundacionales de visión** y sistemas multimodales capaces de adaptarse a múltiples tareas con una misma base arquitectónica.

La obtención de imágenes se realiza mediante cámaras y otros sensores especializados, como dispositivos de profundidad, sistemas térmicos o LiDAR, tras lo cual el software procesa la información visual para reconocer estructuras, localizar objetos, estimar su posición y seguir su evolución en el tiempo. A partir de este procesamiento, la visión artificial ofrece ventajas operativas muy importantes en velocidad, precisión, repetibilidad y capacidad de análisis continuo, especialmente en entornos industriales, logísticos, médicos y de seguridad. Al mismo tiempo, la integración reciente de visión y lenguaje ha ampliado sus posibilidades, permitiendo sistemas capaces de responder preguntas sobre imágenes, interpretar documentos complejos o analizar escenas en combinación con instrucciones textuales.

Algunas de las principales técnicas y aplicaciones actuales de la visión artificial son las siguientes:

1. **Clasificación de imágenes:** consiste en asignar una etiqueta global a una imagen completa, identificando la categoría a la que pertenece.
2. **Detección de objetos:** permite localizar e identificar objetos concretos dentro de una imagen o vídeo, indicando su posición mediante regiones delimitadas.
3. **Segmentación semántica e instance segmentation:** divide la imagen en regiones o píxeles etiquetados, permitiendo una comprensión más precisa de la escena.
4. **Seguimiento de objetos:** analiza la trayectoria de uno o varios elementos a lo largo de una secuencia de imágenes o en tiempo real.
5. **Estimación de pose y puntos clave:** identifica articulaciones, posturas o puntos anatómicos relevantes en personas u objetos.
6. **OCR y comprensión documental:** convierte texto presente en imágenes o documentos escaneados en información legible por máquina y estructurable para su tratamiento automático.
7. **Inspección visual y detección de defectos:** se aplica en industria para localizar anomalías, fallos de fabricación o desviaciones respecto a un patrón esperado.
8. **Reconocimiento facial y biometría:** permite identificar o verificar personas a partir de rasgos faciales, aunque su uso exige especial cautela desde el punto de vista ético y legal.
9. **Análisis de vídeo y reconocimiento de acciones:** interpreta secuencias visuales para detectar comportamientos, eventos o actividades.
10. **Reconstrucción 3D y estimación de profundidad:** facilita la percepción espacial del entorno y resulta clave en robótica, vehículos autónomos y sistemas avanzados de navegación.
11. **Realidad aumentada y sistemas multimodales:** combinan información visual del entorno con contenido generado por ordenador o con instrucciones en lenguaje natural para ofrecer interacción en tiempo real.

Los beneficios operacionales de estas técnicas se reflejan en el aumento de la calidad, la productividad, la trazabilidad y la automatización, así como en la reducción de errores, tiempos de inspección, costes de operación y desperdicio. Entre sus aplicaciones más relevantes en la actualidad destacan la **industria 4.0**, la **robótica**, los **vehículos autónomos**, la **seguridad**, la **medicina asistida por IA**, la **logística**, la **lectura inteligente de documentos** y la **agricultura de precisión**. En consecuencia, la

visión artificial debe entenderse hoy como un campo en rápida evolución, cada vez más integrado con modelos fundacionales y sistemas multimodales capaces de analizar imágenes, vídeo y lenguaje de forma conjunta.

9.1 Resumen del apartado

La visión artificial es la rama de la IA que permite captar, procesar e interpretar imágenes y vídeo para extraer información útil, automatizar tareas y apoyar decisiones, con aplicaciones destacadas en industria, medicina, logística, seguridad y robótica.

10 REGLAMENTO EUROPEO DE INTELIGENCIA ARTIFICIAL (RIA)

El [Reglamento \(UE\) 2024/1689 de Inteligencia Artificial](#) es la primera norma jurídica del mundo sobre Inteligencia Artificial. Entró en vigor el 1 de agosto de 2024 y su aplicación se realizará de forma progresiva entre 2025 y 2027. El objetivo del reglamento es garantizar que los sistemas de Inteligencia Artificial (IA) se desarrollen y utilicen de manera responsable, es decir, que sean seguros, éticos y fiables garantizando al mismo tiempo un elevado nivel de protección de la salud, la seguridad y los derechos fundamentales recogidos en la [Carta de los Derechos Fundamentales de la Unión Europea](#).

La norma clasifica los sistemas de Inteligencia Artificial en función de su riesgo e impone obligaciones a los proveedores y a los responsables del despliegue de tecnologías de IA en el mercado único de la UE. Además de abordar los posibles riesgos, el Reglamento también promueve la innovación y fomenta la adopción de una IA ética y sostenible.

10.1 Ámbito objetivo

De acuerdo con el **art. 1** RIA, esta norma persigue los siguientes objetivos:

1. **Mejorar el funcionamiento del mercado interior**, estableciendo un marco común para el desarrollo, comercialización y uso de sistemas de Inteligencia Artificial en la Unión Europea.
2. **Promover una Inteligencia Artificial centrada en el ser humano y fiable, garantizando al mismo tiempo un elevado nivel de protección** de la salud, la seguridad y los derechos fundamentales reconocidos en la Carta, incluidos la democracia, el Estado de Derecho y la protección del medio ambiente, frente a los efectos perjudiciales de los sistemas de IA.
3. **Apoyar la innovación**, favoreciendo un desarrollo tecnológico seguro y armonizado dentro del marco jurídico de la Unión.

El RIA establece lo siguiente:

- a) normas armonizadas para la introducción en el mercado, la puesta en servicio y la utilización de sistemas de IA en la Unión;
- b) prohibiciones de determinadas prácticas de IA;
- c) requisitos específicos para los sistemas de IA de alto riesgo y obligaciones para los operadores de dichos sistemas;
- d) normas armonizadas de transparencia aplicables a determinados sistemas de IA;
- e) normas armonizadas para la introducción en el mercado de modelos de IA de uso general;
- f) normas sobre el seguimiento del mercado, la vigilancia del mercado, la gobernanza y la garantía del cumplimiento;
- g) medidas en apoyo de la innovación, prestando especial atención a las pymes, incluidas las empresas emergentes.

10.2 Ámbito subjetivo

El ámbito subjetivo del art. 2 del RIA identifica los sujetos a los que se aplica la norma, esto es, las personas físicas o jurídicas, públicas o privadas, que intervienen en el desarrollo, comercialización, puesta en servicio o utilización de sistemas de Inteligencia Artificial.

Quedan comprendidos en el ámbito subjetivo del RIA los siguientes sujetos:

- a) **los proveedores** que introduzcan en el mercado o pongan en servicio sistemas de IA o que introduzcan en el mercado modelos de IA de uso general en la Unión, con independencia de si dichos proveedores están establecidos o ubicados en la Unión o en un tercer país;
- b) **los responsables del despliegue** de sistemas de IA que estén establecidos o ubicados **en la Unión**;
- c) **los proveedores y responsables** del despliegue de sistemas de IA que estén establecidos o ubicados en un tercer país, cuando los **resultados** de salida generados por el sistema de **IA se utilicen en la Unión**;
- d) **los importadores y distribuidores** de sistemas de IA;
- e) **los fabricantes** de productos que introduzcan en el mercado o pongan en servicio un sistema de IA junto con su producto y con su propio nombre o marca;
- f) **los representantes autorizados de los proveedores** que no estén establecidos en la Unión;

- g) las **personas afectadas** que estén ubicadas en la Unión.

Junto a ello, deben tenerse en cuenta algunas **exclusiones subjetivas o funcionales**, entre las que destacan:

1. **Los usos vinculados exclusivamente a fines militares, de defensa o de seguridad nacional**, que quedan fuera del ámbito de aplicación del RIA.
2. **Las actividades personales de carácter no profesional**, cuando una persona física utilice un sistema de IA en ese ámbito estrictamente privado.
3. **Determinados sistemas desarrollados y utilizados exclusivamente con fines de investigación científica**, en los términos previstos por la propia norma.

10.3 Definiciones

El **artículo 3 del RIA** contiene el catálogo de definiciones necesarias para interpretar correctamente la norma. No obstante, a efectos sistemáticos, pueden destacarse únicamente aquellas que resultan más relevantes para comprender su estructura, su ámbito de aplicación y el régimen de obligaciones que establece.

Entre las definiciones más importantes cabe señalar las siguientes:

1. **Sistema de IA:** El RIA define el sistema de Inteligencia Artificial como un sistema basado en una máquina, diseñado para funcionar con distintos niveles de autonomía y que puede mostrar capacidad de adaptación tras el despliegue. Su rasgo esencial es que, a partir de la información de entrada recibida, **infiere** la manera de generar resultados de salida, tales como predicciones, contenidos, recomendaciones o decisiones, capaces de influir en entornos físicos o virtuales. Esta es la noción central de todo el Reglamento, pues delimita el objeto mismo de la regulación.
2. **Modelo de IA de uso general:** Se trata de un modelo de IA, también entrenado con grandes volúmenes de datos utilizando auto-supervisión a gran escala, que presenta una generalidad significativa y es capaz de realizar de manera competente una amplia gama de tareas diferenciadas, con independencia de cómo se introduzca en el mercado, y que puede integrarse en una variedad de sistemas o aplicaciones posteriores. Su inclusión es fundamental, porque el RIA dedica a estos modelos un régimen específico, especialmente relevante por su versatilidad y capacidad de reutilización.
3. **Proveedor:** Es la persona física o jurídica, autoridad pública, órgano u organismo que desarrolla un sistema de IA o un modelo de IA de uso general, o para el que estos se desarrollan, y que los introduce en el mercado o los pone en servicio con su propio nombre o marca, ya sea a título oneroso o gratuito. Se trata de una figura esencial, ya que sobre ella recaen las principales obligaciones de cumplimiento previstas por el RIA.
4. **Responsable del despliegue:** El RIA considera responsable del despliegue a la persona física o jurídica, autoridad pública, órgano u organismo que utilice un sistema de IA bajo su propia autoridad, salvo cuando ese uso se encuadre en una actividad personal de carácter no profesional. Esta definición es particularmente importante porque distingue entre quien desarrolla o comercializa el sistema y quien lo utiliza efectivamente.
5. **Representante autorizado:** Es la persona física o jurídica ubicada o establecida en la Unión que ha recibido y aceptado el mandato escrito de un proveedor para cumplir, en su nombre, las obligaciones y procedimientos previstos en el RIA. Su relevancia práctica se aprecia especialmente cuando el proveedor no está establecido en la Unión.
6. **Importador:** Se entiende por importador la persona física o jurídica ubicada o establecida en la Unión que introduce en el mercado un sistema de IA que lleva el nombre o la marca de una persona física o jurídica establecida en un tercer país. Esta figura resulta clave para garantizar el control de los sistemas procedentes de fuera de la Unión.
7. **Riesgo:** El RIA define el riesgo como la combinación entre la probabilidad de que se produzca un perjuicio y la gravedad de ese perjuicio. Esta definición es básica porque el Reglamento se construye sobre un **enfoque basado en el riesgo**, del que derivan tanto las prohibiciones como las obligaciones reforzadas para determinados sistemas.

10.4 Regulación sistemas de IA

La regulación de los sistemas de IA en el RIA se articula a partir de un **enfoque basado en el riesgo**. Esto significa que el Reglamento no impone el mismo nivel de exigencia a todos los sistemas, sino que gradúa la intensidad de la intervención jurídica según la peligrosidad que cada uso de la Inteligencia Artificial puede representar para la salud, la seguridad y, sobre todo, para los derechos fundamentales de las personas. Así, el RIA construye una clasificación escalonada que distingue entre **prácticas prohibidas**, **sistemas de IA de alto riesgo**, **sistemas de IA de riesgo limitado** y **sistemas de IA de riesgo mínimo**




Figura 35: Niveles de riesgo RIA. Fuente: [S.E. Digitalización e IA](#).

La regulación de los sistemas de IA en el RIA responde a una gradación en función del riesgo: en el nivel más alto se sitúan las **prácticas prohibidas** del **artículo 5**, que quedan directamente vedadas por implicar un riesgo inaceptable y ser incompatibles con los valores de la Unión; en un segundo nivel se encuentran los **sistemas de IA de alto riesgo**, regulados en el **artículo 6** y sus anexos, que no se prohíben, pero sí se someten a un régimen jurídico especialmente estricto, con exigencias de gestión de riesgos, calidad de datos, documentación, supervisión humana, precisión, solidez, ciberseguridad y evaluación de conformidad; a continuación aparecen los **sistemas de riesgo limitado**, respecto de los cuales el RIA impone principalmente **obligaciones de transparencia** en el **artículo 50**, con el fin de que las personas sepan cuándo interactúan con una IA o cuándo se enfrentan a contenidos sintéticos o manipulados; y, por último, se sitúan los **sistemas de riesgo mínimo**, para los que el Reglamento no prevé obligaciones específicas relevantes, sin perjuicio de que sigan sometidos a otras normas aplicables del Derecho de la Unión o del Derecho nacional.

10.4.1 Prácticas de IA prohibidas

Dentro de la regulación de los sistemas de IA, el RIA reserva la respuesta más intensa para aquellas prácticas que considera incompatibles con los valores de la Unión y con la protección de los derechos fundamentales. Por ello, el **artículo 5 del RIA** no se limita a someter estos usos a control o a imponerles requisitos reforzados, sino que **prohíbe directamente** su introducción en el mercado, su puesta en servicio o su utilización. Se trata, en definitiva, de supuestos de **riesgo inaceptable**, en los que el legislador europeo entiende que la IA no puede admitirse por la especial gravedad de los perjuicios que puede causar.

Las **prácticas de IA prohibidas** son las siguientes:

1. **El uso de técnicas subliminales o deliberadamente manipuladoras o engañosas** que alteren de manera sustancial el comportamiento de una persona o de un colectivo, menoscabando su capacidad de tomar una decisión informada y provocando, o pudiendo provocar razonablemente, perjuicios considerables.
2. **La explotación de vulnerabilidades** de una persona o de un colectivo derivadas de la edad, la discapacidad o una situación social o económica específica, cuando ello tenga por finalidad o efecto alterar sustancialmente su comportamiento de un modo que cause, o pueda causar razonablemente, perjuicios considerables.

3. **La puntuación ciudadana o social** de personas físicas o colectivos basada en su comportamiento social o en características personales o de la personalidad conocidas, inferidas o predichas, cuando dé lugar a tratos perjudiciales o desfavorables en contextos no relacionados con los datos de origen, o a tratos injustificados o desproporcionados respecto del comportamiento evaluado.
4. **Los sistemas de IA para evaluar o predecir el riesgo de que una persona cometa un delito**, cuando esa valoración se base únicamente en la elaboración de perfiles o en la evaluación de rasgos y características de la personalidad. El RIA exceptúa los sistemas utilizados para apoyar una valoración humana fundada en hechos objetivos y verificables directamente vinculados con una actividad delictiva.
5. **La creación o ampliación de bases de datos de reconocimiento facial mediante la extracción no selectiva de imágenes faciales** obtenidas de internet o de circuitos cerrados de televisión.
6. **Los sistemas de IA destinados a inferir emociones en lugares de trabajo y centros educativos**, salvo cuando estén destinados a fines médicos o de seguridad.
7. **Los sistemas de categorización biométrica** que clasifiquen individualmente a personas físicas a partir de sus datos biométricos para deducir o inferir su raza, opiniones políticas, afiliación sindical, convicciones religiosas o filosóficas, vida sexual u orientación sexual.
8. **El uso de sistemas de identificación biométrica remota “en tiempo real” en espacios de acceso público con fines de garantía del cumplimiento del Derecho**, salvo en los supuestos excepcionales expresamente previstos en el propio artículo 5: búsqueda de determinadas víctimas o personas desaparecidas, prevención de amenazas graves e inminentes para la vida o la seguridad o de atentados terroristas, y localización o identificación de sospechosos de ciertos delitos graves. Incluso en estos casos, el uso queda sometido a condiciones estrictas de necesidad, proporcionalidad y autorización.

10.4.2 Sistemas de IA de alto riesgo

Los **sistemas de IA de alto riesgo** ocupan el segundo nivel en la estructura del RIA. No se trata de sistemas prohibidos, pero sí de sistemas cuyo uso puede afectar de manera significativa a la salud, la seguridad o los derechos fundamentales, razón por la cual quedan sometidos a un régimen jurídico especialmente estricto. Su clasificación se contiene en el **artículo 6 del RIA**, que distingue, por un lado, los sistemas de IA que actúan como **componentes de seguridad de productos** sometidos a normativa sectorial de armonización de la Unión y, por otro, los sistemas enumerados en el **anexo III**. Además, el propio artículo 6 prevé que ciertos sistemas del anexo III no serán considerados de alto riesgo cuando no planteen un riesgo importante ni influyan sustancialmente en la toma de decisiones, salvo que efectúen elaboración de perfiles de personas físicas.

Los **sistemas de IA de alto riesgo** son, en síntesis, los siguientes:

1. **Los sistemas de IA que sean componentes de seguridad de productos** sujetos a los actos legislativos de armonización de la Unión enumerados en el **anexo I**, o que sean ellos mismos uno de esos productos, siempre que el producto o el propio sistema deban someterse a una evaluación de conformidad por terceros antes de su introducción en el mercado o puesta en servicio (**art. 6.1 RIA**).
2. **Los sistemas de IA en materia de biometría**, en la medida en que su uso esté permitido por el Derecho de la Unión o nacional aplicable, incluyendo los sistemas de identificación biométrica remota, los sistemas de categorización biométrica basados en atributos o características sensibles o protegidos y los sistemas de reconocimiento de emociones (**anexo III.1 RIA**).
3. **Los sistemas de IA destinados a infraestructuras críticas**, cuando se utilicen como componentes de seguridad en la gestión y funcionamiento de infraestructuras digitales críticas, tráfico rodado o suministro de agua, gas, calefacción o electricidad (**anexo III.2 RIA**).
4. **Los sistemas de IA en educación y formación profesional**, cuando se empleen para admisión y acceso, evaluación de resultados de aprendizaje, determinación del nivel educativo adecuado o vigilancia de conductas prohibidas durante exámenes (**anexo III.3 RIA**).
5. **Los sistemas de IA en el ámbito del empleo y la gestión de trabajadores**, especialmente en selección, contratación, adopción de decisiones que afecten a condiciones de trabajo,

promoción o terminación de relaciones laborales. Esta categoría forma parte de los ámbitos sensibles del **anexo III**.

6. **Los sistemas de IA utilizados para el acceso a servicios esenciales públicos o privados y para el disfrute de prestaciones y servicios esenciales**, como los que se emplean en evaluación de solvencia, acceso a seguros, servicios sanitarios u otros servicios básicos de gran impacto para las personas (**anexo III**).
7. **Los sistemas de IA utilizados por autoridades públicas o por entidades que actúan en su nombre en materia de garantía del cumplimiento del Derecho**, cuando afecten a la valoración de hechos, riesgos o personas en contextos policiales o de investigación (**anexo III**).
8. **Los sistemas de IA utilizados en migración, asilo y control fronterizo**, especialmente cuando incidan en la evaluación de personas o en la adopción de decisiones administrativas en estos ámbitos (**anexo III**).
9. **Los sistemas de IA empleados en la administración de justicia y en procesos democráticos**, cuando sirvan de apoyo a decisiones judiciales o influyan en procedimientos electorales o equivalentes (**anexo III**).

En cuanto a los **requisitos que deben cumplir los sistemas de IA de alto riesgo**, el RIA los recoge en los **artículos 8 a 15**, y pueden resumirse del siguiente modo:

1. **Un sistema de gestión de riesgos**, que debe establecerse, implantarse, documentarse y mantenerse durante todo el ciclo de vida del sistema (**arts. 8 y 9 RIA**).
2. **Requisitos sobre datos y gobernanza de los datos**, de manera que los conjuntos de datos de entrenamiento, validación y prueba sean pertinentes, suficientemente representativos y adecuados para minimizar riesgos y sesgos (**art. 10 RIA**).
3. **Documentación técnica**, suficiente para demostrar la conformidad del sistema con el Reglamento y permitir a las autoridades evaluar su cumplimiento (**art. 11 RIA**).
4. **Conservación automática de registros o logs**, a fin de garantizar la trazabilidad del funcionamiento del sistema (**art. 12 RIA**).
5. **Transparencia e instrucciones de uso adecuadas**, para que el sistema pueda ser utilizado correctamente y sus capacidades y limitaciones sean comprendidas por quienes lo despliegan (**art. 13 RIA**).
6. **Supervisión humana efectiva**, de forma que el sistema pueda ser controlado por personas físicas con la competencia y autoridad necesarias, evitando automatismos incontrolados (**art. 14 RIA**).
7. **Precisión, solidez y ciberseguridad**, lo que incluye resistencia frente a errores, fallos, incoherencias y ataques maliciosos, así como protección frente a vulnerabilidades específicas de la IA, como el envenenamiento de datos o los ejemplos adversarios (**art. 15 RIA**).

Por lo que se refiere a las **obligaciones de los proveedores de sistemas de IA de alto riesgo**, el **artículo 16 del RIA** impone, entre otras, las siguientes:

1. **Garantizar que el sistema cumple los requisitos** establecidos para los sistemas de alto riesgo.
2. **Identificar al proveedor** en el propio sistema, en su embalaje o en la documentación que lo acompañe, indicando nombre y dirección de contacto.
3. **Disponer de un sistema de gestión de la calidad** conforme al artículo 17.
4. **Conservar la documentación técnica** exigida por el Reglamento.
5. **Conservar los registros generados automáticamente** por el sistema cuando estén bajo su control.
6. **Someter el sistema a la evaluación de conformidad pertinente** antes de su introducción en el mercado o puesta en servicio.
7. **Elaborar la declaración UE de conformidad**.
8. **Colocar el marcado CE** en el sistema, en el embalaje o en la documentación acompañante, según proceda.
9. **Cumplir las obligaciones de registro** en la base de datos correspondiente.
10. **Adoptar medidas correctoras e informar a las autoridades** cuando resulte exigible.
11. **Demostrar la conformidad del sistema** a requerimiento motivado de la autoridad nacional competente.

12. **Garantizar el cumplimiento de los requisitos de accesibilidad**, conforme a las Directivas (UE) 2016/2102 y (UE) 2019/882.

Finalmente, las **obligaciones de los responsables del despliegue** de sistemas de IA de alto riesgo, recogidas principalmente en el **artículo 26 del RIA**, pueden sintetizarse así:

1. **Adoptar medidas técnicas y organizativas adecuadas** para utilizar el sistema con arreglo a las instrucciones de uso del proveedor.
2. **Encomendar la supervisión humana** a personas físicas con la competencia, formación y autoridad necesarias.
3. **Asegurar, cuando controlen los datos de entrada, que estos sean pertinentes y suficientemente representativos** en relación con la finalidad prevista del sistema.
4. **Vigilar el funcionamiento del sistema** basándose en las instrucciones de uso.
5. **Informar al proveedor** cuando proceda conforme al artículo 72, y también al distribuidor o a la autoridad de vigilancia del mercado cuando existan motivos para pensar que el sistema presenta un riesgo.
6. **Suspender el uso del sistema** cuando tengan motivos para considerar que su utilización conforme a las instrucciones puede generar un riesgo en el sentido del Reglamento.
7. **Comunicar sin demora los incidentes graves** al proveedor y, en su caso, al importador o distribuidor y a la autoridad de vigilancia del mercado.
8. **Realizar, en determinados casos, una evaluación de impacto sobre los derechos fundamentales antes del despliegue**, especialmente cuando se trate de organismos de Derecho público, entidades privadas que prestan servicios públicos o ciertos sistemas del anexo III, debiendo además notificar sus resultados a la autoridad de vigilancia del mercado.

10.4.3 Sistemas de IA de riesgo limitado

Los **sistemas de IA de riesgo limitado** ocupan un nivel intermedio en la estructura del RIA. No quedan prohibidos ni sometidos al régimen reforzado previsto para los sistemas de alto riesgo, pero sí están sujetos a **obligaciones de transparencia**, fundamentalmente recogidas en el **artículo 50 del RIA**. La lógica de esta categoría es que, cuando una persona interactúa con un sistema de IA o se expone a contenidos generados o manipulados artificialmente, debe poder conocer esa circunstancia para no ser inducida a error.

Pueden incluirse dentro de esta categoría, a efectos sistemáticos, los siguientes **sistemas de IA de riesgo limitado**:

1. **Los sistemas de IA destinados a interactuar directamente con personas físicas**, cuando no resulte evidente para una persona razonablemente informada que está interactuando con una IA. En estos casos, el Reglamento exige que la persona sea informada de dicha interacción.
2. **Los sistemas de IA que generen contenido sintético de audio, imagen, vídeo o texto**, incluidos los sistemas de IA de uso general cuando produzcan este tipo de resultados de salida, ya que el RIA exige que tales contenidos puedan ser identificados como generados o manipulados artificialmente.
3. **Los sistemas de reconocimiento de emociones**, respecto de los cuales el responsable del despliegue debe informar a las personas físicas expuestas al funcionamiento del sistema.
4. **Los sistemas de categorización biométrica**, respecto de los cuales también se impone un deber de información a las personas afectadas, además del sometimiento al régimen general de protección de datos cuando proceda.
5. **Los sistemas de IA que generen o manipulen imágenes, audio o vídeo constitutivos de ultrasuplantaciones o “deepfakes”**, ya que el RIA obliga a hacer público que tales contenidos han sido generados o manipulados artificialmente.
6. **Los sistemas de IA que generen o manipulen texto publicado para informar al público sobre asuntos de interés público**, supuesto en el que también debe divulgarse que ese texto ha sido generado o manipulado de manera artificial, salvo las excepciones previstas en la norma.

En relación con esta categoría, el RIA no establece un catálogo de requisitos técnicos y organizativos tan amplio como el previsto para los sistemas de alto riesgo. En realidad, el elemento característico de los sistemas de riesgo limitado es el cumplimiento de **requisitos de transparencia**, que pueden resumirse así:

1. **Información sobre la interacción con un sistema de IA**, de forma que la persona sepa que no está tratando con un ser humano cuando ello no resulte evidente.
2. **Marcado identificable de los contenidos sintéticos**, en formato legible por máquina, para que pueda detectarse que el contenido ha sido generado o manipulado artificialmente.
3. **Información a las personas expuestas a sistemas de reconocimiento de emociones o de categorización biométrica**, con respeto además a la normativa aplicable de protección de datos personales.
4. **Publicidad de las ultrasuplantaciones o deepfakes**, indicando que las imágenes, audios o vídeos han sido generados o manipulados artificialmente.
5. **Divulgación del carácter artificial del texto generado o manipulado** cuando se publique para informar al público sobre asuntos de interés público.

Por lo que respecta a las **obligaciones de los proveedores**, el **artículo 50 del RIA** impone principalmente las siguientes:

1. **Garantizar que los sistemas destinados a interactuar directamente con personas físicas** se diseñen y desarrollen de forma que estas sean informadas de que están interactuando con un sistema de IA, salvo que ello resulte evidente por el contexto.
2. **Garantizar que los resultados de salida de sistemas que generen contenido sintético** de audio, imagen, vídeo o texto estén marcados en un formato legible por máquina, de manera que pueda detectarse que han sido generados o manipulados artificialmente.
3. **Asegurar que las soluciones técnicas empleadas para ese marcado sean eficaces, interoperables, sólidas y fiables**, en la medida en que ello sea técnicamente viable y atendiendo al estado de la técnica y a los costes de aplicación.

En cuanto a las **obligaciones de los responsables del despliegue**, destacan las siguientes:

1. **Informar a las personas físicas expuestas** al funcionamiento de un sistema de reconocimiento de emociones o de un sistema de categorización biométrica.
2. **Tratar los datos personales conforme a la normativa aplicable de protección de datos**, cuando utilicen sistemas de reconocimiento de emociones o de categorización biométrica.
3. **Hacer público que las imágenes, audios o vídeos constitutivos de ultrasuplantación** han sido generados o manipulados artificialmente.
4. **Divulgar que el texto ha sido generado o manipulado artificialmente** cuando se publique con la finalidad de informar al público sobre asuntos de interés público, salvo en los supuestos exceptuados por el propio artículo 50.

10.4.4 Sistemas de IA de riesgo mínimo

Los **sistemas de IA de riesgo mínimo** son aquellos que, aun quedando comprendidos dentro del concepto de sistema de IA del RIA, no encajan ni en las prácticas prohibidas, ni en la categoría de alto riesgo, ni en los supuestos sometidos a obligaciones específicas de transparencia. Por ello, el Reglamento no les impone, con carácter general, requisitos u obligaciones específicas equivalentes a las previstas para las categorías anteriores.

10.5 Regulación modelos de IA de uso general

El RIA dedica un régimen específico a los **modelos de IA de uso general**, conscientes de que, aunque no constituyen por sí mismos sistemas de IA, pueden integrarse en multitud de sistemas y aplicaciones posteriores y, por ello, proyectar sus riesgos y efectos a lo largo de toda la cadena de valor. Esta regulación se contiene en el **capítulo V** del Reglamento y distingue entre, de un lado, las **obligaciones generales aplicables a todos los proveedores de modelos de IA de uso general** y, de otro, las **obligaciones reforzadas para los modelos de IA de uso general con riesgo sistémico**.

Con carácter general, los proveedores de estos modelos deben **elaborar y mantener actualizada la documentación técnica del modelo**, incluida la relativa al proceso de entrenamiento, pruebas y resultados de evaluación; **poner a disposición de los proveedores de sistemas de IA la información y documentación necesarias** para integrar correctamente el modelo en sistemas posteriores; **establecer una política de respeto del Derecho de la Unión en materia de derechos de autor y derechos afines**; y **publicar un resumen suficientemente detallado sobre el contenido utilizado para el entrenamiento del modelo**. Estas obligaciones buscan reforzar la trazabilidad, la

transparencia y la seguridad jurídica en torno a modelos que pueden servir de base para muy diversos usos ulteriores.

Junto a ello, el RIA prevé reglas específicas sobre el **representante autorizado** de los proveedores no establecidos en la Unión y contempla una excepción relevante para determinados modelos divulgados con **licencia libre y de código abierto**, siempre que sus parámetros e información esencial se pongan a disposición del público. No obstante, esta exclusión no opera cuando el modelo de IA de uso general presente **riesgos sistémicos**, supuesto en el que el Reglamento impone igualmente el régimen reforzado correspondiente.

La categoría de **modelo de IA de uso general con riesgo sistémico** ocupa un lugar central en esta materia. El RIA presume que existe ese riesgo cuando el modelo alcanza una **capacidad de alto impacto**, tomando como referencia los criterios del **anexo XIII**, y faculta a la Comisión para designar modelos con riesgo sistémico y mantener una lista actualizada de los mismos. Sobre estos modelos recaen, además de las obligaciones generales, deberes adicionales particularmente intensos: evaluar el modelo conforme al estado de la técnica, incluida la realización de pruebas de simulación de adversarios; evaluar y mitigar los riesgos sistémicos a escala de la Unión; vigilar, documentar y comunicar sin demora los incidentes graves y las medidas correctoras; y garantizar un nivel adecuado de ciberseguridad tanto del modelo como de su infraestructura física.

Finalmente, el Reglamento otorga un papel relevante a los **códigos de buenas prácticas**, promovidos por la **Oficina de IA**, como instrumento para facilitar la aplicación homogénea de estas obligaciones mientras no existan normas armonizadas europeas.

10.6 Gobernanza

La gobernanza del RIA se articula mediante una estructura multinivel, en la que participan instituciones de la Unión y autoridades nacionales, con el fin de garantizar una aplicación coherente, uniforme y eficaz del Reglamento. El régimen general se contiene en el **capítulo VII del RIA**.

Los principales elementos de esta gobernanza son los siguientes:

1. **La Comisión Europea**, que asume funciones generales de impulso, coordinación, supervisión y desarrollo del marco de aplicación del RIA. Entre otras tareas, participa en la adopción de actos de ejecución, en la elaboración de criterios técnicos y en el funcionamiento general del sistema europeo de supervisión.
2. **La Oficina de IA (AI Office)**, integrada en la Comisión, que actúa como órgano técnico especializado y desempeña un papel especialmente relevante en relación con los **modelos de IA de uso general**, en particular los que presentan **riesgo sistémico**. También contribuye a la elaboración de guías, modelos y buenas prácticas.
3. **El Consejo Europeo de Inteligencia Artificial**, configurado como órgano de cooperación entre los Estados miembros y de apoyo a la Comisión. Su función principal es favorecer una aplicación armonizada del RIA, facilitar el intercambio de experiencias y conocimientos y contribuir a la coordinación entre autoridades nacionales.
4. **Las autoridades nacionales competentes**, que cada Estado miembro debe designar para velar por la aplicación y ejecución del Reglamento. Estas autoridades deben actuar con independencia, imparcialidad y objetividad, y contar con recursos suficientes y conocimientos especializados en IA, datos, ciberseguridad, salud, seguridad y derechos fundamentales.
5. **Las autoridades de vigilancia del mercado**, a las que corresponde controlar el cumplimiento del RIA respecto de los sistemas de IA, en conexión con el régimen general de vigilancia del mercado previsto en el Reglamento (UE) 2019/1020.
6. **Las autoridades notificantes y los organismos notificados**, que intervienen en la evaluación de la conformidad de determinados sistemas de IA de alto riesgo, asegurando que estos puedan introducirse en el mercado o ponerse en servicio solo cuando cumplan las exigencias del Reglamento.
7. **El Supervisor Europeo de Protección de Datos**, que actúa como autoridad competente cuando las instituciones, órganos y organismos de la Unión entren en el ámbito de aplicación del RIA.

En **España** las autoridades más relevantes o llamadas a desempeñar un papel destacado en la aplicación del RIA son las siguientes:

1. **La Agencia Española de Supervisión de la Inteligencia Artificial (AESIA)**, creada como agencia estatal y concebida precisamente para asumir funciones de supervisión en materia de

Inteligencia Artificial y servir de referencia institucional en este ámbito. Su estatuto ya vinculaba su creación con las exigencias europeas de supervisión en materia de IA.

2. **La Agencia Española de Protección de Datos (AEPD)**, especialmente en aquellos supuestos en que el uso de sistemas de IA implique tratamiento de datos personales o afecte al derecho fundamental a la protección de datos.
3. **Otras autoridades sectoriales de vigilancia del mercado o competentes por razón de la materia**, que previsiblemente intervendrán cuando los sistemas de IA se integren en sectores regulados específicos, como consumo, productos, sanidad, industria o servicios digitales. Esta intervención sectorial es coherente con el diseño del propio RIA, que remite en parte a la lógica de la vigilancia del mercado y a la especialización material de las autoridades nacionales.

10.7 Régimen sancionador

El RIA regula su régimen sancionador en el **capítulo XII** y parte de que corresponde a los **Estados miembros** establecer las sanciones aplicables a las infracciones del Reglamento, que deberán ser **efectivas, proporcionadas y disuasorias**. No obstante, el propio Reglamento fija unos límites máximos comunes para las multas administrativas más relevantes, distingue distintos niveles de gravedad e incluye reglas específicas para las pymes y empresas emergentes, para las instituciones, órganos y organismos de la Unión y para los proveedores de modelos de IA de uso general.

La cuantía de las sanciones se resume en la siguiente tabla:

Infracción	Precepto	Multa máxima
Incumplimiento de las prácticas de IA prohibidas	Art. 99.3 RIA	Hasta 35.000.000 € o 7 % del volumen de negocios mundial
Incumplimiento de otras obligaciones esenciales del RIA	Art. 99.4 RIA	Hasta 15.000.000 € o 3 % del volumen de negocios mundial
Suministro de información inexacta, incompleta o engañosa	Art. 99.5 RIA	Hasta 7.500.000 € o 1 % del volumen de negocios mundial
Regla especial para pymes y empresas emergentes	Art. 99.6 RIA	Se aplica el importe o el porcentaje, el que resulte menor
Infracciones de instituciones, órganos y organismos de la Unión	Art. 100 RIA	Hasta 1.500.000 € o 750.000 €, según el caso
Infracciones de proveedores de modelos de IA de uso general	Art. 101 RIA	Hasta 15.000.000 € o 3 % del volumen de negocios mundial

Tabla 12. Infracciones AI Act

10.8 Resumen del apartado

Elemento	Resumen del RIA
Finalidad	Crear un marco jurídico común en la UE para el desarrollo, comercialización y uso de la IA.
Enfoque	Se basa en un modelo de regulación según el nivel de riesgo .
Objetivo	Proteger derechos, seguridad e intereses generales, sin impedir la innovación.

Tabla 13. Conceptos clave

Niveles de riesgo:

Nivel de riesgo	Resumen
Riesgo inaceptable	Incluye prácticas prohibidas por su especial gravedad.
Alto riesgo	Sistemas sometidos a exigencias estrictas de cumplimiento, control y supervisión .
Riesgo limitado	Se imponen principalmente obligaciones de transparencia .
Riesgo mínimo	No está sujeto, con carácter general, a cargas regulatorias intensas.

Tabla 14. clasificación sistemas IA en el AI Act

11 IA EN LAS ADMINISTRACIONES PÚBLICAS

La Inteligencia Artificial se ha convertido en una herramienta estratégica para la transformación de las Administraciones Públicas, al permitir mejorar la eficiencia interna, reforzar la capacidad de análisis y ofrecer servicios públicos más ágiles, accesibles y personalizados. Su incorporación al sector público no debe entenderse únicamente como una cuestión tecnológica, sino como parte de un proceso más amplio de modernización administrativa, basado en el uso inteligente de los datos, la automatización de tareas, el apoyo a la toma de decisiones y la mejora de la relación entre la Administración y la ciudadanía. En este contexto, las Administraciones Públicas pueden actuar no solo como usuarias de soluciones de IA, sino también como impulsoras de su adopción, estableciendo marcos de actuación, promoviendo casos de uso de alto valor público y garantizando que su desarrollo se ajuste a principios de legalidad, transparencia, seguridad y respeto a los derechos fundamentales. Por ello, en los apartados siguientes se analizarán, en primer lugar, los principales casos de uso y aplicaciones de la IA en el sector público y, en segundo lugar, el marco de políticas públicas que orienta su despliegue, tanto desde la perspectiva europea como desde el ámbito nacional, con especial atención a la Estrategia de Inteligencia Artificial 2024 y al modelo de gobernanza institucional existente en España.

11.1 El papel de la IA en la transformación del sector público: casos de uso y aplicaciones

Desde un punto de vista práctico, los principales casos de uso de la IA en la transformación del sector público pueden agruparse del siguiente modo:

- **Automatización de procesos administrativos y tramitación de expedientes:** Uno de los ámbitos con mayor potencial es la automatización de tareas repetitivas y regladas, como la clasificación de solicitudes, la verificación de datos, la extracción de información de documentos, la generación de avisos, el encaminamiento de expedientes o la cumplimentación asistida de formularios. Estas aplicaciones permiten reducir tiempos de tramitación, disminuir cargas burocráticas y liberar recursos humanos para funciones de mayor valor añadido. En España, la Administración ya ha impulsado servicios de automatización inteligente y robotización centralizada para facilitar la adopción de estas tecnologías en la AGE.
- **Atención a la ciudadanía y asistentes virtuales:** La IA también desempeña un papel importante en la mejora de la atención al público mediante asistentes conversacionales, *chatbots* y sistemas de voz capaces de resolver consultas frecuentes, orientar sobre trámites, ofrecer información personalizada y derivar incidencias cuando sea necesario. Este tipo de soluciones resultan especialmente útiles en servicios de alta demanda, donde permiten ampliar la disponibilidad horaria, reducir tiempos de espera y ofrecer un primer nivel de atención inmediata. La propia Estrategia de Inteligencia Artificial 2024 contempla como ejemplo escalable para toda la Administración la creación de un banco de conocimiento común y de servicios de *chatbots* entrenables para web y atención telefónica, señalando expresamente el caso del 060 como asistente inteligente por voz basado en IA generativa.
- **Explotación documental y procesamiento del lenguaje natural:** Buena parte de la actividad administrativa se apoya en documentos, textos jurídicos, informes, registros, resoluciones y comunicaciones. En este contexto, la IA puede utilizarse para clasificar documentos, resumir expedientes, extraer datos relevantes, buscar información semánticamente, detectar duplicidades o inconsistencias y traducir información a lenguaje claro. Las técnicas de procesamiento del lenguaje natural y los modelos de lenguaje resultan especialmente valiosos en Administraciones que manejan grandes volúmenes de información textual y deben garantizar además accesibilidad lingüística y claridad en la comunicación. En este ámbito destaca el proyecto **ALIA**, concebido como una infraestructura pública de IA en castellano y lenguas cooficiales, con modelos de lenguaje abiertos y transparentes que buscan reducir la dependencia de modelos entrenados principalmente en inglés y facilitar el desarrollo de soluciones adaptadas al contexto lingüístico y administrativo español. ALIA Kit da acceso a modelos de lenguaje, modelos multimodales de texto, voz e imagen, metodologías, documentación y conjuntos de datos de entrenamiento y evaluación.
- **Apoyo a la toma de decisiones y analítica avanzada:** Otro ámbito de creciente relevancia es el uso de IA para apoyar la toma de decisiones administrativas mediante modelos predictivos, sistemas de priorización o herramientas de análisis avanzado. Estas aplicaciones permiten identificar patrones de demanda, anticipar cargas de trabajo, detectar riesgos de incumplimiento, optimizar la asignación de recursos o mejorar el diseño y evaluación de

políticas públicas. No se trata de sustituir la decisión administrativa, que debe seguir siendo humana y jurídicamente responsable, sino de proporcionar información más rápida y mejor estructurada para fundamentarla. La Comisión Europea ha señalado que la IA puede modernizar la acción pública precisamente al mejorar la eficiencia interna y apoyar a las administraciones en el uso de tecnologías fiables y dignas de confianza.

- **Detección de fraude, anomalías y riesgos:** La capacidad de la IA para detectar patrones anómalos la hace especialmente útil en tareas de inspección, control y prevención del fraude. Puede aplicarse, por ejemplo, al análisis de subvenciones, contratación pública, prestaciones, tributos o uso irregular de servicios públicos, identificando comportamientos atípicos que merezcan revisión posterior. Estas técnicas no sustituyen la actividad inspectora, pero permiten priorizar actuaciones y mejorar la eficiencia del control público, especialmente cuando el volumen de expedientes hace inviable una revisión manual exhaustiva. La OCDE recoge la detección de fraude entre los usos públicos más habituales y de mayor impacto potencial.
- **Políticas públicas basadas en datos y evaluación de programas:** La IA puede contribuir también a una Administración más inteligente en el diseño, seguimiento y evaluación de políticas públicas. Al analizar grandes bases de datos, identificar correlaciones, simular escenarios o detectar cambios de comportamiento, permite obtener evidencias útiles para orientar decisiones públicas en ámbitos como empleo, salud, movilidad, educación o servicios sociales. La propia Estrategia de Inteligencia Artificial 2024 prevé que el espacio integrado de datos del sector público sirva no solo para desarrollar modelos de IA generativa, sino también para evaluar políticas públicas y avanzar hacia un gobierno más abierto y basado en datos. En esta línea se sitúa la **Plataforma del Dato de la AGE**, puesta a disposición por la Agencia Estatal de Administración Digital, como infraestructura orientada a centralizar, gestionar y optimizar el intercambio y tratamiento de grandes volúmenes de datos públicos. Esta plataforma incorpora capacidades vinculadas al gobierno del dato, la ingesta y almacenamiento de información, la interoperabilidad, la analítica avanzada, la inteligencia de negocio, el *big data* y la inteligencia artificial, facilitando una explotación más eficiente y segura de la información pública.
- **Gestión de recursos, planificación y optimización operativa:** Otro conjunto de aplicaciones se refiere a la optimización de recursos públicos: distribución de cargas de trabajo, planificación de turnos, mantenimiento predictivo de infraestructuras, predicción de demanda en servicios públicos o mejora de la logística administrativa. En este terreno, la IA permite una gestión más eficiente y anticipatoria, reduciendo ineficiencias y favoreciendo un uso más racional de medios materiales y humanos. La OCDE subraya que estas herramientas pueden acelerar tareas administrativas y de apoyo, mejorando tanto la eficiencia del sector público como la calidad del servicio ofrecido.
- **Accesibilidad, personalización y mejora de la experiencia ciudadana:** La transformación pública impulsada por la IA no debe medirse solo en términos internos de eficiencia, sino también por su impacto en la relación entre la Administración y la ciudadanía. En este sentido, la IA permite personalizar respuestas, adaptar contenidos a diferentes perfiles, traducir información, simplificar el acceso a servicios digitales e incluso facilitar la interacción mediante voz o lenguaje natural. Ello puede contribuir a reducir barreras de acceso y mejorar la inclusión, siempre que su implantación no genere nuevas brechas tecnológicas ni sustituya indebidamente la atención humana cuando esta resulte necesaria. La Comisión Europea y la OCDE coinciden en que el potencial transformador de la IA en el sector público depende tanto de su utilidad como de la confianza, la supervisión y la inclusión con las que se despliegue.

Ejemplos de aplicaciones que usan IA en el sector público hoy en día:

- ISSA, asistente virtual de la Seguridad Social.
- WebChat 060 y servicios automáticos de atención del Punto de Acceso General.
- Servicio de Automatización Inteligente de la AGE, SAI.
- Asistentes virtuales de la Agencia Tributaria.
- Modelos ALIA en castellano y lenguas cooficiales.
- Plataforma del Dato de la AGE.

11.2 Políticas públicas

La implantación de la Inteligencia Artificial en el sector público no depende solo de sus aplicaciones prácticas, sino también de la existencia de políticas públicas que impulsen, orienten y ordenen su

desarrollo. Por ello, tras analizar sus principales casos de uso, se procede examinar el marco europeo y nacional que promueve su incorporación en las Administraciones Públicas.

11.2.1 Marco Europeo

Entre las últimas políticas e iniciativas europeas relacionadas con la IA destacan las siguientes:

- **Reglamento de Inteligencia Artificial (AI Act):** constituye la norma central del marco europeo de IA. Entró en vigor el 1 de agosto de 2024 y regula la IA con un enfoque basado en riesgos, combinando protección de derechos, seguridad jurídica e impulso a la innovación.
- **Paquete europeo de innovación en IA (2024):** presentado por la Comisión en enero de 2024 para reforzar el ecosistema europeo de IA, especialmente mediante apoyo a startups y pymes, el impulso de las **AI Factories** y la creación de la **AI Office** dentro de la Comisión para coordinar la política europea y supervisar la aplicación del *AI Act*.
- **AI Factories:** iniciativa orientada a conectar supercomputación, datos, talento y capacidad de experimentación para facilitar el desarrollo de IA en Europa. La Comisión señala que, tras el paquete de 2024, ya se ha puesto en marcha el trabajo en **19 AI factories** en 16 Estados miembros, la mayoría previstas para estar operativas antes de finales de 2026.
- **AI Continent Action Plan (2025):** lanzado el **9 de abril de 2025**, busca reforzar la posición competitiva de Europa en IA mediante inversión, computación a gran escala, acceso a datos de calidad, infraestructuras y despliegue industrial. La Comisión lo presenta como una de las piezas centrales para convertir a Europa en líder global en Inteligencia Artificial confiable.
- **Apply AI Strategy (2025):** integrada en la agenda reciente de la Comisión, está orientada a acelerar la adopción de la IA en sectores estratégicos europeos y a trasladar sus beneficios desde la investigación y la infraestructura al tejido productivo y a la economía real.

11.2.2 Marco nacional

En el ámbito nacional, España ha ido configurando en los últimos años un marco propio de impulso y gobernanza de la Inteligencia Artificial, alineado con las directrices europeas y orientado tanto a fomentar la innovación como a garantizar un uso responsable de esta tecnología. Este marco se articula a través de estrategias públicas, órganos de supervisión y políticas de apoyo a la digitalización, entre las que destacan especialmente la **Estrategia de Inteligencia Artificial 2024** y la **gobernanza institucional de la IA en España**, que concretan las prioridades, capacidades y mecanismos de coordinación para su desarrollo en el sector público y en el conjunto de la economía.

11.2.2.1 Estrategia de Inteligencia Artificial 2024

La **Estrategia de Inteligencia Artificial 2024** (Estrategia de IA 2024) constituye el principal instrumento de planificación estatal para reforzar y acelerar el desarrollo de la IA en España, enmarcado en la Agenda España Digital 2026, el Plan de Recuperación, Transformación y Resiliencia y el Plan de Digitalización de las Administraciones Públicas. Adapta la estrategia al nuevo contexto marcado por el auge de la IA generativa, la necesidad de mayores capacidades de computación y datos, y la aplicación del marco regulatorio europeo. Se estructura en **tres grandes ejes de actuación**, dentro de los cuales se integran **ocho palancas** que concretan las principales líneas de intervención pública y con un total de 23 iniciativas. Su esquema es el siguiente:

- **Eje 1. Reforzar las palancas claves para el desarrollo de la IA**
 - **Palanca 1.** Impulso a la inversión en supercomputación.
 - **Palanca 2.** Generar capacidades de almacenamiento en condiciones de sostenibilidad.
 - **Palanca 3.** Generar modelos y corpus para una infraestructura pública de modelos de lenguaje.
 - **Palanca 4.** Fomentar el talento en la IA.
- **Eje 2. Facilitar la expansión de la IA en el sector público y privado, fomentando la innovación y la ciberseguridad**
 - **Palanca 5.** Impulsar la IA en el sector público.
 - **Palanca 6.** Ayudar a la expansión de la IA en el sector privado, singularmente en pequeñas y medianas empresas.

- **Palanca 7.** Desarrollar un marco integral de ciberseguridad.
- **Eje 3. Desarrollar una IA transparente, responsable y humanística**
 - **Palanca 8.** Desarrollar las funciones de la AESIA.

11.2.2.2 Gobernanza institucional de la IA en España

La gobernanza institucional de la Inteligencia Artificial en España se articula a través de un conjunto de órganos encargados de **impulsar, coordinar, supervisar y ordenar** su desarrollo, tanto desde la perspectiva de la política pública como desde la transformación digital de las Administraciones. Este modelo combina funciones estratégicas, regulatorias, técnicas y de gestión del dato, en línea con el marco europeo y con la Estrategia de IA 2024, que atribuye un papel especialmente relevante a la supervisión, la gobernanza del dato y la implantación de servicios comunes de IA en el sector público.

Los **principales órganos de la gobernanza de la IA en España** son los siguientes:

- **Ministerio para la Transformación Digital y de la Función Pública:** es el departamento ministerial de referencia en materia de digitalización e Inteligencia Artificial, al que corresponde el impulso general de la política pública estatal en este ámbito.
- **Secretaría de Estado de Digitalización e Inteligencia Artificial (SEDIA):** es el órgano directivo encargado del impulso de la política de digitalización y del desarrollo de la Inteligencia Artificial en España, incluyendo la definición estratégica, la coordinación de iniciativas y la interlocución institucional en esta materia.
- **Agencia Española de Supervisión de la Inteligencia Artificial (AESIA):** constituye el principal órgano especializado de supervisión de la IA en España. Su función es promover una Inteligencia Artificial fiable, ética y respetuosa con los derechos fundamentales, además de desempeñar tareas de análisis, acompañamiento, buenas prácticas y apoyo a la aplicación del marco regulatorio europeo. La Estrategia de IA 2024 le atribuye un papel central dentro del tercer eje, dedicado a una IA transparente, responsable y humanística.
- **Agencia Estatal de Administración Digital (AEAD):** es el organismo responsable de la coordinación funcional de las unidades TIC de la Administración del Estado y de los servicios comunes digitales, por lo que ocupa una posición relevante en la implantación operativa de capacidades digitales e infraestructuras comunes sobre las que pueden desplegarse soluciones de IA en la AGE.
- **Dirección General del Dato y Chief Data Officer (dependiente de la SEDIA):** desempeñan funciones clave en la gobernanza del dato, estableciendo principios, estándares y marcos de gestión de datos que resultan esenciales para el desarrollo y uso de sistemas de Inteligencia Artificial en el sector público.

11.3 Resumen del apartado

Principales utilidades de la IA en el sector público: Automatización, atención a la ciudadanía, apoyo a la toma de decisiones y personalización de servicios.

Nivel	Esquema mínimo
Europeo	AI Act: norma central de la UE. Paquete europeo de innovación en IA (2024): impulso al ecosistema. AI Factories: supercomputación, datos y experimentación. AI Continent Action Plan (2025): competitividad e infraestructuras. Apply AI Strategy (2025): adopción sectorial de la IA.
Nacional	Marco español alineado con la UE. Se articula sobre Estrategia de IA 2024 + gobernanza institucional + políticas de digitalización.

Tabla 15. Resumen de políticas

La estrategia española IA 2024 está compuesta por 3 ejes y 8 palancas. Los ejes son estos:

- Capacidades
- Expansión
- IA responsable

Órgano	Función básica
Ministerio para la Transformación Digital y de la Función Pública	Impulso general de la política pública de IA.
SEDIA	Dirección estratégica y coordinación.
AESIA	Supervisión especializada, buenas prácticas y apoyo al marco europeo.
AEAD	Servicios comunes digitales e implantación operativa en la AGE.
Oficina del Dato / Chief Data Officer	Gobernanza del dato, estándares y marcos de gestión.

Tabla 16. Gobernanza institucional de IA en España

12 ASPECTOS ÉTICOS

La dimensión ética de la Inteligencia Artificial ha adquirido una importancia creciente a medida que estos sistemas se integran en ámbitos cada vez más sensibles de la vida social, económica y administrativa. Junto a sus beneficios en eficiencia, automatización y apoyo a la toma de decisiones, la IA plantea también interrogantes sobre su impacto en los derechos fundamentales, la igualdad, la privacidad, la transparencia y la responsabilidad. Por ello, en los últimos años se han desarrollado distintos marcos internacionales, europeos y nacionales orientados a promover una IA fiable, segura y centrada en las personas.

La reflexión ética sobre la Inteligencia Artificial se apoya hoy en varios documentos de referencia de amplio reconocimiento institucional. A escala mundial, destacan la [Recomendación sobre la Ética de la Inteligencia Artificial de la UNESCO](#), adoptada en 2021 y presentada por la propia organización como el primer estándar mundial en esta materia, y los [Principios de IA de la OCDE](#), adoptados en 2019 y [actualizados](#) en 2024 para incorporar mejor los retos asociados a la IA generativa y a los modelos de propósito general. En el ámbito europeo, siguen siendo una referencia muy citada las [Ethics Guidelines for Trustworthy AI](#) de la Comisión Europea, que estructuran la idea de una IA fiable en torno a siete requisitos clave, y hoy deben leerse junto al **Reglamento de IA de la Unión Europea (AI Act)**, en vigor desde el 1 de agosto de 2024. Por último, en España, los textos más relevantes son la [Carta de Derechos Digitales](#), aprobada en julio de 2021 como hoja de ruta de una digitalización humanista, y la [Estrategia de Inteligencia Artificial 2024](#), que insiste en una IA transparente, ética, responsable y humanista y sitúa a la **AESIA** como actor clave de supervisión y buenas prácticas.

A partir de estos marcos, los principales retos éticos de la IA pueden resumirse en los siguientes:

- **Sesgos y discriminación**, cuando los sistemas reproducen o amplifican desigualdades presentes en los datos o en su diseño.
- **Falta de transparencia y explicabilidad**, que dificulta comprender cómo se producen ciertas recomendaciones, clasificaciones o decisiones automatizadas.
- **Privacidad y protección de datos**, especialmente cuando se emplean grandes volúmenes de información personal o sensible.
- **Seguridad, robustez y fiabilidad técnica**, ya que un sistema de IA puede fallar, ser manipulado o comportarse de forma no prevista si no ha sido diseñado y evaluado adecuadamente.
- **Desinformación, manipulación e integridad informativa**, un reto especialmente visible en la IA generativa y en la creación automatizada de contenidos.
- **Déficit de supervisión humana**, cuando se delegan excesivamente en la máquina decisiones que afectan a derechos, libertades o intereses relevantes de las personas.
- **Dificultad para exigir responsabilidades**, si no existen trazabilidad, documentación y mecanismos claros de auditoría o revisión.
- **Impacto social y medioambiental**, tanto por sus efectos sobre inclusión, empleo o desigualdad como por el consumo energético y de recursos asociado a determinados sistemas.

En cuanto a los **principios éticos** que deberían orientar el desarrollo y uso de la IA, los documentos anteriores coinciden, con matices, en un núcleo bastante estable:

- **Centralidad de la persona y respeto a los derechos humanos**, de modo que la IA esté al servicio de las personas y no al revés.
- **Equidad y no discriminación**, evitando sesgos injustificados y promoviendo un trato igualitario.
- **Transparencia y explicabilidad**, para que los sistemas sean comprensibles en un grado adecuado al contexto y a sus efectos.
- **Supervisión y control humano**, garantizando que existan mecanismos de intervención, revisión o corrección por parte de personas.
- **Robustez técnica, seguridad y fiabilidad**, durante todo el ciclo de vida del sistema.
- **Responsabilidad, trazabilidad y rendición de cuentas**, para poder auditar el sistema y atribuir responsabilidades cuando proceda.
- **Sostenibilidad y orientación al bienestar social**, procurando que la IA contribuya al desarrollo inclusivo y minimice impactos negativos sobre personas y entorno.

Junto a esos principios, pueden señalarse algunas **recomendaciones prácticas** habituales en estos marcos de referencia:

- Realizar evaluaciones de riesgos antes del despliegue y durante todo el ciclo de vida del sistema.
- Documentar datos, procesos, limitaciones y decisiones relevantes para facilitar la trazabilidad.
- Informar de forma clara cuando una persona interactúa con un sistema de IA o con contenido generado por IA.
- Establecer mecanismos de revisión humana, reclamación y corrección de resultados perjudiciales.
- Reforzar la formación y alfabetización en IA de profesionales, organizaciones y ciudadanía.
- Promover una gobernanza pública y organizativa que combine innovación con protección de derechos, seguridad y confianza.

12.1 Sesgos en Inteligencia Artificial

Uno de los principales riesgos éticos asociados a la Inteligencia Artificial es la aparición de sesgos. En este contexto, un **sesgo** puede definirse como una desviación sistemática en los datos, en el diseño del sistema, en el entrenamiento del modelo o en su uso, que provoca que los resultados generados favorezcan o perjudiquen de forma injustificada a determinados grupos, situaciones o individuos.

Los sesgos no aparecen necesariamente porque el sistema haya sido diseñado con una intención discriminatoria. En muchos casos surgen porque los datos utilizados para entrenar el modelo reflejan desigualdades existentes en la realidad, porque la muestra no representa adecuadamente a toda la población, porque se seleccionan variables inadecuadas o porque el modelo se aplica en un contexto distinto de aquel para el que fue diseñado. Por ello, la detección y mitigación de sesgos constituye una parte esencial del desarrollo responsable de sistemas de IA.

Entre los principales tipos de sesgo en Inteligencia Artificial pueden destacarse los siguientes:

- **Sesgo de datos o de representación:** Se produce cuando los datos utilizados para entrenar el modelo no representan de forma equilibrada a todos los grupos o situaciones relevantes. Por ejemplo, un sistema de reconocimiento facial entrenado mayoritariamente con imágenes de personas de un determinado perfil puede presentar peor rendimiento en personas con características menos representadas en el conjunto de entrenamiento.
- **Sesgo histórico:** Aparece cuando los datos reflejan desigualdades o discriminaciones existentes en la sociedad. Aunque los datos sean técnicamente correctos, pueden reproducir patrones injustos del pasado. Por ejemplo, un sistema de selección de personal entrenado con historiales de contratación anteriores podría aprender a favorecer perfiles tradicionalmente más contratados, aunque ello responda a prácticas previas discriminatorias.
- **Sesgo de selección:** Surge cuando la forma de recopilar los datos introduce una distorsión en la muestra. Por ejemplo, si se analiza la satisfacción ciudadana solo a partir de encuestas online, pueden quedar infrarrepresentadas las personas con menor acceso o menor familiaridad con medios digitales.
- **Sesgo de etiquetado:** Se produce cuando las etiquetas utilizadas para entrenar un modelo son incorrectas, incompletas o reflejan criterios subjetivos. Por ejemplo, en un sistema de clasificación de incidencias administrativas, distintos empleados podrían etiquetar casos similares de manera diferente, generando inconsistencias que después aprende el modelo.
- **Sesgo algorítmico o de modelado:** Puede aparecer por las decisiones técnicas adoptadas durante el diseño del modelo, como la elección del algoritmo, las variables utilizadas, la función de pérdida o los criterios de optimización. Por ejemplo, un modelo optimizado únicamente para maximizar la precisión global puede funcionar peor en grupos minoritarios si estos tienen menor peso en el conjunto de datos.
- **Sesgo de medición:** Se produce cuando las variables utilizadas no miden adecuadamente el fenómeno que se quiere analizar. Por ejemplo, utilizar el número de visitas a un portal electrónico como indicador único de necesidad ciudadana puede sesgar el análisis, ya que no todas las personas acceden con la misma facilidad a los servicios digitales.
- **Sesgo de automatización:** Aparece cuando las personas tienden a confiar excesivamente en los resultados generados por un sistema automatizado, incluso cuando pueden ser erróneos o incompletos. Por ejemplo, un empleado público podría aceptar sin suficiente revisión una recomendación generada por un sistema de apoyo a la decisión.

- **Sesgo de despliegue o de uso:** Surge cuando un sistema se utiliza en un contexto diferente de aquel para el que fue diseñado o entrenado. Por ejemplo, un modelo desarrollado con datos de una determinada población o territorio puede no funcionar correctamente si se aplica directamente a otro entorno con características distintas.

12.2Resumen del apartado

Nivel	Principales documentos relativos al impacto ético de la IA
Mundial	Recomendación sobre la Ética de la Inteligencia Artificial (UNESCO, 2021); Principios de IA de la OCDE (2019, actualizados en 2024)
Europeo	<i>Ethics Guidelines for Trustworthy AI</i> de la Comisión Europea; Reglamento de IA de la UE (<i>AI Act</i> , en vigor desde 1 de agosto de 2024)
Nacional (España)	Carta de Derechos Digitales (2021); Estrategia de Inteligencia Artificial 2024

Tabla 17. Principales documentos relativos a la ética en IA

13 RESUMEN ESQUEMÁTICO

La Inteligencia Artificial es la disciplina que diseña sistemas capaces de **tratar información compleja** y generar resultados útiles con cierto grado de autonomía. Su finalidad principal es **automatizar tareas cognitivas, inferir o predecir, apoyar la toma de decisiones, optimizar procesos y generar contenidos**. En la actualidad, su relevancia no es solo técnica, sino también **jurídica, organizativa y ética**.

Evolución de la IA:

Etapas	Periodo	Idea esencial	Hitos representativos
Antecedentes	1943-1950	Bases teóricas de computación y redes neuronales	McCulloch y Pitts; Turing
Nacimiento formal	1956	Inicio institucional de la IA	Dartmouth
IA simbólica	1950-1960	Predominio de reglas, símbolos y lógica	Logic Theorist, GPS, perceptrón
Sistemas expertos e inviernos	1960-1980	Aplicación en dominios concretos y crisis por límites técnicos	DENDRAL, MYCIN
Machine Learning y redes neuronales	1980-1990	Aprendizaje a partir de datos	Retropropagación, Deep Blue
Deep Learning e IA generativa	2010-actualidad	Redes profundas, transformers y modelos generativos	AlexNet, Transformer, ChatGPT
Expansión y regulación	2023-2026	Modelos fundacionales, multimodalidad, IA agéntica y regulación	AI Act

Tabla 18. Evolución de la IA

Clasificación de la Inteligencia Artificial:

- Según su capacidad:

Tipo	Caracterización
IA débil o estrecha	Diseñada para tareas concretas. Es la existente en la práctica actual
IA fuerte o general	Hipotética. Equivaldría a una inteligencia general comparable a la humana

Tabla 19. Clasificación IA según su capacidad

- Según su enfoque:

Enfoque	Rasgo principal	Fortalezas	Limitaciones
Simbólico	Representa conocimiento con reglas y lógica	Explicabilidad	Rigidez ante contextos complejos
Estadístico	Aprende patrones a partir de datos	Buena capacidad predictiva	Depende de datos y calidad del entrenamiento
Conexionista	Redes neuronales que ajustan pesos	Gran rendimiento en lenguaje, imagen y voz	Menor interpretabilidad

Tabla 20. Clasificación de la IA según su enfoque

- **Según su ámbito de aplicación. Principales ámbitos:** Industria y logística, sanidad, finanzas, educación, administraciones públicas, seguridad y defensa, lenguaje y comunicación, visión artificial, robótica y sistemas autónomos.

Principales ramas de la IA:

Rama	Objeto principal	Aplicaciones típicas
Machine Learning	Aprender patrones a partir de datos	Predicción, clasificación, recomendación
Deep Learning	Aprendizaje profundo mediante redes neuronales	Lenguaje, imagen, voz, IA generativa
PLN / NLP	Comprensión y generación de lenguaje humano	Traducción, resumen, <i>chatbots</i> , asistentes
Visión artificial	Extracción de información desde imágenes y vídeo	Reconocimiento, detección, segmentación
Sistemas expertos	Razonamiento basado en reglas	Diagnóstico, apoyo experto en dominios concretos
Robótica	Percepción, planificación y actuación física	Robots industriales, drones, vehículos autónomos
Agentes inteligentes	Sistemas que perciben, razonan y actúan orientados a objetivos	Asistentes, sistemas multiagente, automatización compleja

Tabla 21. Ramas de estudio de la IA

Machine Learning: es la rama de la IA que permite a las máquinas **aprender a partir de datos** sin programar explícitamente todas las reglas. Sus tareas más habituales son:

- Clasificación
- Regresión
- Predicción
- Agrupamiento

Ciclo de vida del *Machine Learning*:

Fase	Contenido esencial
1. Obtención de datos	Definición del problema, variable objetivo y recopilación de datos
2. Preparación de datos	Limpieza, codificación, selección y normalización
3. Entrenamiento	Ajuste del algoritmo a los datos
4. Evaluación	Comprobación del rendimiento sobre datos no vistos
5. Mejora continua	Revisión, monitorización y actualización del modelo

Tabla 22. Ciclo de vida ML

Tipos de aprendizaje:

Tipo	Idea esencial	Ejemplos de uso
Supervisado	Aprende con datos etiquetados	Clasificación y regresión
No supervisado	Descubre patrones sin etiquetas	<i>Clustering</i> , reducción de dimensionalidad
Semi-supervisado	Combina pocos datos etiquetados con muchos no etiquetados	Texto, imagen, voz
Por refuerzo	Aprende mediante recompensas y penalizaciones	Robótica, juegos, planificación

Tabla 23. Tipos de aprendizaje en ML

Algoritmos representativos:**Supervisados:**

- Regresión lineal
- Regresión logística
- SVM
- k-NN
- *Naive Bayes*
- Árboles de decisión
- *Random Forest*
- ExtraTrees
- GBM

No supervisados:

- *k-Means*
- *k-Medoids*
- DBSCAN
- GMM

Otros enfoques:

- Algoritmos genéticos

Redes neuronales y *Deep Learning*:

Elemento	Idea esencial
Perceptrón	Unidad básica inspirada en la neurona
Redes multicapa	Permiten modelar relaciones más complejas
CNN	Especializadas en tratamiento de imágenes
RNN	Adecuadas para secuencias y series temporales
Transformers	Arquitectura clave del PLN moderno y de los modelos fundacionales

Tabla 24. Arquitecturas redes neuronales

Arquitecturas de IA generativa:

Arquitectura	Idea básica
VAE	Aprende representaciones latentes para generar datos
GAN	Dos redes compiten para generar muestras realistas
Modelos de difusión	Generación progresiva de contenido desde ruido

Tabla 25. Arquitecturas IA generativa

Procesamiento del Lenguaje Natural busca que las máquinas puedan: analizar, comprender, interpretar y generar lenguaje humano

- Elementos actuales más destacados:
 - **LLM**: grandes modelos de lenguaje
 - **RAG**: combinación de generación con recuperación de información externa

Sistemas expertos: Basados en **conocimiento explícito** y **reglas de inferencia**. Muy útiles en dominios concretos

- Ventaja: **explicabilidad**
- Inconveniente: menor flexibilidad y mayor dificultad de mantenimiento

Robótica: Integra IA, sensores, planificación, control y actuación física

Agentes inteligentes: Perciben el entorno, razonan sobre él y actúan para alcanzar objetivos

Visión artificial: Extrae información útil de imágenes y vídeo

- Tareas principales: clasificación, detección de objetos, segmentación y reconocimiento

Reglamento Europeo de Inteligencia Artificial:

Finalidad del Reglamento:

Elemento	Contenido
Finalidad	Crear un marco jurídico común para el desarrollo, comercialización y uso de la IA
Enfoque	Regulación según nivel de riesgo
Objetivo	Proteger derechos, seguridad e intereses generales sin frenar la innovación

Tabla 26. Conceptos clave AI Act

Niveles de riesgo:

Nivel	Caracterización
Riesgo inaceptable	Prácticas prohibidas
Alto riesgo	Sistemas sometidos a requisitos estrictos
Riesgo limitado	Obligaciones de transparencia
Riesgo mínimo	Sin cargas regulatorias intensas, con carácter general

Tabla 27. Clasificación sistemas de IA en el AI Act

Marco de políticas públicas:

Resumen de políticas:

Nivel	Esquema mínimo
Europeo	AI Act: norma central de la UE. Paquete europeo de innovación en IA (2024): impulso al ecosistema. AI Factories: supercomputación, datos y experimentación. AI Continent Action Plan (2025): competitividad e infraestructuras. Apply AI Strategy (2025): adopción sectorial de la IA.
Nacional	Marco español alineado con la UE. Se articula sobre Estrategia de IA 2024 + gobernanza institucional + políticas de digitalización.

Tabla 28. Resumen de políticas

La estrategia española IA 2024 está compuesta por 3 ejes y 8 palancas. Los ejes son estos:

- Capacidades
- Expansión
- IA responsable

Gobernanza institucional de IA en España:

Órgano	Función básica
Ministerio para la Transformación Digital y de la Función Pública	Impulso general de la política pública de IA.
SEDIA	Dirección estratégica y coordinación.
AESIA	Supervisión especializada, buenas prácticas y apoyo al marco europeo.
AEAD	Servicios comunes digitales e implantación operativa en la AGE.
Oficina del Dato / <i>Chief Data Officer</i>	Gobernanza del dato, estándares y marcos de gestión.

Tabla 29. Gobernanza institucional IA en España

14 GLOSARIO

- **AEAD:** Agencia Estatal de Administración Digital.
- **AESIA:** Agencia Española de Supervisión de la Inteligencia Artificial.
- **AGE:** Administración General del Estado.
- **AGI (*Artificial General Intelligence*):** Inteligencia Artificial General o Inteligencia Artificial fuerte de propósito general, de carácter hipotético.
- **Algoritmo:** procedimiento o método matemático utilizado para aprender a partir de los datos y construir un modelo.
- **Aprendizaje por refuerzo:** tipo de aprendizaje automático en el que un agente aprende mediante interacción con un entorno a partir de recompensas y penalizaciones.
- **Aprendizaje semi-supervisado:** tipo de aprendizaje automático que combina una pequeña cantidad de datos etiquetados con una cantidad mayor de datos no etiquetados.
- **Aprendizaje supervisado:** tipo de aprendizaje automático en el que el modelo se entrena con ejemplos etiquetados, es decir, con entradas y salidas conocidas.
- **Aprendizaje no supervisado:** tipo de aprendizaje automático en el que el sistema identifica patrones, estructuras o agrupaciones en datos no etiquetados.
- **Capacitación:** proceso para establecer o mejorar los parámetros de un modelo de aprendizaje automático mediante el uso de datos de entrenamiento.
- **Clasificación:** tarea de aprendizaje automático consistente en asignar una observación a una categoría o clase.
- **Clustering:** técnica de aprendizaje no supervisado orientada a agrupar observaciones similares en clústeres.
- **Codificación** de variables: transformación de variables no numéricas en representaciones aptas para ser procesadas por algoritmos de aprendizaje automático.
- **Dataset:** conjunto de datos organizado para el entrenamiento, validación o prueba de un modelo.
- **DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*):** algoritmo de agrupamiento no supervisado basado en densidad, capaz de detectar clústeres y ruido.
- **DAI (*Distributed Artificial Intelligence*):** Inteligencia Artificial Distribuida.
- **Deep Learning (DL):** subcampo del aprendizaje automático basado en redes neuronales profundas capaces de aprender representaciones complejas de los datos.
- **Detección de anomalías:** identificación de observaciones atípicas o poco frecuentes que se apartan del comportamiento habitual de los datos.
- **Entrenamiento:** fase del ciclo de vida del aprendizaje automático en la que el algoritmo ajusta sus parámetros a partir de los datos disponibles.
- **ExtraTree (*Extremely Randomized Trees*):** método de combinación basado en árboles extremadamente aleatorizados, utilizado en clasificación y regresión.
- **Feature:** característica o variable de entrada utilizada por un modelo para realizar predicciones.

- **GAN (Generative Adversarial Network)**: red adversaria generativa formada por dos redes neuronales que compiten entre sí para generar datos sintéticos realistas.
- **GBM (Gradient Boosting Machine)**: técnica de combinación que construye secuencialmente modelos débiles para mejorar la precisión predictiva.
- **GMM (Gaussian Mixture Model)**: modelo probabilístico de mezcla gaussiana empleado en tareas de agrupamiento.
- **GPT (Generative Pre-Training)**: familia de modelos generativos preentrenados basados en transformadores.
- **Hiperparámetros**: configuraciones fijadas antes del entrenamiento que determinan cómo aprende el modelo.
- **IA**: Inteligencia Artificial.
- **IA agéntica**: enfoque orientado a sistemas capaces de planificar y ejecutar secuencias de acciones para alcanzar objetivos complejos con cierto grado de autonomía.
- **IA débil**: Inteligencia Artificial especializada en tareas concretas, sin capacidades generales equivalentes a la inteligencia humana.
- **IA fuerte**: concepto teórico de Inteligencia Artificial general capaz de comprender, razonar y adaptarse de forma amplia a múltiples contextos.
- **IA generativa**: rama de la Inteligencia Artificial capaz de generar contenidos nuevos, como texto, imagen, audio o código.
- **k-Means (k-Medias)**: algoritmo de aprendizaje no supervisado que agrupa los datos en k clústeres a partir de centroides.
- **k-medoids**: algoritmo de agrupamiento similar a k-Means, pero basado en medoids, es decir, puntos reales del conjunto de datos.
- **k-NN (k-Nearest Neighbors)**: algoritmo de aprendizaje supervisado que clasifica o predice en función de los k vecinos más cercanos.
- **LLM (Large Language Model)**: gran modelo de lenguaje entrenado sobre grandes volúmenes de texto para comprender y generar lenguaje natural.
- **ML (Machine Learning)**: aprendizaje automático; rama de la Inteligencia Artificial centrada en el desarrollo de algoritmos que aprenden a partir de los datos.
- **Modelo**: resultado concreto de aplicar un algoritmo de aprendizaje automático a un conjunto de datos; representación entrenada capaz de predecir sobre nuevos casos.
- **Modelo fundacional**: modelo de gran escala entrenado sobre grandes volúmenes de datos y reutilizable para múltiples tareas posteriores.
- **Modelo multimodal**: sistema de Inteligencia Artificial capaz de procesar o generar información en varios modos, como texto, imagen, audio o vídeo.
- **Naive Bayes**: familia de algoritmos probabilísticos de clasificación basados en el teorema de Bayes y en la hipótesis de independencia entre variables.
- **Normalización de datos**: proceso de reescalado de variables numéricas para expresarlas en magnitudes comparables.
- **NLP (Natural Language Processing)**: Procesamiento del Lenguaje Natural.

- **OCDE:** Organización para la Cooperación y el Desarrollo Económicos.
- **Overfitting:** sobreajuste; situación en la que el modelo aprende en exceso los datos de entrenamiento y pierde capacidad de generalización.
- **Patrón:** conjunto de características y relaciones que permite reconocer regularidades, entidades o comportamientos en los datos.
- **Perceptrón:** modelo básico de neurona artificial utilizado como base conceptual de las redes neuronales.
- **PLN:** Procesamiento del Lenguaje Natural.
- **Predicción:** estimación de un resultado futuro o desconocido a partir de los datos disponibles.
- **Preprocesado:** conjunto de operaciones de preparación de datos previas al entrenamiento, como limpieza, codificación, selección de variables o normalización.
- **RAG (Retrieval-Augmented Generation):** Generación Aumentada por Recuperación; técnica que combina un modelo generativo con recuperación previa de información relevante.
- **Regresión:** tarea de aprendizaje automático orientada a predecir valores numéricos continuos.
- **Regresión logística:** algoritmo de aprendizaje supervisado utilizado principalmente en problemas de clasificación.
- **Regresión lineal:** algoritmo de aprendizaje supervisado que modela la relación lineal entre una variable dependiente y una o varias variables independientes.
- **Regularización:** conjunto de técnicas destinadas a limitar la complejidad del modelo y reducir el sobreajuste.
- **Red neuronal:** modelo computacional inspirado de forma simplificada en el funcionamiento de las neuronas biológicas, compuesto por nodos interconectados.
- **RGPD:** Reglamento General de Protección de Datos.
- **RIA:** Reglamento Europeo de Inteligencia Artificial.
- **Selección de características:** proceso de identificación de las variables más relevantes para entrenar un modelo.
- **Sesgo:** error sistemático que puede producirse en los datos, en el muestreo o en el modelo, favoreciendo determinados resultados frente a otros.
- **SMA:** Sistema Multiagente.
- **Sistema experto:** sistema de Inteligencia Artificial basado en reglas y conocimiento explícito para emular el razonamiento de especialistas humanos en un dominio concreto.
- **SVM (Support Vector Machine):** algoritmo de aprendizaje supervisado que busca la frontera de decisión que mejor separa las clases maximizando el margen.
- **Target:** variable objetivo que el modelo debe predecir.
- **Testing:** fase de evaluación del modelo sobre datos no vistos para medir su capacidad de generalización.
- **Transformer:** arquitectura de red neuronal basada en mecanismos de atención, clave en el desarrollo moderno del PLN y de los grandes modelos generativos.

- ***Underfitting***: infraajuste; situación en la que el modelo no aprende suficientemente los patrones relevantes de los datos.
- **Validación**: comprobación del rendimiento del modelo durante su ajuste, normalmente sobre un conjunto de datos distinto del de entrenamiento.
- **VAE (*Variational Autoencoder*)**: autoencoder variacional utilizado en generación de datos y aprendizaje de representaciones.
- **Variable** objetivo: resultado o etiqueta que el modelo trata de predecir.
- **Verificación**: comprobación de que un sistema cumple los requisitos especificados.
- **Visión artificial**: rama de la Inteligencia Artificial orientada a extraer información útil a partir de imágenes, vídeo y otras señales visuales.

15 TEST

15.1 Preguntas de test

1. ¿Cuál de las siguientes afirmaciones describe mejor la finalidad general de la Inteligencia Artificial?
 - a. Reproducir exactamente la conciencia humana.
 - b. Dotar a los sistemas informáticos de capacidad para tratar información compleja y producir resultados útiles.
 - c. Sustituir por completo a las personas en cualquier tarea.
 - d. Eliminar la necesidad de datos en la toma de decisiones.
2. Según el tema, ¿qué hito suele considerarse el nacimiento formal de la Inteligencia Artificial como disciplina?
 - a. La publicación del test de Turing en 1950.
 - b. La creación de Deep Blue en 1997.
 - c. La conferencia de Dartmouth de 1956.
 - d. La aparición de AlexNet en 2012.
3. ¿Cuál de los siguientes ejemplos pertenece principalmente a la etapa de los sistemas expertos?
 - a. Transformer.
 - b. MYCIN.
 - c. AlexNet.
 - d. ChatGPT.
4. ¿Qué caracteriza principalmente al enfoque simbólico de la Inteligencia Artificial?
 - a. Aprende exclusivamente a partir de grandes volúmenes de datos no etiquetados.
 - b. Representa el conocimiento mediante símbolos, reglas lógicas y relaciones formales.
 - c. Se basa únicamente en redes neuronales profundas.
 - d. Solo puede aplicarse a visión artificial.
5. ¿Cuál de las siguientes opciones es una diferencia correcta entre algoritmo y modelo de *Machine Learning*?
 - a. El algoritmo es el resultado final entrenado y el modelo es el procedimiento matemático.
 - b. No existe diferencia práctica entre ambos conceptos.
 - c. El algoritmo es el método de aprendizaje y el modelo es el resultado entrenado obtenido.
 - d. El algoritmo solo se usa en aprendizaje no supervisado y el modelo en supervisado.
6. ¿Cuál de las siguientes tareas corresponde típicamente al aprendizaje supervisado?
 - a. Agrupar clientes sin etiquetas previas.
 - b. Predecir si un correo es spam o no a partir de ejemplos etiquetados.
 - c. Detectar estructura latente sin variable objetivo.
 - d. Reducir dimensionalidad sin salidas conocidas.
7. ¿Cuál de los siguientes algoritmos se menciona en el tema como método de aprendizaje no supervisado basado en densidad?

- a. *Random Forest*.
 - b. DBSCAN.
 - c. Regresión logística.
 - d. SVM.
8. ¿Cuál es la principal ventaja de DBSCAN frente a otros métodos de agrupamiento?
- a. Exige fijar previamente el número exacto de clústeres.
 - b. Solo funciona con datos linealmente separables.
 - c. Puede detectar grupos de forma arbitraria e identificar ruido.
 - d. No necesita parámetros de entrada.
9. ¿Para qué se utiliza principalmente la normalización de datos?
- a. Para eliminar todas las variables categóricas del *dataset*.
 - b. Para reducir la dimensionalidad mediante proyecciones lineales.
 - c. Para reescalar variables numéricas y hacer comparables sus magnitudes.
 - d. Para convertir variables numéricas en texto.
10. ¿Qué situación describe mejor el *overfitting*?
- a. El modelo no aprende suficientemente los patrones relevantes de los datos.
 - b. El modelo memoriza en exceso los datos de entrenamiento y generaliza peor.
 - c. El modelo funciona igual en entrenamiento y prueba.
 - d. El modelo no utiliza hiperparámetros.
11. ¿Cuál de las siguientes arquitecturas tuvo una importancia decisiva desde 2017 en el desarrollo del procesamiento del lenguaje natural?
- a. Perceptrón simple.
 - b. Transformer.
 - c. Árbol de decisión.
 - d. k-NN.
12. ¿Qué rama de la Inteligencia Artificial se ocupa principalmente de que las máquinas analicen, comprendan y generen lenguaje humano?
- a. Visión artificial.
 - b. Robótica.
 - c. Procesamiento del Lenguaje Natural.
 - d. Sistemas expertos.
13. ¿Qué significa la sigla RAG en el contexto de los LLMs?
- a. Randomized Algorithm Generator.
 - b. Retrieval-Augmented Generation.
 - c. Recursive Attention Graph.
 - d. Reinforced Autonomous Guidance.
14. ¿Cuál de las siguientes afirmaciones sobre el aprendizaje por refuerzo es correcta?
- a. Aprende exclusivamente con datos previamente etiquetados.
 - b. No existe interacción con el entorno.
 - c. El agente aprende mediante recompensas y penalizaciones derivadas de sus acciones.

- d. Su única aplicación es la clasificación documental.
15. ¿Qué se entiende por IA débil según el tema?
- a. Un sistema especializado en tareas concretas dentro de un ámbito limitado.
 - b. Una inteligencia equivalente a la humana en cualquier contexto.
 - c. Una máquina consciente capaz de comprender cualquier problema.
 - d. Una IA que no utiliza datos para aprender.
16. ¿Cuál de las siguientes opciones se considera una de las principales ramas de estudio de la IA en el tema?
- a. Contabilidad computacional.
 - b. Procesamiento del Lenguaje Natural.
 - c. Ingeniería fiscal automatizada.
 - d. Ofimática predictiva.
17. ¿Cuál es la función principal de la selección de características?
- a. Escoger las variables más relevantes para entrenar el modelo.
 - b. Convertir texto en audio.
 - c. Asignar etiquetas manuales a todo el *dataset*.
 - d. Aumentar siempre el número de variables de entrada.
18. ¿Cuál de las siguientes afirmaciones sobre los modelos de mezclas gaussianas (GMM) es correcta?
- a. Son un método supervisado de clasificación binaria.
 - b. Son modelos probabilísticos utilizados para agrupamiento.
 - c. Son redes neuronales recurrentes especializadas en texto.
 - d. Son una técnica de regularización.
19. Según el tema, el Reglamento Europeo de Inteligencia Artificial (RIA) entró en vigor el:
- a. de agosto de 2026.
 - b. 1 de agosto de 2024.
 - c. 1 de enero de 2025.
 - d. 7 de junio de 2023.
20. ¿Cuál de las siguientes opciones describe mejor la visión artificial?
- a. La disciplina orientada a extraer información útil a partir de imágenes, vídeos y señales visuales.
 - b. La técnica dedicada exclusivamente a traducir textos entre idiomas.
 - c. El uso de reglas lógicas para representar conocimiento jurídico.
 - d. La automatización de expedientes administrativos sin uso de imágenes.

15.2 Soluciones a las preguntas de test

PREGUNTA	SOLUCIÓN
1	b
2	c
3	b
4	b
5	c
6	b
7	b
8	c
9	c
10	b
11	b
12	c
13	b
14	c
15	a
16	b
17	a
18	b
19	b
20	a

16 BIBLIOGRAFÍA BÁSICA

16.1 Bibliografía básica

- Recommendation of the Council on Artificial Intelligence (OCDE): <https://legalinstruments.oecd.org/en/instruments/oecd-legal-0449>
- OECD. Explanatory Memorandum on the Updated OECD Definition of an AI System: https://www.oecd.org/en/publications/explanatory-memorandum-on-the-updated-oecd-definition-of-an-ai-system_623da898-en.html
- OCDE. AI Principles: <https://www.oecd.org/en/topics/ai-principles.html>
- Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de Inteligencia Artificial (Reglamento de IA / AI Act): <https://eur-lex.europa.eu/legal-content/ES/ALL/?uri=CELEX:32024R1689>
- Estrategia de Inteligencia Artificial 2024: <https://espanadigital.gob.es/estrategia-de-inteligencia-artificial-2024>
- Agencia Española de Supervisión de la Inteligencia Artificial (AESIA): <https://aesia.digital.gob.es/es>
- Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016 (Reglamento General de Protección de Datos): <https://eur-lex.europa.eu/eli/reg/2016/679/oj?locale=es>
- Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales: <https://www.boe.es/eli/es/lo/2018/12/05/3/con>
- Parlamento Europeo. Marco de los aspectos éticos de la Inteligencia Artificial, la robótica y las tecnologías conexas: https://www.europarl.europa.eu/doceo/document/TA-9-2020-0275_ES.html
- Stanford HAI. Artificial Intelligence Index Report 2025: https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf

16.2 Bibliografía para ampliar el tema

- Russell, S.; Norvig, P. *Artificial Intelligence: A Modern Approach*.
- Goodfellow, I.; Bengio, Y.; Courville, A. *Deep Learning*.
- Mitchell, T. *Machine Learning*.
- Bishop, C. M. *Pattern Recognition and Machine Learning*.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*.
- Murphy, K. P. *Probabilistic Machine Learning: An Introduction*.
- Vaswani, A. et al. *Attention Is All You Need*.
- LeCun, Y.; Bengio, Y.; Hinton, G. *Deep learning*.