



*Asociación Profesional de Cuerpos Superiores
de Sistemas y Tecnologías de la Información
de las Administraciones Públicas.*

Temario para la preparación de la Oposición al Cuerpo Superior de Sistemas
y Tecnologías de la Información de la Administración del Estado.

TEMAS ESPECÍFICOS – BLOQUE B

II. Tecnología básica

Tema 71. Ciencia de datos. Ciclo de vida de los procesos de modelado de datos (ETL, preprocesado, modelado, validación, MLops). Fundamentos estadísticos. Herramientas y lenguajes. Visualización de datos.

AUTOR: Guillermo Bayón del Oso.

REVISOR: José Manuel Goberna Ruiz Poveda.

**Creación:
septiembre
2023**

ÍNDICE DE CONTENIDOS

1	CIENCIA DE DATOS	4
1.1	INTRODUCCIÓN A LA CIENCIA DE DATOS	4
1.2	PERFILES PROFESIONALES.....	8
1.3	ÓRGANOS Y ORGANISMOS. NORMATIVA RELEVANTE.	9
1.3.1	AGENCIA ESPAÑOLA DE SUPERVISIÓN DE LA INTELIGENCIA ARTIFICIAL (AESIA) 9	
1.3.2	GOBIERNO DEL DATO Y CALIDAD DEL DATO	9
1.3.3	NORMAS ISO 8000	10
1.3.4	ISO 38505	11
1.3.5	NORMATIVA Y ÓRGANOS ESTATALES	12
1.3.6	NORMATIVA Y ÓRGANOS EUROPEOS.....	12
1.4	METODOLOGÍAS Y GOBIERNO DEL DATO	13
1.5	TEMAS RELACIONADOS	15
2	CICLO DE VIDA DE LOS PROCESOS DE MODELADO DE DATOS	16
2.1	DESCRIPCIÓN DEL CICLO DE VIDA DEL DATO	16
2.2	PROCESOS DE INTEGRACIÓN DE DATOS	17
2.2.1	PROCESOS ETL/ELT	18
2.2.2	SINCRONIZACIÓN MEDIANTE STREAMING	20
2.3	PREPROCESADO DE DATOS.....	20
2.4	MODELADO.....	21
2.4.1	ANÁLISIS DESCRIPTIVO.....	22
2.4.2	ANÁLISIS PREDICTIVO	23
2.5	VALIDACIÓN	24
2.5.1	ALGUNAS ESTRATEGIAS DE VALIDACIÓN	24
2.6	MLOPS – MACHINE LEARNING OPERATIONS	25
3	FUNDAMENTOS ESTADÍSTICOS	27
3.1	FUNDAMENTOS MATEMÁTICOS Y ESTADÍSTICOS	27
4	HERRAMIENTAS Y LENGUAJES DE CIENCIA DE DATOS 30	
4.1.1	LENGUAJES DE PROGRAMACIÓN UTILIZADOS EN CIENCIA DE DATOS.....	30
4.1.2	HERRAMIENTAS PARA LA CIENCIA DE DATOS	31
5	VISUALIZACIÓN DE DATOS.....	34
5.1.1	VISUALIZACIÓN COMO PROCESO DE COMUNICACIÓN	34
5.1.2	ELEMENTOS CLAVE PARA UNA BUENA VISUALIZACIÓN DE DATOS	34
5.1.3	DIFERENTES TIPOS DE VISUALIZACIONES	35
6	EJEMPLOS DE PROYECTOS RELACIONADOS CON CIENCIA DE DATOS EN LAS ADMINISTRACIONES	37

7	RESUMEN ESQUEMÁTICO.....	38
8	GLOSARIO	39
9	TEST	41
9.1	PREGUNTAS DE TEST	41
9.2	SOLUCIONES A LAS PREGUNTAS DE TEST.....	44
10	REFERENCIAS	45
10.1	BIBLIOGRAFÍA BÁSICA [BBx]	45
10.2	BIBLIOGRAFÍA COMPLEMENTARIA PARA AMPLIAR EL TEMA [BCx]	45
10.3	OTRAS REFERENCIAS [ORx]	45

1 Ciencia de datos




Figura 1: Una visión arquitectónica de la ciencia de datos, extremo-a-extremo

1.1 Introducción a la ciencia de datos

Según diversos estudios académicos y de mercado cuyos objetivos son estimar el crecimiento de los datos creados, consumidos y almacenados durante los últimos años, se ha pasado de apenas 1 zettabyte en 2010 de datos, hasta los 200 zettabytes que se prevén en 2025. Aunque estos datos son meras estimaciones se puede observar que el crecimiento según las gráficas es exponencial. Parte de esta información se está recopilando en diferentes sistemas analíticos, donde se pueda realizar una explotación de los mismos para la creación de valor. Esto motivó la creación de una no tan nueva disciplina que se ha denominado ciencia de datos.

La ciencia de datos es un campo interdisciplinario que hace uso de otros campos de conocimiento para tratar este conjunto de datos tan amplio del que hemos hablado y así generar valor a las partes interesadas. El resultado final normalmente consiste en diferentes visualizaciones de estos conjuntos de datos (mediante informes, gráficas, paneles de mando, etc). Esta información la utilizan diferentes actores para extraer conclusiones. Es habitual la consulta por parte de cargos directivos y ejecutivos, pero cada vez es más normal que cierto tipo de información también esté disponible para la ciudadanía (previos procesos de anonimización o seudonimización que añadan privacidad y eliminen los datos personales concretos), lo que aumenta la transparencia de las instituciones y fomenta el buen gobierno.

Mediante modelado del ciclo de vida del proceso de ciencia de datos se recopila de diferentes orígenes de datos la información, volcando la información en los almacenes de datos y procesándola. Al final se tiene como resultado final la visualización de esos datos para los actores interesados.

Un adecuado conocimiento del negocio es uno de los factores con contribuyen al éxito de los proyectos de ciencia de datos. Se han de definir entonces los procesos de adquisición y comprensión de los datos, que extraerán esta información de los orígenes de datos y la presentarán en una forma óptima para su almacenamiento posterior. Estos orígenes en el caso más habitual suelen ser sistemas operacionales (bases de datos relacionales o NoSQL) que están dando servicio productivo a los usuarios. En otros

casos existen orígenes más heterogéneos, como pueden ser ficheros estructurados (XML, hojas de cálculo, etc) o incluso fuentes no estructuradas como imágenes (JPEG, PNG, TIFF, etc), ficheros de audio (OGG, FLAC, MP3) o de vídeo (AVI, MKV, MP4, etc) o documentos (PDF, procesador de texto, etc). Estas fuentes no estructuradas probablemente necesiten un procesamiento previo de la información para poder analizarlas adecuadamente. En el caso del audio por ejemplo se podría realizar un proceso de transformación de voz a texto (Speech-To-Text) antes o después de insertar la información en el almacén.

El modelado adecuado de los datos precede a la implementación de los procesos analíticos, para lo que se necesita perfiles adecuados que sepan hacer esta traducción. Se diseñan entonces las visualizaciones que se mostrarán a los interesados, que podrán ser en forma de informes, cuadros de mando, gráficas interactivas, etc. Por último, el cliente (de la parte de negocio) revisa estas visualizaciones y acepta el resultado final.

El modelado de este proceso da como resultado la definición de los conjuntos de datos o *DataSets* que se procesarán. En una fase posterior, el proceso de integración moverá estos datos desde los orígenes hasta el destino. Este proceso de integración puede mover los datos de forma periódica (mediante descargas puntuales a través de los denominados procesos *batch* que se ejecutan de forma planificada) o bien de forma continua mediante *streaming*. El destino son los diferentes tipos de almacenes de datos que se han ido definiendo. Se ampliará más sobre estos temas en el apartado 2 de este documento.

Los almacenes de datos pueden ser de varios tipos. Un almacén de datos de tipo **DataWarehouse** almacena los datos de forma estructurada para su uso posterior y toma de decisiones. Debido a ello, el enfoque utilizado para construirlo es *top-down*, es decir, que los datos se transforman mediante el proceso de integración antes de ser finalmente almacenados. Por el contrario, los otros almacenes que se mencionan (**DataLake**, **DataMart**, **DataCube**) son repositorios de datos en bruto, no necesariamente estructurados, que provienen de varias fuentes. No se transforman previamente, sino que se vuelcan y el procesamiento se hace posteriormente. Utilizan entonces un enfoque *bottom-up*. Además, en los DataCube se representan los datos o hechos en varias dimensiones, normalmente mediante *arrays* multidimensionales.

Existe una división en los sistemas de bases de datos actuales en cuanto a la forma de procesamiento principal que se realiza en ellos [OR5]. Por una parte tenemos los sistemas OLTP (*On-Line Transaction Processing*, o sistemas de procesamiento de transacciones en línea) y por otra los OLAP (*On-Line Analytic Processing*, o sistemas de procesamiento analítico en línea).

- ◆ El propósito de los sistemas **OLTP** es el de hacer el procesamiento de los datos con los que trabajan las aplicaciones operacionales, para dar el servicio requerido a los clientes o ciudadanos. Por ejemplo, en una sede electrónica trabajaría con la información de los expedientes, apertura y cierre de los mismos, gestión de los documentos e índice de documentos, etc.
- ◆ Por su parte, los sistemas **OLAP** se emplean para generar informes o realizar análisis de los datos almacenados, identificar tendencias, etc. Es decir, para generar información útil a la dirección y ayudar en la toma de decisiones. Utilizan estructuras de datos diversas, normalmente multidimensionales como cubos OLAP, que contienen los datos resumidos de las bases de datos transaccionales.

En ciencia de datos, los orígenes de datos suelen ser sistemas OLTP y los almacenes de datos pueden ser OLAP u OLTP, dependiendo de la arquitectura que se haya diseñado. Se dice que los datos recopilados en ciencia de datos cumplen "las 4 V's del BigData" [Gartner, 2012]: Volumen, Variedad, Velocidad y Valor. Algunos añaden dos V's más: Variabilidad y Veracidad. En resumen podemos decir que tratamos con un volumen de información enorme, que se expande rápidamente, desordenada y en

diferentes formatos, que ha de ser correcta, siempre en continuo proceso de cambio y que no vale de nada si no se utiliza para aportar valor al negocio.

Una vez se dispone de los datos en los almacenes de datos (o en ocasiones, en la fase de transformación de los datos), estos pueden sufrir un **procesado adicional** para extraer la información con valor de negocio. Para realizar este procesado es habitual el uso de **CPUs especializadas** (GPU, TPU, IPU, NPU, xPU). Dichos procesos son de diferente naturaleza y de forma no exhaustiva podemos enumerar los siguientes:

- ◆ Inteligencia Artificial (IA) o **Artificial Intelligence (AI)**. Es un término que nació a mediados del siglo XX, con los trabajos de Alan Turing y John McCarthy. Se puede definir como «una disciplina y conjunto de capacidades cognitivas e intelectuales expresadas por sistemas informáticos o combinaciones de algoritmos cuyo propósito es la creación de máquinas que imiten la inteligencia humana para realizar tareas, y que pueden mejorar conforme recopilan información»¹.
 - ➔ Caso particular: **IA generativa**. Es un caso particular de IA, que genera textos, imágenes y otros medios, respondiendo a instrucciones que se le suministran, y que aprenden a través de los patrones y estructuras de sus datos de entrenamiento de entrada. A partir de ellos, mediante algoritmos se pueden generar nuevos datos con características similares.
- ◆ Inteligencia empresarial o **Business Intelligence (BI)**. Analiza datos actuales e históricos, para presentar conclusiones a perfiles normalmente directivos, en formato visual que facilite la toma de decisiones. Se revelan tendencias y datos inconsistentes, de forma que se puedan encontrar patrones sobre los datos. Se realizan diferentes tipos de análisis (exploratorios, descriptivos, predictivos o estadísticos).
- ◆ Redes neuronales o **Neural Networks**. Se definen un conjunto de neuronas artificiales conectadas entre sí mediante envío de señales. La información de entrada atraviesa la red neuronal, donde sufre una serie de operaciones aritméticas, y genera unos valores de salida. Originalmente fueron propuestas por Warren McCulloch y Walter Pitts en 1943. En 1958, Frank Rosenblatt propuso el modelo teórico de perceptrón, un algoritmo implementado con dos capas de neuronales (con adición y resta simple) que reconocía patrones. El algoritmo de retropropagación hacia atrás fue creado por Paul Werbos en 1975. Las primeras investigaciones con redes multicapa se publicaron en 1965 (por los profesores Alekséi Ivájenko y V.G. Lapa). En 1969 hubo un estancamiento en la investigación debido a los descubrimientos de Marvin Minsky y Seymour Papert, en los que se descubrió que los perceptrones básicos eran incapaces de procesar el o-exclusivo y se demostró que los ordenadores de la época no tenían capacidad suficiente para procesar las grandes redes neuronales.
 - ➔ Aprendizaje profundo o **Deep Learning (DP)**. Son redes neuronales artificiales multicapa, con una profundidad mayor, que se especializan en detectar determinadas características existentes en los objetos percibidos.
 - ➔ Mapas auto-organizados o **Self-Organizing Maps (SOM)**. Se trata de realizar aprendizaje-máquina no supervisado mediante técnicas que producen representaciones con un número bajo de dimensiones (normalmente 2) de datos que en realidad originalmente tienen un alto número de dimensiones. El objetivo es preservar las características estructurales de los datos. Existen variantes como los SOM de tiempo adaptativo (emplean ratios de aprendizaje adaptativo y funciones de proximidad/vecindario), SOM en crecimiento (empiezan con un número de nodos pequeño y van creciendo basándose en una heurística) o los SOM elásticos (que minimizan la energía elástica).

¹ [Wikipedia](#).

- ◆ Modelos de gráficos probabilísticos o **Probabilistic Graphical Models** (PGM). Es un modelo probabilístico en donde un gráfico expresa la estructura de dependencia condicional entre variables aleatorias. Se utilizan comúnmente en teoría de la probabilidad, estadística (particularmente estadística bayesiana) y aprendizaje automático.
- ◆ Aprendizaje automático (AA), aprendizaje automatizado, aprendizaje-máquina o **Machine Learning** (ML). Desarrolla diferentes técnicas con el objetivo de que las computadoras aprendan.
 - ➔ Aprendizaje **supervisado**. Se tienen ejemplos etiquetados para entrenar al sistema, donde los ejemplos se encuadran dentro de una de las categorías/clases definidas. Es útil en problemas de tipo biológico, biología computacional, bioinformática, visión por computador, etc.
 - ➔ Aprendizaje **no supervisado**. Se realiza el modelado sobre un conjunto de ejemplos, teniendo en cuenta sólo las entradas al sistema.
 - ➔ Aprendizaje **semisupervisado**. Una mezcla entre los dos anteriores.
 - ➔ Aprendizaje **por refuerzo**. Hace que la IA desarrolle estrategias efectivas en base a la experimentación con los datos. Se trata de una forma de optimización basada en datos.
 - ➔ **Transducción**. Es similar al aprendizaje supervisado, pero intenta predecir ejemplos futuros basándose en información ya disponible y la que va adquiriendo.
 - ➔ Aprendizaje **multi-tarea**. Consiste en entrenar un algoritmo de aprendizaje automático para aprender múltiples tareas usando una representación compartida para todas ellas.
 - ➔ **Métodos kernel** y máquinas de soporte vectorial o **Support Vector Machines** (SVM). Dado un conjunto de ejemplos de entrenamiento, cada uno marcado como perteneciente a una de dos categorías, un algoritmo de entrenamiento SVM construye un modelo que asigna nuevos ejemplos a una categoría u otra, convirtiéndolo en un clasificador lineal binario no probabilístico. Maximiza el ancho del *gap* entre las dos categorías. Luego se asignan nuevos ejemplos a ese mismo espacio y predice a qué categoría pertenecen según el lado del *gap* en el que se encuentran.
- ◆ Procesado de lenguaje natural o **Natural Language Processing** (NLP). Es un subcampo interdisciplinario de la informática y la lingüística. Implica procesar conjuntos de datos de lenguaje natural, como corpus de texto o corpus de voz, utilizando enfoques de aprendizaje automático basados en reglas o probabilísticos. Luego, la tecnología puede extraer con precisión la información y los conocimientos contenidos en los documentos, así como categorizar y organizar los documentos.
- ◆ **Data mining**: Permite realizar extracción de datos para detectar patrones de comportamiento concretos, gracias al uso de algoritmos matemáticos. Se utilizan métodos de inserción de ML, estadísticos y contra bases de datos. Se puede realizar de forma automática o semiautomática, y forma parte del paso de análisis del proceso "**Knowledge Discovery in Databases**" (KDD).
 - ➔ Algunas variantes de Data mining: *Text mining*, *Web mining*, *Hypertext mining*.
- ◆ **Computación cuántica**. Paradigma de computación que utiliza la mecánica cuántica para resolver problemas complejos más rápido que las computadoras clásicas.

El ciclo de vida del dato se explicará en un apartado posterior, por lo que en este punto sólo daremos una definición previa. Se podría definir como el flujo que experimentan los datos desde que se capturan o recopilan, hasta que se transforman en conocimiento y se toman decisiones estratégicas en base a ellos.

Para terminar con esta introducción a la ciencia de datos, el resultado de todo este proceso ha de presentarse a ciertas partes interesadas, que mediante una visualización de forma sintética de los mismos los interpretarán y se hará la toma de decisiones en función de los objetivos de cada administración. Los diferentes tipos de visualizaciones y sus usos se desarrollarán al final de este documento.

1.2 Perfiles profesionales

Dentro de la ciencia de datos hay diferentes **perfiles profesionales**. Algunos tienen una formación más técnica, otros más científica, y también destacan los perfiles de dirección de proyectos. Podemos enumerar los siguientes:

- ◆ **Científico de datos** o Data Scientist. Es el perfil más transversal, ya que entiende todo el procesos de análisis de datos y puede dar una visión extremo a extremo. Se comunica con la parte de negocio, es capaz coordinar la recolección y análisis de datos, e incluso diseñar las visualizaciones. Si el equipo es reducido, es preferible tener uno o varios perfiles de este tipo, ya que pueden cubrir a otro tipo de perfiles.
- ◆ **Analista de datos** o Data Analyst. Se encarga de actividades como transformación y manipulación de datos, así como la visualización. A veces cumplen otros roles como la analítica web o el análisis de test A/B.
- ◆ **Ingeniero de datos** o Data Engineer. Los ingenieros de datos diseñan y mantienen los ecosistemas que soportan los procesos de ciencia de datos. También desarrolla, construyen y administran los pipelines de datos. Se aseguran de que los datos estén disponibles para su análisis y procesamiento, y que el resto de perfiles puedan ejecutar sus procesos y algoritmos de forma estable y optimizada.
- ◆ **Arquitecto de datos** o Data Architect. Realizan funciones parecidas a los ingenieros de datos. Adicionalmente, se encargan de diseñar y desarrollar nuevos sistemas de bases de datos que se adapten a ciertas necesidades del negocio, en donde se produzca una integración sencilla, centralizada y segura, conservando los requisitos de seguridad del resto del sistema. Mantienen registro de quién accede a los datos y manipula cada parte de los mismos.
- ◆ **Narrador de datos** o Data Storyteller. Se dedica a explicar, a partir de las visualizaciones de datos generadas, la narrativa que mejor representa a los datos de forma que se encuentre una explicación en lenguaje claro que entiendan los perfiles menos técnicos.
- ◆ **Científico/Ingeniero de aprendizaje-máquina** o Machine Learning Scientist/Engineer. Un perfil similar a los anteriormente definidos, pero especializado en aprendizaje-máquina.
- ◆ **Desarrollador de procesos de BI**, inteligencia de negocio o *Business Intelligence Developer*. Planifican e implementan métodos que permiten a los usuarios del negocio localizar de forma eficiente y rápida la información para la toma de decisiones. Están familiarizados con las herramientas de BI o crean nuevas herramientas ellos mismos para ayudar con esta labor.
- ◆ **Administrador de bases de datos**. Es un perfil técnico que entiende de los diferentes motores de bases de datos, cómo configurarlos para que funcionen de forma más óptima con los procesos analíticos, realizan la optimización de los procesos de extracción de datos, etc. Es un perfil fundamental en la ciencia de datos, puesto que tanto orígenes como destinos del proceso de integración que hace las descargas de datos suelen ser bases de datos operacionales.
- ◆ **Especialista de procesamiento de lenguaje natural** o NLP Specialist. Es un perfil especialista que se encarga de analizar textos en lenguaje natural, en diferentes idiomas, para luego extraer información de utilidad analítica.
- ◆ **Estadístico**. Es un perfil matemático que entiende de la teoría estadística, y puede generar nuevos métodos que la parte más técnica del equipo puede aplicar sobre los datos.
- ◆ **Desarrollador/Programador** especializado en **lenguajes de ciencia de datos**. Algunos procesos de transformación, de análisis o de visualización de los datos requieren conocimiento específico de lenguajes de programación, uso de las metodologías adecuadas para crear los programas correspondientes y que se pruebe el funcionamiento adecuado de los mismos. Los lenguajes de programación son variados y se indican en el apartado 4 de este documento.
- ◆ **Jefe de proyecto de ciencia de datos** o Data and Analytics Manager. Es un perfil de dirección de proyectos que ha tenido experiencia previa en proyectos de ciencia de datos. Aunque podría encajar un jefe de proyectos con experiencia más generalista, la ciencia de datos tiene cierta

problemática particular que aconseja buscar un jefe de proyecto con experiencia más específica.

1.3 Órganos y organismos. Normativa relevante.

1.3.1 Agencia Española de Supervisión de la Inteligencia Artificial (AESIA)

La AESIA se crea con la necesidad de avanzar en los objetivos de transformación digital fijados por la Agenda Digital 2026, entre cuyos planes estratégicos se encuentra la Estrategia Nacional de Inteligencia Artificial (ENIA), con el objetivo de proporcionar un marco de referencia para el desarrollo de una IA “inclusiva, sostenible y centrada en la ciudadanía”. Además, esta Estrategia es una de las medidas del Componente 16, Reforma 1 del Plan de Recuperación, Transformación y Resiliencia (PRTR), que pretende situar a España como país puntero de la IA. La AESIA se adscribe al Ministerio de Asuntos Económicos y Transformación Digital a través de la Secretaría de Estado de Digitalización e Inteligencia Artificial (SEDIA). España, con la creación de este órgano, es uno de los primeros países de la UE en disponer de una Agencia encargada de estos temas, y además se anticipa a la entrada en vigor del Reglamento Europeo de Inteligencia Artificial.

1.3.2 Gobierno del dato y calidad del dato

Se puede definir el gobierno del dato como aquel conjunto de políticas y procedimientos que hacen que la gestión de los datos se haga de una forma efectiva y proactiva. La normalización se define en función de una serie de principios:

1. Gobernanza
2. Gestión
3. Calidad
4. Seguridad y Privacidad

Para alcanzar estos principios las organizaciones han de implementar un marco de gobierno, que emplea una serie de normas técnicas, de forma que estos principios esenciales hagan que los datos de las organizaciones estén correctamente gestionados y gobernados.

La web datos.gob.es publicó una infografía sobre las normas UNE necesarias para un correcto Gobierno del dato:

- ◆ Gestión de la calidad de los datos. A través de normas como la ISO 8000 (marcos para mejorar la calidad de los datos) o la ISO/IEC 25012 (modelo general de calidad para datos estructurados).
- ◆ Medición de la calidad. ISO 25024 (SQuaRE).
- ◆ Gobierno del dato. ISO 38505 (mapa de gobierno de datos y mapa de responsabilidades).
- ◆ Normas transversales para la Seguridad y Privacidad de los datos. Seguridad: ISO 27000. Privacidad y protección de datos: ISO 27701, 29100, 29134 y 20889. Seguridad y privacidad por defecto: PNE-prEN 17529, ISO/DIS 31700.

Además, se han de considerar las siguientes ISO:

- UNE 0077:2023 Gobierno del dato
- UNE 0078:2023 Gestión del dato
- UNE 0079:2023 Gestión de la calidad del dato




Figura 2: Normas UNE para un correcto Gobierno del Dato (datos.gob.es)


1.3.3 Normas ISO 8000

Se trata de un conjunto de normas que definen un marco para la mejora de la calidad de los datos, para tipos específicos de datos. Estos marcos pueden utilizarse de forma independiente o junto con otros sistemas de calidad como EFQM. Considera varios tipos específicos de datos:

- ◆ Datos maestros
- ◆ Datos de transacciones
- ◆ Datos de productos

Está compuesta por 4 partes principales:

1. Conceptos generales sobre calidad de datos (partes 1, 2 y 8).
 - ➔ Introducción al estándar, principios de calidad de los datos, conceptos fundamentales y vocabulario de calidad de los datos.
2. Procesos de gestión de calidad de datos (partes 6x).
 - ➔ Define un modelo de gestión de calidad de datos, mediante un modelo de referencia de procesos y otro de evaluación de la madurez de la organización.
3. Aspectos de intercambio de datos maestros entre organizaciones, atendiendo a ciertos aspectos de calidad (partes 100 a 150, o 1x0).
 - ➔ Trata el intercambio de datos maestros, que son listas de datos compartidas entre las aplicaciones del ecosistema de la organización. Ejemplos de datos maestros son las tablas maestras de clientes, las de artículos o cuentas.
4. Información de ingeniería (parte 311).
 - ➔ Es una guía para aplicación de calidad de datos del producto para PDQ-S. Se describe asimismo en la norma ISO 10.303-59.



DM - Data Managment

DQM - Data Quality Management

DG - Data Government

Figura 3: Diferencia entre Gestión de los datos, Gestión de la calidad de los datos y el Gobierno de los datos (Fuente: Revista AENOR)

1.3.4 ISO 38505

La primera parte (ISO 38505-1) trata de la aplicación de la norma ISO 38500 (estándar internacional para el Gobierno de TI) al gobierno de los datos y la segunda (ISO 38505-2) de las implicaciones de la aplicación de la primera parte para la gestión de los datos. La norma enuncia los principios rectores para que los miembros de los órganos de gobierno de las organizaciones hagan un uso efectivo, eficiente y aceptable de los datos dentro de sus organizaciones.

1.3.5 Normativa y órganos estatales

En cuanto a normativa estatal que afecta a la ciencia de datos, podemos destacar las siguientes normas:

- ◆ **Ley Orgánica 3/2018**, de Protección de datos personales y Garantía de los derechos digitales, en lo que respecta al tratamiento de los datos personales contenidos en los almacenes de datos.
- ◆ **Eje estratégico 4 de España Digital 2026**: Economía del dato e Inteligencia Artificial. Mediante este objetivo se está impulsando la economía del dato², garantizando al mismo tiempo una adecuada seguridad y privacidad de los datos tratados por las administraciones. Además, aprovecha las oportunidades de la IA con el objetivo de que el 25 % de las empresas la usen, junto con otros procesos de Big Data, en un período de 5 años (2021 – 2026).

Oficina del Dato. En el Eje estratégico 3 de la ENIA (Estrategia Nacional de Inteligencia Artificial), para potenciar el uso de las plataformas de datos públicos y hacer una correcta gestión dentro del ámbito público, se impulsa la creación de la Oficina del Dato y la definición del DCO.

Una figura en la administración central destacada es el **DCO** (Data Chief Officer) de la AGE, que se podría traducir como Director/a de datos de la AGE. Es una figura que aparece en 2021 por primera vez, que entre otras atribuciones tiene la encomienda de poner en marcha la Oficina del Dato, dependiente de la **SEDIA** (Secretaría de Estado de Digitalización e Inteligencia Artificial).

1.3.6 Normativa y órganos europeos

A nivel europeo se está desarrollando la **Década Digital de Europa**. Como parte la brújula digital que ha de marcar el rumbo de la normativa e instituciones europeas en la próxima década (metas digitales para 2030), uno de los puntos cardinales es el de “Infraestructuras digitales seguras y sostenibles”. En este apartado se pretende impulsar la economía de los datos, la computación en el borde y los diferentes tipos de nubes.

Estrategia Europea para los Datos se centra en poner a las personas en primer lugar en el desarrollo de la tecnología y en la defensa y promoción de los valores y derechos europeos en el mundo digital. De esta forma se creará un mercado único de datos que garantice la competitividad mundial y la soberanía de los datos de Europa.

La **Ley de Datos** o “**Data-Act**” fue adoptada por la Comisión el 23 de febrero de 2022, es una parte crucial de la estrategia europea para los datos, cuyo objetivo es garantizar un acceso justo y un uso de los datos de acuerdo con las normas y valores de la UE. Complementa el Reglamento sobre gobernanza de datos (**Reglamento (UE) 2022/868**), que se centra en la creación de datos y de valor. La Ley tiene como objetivo garantizar la coherencia entre los derechos de acceso a los datos, que a menudo se desarrollan para situaciones específicas y con diferentes reglas y condiciones. Las normas existentes deben evaluarse y alinearse con la Ley de Datos.

Iniciativa **Gaia-X**. Es una propuesta para la próxima generación, en donde se quiere fomentar la creación de una infraestructura común de datos para todos los países de Europa, mediante un sistema seguro y federado que cumpla los más altos estándares de soberanía digital, al tiempo que se promueve la innovación. Se ha creado el *hub* de Gaia-X España, que apoyará el proyecto europeo.

En protección de datos personales, se reguló el **Reglamento (UE) 679/2016**, General de Protección de Datos (**RGPD**), cuyos objetivos son la protección de los datos personales de las personas al ser tratados por el sector privado y público, la mejora en el control de los datos personales, creación un sistema de autoridades de control independiente que vele y supervise el cumplimiento de la normativa,

² «Conjunto de iniciativas, actividades y/o proyectos cuyo modelo de negocio se basa en la exploración y explotación de las estructuras de bases de datos existentes (tradicionales y procedentes de nuevas fuentes) para identificar oportunidades de generación de productos y servicios». [OR12]

y además forma parte de la reforma de protección de datos de la UE, junto con la **Directiva (UE) 2016/680**, sobre protección de datos personales en el ámbito penal para prevención, investigación, detección o enjuiciamiento de infracciones penales o de ejecución de sanciones penales, y libre circulación de dichos datos, transpuesta en la **Ley Orgánica 7/2021**; y el **Reglamento (UE) 2018/1725**, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales por las instituciones, órganos y organismos de la UE.

1.4 Metodologías y gobierno del dato

A continuación, se describen brevemente algunas de las principales metodologías para el gobierno del dato. Se puede ampliar más información en el tema correspondiente del temario.




Figura 4: DAMA International Model.

- ◆ **DAMA** (DAta Management Association). La definición oficial suministrada por DAMA del proceso de gobierno o gestión de los datos es «[...] el desarrollo y ejecución de arquitecturas, políticas, prácticas y procedimientos que gestionan apropiadamente las necesidades del ciclo de vida completo de los datos de una empresa». Define los siguientes procesos:
 - ➔ Arquitectura de datos: define la estructura de los activos de datos lógicos y físicos y los procesos de gestión de datos de una organización a lo largo del ciclo de vida de los datos.
 - ➔ Modelado y diseño de datos: el proceso de descubrir, analizar, representar y comunicar requisitos de datos en forma de modelo de datos.
 - ➔ Almacenamiento y operación de datos: el proceso de diseño, implementación y soporte del almacenamiento de datos.
 - ➔ Seguridad de los datos: garantizar que se acceda a los datos y se utilicen correctamente manteniendo la privacidad y la confidencialidad de los datos.
 - ➔ Integración e interoperabilidad de datos: el proceso de diseño e implementación del movimiento y consolidación de datos entre fuentes de datos y los destinos finales.
 - ➔ Gestión de documentos y contenidos: el proceso de gestión de datos almacenados en medios no estructurados.
 - ➔ Datos maestros y de referencia: el proceso de mantener los datos compartidos críticos centrales dentro de la organización.

- ➔ Almacenamiento de datos e inteligencia empresarial: el proceso de planificación, implementación y control de los procesos para gestionar los datos que respaldan las decisiones.
- ➔ Metadatos: Administración de datos que describen otros datos. Implica establecer políticas y procesos que garanticen que la información se pueda integrar, acceder, compartir, vincular, analizar y mantener para proteger la privacidad de la información y optimizar a su vez los procesos de la misma.
- ➔ Calidad de los datos: el proceso de garantizar que los datos sean aptos para su uso.




Figura 5: Modelo DCAM v2.2.

- ◆ **DCAM** (Data Management Capability Assessment Model). DCAM define cómo establecer la estrategia de datos, cómo posicionarse para el caso de negocio concreto e implementar la estrategia operativa. Modelo, garantizar la financiación y apoyar la colaboración organizativa necesaria para regir el significado, uso y protección de uno de los activos más importantes de una empresa, como son los datos.
- ◆ **TOGAF**. Es un esquema de la arquitectura empresarial completa, donde se hace foco en el diseño, planificación, implementación y gobierno de la arquitectura. Dentro de esta definición se contempla la arquitectura de los datos, donde se describe los elementos lógicos y físicos que soportan las estructuras de datos, junto con los recursos para gestionarlos. En este aspecto, este esquema contribuye al gobierno del dato, pero no se especializa en conseguirlo.




Figura 6: Modelo Alarcos de Mejora de Datos (MAMD)³.

- ◆ **Modelo MAMD.** El Modelo Alarcos de Mejora de Datos (MAMD) «integra los procesos de gestión de datos, de gestión de calidad de datos y de gobierno de datos, de manera conjunta y coordinada, y permite evaluar y mejorar la capacidad de los procesos de la organización relacionados con la gestión, el gobierno y la calidad de los datos. Este modelo ha sido desarrollado por un grupo de expertos en gobierno y gestión de datos, coordinado por el grupo Alarcos de la Universidad de Castilla-La Mancha en colaboración con las empresas DQTeam y AQCLab. Está compuesto por un total de 20 procesos, y éstos a su vez están agrupados en 5 niveles de madurez» (ver referencias al final del documento).

1.5 Temas relacionados

Otros temas relacionados con la ciencia de datos dentro del temario de la oposición del Cuerpo Superior de Sistemas y Tecnologías de la Información de la A.E. son los siguientes:

- ◆ Tema 70: Inteligencia artificial: Finalidad y clasificación: machine learning, deep learning, NLP, visión artificial, sistemas expertos, robótica, y agentes inteligentes. Aspectos éticos.
- ◆ Tema 75: Tecnologías y sistemas de explotación de datos: data lake, data warehouse, lakehouse, data fabric, data mesh, tecnologías para la protección de la confidencialidad (PET). Entornos de compartición de datos: espacios de datos, aspectos tecnológicos y organizativos.
- ◆ Tema 76: Estrategia del dato. Gobierno del dato, gestión del dato y gestión de la calidad del dato. Tecnologías y estándares para descripción de catálogos y conjuntos de datos: semánticas y ontologías.

³ Imagen disponible en la web <https://dqteam.es/mamd/>.

2 Ciclo de vida de los procesos de modelado de datos

2.1 Descripción del ciclo de vida del dato

Se puede definir como ciclo de vida del dato (*Data Lifecycle Management* o DLM en inglés) como las diferentes etapas por las que viaja un dato desde su forma más primitiva (el dato en sí) hasta que se genera finalmente la acumulación de conocimientos en forma de sabiduría que pueda ser útil para la toma de decisiones, pasando por la generación de información. Este enfoque se conoce como jerarquía D-I-K-W (del inglés: Data – Information – Knowledge – Wisdom). Esta teoría fue formulada por Jennifer Rowley en 2007 y que pretendía encontrar un consenso entre las diferentes definiciones y procesos de transformación de los datos, para discriminar dichos conceptos entre sí. En otras formulaciones, debajo de los datos se considera un concepto más fundamental, como es la propia medida del dato (mediante sensores del Internet de las cosas / IoT).



Figura 7: Jerarquía D-I-K-W / D-I-C-S

Desde un punto de vista más moderno y práctico, se suele considerar como parte del ciclo de vida del dato las siguientes fases:

1. **Planificar.** Establecer una hoja de ruta para una mejor gestión de los datos, analizando las diferentes metodologías y herramientas disponibles. Se determina a su vez qué información hay que recopilar, de qué manera se va a recopilar y los objetivos que se pretenden conseguir. En esta fase hay que tener en cuenta todos los factores que influyen, tanto en complejidad como los riesgos detectados, y asesorará a la Dirección sobre la decisión que habría que adoptar: seguir adelante con el proyecto actual, reducir el alcance del mismo para poder conseguir los objetivos, o bien abandonar el proyecto por ser inviable.
2. **Creación y captura.** Consiste en diseñar e implementar los procesos para recopilar los datos relevantes para el negocio. Pueden ser datos que ya existan previamente, porque hayan sido creado por actores externos a nuestro sistema; datos creados por personal de negocio de nuestra organización o dispositivos medidores dentro de la organización; o bien datos recopilados mediante dispositivos de la Internet de las cosas (IoT).
3. **Transmisión, almacenamiento y seguridad.** Los datos deben viajar desde sus orígenes hasta los almacenes de datos donde se procesan, de una forma segura. Además, dependiendo de la naturaleza de los datos, puede ser necesario implementar medidas de seguridad para protegerlos una vez recopilados y almacenados. Hay que tener en cuenta que el crecimiento de los datos recopilados puede ser grande, y habrá que tener un plan de gestión de la capacidad de los sistemas que contemple dicho crecimiento. A nivel de seguridad, puede ser necesario el cifrado y/o la ofuscación de los datos, para hacerlos inservibles en caso de un ataque que comprometa dichos datos.
4. **Gestión y trabajo colaborativo.**

- Hay que proporcionar los medios de acceso seguro a los datos, mediante métodos de autenticación adecuados y una gestión adecuada de las altas y las bajas. Es necesario involucrar a la parte de negocio para que este requisito de seguridad y control de acceso se traduzca a nivel de la aplicación desarrollada. Además, es necesario proporcionar los métodos adecuados para poder interactuar correctamente con los datos y la información que se está generando: que se pueda mover de un sistema a otro (datos interoperables), realización de copias de seguridad con las políticas definidas por la organización, gestión de permisos de acceso, registro de la naturaleza de los datos y los tratamientos que se realizan sobre los mismos (Reglamento General de Protección de Datos y Ley Orgánica 3/2018), etc.
 - En cuanto a la colaboración, se implementa mediante estrategias como DevSecOps o la más específica para ciencia de datos MLops. Esto supone llevar un control de versiones de los modelos de datos, de los procesos de transformación de datos y demás procesos asociados, en un repositorio centralizado al que puedan acceder todos los equipos de la organización y externos a la misma. El objetivo final es implementar los *pipelines* y los procedimientos a seguir por los diferentes equipos que permitan un despliegue e integración continua de los procesos analíticos.
5. **Análisis, explotación de los datos y visualización**, proporcionando valor al negocio. Esta última fase es la más importante, puesto que en ella se va a conseguir aportar valor al negocio o no. Los datos recabados en las fases anteriores, han de ser refinados mediante diferentes procesos (IA, redes neuronales, procesos BI, etc) que los transformarán en conocimiento útil para la toma de decisiones. El sistema debe de ser capaz de tratar esta ingente cantidad de datos, para generar los informes, las visualizaciones o cualquier otro resultado interpretable.
 6. **Publicación**. En el caso de que el conocimiento que se genere tenga el objetivo de publicarse como datos abiertos, este procesamiento puede tener como resultado la generación de archivos o APIs para consulta externa por parte de los actores interesados (ciudadanos, empresas, otras administraciones, etc). Previamente a la publicación puede ser conveniente un proceso que añada privacidad a los datos, mediante seudonimización o anonimización, modificando los datos mediante métodos de k-anonimidad, generando datos sintéticos que conserven las propiedades estadísticas de los datos originales, o mediante privacidad diferencial.
 7. **Archivo y destrucción**. Debido al crecimiento en los almacenes de datos, puede ser necesario acordar una política de borrado de datos no necesarios, de forma periódica. En el caso de que no puedan ser eliminados, se definirá una política de archivado en medios más económicos (archivado en nube o a cinta de disco), de forma que si se necesitan recuperar en un futuro sea viable.

2.2 Procesos de integración de datos

El conjunto de tareas que se realizan para integrar los datos desde los orígenes hasta los almacenes de datos define el proceso de integración. De esta forma se logra que todos los datos de los que dispone un organismo estén accesibles y se haga la entrega de estos a los almacenes de datos, de una manera coherente. Todos los departamentos que forman parte de una organización producen y recopilan gran cantidad de datos, por lo que los volúmenes, estructura y frecuencia de actualización puede tener una gran variabilidad.

Se utilizan varias estrategias para conseguirlo:

- ◆ Sincronización mediante **procesos de ETL/ELT**. Se puede realizar a través del lanzamiento de **procesos batch** (deberá existir un programador de tareas que permita lanzar las cargas), de forma periódica (habitualmente 1 vez al día), o bien mediante descargas incrementales cada cierto tiempo (menos de 1 hora).
- ◆ **Sincronización mediante streaming**, de forma continua. A la vez que se producen los cambios en los orígenes, se generan mensajes con la información que ha cambiado, que se encolan en un bus de mensajes, para su consolidación posterior en los sistemas intermedios.

Se dispone de esta forma de una imagen del sistema de origen junto con los cambios que ha ido experimentando. Se utilizan técnicas como *Change Data Capture* (CDC), que extraen la información de los cambios desde los ficheros de *logs* transaccionales de las bases de datos, de forma que se reduce la afectación del servicio.

- ◆ **Replicación de datos.** Mediante herramientas de los fabricantes de los motores de bases de datos y productos de terceros, se puede llegar a realizar una propagación de los datos operacionales hacia los almacenes de datos o sistemas intermedios. Además, algunos de estos productos son compatibles con diversas fuentes de datos diferentes, lo que permite la integración de fuentes heterogéneas. La sincronización se puede hacer a intervalos regulares o bien en tiempo casi real.
- ◆ **Integración de información empresarial o Enterprise Information Integration (EII).** Consiste en reunir los datos de diferentes fuentes, tanto internas como externas. Luego se transforman para proporcionar una vista más unificada. De esta manera se ayuda a las organizaciones a obtener una visualización de sus capacidades para ejecutar todo tipo de procesos: consultas sencillas a las bases de datos del negocio, hasta realizar estadísticas predictivas complejas. Se hace el foco en la escalabilidad para conseguir el procesamiento de toda la información.

2.2.1 Procesos ETL/ELT

Los procesos ETL/ELT son procesos de descarga de datos, desde un origen de datos a un destino. Se utilizan para alimentar los almacenes de datos con información actualizada, aunque también tienen otros usos como mover información a otra aplicación de forma permanente, durante un proceso de migración de una aplicación a motores de base de datos actualizados o diferentes al original.

Este proceso de integración de datos por ETL/ELT se suele ofrecer mediante lanzamiento periódico de **procesos batch**, que son *scripts* planificados que se ejecutan en secuencia o en paralelo. Hay que tener en cuenta que intervendrá en la arquitectura otro componente que son los **planificadores de trabajo**, que son los encargados de supervisar que las cargas se lancen. Si fallan las cargas también se encargan de gestionar los posibles relanzamientos. Las principales nubes públicas tienen módulos encargados de gestionar estas planificaciones.

La **Fase "E"** o de Extracción / *Extract* consiste en conectarse a los orígenes de datos, mediante drivers de conexión, y leer la información de interés para cada volcado particular. La consulta que realizan estos procesos de integración de datos se puede realizar contra diferentes recursos:

- ◆ **Ficheros** estructurados (CSV, XML, XLS, etc) o no estructurados (PDF, imágenes, vídeos, audio, etc).
- ◆ **Bases de datos** relacionales y no relacionales.
- ◆ **APIs** ofrecidas para consumo de datos desde el proceso de integración.
- ◆ Información ofrecida por otros sistemas de información. Entre otros métodos, tenemos:
 - ➔ **Web scraping:** Extrae información de sitios web mediante programas que simulan la navegación, utilizando los protocolos propios de la web.
 - ➔ **RPA (Robotic Process Automation):** Mediante estos procesos también es posible extraer información de S.I. que no ofrecen una interfaz programática estándar.

En los procesos ELT/ETL, una vez extraída la información de los orígenes de datos se pueden producir transformación de estos mediante alguno de los procesos siguientes (**Fase "T"** de Transformación / *Transform*):

- ◆ **Limpieza de los datos** o Data cleaning. Se corrigen, borran o actualizan los registros que se detecta que contienen información incorrecta o que ha llegado con errores.

- ◆ **Agregado de los datos** o Aggregate data. Se genera un agregado de un conjunto de datos para como un resumen del conjunto total. Es típico por ejemplo la suma de los valores de una columna.
- ◆ **Cambio de formato:** Para adaptarlo a un formato más adecuado al análisis.
 - ➔ **Estandarización:** Transformar los datos para que tengan unas características estadísticas concretas. Por ejemplo, cambiarlos para que la media sea 0 y la varianza 1.
 - ➔ **Normalización:** Cambio de escala de los datos para adaptarlos a un rango determinado.
 - ➔ **Discretización:** Dividir un continuo de valores en categorías o intervalos discretos. Es necesario cuando se tiene que trabajar con categorías de datos. Técnicas empleadas: agrupación de intervalos de anchura equivalente, agrupación de igual frecuencia y agrupación en clústeres.
- ◆ **Precálculo** o Pre-computation: Calcular un valor nuevo en función de una fórmula matemática, para transformar el dato en bruto en una medida del negocio. Por ejemplo, el cálculo de una razón de dos números o de una tendencia.
- ◆ **Reducción:** Consiste en reducir el tamaño de los conjuntos de datos, preservando las características esenciales de la información. Se consigue con técnicas como:
 - ➔ **Selección de características:** Es un proceso que implica eliminar características irrelevantes o redundantes de un conjunto de datos mediante técnicas como el análisis de correlación, la información mutua y el análisis de componentes principales (PCA).
 - ➔ **Extracción de características:** Es un método utilizado para transformar datos complejos de muchas dimensiones en un espacio de menor dimensión, preservando información importante utilizando técnicas como PCA, LDA y NMF.
 - ➔ **Muestreo:** Seleccionar un subconjunto de muestras de un conjunto de datos más extenso, de forma que sean representativas. Técnicas: muestreo aleatorio, muestreo estratificado, y muestreo sistemático.
 - ➔ **Clusterizado:** Se agrupan puntos de datos similares en clústeres. La agrupación en clústeres se utiliza a menudo para reducir el tamaño del conjunto de datos mediante la sustitución de puntos de datos similares con un centroide representativo. Se puede hacer usando técnicas como k-medias, agrupamiento jerárquico y agrupamiento basado en densidad.
 - ➔ **Compresión:** Reducir por compresión el tamaño de los datos, sin perder sus características. Se hace para reducir el tamaño que ocupa el conjunto de datos y para que se puedan transmitir de forma más rápida. Técnicas: compresión wavelet, compresión JPEG, compresión GZIP.

Por último, en la **Fase "L"** o de Carga / *Load*, se vuelca esta información en los sistemas destino, normalmente almacenes de datos, para que esté disponible para el análisis y procesado posterior. Se utilizan *drivers* similares a la fase de extracción, siendo la variedad de dichos *drivers* una característica deseable en los productos que se seleccionen en la fase de Planificación del proyecto.

En esta fase se realiza una carga de datos en un almacén de datos. En esta carga se puede:

- ◆ Sobrescribir la información existente con datos más recientes (**carga total o completa**). Tiene una duración mayor, pero hay una seguridad de que todos los datos se han traspasado.
- ◆ Actualizar los datos extraídos diaria, semanal o mensualmente, o agregar nuevos datos en forma histórica a intervalos regulares (**cargas incrementales**). La descarga dura menos, pero hay que configurarla adecuadamente para que no haya una pérdida de datos o inconsistencias.

El momento y alcance al reemplazar o agregar datos son opciones de diseño estratégico basadas en el tiempo disponible para las descargas de datos (**ventanas de descarga**) y las necesidades comerciales o de negocio. Las ETLs por lo tanto pueden consolidar elementos de datos de varios departamentos o servicios en una presentación uniforme.

2.2.2 Sincronización mediante streaming

Los datos de *streaming* se generan continuamente en el mundo, desde innumerables de fuentes de datos. Estas fuentes incluyen: archivos de registro/*log*, registros de compras de comercio electrónico e información de servicios geoespaciales (Google Maps), etc. En el momento de la generación del dato, con este tipo de sincronización se envía el mismo a un sistema de procesamiento de mensajes (cola de mensajes, bus de mensajes) que lo envía de forma asíncrona al destino cuando está disponible. Los datos se procesan de forma secuencial e incremental para análisis con correlaciones, agregaciones, filtrado y muestreo. Debido a la tasa de actualización tan frecuente, se aporta valor al negocio mediante la visibilidad a los servicios que se ofrecen en tiempo real, y permite responder de una forma más ágil ante situaciones excepcionales. Un ejemplo es la monitorización de redes sociales utilizando “análisis de sentimiento” para toma de decisiones.

Beneficios:

- ◆ Si se generan datos de forma continua y dinámica, los procesos de sincronización por streaming son más ligeros y afectan menos a los sistemas operacionales que las descargas ETL/ELT.
- ◆ Se suele partir de un enfoque basado en descargas totales o incrementales, y se va evolucionando hacia la sincronización mediante streaming.

2.3 Preprocesado de datos

El preprocesado de datos tiene como propósito preparar los datos recopilados en las fases previas de cara a su análisis posterior, de forma que se mejore la calidad la información recopilada y se adapte a los objetivos fijados para cada proyecto concreto. Por mencionar un caso concreto, los métodos de recopilación de mediciones de sensores físicos funcionan según un margen de error y no están exentos de posibles fallos, pudiendo adolecer de ciertos problemas como puede ser valores fuera de rango, pérdida de mediciones intermedias o datos no consistentes o imposibles, entre otros.

Hay que tener en cuenta la información que se conoce sobre el dominio de las variables que se han medido. Por ejemplo, en una variable en la que se refleja el país se deberá comprobar que sea uno existente, o si es una temperatura medida en la superficie terrestre que esté dentro del rango de temperaturas habituales que se miden en las series históricas.

Dejando fuera las fases de captura y descubrimiento de los datos, el preprocesado consiste en la realización de algunos pasos previos, entre los que pueden incluir los siguientes:

- ◆ **Limpieza de los datos.** Los datos recopilados pueden contener muchas partes irrelevantes o que simplemente se han perdido, pueden contener datos con ruido, etc. Frente a los datos que se han perdido, se pueden rellenar con valores calculados (mediante interpolación por ejemplo), o bien ignorar los valores perdidos (si el resto de valores recopilados representa bien el fenómeno bajo estudio).

En cuanto al ruido aditivo, se puede tratar de diferentes formas: métodos del agrupamiento (*binning*) que lo suavizará tratándolo por segmentos de igual tamaño, métodos de regresión (ajustando a una función de regresión que puede ser lineal con una variable independiente o múltiple con varias variables) o métodos de *clustering* (agrupar los datos en clústeres, de forma que los valores atípicos caen fuera de los grupos y no se consideran).

- ➔ Es el proceso que consiste en evitar la introducción de datos incorrectos en un almacén de datos. Es decir, los valores especificados en los objetos cumplen las restricciones dentro de un dominio de valores.

En términos matemáticos, el valor pertenecería al dominio (el número que se registra pertenece al conjunto de los números Naturales). Para conseguir este objetivo se realizan

procesos de verificación de formatos dentro de las celdas, y permite proporcionar instrucciones previas a los analistas para que sepan cuál es la mejor forma de introducir o transformar la información.

Es siempre recomendable validar los datos antes de enviar las actualizaciones a la base de datos subyacente. [OR14].

- ➔ Validación del dominio de valores de los datos. Se puede hacer de varias formas:
- Que lo realice la propia aplicación antes de insertar los datos. Se puede hacer una comprobación de los valores de las filas o columnas de datos, de forma que previamente a insertarlos la aplicación genere un error si no son correctos. Puede ocurrir:
 - ✗ En la inserción por columnas.
 - ✗ Durante el cambio de una fila completa de datos.
 - Mediante restricciones establecidas en el modelo de datos. Algunas funcionalidades de los motores de base de datos permiten lanzar excepciones si se insertan valores que no cumplen ciertas propiedades. Estas funcionalidades son por ejemplo creación de claves, restricciones a nivel de disparadores, etc.
 - Restricciones en los objetos con los que trabaja la aplicación, tanto si son clases como si se trata de estructuras en lenguajes no orientados a objetos.

- ◆ **Transformación de datos.** Transforma los datos de forma adecuada mediante técnicas como la normalización (para que los valores “caigan” dentro de un rango especificado, por ejemplo 0,0-1,0), selección de atributos (no seleccionar todos los atributos que se han registrado, sino un subconjunto de ellos que maximice la utilidad para la que se han recopilado los datos), discretización (transformar un conjunto de valores numéricos con más precisión en intervalos o niveles conceptuales, o dicho de otra manera, transformar los valores del mundo real en valores discretos con una cierta precisión) o mediante jerarquías de conceptos (agrupar varias categorías de nivel inferior en una supercategoría que las abarque a todas, por ejemplo agrupar municipio, provincia e isla dentro de la supercategoría “Entidad local”).
- ◆ **Reducción de datos.** Consiste en reducir el tamaño del conjunto de datos de forma que se preserven las características esenciales del mismo para un correcto análisis. Se hace de cara a mejorar en el procesamiento de los datos y evitar un sobreajuste del modelo. Utilizamos técnicas como la selección de características (mediante análisis de componentes principales o PCA, análisis de correlación o de información semejante), extracción de características (transformando los datos en un espacio de menores dimensiones cuando los datos originales son complejos y están definidos en muchas dimensiones), muestreo (selección de los puntos más significativos del conjunto de datos), etc.
- ◆ **Enriquecimiento de los datos.** En esta fase de preprocesado también se puede agregar desde fuentes adicionales información o datos que faciliten la fase posterior de análisis. Por ejemplo, si se recopila en el conjunto de datos principal el “login” de un usuario, se puede complementar con información adicional como nombre completo o género.

2.4 Modelado

El concepto de modelo en ciencia de datos proviene de otro concepto anterior que es el modelo matemático de un objeto o fenómeno del mundo real. Es un esquema simplificado e idealizado, constituido por símbolos y operaciones matemáticas, que intenta reflejar el comportamiento del objeto o fenómeno. En el caso de la ciencia de datos, mediante el modelado de los datos se intenta representar de forma abstracta la información en la organización, de forma que los datos se relacionen unos con

otros, se puedan realizar análisis sobre los mismos y su representación ayude a generar el conocimiento necesario para cumplir las metas y objetivos fijados.

Existen varios tipos de análisis sobre los datos:

- ◆ **Análisis descriptivo (¿Qué sucedió?).** Consiste en describir un conjunto de datos definiendo los parámetros que les son característicos. De esta forma se ve qué características define a cada dato. Se puede conocer detalladamente la información y estructura de los datos, puesto que se limita a realizar deducciones con la información disponible.
- ◆ **Análisis predictivo (¿Qué es probable que suceda en el futuro?).** Identifica las relaciones existentes entre las variables y los eventos pasados, para explorarlas y predecir su comportamiento futuro. Un ejemplo de este análisis es la predicción de beneficios empresariales, situación de los incendios en función de las condiciones meteorológicas, o la evolución del número de instancias registradas en un determinado procedimiento administrativo.
- ◆ **Análisis inferencial (¿Qué puedo inferir de esta muestra parcial?).** Se basa en demostrar una hipótesis, ofreciendo conclusiones con un nivel de confianza determinado. Permite realizar estudios sobre un conjunto de datos pequeños, e inferir las conclusiones sobre una población mayor. Ejemplos son las encuestas de intención de voto en las elecciones, los análisis de mercado o la epidemiología médica.
- ◆ **Análisis exploratorio o diagnóstico (¿Por qué sucedió?).** Pretende comprender la naturaleza de ciertos datos para detectar alguna característica concreta o anormal. Estudia la tendencia de indicadores y controla que se encuentren en los rangos definidos. Un ejemplo sería el estudio del nivel de vida en los diferentes barrios de una ciudad con respecto al nivel de inversión realizado por las administraciones en ese barrio.
- ◆ **Análisis casual (¿Qué lo causó o qué efecto provocó?).** Se estudian las causas y los efectos, y cómo se afectan unos a otros. Identifica las razones de las actuaciones o situaciones. Un ejemplo sería el aumento instancias en un determinado procedimiento administrativo pueda causar disminución de otros procedimientos.
- ◆ **Análisis prescriptivo (¿Cuál es el mejor curso de acción?).** La analítica prescriptiva tiene en cuenta específicamente la información sobre posibles situaciones o escenarios, recursos disponibles, rendimientos pasados y actuales, para sugerir una estrategia operativa a la organización. Un ejemplo podría ser el estudio de las líneas de investigación dentro de una Universidad abiertas, las que más financiación proporcionan a los departamentos y las posibles líneas de investigación que habría que potenciar en el futuro.
- ◆ **Análisis mecanicista.** Busca comprender cómo las fluctuaciones en los valores de ciertos datos afectan a las fluctuaciones de otros datos. Es el análisis más complejo.

2.4.1 Análisis descriptivo

El análisis descriptivo es una herramienta de ciencia de datos que utiliza los datos en bruto para proporcionar información sobre el rendimiento pasado de la organización. Ayuda a identificar fortalezas y debilidades, guiando a los procesos de decisión. Es una pieza importante en las herramientas de inteligencia empresarial.

Su utilización permite a las organizaciones entender si están funcionando bien o mal, y puede permitir identificar puntos de mejora. Hay dos métodos principales para recopilar los datos para este tipo de análisis:

- ◆ **Agregación de datos.**
- ◆ **Minería de datos.**

Los pasos para realizar un correcto análisis descriptivo son los siguientes:

- ◆ **Identificar** qué **métricas** se quiere analizar.

- ◆ **Identificar y localizar los datos** para el cálculo de esas métricas.
- ◆ **Recopilar** los datos.
- ◆ **Analizarlos.**

Las **ventajas** del análisis descriptivo son que proporciona una herramienta sencilla a los *stakeholders* para que entiendan ideas complejas y que permite a los directivos compararse con otras organizaciones similares.

Como **desventajas** se pueden mencionar que proporciona explicaciones para comportamientos pasados, pero no puede predecir comportamientos futuros; y que pueden desvirtuarse las conclusiones si se escogen las métricas más favorables a la organización.

2.4.2 Análisis predictivo

Modelos que implementan el análisis predictivo:

- ◆ **Modelo de clasificación.** Se utilizan técnicas de aprendizaje supervisado para predecir la probabilidad de que una determinada instancia pertenezca a una clase. Se utiliza a menudo para la detección del fraude.
- ◆ **Modelo de regresión.** Busca encontrar la relación entre una variable dependiente (X) con respecto a otras variables (una o varias), que se denominan independientes o explicativas (Y). Hay tres tipos básicos: regresión lineal simple (confirmado por dos variables estadísticas), regresión lineal múltiple (analiza la relación entre una variable dependiente con dos o más variables independientes) y regresión no lineal.
- ◆ **Modelo de pronóstico.** Permite predecir valores futuros basándose en valores pasados. Se utiliza para pronóstico financiero, pronóstico de ventas y previsión meteorológica.
- ◆ **Modelo de agrupación en clústeres.** Técnica de aprendizaje no supervisado. Agrupa las instancias en función de su similitud. Se utiliza para segmentación de mercado y de clientes, identificación de grupos de artículos similares.
- ◆ **Modelo de valores atípicos.** Identifica instancias inusuales o inesperadas. Sirve para detección de fraude, anomalías o eventos.
- ◆ **Modelo de series temporales.** La particularidad de este modelo es que las mediciones se hacen a lo largo del tiempo, y se almacenan en una serie temporal. Permite hacer predicciones en función de la evolución de un valor. Un ejemplo sería la evolución de la población activa o la tasa de paro en España.

Algunas **técnicas** para el análisis predictivo:

- ◆ **Análisis bayesiano.** Se hace uso del teorema de Bayes durante la inferencia. El objetivo final es inferir la probabilidad de que una hipótesis sea cierta. Se utiliza en teoría de la comunicación, para discriminar entre señal y ruido, en un canal ruidoso.
- ◆ **Redes neuronales.** Explicado anteriormente.
- ◆ **Árboles de decisión.** Modelo de predicción en el que dado un conjunto de datos, se elabora un diagrama de construcciones lógicas donde las transiciones están basadas en reglas. De esta forma, se representa y categorizan las condiciones por las que transita la lógica del problema, hasta alcanzar una resolución.
- ◆ **Bosques aleatorios o Random Forest (RF).** Combinación de árboles predictores, en el que cada árbol depende de los valores de un vector probado independientemente y con la misma distribución de probabilidad para cada uno. El primer algoritmo de bosques aleatorios de decisión lo creó Tim Kam Ho en 1995. Una extensión del algoritmo la propuso posteriormente Leo Breiman y Adele Cutler.
- ◆ **Gradient boosting.** Produce un modelo predictivo en forma de conjunto de modelos de predicción débiles, típicamente árboles de decisión.

La minería de datos también puede emplearse en la fase de recopilación de datos.

2.5 Validación

Cuando ya se ha definido el modelo predictivo en el punto anterior, se ha de comprobar si dicho modelo es válido y estima de forma conveniente con datos nuevos que no ha visto todavía el modelo. Se pueden evaluar los errores que se están cometiendo sobre un modelo funcional, pero no obstante este enfoque no es útil para entender cómo está aprendiendo el modelo y poder mejorarlo. Para conseguir estimaciones más acertadas se tienen que emplear conjuntos de datos de test o estrategias de validación basadas en *resampling*.

Antes de definir las diferentes estrategias de validación es necesario que definamos los siguientes conceptos:

- ◆ **Conjunto de entrenamiento.** Es el conjunto de datos con los que se entrena al modelo.
- ◆ **Conjunto de validación y conjunto de test.** Son un conjunto de datos que no se han empleado para entrenar al modelo.
- ◆ **Error de entrenamiento.** Error que arroja al modelo al predecir las observaciones que pertenecen al conjunto de entrenamiento.
- ◆ **Error de validación y error de test.** Error que comete el modelo al predecir las observaciones del conjunto de validación y del conjunto de test.

2.5.1 Algunas estrategias de validación

Se listan a continuación algunas de las estrategias de validación de modelos de ML que se pueden emplear.

- ◆ **Validación simple.** Es el método más sencillo, que consiste en repartir aleatoriamente las observaciones disponibles en dos grupos: uno que se utiliza para entrenar al modelo y otro para evaluarlo. Adolece de dos problemas:
 - ➔ Varía en función de la división que hagamos entre estos dos grupos (problema de varianza).
 - ➔ Como excluimos parte de los datos disponibles para el entrenamiento, se dispone de menos información en la práctica, lo que reduce la eficiencia del modelo. Se sobrestima el error comparado al que se obtendría empleando todas las observaciones (problema de sesgo / *bias*).
- ◆ **LOOCV – Leave One Cut Cross-Validation.** Es un método iterativo que se inicia utilizando todas las observaciones disponibles excepto una, que se emplea finalmente para la validación. Como sólo se emplea una observación para evaluar, depende mucho de cuál se elija puede variar el resultado. Para evitar esto, el modelo se repite de forma iterativa tantas veces como observaciones y en cada iteración se emplea una observación diferente para validar. El error final estimado es el promedio de todos los errores calculados en las iteraciones.
- ◆ **K-Fold Cross-Validation.** También es iterativo y consiste en dividir el conjunto total de observaciones disponibles en K-grupos de aproximadamente el mismo tamaño. K-1 grupos se utilizan para entrenar al modelo y el otro grupo para validación. El proceso se repite K veces utilizando de cada vez un grupo diferente y el promedio del error obtenido se emplea como estimación final. Tiene dos ventajas con respecto la estrategia LOOCV: requiere menos capacidad de cómputo, y consigue un mejor compromiso entre varianza y *bias*.
- ◆ **Repeated k-Fold-Cross-Validation.** Exactamente igual al anterior, pero repitiendo el proceso *n* veces.
- ◆ **Bootstrapping.** Es una estrategia de *resampling*, que consiste en generar una muestra a partir de muestreo aleatorio con reposición, del mismo tamaño que la muestra original.

Para elegir el método correcto hay que evaluar el tamaño muestral y el objetivo del análisis:

- ◆ Tamaño muestral pequeño: emplear el método k-Fold-Cross-Validation.
- ◆ Tamaño muestral muy grande: se reduce la diferencia entre los métodos y es más importante evaluar el coste computacional, por lo que se recomienda utilizar k-Fold-Cross-Validation, con un valor de $k < 10$.
- ◆ Si el objetivo principal del análisis que se realiza es comparar modelos más que obtener una estimación precisa: lo mejor es utilizar *bootstrapping* ya que se tiene menos varianza.

En cuanto a la **validación y evaluación de los modelos de regresión**, el concepto de validación es parecido, pero en vez de algoritmos para evaluar se utilizan medidas matemáticas. Se puede conseguir mediante varios métodos:

- ◆ **Error medio absoluto.** Mide las diferencias absolutas entre el valor objetivo y la predicción. No penaliza errores grandes, lo que aumenta la sensibilidad ante valores anómalos. Si hay muchos de estos, no es una métrica que se deba usar. Representa el error en el dominio de los números reales. El objetivo con esta métrica es que el valor medio sea cercano a 0.
- ◆ **Error cuadrático medio.** Es una de las medidas más utilizadas. Consiste en hacer la media de las diferencias entre el valor objetivo y la predicción, y elevarlo al cuadrado. Pondera mucho más en la suma los errores grandes, con lo que hay que utilizarla con precaución cuando hay muchos valores anómalos en nuestra muestra de datos. El rango de valores es entre 0 e infinito, siendo mejor la métrica cuanto más se aproxime a 0.
- ◆ **Raíz cuadrada del error cuadrático medio.** Consiste en hacer la raíz cuadrada de la métrica anterior. Tiene como ventaja representar el error en las mismas unidades que la variable objetivo, lo que la hace más fácil de comprender.
- ◆ **R cuadrado o Coeficiente de determinación.** Devuelve como predicción la media de los valores objetivo de entrenamiento. Puede tomar valores de menos infinito a 1 y cuanto más cercano a 1 esté, mejor será el modelo evaluado. Tiene como problema que si se añaden más variables independientes al modelo, esta métrica devuelve el mismo resultado o mejor, pero no empeora, lo que puede llegar a ser confuso, ya que un modelo que utilice más variables predictoras no tiene que funcionar mejor que otro que utilice menos.
- ◆ **R cuadrado ajustado.** Es una métrica mejorada de R cuadrado. Resuelve el problema de la métrica anterior, porque el valor que devuelve es siempre menor o igual a de R cuadrado, mostrando mejoría cuando el modelo es realmente mejor.

2.6 MLops – Machine Learning Operations

Con MLops realizaremos una serie de procesos en pasos para desplegar un modelo de ML en producción, que implicarán pasos previos para asegurar un despliegue correcto de los modelos y que cumplan los estándares de calidad requeridos por nuestra organización. De esta forma se define un conjunto de prácticas cuyo objetivo es mantener un despliegue continuo en los modelos de ML.

La **motivación** del uso de este tipo de prácticas es múltiple, pudiendo enumerar los siguientes puntos:

- ◆ Los modelos de ML dependen de una **gran cantidad de datos**, a lo que hay que añadir un requisito de **calidad**. Esto supone el lanzamiento de **procesos pesados** que hay que controlar. No pueden depender estos procesos del control de una persona o conjunto de personas, siendo recomendable la **automatización** de los mismos.
- ◆ Es **difícil llevar el control de los cambios** de los modelos de ML que vamos probando, por lo que es conveniente llevar el registro de cambios de estos modelos en algún sistema de **control de versiones** que nos permita el **trabajo de un equipo de personas más amplio** y volver a versiones anteriores si fuera necesario.
- ◆ El control de los cambios en las características (*features*) con las que trabaja el modelo es una tarea que se puede separar del resto de procesos, obteniendo beneficios del control de versiones. De esta forma, se puede conseguir **mejores precisiones en el modelo**, puesto

que no es un proceso que se realiza a ciegas, sino que se puede volver a situaciones anteriores donde el modelo ha sido más preciso y evolucionarlo a partir de ellas.

- ◆ La **monitorización** de los modelos de ML es una tarea completamente diferente a la de entornos web, y por lo tanto hay que considerar sus especificidades.
- ◆ La **depuración** de modelos ML es compleja.
- ◆ Los **cambios en el mundo real provocan cambios en el modelo**, lo que produce una **degradación** de los modelos **con el tiempo, perdiendo su calidad**. Por ello, hay que tener en cuenta cómo se producen estos cambios, de forma que el modelo se adapte a ellos.

El ciclo de mejora continua en un proceso clásico de DevSecOps se suele representar como un bucle infinito, donde se puede ver la correspondencia entre las fases clásicas de PDCA (Plan, Do, Check, Act), que se traducen en: Planificar, Codificar, Construir, Probar, Liberar, Desplegar, Operar y Monitorizar. El fallo en alguna de estas fases supone que hay que reevaluar el proceso desde una fase anterior. Un cambio radical en las condiciones sobre los modelos puede hacer cíclicas las fases, aunque lo habitual es que los cambios sean suaves.

En el caso de los procesos asociados con ML, el **ciclo de MLops** es diferente. Existen tres niveles de implementación de ML: datos, modelo y código. Se podría implementar en las siguientes fases:

1. **Planificación** y definición el **alcance**. Tenemos que determinar si nuestro problema se puede resolver con técnicas de ML implementadas o conocidas, haciendo la ingeniería de requisitos previa y comprobando de que disponemos de los datos necesarios.
2. **Ingeniería de datos**. Se involucran varios procesos, que tienen como objetivo preparar los datos para que sean posteriormente procesados. Se tienen procesos como por ejemplo recoger los datos, establecer las líneas base, cambiar el formato de los datos para que sean homogéneos, etiquetar los datos para los conjuntos de entrenamiento y en general organizar de forma adecuada los datos para la siguiente fase de modelado.
3. **Modelado**. Se crea mediante codificación el modelo de ML que representa los datos y se entrena dicho modelo con el conjunto de datos de entrenamiento disponibles. Se hace un análisis de los errores cometidos, teniendo una definición adecuada de error, y se registra la evolución del modelo a lo largo de los ajustes realizados. Es difícil que acertemos inicialmente con el modelo, por lo que habrá que realizar varias iteraciones.
 - Normalmente en un DevSecOps se diseñan diferentes tipos de pruebas que evalúan la calidad de un determinado producto, en función de las pruebas que haya pasado. En el caso de MLops hay que definir también métricas adecuadas. Por ejemplo, se puede definir los errores cometidos sobre el conjunto de entrenamiento con respecto al etiquetado que se ha definido, en el caso de aprendizaje supervisado.
4. **Despliegue**. Se realiza un empaquetado del modelo en la tecnología en la que se vaya a ejecutar. Puede ser sobre sistemas on-premise, o bien sobre alguna de las nubes disponibles para tal efecto, que pueden exponer servicios de despliegue automáticos.
5. **Monitorización**. Tiene dos componentes principales: monitorización de la infraestructura subyacente, de forma que se asegure su funcionamiento bajo unas condiciones óptimas, y monitorización del modelo ML que se ha definido, de forma que no pierda precisión a lo largo del tiempo.

De estos dos tipos, el segundo tipo es el más difícil de conseguir, ya que se puede también adolecer de otro tipo de problemas más difíciles de controlar, como las pérdidas de datos, que se creen sesgos en el modelo que desvirtúen los resultados obtenidos, o también la deriva en los datos o el modelo definido.

Estas derivas se provocan debido a cambios en las propiedades estadísticas de los datos que se usaron para entrenar al modelo. Hay varias causas que provocan estos cambios, como son que los datos se hayan desactualizado o no representen la realidad actual, o bien que el modelo no se haya diseñado para contemplar estos cambios a lo largo del tiempo. Estas derivas a lo largo del tiempo se pueden detectar mediante enfoques basados en procesos ML, o bien mediante pruebas estadísticas.

3 Fundamentos estadísticos

Como apoyo a la ciencia de datos, para extraer las conclusiones y el conocimiento necesarios, nos apoyamos en una serie de conceptos de origen matemático y estadístico, que se desarrollan en los apartados siguientes. Desarrollar cada uno de estos conceptos sería inabarcable en un temario de oposición, por lo que se hace una pequeña introducción a cada uno de ellos y se emplaza al lector a la sección de referencias por si quiere ampliar información en su estudio.

3.1 Fundamentos matemáticos y estadísticos

Para tener éxito en la ciencia de datos, es necesario conocer los conceptos y estudiar campos de conocimiento que se enumeran a continuación:

- ◆ **Eventos y variables aleatorias (VA en adelante).** Una VA es una función que asigna un valor al resultado de la medición de un experimento. Al realizar un experimento se producen eventos aleatorios, y en su medición es habitual registrar valores naturales, reales, pero también podrían ser valores lógicos, funciones o cualquier otro tipo de elemento (bastaría que estuvieran dentro de un espacio medible). Ejemplos: resultado de lanzar un dado de 6 caras de forma consecutiva 100 veces, tiempo de fallo de un dispositivo electrónico, tiempo medio entre fallos de un sistema de información, etc.
- ◆ **Procesos estocásticos.** Representa magnitudes aleatorias que varían con el tiempo o caracteriza una sucesión de variables aleatorias que cambian en función de otra variable, generalmente el tiempo. Cada una de las variables aleatorias que conforman el proceso estocástico puede tener su propia distribución de probabilidad y pueden estar correlacionadas o no entre sí.
- ◆ **Correlación de variables aleatorias.** Establece la fuerza y la dirección de una relación lineal y la proporcionalidad entre dos variables estadísticas.
- ◆ **Medidas estadísticas de centralización** (media, moda y mediana) **y de dispersión** (varianza y desviación típica).
 - **Media:** Mide alrededor de qué valor se distribuyen los datos, representado por la letra griega μ ("mu") o x . Es un valor comprendido entre los extremos de la distribución.
 - **Moda:** Es el valor que aparece con mayor frecuencia dentro de una muestra. Una muestra puede tener más de una moda o no tener ninguna. Es una medida de tendencia central poco eficaz.
 - **Mediana:** Es el valor central de una serie de datos. Para hallarla, es imprescindible ordenar los datos. No se ve afectada por los valores extremos.
 - **Desviación con respecto de la media (de una medida):** Es la cantidad, en valor absoluto, que ese dato se desvía de la media muestral.
 - **Desviación media:** Es la media de todas las desviaciones con respecto de la media. Se suman todas las desviaciones de todas las muestras y se divide entre el número de datos.
 - **Varianza:** Establece una medida de dispersión de la variable aleatoria. Se representa por σ^2 .
 - **Desviación típica o estándar:** Mide cuánto se separan los datos, el símbolo matemático normalmente empleado es σ ("sigma") y se define como la raíz cuadrada de la varianza.

Nombre	Fórmula
Media	$\bar{x} = \frac{1}{N} \cdot \sum_{i=1}^N x_i$
Moda	Datos x_i más repetidos.
Mediana	$\frac{x_{N+1}}{2}$ si N impar $\frac{1}{2} \cdot (x_{\frac{N}{2}} + x_{\frac{N}{2}+1})$ si N par
Desviación respecto de la media	$D_i = x_i - \bar{x} $
Desviación media	$D_m = \frac{1}{N} \cdot \sum_{i=1}^N x_i - \bar{x} $
Varianza	$\sigma^2 = \frac{1}{N} \cdot \sum_{i=1}^N (x_i - \bar{x})^2$
Desviación estándar	$\sigma = \sqrt{\frac{1}{N} \cdot \sum_{i=1}^N (x_i - \bar{x})^2}$

Figura 8: Tabla resumen de medidas estadísticas⁴.

◆ **Modelado y análisis estadístico.**

→ **Distribuciones de probabilidad.** Describe las probabilidades de ocurrencia de los diversos resultados posibles de una VA.

- Distribuciones de probabilidad **discretas**. Cuando la VA es discreta y sólo puede tomar un conjunto de valores finito.
 - **Distribución Binomial.** Cuenta el número de éxitos en una secuencia de n ensayos de Bernoulli independientes entre sí con una probabilidad fija p de ocurrencia de éxito entre los ensayos.
 - **Distribución de Poisson.** Expresa, a partir de una frecuencia de ocurrencia media, la probabilidad de que ocurra un determinado número de eventos durante un período de tiempo determinado. Se centra en sucesos con probabilidades pequeñas.
 - **Distribución Hipergeométrica.** Relacionada con muestreos aleatorios y sin reemplazo. Modela procesos de Bernoulli con probabilidades no constantes. Es muy útil en los casos en los que se extraigan muestras o experiencias repetidas sin reemplazo o sin retornar a la situación inicial al realizar el experimento.
- Distribuciones de probabilidad **continuas**. Cuando la VA es continua y toma valores reales.
 - **Distribución Normal o de Gauss ("campana de Gauss").** Es una de las distribuciones de probabilidad más habituales. La gráfica de la función de densidad de probabilidad tiene una forma acampanada y es simétrica respecto al parámetro de la media de la distribución. La anchura de la campana tiene relación con la varianza. Por tanto, la caracterizan esos dos parámetros: la media y varianza. Permite modelar fenómenos naturales, sociales y psicológicos. Por el Teorema Central del Límite, todas las variables que puedan ser causadas por un gran número de efectos pequeños tienden a distribuirse según la distribución normal.
 - **Distribución de Cauchy-Lorentz.** Es muy útil en física por ser la solución de la ecuación diferencial que describe la resonancia forzada. Tiene dos parámetros principales: x_0 (describe la ubicación del pico de la distribución) y γ (especifica el ancho medio al máximo medio). Si $x_0 = 0$ y $\gamma = 1$, se denomina distribución estándar Cauchy.

⁴ [Enlace a la tabla.](#)

- **Distribución exponencial.** Modela los tiempos de espera de cierto evento. Tiene la propiedad de pérdida de memoria. Se aplica por ejemplo en el análisis de VA que miden la precipitación sobre una región.
- Diferentes tipos de **análisis estadístico** (ver apartado de modelado): Análisis descriptivo, predictivo, inferencial, diagnóstico, casual, prescriptivo y mecanicista.
- **Proceso de Bernoulli.** Es la repetición de un ensayo de Bernoulli, que es un experimento aleatorio con sólo dos resultados posibles: éxito o fracaso.
- ◆ **Diseño de experimentos.** Son modelos estadísticos con el objetivo de determinar si ciertos factores afectan a una variable de interés y si existe dicha influencia, poder cuantificarla. La metodología de dichos experimentos se basa en el método científico, puesto que al repetir el experimento varias veces se intenta reducir el efecto del error de medición cometido. Estos experimentos se realizan para evaluar si un determinado cambio aplicado ha mejorado o empeorado la situación inicial de partida.
- ◆ **Teorema de Bayes.** Expresa la probabilidad condicionada de un evento aleatorio. Es de gran relevancia puesto que vincula la probabilidad de un evento aleatorio A dado B, con la probabilidad de B dado A.
 - Teoría de la **inferencia bayesiana.** Las evidencias u observaciones se emplean para actualizar o inferir la probabilidad de que una hipótesis pueda ser cierta.
- ◆ Algoritmos de ciencia de datos:
 - Aprendizaje supervisado:
 - **Árboles de decisión.** Diagramas de construcciones lógicas que representan y categorizan una serie de condiciones que ocurren de forma sucesiva, que resuelven un problema.
 - **Random forests.** Combinación de árboles predictores, cada árbol depende de los valores de un vector aleatorio y con la misma distribución de probabilidad.
 - Regresión logística. Predice el resultado de una variable categórica.
 - Aprendizaje no supervisado:
 - **Clustering**
 - Algoritmo de k-medias (k-means). Partición de un conjunto de n observaciones en k grupos.
 - Reducción dimensional. Identifica y selecciona conjunto de características relevantes.
 - Algoritmos de **optimización**:
 - **Descenso de gradiente.** Encuentra mínimos locales en una función diferenciable.
 - Programación y regresión lineal: representa la solución final mediante una función lineal de las variables implicadas.
 - **MapReduce.** Algoritmo de computación paralela, implementado en diversas plataformas, como Hadoop.
 - Suele estar compuesto por 4 fases:
 - *Map*: Toma los datos de entrada y los divide en bloques más pequeños. La salida son pares de clave-valor.
 - *Shuffle and Sorting*: Elimina los valores iguales y los diferentes los agrupa en función de la clave.
 - *Reduce*. Se ejecuta la lógica para agrupar los valores en función de las claves.
 - *Combine*. Es una fase opcional, para optimizar el rendimiento de las fases anteriores.
 - Otros algoritmos de optimización:
 - **Algoritmos genéticos:** intenta minimizar o maximizar una función objetivo, denominada función de *fitness*, mediante algoritmos evolutivos sobre una población inicial. Los individuos de la población se caracterizan por un genotipo, que va evolucionando por selección natural, mediante procesos como mutación o combinación.

4 Herramientas y lenguajes de ciencia de datos

Existen diferentes ecosistemas de herramientas de ciencia de datos y lenguajes de programación que se utilizan habitualmente para programar los modelos y resto de procesos necesarios.

4.1.1 Lenguajes de programación utilizados en ciencia de datos

◆ Generalistas.

- **Python:** Es un lenguaje que ha adquirido mucha popularidad, y en el que se han desarrollado muchas librerías específicas para ciencia de datos: NumPy, pandas (gestión de conjuntos de datos), Matplotlib (gráficas), scikit-learn, TensorFlow, Keras. Tiene una gran comunidad detrás.
- **Java:** Es a la vez un lenguaje y una plataforma (implementa su propia máquina virtual). Es orientado a objetos, permite independencia de la plataforma ("write once, run anywhere") y tiene su propio recolector de basuras (GC, Garbage Collector). Al ser tan popular es muy fácil encontrar perfiles en el mercado.
- **C/C++:** Produce implementaciones bastante eficientes. Trabaja bien sobre grandes conjuntos de datos. La primera versión de MapReduce se programó en C++.
- **Scala:** Es un lenguaje multiparadigma, que permite orientación a objetos pero integra también características de lenguajes funcionales. La plataforma Spark se puede programar con este lenguaje.
- **GO:** Es un lenguaje que permite paralelizar muy fácilmente los trabajos, por lo que ha ido ganando popularidad tanto para la recolección de datos, como para programar procesos de ML, pasando por la visualización.
- **Perl / Bash / PowerShell:** Para programar el lanzamiento de las descargas de datos se pueden utilizar estos lenguajes. Los dos primeros sobre SO Linux, y el último sobre Windows.
- **SQL:** Se diseñan las consultas a las BDs relacionales que actúan como orígenes de datos.

◆ Específicos:

- **R:** Es un lenguaje con mucha tradición y de uso muy extendido. Proporciona herramientas de análisis de conjuntos de datos y visualización de información. Originalmente enfocado al análisis estadístico.
- **MATLAB & Simulink:** Muy sencillo de programar y de utilizar por parte de los perfiles dedicados a ciencia de datos, permite:
 - Acceso a orígenes de datos diversos (incluidos almacenamientos en nube de AWS y Azure), bases de datos SQL y NoSQL.
 - Limpieza de los datos, análisis y desarrollo de modelos de ML en muestras pequeñas de datos.
 - Escalado a conjunto de datos mayores, sin necesidad de reescribir los algoritmos.
 - Utilizar características de clústeres de HPC, Spark o plataformas en la nube para lanzar las cargas.
- **Julia:** Lenguaje dinámico flexible adecuado para computación científica y numérica, que ofrece un rendimiento comparable a los lenguajes tradicionales de tipo estático. Cuenta con tipado fuerte opcional, envío múltiple de mensajes y buen rendimiento a través de la inferencia de tipos y la compilación *Just-in-Time*. Julia es multiparadigma, combinando características de programación imperativa, funcional y orientada a objetos. Soporta computación numérica de alto nivel y programación genérica, basándose en lenguajes de programación matemáticos ya existentes (Matlab, Fortran, etc).
- **SAS:** Lenguaje para análisis estadístico, que puede leer de hojas de cálculo y otros documentos. Es multiplataforma.

- ➔ Microsoft SQL Server Integration Services (**SSIS**). Es una Plataforma para crear soluciones empresariales para transformación e integración de datos. Contempla un conjunto completo de tareas y transformaciones integradas, herramientas gráficas para crear aplicaciones, y una base de datos de catálogo para almacenar, ejecutar y administrar los paquetes.

4.1.2 Herramientas para la ciencia de datos

Podemos clasificar las herramientas de ciencia de datos en los siguientes tipos principales:

- ◆ Herramientas para integración de datos. Herramientas para implementar *streaming* de datos y para gestión de cargas ETL/ELT.
- ◆ Herramientas para el gobierno de los datos.
- ◆ Herramientas de monitorización y gestión de infraestructura.
- ◆ Herramientas de visualización de datos.
- ◆ Herramientas de análisis de datos.
- ◆ Herramientas de planificación de (des)cargas de datos.

Las principales nubes tienen sus herramientas y tecnologías específicas para ciencia de datos.

◆ Ecosistema **Microsoft**

- ➔ Data Science Virtual Machine (**DSVM**). Imágenes de Azure preinstaladas, configuradas y probadas con varias herramientas de ciencia de análisis de dsots, aprendizaje automático y entrenamiento con IA.
- ➔ **HDInsight**. Aprovisionamiento de clústeres Hadoop, Spark y HBase en la nube.
- ➔ Azure **Synapse** Analytics. Servicio de análisis empresarial que agiliza el tiempo necesario para obtener la información desde los orígenes de datos y de macrodatos. Utiliza tecnologías SQL que usan almacenamiento empresarial, tecnologías Apache Spark para macrodatos y Azure Data Explorer para análisis de registros de log y de series temporales.
- ➔ Azure **Data Factory**. Servicio de integración de datos *serverless* totalmente administrador. Se pueden integrar más de 90 conectores con diversos orígenes de datos sin necesidad de mantenimiento ni coste adicional. Se pueden construir procesos ETL/ELT de forma sencilla sin código mediante un entorno intuitivo o bien programarlo. Se conecta con Azure Synapse Analytics para descubrimiento de información empresarial.
- ➔ Azure **Data Lake**. Implementa un data lake en la nube, almacenando y analizando archivos de hasta petabytes, y billones de objetos. Se pueden depurar y optimizar los macrodatos. Es muy flexible, puesto que se paga por uso y se puede escalar de forma instantánea. Se pueden desarrollar programas con un alto nivel de paralelismo.
- ➔ Azure **Cloud File Storage**. Compartición de archivos por protocolos SMB o NFS. Los sistemas de ficheros se pueden montar en diferentes sistemas operativos (Windows, Linux y macOS). En Windows Server se puede acelerar el acceso con Azure File Sync.
- ➔ **Microsoft PowerBI y PowerBI Portal** (visualización de datos). Es una herramienta muy intuitiva que permite el diseño de paneles de mando y visualizaciones a las unidades de negocio, si se les presenta los conjuntos de datos adecuados.

◆ Ecosistema **Google**

- ➔ **TensorFlow**. Biblioteca de código abierto para aprendizaje automático mediante diferentes procesos. Desarrollado por Google, actualmente es utilizado tanto en investigación como en los propios productos de Google. Puede correr en múltiples CPUs y GPUs, y está disponible en diferentes sistemas operativos.
- ➔ **Looker Studio** (visualización de datos). Para crear informes y visualizaciones de forma sencilla en el ecosistema Google.

- **BigQuery.** Almacén de datos empresariales *serverless*, que funciona en diferentes nubes aunque la nativa es la de Google. Escalable hasta tamaños de petabytes, permite la interrogación mediante un dialecto de SQL. Implementa características de ML integradas.
- **Vertex AI Platform.** Despliega y escala modelos de ML rápidamente y de forma sencilla. Permite crear aplicaciones de IA generativa. Implementa prácticas de MLOps.
- **AutoML.** Permite entrenar modelos de IA a desarrolladores con experiencia limitada.
- **Google Colab.** Permite programar y ejecutar código Python desde el navegador, sin configuración adicional, sobre servidores en la nube, y compartir el resultado fácilmente. Se emplea habitualmente para proyectos de ciencia de datos.
- ◆ Ecosistema Amazon Web Services (**AWS**).
 - Amazon **CodeGuru.** Identifica porciones de código que se podrían optimizar.
 - Amazon **CodeWhisperer.** Asiste a los programadores mientras están codificando las aplicaciones, en C#, Java, Javascript, Python y Typescript.
 - Amazon **DevOps Guru.** Detecta patrones en la monitorización del rendimiento y disponibilidad de aplicaciones, identificando problemas e informando de impacto sobre los clientes.
 - Amazon **Forecast.** Realiza predicciones precisas mediante ML, sobre variables medidas por el negocio, como demanda de productos, necesidad de recursos o rendimientos financieros.
 - Amazon **Fraud Detector.** Especializado en detección de fraude.
 - Amazon **Kendra.** Un motor de búsqueda inteligente que utiliza ML para aprender. Encuentra la información en repositorios dispersos y en múltiples localizaciones.
 - Amazon **Lex.** Es un servicio de IA totalmente administrado para diseñar, construir, probar e implementar interfaces conversacionales en cualquier aplicación mediante voz y texto. Proporciona las funcionalidades avanzadas de *Deep Learning* para reconocimiento automático de voz ASR para convertir voz en texto y comprensión del lenguaje natural (NLU) para reconocer la intención del texto.
 - Amazon **Lookout for Equipment.** Analiza datos de sensores en equipos industriales, para entrenar automáticamente modelos ML basados en dichos datos, de forma totalmente personalizada.
 - Amazon **Lookout for Metrics.** Detecta y diagnostica anomalías en datos operacionales de negocio.
 - Amazon **Lookout for Vision.** Detecta defectos y anomalías en representaciones visuales, usando visión por computador (*Computer Vision*).
 - Amazon **Monitron.** Detecta mediante ML comportamientos anómalos en maquinaria industrial.
 - Amazon **Personalize.** Para recomendaciones a los usuarios en el uso de aplicaciones.
 - Amazon **Polly.** Convierte texto en habla. Permite crear aplicaciones que hablen.
 - Amazon **Rekognition.** Añade vídeo e imagen a las aplicaciones. Puede identificar objetos, personas, texto, escenas y actividades en imágenes y vídeos, así como contenido inadecuado.
 - Amazon **Textract.** Extrae texto de documentos escaneados (OCR).
 - Amazon **Transcribe.** Detección de conversaciones automática (ASR) en ficheros de audio.
 - Amazon **Translate.** Traduce desde diferentes idiomas, utilizando modelos de Deep learning.
 - AWS **DeepComposer.** Crea música.

Otras plataformas en nube diferentes de estos ecosistemas son:

- ◆ **IBM Watson Developer Cloud.**
- ◆ **BigML.**

Plataformas y herramientas de software libre on-premise:




Figura 9: Arquitectura de Apache Hadoop.

- ◆ **Apache Hadoop:** Es un *framework* que permite el procesamiento distribuido de grandes conjuntos de datos en grupos de servidores utilizando modelos de programación simples. Está diseñado para escalar desde servidores individuales hasta miles de máquinas, cada una de las cuales ofrece computación y almacenamiento local. En lugar de depender del hardware para ofrecer alta disponibilidad, está diseñado para detectar y manejar fallas en la capa de aplicación, entregando así un servicio de alta disponibilidad sobre un grupo de servidores, cada una de los cuales puede ser propenso a fallos. Tiene varios componentes, entre otros podemos destacar:
 - ➔ Ambari: Gestión y monitorización.
 - ➔ Zookeeper: Coordinación de los nodos del clúster Hadoop. Alta disponibilidad.
 - ➔ Oozie: Planificación y gestión del *workflow*.
 - ➔ Pig: Para *scripting* de procesos sobre la plataforma.
 - ➔ Mahout: Implementa algoritmos de ML.
 - ➔ Hive: Interrogación a recursos.
 - ➔ MapReduce: Es un modelo de programación para computación paralela desarrollado inicialmente por Yahoo y actualmente forma parte de un proyecto Apache.
 - ➔ HDFS: Sistema de ficheros distribuido.
 - ➔ HBase: Base de datos distribuida y no relacional, basada en BigTable.
 - ➔ Integración de datos con: Sqoop, REST u ODBC.
- ◆ **Apache Spark:** Motor multilenguaje para ejecutar cargas de ingeniería y ciencia de datos, y MLK en uno o varios nodos en clúster. Añade posibilidad de un procesamiento en línea.
- ◆ **Asterix.** Desarrollado por UC Irvine.
- ◆ **Jupyter Notebooks.** Implementa programación y ejecución de scripts en Python y otros lenguajes de programación, desde el navegador.

Suites comerciales que integran varios componentes:

- ◆ **Pentaho.** Suite completa con diferentes módulos, con herramientas de análisis e informes integrados con un motor de *workflow* de procesos de negocio.
- ◆ **Tableau.** Tiene versión Desktop, Online (nube) y Server (on-premise).
- ◆ **MicroStrategy.** Plataforma analítica abierta y basada en nube.
- ◆ **Oracle BI Suite.** Solución de Oracle para BI, integrada con otros productos de Oracle.

Mencionamos también alguna plataformas de sincronización de datos por *streaming*: Apache Flink, Apache Spark, Apache Storm, Apache Samza, Amazon Kinesis.

5 Visualización de datos

5.1.1 Visualización como proceso de comunicación

La visualización de datos se puede definir a un nivel esencial como un **proceso de comunicación**, en donde:

- ◆ El **emisor** del mensaje suele ser el sistema de información que analiza los datos (que pueden ser resultados, ideas, anomalías detectadas, tendencias, procesos complejos que hay que simplificar, descubrimiento de fraude, etc).
- ◆ Se **codifica** dicha información en forma normalmente de gráficas o visualizaciones más o menos complejas, que forman el **mensaje** en sí que se está transmitiendo.
- ◆ Y dicho mensaje lo recibe uno o varios **receptores**, que son las partes interesadas (pueden ser internos o externos a la organización que genera la visualización), que lo interpretan y les provoca inspiración, conocimiento, entendimiento o les persuade de algo.

5.1.2 Elementos clave para una buena visualización de datos

En este proceso de comunicación, los **elementos clave** que hay que tener en cuenta son los siguientes:

- ◆ Hay que elegir la forma de **representación** adecuada de la información, de forma que sea lo más intuitiva al receptor y que pueda interpretar sin necesidad de una explicación previa. Es decir, el uso de la forma física, si se representa con líneas, barras, círculos o cualquier otra forma visual.
- ◆ La **presentación** de los datos va un paso más allá, y permite integrar los datos representados en el trabajo final. Incluye la elección de colores, anotaciones, características interactivas, y la organización y distribución de los elementos (*layout*).
- ◆ También hay que tener en cuenta la **percepción** que pueden realizar los receptores, que puede variar en función de los procesos mentales de cada uno. No es lo mismo transmitir una información a una persona menor de edad que a una persona adulta, cada uno lo percibirá de forma diferente.
- ◆ Finalmente, en nuestra visualización podemos **amplificar el efecto** de ciertos elementos que consideramos importantes, para recalcar su importancia en el mensaje final.

En todo proyecto de visualización de datos hay que tener en cuenta:

- ◆Cuál es el **propósito** y la **audiencia objetivo** a la que se va a presentar la información.
- ◆ Qué **restricciones de tiempo y deadlines** tenemos para el proyecto en concreto. Puede ser necesario replantearse los objetivos a conseguir, si no es posible cumplir los plazos.
- ◆ Qué **costes** tendrá asociado el diseño del proyecto, a qué personal involucrará, si serán internos de nuestra organización o externos, si es posible ofrecer parte en modo autoservicio (de forma que las diferentes unidades creen sus propias visualizaciones), etc.
- ◆ **Presiones por parte del cliente** que ha encargado la visualización. Pueden ser importantes y hay que tenerlas en cuenta para poder regular la presión a los equipos involucrados.
- ◆ Si el **formato** en el que se presenta la visualización es estático o dinámico.
- ◆ Si la **capacitación técnica de los equipos** involucrados es suficiente para cubrir las necesidades del proyecto, o hay que reclamar un aumento del personal dedicado a ello.

5.1.3 Diferentes tipos de visualizaciones

Dependiendo del grado de madurez de los proyectos de visualización, el resultado del proceso de ciencia de datos puede ser de alguno de los siguientes tipos:

- ◆ **Informes.** Mediante herramientas de generación de informes, se genera una representación estática del conocimiento generado. Tiene la ventaja de que se puede archivar el informe y consultar en cualquier momento, aunque siempre va a estar desactualizado.
- ◆ **Cuadros de mando (C.M.).**
 - ➔ Es una representación gráfica de los indicadores de la organización. Se representan parámetros como las **KPI** (Key Process Indicator), **KGI** (Key Goal Indicator) y otros indicadores.
 - ➔ Los hay de varios tipos:
 - Según su **función**, se pueden clasificar en:
 - C.M. **operacional**: ayuda a la ejecución de los procesos.
 - C.M. **táctico**: muestra información que ayuda a controlar los procesos.
 - C.M. **estratégico**: gestiona el proceso de forma global, lo que permite la consecución de los objetivos propuestos.
 - Según su **contenido** pueden ser:
 - **BAM – Business Activity Monitoring**. Muestra información en tiempo real de carácter operacional y táctico.
 - **Dashboard**: Muestran información sin compararla con los objetivos.
 - **Scorecard**: Muestran información estratégica y están orientados a mostrar objetivos (muestran KPIs y KGIs).
 - **C.M. balanceados (Balanced Scorebard)**: Es una metodología de gestión estratégica independiente creada por Robert Kaplan y David Norton. Permite estructurar de forma dinámica e integral los objetivos estratégicos, y ponerlos a prieda según una serie de indicadores. Evalúan el rendimiento de todas las iniciativas y proyectos, de forma que se consiga un cumplimiento satisfactorio.

Las **visualizaciones y tipos de gráficos** más habituales en ciencia de datos son los siguientes:

- ◆ **Para comparación de categorías.**
 - ➔ **Gráfico de puntos.** Compara variables categóricas representando valores cuantitativos con una marca simple, como un punto o un símbolo.
 - ➔ **Gráfico de barras.** Muestra los datos por la longitud o la anchura de una barra, permitiendo comparaciones entre diferentes categorías.
 - ➔ **Histograma.** Muestra la distribución de la frecuencia de valores cuantitativos (eje y) frente a intervalos definidos de otro valor cuantitativo (eje x). No confundir con el gráfico de barras.
 - ➔ **Nube de palabras.** Representa la frecuencia de aparición de una palabra por el tamaño del tipo de letra que la representa, y en ocasiones el color.
- ◆ **Para evaluación de jerarquías y relaciones parte-a-todo.**
 - ➔ **Gráfico de sectores.** Representa en un círculo los diferentes sectores, cuya frecuencia tiene relación con el ángulo que abarca cada sector.

- **Gráfico de barras apilado.** Sobre una barra se representan diferentes variables, que luego se comparan con otras barras. Un ejemplo podría ser la población por rango de edades, en porcentaje, en diferentes países.
 - **Jerarquía en árbol.** Se representa los datos mediante una red jerárquica en forma de árbol.
- ◆ **Para mostrar cambios a lo largo del tiempo.**
- **Gráfico de líneas.** Representa el cambio de una variable cuantitativa continua (eje y) cuando cambia otra variable (eje x, que puede ser temporal).
 - **Gráfico de áreas.** Es parecido al anterior, sólo que se rellena el área bajo la línea, formándose un área que se colorea.
 - **Gráfico de áreas apilado.** Representa varios gráficos de área, uno encima del otro. Habitualmente la suma da un número fijo (un porcentaje por ejemplo), por lo que la representación final presenta de las proporciones con respecto a la variable x.
- ◆ **Para dibujar conexiones y relaciones.**
- **Gráfico de dispersión ("scatter").** Representa la combinación de dos variables cuantitativas dibujadas en el eje x e y, de forma que se muestran los patrones de correlaciones, clustering y valores atípicos.
 - **Gráfico de burbujas ("bubble").** Representa en dos ejes dos variables, y varía el tamaño de los puntos en función de una tercera variable.
 - **Mapa de calor.** Mediante rejillas rectangulares, que se rellenan con colores de diferente tonalidad, se representan la relación de dos variables categóricas, con una variable cuantitativa que varía con la tonalidad del color. Se podría representar por ejemplo mediante esta gráfica el número de procedimientos presentados por la sede electrónica, lo largo de las semanas de un mes, con tonalidades tendiendo al rojo cuantos más procedimientos se presenten.
 - **Red radial (o diagrama de acordes).** Representa una relación de valores categóricos situados alrededor de una circunferencia, que se conectan mediante arcos que van variando el tamaño. Un ejemplo serían las colaboraciones entre diferentes profesores de un departamento Universitario, en donde los profesores que colaboran más tendrían arcos más anchos conectándolos.
- ◆ **Para mapeo de datos georeferenciados.**
- **Mapa coroplético.** Es un tipo de mapa temático en el que las áreas se rellenan de distintos colores de la misma gama cromática, que representan distintos valores de una variable estadística característica de esa región geográfica. Ejemplos de variables podrían ser la densidad de población o la renta per cápita.
 - **Gráfico de mapa de puntos.** Sobre un mapa geográfico, se dibujan puntos del mismo tamaño, que representa algún tipo de evento. Por ejemplo, una representación de las oficinas postales en el territorio español.
 - **Cartograma.** Cambia el tamaño de una representación geográfica, para reflejar una determinada variable. Por ejemplo, se podría representar el mapa del mundo, cambiando el tamaño de los países en función de su población.

6 Ejemplos de proyectos relacionados con Ciencia de datos en las administraciones

Algunos proyectos destacados en ciencia de datos de las diferentes administraciones son:

- ◆ Proyecto **ARBARIA** (Ministerio para la Transición Ecológica y el Reto Demográfico). IA para detectar y extinguir incendios forestales.
 - ➔ Utiliza técnicas de Machine Learning y Deep Learning para explotar diversas fuentes de información.
 - ➔ Hace uso de datos de pronóstico meteorológico de la AEMET.
 - ➔ Permite el uso eficiente de recursos en la lucha contra incendios.
- ◆ Proyecto **Nidel** de la Agencia Española de Administración Tributaria (Ministerio de Hacienda y Función Pública). Para detección de redes de blanqueo de capitales. Utiliza técnicas de data mining, AML (*Anti-Money Laundering*).
- ◆ Gerencia Informática de la Seguridad Social (GISS). '**Ciudadano 360 y Asistentes Virtuales** en la Seguridad Social'
- ◆ Proyecto de **Calidad del Aire**, en el Ayuntamiento de Madrid (técnicas predictivas).
 - ➔ Es un proyecto en el que, mediante técnicas predictivas basándose en información histórica recopilada, se predice la situación atmosférica futura de la ciudad.
- ◆ **Chatbots** (utilizan tecnologías de procesamiento de lenguaje natural, NLP):
 - ➔ Chatbot de Aragón OpenData
 - ➔ **Ayuntamientos**: María (del Ayuntamiento de Las Rozas), Karina (Sagunto) o Asistente virtual de Línea Madrid (Ayuntamiento de Madrid).
 - ➔ Asistentes de voz en **Universidades** Españolas: Lola (Murcia), Pilar (Zaragoza), Aina (Baleares), Isidra (Alcalá de Henares), Ada (Jaén), Pau (Politécnica de Valencia), Carol (Complutense de Madrid), Carina (Alicante).

7 Resumen esquemático

- Introducción y conceptos de ciencia de datos.
 1. Motivación, gran cantidad de datos generados.
 2. Visión arquitectónica extremo-a-extremo. Fuentes de datos, procesos de integración y almacenes de datos.
 3. Perfiles profesionales de ciencia de datos.
 4. Normativa y regulación. Nivel europeo y estatal.
- Ciclo de vida de los procesos de modelado de datos.
 1. Ciclo de vida. Planificar; Creación y captura; Transmisión, almacenamiento y seguridad; Gestión y trabajo colaborativo; Análisis, explotación de los datos y visualización; Publicación; y Archivo y destrucción.
 2. Proceso de integración de datos. ETL/ELT, Extract-Transform-Load. Descargas totales mediante procesos *batch*, incrementales y *streaming*.
 - a) Tipos de almacenes de datos.
 3. Modelado.
 4. Validación
 5. MLops.
- Fundamentos estadísticos
 1. Eventos y variables aleatorias
 2. Procesos estocásticos
 3. Correlación
 4. Medidas estadísticas de centralización y dispersión
 5. Distribuciones de probabilidad (discretas y continuas)
 6. Diseño de experimentos
 7. Teoría de inferencia bayesiana
 8. Algoritmos de ciencia de datos (supervisados, no supervisados, de optimización, otros)
- Herramientas y plataformas.
 1. Lenguajes: R, Python, Java, Julia, etc.
 2. Ecosistemas: Azure, Google y AWS.
 3. Otras plataformas en nube: Watson, BigML.
 4. Plataformas *on-premise* (Hadoop, Spark, etc).
- Visualización
 1. Proceso de comunicación (emisor, codificación, mensaje, decodificación, receptor)
 2. Aspectos clave: Representación, Presentación, Percepción y Amplificación de efecto.
 3. Tipos de visualizaciones: Informes, Cuadros de mando.
 4. Tipos de gráficos: gráfico de barras, de sectores, de líneas, etc.
- Ciencia de datos en las administraciones
 1. ARBARIA (Transición Ecológica).
 2. Nidel (AEAT).
 3. Ciudadano 360 (GISS).
 4. Chatbots:
 1. Ayuntamientos.
 2. Universidades.

8 Glosario

TÉRMINO	BREVE DEFINICIÓN
AESIA	Agencia Española de Supervisión de la Inteligencia Artificial.
Apache Hadoop	Framework de procesamiento distribuido.
Apache Spark	Motor multilenguaje para ejecutar cargas de ingeniería y ciencia de datos, y MLK en uno o varios nodos en clúster.
API	Application Programming Interface. Interfase de comunicación mediante protocolo estándar con una aplicación.
Aprendizaje profundo (DL)	Redes neuronales multicapa diseñadas para detectar ciertas características. Deep Learning.
Bash	Lenguaje de scripting.
C/C++	Lenguajes para implementaciones eficientes.
Correlación	Mide la fuerza y dirección de una relación lineal, y la proporcionalidad entre dos variables aleatorias.
DAMA	DAta Management Association. Metodología que define cómo se ha de hacer el gobierno del dato.
DCAM	Data Management Capability Assessment Model. Modelo que define estrategias de datos.
DCO	Data Chief Officer. Figura de la administración que lidera la política de datos de la AGE.
Desviación media	Media de todas las desviaciones con respecto a la media.
Desviación típica o estándar	Medida de separación de los datos.
ETL / ELT	Extract - Transform - Load
GO	Lenguaje muy paralelizable. Compilado.
Gobernanza (del dato)	Conjunto de políticas y procedimientos que hacen que la gestión de los datos se haga de forma efectiva y proactiva.
GPU	Graphics Process Unit
IPU	Intelligence Processing Unit. Procesador paralelo, altamente flexible, diseñado desde el principio para cargas de IA.
Inteligencia Artificial (IA)	Emulación de la inteligencia humana.
Inteligencia de negocio (BI)	Análisis de datos actuales e históricos para presentar conclusiones a perfiles directivos.
Java	Lenguaje y plataforma, orientada a objetos.
Julia	Lenguaje dinámico y flexible para computación científica y numérica.
MapReduce	Algoritmo de computación paralela, usado habitualmente en Hadoop.
Matlab	Lenguaje de uso científico, con una curva de aprendizaje suave.
Media	Mide alrededor de qué valor se distribuyen las muestras.
Minería de datos	Extrae información relevante de un conjunto grande de datos. Data mining.
ML	Machine Learning.
Norma ISO 38505	Mapa de gobierno de datos y mapa de responsabilidades.
Norma ISO 8000	Marco para la mejora de la calidad de los datos.
NPU	Neural Processing Unit. Creado especialmente para redes neuronales profundas.

TÉRMINO	BREVE DEFINICIÓN
pandas	Librería para gestionar y trabajar con conjuntos de datos.
Perl	Lenguaje de scripting.
PowerShell	Lenguaje de scripting (para Windows).
Proceso estocástico	Sucesión de variables aleatorias que cambian en función de otra variable.
Python	Lenguaje popular en ciencia de datos.
R	Lenguaje estadístico y para visualización de datos.
Redes neuronales	Conjunto de neuronas artificiales conectadas entre sí, diseñadas para resolver un problema.
SAS	Lenguaje de programación estadístico.
SEDIA	Secretaría de Estado de Digitalización e Inteligencia Artificial.
Simulink	Librería matemática para Matlab.
SOM	Self-Organizing Maps. Aprendizaje máquina no supervisado con representaciones con bajo número de dimensiones.
SQL	Lenguaje descriptivo para diseño de consultas.
SSIS	SQL Server Integration Services. Plataforma para programar transformación e integración de datos.
Streaming	Sincronización continua de datos entre origen y destino.
TOGAF	Arquitectura empresarial para diseño, planificación, implementación y gobierno.
TPU	Tensor Processing Unit. ASIC específico desarrollado por Google para cargas de IA.
Variable aleatoria (VA)	Función que asigna un valor al resultado de la medición de un experimento.
Varianza	Medida de dispersión de la variable aleatoria.

9 Test

9.1 Preguntas de test

- 1) El objetivo principal de la minería de datos es:
 - a) Descubrir el conocimiento oculto en grandes volúmenes de datos y expresarlo de forma inteligible.
 - b) Reorganizar adecuadamente los grandes volúmenes de datos.
 - c) Tener copias de seguridad fiables y rápidas de todos y cada uno de los datos de que se dispone.
 - d) Ninguna de las anteriores respuestas es correcta.
- 2) ¿Cuál de las siguientes utilidades permite realizar minería de datos?
 - a) JDataMiner.
 - b) Cubos OLAP de Excel.
 - c) VNC.
 - d) Extract to Learnt by SQLServer.
- 3) Entre las extensiones del Data Mining se encuentra:
 - a) Web Mining y Text Mining.
 - b) Web Mining, Text Mining e Hipertext Mining.
 - c) Text Mining e Hipertext Mining.
 - d) Web Mining e Hipertext Mining.
- 4) Indique cuál de los siguientes elementos **NO** se asocia a un sistema datawarehouse:
 - a) Un motor de transacciones.
 - b) Las herramientas de Extracción, Transformación y Carga de datos.
 - c) Las herramientas de explotación analítica de la información.
 - d) La base de datos multidimensional.
- 5) A la hora de aplicar métodos de data mining:
 - a) Lo único importante es que se disponga de muchos datos.
 - b) Debe disponerse de muchos datos residentes en una base de datos relacional.
 - c) Lo más importante es disponer de una buena herramienta comercial.
 - d) Los datos deben haber sido preprocesados.
- 6) En las bases de datos usadas para data warehousing, ¿qué tipo de esquema es un modelo de datos que tiene una tabla de hechos (o tabla fact) que contiene los datos para el análisis, rodeada de las tablas de dimensiones?
 - a) Radio
 - b) Estrella
 - c) Cubo
 - d) Copo de nieve
- 7) SCALA
 - a) Son las siglas de Scalable Language.
 - b) Es usado como lenguaje en Ciencia de Datos.

- c) La compilación del código fuente de Scala produce bytecode Java para su ejecución en una JVM.
 - d) Todas las anteriores son correctas.
- 8) En el paradigma MapReduce
- a) Siempre tiene que haber por lo menos un Mapper, pero puede no haber Reducer
 - b) Puede no haber un Mapper, pero siempre tiene que haber al menos un Reducer
 - c) Puede no haber ni Mapper ni Reducer
 - d) Tiene que haber por lo menos un Mapper y un Reducer
- 9) Qué fundamento no establece la Unión Europea en la construcción de espacio de datos.
- a) Descentralización.
 - b) Centralización.
 - c) Soberanía.
 - d) Transparencia.
- 10) ¿Qué es 'slice & dice'?
- a) Una utilidad de las hojas de cálculo para seleccionar filas y columnas.
 - b) Una técnica OLAP que permite obtener subconjuntos de las vistas multidimensionales.
 - c) Una técnica de representación gráfica de un sistema de información geográfica de acuerdo al modelo ráster.
 - d) Una técnica para redistribuir los flujos convergentes en un sistema de workflow.
- 11) ¿Cuál de las siguientes es una operación que implica un cambio en el número de dimensiones contempladas en la visión de un sistema OLAP?
- a) Drill-Across.
 - b) Drill-In.
 - c) Roll-Up.
 - d) Rotación.
- 12) Seleccione qué estrategias son de validación de modelo de datos en ciencia de datos.
- a) Validación simple.
 - b) LOOCV
 - c) K-Fold Cross-Validation.
 - d) Todas las respuestas anteriores son correctas.
- 13) La recomendación ITU donde se presentan los requisitos y capacidades basados en la computación en la nube (Big Data) es:
- a) AY.3600
 - b) BY.3700
 - c) CY.3800
 - d) DY.3900
- 14) Las tablas primarias en el modelo dimensional de un Datawarehouse y que contienen los valores y métricas se conocen como:
- a) Tablas de dimensiones.

- b) Tablas maestras.
 - c) Tablas de hechos.
 - d) Tablas externas.
- 15) ¿Qué arquitectura no es usada en construcción de espacio de datos?
- a) Data Fabric.
 - b) Data Lakehouse.
 - c) Data River.
 - d) Data Mesh.
- 16) ¿Cuál de los siguientes no es un proceso definido por DAMA?
- a) Gestión de documentos y contenidos
 - b) Limpieza y preprocesado de los datos
 - c) Datos maestros y de referencia
 - d) Seguridad de los datos
- 17) Perfil de ciencia de datos que se dedica a explicar, a partir de las visualizaciones de datos generadas, la narrativa que mejor representa a los datos.
- a) Narrador de datos
 - b) Administrador de base de datos
 - c) Desarrollador
 - d) Arquitecto de datos
- 18) ¿Cuál de los siguientes es un *framework* para procesamiento distribuido de grandes conjuntos de datos, que forma parte del proyecto Apache?
- a) Asterix
 - b) Pentaho
 - c) MicroStrategy
 - d) Hadoop

9.2 Soluciones a las preguntas de test

PREGUNTA	SOLUCIÓN
1	a
2	b
3	a
4	a
5	d
6	b
7	d
8	a
9	b
10	b
11	c
12	d
13	a
14	c
15	c
16	b
17	a
18	d

10 Referencias

Cuando se referencia desde el documento alguna entrada de esta sección, se sigue la siguiente convención: si está dentro de la Bibliografía Básica, la entrada de número "n" se referencia como [BBn]. Por ejemplo, la primera entrada sería [BB1]. De forma similar con la Bibliografía Complementaria [BCn] o las Otras Referencias [ORn].

10.1 Bibliografía Básica [BBx]

1. "Probability, Random Variables and Stochastic Processes" de Athanasios Papoulis y S. Unnikrishna Pillai. Ed. McGraw-Hill.
2. "Data Science from Scratch: First Principles with Python" (2ª Edición) por Joel Grus. Ed. O'Reilly.
3. "Naked Statistics: Stripping the Dread from the Data" por Charles Wheelan. Ed. W. W. Norton & Company.
4. "Artificial Intelligence & Generative AI for Beginners: The Complete Guide" por David M. Patel.

10.2 Bibliografía Complementaria para ampliar el tema [BCx]

1. "Probabilistic Graphical Models" por Daphne Koller y Nir Friedman.
2. "Artificial Intelligence Programming. Case studies in Common Lisp" por Peter Norvig.
3. "Artificial intelligence programming" por Eugene Charniak, Christopher K. Riesbeck, Drew V. McDermott, James R. Meehan.
4. "Self-Organizing Maps (SOM)" por Teuvo Kohonen.
5. Pirámide DICS / D-I-K-W / de Rowley. "The wisdom hierarchy: representations of the DIKW hierarchy". Jennifer Rowley.
<https://journals.sagepub.com/doi/abs/10.1177/0165551506070706>.
6. Becerra, Cotino Hueso, L., León, I. P., Sánchez Acevedo, M. E., Torres vila, J., & Velandia Vega, J. (2018). **Derecho y big data** / Jairo Becerra y otros cinco; corrección de estilo John Fredy Guzmán Vargas. Universidad Católica de Colombia.

10.3 Otras Referencias [ORx]

1. Crecimiento de los datos. <https://www.statista.com/statistics/871513/worldwide-data-created/>
2. Perfiles de profesionales asociados a la ciencia de datos (data scientist, programmer, etc)
 - a) <https://www.analyticsinsight.net/top-10-data-science-job-profiles/>
 - b) <https://www.mygreatlearning.com/blog/different-data-science-jobs-roles-industry/>
3. MLops: <https://towardsdatascience.com/a-gentle-introduction-to-mlops-7d64a3e890ff>.
4. Data Drift y Model Drift: <https://www.datacamp.com/tutorial/understanding-data-drift-model-drift>.
5. OLTP vs OLAP: <https://aws.amazon.com/es/compare/the-difference-between-olap-and-oltp/>.
6. DAMA: <https://www.dama.org/cpages/home>, <https://keepcoding.io/blog/dama-en-data-management/>.
7. DCAM: <https://edmcouncil.org/frameworks/dcam/>.

8. MAMD: <https://administracionelectronica.gob.es/pae/Home/pae/Actualidad/pae/Noticias/Anio2023/Marzo/Noticia-2023-03-06-Metodologia-MAMD-El-Modelo-Alarcos-de-mejora-de-datos.html> , <https://dqteam.es/mamd/>.
9. AESIA: <https://administracionelectronica.gob.es/pae/Home/pae/Actualidad/pae/Noticias/Anio2023/Ago/Noticia-2023-08-29-Aprobado-estatuto-Agencia--Espanola-de-Supervision-Inteligencia-Artificial.html>, <https://www.hacienda.gob.es/Documentacion/Publico/GabineteMinistro/Notas%20Prensa/2023/CONSEJO-DE-MINISTROS/22-08-23-NP-CM-Estatutos-Agencia-Inteligencia-Artificial.pdf>.
10. Gobierno del Dato: <https://administracionelectronica.gob.es/pae/Home/pae/Actualidad/pae/Noticias/Anio2022/Mayo/Noticia-2022-05-25-Normas-tecnicas-alcanzar-Calidad-Dato-.html>, <https://datos.gob.es/es/documentacion/normas-tecnicas-para-un-correcto-gobierno-del-dato>.
11. Ciclo de vida de los datos. <https://www.ibm.com/topics/data-lifecycle-management>, <https://learn.microsoft.com/en-us/purview/get-started-with-data-lifecycle-management>, <https://www.ekon.es/blog/ciclo-de-vida-dato-sistemas-salud/>, <https://www.clase10.com/las-4-fases-de-la-gestion-del-ciclo-de-vida-de-los-datos/>.
12. Economía de los Datos, Emilio Ontiveros y Verónica López Sabater. Fundación Carolina. <https://www.fundacioncarolina.es/wp-content/uploads/2018/11/Libro-Economia-de-los-Datos-Ontiveros.pdf>.
13. ENIA: <https://www.lamoncloa.gob.es/presidente/actividades/Documents/2020/ENIA2B.pdf>.
14. "Validar datos en conjuntos de datos". <https://learn.microsoft.com/es-es/visualstudio/data-tools/validate-data-in-datasets?view=vs-2022&tabs=csharp>.
15. "Estándares para la economía del dato". UNE – Normalización Española. https://www.une.org/normalizacion/documentos/Estandares_economia_del_dato.pdf.
16. Procesos ETL/ELT: <https://www.holistics.io/books/setup-analytics/transforming-data-in-the-elt-paradigm/>, <https://www.geeksforgeeks.org/data-preprocessing-in-data-mining/>.
17. Tipos de análisis de datos: https://excelparatodos.com/estadistica-inferencial/?utm_content=cmp-true, <https://www.sciendat.es/cuales-son-los-4-tipos-de-ciencia-de-datos.html>, <https://www.makingscience.es/blog/4-tipos-de-analisis-de-datos-que-debes-conocer/>.
18. Modelado. <https://www.northware.mx/blog/que-es-un-modelo-de-analitica-de-datos/>, <https://www.thepowermba.com/es/blog/analisis-predictivo-que-es>.
19. Estrategias de validación: https://cienciadedatos.net/documentos/30_cross-validation_oneleaveout_bootstrap, <https://librovivodecienciadedatos.ai/desempe%C3%B1o-modelo.html>, <https://datos.gob.es/es/blog/como-se-si-mi-modelo-de-prediccion-es-realmente-bueno>.
20. MLops: <https://towardsdatascience.com/a-gentle-introduction-to-mlops-7d64a3e890ff>
21. Tipos de análisis estadísticos: <https://www.esic.edu/rethink/tecnologia/tipos-de-analisis-estadistico-de-datos>.
22. Gestión del ciclo de vida: Microsoft Purview. <https://learn.microsoft.com/en-us/purview/get-started-with-data-lifecycle-management>
23. Plataformas de ciencia de datos de Microsoft: <https://learn.microsoft.com/en-us/azure/architecture/data-science-process/platforms-and-tools>