



*Asociación Profesional de Cuerpos Superiores
de Sistemas y Tecnologías de la Información
de las Administraciones Públicas.*

Temario para la preparación de la Oposición al Cuerpo Superior de
Sistemas y Tecnologías de la Información de la Administración del
Estado.

TEMAS ESPECÍFICOS – BLOQUE B

II TECNOLOGÍA BÁSICA

Tema 75. Tecnologías y sistemas de explotación de datos: data lake, data warehouse, lakehouse, data fabric, data mesh, tecnologías para la protección de la confidencialidad (PET). Entornos de compartición de datos: espacios de datos, aspectos tecnológicos y organizativos.

AUTOR: Javier Esteve

REVISOR: Carlos Alonso

Creación: septiembre 2023

Actualización: septiembre
2003

ÍNDICE

1.1	TECNOLOGÍAS Y SISTEMAS DE EXPLOTACIÓN DE DATOS	5
1.1.1	APROXIMACIÓN AL ESTUDIO DE LOS SISTEMAS DE EXPLOTACIÓN DE DATOS	5
1.1.2	DATA LAKES	5
1.1.2.1	DEFINICIÓN DE DATA LAKE	5
1.1.2.2	CARACTERÍSTICAS GENERALES DE UN DATA LAKE.....	7
1.1.2.3	PARTES DE UN DATA LAKE	9
1.1.2.3.1	PARTES DE UN DATA LAKE.....	9
1.1.2.3.2	CAPA DE ALMACENAMIENTO Y TRANSFORMACIÓN	13
1.1.2.3.3	SISTEMAS PARA LA GOBERNANZA DEL DATO	17
1.1.2.3.4.	CATÁLOGO DE DATOS	19
1.1.2.3.5	FORMATOS DE FICHEROS EN UN <i>DATA LAKE</i>	22
1.1.2.3.6	SISTEMAS DE ALMACENAMIENTO	26
1.1.2.4	ARQUITECTURAS DE <i>DATA LAKES</i> POR TIPO DE INGESTA	29
1.1.2.4.1	EL TEOREMA CAP (CONSISTENCY, AVAILABILITY, PARTITION).....	29
1.1.2.4.2	ARQUITECTURA TRADICIONAL DE UN <i>DATA LAKE</i>	30
1.1.2.4.3	ARQUITECTURA LAMBDA.....	31
1.1.2.4.4	ARQUITECTURA KAPPA	33
1.1.2.5	DATA WAREHOUSES Y DATA LAKES	35
1.1.3	TENDENCIAS EN SISTEMAS DE EXPLOTACIÓN DE DATOS.....	40
1.1.3.1	DATA LAKEHOUSE.....	40
1.1.3.2	VIRTUALIZACIÓN DE DATOS	43
1.1.3.3	DATA MESH	47
1.1.3.4	GESTIÓN DE METADATOS ACTIVOS	49
1.1.3.5	USO DE GRAFOS DE CONOCIMIENTO (<i>KNOWLEDGE GRAPHS</i>)	50
1.1.3.6	CAPACIDADES DE AUTOSERVICIO (<i>SELF-SERVICE CAPABILITIES</i>)	52
1.1.3.7	CATÁLOGO AUMENTADO	53
1.1.3.8	DATAOPS, MODELOPS, MLOPS	55
1.1.3.9	DATA FABRIC.....	57
1.2	ESPACIOS DE DATOS	61
1.2.1	INTRODUCCIÓN.....	61
1.2.2	ESPACIOS DE DATOS Y VALORES EUROPEOS	61
1.2.3	PRINCIPALES ORGANIZACIONES, ALIANZAS Y PROYECTOS EUROPEOS PARA EL IMPULSO DE LOS ESPACIOS DE DATOS	62
1.2.3.1	ORGANIZACIONES	62
1.2.3.1.1	Asociación Gaia-X AISBL	62
1.2.3.1.2	International Data Spaces Association (IDSA)	66

1.2.3.1.3	FIWARE	66
1.2.3.2	ALIANZAS	66
1.2.3.2.1	DATA SPACE BUSINESS ALLIANCE (DSBA)	66
1.2.3.3	PROYECTOS.....	67
1.2.3.3.1	Open Dei.....	67
1.2.3.3.2	Gaia-X Federation Services.....	67
1.2.3.3.3	ESPACIO DE DATOS COMUNES EUROPEOS.....	68
1.2.3.3.4	DATA SPACE SUPPORT CENTRE (DSSC)	68
1.2.3.3.5	SIMPL.....	69
1.2.4	PRINCIPIOS DE DISEÑO DE ESPACIOS DE DATOS	69
1.2.4.1	PRINCIPIO DE DISEÑO 1: SOBERANÍA DEL DATO	70
1.2.4.2	PRINCIPIO DE DISEÑO 2: IGUALDAD DE CONDICIONES PARA LOS PARTICIPANTES	70
1.2.4.3	PRINCIPIO DE DISEÑO 3: INFRAESTRUCTURA DESCENTRALIZADA DE ESPACIOS DE DATOS.....	71
1.2.4.4	PRINCIPIO DE DISEÑO 4: ESTABLECIMIENTO DE UNA GOBERNANZA COMPARTIDA PÚBLICO-PRIVADA.....	72
1.2.5	COMPONENTES DE UN ESPACIO DE DATOS (<i>BUILDING BLOCKS</i>).....	73
1.3	TECNOLOGÍAS PET	75
1.3.1	TÉCNICAS DE ANONIMIZACIÓN Y PSEUDOANONIMIZACIÓN	76
1.3.1.1	K-ANONIMATO (<i>K-ANONYMITY</i>)	76
1.3.1.2	PRIVACIDAD DIFERENCIAL (<i>DIFFERENTIAL PRIVACY</i>).....	77
1.3.2	TÉCNICAS DE ENMASCARAMIENTO Y DE COMPUTACIÓN CONFIDENCIAL	78
1.3.2.1	CIFRADO HOMOMÓRFICO (<i>HOMOMORPHIC ENCRYPTION</i>)	78
1.3.2.2	<i>SECURE MULTIPARTY COMPUTATION</i> (SMC)	79
1.3.2.3	APRENDIZAJE FEDERADO (<i>FEDERATED LEARNING</i>)	80
1.3.2.4	ENTORNOS DE COMPUTACIÓN DE CONFIANZA (<i>TRUSTED EXECUTION ENVIRONMENTS - TEE</i>).....	81
1.3.2.5	CONSULTA DE INFORMACIÓN PRIVADA (<i>PRIVATE INFORMATION RETRIEVAL</i>)	82
1.3.2.6	GENERACIÓN DE DATOS SINTÉTICOS	82
1.3.3	ACCESO, COMUNICACIÓN Y ALMACENAMIENTO	83
1.3.3.1	TÉCNICAS PET APLICADAS A LAS COMUNICACIONES	83
1.3.3.1.1	CIFRADO EXTREMO A EXTREMO (<i>END TO END ENCRYPTION - E2EE</i>).....	83
1.3.3.1.2	<i>PROXY & ONION ROUTING</i>	84
1.3.3.2	ALMACENAMIENTO.....	85
1.3.3.2.1	ALMACENAMIENTO GARANTE DE LA CONFIDENCIALIDAD (<i>PRIVACY PRESERVING STORAGE- PPS</i>)	85
1.3.3.3	TÉCNICAS PET APLICADAS AL CONTROL DE ACCESO, AUTORIZACIÓN Y AUTENTICACIÓN	85
1.3.3.3.1	CREDENCIALES BASADAS EN ATRIBUTOS CON CONFIDENCIALIDAD MEJORADA (<i>PRIVACY-ENHANCING ATTRIBUTE-BASED CREDENTIALS - P-ABC</i>)	85
1.3.3.3.2	PRUEBA DE CONOCIMIENTO CERO (<i>ZERO KNOWLEDGE PROOF - ZKP</i>).....	87
2.	RESUMEN ESQUEMÁTICO.....	90

3. TEST.....	92
1.1 PREGUNTAS DE TEST.....	92
1.2 SOLUCIONES A LAS PREGUNTAS DE TEST	98
2. BIBLIOGRAFÍA	100
2.1 BIBLIOGRAFÍA BÁSICA	100
2.2 BIBLIOGRAFÍA PARA AMPLIAR EL TEMA.....	103

1 TECNOLOGÍAS Y SISTEMAS DE EXPLOTACIÓN DE DATOS: DATA LAKE, DATA WAREHOUSE, LAKEHOUSE, DATA FABRIC, DATA MESH

1.1 TECNOLOGÍAS Y SISTEMAS DE EXPLOTACIÓN DE DATOS

1.1.1 APROXIMACIÓN AL ESTUDIO DE LOS SISTEMAS DE EXPLOTACIÓN DE DATOS

Existe en la actualidad una gran variedad de sistemas para la explotación de los datos que una organización puede utilizar. De entre ellos, el *data lake* es, quizá, el más popular. No obstante, como se expondrá en el capítulo 1.1.3 *TENDENCIAS EN SISTEMAS DE EXPLOTACIÓN DE DATOS*, la tendencia actual de la industria es a ofrecer nuevos conceptos de sistemas de gestión de datos que complementan los *data lakes* mediante el uso de nuevas tecnologías para la gestión de los datos junto con nuevos enfoques operacionales. Estos nuevos conceptos permiten superar muchas de las carencias que presentan los *data lakes* pero, a pesar de sus limitaciones, los *data lakes* son aún la columna vertebral de los sistemas de explotación de datos en muchas organizaciones y se prevé que lo sigan siendo. Además, las nuevas tendencias no reemplazan necesariamente a los *data lakes* sino que en muchos casos los complementan o los transforman, por lo que el análisis de sus fundamentos sigue siendo necesario para comprender los mecanismos de explotación de datos vigentes.

Por esta razón, en el desarrollo de este tema se ha adoptado una aproximación en la que se abordan, por un lado, las características, los componentes y las distintas arquitecturas de los *data lakes* (apartado **¡Error! No se encuentra el origen de la referencia. ¡Error! No se encuentra el origen de la referencia.**) para después analizar de forma separada las nuevas tendencias (apartado 1.1.3 *TENDENCIAS EN SISTEMAS DE EXPLOTACIÓN DE DATOS*).

El tema se aborda desde una perspectiva principalmente técnica centrada en la descripción de los subsistemas que componen los sistemas de gestión de datos así como las tecnologías que se emplean.

1.1.2 DATA LAKES

1.1.2.1 DEFINICIÓN DE DATA LAKE

Gartner define el *data lake* como «una colección de recursos de almacenamiento donde se guardan distintos activos de datos que son copias exactas o casi exactas de los datos de origen [1]». Otras compañías como **Oracle** los definen como «un lugar donde almacenar datos estructurados y no estructurados y un método para organizar grandes volúmenes de datos muy diversos de distintas fuentes» [2].

La idea detrás del concepto de *data lake* es la de disponer de un repositorio donde copiar datos operativos de la organización (ventas, productos, CRM) y externos a ella (por ejemplo, datos extraídos de redes sociales), sea cual sea su naturaleza y con independencia del mecanismo de explotación que se vaya a aplicar (por ejemplo, consultas sobre datos agregados o modelado de datos mediante técnicas de inteligencia artificial). Los *data lakes* son sistemas generalistas que almacenan datos con poca o ninguna transformación porque cuentan con

herramientas para su procesamiento, transformación y catalogación, una vez que han sido ingeridos. De esta forma pueden ser explotados mediante múltiples técnicas de analítica de datos, inteligencia de negocio o *machine learning*.

Aunque en sentido estricto el término se refiere únicamente al repositorio de los datos, en la práctica, cuando se habla de un *data lake*, se suele hacer referencia a un sistema completo de explotación¹ que cuenta con los siguientes componentes:




Ilustración 1. Arquitectura general de un data lake con sus partes principales. En data lakes, el paradigma ETL (Extract/ Transform/ Load) se sustituye por el ELT (Extract/ Load/ Transform) en el que la transformación o transformaciones siguen a la carga de los datos en el sistema.

1. Capa de ingestión.

Es la capa encargada de recoger datos tanto de la organización como externos y copiarlos en una zona del *data lake* destinada a almacenar datos recién ingeridos. En un *data lake* los datos se almacenan tras la ingesta típicamente tras poca o ninguna transformación.

2. Capa de almacenamiento y transformación.

Es el repositorio de datos propiamente dicho. Dispone de distintas zonas de almacenamiento y de herramientas de transformación y agregación de datos. Cada zona de la capa de almacenamiento se destina a almacenar datos en sus diferentes estados de transformación y madurez: desde los datos recién ingeridos a los datos destinados a su consumo.

Capa de gobierno del dato, seguridad y auditoría. Compuesta por herramientas para la gestión de los datos, la gestión de la calidad, la generación de catálogos, el control de acceso y la auditoría.

¹ El término oficioso acuñado para los sistemas de explotación de datos es el de *sistemas de gestión de datos (Data Management Systems)* por lo que los *benchmarking* de las soluciones de los distintos proveedores se encuentran bajo esta segunda denominación. El *data lake* sería, en sentido amplio, un tipo de sistema de gestión de datos basado en la descarga de datos en un repositorio para su posterior explotación. En este documento se usan indistintamente los términos *sistema de gestión de datos* y *sistema de explotación de datos*.

3. Capa de herramientas de consulta y desarrollo.

La última capa la constituyen las herramientas de consulta de datos y de desarrollo. Esta capa está constituida por herramientas muy variadas: desde máquinas de consulta (*query engines*) SQL hasta software para la elaboración de informes visuales pasando por herramientas de desarrollo para elaborar modelos de Machine learning o aplicación de técnicas de ciencia de datos en lenguajes como Python o R.

1.1.2.2 CARACTERÍSTICAS GENERALES DE UN DATA LAKE

Las características de un *data lake* están estrechamente ligadas a la naturaleza de la organización que lo explota y a su finalidad. Por esta razón, no existen de hecho dos *data lakes* iguales, pero se pueden extraer unas características comunes que se describen a continuación:

1. Soporte para el almacenamiento y la catalogación de datos de cualquier formato y estructura.

La capacidad de almacenar datos independientemente de su formato es una de las principales aportaciones de los *data lakes*. Permite a las organizaciones disponer en un solo lugar todos los datos susceptibles de ser explotados. Si no se dispusiera de un *data lake*, la organización precisaría de múltiples repositorios aislados (silos) especializados en el tipo de dato que se va a explotar con resultado de una dispersión de la analítica de los datos, sin visión única global y, probablemente, con duplicidad en la copia de datos y sistemas para su tratamiento y explotación.

Por otro lado, esta flexibilidad en el tipo de datos que un *data lake* puede aceptar lo habilita para integrar cualquier herramienta de explotación de datos: no sólo las relativas a analítica y *machine learning* que pueden requerir datos semi y no estructurados, sino también los clásicos *data warehouses* que trabajan sobre datos fuertemente estructurados destinados a la analítica de negocio.

La siguiente tabla resume las características de los datos soportados por un *data lake*:

Tipo de datos	Definición	Ejemplo
Datos estructurados	Datos organizados de manera sistemática y coherente con un formato específico predeterminado y fijo. Estos datos se dividen en campos con etiquetas que describen el tipo de información que contienen.	Filas de una tabla en una base de datos relacional.
Datos semiestructurados	A caballo entre los datos estructurados y los datos no estructurados. Disponen de una estructura, jerarquía y organización que permiten su interpretación semántica, pero esta estructura no es fija. Para su interpretación se emplean etiquetas.	CSV, JSON, XML, ficheros de log.
Datos no estructurados	Pueden disponer de estructura interna pero es desconocida por lo que su aprovechamiento requiere de análisis que permitan conocer su organización.	Ficheros multimedia (audio, vídeo), ficheros de texto, PDF.

Tabla 1. Tipos de datos almacenados en un *data lake*.

2. Almacenamiento de datos en zonas.

Asumido que en un *data lake* los datos se almacenan en primera instancia tras la ingestión con poca o ninguna transformación previa, existe la necesidad de realizar trabajos adicionales para que los datos sean aprovechables en un entorno de producción. Si en el caso de los *data warehouses* el procedimiento de transformación de los datos se realizaba durante la ingesta y se cargaban los datos ya transformados (proceso ETL o Extraction/Transformation/Load), en el caso de un *data lake* se habla de procesos ELT o de Extraction/Load/Transformation, en los que los datos se transforman **dentro** del *data lake* una vez completada la extracción y la carga.

No obstante, los datos del *data lake* no se suelen someter a un solo proceso de transformación sino a varios; tras cada transformación se obtienen conjuntos de datos con metadatos cada vez más maduros. Por esta razón, es común disponer dentro de los *data lakes* de distintas zonas de almacenamiento conforme los datos inicialmente ingeridos son sometidos a diferentes transformaciones y agregaciones.

3. Gestión y procesamiento de datos masivos.

Se entiende por datos masivos (*Big Data*) aquellos activos de datos tan voluminosos, cambiantes y variados que requieren para su explotación tecnologías específicas para su gestión y explotación. En concreto, las tecnologías de Big Data deben ser capaces de soportar las famosas "Vs" del *Big Data*:

Volumen: los *data lakes* aceptan grandes volúmenes de datos por lo que normalmente se construyen sobre un sistema de ficheros distribuido escalable horizontalmente. Típicamente, la solución adoptada era Hadoop Distributed File System (HDFS), pero existen otras alternativas tanto para *data lakes on premises* como en la nube, como se verá.

Variedad. Ya mencionado anteriormente: los *data lakes* tienen como objetivo servir de repositorio para datos estructurados, semiestructurados y no estructurados.

Velocidad. Un *data lake* está preparado para la ingestión y procesamiento de datos a altas velocidades y en tiempo real. Para ello ha surgido un ecosistema de herramientas (Spark, Kafka, Flink) que permiten la ingesta y la transformación a las velocidades requeridas por las aplicaciones o incluso, si se requiere, en tiempo real.

Veracidad: Los *data lakes* están provistos de herramientas para el gobierno del dato de forma que se pueda garantizar en todo momento su calidad, su linaje, su procedencia y que permitan gestionar su ciclo de vida. De esta manera se facilita el conocimiento de las características de los datos posibilitando veracidad.

4. Adherencia a marcos normativos

Los *data lakes* deben incorporar herramientas para satisfacer los requisitos de seguridad y la normativa que sea de aplicación en el tratamiento de los datos, sea ésta el ENS, la normativa de protección de datos personales vigente o la normativa sectorial relativa a los datos que se van a albergar en el *data lake*, como podría ser la normativa referente a datos de salud si se trata de un *data lake* sanitario.

5. Desacoplamiento entre almacenamiento y cómputo²

² En sentido estricto, no todos los *data lakes* separan almacenamiento y cómputo. Por ejemplo, Hadoop (y con Hadoop, la primera generación de *data lakes*) asume que ambas tareas están sustentadas por el mismo *cluster* (*Hadoop File System* para almacenamiento y *MapReduce* para procesamiento). Pero

Frente a los tradicionales *data warehouses*, en los que almacenamiento y cómputo se encuentran estrechamente acoplados, los modernos *data lakes* ofrecen la posibilidad de desacoplar ambos tipos de recursos con numerosos beneficios para el procesamiento y análisis de datos a gran escala. El mundo de los *data lakes* es el mundo de los *clusters*: *clusters* para almacenamiento de datos en sistemas de ficheros distribuidos (por ejemplo, Hadoop File System) o en sistemas de almacenamiento basados en objetos (por ejemplo, Amazon S3), *clusters* para ingesta, *clusters* para procesamiento de datos, *clusters* para analítica; todos separados lógicamente y físicamente según el diseño que se haya realizado. Esto aporta importantes beneficios al sistema global. En concreto:

Escalabilidad: Al separar el almacenamiento de los datos de su procesamiento, es posible escalar cada uno de forma independiente según sea necesario. Esto es clave para manejar grandes volúmenes de datos de manera eficiente y económica principalmente si se tiene en cuenta que los recursos de almacenamiento suelen ser más económicos que los de cómputo.

Mayor flexibilidad³: La separación de almacenamiento y cómputo permite utilizar diferentes herramientas y servicios de procesamiento de datos sin cambiar la infraestructura de almacenamiento subyacente. Dicho de otra forma, permite actualizar el *data lake* aprovechando las últimas tecnologías y enfoques de análisis de datos sin realizar costosas migraciones.

Rendimiento optimizado: Al mantener los datos en un almacenamiento duradero y distribuido es posible acceder a ellos de manera eficiente y aprovechar herramientas de procesamiento de datos altamente distribuidas, como Apache Spark. Esto permite un procesamiento paralelo y distribuido que mejora el rendimiento de los procesos de transformación, las consultas y el análisis de los datos.

1.1.2.3 PARTES DE UN DATA LAKE

A continuación se describen con algo más de detalle los subsistemas de un data lake:

1.1.2.3.1 PARTES DE UN DATA LAKE

Es la capa encargada de recoger datos tanto de los sistemas de información de la organización como de los sistemas externos a ella y copiarlos en el *data lake* donde, una vez almacenados, pueden ser procesados para su explotación. Recuérdese que, por regla general, los datos en un *data lake* se transforman después de la ingesta.

en la actualidad, la aparición de nuevos marcos de procesamiento de datos, como Apache Spark, y, sobre todo, la computación en la nube, permiten separar los repositorios de datos (sean sistemas de ficheros distribuidos o sean sistemas de almacenamiento basados en objetos) de las aplicaciones que procesan esos mismos datos, haciendo más escalables y flexibles las arquitecturas de los *data lakes*.

³ En este tema se entenderá el término flexibilidad según el contexto bien como la capacidad de un sistema para adaptarse a cambios externos, bien como la capacidad para ofrecer una gran variedad de productos sin requerir costosas transformaciones. Los *data lakes* se pueden considerar flexibles en ambos sentidos.

En un *data lake*, los datos recién ingeridos suelen tener como destino una zona específica para su descarga en bruto denominada "zona de aterrizaje" (*Landing Zone*), "zona bronce" (*Bronze Zone*) o simplemente "zona de datos en bruto" (*Raw Zone*).

Tecnologías de gestión de corrientes de datos (*data streams*)

Una corriente de datos (*data stream*) es un flujo continuo de datos sin principio ni final (sin límites). Es lo contrario a un lote de datos (*Data Batch*), que tiene límites (principio y fin) y cuya transmisión se encuentra programada periódicamente. Para la creación y gestión de *data streams*, los *data lakes* se apoyan en una serie de productos tecnológicos que son de uso habitual, no sólo en la ingesta, sino en cualquier operación de procesamiento de datos entre zonas del *data lake* que requiera transformaciones y agregaciones. Por su interés y para la mejor comprensión de los subsistemas de un *data lake* se comentan brevemente.

Las tecnologías de *data stream* se pueden agrupar en dos categorías:

i. Tecnologías de gestión de flujos de datos (*Dataflow*)

Se emplean para el traslado de datos de un sitio a otro, tanto desde sistemas externos al *data lake* como entre zonas de almacenamiento internas. Reciben muchas contribuciones de datos en su entrada que trasladan a su destino, donde cada destinatario los recibe para su posterior procesamiento o simplemente para descargarlos. En ocasiones se trata de sistemas de mensajería en los que los datos van encapsulados en mensajes remitidos por las fuentes y que los consumidores extraen de las colas de mensajes, leen y procesan. En todo caso, estos sistemas deben ofrecer funcionalidades para el *buffering* de los datos, la compresión y el cifrado.

Ejemplos Open Source de estos sistemas son Apache NiFi, Apache Kafka, Apache Flume, Apache Storm o Apache Flink.

ii. Tecnologías de procesamiento de corrientes de datos (*stream processing*)

El procesamiento de corrientes de datos o *stream Processing* es una técnica de manipulación de datos que recibe como entrada un flujo o *stream* de datos para su transformación o agregación en tiempo real. Una vez procesado el flujo, lo entrega a otra aplicación, a un repositorio de datos o a otra instancia de procesamiento de flujos.

La diferencia entre transformación y agregación está en el resultado del procesamiento y los elementos necesarios para la operación: una transformación se aplica por igual a todos y cada uno de los elementos del *stream* (por ejemplo, una operación de normalizado). Por el contrario, las agregaciones se aplican a conjuntos de elementos (por ejemplo, seleccionar los 5 valores más altos de entre los elementos recibidos en un periodo de 10 minutos o calcular su media).

Los subsistemas que implementan tecnologías de *stream Processing* son fundamentales en un *data lake* y se aplican cada vez que los datos requieren alguna transformación o agregación dentro del *data lake*. Aparte de procesar y agregar datos con la mayor eficiencia posible y en tiempo real, se deben generar metadatos tras cada transformación y agregación para garantizar el registro del linaje y la procedencia de los datos en todo momento, por lo que resultan claves también para las tareas de gobierno del dato.

Soluciones comunes Open Source para procesamiento de flujos de datos son Apache Spark *stream*, Apache Kafka *streams* o Apache Storm.

Una característica de los *streams* de datos en un *data lake* es que disponen de cierto grado de persistencia; esto es, almacenan y retienen los datos que pasan por la corriente de

datos un periodo de tiempo determinado por la configuración del cluster que los alberga (por ejemplo, una semana). Esta característica permite, caso de que se presentase algún problema tras la ingesta, volver a recuperar los datos **desde** el *stream*, evitando realizar de nuevo la ingesta de los datos desde la fuente.

No siempre está clara la diferencia entre la gestión de flujos de datos (*Dataflow*) y el procesamiento de flujos (*stream Processing*) porque las herramientas de gestión de flujos pueden ofrecer funcionalidades de procesamiento y recíprocamente. La diferencia es una cuestión de especialización y de función primaria del sistema. Típicamente, para la ingesta de datos, un *data lake* usa ambos tipos de tecnologías: un subsistema de gestión de flujos de datos de entrada para traer los datos desde las fuentes hasta el *data lake* (por ejemplo, Apache Kafka) y un subsistema de procesamiento de *streams* (por ejemplo, Apache Spark *stream*) que se acopla a la salida del anterior para transformar o agregar datos de alguna forma antes de depositarlos en la zona de aterrizaje del *data lake*.

Las características clave de sistemas que implementan estas tecnologías son:

Alta disponibilidad.

Throughput de datos que el sistema es capaz de ingerir y, si procede, procesar en tiempo real. Lógicamente, estos sistemas deben tener capacidad para absorber grandes cantidades de datos para satisfacer la necesidad de ingestión en los momentos de pico de envío de datos.

Durabilidad de los datos y tolerancia a fallos. Los datos que se colocan en un *stream* se mantienen en el tiempo de forma que puedan recuperarse si ocurriese algún fallo en alguno de los sistemas.

Baja latencia. Crítico para sistemas que trabajan en tiempo real.

Mantenimiento de datos históricos y capacidad de reenvío: relacionado con la durabilidad de los datos. Debe ser posible solicitar datos históricos que pasaron por el *stream* para evitar que tengan que ser extraídos de nuevo de sus fuentes en el caso de que se necesite reprocesarlos.

Como ocurre con otros subsistemas del *data lake*, los sistemas encargados de gestionar corrientes de datos son sistemas distribuidos escalables horizontalmente que se instalan en *clusters* con múltiples nodos capaces de ofrecer las características mencionadas.

Mecanismos de ingesta de datos: por lotes y por flujos

En sentido estricto, existen dos mecanismos no excluyentes para la ingestión de datos en un *data lake*: ingestión basada en lotes e ingestión basada en flujos de datos. Además, algunos *data lakes* ofrecen la posibilidad de un tratamiento integrado de ambos tipos de ingesta. A continuación, se describen.

i. Ingestión de datos basada en lotes (*Batch*)

Se trata del mecanismo clásico de ingestión. La extracción y carga desde los sistemas operacionales de la organización hasta el *data lake* se programa a intervalos regulares en lotes de datos. Se emplea para casos de uso en que no resulta crítico explotar los datos en tiempo real. Típicos escenarios son los datos que se utilizan para elaborar informes periódicos sobre la marcha del negocio.

Este tipo de ingestión puede no precisar flujos de datos, al menos para la ingesta.

ii. Ingestión basada en flujos de datos (*Dataflow*)

Linaje, procedencia y gobierno del dato

Linaje (*Data Lineage*), procedencia (*Data Provenance*) y gobierno o gobernanza del dato (*Data Governance*) son conceptos clave en un *data lake* que se hayan estrechamente relacionados y se apoyan unos en otros.

- El **linaje de los datos** es el proceso de registro de los flujos de datos a lo largo del tiempo, proporcionando una clara comprensión sobre dónde se han originado, cómo se han procesado y transformado, y su destino final. El linaje de los datos define por tanto el origen y los procesos a los que se ha sometido un conjunto de datos concreto. El registro del linaje de los datos es una parte esencial del catálogo de datos de un *data lake*.
- La **procedencia de los datos** se refiere específicamente al origen de los datos en primera instancia y, típicamente, forma parte del linaje de los datos.
- El **Gobierno del dato** es la función de la organización responsable de la rendición de cuentas sobre el uso eficaz, eficiente y aceptable de los datos durante su ciclo de vida [3]. El registro del linaje y la procedencia son tareas críticas para el gobierno del dato, entre otras cosas, porque a partir de ellos se elaboran informes sobre el tratamiento de los datos que son obligatorios en normativas como la de protección de datos.

En este mecanismo existen productores de datos externos al *data lake* que envían al sistema los datos en el momento de su generación a través de un flujo creado específicamente para la ingesta. Se emplea en áreas en las que es necesario disponer de datos actualizados al instante como, por ejemplo, localizaciones de una flota de vehículos, precios del mercado de valores o negocios con sistemas de precios dinámicos (por ejemplo, de hoteles o líneas aéreas).

La estructura de estos sistemas de ingestión se compone típicamente de un *Data Flow* de entrada consistente en un sistema de mensajería al que las diferentes fuentes ("*producers*" en el argot de los *data lakes*) envían sus datos encapsulados en mensajes desde las fuentes de los datos. Los consumidores se conectan en el destino al servicio de mensajería y leen el contenido de los mensajes recibidos descargándolo en el *data lake*. Estos consumidores pueden ser sistemas de procesamiento de corrientes de datos (*stream Processing*) que realizan alguna transformación o agregación en los datos antes de la descarga o pueden ser agentes que directamente toman los datos encapsulados en los mensajes y los descargan.

iii. Ingestión simultánea por flujos de datos y por lotes

Existe un tercer tipo de ingesta que consiste en ingerir por medio de flujos de datos (*Dataflow*) todo tipo de datos, tanto lotes periódicos como flujos de datos en tiempo real. Si se emplea este mecanismo, todos los datos se introducen en el flujo de datos de ingestión. Al final, que un dato pertenezca a un lote o a una fuente de datos generada en tiempo real es indiferente para un flujo de datos. La diferencia estará en cuándo se inyectan los datos en el flujo usado para la ingestión, que en un caso será en tiempo real y en otro según una programación de ingesta periódica (lotes). Este mecanismo se volverá a ver cuando se describan las arquitecturas de los *data lakes* porque es el mecanismo empleado en la arquitectura Kappa.

Sea cual sea el mecanismo de ingestión que se emplee, los datos son finalmente descargados en la zona común de datos en bruto del *data lake*. Por otro lado, los mecanismos de ingestión no son excluyentes. Los *data lakes* pueden disponer tanto de mecanismos de ingesta por lotes como de ingesta por flujo de datos.




Ilustración 2. Mecanismos de ingesta en un data lake

1.1.2.3.2 CAPA DE ALMACENAMIENTO Y TRANSFORMACIÓN

En la capa de almacenamiento y transformación se almacenan y procesan los datos por zonas para su explotación.

Como ocurre con tantas otras características de un *data lake*, no existen reglas definidas sobre cuántas zonas de almacenamiento debe poseer. Típicamente se considera una buena práctica disponer al menos de tres: una zona bronce (de la que ya se ha hablado al ver la capa de ingesta), una zona plata y una zona oro. En algunos casos se añade también una zona de experimentación (*sandbox*) y una adicional para almacenamiento de datos especialmente sensibles. Los nombres bronce, plata y oro en todo caso no son nombres oficiales, sólo de uso común, pudiéndose encontrar también otras denominaciones como las mostradas en la siguiente tabla:

Nombre	Nombre alternativo
Zona bronce (Bronze)	Zona de datos en bruto (<i>raw zone</i>), zona de aterrizaje (<i>landing zone</i>).
Zona plata (Silver)	Zona de datos limpios (<i>cleansed</i>), zona de refinado (<i>refined</i>), zona de preparación.

Zona oro (Gold)	Zona de presentación (<i>performance</i>), zona de datos curados (<i>curated</i>), zona de modelado de datos (<i>data model</i>), zona de transformación.
-----------------	---

Tabla 2. Nombres de las zonas de un data lake

Como se ha comentado en apartados anteriores, la zona bronce es el repositorio donde se vuelcan los datos inmediatamente después de la ingesta, habitualmente tras poca o ninguna transformación. Por su parte, la zona plata es un repositorio donde se almacenan datos tomados de la zona bronce tras someterlos a un proceso de refinado. Por último, la zona oro es el destino final de los datos, el lugar donde se almacenan limpios y empaquetados tras someter los datos de la zona plata a los procesados que se considere suficientes para ofrecerlos a los usuarios del sistema por medio de un catálogo de productos de datos disponibles. Procesados típicos de los datos que pasan a la zona oro son la agregación, las uniones de conjuntos de datos o el modelado de datos.

Como se puede ver en la Ilustración 3, los datos van pasando de una zona a otra conforme




Ilustración 3. Zonas típicas de un data lake para almacenamiento y transformación

se procesan, ofreciendo cada vez una mayor madurez hasta que finalmente, en la zona oro, alcanzan el estado adecuado para su verdadero propósito: servir de herramienta para la toma de decisiones en la organización.

El concepto de tubería de datos (*Data Pipeline*) en un *data lake*

Una tubería de datos es un flujo de datos extremo a extremo que va desde la fuente original de los datos externa al *data lake* hasta su puesta a disposición de los usuarios, normalmente en la zona oro. Es decir, es un flujo de datos en el que se intercalan procesos que convierten datos de fuera y dentro de la organización en un producto aprovechable. Durante el camino, los datos se descargarán en el *data lake*, se refinarán, se transformarán y se agregarán, hasta alcanzar el estado y la madurez necesaria para poder ser analizados mediante distintas tecnologías de analítica de negocio o de datos.

Las *Data Pipelines* constituyen el verdadero producto que un *data lake* ofrece a sus usuarios: un conjunto de operaciones y procesos extremo a extremo que integra todas las actuaciones necesarias para convertir datos que por sí solos poseen una validez limitada para la toma de decisiones en datos adecuados para en conocimiento de la organización y su contexto de negocio. Para crear *Data Pipelines* se utilizan tecnologías de gestión de

data streams como las mencionadas al explicar la ingesta de datos. En función del estado de transformación en que se encuentren los datos, se almacenarán en la zona del *data lake* que corresponda. Los *data lakes* suelen contar con herramientas de monitorización que registran e informan del estado de todas las acciones que forman parte de las tuberías implementadas.

Pero, en un *data lake*, no todos los datos ingeridos forman parte de una tubería de datos extremo a extremo. Muchos, de hecho, la mayoría, permanecen almacenados y catalogados en distintas zonas y en distintos estados de transformación.

Dicho de otra forma: no todos los datos ingeridos son sometidos a un proceso de limpieza y almacenados en la zona plata; de la misma manera, no todos los datos de la zona plata son procesados y ofrecidos a los usuarios en la zona oro. La preparación, el diseño e implementación de los procesos de limpieza y de curación de los datos requiere esfuerzo y dedicación por parte de los ingenieros de datos e implica la utilización de recursos de almacenamiento y cómputo, por lo que sólo una parte de los datos ingeridos serán finalmente transformados en productos útiles para los usuarios finales.




Ilustración 4. Tubería de datos en un data lake (Data Pipeline)

La zona bronce

Ya se han mencionado las principales funciones de la zona bronce al hablar sobre la capa de ingesta. La clave del funcionamiento de esta zona es que los datos se almacenan tras la ingesta tal y como vienen. Como mucho, puede abordarse un proceso de agregación de datos (por ejemplo, agrupar datos de ventas en días, semanas y meses), pero es un principio de aplicación general en *data lakes* no realizar transformaciones ni corregir errores antes de almacenar los datos en la zona bronce: los datos operacionales y los importados de fuentes externas a la organización deberían ser idénticos a los que se almacenan en la zona de aterrizaje del *data lake*.

Por lo demás, lo prioritario cuando se realizan operaciones sobre la zona bronce es la velocidad: ingerir los datos con el menor retraso posible. Si los datos presentan errores, ya habrá tiempo para corregirlos. Téngase en cuenta que no todos los datos del *data lake* se someten a un proceso de limpieza pero sí todos tienen que almacenarse en primera instancia en la zona bronce por lo que lograr la máxima eficiencia en la operación de ingesta es crítico.

La zona plata

La zona plata se rellena con datos procedentes de la zona bronce a los que se ha sometido a un proceso de refinado (*refinement*) o preparación. El objetivo final del refinamiento es aportar a los datos la calidad necesaria para someterlos con posterioridad a procesos de analítica con garantías suficientes.

Típicas operaciones de refinamiento de los datos son:

- iv. Limpieza de los datos (Data cleansing) como por ejemplo, eliminación de errores y valores no válidos (fuera de rango), eliminación de duplicados, gestión de anomalías y gestión de valores ausentes.
- v. Normalización de datos y de estructuras. Aplicable cuando diferentes fuentes reportan datos con distintas escalas, nombres de variables o estructuras.

Por ejemplo, podrían recibirse datos de información ambiental (temperatura, humedad, presión, etc.) de diferentes modelos de sensor. Un modelo puede enviar un registro consistente en una estructura JSON en el que el campo con la temperatura se llama "TEMP" en vez de "Temp"; podría enviar los datos de temperatura en °F en vez de en °C; y podría ocurrir que la propia estructura JSON del registro que reciba sea distinta en función del modelo de sensor que envió el registro. En estos casos se debe optar por transformar todos los registros en una estructura JSON común con etiquetas comunes para los valores y que estos se registren en la misma escala como parte de los trabajos de refinamiento.
- vi. Enriquecimiento de los datos. Consiste en añadir información a los datos. Por ejemplo, supongamos en el caso anterior que los sensores envían información sobre su identificador y que se dispone de información de otra fuente sobre su ubicación. En este caso podría añadirse a la estructura JSON la longitud y latitud del lugar donde está situado el sensor con vistas a la investigación analítica.
- vii. Validación. Confirmación de la consistencia y calidad del dato una vez refinado.
- viii. Publicación. Publicación de los metadatos en un catálogo que dé visibilidad a los datos refinados.




Ilustración 5. Actividades de refinamiento de datos

Aunque la zona especialmente dedicada a la explotación de los datos mediante cualquier tipo de analítica es la zona oro, los datos de la zona plata disponen ya de la calidad suficiente como para su explotación mediante tecnologías ciencia de datos o *Machine learning*. Sin embargo, lo habitual es que aún no se encuentran maduras para la analítica de negocio, que requiere agregaciones de datos y creación de estructuras complejas para

las consultas multidimensionales, como se verá en el apartado sobre la integración de los *data lakes* con los *data warehouses* (ver 1.1.2.5)

La zona oro

Los datos de la zona plata han sido procesados para su refinado de forma que se garantice la calidad, pero aún no han experimentado apenas transformaciones sustanciales más allá de las estrictamente imprescindibles para garantizar su refinamiento. El último paso es ponerlos a disposición de los usuarios finales según los requerimientos establecidos por analistas de negocio, científicos de datos y expertos en inteligencia artificial, tras analizar las necesidades de negocio. Cada grupo tiene sus propios requisitos, pero la ventaja del *data lake* es que da a cada uno la oportunidad de transformar los datos de la zona plata según su necesidad y la del negocio.

Típicas operaciones a las que se somete a los datos de la zona plata antes de pasar a la zona oro son:

- Uniones de conjuntos de datos (*joining*).
- Agregaciones de datos.
- Modelado de datos (IA y ML).

Lógicamente, también puede someterse los datos a una combinación de las acciones anteriores. Una vez que han sido mezclados, agregados y transformados, pasan a estar a disposición de los usuarios finales tras su publicación en un catálogo de productos de datos.

Mención especial merece la puesta a disposición de los datos de negocio en un *data warehouse* para consultas de analistas de negocio a partir de los cuales se crearán visualizaciones, cuadros de mando, gráficas e informes basados en consultas multidimensionales (ver 1.1.2.5).

1.1.2.3.3 SISTEMAS PARA LA GOBERNANZA DEL DATO

Según la norma UNE 077 de Gobierno del Dato [3] se define el Gobierno o Gobernanza del Dato como «la función organizativa responsable de rendir cuentas sobre el uso eficaz, eficiente y aceptable de los datos por parte de la organización». En otras palabras, el Gobierno del Dato es una unidad organizativa (función) responsable de garantizar que la explotación (su uso) de los datos se realiza de una forma:

- **Eficaz:** que cumple con la finalidad establecida. La eficacia está directamente relacionada con la calidad de los datos.
- **Eficiente:** que se realiza con los recursos estrictamente necesarios. Por ejemplo, sin duplicar *pipelines*, almacenar los mismos conjuntos de datos repetidas veces, ni perder el control de los datos ingeridos.
- **Aceptable:** con cumplimiento de la normativa y las políticas corporativas; por ejemplo, garantizando un uso acorde con la normativa de protección de datos y la política de confidencialidad de la organización.

Nótese que queda fuera del ámbito de la gobernanza la gestión directa de los datos o la gestión de calidad, aunque se trate de actividades estrechamente relacionadas. La gobernanza se limita a establecer y garantizar el cumplimiento del marco en que se desenvuelve el uso de los datos y de establecer mecanismos para la rendición de cuentas.

Los sistemas (*servicios, infraestructuras y aplicaciones*, en la terminología UNE 077) que dan soporte a esta actividad constituyen uno de los siete componentes de la Gobernanza

del Dato según dicha norma [3]. Sin ellos no sería posible la implantación de un marco de gobernanza.

A pesar de lo anterior, la norma UNE sobre el Gobierno del Dato no especifica ni los sistemas ni las funcionalidades que dan soporte a la función de Gobierno del Dato. Sin embargo, se puede extraer un conjunto de subsistemas que caen dentro del ámbito de la función definida por la norma UNE tomando como punto de partida:

- Qué subsistemas en un sistema de gestión de datos sirven de apoyo a para garantizar el uso *eficaz, eficiente y aceptable* de los datos.
- La oferta actual de los principales suministradores de sistemas para la gobernanza del dato.

Téngase en cuenta en todo caso que en este apartado no se describe cómo implementar la gobernanza del dato sino describir los sistemas que le dan soporte. Dicho esto, los subsistemas esenciales para la gobernanza en un *data lake* son:

1. Catálogo de datos

De acuerdo con Gartner, un catálogo de datos es un sistema que «crea y mantiene un inventario de activos de datos mediante el descubrimiento, la descripción y la organización de conjuntos de datos. Permite a los consumidores de datos encontrar y comprender conjuntos de datos relevantes para extraer valor de negocio de los datos.»

De la definición se deduce que un catálogo de datos va más allá del mero inventario de conjuntos de datos: los modernos catálogos cuentan también con herramientas para el descubrimiento (incluida la localización) y la caracterización de los datos mediante metadatos.

Por su parte, los modernos catálogos trascienden las plataformas de gestión de datos: su misión es centralizar el inventario de datos disponibles de la organización aunque se encuentren repartidos por múltiples sistemas y plataformas de gestión de datos o incluso en un repositorio de datos en la nube.

Por su importancia se describen con más detalle sus características en el apartado 1.1.2.3.4.

2. Control de acceso a los datos

Deben existir herramientas que gestionen el control de acceso a los datos basado en roles (RBAC) y basado en atributos (ABAC) en función de la confidencialidad de los datos.

3. Aplicación de marcos normativos y políticas corporativas

Esta funcionalidad permite aplicar marcos normativos (como por ejemplo, la normativa de protección de datos) y políticas corporativas (por ejemplo, política de confidencialidad) sobre los datos disponibles en el catálogo. Implica realizar operaciones como enmascarar los datos de manera automática. El enmascaramiento puede realizarse mediante algún tipo de procesamiento basado en tecnologías de mejora de la privacidad (*Privacy Enhancement Technologies*). De esta forma se permite acceder aunque sólo se parcialmente a conjuntos de datos que de otra forma tendrían vedado el acceso.

4. Auditoría e informes

Estas herramientas permiten auditar el uso que se está dando a los datos. En concreto:

- El linaje de los datos: procesados de los datos desde su origen hasta su destino, necesario en aplicación de determinadas normativas.
- Quién accede a los datos, cuándo y de qué manera.

Una buena herramienta de Gobierno del Dato permite obtener informes automatizados sobre el uso de los datos.

5. Monitorización

Esta funcionalidad permite realizar un seguimiento del estado y las prestaciones de los flujos de procesamiento y transformación de los datos (*Data Pipelines*) desde la ingesta a su puesta a disposición en la zona oro. Permite identificar problemas y obtener indicadores de prestaciones de los sistemas y de la calidad de los datos, su disponibilidad, consumo y seguridad, así como la recepción de alertas y notificaciones caso de que se presente alguna anomalía o algún incidente en la plataforma.

Los sistemas que dan soporte a la aplicación de marcos de gobernanza constituyen un área que está experimentando una fuerte evolución en los últimos años por considerarse una de las principales deficiencias de los sistemas de explotación de datos (en particular, de los *data lakes*) y en la que los suministradores están tratando de diferenciarse, como se verá en el apartado 1.1.3 TENDENCIAS EN SISTEMAS DE EXPLOTACIÓN DE DATOS.

1.1.2.3.4. CATÁLOGO DE DATOS

En esencia, un catálogo de datos es una base de datos de metadatos que cuenta con herramientas para el rastreo y localización de activos de datos, la extracción de metadatos de los activos localizados y con un motor de búsqueda de conjuntos de datos que actúa sobre los metadatos generados.




Ilustración 6. Componentes de un catálogo de datos a muy alto nivel.

Las funcionalidades nucleares de los catálogos de datos se pueden agrupar en tres grupos [4]:

1. Funcionalidades para la elaboración del inventario de activos de datos

El primer paso en la elaboración del catálogo es la construcción del inventario para lo que son necesarias funcionalidades para la detección de los datos, su localización y para la elaboración de metadatos que describan los activos localizados con todas sus transformaciones y agregaciones. Todo esto, a ser

posible, de manera automatizada. Además, los metadatos se deben mostrar mediante interfaces gráficas.

Visto esto, las capacidades clave para la elaboración del inventario son:

- Capacidad de descubrimiento de datos (*data discovery*), entendida esta actividad como el rastreo (*data crawling*), detección y caracterización de los datos (estructura, campos, etc.)
- Perfilado de los datos (*data profiling*⁴) para evaluar la calidad de los datos.
- Clasificación de los datos: caracterización de los conjuntos de datos desde el punto de vista de negocio según una taxonomía predefinida (típicamente, un glosario de negocio).
- Registro del linaje. El registro del linaje es particularmente importante para la gobernanza del dato porque, en determinados escenarios, la normativa vigente puede exigir la realización de informes de auditoría sobre el tratamiento de los datos. Además, ayuda a la comprensión de los *datasets*.

Caso de que las transformaciones y agregaciones no se hayan registrado en tiempo de ejecución, las herramientas más avanzadas disponen de la capacidad de inferir el linaje y la procedencia.
- Descubrimiento de la normativa y políticas corporativas aplicables. En particular, los sistemas más avanzados permiten detectar automáticamente si los activos de datos contienen datos de carácter personal y la política de gobernanza de datos que sea de aplicación a nivel corporativo como, por ejemplo, el nivel de confidencialidad. Una vez identificadas normativa y políticas aplicables, se generan metadatos que indiquen esta característica de los datos.

⁴ Gartner define perfilado de datos o *data profiling* como el proceso de «descubrimiento e investigación de potenciales problemas de calidad de los datos». El perfilado de datos implica examinar, analizar y crear resúmenes útiles de un conjunto de datos y su posterior evaluación desde el punto de vista de la calidad. El proceso aporta una visión de alto nivel que ayuda a la comprensión de los datos, a la identificación de riesgos y a la corrección de problemas de calidad. Se diferencia del descubrimiento de datos (*Data Discovery*) en que este último término tiene como objetivo describir el conjunto de datos para su comprensión mediante la inferencia de sus campos, su estructura y el establecimiento de relaciones con otros *datasets*.

Más específicamente, el perfilado de datos criba los datos para determinar su calidad mediante algoritmos de analítica de datos que detectan estadísticos (media, mínimo, máximo, percentiles, etc.) de los campos, distribución de los valores (funciones de densidad de probabilidad), claves primarias, potenciales claves externas y dependencias funcionales. El objetivo final es mostrar esta información al consumidor para facilitarle la comprensión del *dataset* y sugerir acciones a realizar, como limpieza de datos.

Por último, el perfilado de datos permite evaluar la calidad del conjunto de datos mediante detección de patrones inesperados, valores faltantes, valores atípicos y fuera de rango, inexactitudes, inconsistencias e incompletitud. A partir de la evaluación de la calidad realizada por el perfilado se sugieren acciones de mejora mediante la limpieza y tratamiento de los datos, con el consiguiente ahorro de tiempo de personal especializado.

En función de la normativa y política detectada se puede aplicar un mecanismo de control de acceso predefinido y un tratamiento específico para los datos (por ejemplo, aplicación de técnicas de enmascaramiento para datos de carácter personal y para datos confidenciales).

Por su parte, el rastreo de datos y su localización se puede realizar de dos maneras:

- Mediante extracción y envío (*push*): en esta modalidad, las propias fuentes de datos son las que avisan de la existencia del nuevo activo para su inventariado.
- Mediante tracción (*pull*): el catálogo rastrea los repositorios en busca de nuevos activos.

Típicamente, el rastreo de datos mediante tracción (*pull*) se realiza a través conectores que las fuentes de datos ofrecen para que se pueda acceder a ellas desde un sistema externo, mientras que en la extracción y envío (*push*) son las propias fuentes las que reportan la existencia de nuevos activos invocando APIs ofrecidas por los catálogos.

Como se verá en el apartado 0

1.1.3.7 CATÁLOGO AUMENTADO, los modernos catálogos de datos se apoyan en técnicas de inteligencia artificial (IA) para la elaboración de los inventarios con la mínima intervención humana posible, haciendo viable el inventariado de grandes cantidades de datos desde el momento de la ingesta o incluso el inventariado de datos que se encuentran en los sistemas operacionales (virtualización).

2. Organización de los datos en categorías

La organización de los datos juega un importante papel en el catálogo. Por un lado, una correcta organización facilita la consulta de activos por cualquier participante, sea usuario de negocio o técnico, al permitir múltiples de criterios de búsqueda. En particular, la categorización de los datos por categorías de negocio es un nexo entre el negocio y los propios datos.

En [4] se recomienda emplear tres criterios para la organización de los datos:

i. Organización vertical (categorías de negocio)

Consiste en la creación de una taxonomía de categorías y subcategorías de negocio que se asigna a los datos en función de los sistemas operacionales que generan los datos, de los potenciales usuarios o una mezcla de ambas. Por poner un ejemplo, los datos del CRM típicamente forman parte de la subcategoría de ATENCIÓN AL CLIENTE que a su vez es parte de POSVENTA, que forma parte de VENTAS.

La taxonomía de las categorías típicamente se refleja en un glosario de negocio que define y explica la naturaleza de cada una de ellas.

Los catálogos más avanzados aprenden la categoría a la que debe pertenecer cada activo de datos mediante técnicas de IA. Esta categorización no sólo es útil para la búsqueda de datos sino para la asignación de responsables de cada *dataset*.

ii. Organización horizontal (linaje).

Este mecanismo organiza los datos en función de su linaje; esto es, en función de la fuente de los datos, de las transformaciones y agregaciones sucesivas que ha experimentado, del lugar en que se encuentran (zonas bronce, plata y oro) y de su destino final. Permite también relacionar los *datasets* que se han creado a partir de una fuente concreta pero que mediante sucesivas transformaciones han ido generando diferentes versiones.

iii. Organización relacional (relaciones entre *datasets*)

La organización relacional permite establecer relaciones entre conjuntos de datos. Los catálogos más modernos se apoyan en la elaboración de grafos de conocimiento (ver 1.1.3.5) para el registro de las relaciones de forma similar a como funcionan los motores de búsqueda de Internet. Esta tecnología resulta una herramienta muy potente tanto para la búsqueda de activos de datos como para la aplicación de técnicas analíticas y para el propio perfilado de los datos.

Lógicamente, la organización de los activos de datos está estrechamente ligada con la capacidad de generar metadatos que permitan aplicar los mecanismos de organización definidos, por lo que estas funcionalidades están estrechamente relacionadas con las del punto anterior.

3. Herramientas de búsqueda

De acuerdo con el Data Management Body of Knowledge (DAM-DMBOOK), «los repositorios de metadatos [de un sistema de gestión de datos] deben disponer de una interfaz de usuario que soporte la búsqueda de activos de datos».

Queda fuera del alcance de este tema adentrarse en las complejidades de los motores de búsqueda, pero no el señalar la importancia de esta funcionalidad en un sistema de explotación de datos: resulta obvio que de las capacidades de la herramienta de búsqueda van a depender el aprovechar o no el esfuerzo realizado en organizar e inventariar los datos mediante metadatos.

Por lo demás, es preciso tener en cuenta las particularidades de un buscador como el que requieren los catálogos: en un catálogo de datos se buscan activos de datos a partir de un conjunto de metadatos disponibles pero no se buscan datos en particular ni se examinan conjuntos de datos en busca de algún dato concreto. No tiene por tanto sentido preguntar, por ejemplo *¿Qué temperatura media hizo en Madrid el pasado 28 de agosto?*; un catálogo de datos simplemente no está preparado para una pregunta así. Sí tiene sentido realizar una búsqueda preguntando, por ejemplo, *¿Dónde puedo encontrar datos de temperaturas en Madrid el pasado verano?*

Como se verá, los catálogos más avanzados se basan en algoritmos de IA para realizar las búsquedas e incluso soportan procesamiento de lenguaje natural (NLP) como interfaz de entrada para las consultas.

1.1.2.3.5 FORMATOS DE FICHEROS EN UN *DATA LAKE*

En el apartado anterior se ha descrito el trayecto que los datos siguen en un *data lake* desde la ingestión hasta su explotación. Pero ¿En qué formatos de fichero se guardan los datos en cada una de las zonas del *data lake*? La elección del formato correcto es importante porque afecta a las prestaciones globales del sistema, permite ahorrar espacio en los sistemas de almacenamiento, sirve de ayuda para la catalogación y gobernanza del dato y facilita los trabajos de transformación y procesamiento.

En líneas generales cabe distinguir dos tipos de formatos de ficheros:

i. Formatos de ficheros de datos.

Almacenan datos estructurados y semiestructurados. Dentro de esta categoría cabe distinguir ficheros de texto y ficheros de datos en formato binario.

Ficheros de texto

- CSV (*Comma Separated Values*).

Formato de datos para guardar tablas muy popular, basado en filas, legible por personas, editable a mano y fácil de procesar (*parsing*) por máquinas gracias a que en su cabecera se indican los campos de la tabla. Su principal ventaja es la simplicidad y la velocidad de escritura de este tipo de ficheros. El formato CSV es muy compacto (sólo requiere que se escriba y lea la cabecera con las columnas de la tabla una vez). Además, los ficheros CSV son divisibles en unidades más pequeñas, caso de darse la circunstancia de ser muy voluminosos, aunque esta operación resulta más compleja si los ficheros están comprimidos.

Como inconveniente destaca el estar orientado a filas (lectura fila a fila), contra la tendencia actual en *data lakes* de disponer de ficheros de datos orientados a columnas (*columnars*)⁵, de más rápida lectura. Sólo soportan estructuras de tablas planas; no soportan por tanto datos anidados⁶ ni estructuras complejas (con Arrays o Maps, por ejemplo). Tampoco permiten añadir metadatos que describan los tipos de los datos que contienen o su linaje, más allá de especificar el nombre de los campos. De hecho, los tipos de los campos son siempre de texto. La separación entre campos puede ser problemática pues no deja de ser un carácter (la coma) que puede formar parte del propio contenido de los campos. Por último, a pesar de existir una especificación que define los ficheros CSV (RFC 4180), no existe una interpretación única aceptada de dicha norma.

- JSON (JavaScript Object Notation)

Formato abierto de datos semiestructurados muy usado por APIs programáticas para intercambio de información. Los ficheros JSON contienen listas de parejas clave-valor autodescriptivas. Al igual que el formato CSV, es legible y editable a mano por personas y fácil de leer por máquinas, aunque tanto la lectura como la escritura son más lentas que con ficheros CSV, principalmente si el fichero es largo. Además, para conocer la estructura de los datos es necesario un procesado previo (*parseado*). Los ficheros JSON

⁵ Las estructuras orientadas a filas almacenan ordenadamente los registros en filas consecutivas (una fila detrás de otra), por lo que cuando se busca un registro de una fila concreta se debe leer el fichero fila a fila hasta dar con el registro deseado. Los ficheros orientados a columna (*columnares*) almacenan los registros en columnas consecutivas y permiten leer directamente la columna que el lector necesita, lo que suele acortar los tiempos de lectura. Como inconveniente, los formatos orientados a columnas suelen ser de más lenta escritura pero, en *data lakes*, se asume que resulta más crítica la lectura que la escritura dado que por regla general cada fichero se escribe sólo una vez pero se lee múltiples veces (paradigma WORM: *Write Once, Read Many*), por lo menos en la zona de presentación (oro).

⁶ Se dice que una estructura de datos soporta datos anidados (o es *nestable*) cuando sus campos soportan múltiples registros que a su vez pueden soportar agrupaciones de más registros. Las estructuras soportadas por los ficheros CSV son estrictamente planas y no soportan más que un valor dada una fila-columna concreta.

son divisibles pero, como ocurre con los CSV, la operación resulta complicada si los datos están comprimidos. Su gran virtud es el soportar cualquier tipo de anidación y estructuras complejas que incluyan arrays o maps. Además, al contrario que en CSV, los ficheros JSON permiten especificar los tipos de los campos y, en caso de no estar especificados, pueden inferirse. Se considera que es un formato basado en filas. Es menos compacto (ocupa más espacio) que CSV.

La principal ventaja de los formatos de texto es su gran aceptación. Casi todos los sistemas los aceptan. Como contrapartida, ocupan más espacio en disco que sus alternativas binarias, incluso si van comprimidos; su capacidad para incluir metadatos con información descriptiva sobre los datos es muy limitada y, en el caso de CSV, sólo aceptan tablas de datos planas.

Datos orientados a la fila

ID	NOMBRE	EDAD	PESO
0007	JAMES	89	60
0008	MONY	70	70
009	M	90	75

Datos orientados a la columna

ID	NOMBRE
0007	JAMES
0008	MONY
009	M

ID	EDAD
0007	89
0008	70
009	90

ID	PESO
0007	60
0008	70
009	75

Ilustración 7. Formatos de datos orientados a la fila (Avro) y a la columna (Parquet, ORC). En ambos casos se almacena la misma tabla, pero en el formato orientado a la fila, cada fila es un registro completo. En formatos de datos orientados a la columna se permite el acceso directo a las columnas de la tabla.

Ficheros en formato binario

Los ficheros en formato binario que se presentan son de más reciente implantación y se encuentran más adaptados para su uso en *data lakes*. En todos los casos soportan metadatos, esquemas con datos anidados y estructuras complejas.

▪ Apache Avro

El formato Avro fue publicado en 2008 por el Hadoop Working Group. Se trata de un formato orientado a la fila que es altamente divisible. Se emplea también para serializar datos que se envían en flujos entre entidades distintas.

Avro guarda los datos en formato binario junto con un esquema con su estructura en formato JSON, a modo de autodescripción. Además, permite añadir como metadatos parejas clave-valor con información adicional que resulta útil para la trazabilidad del conjunto de datos. Soporta cualquier tipo de estructura, incluidos datos anidados y tipos complejos. También soporta compresión de datos sin perjuicio de su divisibilidad. Está diseñado para ofrecer una gran robustez y eficiencia.

Frente a formatos como CSV o JSON, Avro proporciona mecanismos para compatibilizar conjuntos de datos cuyo esquema ha sido modificado (evolución de esquemas) lo que garantiza la compatibilidad hacia atrás y hacia adelante del software que maneja los conjuntos de datos. Esto permite actualizar la estructura de los datos sin que sea necesario reescribir código.

Las características de Avro lo hacen particularmente adecuado para su almacenamiento en la zona de aterrizaje tras la ingesta y para estructuras de datos con un número limitado de columnas.

- Apache Parquet

El formato Apache Parquet fue desarrollado en 2013 conjuntamente por Twitter y Cloudera para almacenamiento de datos columnar. Por ser un formato orientado a la columna ofrece una mayor velocidad de lectura, aunque a costa de una mayor lentitud en la escritura. Por su parte, el almacenamiento en columnas permite una compresión mayor al reducir la entropía de los datos (los datos de una columna son contiguos y suelen ser parecidos entre sí). Al igual que Avro, Parquet guarda los datos en formato binario pero incluye al final del fichero la descripción completa del esquema y los tipos de los campos junto con información estadística adicional de la tabla. También permite añadir metadatos con información de trazabilidad, linaje o de negocio.

La ventaja diferencial de Parquet frente a Avro es el ser un formato columnar y su mayor capacidad de compresión. Suele ser el formato escogido para almacenar datos en la zona de presentación, donde los datos se escriben una vez y se espera que sean consultados múltiples veces, particularmente en servicios de inteligencia de negocio. Es muy usado por los formatos de tablas, como se verá más adelante. Marcos de procesamiento de datos muy populares en *data lakes*, como Apache Spark, lo soportan de forma nativa.

- Apache ORC

Apache ORC (Optimized Row Columnar) es un formato de datos desarrollado por Facebook y Hortonworks en 2013. Al igual que Apache Parquet, es un formato binario y columnar muy similar en funcionalidad y especialmente indicado para la lectura de datos. La diferencia fundamental con Parquet está en la aceptación por parte del mercado, algo superior en el caso de Parquet, pero en términos de funcionalidad se trata de soluciones intercambiables.

Propiedad	CSV	JSON	AVRO	PARQUET	ORC
Formato columnar	NO	NO	NO	SÍ	SÍ
Comprimible	SÍ	SÍ	SÍ	SÍ	SÍ
Divisible	Limitado	Limitado	SÍ	SÍ	SÍ
Legible por personas	SÍ	SÍ	NO	NO	NO
Soporte de estructuras complejas	NO	SÍ	SÍ	SÍ	SÍ
Evolución del esquema	NO	NO	SÍ	SÍ	SÍ

Soporta datos anidados	NO	SÍ	SÍ	SÍ	SÍ
Metadatos autodescriptivos	Limitado	Limitado	SÍ	SÍ	SÍ
Mejor para (E = Escritura; L = Lectura)	E	E	E	L	L

Tabla 3. Comparativa de formatos de datos.

Como conclusión, los formatos de texto ofrecen la ventaja de su gran aceptación y fácil manipulación. Además, son fácilmente leíbles y editables por personas. Por contra, el soporte de metadatos autodescriptivos es pobre o inexistente, no soportan evolución de los esquemas y su divisibilidad es limitada. El formato CSV, en concreto, sólo permite definir estructuras planas. Los formatos binarios están claramente especializados en la escritura (Avro) y en la lectura (Parquet y ORC). Avro es más apropiado para la escritura en la zona de aterrizaje, donde teóricamente los datos tan sólo van a ser leídos una vez para su procesamiento hasta la zona de refinado. Por su parte, los formatos columnares ofrecen una mayor velocidad de lectura y se ajustan más a los datos de la zona oro, donde pueden contener los datos de estructuras complejas especificadas mediante formatos de tabla como los que se presentan a continuación.

ii. Formatos de tablas.

Los formatos de tablas (*table formats*) son ficheros destinados a almacenar metadatos que ofrecen un nivel de abstracción superior sobre estructuras complejas de datos. Constituyen un método alternativo a las tradicionales bases de datos para estructurar múltiples conjuntos de datos relacionados que se encuentran repartidos por un repositorio de forma que se muestren a las herramientas de consulta como una estructura de datos unificada sobre la que se pueden realizar consultas SQL complejas.

Los ficheros de formato de tablas no contienen por lo tanto datos, sino metadatos variados que definen la estructura de los datos y la ubicación de los ficheros (típicamente Apache Parquet u ORC) que, estos sí, contienen los datos de las estructuras definidas por los ficheros de formato de tablas.

Los formatos de tablas son de relativamente reciente aplicación en los *data lakes*. Ofrecen una solución para integrar un *data warehouse* en un *data lake* de manera más eficiente y sin el requisito de tener que desplegar bases de datos relacionales que sirvan de soporte para las consultas tradicionales de ese tipo de sistemas. Como se verá, resultan clave en la implementación de *data lakehouses*.

Formatos de tablas abiertos disponibles en el mercado son Apache Iceberg, Delta Lake o Apache Hudi.

1.1.2.3.6 SISTEMAS DE ALMACENAMIENTO

En este desarrollo temático sobre los *data lakes* se ha insistido en la misión principal que tiene este tipo de sistemas: almacenar grandes cantidades de datos de distintos tipos en un único repositorio para su posterior procesamiento, transformación y almacenamiento en distintas zonas. Pero ¿Cómo son los sistemas que se emplean para almacenar estos datos? En la actualidad existen dos aproximaciones para el almacenamiento de datos en

un *data lake*: sistemas de ficheros distribuidos (*Distributed File Storage Systems*) y sistemas de almacenamiento basados en objetos (*Object-Based Storage Systems*).

i. Sistemas de ficheros distribuidos

Los sistemas de ficheros distribuidos son *clusters* para el almacenamiento de




Ilustración 8. Tipos de sistemas de almacenamiento para data lakes.

grandes cantidades de datos formados por múltiples nodos contruidos sobre hardware de propósito general. El hecho de estar compuestos hardware no especializado los hace económicos y, el hecho de estar constituidos por nodos y *clusters*, los convierten en sistemas fácilmente escalables horizontalmente, caso de que sea necesario ampliarlos. Como corresponde con los sistemas distribuidos, permiten ofrecer un compromiso entre consistencia, disponibilidad y tolerancia a la partición (teorema CAP), en función de las necesidades del negocio.

La característica diferenciadora de los sistemas de ficheros distribuidos es el hecho de estar organizados jerárquicamente en carpetas de igual manera que los sistemas de ficheros locales. Dicho de otro modo, el acceso a sistemas de ficheros distribuidos no se diferencia del acceso a un sistema de ficheros local. Aunque internamente los ficheros se descomponen en partes que se multiplican y distribuyen a lo largo de los nodos del *cluster*, la unidad de almacenamiento en estos sistemas es el fichero, que queda unívocamente identificado mediante su nombre y su directorio. Para su acceso, los sistemas de ficheros distribuidos admiten total o parcialmente la interfaz POSIX.

En sus inicios, los *data lakes* se instalaban localmente en los propios centros de datos de las organizaciones (*On-Premises*) y estaban basados en este tipo de sistemas de almacenamiento, típicamente *Hadoop Distributed File System*. Alternativas en código abierto disponibles de sistemas de ficheros distribuidos son HDFS (*Hadoop Distributed File System*), GlusterFS o Ceph.

Los sistemas de ficheros distribuidos fueron los primeros sistemas de almacenamiento distribuido que se popularizaron para almacenar grandes

cantidades de datos. Hoy, siguen siendo muy usados, principalmente en instalaciones locales, pero los sistemas de almacenamiento en la nube utilizan preferentemente almacenamiento basado en objetos.

ii. Sistemas de almacenamiento de objetos (*Object Storage Systems*)

Los sistemas de almacenamiento de objetos están diseñados igualmente para almacenar grandes cantidades de datos de muy variada naturaleza. También son sistemas distribuidos escalables horizontalmente y basados en hardware no especializado con todas las ventajas de consistencia, disponibilidad y tolerancia a la partición que ofrecen los sistemas distribuidos.

La principal diferencia con los sistemas de ficheros distribuidos está en que, en vez de gestionar ficheros, gestionan objetos que se almacenan en repositorios planos, sin estructuras jerárquicas de carpetas, denominados *buckets*. La unidad de almacenamiento no es el fichero sino un objeto constituido por un paquete simple, discreto y autocontenido que incluye datos (uno o varios ficheros de datos, a fin de cuentas), metadatos asociados y, en vez de un nombre y un directorio, un identificador único asociado al objeto (normalmente un URI). En la práctica, los sistemas de almacenamiento de objetos funcionan como bases de datos clave-valor, en las que la clave es el identificador y, el valor, los metadatos y los datos. Los metadatos pueden asociarse en el momento de creación del objeto o con posterioridad.

La segunda gran diferencia de esta tecnología de almacenamiento de datos frente a los sistemas de ficheros distribuidos está en que los sistemas de almacenamiento basados en objetos no soportan la interfaz POSIX ni los protocolos que se apoyan en él (por ejemplo, NFS o SMB). A los objetos de un sistema de almacenamiento de objetos se accede a través de una API HTTP RESTful. La API RESTful desarrollada por Amazon, de nombre Simple Storage Service (Amazon S3), se ha convertido en el estándar de facto de la industria para el acceso a sistemas de almacenamiento de este tipo.

Los sistemas de almacenamiento basados en objetos no sólo se han convertido en la tecnología preferencial para *data lakes* en la nube sino que de hecho se emplean en sistemas de *backups* y en cualquier servicio en la nube que requiera un repositorio de datos. Cuenta con muchas de las ventajas de los sistemas de ficheros distribuidos pero, la posibilidad de añadir metadatos que describan y documenten los objetos que contienen, convierten esta tecnología en especialmente adecuada para los sistemas de gestión de datos.

El inconveniente principal de estos sistemas es que la modificación de un objeto supone tener que reescribirlo por completo: los objetos de un repositorio no pueden ampliarse, reducirse ni cambiarse. Como consecuencia, estos sistemas ofrecen muy buenas prestaciones de lectura pero no tanto de escritura. Por esta razón, se considera que los sistemas de almacenamiento de objetos no ofrecen buenas prestaciones para escenarios en que los objetos experimentan modificaciones constantes (por ejemplo, transacciones OLTP en bases de datos relacionales) pero podrían valer para cubos OLAP que, una vez creados, cambien con poca frecuencia. Debido a esto, en algunos casos, sobre todo cuando se requiere usar bases de datos relacionales, se opta por sistemas mixtos que almacenan los datos en parte en sistemas basados en objetos y, en parte, en sistemas de ficheros distribuidos.

Alternativas de sistemas de almacenamiento de objetos *open source* son Ceph, MinIO, Openio.io o SwiftStack/OpenStack Swift. La mayoría de los proveedores de servicios en la nube ofrecen su propia solución como, por ejemplo, AWS

(Amazon S3 Glacier y S3 Simple Storage), Google (Google Cloud Storage) o Microsoft (Azure Blob Storage).

1.1.2.4 ARQUITECTURAS DE *DATA LAKES* POR TIPO DE INGESTA

Aunque la variedad de *data lakes* que se encuentran en las organizaciones es prácticamente infinita, existen arquitecturas de referencia para su construcción en función de las necesidades de la organización. En este apartado se presentan las arquitecturas más comunes en función de cómo se implemente la capa de ingestión.

Pero antes de abordar las alternativas principales para las arquitecturas de un *data lake*, es necesario entender el compromiso que es preciso adoptar en la construcción de este tipo de sistemas.

1.1.2.4.1 EL TEOREMA CAP (CONSISTENCY, AVAILABILITY, PARTITION)

Aunque desde el punto de vista lógico los *data lakes* son sistemas centralizados, desde el punto de vista de la infraestructura suelen ser sistemas distribuidos instalados en *clusters* que disponen de numerosos nodos físicos. En sistemas de este tipo es necesario adoptar un compromiso entre las tres principales características que ofrecen: consistencia (*Consistency*), disponibilidad (*Availability*) y tolerancia a la partición (*Partition Tolerance*):

- Consistencia: Todos los nodos del *data lake* ofrecen la misma vista de los datos en un momento dado. Esto implica que los datos están replicados en todos los nodos en todo momento.
- Disponibilidad: Todos los nodos activos del sistema devuelven una respuesta válida en un momento dado ante solicitudes de datos.
- Tolerancia a la Partición: una partición es una caída en las comunicaciones entre nodos. La tolerancia a la partición supone que, aunque haya caídas (particiones) en las comunicaciones de los nodos, el cluster sigue funcionando.

Lo que el teorema CAP afirma es que, en sistemas distribuidos, **no es posible garantizar simultáneamente consistencia, disponibilidad y tolerancia a la partición**, por lo que por diseño es necesario optar por dos de esas características.

Al aplicar este teorema al caso de los *data lakes* es necesario considerar que en este tipo de sistemas *no se quiere prescindir en ningún caso de tolerancia a la partición*. Es decir, en el caso de los *data lakes*, se quiere que el cluster funcione aunque haya nodos fuera de operación por haberse caído la comunicación con el resto de los nodos. Asumido esto, de acuerdo con el teorema CAP, el diseñador del *data lake* debe optar por un compromiso entre la consistencia y la disponibilidad.

Esto puede resultar muy teórico pero en realidad es más intuitivo de lo que parece. Al ser un sistema distribuido compuesto por múltiples nodos, una actualización de datos durante la ingesta supone replicar los datos actualizados en todos los nodos. Es razonable pensar que la réplica en los distintos nodos implica recursos y tiempo y que ante picos de demanda esta tarea se puede demorar. O es posible que simplemente el nodo al que se solicitan los datos haya perdido momentáneamente la comunicación con el resto de los nodos y no se haya propagado aún la actualización. En cualquier caso, podría suceder que un cliente del cluster que solicite datos a un nodo en el que aún no se ha replicado la actualización reciba datos no actualizados, mientras que si solicitase los datos a otro nodo recibiría los datos actualizados (falta de consistencia). Si en el sistema prima la disponibilidad, los nodos consultados responderán con lo que tienen en el momento de la consulta aunque exista riesgo de falta de consistencia. Si se quisiera primar la

consistencia, el cluster debería retener la respuesta del nodo hasta tener la certeza de que la actualización ha tenido lugar, causando con ello un problema de falta de disponibilidad.

En un clúster que albergue una base de datos relacional se suele primar simultáneamente la consistencia y la disponibilidad (CA), pero en un *data lake* se parte de la base de que se quiere mantener la tolerancia a la partición por lo que, dependiendo de si se desea primar consistencia (C) o disponibilidad (A), se optará por una arquitectura específica u otra.

Como se verá, en la mayoría de los casos, las arquitecturas de *data lakes* optan por primar la disponibilidad frente a consistencia, sacrificando la exactitud de los datos por un bien mayor. Se asume que unas cuantas inconsistencias no van a afectar el resultado de las analíticas aplicadas. Sin embargo, puede haber escenarios en los que la consistencia




Ilustración 9. Teorema CAP

resulte clave (por ejemplo, la lectura de sensores de temperatura en una estación de prevención de incendios en un bosque) y se quiera primar sobre la disponibilidad. Para ello existen distintos diseños de arquitecturas.

1.1.2.4.2 ARQUITECTURA TRADICIONAL DE UN *DATA LAKE*

En este modelo de arquitectura de *data lakes* se asume la ingestión de los datos por lotes según una frecuencia determinada que puede ser de días, horas o minutos, dependiendo de la naturaleza de los datos de la ingesta. Los datos normalmente se ingieren sin procesar en el *data lake* y posteriormente se transforman de acuerdo con el modo en que se desea explotarlos. Es el escenario para el que los *data lakes* fueron creados inicialmente.

Un escenario de uso puede ser el siguiente: un Product Manager de la organización necesita semanalmente realizar un informe sobre métricas de consumo de su producto para el que se requiere recoger numerosos datos de diversas fuentes. Este sería el escenario típico de aplicación de un *data warehouse* pero, dado que se dispone de un *data lake*, se quiere que se "democratizen" los datos poniendo a disposición de los científicos de datos tanto los datos recogidos para el *data warehouse* como otros adicionales para realizar una clasificación de los clientes mediante técnicas de *Machine learning* (por ejemplo, *clustering*).

Los ingenieros de datos de la organización deberán programar semanalmente una ingesta de datos que colocarán inicialmente en una zona del *data lake* destinada a recibir datos en bruto. Una vez allí, procesarán cada tipo de dato en función de su destino; en algunos casos los datos transformados se almacenarán en el *data warehouse* que reside en el *data lake* (por ejemplo, Apache Hive o ficheros Apache Iceberg); en otros, los datos tendrán como destino datasets en formato CSV con metadatos asociados para su entrenamiento mediante técnicas de *clustering*.




Ilustración 10. Arquitectura tradicional de un data lake.

Como se puede observar, este modelo garantiza la disponibilidad puesto que los nodos del *data lake* siempre responderán a una consulta con los datos de que disponen.

El problema está en las consultas realizadas durante el periodo entre ingestas. Pasados unos días de realizada la ingesta los datos pueden estar desactualizados. Esto se puede paliar reduciendo el tiempo entre ingestas pero siempre existirá un límite al tiempo entre ingestas por lotes programadas que será el tiempo que dure la propia ingesta. Para algunos casos de uso esta limitación puede ser determinante. Al final, hay escenarios que requieren una arquitectura que soporte o se aproxime a la ingesta en tiempo real.

1.1.2.4.3 ARQUITECTURA LAMBDA

La arquitectura lambda combina el procesamiento por lotes (*Batch*) con la puesta a disposición de datos recibidos en tiempo real mediante flujos de datos (*data streams*). En esta arquitectura, la ingesta de datos, en vez de responder únicamente al paradigma de la ingestión por lotes, se descompone en tres niveles:

- Capa de procesamiento por lotes (*Batch Layer*).
- Capa de procesamiento rápido (*Speed Layer*).
- Capa de servicio (*Serving Layer*).

A continuación se describen con algo más de detalle las características de las capas de un *data lake* con arquitectura Lambda.

La capa de procesamiento por lotes (*Batch Layer*)

El *Batch Layer*, también llamado, *Cold Layer* o *capa fría*, realiza la ingestión por lotes programados y almacena los datos en bruto en un repositorio del *data lake* denominado *Master Dataset*, que guarda el histórico de todos los lotes de datos ingeridos, normalmente en carpetas de un sistema de ficheros distribuidos. Independientemente del procesamiento al que se someta a los datos, el repositorio del Master Dataset con los datos en bruto es inmutable: no está sometido a modificaciones ni a borrados. Los datos de este repositorio se consideran la "*fuentes de verdad*" del *data lake*. Además, junto con los datos en bruto se almacenará el esquema con la estructura de los datos almacenados (típicamente esquemas SQL).

La segunda tarea que realiza el *Batch Layer* es la agregación de los datos recibidos en el




Ilustración 11. Arquitectura Lambda de data lakes

último lote con los acumulados de lotes anteriores. La tarea de agregación es intensiva en cómputo y normalmente se realiza mediante herramientas como Apache Flink, Apache Spark o el propio Hadoop (MapReduce), desplegadas en clústeres que permiten la computación distribuida.

La capa de servicio (Serving Layer)

La capa de servicio almacena y pone a disposición de los usuarios en una zona distinta los datos que a su vez ha recogido y agregado el *Batch Layer*. Estos usuarios pueden ser otros procesos encargados de transformar los datos ofrecidos o pueden ser los propios usuarios finales del *data lake*. Los datos son puestos a disposición en forma de vistas que normalmente consisten en diferentes niveles de agregación de los datos ingeridos realizados por el *Batch Layer*. Por ejemplo, si los datos contienen la facturación de la organización, se pueden ofrecer agregados por días, semanas, meses, trimestres o años.

La capa de velocidad (Speed Layer)

El *Speed Layer*, también llamada *capa de procesamiento de streams* o *capa caliente*, es el componente diferencial de la arquitectura lambda. Su misión es agregar datos en tiempo real que aún no han sido recibidos ni agregados por el *Batch Layer* y exponerlos a los usuarios que quieren consultar los datos más frescos recibidos por el *data lake*.

Típicamente, el *Speed Layer* se basa en la creación de *streams* de datos que contienen el flujo de todos los datos generados en tiempo real por las fuentes de datos del *data lake* (*Producers*) durante una ventana de tiempo determinada por el administrador. A este flujo o *stream* de datos se conectan diferentes agentes (denominados consumidores), que a partir de los datos del flujo generan vistas para su consulta por los potenciales usuarios.

Los consumidores también pueden realizar procesos de los datos recibidos en el *stream* y, si procede, enviar avisos en tiempo real a aplicaciones que requieren notificaciones inmediatas de determinados eventos.

Los *streams* de datos (también denominados *streams* de eventos) constituyen una tecnología muy eficiente para la gestión de este tipo de tareas en términos de disponibilidad y rapidez de proceso. Herramientas típicas para la creación de los *streams* de datos son Apache Spark *streaming*, Apache Kafka, Apache Storm o Apache Flink.

En el momento de la consulta de los datos por parte de un usuario es posible añadir a los datos agregados por el *Batch Layer* aquellos agregados por el *Speed Layer* y puestos a disposición en sus propias vistas de forma que se ofrezca una visión completa y actualizada de los datos recibidos.




Ilustración 12. Capa de velocidad de un data lake con arquitectura Lambda

La arquitectura Lambda reduce la latencia en la recepción de aquellos datos que pueden resultar críticos mediante la introducción de un nivel de procesamiento basado en *streams* de datos al tiempo que mantiene las ventajas de disponer de una capa de procesamiento por lotes, adecuada para un gran número de aplicaciones.

Otra de las principales ventajas de la arquitectura lambda es la facilidad de migración de las arquitecturas tradicionales hacia una de este tipo: si el *data lake* está basado en procesamiento por lotes bastará añadir una capa adicional (el *Speed Layer*) para tener una arquitectura Lambda. En líneas generales esta solución ofrece un buen equilibrio entre la frescura de los datos ofrecidos por el *data lake* y los recursos exigidos por el sistema.

La principal crítica que se realiza a este modelo es la complejidad pues, en definitiva, requiere la duplicación de los trabajos de ingesta y agregación que deben realizarse dos veces: una vez en el *Batch Layer* y otra en el *Speed Layer*; los datos agregados por el *Speed Layer* deben ser agregados nuevamente cuando se carguen mediante el procedimiento de ingesta por lotes. Esto ha provocado la aparición de nuevos modelos de arquitectura como la arquitectura Kappa que se describe a continuación.

1.1.2.4.4 ARQUITECTURA KAPPA

La arquitectura Kappa da un paso más allá respecto a la Lambda y emplea únicamente procesamiento de streams como mecanismo de ingesta de los datos en el *data lake*. Esta arquitectura consta de 3 capas:

- **Flujo de ingestión.** El punto de entrada para la ingesta es un sistema de mensajería al que "productores" (*producers*) de datos envían datos procedentes de las fuentes de datos que gestionan. Los mensajes del sistema de mensajería encapsulan los datos de entrada al *data lake*. Estos sistemas de mensajería




Ilustración 13. Arquitectura Kappa.

(típicamente *clusters* de Apache Kafka escalables horizontalmente) están continuamente recibiendo datos que almacenan en sistemas de ficheros distribuidos etiquetados en forma de archivos de logs. Este repositorio de mensajes se puede considerar como el almacenamiento en bruto del *data lake*; el "*Master Data*" de la arquitectura Lambda.

- **Capa de streaming.** Una vez que los datos están en el sistema de mensajería en forma de mensajes, se activan los "consumidores" de datos. Estos consumidores son receptores de los mensajes del *stream* de ingestión que los procesan en tiempo real mediante la generación de *streams* de procesamiento de datos (*streaming processing*), produciendo la salida o las salidas que se deseen para su uso por los sistemas de analítica. Los *streams* pueden encadenarse secuencialmente para realizar transformaciones complejas de datos o agregaciones de datos que emplean diversas fuentes.
- **Capa de servicio.** Por último, una tercera capa pone los datos a disposición de los potenciales usuarios mediante APIs, fuentes de datos, bases de datos o cualquier otro medio de acceso que puedan requerir las herramientas de analítica.

La arquitectura Kappa permite tener una sola línea de proceso para todos los datos, sin duplicaciones ni caminos divergentes. Al estar basada en *streams* de datos se simplifica el diseño general y se reduce la complejidad operacional. Se trata de una arquitectura válida tanto para aplicaciones que requieren consistencia de datos en tiempo real como para aquellas en las que el tiempo no es crítico.

La crítica que reciben estos sistemas es la de no disponer de un repositorio en bruto directamente accesible para, por ejemplo, análisis de series históricas. Aunque los datos en bruto se almacenan, están encapsulados en mensajes y su acceso no es tan directo como en los casos de las arquitecturas tradicional y lambda.

Además, se critica el hecho de emplear tecnologías para el procesamiento en tiempo real incluso para aquellos datos que no lo necesitan. El hecho de que se compartan los mismos sistemas para tareas con distinta exigencia puede afectar a la eficiencia con la que se ingieren datos que resulta vital que se carguen en el sistema en tiempo real.

1.1.2.5 DATA WAREHOUSES Y DATA LAKES⁷

Definición y características de un *data warehouse*

Una de las definiciones canónicas de *data warehouse* define el concepto como «*un almacén de datos que extrae, limpia, conforma y entrega una fuente de datos dimensional para la consulta y el análisis*» (R. Kimball). La idea que hay detrás de esta definición de *data warehouse* es la de un sistema que ofrece a los usuarios un repositorio con información **multidimensional, consolidada y estructurada** procedente de múltiples fuentes, principalmente sistemas operacionales de la organización (clientes, compras, ventas, productos, actividades de atención al cliente). La finalidad del repositorio es integrar y agregar datos en estructuras relacionales complejas a partir de las cuales se elaboran cubos n-dimensionales sobre los que realizar consultas SQL multidimensionales y, a partir de los resultados, elaborar informes de negocio.

La segunda definición aceptada por la industria es más descriptiva pero compatible con la anterior y define el término como «*una colección de datos orientada al negocio, integrada, variante en el tiempo y no volátil para el soporte del proceso de toma de decisiones de la gerencia*» (W. Immon).

Con objeto de señalar las diferencias con un *data lake*, se analiza con algo más de detalle esta segunda definición:

1. **Colección de datos orientada a negocio.** Cualquier dato operacional residente en las bases de datos de los sistemas de información es susceptible de ser incorporado al almacén de datos común siempre y cuando sea útil para el análisis de negocio de la organización. Sobre el conjunto de los datos incorporados y estructurados se realizan consultas (*queries*) rápidas y, normalmente, complejas, de inteligencia de negocio que arrojan luz sobre la marcha de las actividades de la organización pero, por principio, en un *data warehouse* no se incorporan datos que no se prevea que van a tener una utilidad para conocimiento del negocio (por ejemplo, DNI de los clientes) porque los *data warehouses* no tienen como finalidad la gestión del negocio sino su conocimiento y análisis. Es la diferencia entre datos orientados a la operación (los que contienen los sistemas de información de la organización) y datos orientados a negocio, propios del *data warehouse*. Además, como norma general y con el objetivo de economizar recursos, sólo se cargan datos con una finalidad de negocio establecida de antemano: en un *data warehouse* no se cargan datos por si acaso son necesarios en el futuro.
2. **Integrada.** Los datos se almacenan en una única estructura centralizada de datos ubicada en un único repositorio común que reúne y consolida los datos a pesar de proceder de múltiples fuentes. Esta característica permite relacionar múltiples variables (volumen de ventas, productos, clientes, geografía, etc.) a lo largo del tiempo mediante estructuras complejas (estrella, copo de nieve, constelación) que residen en una base de datos relacional.
3. **Invariante.** Por invariante se debe entender que, una vez consolidados los datos en el repositorio común, no se modifican. Por regla general, las estructuras de datos creadas en un *data warehouse* sólo admiten operaciones de consulta, por lo que los datos no se pueden modificar ni borrar una vez almacenados. Esta característica es propia de la finalidad del *data warehouse* como herramienta de análisis de negocio y no operacional. Los datos de los sistemas operacionales cambian con el tiempo (hay altas y bajas de clientes, productos

⁷ En este tema no se abordan en profundidad las características de un *data warehouse* sino sólo sus rasgos más generales y diferenciales respecto a los *data lakes*, así como las distintas alternativas de integración. Para un estudio en profundidad se recomienda leer el anexo, que es el tema sobre *data warehouses* de la versión anterior del temario ASTIC (79).

descontinuados, se abren y cierran subsidiarias en nuevas regiones, etc.) pero los datos de un *data warehouse*, no.

4. **Variable con el tiempo.** Cada lote de datos ingeridos se asocia a su fecha de carga al incorporarlos al repositorio común. Esto permite obtener series de datos temporales muy valiosas para el análisis de negocio. Nótese que lo que es variable con el tiempo es el propio *data warehouse* y los datos que contiene, no los datos que ya se han ingerido que, como se ha dicho, una vez almacenados, no varían. Típicamente, en un *data warehouse* se almacenan datos que son resultado de años de operación de la organización.

La tecnología OLAP

OLAP (*Online Analytical Processing*) es el nombre que recibe la tecnología para el análisis multidimensional y a alta velocidad de grandes cantidades de datos en un *data warehouse*. La tecnología OLAP se contrapone a la denominada tecnología OLTP (*Online Transaction Processing*) destinada a soportar eficientemente transacciones ACID en los sistemas operacionales de la organización, que es donde se generan en primera instancia los datos ingeridos mediante ETL.

La tecnología OLAP es el fundamento de los *data warehouses*. Surgió para superar las limitaciones de las bases de datos relacionales en el almacenamiento y consulta de grandes volúmenes de datos multidimensionales y, en última instancia, es la tecnología que permite explotar el alto volumen de datos de un *data warehouse*. Aunque basada en bases de datos relacionales, la tecnología OLAP extiende su función y añade una capa adicional en la que le ofrece vistas multidimensionales de los datos almacenados en forma de cubos o hipercubos de datos. Dicho de otra forma: en sistemas OLAP, los datos se almacenan en estructuras complejas residentes en una base de datos relacional (estrella, copo de nieve, constelación) a partir de las cuales se elaboran y extraen cubos multidimensionales que se ofrecen a los usuarios para la realización de las consultas y elaboración de informes de negocio.

Arquitectura de un *data warehouse* tradicional

Al igual que los *data lakes*, la arquitectura general de un *data warehouse* se puede descomponer en 4 partes:

- Subsistema de Extracción/ Transformación/ Carga (ETL). Encargado de la recogida de los datos de los sistemas operacionales, su limpieza y transformación, y su carga (proceso ETL) en estructuras de datos OLAP destinadas a facilitar consultas multidimensionales complejas. Puede hacer uso de un repositorio de datos temporal.
- Almacén de datos estructurados. Repositorio de datos propiamente dicho donde se almacenan los datos en las distintas estructuras. Típicamente se trata de una base de datos que guarda los datos en estructuras complejas (estrella, constelación, etc.) a partir de las cuales el sistema OLAP crea los hipercubos que ofrece a los usuarios.
- Herramientas de consulta. Recibe las consultas de los usuarios, las traduce y traslada a la estructura de datos correspondiente (cubo multidimensional, Business Models, etc.) y devuelve los resultados obtenidos. Se incluyen aquí también las herramientas de visualización.
- Herramientas de gobernanza de los datos y del *data warehouse*. Es quizá la parte más conseguida de los *data warehouses*. Al ser sistemas monolíticos su principal virtud es la integración de sus distintas partes sin fisuras y el suministro de herramientas para el gobierno del dato bien integradas con el sistema.

Otras características de los *data warehouses*

Por regla general, los *data warehouses* se basan en tecnologías propietarias integradas en un sólo sistema monolítico que cubre desde el proceso de ETL y el almacenamiento en las estructuras de datos

relacionales y los cubos OLAP, pasando por las herramientas de consulta, hasta la gobernanza general de los datos y del sistema.

Esta capacidad de integrar todo el proceso de carga, transformación, analítica de datos y gobernanza en una única solución monolítica ofrece como ventaja un funcionamiento coherente y sin fisuras de




Ilustración 14. Arquitectura general de un data warehouse

todos los subsistemas implicados. Por contra, la adquisición de estos sistemas suele colocar a las organizaciones en una situación de dependencia tecnológica del proveedor.

Un problema asociado a los *data warehouses* es la dificultad de acceder directamente a los datos almacenados salvo que se utilicen las herramientas de consulta ofrecidas por el suministrador. Incluso si se encuentra el modo de acceder a los datos, puede resultar que los datos estén codificados en formatos propietarios de difícil lectura. Este hecho puede suponer en la práctica la pérdida del control de los datos de la organización, estableciendo una dependencia adicional respecto al producto tecnológico en el control del histórico de datos cargados en el sistema.

Otro problema añadido de las arquitecturas tradicionales de *data warehouses* es el fuerte acoplamiento entre almacenamiento y cómputo, lo que introduce problemas de escalabilidad. En concreto, resulta difícil aumentar la capacidad de almacenamiento sin hacer lo propio con la capacidad de cómputo, con lo que resultan sistemas caros de mantener.

Pros	Contras
Funciona como un único repositorio con grandes volúmenes de datos operacionales históricos procedentes de múltiples fuentes	Sólo soporta datos estructurados
Permite realizar rápidamente analíticas de negocio complejas	Poca flexibilidad. No soporta <i>Machine learning</i> de forma nativa.
Ofrece una gobernanza integrada que asegura la disponibilidad de los datos, su catalogación, usabilidad y alineamiento con políticas de seguridad	Dependencia tecnológica del suministrador

Optimizado para consultas de negocio. Muy adaptado a su funcionalidad principal

Caro en términos de almacenamiento, capacidad de cómputo y mantenimiento, en general.

Tabla 4. Pros y contras de un data warehouse

La gran virtud de los *data warehouses* es su madurez y el haber sido la primera herramienta capaz de extraer, cargar y organizar grandes volúmenes de datos históricos en un único lugar desde donde los analistas de inteligencia de negocio pueden hacer consultas de una manera rápida y simple. Se considera que estos sistemas han resultado clave en la democratización de los datos haciéndolos accesibles a personal experto en el negocio que dispone de poco conocimiento de ingeniería de datos. Por poner un ejemplo, en una empresa de transportes, un analista del negocio podría fácilmente obtener cuántos fletes se han realizado entre puntos de distintas regiones seleccionadas durante un periodo de tiempo señalado, clasificar el resultado por tipo de flete y obtener un informe de las quejas de los clientes por tipo de flete, ruta y periodo de tiempo.

Más difícil resulta en un *data warehouse* realizar predicciones sobre cuántos fletes tendrán lugar durante un periodo de tiempo en el futuro. Esta tarea requeriría como mínimo la aplicación de técnicas de ciencia de datos o incluso de *Machine learning* para las que los *data warehouses* no suelen estar diseñados porque sus herramientas de consulta están especializadas en la ejecución de comandos SQL multidimensionales o, como mucho, aplicaciones de *machine learning* predefinidas (por ejemplo, *clustering* de clientes). Una opción para realizar esta analítica podría ser la descarga de los datos históricos en una segunda plataforma que sí ofrezca estas capacidades, con el consiguiente aumento de complejidad, coste y riesgo de falta de consistencia de los datos por duplicación. Se perdería además la gran ventaja de los *data warehouses*, que es el constituir sistemas integrados «*todo en uno*».

Un obstáculo adicional para la aplicación de técnicas avanzadas de analítica sobre los datos recolectados por un *data warehouse* es el hecho de que estos sistemas sólo soportan datos fuertemente estructurados. Analíticas avanzadas como el análisis de sentimiento de una red social respecto a un determinado tema (por ejemplo, la imagen de marca, necesaria para el análisis de la reputación corporativa de la organización) requieren habitualmente análisis de datos semiestructurados en formato JSON; otros casos de uso interesantes requieren la aplicación de analíticas avanzadas sobre ficheros de imágenes, audio o texto, que son no estructurados.

	<i>Data lake</i>	<i>Data warehouse</i>
Naturaleza de los datos	Variada: estructurados, semi estructurados, no estructurados	Estructurados
Destino de los datos	Sin determinar necesariamente	Finalidad establecida antes de su carga
Usuarios	Científicos de datos, analistas de negocio, expertos en <i>Machine learning</i> .	Analistas de negocio
Ingesta y procesamiento	Poco o ningún procesamiento durante de la ingesta (Paradigma ELT - Extracción/Carga/Transformación): datos procesados en etapas después de su carga.	Datos procesados durante la ingesta mediante un único proceso de Extracción/ Transformación/ Carga (ETL)

Accesibilidad y actualización de los datos	Alta accesibilidad y rápida actualización	Difícil acceso salvo mediante herramientas de consulta. Actualización de los datos del sistema lenta (por lotes).
Flexibilidad	Alta. Sistemas multipropósito con múltiples aplicaciones, incluida IA y la analítica de negocio.	Baja. Sistemas destinados a la analítica de negocio o aplicaciones de ML predefinidas. Difícil de añadir nuevas aplicaciones.
Escalabilidad horizontal	Fácil de escalar	Costoso de escalar
Coste por unidad de espacio y por unidad de cómputo	Menor. Permite desacoplar almacenamiento y cómputo y usa hardware de propósito general.	Mayor. No permite desacoplar almacenamiento y cómputo y utiliza el hardware que determine el suministrador.
Analítica e inteligencia de negocio	Factible mediante alguna de las arquitecturas diseñadas para ofrecer servicios de <i>data warehouse</i> en un <i>data lake</i> .	Más eficiente. El servicio de analítica de negocio está optimizado en los <i>data warehouses</i> .
Integración	Compleja. Implica numerosos subsistemas.	Más sencilla al ser una solución monolítica del suministrador.
Gobernanza	Compleja por integrar gran variedad de subsistemas distintos de diferentes suministradores	Integrada por ser un sistema monolítico gestionado por un único suministrador.

Tabla 5. Comparación entre *data lake* y *data warehouse*.

Integración *data warehouse-data lake*

Frente a *data warehouses*, orientados a la analítica de negocio, los *data lakes* son sistemas generalistas, muy flexibles para adaptarse a un gran número de aplicaciones finales. La flexibilidad, escalabilidad y economía de los *data lakes* los han convertido en la opción preferencial del mercado.

A pesar de lo anterior, los *data warehouses* siguen siendo herramientas necesarias que han demostrado ofrecer un servicio de alto valor añadido a los analistas de negocio de las organizaciones.

Para evitar la duplicidad de sistemas, se hacía necesaria la incorporación de los *data warehouses* a las arquitecturas de los *data lakes*. A tal efecto se distinguen dos aproximaciones para la integración de los *data warehouses* en los *data lakes*:

1. **Arquitectura en dos niveles (Tier 2).** En los *data lakes* con arquitectura tier 2, los datos OLTP a partir de los cuales se construye el *data warehouse* se han incorporado al sistema como una fuente más desde la que se ingieren los datos. Como es práctica en *data lakes*, desde la zona de ingesta, los datos refinan y copian de zona en zona hasta alcanzar el grado de agregación y calidad deseado en la última zona de almacenamiento del sistema. Una vez allí, son sometidos a un proceso ETL adicional para la construcción del *data warehouse* sobre esta última capa del *data lake*, incluida la base de datos y los cubos OLAP.

2. **Data lakehouse.** En vez de replicar la arquitectura de un *data warehouse* sobre la última capa del *data lake*, el *lakehouse* utiliza ficheros de formatos de tablas de última generación, principalmente Apache Iceberg, Delta o Apache Hudi, para construir las estructuras de variables multidimensionales típicas de los *data warehouses*. Al emplear formatos de tablas, los casos de uso de analítica de negocio consistentes en consultas SQL n-dimensionales pasan a ser un caso más de uso de analítica en el *data lake*.

En el apartado destinado a describir los *data lakehouses* (ver 0) se desarrollan con más detalle los problemas asociados a las arquitecturas Tier 2 y las características del paradigma *data lakehouse*.

1.1.3 TENDENCIAS EN SISTEMAS DE EXPLOTACIÓN DE DATOS

En el ámbito de los sistemas de gestión de datos surgen cada año nuevos conceptos que sirven de reclamo por parte de los suministradores. Con frecuencia, estos conceptos suelen tener simultáneamente algo de avance tecnológico y algo de mera estrategia de marketing pero, normalmente, existe un porqué para su aparición y un problema subyacente que se trata de abordar. Esta rápida aparición de nuevos conceptos y tendencias es consecuencia del momento de ebullición del negocio y de las propias tecnologías de los sistemas de explotación de datos. De hecho, el *data lake* no es la última etapa en la evolución de estos sistemas, sino un paso intermedio hacia nuevos conceptos y arquitecturas para la explotación de los datos apoyados en tecnologías emergentes cuyo resultado final no parece aún claro a fecha de redacción de este tema.

En este apartado se agrupan las descripciones de las principales tendencias en dicha evolución. El apartado se presenta como una especie de cajón de sastre donde se incluyen tanto nuevos diseños conceptuales de sistemas de gestión de datos como tecnologías emergentes.

1.1.3.1 DATA LAKEHOUSE

Aunque el término *lakehouse* tiene más de una década de existencia, su definición como sistema con un alcance y finalidad establecidos es muy reciente⁸. Gartner define los *lakehouses* como sistemas de explotación de datos que «*integran y unifican las capacidades de los data warehouses con las de los data lakes, ofreciendo soporte de inteligencia artificial, inteligencia de negocio e ingeniería de datos en una misma plataforma*». Es decir, un *lakehouse* combinaría lo mejor del mundo de los *data warehouses* -basados en bases de datos relacionales y enfocados en la agregación de datos para la elaboración de informes de *business intelligence* y cuadros de mando- con la economía, flexibilidad y potencia de los *data lakes* para la ingeniería de datos, la analítica de datos y aplicación de técnicas de IA.

Los *lakehouses* surgieron como respuesta a una necesidad clara: muchas organizaciones que optaron por instalar *data lakes* en la última década se vieron en la necesidad de plantearse qué hacían con sus *data warehouses*. El dilema que se les presentaba era cómo reducir el coste de propiedad de sus sistemas de explotación de datos, ampliados con la adquisición de un *data lake*, sin prescindir de los beneficios que les reportaban los viejos, eficientes y probados, aunque caros de mantener, *data warehouses*.

La primera opción que surgió consistía en montar un *data warehouse* sobre el último repositorio de datos almacenados en el *data lake*. Como se comentó al hablar sobre la convergencia entre *data lakes* y *data warehouses* en el apartado 1.1.2.5, esto supone realizar la ingesta de los datos OLTP en el *data*

⁸ Algunas fuentes sostienen que el origen del significado actual del término procede del artículo del blog <https://databricks.com/blog/2020/01/30/what-is-a-data-lakehouse.html> aunque empresas como Amazon o Snowflake ya usaban el término en la fecha de publicación del artículo.

lake y someterlos a un proceso de ETL posterior para alimentar la base de datos relacional que soporta las tecnologías OLAP. A esta solución se la denomina arquitectura en dos niveles (Tier 2)

No obstante, esta solución plantea algunos inconvenientes:

a. Fiabilidad.

Mantener la consistencia entre los datos del *data lake* y el *data warehouse* es difícil y costoso porque esta arquitectura implica la ejecución de dos procesos de ETL que pueden demorarse en el tiempo: la carga de datos en el *data lake* y los procesos ETL posteriores necesarios para alimentar el *data warehouse*. Los riesgos de fallos y de errores de consistencia que reducen la calidad de los datos crecen exponencialmente al duplicar los procesos de carga.

b. Obsolescencia de los datos (data staleness)

Los datos destinados a alimentar el *data warehouse* sólo se pueden extraer una vez se encuentran cargados en el *data lake*, y este proceso puede durar días, obligando al sistema a alimentar el *data warehouse* con datos obsoletos.

c. Limitación en los procesos de análisis de datos

Los datos generados para y por el *data warehouse* resultan tan interesantes como difíciles de explotar por los sistemas de *Machine learning*. Esto es debido a las propias interfaces y formatos que ofrecen estos sistemas, muchas veces con formatos propietarios. Con esto se limita la capacidad de explotar los datos elaborados para inteligencia de negocio y cuadros de mando mediante técnicas de análisis de datos.

d. Coste de propiedad

El mantenimiento de estos sistemas sigue resultando caro por la duplicación de los datos empleados por el *data warehouse* y su tratamiento para poder explotarlos mediante técnicas analíticas.

e. Rendimiento del sistema

La arquitectura Tier 2 consigue la integración de *data lakes* con *data warehouses*, pero no alcanza los niveles de rendimiento de un *data warehouse* en términos de velocidad en las consultas SQL a los datos agregados para la generación de informes. Esto es resultado de la alta especialización de los *data warehouses* actuales, fruto de décadas de evolución que han permitido alcanzar un alto grado de madurez y eficiencia en su finalidad.

Dicho de otra forma, una arquitectura Tier 2 no alcanza, por un lado, los niveles de rendimiento de un *data warehouse* en la analítica de negocio ni, por el otro, permite aprovechar al 100% las capacidades de los *data lakes* para la analítica avanzada sobre los datos agregados que alimentan los *data warehouses*.

Mejoras introducidas por los *lakehouses*

El reto de los *lakehouses* es alcanzar los niveles equivalentes de rendimiento de los *data warehouses* para la inteligencia de negocio permitiendo simultáneamente la explotación de los datos de negocio por las herramientas de analítica avanzada

Para responder este reto, los *lakehouses* utilizan las siguientes tecnologías⁹:

1. Incorporación de una capa de metadatos para gestión de datos

⁹ Para más información se recomienda la lectura de [37]

La principal innovación es el uso de formatos de tabla como Apache Iceberg, Delta Lake o Apache Hudi para definir las estructuras de los datos junto con metadatos adicionales sobre los que apoyarse para realizar funciones típicas de gobernanza de datos, como control de acceso o auditoría (*audit logging*). Los formatos de tablas definen estructuras complejas de datos y ofrecen APIs sobre los que realizar consultas SQL destinadas a la realización de transacciones ACID. También soportan la definición de versiones y «viajes en el tiempo» (*time traveling*), entendido esto último como la capacidad de navegar por distintas versiones temporales de los conjuntos de datos, clave en la función de *data warehouses*. Todo ello soportado únicamente por formatos de tablas y ficheros de datos estándar junto con APIs específicas de consulta y sin necesidad de disponer de bases de datos relacionales.

Lo anterior es compatible con el uso de repositorios de bajo coste y la lectura directa y




Ilustración 15. Comparación de arquitecturas para la implementación de data warehouses.

desagregada de los datos subyacentes (ficheros Apache Parquet u ORC) por parte de las herramientas de analítica avanzada, si fuera preciso. Además, las herramientas de analítica avanzada pueden emplear también las APIs de los formatos de tabla para el acceso a los datos de inteligencia de negocio si se deseara emplearlos para algún caso de uso de *machine learning* o de ciencia de datos.

2. Mejora de las prestaciones de las consultas SQL

La introducción de formatos de tablas supone una mejora en las capacidades para la analítica de negocio y permite la explotación de los datos por las herramientas de analítica avanzada, pero no resulta suficiente para alcanzar un rendimiento similar al ofrecido por los *data warehouses* en términos de velocidad de respuesta a consultas SQL. Esto es debido a la alta optimización de los *data warehouses*, que utilizan técnicas para mejorar las prestaciones no disponibles en un *data lake*, como son la utilización de discos SSD para almacenar los datos más accedidos o uso de formatos de datos propietarios optimizados.

Para mejorar el rendimiento de las consultas, los *lakehouses* proponen, junto con el desarrollo de APIs para las consultas directas SQL, el uso de cachés y de ficheros auxiliares para el registro de estadísticas y el indexado de tablas, entre otras técnicas de optimización.

3. Uso de APIs de *dataframes* para la analítica avanzada

Los *dataframes* son estructuras de datos bidimensionales muy usadas en los lenguajes de programación más utilizados para analítica de datos y *Machine learning* como Python o R. Los *lakehouses* proporcionan APIs para acceso directo a los ficheros de datos que traducen instantáneamente el resultado a *dataframes* para su uso por las herramientas de analítica avanzada.

1.1.3.2 VIRTUALIZACIÓN DE DATOS

La asociación DAMA (Data Management Association) define virtualización de datos como una tecnología que permite que «*múltiples repositorios de datos sean accedidos y vistos desde un único lugar como si se encontrasen en una única base de datos.*» En otras palabras, la virtualización de datos permite integrar y presentar a los potenciales consumidores, datos procedentes de distintas fuentes sin necesidad de moverlos, transformarlos, agregarlos ni copiarlos **por adelantado**, sino **sólo en el momento de su consumo y transformados en el producto de consumo final**. La idea es presentar a los potenciales consumidores representaciones de datos transformados (informes, datasets limpios y anonimizados, etc.) en un catálogo desde donde puede descargarlos.



Ilustración 16. Arquitectura de los sistemas de virtualización de datos.

Las referencias de los datos transformados y sus metadatos se muestran en un catálogo unificado mientras los datos propiamente dichos permanecen en su lugar original hasta que los usuarios solicitan la descarga **bajo demanda** desde una API puesta a su disposición.

La virtualización es un modelo de gestión de datos que difiere tanto de los *data warehouses* como de los *data lakes* o los *lakehouses*, en los que los datos se descargan por adelantado en un repositorio donde se transforman y agregan tanto si se va a hacer un uso inmediato de ellos como si no.

En la virtualización, los datos se transforman y agregan en tiempo real en el momento de su descarga, caso de ser necesario, pero la tecnología de virtualización de datos abstrae la complejidad del proceso

a los consumidores que sólo conocen las características de los datos que van a descargar, no las de los datos originales.

A las arquitecturas y sistemas de gestión de datos basados en la extracción y descarga de datos (ETL o ELT)¹⁰ se los denomina arquitecturas y sistemas de gestión de datos *físicos* (*physical data architectures and management*) o de *consolidación* de datos físicos (*physical data consolidation*). Por su parte, a los basados en virtualización de datos se los denomina arquitecturas y sistemas de gestión de datos lógicos (*logical data architectures and management*) o consolidación de datos lógicos (*logical data consolidation*). Ejemplos de consolidación de datos físicos son los *data warehouses*, los *data lakes* o los *data lakehouses*. Por su parte, los sistemas basados en los principios de *data mesh* suelen incorporar virtualización de datos así como los que siguen el modelo de *data fabric*, que se verá más adelante.

Arquitectura de los sistemas de virtualización de datos

Las arquitecturas de los sistemas de virtualización de datos se pueden descomponer en cuatro capas:

1. Capa de conexión

Es responsable de acceder a datos variados repartidos en numerosos repositorios mediante conectores especializados en extraer los datos de cada una de las fuentes y que permiten acceder a información estructurada, semiestructurada y no estructurada. Los conectores no se limitan a descargar los datos sino que generan metadatos sobre los datos de las distintas fuentes que incluyen, entre otros, su esquema, formato, y cualquier metadato pertinente que se mostrará posteriormente en la capa de abstracción.

2. Capa de abstracción

También denominada capa virtual o capa semántica, la capa de abstracción es el corazón del sistema de virtualización, el puente entre el lugar donde residen los datos y los consumidores. Puede contener cachés donde almacenar datos que se han solicitado en el pasado pero, salvo esto, no almacena dato alguno, tan sólo almacena metadatos.

Los componentes esenciales de la capa de abstracción son:

- Gestión de metadatos que documenten los datos ofrecidos (estructuras, etiquetas, linaje, etc.)
- Catálogo dinámico. Organiza los datos disponibles clasificándolos y permitiendo la inclusión de etiquetas de negocio, y poniéndolos a disposición de los consumidores.
- *Caching* de datos. Útil para datos sometidos a descargas frecuentes.
- Control de calidad, aplicando una lógica de validación predefinida.
- Agregaciones y transformaciones. Si es necesario, la capa de abstracción transforma y agrega datos de entrada en el momento de la descarga (tiempo real).

3. Capa de consumo

¹⁰ Recuérdese que los *data warehouses* siguen el paradigma ETL (Extract/ Transform/ Load), en el que se transforman los datos durante el proceso de extracción y se almacenan transformados. En cambio, los *data lakes* siguen el modelo ELT, en el que primero se almacenan con poca o ninguna transformación y posteriormente se transforman y agregan en sucesivas etapas. En ambos casos, sin embargo, todos los datos susceptibles de ser explotados se descargan con antelación físicamente en un repositorio común donde se ponen a disposición de los consumidores.

Es el punto de acceso a los datos. Típicamente los sistemas de virtualización soportan gran cantidad de protocolos como SQL o cualquier tipo de API incluyendo estándares como JDBC, ODBC, REST o SOAP entre otros.

La capa de consumo facilita el autoservicio (*self service*) al ofrecer APIs que permitan el acceso directo a un producto de datos concreto sin necesidad de realizar consultas (*queries*). Dicho de otro modo, la virtualización de datos está especialmente enfocada a la prestación de servicios "llave en mano", entendido este término como servicios predefinidos extremo a extremo a los que el consumidor puede acceder directamente a través de APIs.

4. Capa de gobernanza

La capa de gobernanza afecta a todas las capas anteriores. Es la responsable de aplicar el control de acceso y de forzar la aplicación de políticas de uso que requieran transformación de los datos, como anonimización o enmascaramiento.

Beneficios de la virtualización de datos

La virtualización de datos ofrece numerosos beneficios que son de aplicación en un gran número de casos de uso de explotación de datos. A continuación se describen los más significativos:

- **Acceso en tiempo real**

Los datos se descargan en tiempo real directamente desde las fuentes, con lo que los usuarios tienen la garantía de que los datos accedidos son los presentes en las fuentes originales en el momento de su consumo. La garantía de obtener datos lo más actualizados posible en el momento de su consumo resulta crítica para numerosos casos de uso, como aplicaciones financieras de inversión en bolsa de valores.
- **Seguridad y gobernanza mejorada**

En algunas situaciones, puede ser costoso o arriesgado mover o duplicar datos, especialmente cuando se trata de datos sensibles o críticos. La virtualización de datos permite mantener los datos en su ubicación original y suministrar únicamente datos enmascarados o transformados. Esto puede resultar crítico para el cumplimiento de marcos normativos como el de protección de datos de carácter personal.
- **Bajo coste**

La virtualización requiere menos recursos comparado con los sistemas basados en consolidación de datos físicos porque no requiere grandes plataformas con *clusters* ni para almacenamiento ni para procesamiento distribuidos.
- **Agilidad y flexibilidad**

Todos los datos de la organización se encuentran disponibles a través de una única capa de datos virtuales por lo que implementar un nuevo caso de uso resulta más inmediato que en los sistemas basados en consolidación de datos físicos.
- **Capacidades de autoservicio (self-service)**

Permiten diseñar servicios de datos a los que se accede mediante APIs (informes, análisis de negocio, cuadros de mando) para usuarios no expertos a los que se abstrae toda la complejidad del servicio.
- **Evita la redundancia de datos**

La duplicación innecesaria de datos puede llevar a problemas de calidad de datos y aumentar los costes de almacenamiento.

Situaciones en las que la virtualización *no* es la solución óptima

La virtualización de datos no ha llegado con el objetivo de sustituir los sistemas de gestión de datos físicos sino a convivir con las soluciones existentes e integrarse en ellas. Existen numerosas aplicaciones de explotación en las que no resulta la opción óptima. A continuación se describen las más significativas:

- **Aplicaciones que requieren transformaciones complejas**
Cuando se requiere una transformación de datos compleja, como la limpieza, normalización, agregación o enriquecimiento de datos, los sistemas de gestión de datos físicos resultan más adecuados por contar con *clusters* y sistemas de transformación de datos con más capacidades y más escalables que aquellos de los que disponen los sistemas de virtualización.
- **Requisitos de almacenamiento a largo plazo**
Si se requiere almacenar datos de manera persistente para análisis históricos, cumplimiento normativo, o casos específicos de analítica de datos, la consolidación de datos físicos resulta una opción más adecuada por contar con repositorios preparados para el almacenamiento de grandes cantidades de datos. Este es el caso de los *data warehouses* o los *lakehouses*.
- **Manejo de grandes volúmenes de datos**
Por la misma razón que el caso anterior, la gestión de casos de uso que manejan grandes volúmenes de datos requiere habitualmente el uso de grandes repositorios basados en sistemas de almacenamiento distribuido. De igual forma, las soluciones basadas en la consolidación física de datos cuentan con *clusters* capaces de realizar tareas costosas en paralelo y las herramientas de transformación adecuadas.
- **Modelos complejos de datos estructurados**
La virtualización puede no resultar viable por sí sola si las estructuras de datos son tan complejas que resulta difícil configurarlas en tiempo real sin la ayuda de sistemas de procesamiento distribuido. La construcción, a partir de múltiples fuentes, de modelos de datos estructurados complejos, como son los que soportan las funcionalidades de los *data warehouses*, resulta más apropiada en sistemas de consolidación de datos físicos por disponer de potencia y herramientas adecuadas.

Los sistemas de virtualización de datos, más que constituir plataformas, son un middleware para la creación de servicios de datos en los que no se precisa la descarga por adelantado para prestar el servicio. No vienen acompañados necesariamente ni de *clusters* para almacenamiento de datos ni para procesamiento, por lo que por sí mismos no son adecuados para la gestión de datos masivos. Su ligereza y flexibilidad son su principal virtud y también su principal limitación. Pero de hecho se considera que, en un gran número de casos de uso, donde mejor están los datos es en su lugar de origen y la tendencia es a emplear virtualización para su explotación salvo que haya una razón de peso para lo contrario.

Como se verá, los esfuerzos de las nuevas tendencias en sistemas de gestión se están realizando principalmente en la gestión de los metadatos; en tener los datos controlados y documentados, más que en disponer de un repositorio común para todos ellos. Es tendencia la elaboración de catálogos lo más enriquecidos posible en los que basar la gestión de los datos de la organización de forma que se ofrezca una visión completa y global con independencia de dónde se encuentren almacenados, evitando las descargas y transformaciones innecesarias. En un escenario así, la virtualización de datos ocupa un lugar relevante.

Por lo anterior, los nuevos sistemas de gestión de datos combinan las aproximaciones física y lógica. De hecho, la virtualización forma parte de los fundamentos tecnológicos de las nuevas tendencias en sistemas de explotación como son los data mesh o los data *fabric*.

1.1.3.3 DATA MESH

El término *data mesh* apareció por primera vez en 2019 en un artículo de la consultora tecnológica Zhamak Dehghani en el que definía el concepto como «una manera descentralizada de gestionar, acceder y compartir datos analíticos dentro de una organización y entre organizaciones» [5].




Ilustración 17. Arquitectura general de un data mesh. Los dominios elaboran sus propios productos y los comparten. Para ello cuentan con equipos multidisciplinares (TIC y negocio) y usan los servicios ofrecidos por una plataforma de autoservicio común.

En sentido estricto, el término no hace referencia a una nueva arquitectura para construir sistemas de gestión de datos sino a un conjunto de principios y buenas prácticas para la generación de datos analíticos, su explotación y compartición en las que el actor principal es el **dominio**, que actúa a la vez como consumidor y proveedor de datos. Como se verá, el *data mesh* es en esencia un modelo de gobernanza y de gestión de datos.

Un dominio es un área de negocio de la organización (ventas, producción, recursos humanos, etc.) a la que se ha dotado de recursos tecnológicos para crear servicios de explotación de datos que crean valor a partir de los sistemas operacionales que el área de negocio gestiona. Se trata por tanto de un equipo multidisciplinar capacitado para actuar en todas las tareas necesarias para extraer valor de sus datos, desde la ingesta a los procesos de transformación y agregación, hasta la analítica necesaria para que los datos dispongan de valor de negocio.

La organización por dominios, junto con otros principios y buenas prácticas, resolverían el problema que supone la complejidad creciente de los *data lakes* actuales y la dificultad de orientar la explotación de los datos hacia un objetivo de negocio que proporcione un beneficio real. Mediante la constitución de dominios se evitaría la desconexión entre los equipos implicados en la explotación del dato: un equipo especializado que carga y prepara datos operacionales de la organización (los ingenieros de

datos), otro equipo independiente que aplica a los datos técnicas de ciencia de datos e inteligencia artificial para generar valor (los científicos de datos y expertos en IA), y un tercero -el área de negocio- que consume el resultado, sobre los que actuarían los responsables de aplicar el marco de gobernanza (propietarios, responsables y custodios de los datos).

Se puede decir por tanto que, en la práctica, el concepto de *data mesh* propone una manera innovadora de ejecutar la gobernanza del dato entendida esta como «*quién puede hacer qué cosas, sobre qué datos, en qué situaciones y de qué manera*».

El ámbito de aplicación de los *data mesh* son las grandes organizaciones que tienen entidad suficiente como para crear dominios como los definidos.

Los cuatro principios que rigen los *data mesh* son los siguientes:

1. Arquitecturas descentralizadas y propiedad de los datos orientada al dominio.

El modelo es orientado al dominio porque son los dominios los encargados de concebir los casos de uso de explotación de datos y de implementarlos extremo a extremo gracias a que constituyen equipos multidisciplinares. Dado que los dominios pertenecen a las áreas de negocio, el ser un modelo orientado a dominio implica estar más orientado al negocio.

Por su parte, el modelo es descentralizado porque cada dominio es autónomo y autosuficiente en la explotación de los datos. Para la implementación de casos de uso no es preciso encargar los trabajos de desarrollo a las unidades TIC de la organización responsables de la gestión de la plataforma de datos y de los sistemas operacionales ni a los expertos en ciencia de datos e IA.

Además, una vez creados, los datos resultantes se comparten con el resto de los dominios a mediante una topología tipo malla o *mesh* (todos con todos), de ahí el nombre de *data mesh*.

Esta aproximación facilita una explotación de los datos más racional y orientada al consumidor (el área de negocio, que dirige el dominio) y facilita el mantenimiento. Permite también la generación de sinergias entre unidades de negocio al facilitar la compartición de productos de datos.

2. Datos como producto

El lema «*datos como producto*» define un principio no tecnológico que establece como práctica el cuidado y la atención sobre los datos generados y explotados en la organización. Que el dato sea el producto implica poner en él tanta atención como en los productos de mercado que genera la organización. Se asume además su publicación dentro o fuera de la organización como un activo importante, evitando la creación de silos de datos aislados.

Los productos generados y expuestos son *datasets* que deben reunir las condiciones de ser descubribles, accesibles, entendibles, confiables, interoperables y seguros. Habitualmente para la publicación de datos se emplean habitualmente catálogos de datos virtualizados (ver 0 1.1.3.2 VIRTUALIZACIÓN DE DATOS) con metadatos descriptivos y contratos de datos.

3. Plataforma de autoservicio

Este principio es una consecuencia de la descentralización y la orientación al dominio. Para que los dominios sean realmente autónomos se requiere disponer de una plataforma que les ofrezca, mediante las oportunas interfaces, funcionalidades para la gestión y explotación de los datos de manera que, sin participación de más personal que el que

forma parte del dominio y excluyendo por tanto a las áreas TIC que gestionan la plataforma de datos corporativa, puedan llevar a la práctica los casos de uso de explotación del dato que diseñen.

Se requiere por tanto una plataforma que permita el autoservicio de los dominios en la concepción y ejecución de los casos de uso.

4. Gobernanza federada

El último principio establece que debe existir una gobernanza común por encima de los dominios que decida cómo van a operar los dominios: qué derechos tienen, qué recursos van a usar, reglas de funcionamiento común, cómo publicar y compartir los activos de datos, interoperabilidad entre dominios, etc.

Esto es necesario debido a que, aunque los dominios sean autónomos, en la práctica sólo va a existir una plataforma de datos que deben compartir entre todos o, en el caso de que hubiera varias plataformas, se requiere que sean interoperables, lo que hace indispensable un nivel de gobernanza superior que defina las normas de interoperabilidad que deben cumplir.

Las buenas prácticas definidas bajo el concepto de *data mesh* son una respuesta a la creciente complejidad de los sistemas de explotación de datos, que introduce una enorme distancia entre las áreas tecnológicas y las de negocio que en muchas ocasiones impiden la puesta en práctica de casos de uso, la disseminación de los resultados entre los distintos departamentos de la organización y la aplicación de un marco de gobernanza. Para paliar estos problemas proponen un modelo de gobernanza colaborativo en la que, mediante la introducción del concepto de dominio, los datos tienen asignado un equipo de trabajo interdisciplinar encargado de su explotación, de su compartición y de la aplicación del marco de gobernanza.

1.1.3.4 GESTIÓN DE METADATOS ACTIVOS

Los metadatos activos son un paso más en el enriquecimiento y actualización de los metadatos registrados y mostrados en un catálogo. Gartner define metadatos activos como aquellos recogidos por «*un sistema permanentemente activado (always-on), impulsado por tecnologías de IA (intelligent-driven), orientado a la acción (action-oriented) y basado en APIs (API-driven)*».

En otras palabras, los metadatos activos son un tipo de metadatos recogidos por sistemas especialmente dedicados a la tarea que poseen las siguientes características:

1. Permanentemente activado.

Los sistemas de gestión de metadatos activos se encuentran siempre en funcionamiento para detectar eventos que requieran la asignación de nuevos metadatos a los *datasets* de forma automatizada. No esperan a que haya disponible un operador para enriquecer un activo de datos con metadatos adicionales, sino que están permanentemente activados para enriquecer los datos con metadatos que describan cualquier característica que les sea de aplicación: desde una transformación al histórico de uso de los datos.

2. Impulsado por tecnologías de IA/ML

Muchos *data lakes* contaban ya con capacidades para crear metadatos de forma automatizada conforme los datos se cargaban, transformaban y usaban. La característica más diferenciadora de los metadatos activos es que emplean IA/ML para el análisis de los datos, extrayendo conclusiones conforme los datos se procesan y usan que se traducen en metadatos que se añaden a los catálogos de datos.

3. Orientado a la acción.

Los metadatos activos no sólo mejoran la descripción de los datos añadiendo metadatos adicionales, sino que generan recomendaciones, alertas, avisos, o incluso intervienen en los *data pipelines* sin intervención humana *cada vez que pasa algo*. Por ejemplo, si en un determinado momento se detectan problemas de calidad en los datos ingeridos (v.g. más nulls de los esperados) o se detectan anomalías, el sistema de gestión de metadatos activos, que supervisa la operación para registrar los resultados y crear metadatos, podría enviar alertas e incluso parar el *pipeline*.

4. Basado en APIs

Los sistemas de gestión de metadatos ofrecen e invocan APIs para intervenir en todos los procesos que afectan a los datos de un sistema de gestión de datos de forma que pueda realizar su labor de generación de datos activos en tiempo real.

A lo anterior habría que añadir que los metadatos activos se diferenciarían de los pasivos en que estos últimos describen características invariantes de los datos como son su esquema, los tipos de los campos o el modelo de información. Los metadatos pasivos se refieren normalmente a características técnicas y no describen el contexto de los datos sino que se refieren únicamente a su naturaleza.

Por su parte, los metadatos activos están en constante evolución y se actualizan en tiempo real o de manera casi inmediata tras la modificación del contexto de los conjuntos de datos que describen. Una modificación del contexto puede ser una simple descarga por parte de un consumidor que requiera actualizar los metadatos que describen el uso del conjunto de datos o el establecimiento de nuevas relaciones semánticas con otro conjunto de datos del catálogo. Pueden ser técnicos, operacionales, de negocio o sociales, y su objetivo final es describir tanto la naturaleza como el normalmente cambiante contexto de los datos, por lo que requieren para su creación sistemas integrados extremo a extremo con la tubería o pipeline que procesa los datos desde su fuente hasta su puesta a disposición.

El impacto de los sistemas de gestión de metadatos activos en los sistemas de gestión de datos se prevé que sea significativo, como se verá cuando se describan los catálogos aumentados y la última tendencia en diseños de sistemas de gestión de datos: los *data fabric*.

1.1.3.5 USO DE GRAFOS DE CONOCIMIENTO (*KNOWLEDGE GRAPHS*)

Los grafos de conocimiento, *knowledge graphs*, o redes semánticas, constituyen otro de los pilares de los nuevos sistemas de gestión de datos. Se trata de una tecnología tomada prestada de los motores de búsqueda de Internet.

Los grafos de conocimiento se definen como «*una representación en forma de red de instancias del mundo real (objetos, eventos, situaciones o simplemente conceptos) de una forma tal que se muestra la relación entre dichas instancias* [6]».

Una definición más descriptiva y menos enfocada en su finalidad define grafos de conocimiento como «un conjunto de grafos dirigidos y etiquetados compuestos por tres elementos: nodos, aristas y etiquetas [8]».




Ilustración 18. Ejemplo de grafo de conocimiento entre dos instancias de distintas entidades

En el ámbito de las redes semánticas, los nodos de un grafo son instancias de algún tipo de entidad presente en los conjuntos de datos que pueden ser *sujetos* u *objetos*, dependiendo de en qué sentido de la arista se encuentren; las aristas disponen de sentido y sirven para unir un sujeto con un objeto indicando de esta manera que existe una relación entre ambas instancias en el sentido indicado; la etiqueta, denominada también *predicado*, describe el tipo de relación que existe entre ellas.

Un tipo especial de grafo de conocimiento es aquel en el que las instancias son las propias entidades (clases y subclases) de un dominio concreto. En este caso, el grafo de conocimiento definiría la **taxonomía** de ese dominio particular. En todo caso, los grafos de conocimiento incluyen tanto las relaciones entre instancias como la taxonomía de las entidades. Además incluyen grafos que relacionan las entidades con las instancias; esto es, grafos que especifican a qué tipo de entidad o entidades pertenece cada una de las instancias según la taxonomía definida.




Ilustración 19. Ejemplo de grafo de conocimiento. Las relaciones entre entidades se definen con la etiqueta "es_un" o "es_una" y definen las taxonomías. Las relaciones entre instancias y entidades sirven para indicar el tipo de entidad a la que pertenece la instancia y también se marcan con esas etiquetas. En el caso de relaciones entre instancias los tipos de relación pueden ser muy variados; en todo caso, las etiquetas indican el tipo concreto de relación.

En el contexto de un sistema de gestión de datos moderno, los grafos de conocimiento se consideran metadatos activos derivados de aplicar analíticas de IA/ML a los conjuntos de datos disponibles. La consideración de estos metadatos como activos tiene que ver con su propia naturaleza: las redes que definen los grafos de conocimiento están en constante evolución y forma parte del contexto de los conjuntos de datos; la introducción en el sistema de un nuevo *dataset*, relacionado con datos ya ingeridos y catalogados, provoca un cambio en el grafo de conocimiento global. Sería por tanto responsabilidad del sistema de gestión de metadatos activos analizar permanentemente los datos existentes para la extracción y modificación constante de los grafos. Los grafos se almacenan típicamente en bases de datos especializadas para grafos de conocimiento como Amazon Neptune, IBM Graph o Neo4j, entre otras opciones y normalmente puede ser visualizada. Por su parte, el estándar más extendido para expresar grafos de conocimiento es RDF y los formatos más aceptados de RDF son *turtle*, RDF/XML o JSON-LD.

La potencia de esta tecnología aplicada a los sistemas de gestión de datos se intuye sin más que considerar algunas de sus aplicaciones. Por poner un ejemplo, los grafos de conocimiento permiten detectar anomalías en las relaciones de las instancias o correlaciones entre entidades que a simple vista resulta difícil de detectar. Integrados en los motores de búsqueda de un catálogo de datos permiten sugerir conjuntos de datos para su descarga a los potenciales consumidores de datos a partir de los datos de búsqueda, el rol del consumidor y el propio consumo global de los datos, lo que convierte esta tecnología en uno de los fundamentos de los catálogos aumentados, como se verá.

1.1.3.6 CAPACIDADES DE AUTOSERVICIO (SELF-SERVICE CAPABILITIES)

Ya se ha señalado al analizar los modernos sistemas de gobernanza la importancia de del autoservicio como parte integrante de un sistema de gestión de datos. En este ámbito, se entiende por autoservicio la digitalización y automatización de tareas y procesos que de otra forma requerirían la intervención y el soporte de personas en la organización no relacionadas con el área de negocio [8] En otras palabras, consiste en otorgar al personal del área de negocio la capacidad de realizar tareas como generación de informes, descubrir y acceder conjuntos de datos o comprender la calidad de los datos ofrecidos, sin el soporte del área TIC de la organización. A su vez, esto permite al área TIC de la organización dedicarse a tareas más cualificadas que no pueden realizarse mediante autoservicio.

Como se comentó al describir el concepto de *data mesh*, se considera que existe una brecha entre los especialistas TIC y las áreas de negocio y que esta brecha constituye un obstáculo para la agilidad en el desarrollo de casos de uso y la eficacia en la explotación de los datos. Las capacidades de autoservicio se introducen como un medio para salvar la mencionada brecha.

Las capacidades de autoservicio más significativas son:

Capacidad	Descripción
Acceso al catálogo de datos para los usuarios de negocio	Acceso al catálogo de datos con las credenciales corporativas a los usuarios de negocio, no sólo a los de las áreas tecnológicas.
Documentar las APIs de acceso a los datos	Los metadatos deben incluir información sobre cómo acceder a los datos que describen mediante APIS (SQL, REST, .Net, etc.)

Información holística de los datos	El catálogo debe incluir información no sólo técnica sino de negocio proporcionando una visión completa de los conjuntos de datos comprensible por el área de negocio.
Generación de metadatos activos	Generación automática de metadatos activos que ofrezcan información de contexto de los conjuntos de datos puestos a disposición, incluida información de negocio que ayude a los usuarios de negocio a entender el conjunto de datos.
Capacidades de búsqueda semántica	Búsqueda semántica basada en tecnología de IA/ML que se apoye, entre otras tecnologías, en grafos de conocimiento que muestre correlaciones entre activos que no resultan obvias de identificar y que sean relevantes para la finalidad descrita por el usuario. Se incluye búsqueda a partir de instrucciones impartidas en lenguaje natural (capacidades de NLP) que sustituye, por ejemplo, la introducción de comandos SQL.
Herramientas gráficas para la preparación y exploración de datos	Herramientas de preparación y exploración de datos que puedan ser usadas por personal no tecnológico y que sean autoexplicables.

Tabla 6. Capacidades de autoservicio

1.1.3.7 CATÁLOGO AUMENTADO

Gartner define el término *catálogo aumentado* como un tipo de catálogo que «*automatiza tareas propias de los catálogos de datos como el descubrimiento y enriquecimiento de metadatos o la creación de relaciones semánticas, mediante el uso de tecnologías de machine learning* [9]». Además, añaden: «*Estos catálogos de nueva generación [lo catálogos aumentados] permitirán la participación de los usuarios de negocio en la comprensión, enriquecimiento y el uso de los metadatos que den forma a iniciativas de analítica de datos*».

Un catálogo aumentado asume por tanto todas las características especificadas el apartado 0 pero además añade un uso exhaustivo de la inteligencia artificial/ *machine learning* y un especial hincapié en facilitar la participación de los usuarios de negocio.

Como se puede comprobar, el término *catálogo aumentado* no es más que la formalización de un concepto del que se ha estado hablando a lo largo del tema: catálogos que hacen un uso intensivo de la IA y fomentan la colaboración, para lo cual hacen uso de las tecnologías antes mencionadas:

- Grafos de conocimiento: para análisis semántico de los conjuntos de datos y establecimiento de relaciones.
- Metadatos activos: que capturan metadatos de forma automatizada durante todo el ciclo de vida de los datos.
- Autoservicio: para facilitar la autonomía de los usuarios y su participación.
- Herramientas de búsqueda basadas en IA y NLP.

Las tareas típicas de un catálogo aumentado se pueden sintetizar en:

1. **Descubrimiento** de metadatos: localización y extracción de metadatos (incluido linaje), obtención de grafos de conocimiento de los *datasets* y establecimiento de relaciones

semánticas entre los conjuntos de datos. Los catálogos modernos ofrecen APIs para que fuentes de datos puedan acceder a ellos mediante mecanismos de envío (push).

2. **Comprensión** del dato, enriquecimiento y confianza. Tareas encaminadas a una mayor comprensión de los datos. Para ello se organizan y se realiza el perfilado de los datos. Para la organización se emplea, entre otros, el glosario de negocio que contiene la taxonomía de categorías y subcategorías de negocio de la organización.
3. **Gobierno**. Se trata de las tareas específicas para la adecuación de los datos al marco de gobernanza. Consiste en detectar en qué medida son de aplicación la normativa vigente y las políticas corporativas y aplicar el tratamiento adecuado. Por ejemplo, en el caso de tratarse de datos personales o confidenciales se pueden aplicar técnicas de enmascaramiento dinámico o estático¹¹.
4. **Contribución**. Tareas realizadas por los propios usuarios para el enriquecimiento de los



Ilustración 20. Tareas soportadas por un catálogo aumentado.

datos, como pueden ser valoraciones, comentarios, anotaciones o la aplicación de técnicas mediante autoservicio, como limpieza de datos o curación.

5. **Consumo**. Las últimas tareas son las relacionadas con el consumo de los datos. Aquí se incluyen las herramientas de búsqueda por categorías de negocio, por relaciones semánticas o por cualquier criterio que permitan los metadatos recogidos. Los catálogos modernos ofrecen interfaces de procesamiento de lenguaje natural para la búsqueda de conjuntos de datos. Además, el catálogo debe ofrecer APIs para la consulta del catálogo y la descarga de datos por parte de herramientas de terceros, como herramientas de *Business Intelligence* o de ciencia de datos/*Machine Learning*.

¹¹ Se denomina enmascaramiento dinámico (Dynamic Data Masking o DDM) a las técnicas de enmascaramiento que se aplican en el momento de uso de los datos. Requiere normalmente control de acceso basado en roles (RBAC) para conocer los permisos de acceso del consumidor en función del rol asociado. Por el contrario, el enmascaramiento estático de datos (Static Data Masking o SDM) es el nombre que reciben las técnicas de enmascaramiento que se realizan por adelantado, antes del consumo de los datos independientemente del rol del consumidor.

Mención especial merecen los recomendadores de un catálogo aumentado. Los recomendadores no se limitan a aconsejar qué datos se ajustan a un criterio de búsqueda sino que, basándose en los metadatos, realizan acciones como:

- Sugerencias sobre potenciales transformaciones que convienen a los datos. Por ejemplo, puede evaluar la calidad de los datos y recomendar una limpieza.
- Avisos sobre anomalías en los datos y sus relaciones detectadas gracias a los grafos de conocimiento.

1.1.3.8 DATAOPS, MODELOPS, MLOPS

No todas las tendencias consisten en nuevos conceptos de arquitectura o aplicación de tecnologías emergentes. DataOps, ModelOps y MLOps son iniciativas encaminadas a establecer, si no una metodología formal en sentido estricto, sí un conjunto de buenas prácticas que permitan abordar los proyectos de ciencia de datos en general, y de IA en particular, de una manera más sistemática y que favorezca tanto la reducción de los tiempos de entrega como la calidad del producto ofrecido.




Ilustración 21. DataOps, MLOps/ModelOps y su relación con DevOps.

La diferencia entre las prácticas DataOps, ModelOps y MLOps está en el ámbito de aplicación:

- DataOps cubre las etapas de procesamiento de los datos desde la ingesta hasta que los datos se ponen a disposición de los científicos de datos para la creación de modelos de IA/machine learning.
- MLOps cubre todo el proceso de creación de modelos de IA a partir de los datos entregados por DataOps y finaliza cuando los modelos se encuentran desplegados y funcionando en producción.
- ModelOps gestiona el ciclo de vida de los modelos en producción, incluyendo la monitorización de su eficacia y la eficiencia. Se puede considerar que ModelOps es una ampliación del ámbito de MLOps.

DataOps

Gartner [10] define DataOps como «*una práctica colaborativa de gestión de datos centrada en mejorar la comunicación, integración y automatización de flujos de datos entre gestores de datos y consumidores de datos en toda una organización. El objetivo de DataOps es entregar valor de manera más rápida mediante la creación de una entrega y gestión predecible de datos*».

DataOps por tanto no es un producto ni una tecnología, sino un conjunto de buenas prácticas destinadas a acelerar la entrega de productos de datos y a convertir un proceso cargado de incertidumbre, y que tiene mucho de artesanal, en algo predecible, valioso y de calidad. El ámbito de DataOps es la ingeniería de datos; esto es, el proceso desde la ingesta de los datos hasta que se ponen a disposición de los científicos de datos para su explotación mediante analíticas o mediante técnicas de IA/ML.

DataOps toma prestadas prácticas de tres metodologías que han demostrado aportar valor en sus respectivos ámbitos:

1. Metodología ágil

La metodología ágil es particularmente efectiva en entornos poco predecibles con requisitos que evolucionan rápidamente, algo habitual en proyectos de ciencia de datos. Su aplicación permite una respuesta más rápida y alineada con las prioridades inmediatas de los usuarios finales.

2. DevOps

DevOps es una metodología de desarrollo software que se fundamenta, por un lado, en la creación de equipos multidisciplinares que integran a desarrolladores y responsables operacionales de los productos software y, por el otro, en la automatización de tareas como compilación, pruebas unitarias, de integración, de sistema y entrega. La aplicación de la automatización propia de DevOps a DataOps es inmediata: el objetivo es disponer de una infraestructura de automatización que permita crear el data pipeline que produce el artefacto, lo pruebe y publique una nueva analítica con sólo un clic de ratón. A este método de entregar nuevos productos se lo denomina en DevOps entrega continua (*Continuous Delivery*) y es también uno de los fundamentos de DataOps.

Al igual que ocurre con DevOps, DataOps también se basa en la creación de equipos multidisciplinares, en este caso formados por ingenieros de datos y científicos de datos, que serán los que tomen el resultado de DataOps para elaborar modelos de IA.

La metodología ágil y DevOps van de la mano: con la primera se facilita la especificación y el compromiso en la disponibilidad de nuevos artefactos y con la segunda se sistematiza la entrega y el paso a producción de una manera automatizada y más veloz.

La diferencia entre DataOps y DevOps está en que, mientras que DevOps combina tareas de desarrollo software y operaciones en un proceso automatizado, DataOps automatiza el data *pipeline*; esto es, la ingestión, transformación, las agregaciones necesarias para crear el producto final, que se realizan de una manera orquestada mediante las oportunas herramientas de creación de *data pipelines*.

3. Control estadístico de procesos

El control estadístico de procesos o SPC, es una práctica propia de la metodología Lean consistente en monitorizar las etapas de un proceso de fabricación para detectar desviaciones y anticipar problemas de calidad.

Aunque el SPC de la metodología Lean está pensado inicialmente para cadenas de producción, existen paralelismos entre, digamos, la fabricación de un coche y la

construcción de un *dataset* en cuanto a que en ambos casos existe una cadena de producción formada por una serie de procesos (eslabones de la cadena). En el caso de los productos de datos se trata de los procesos de ingestión->refinado->curación de los que ya se ha hablado en otros apartados. Mediante SPC se controla el resultado de cada proceso del data pipeline, no sólo desde el punto de vista de la calidad sino de la aplicación de la normativa y las políticas de la organización. Si ocurre alguna anomalía, el equipo de «desarrollo» de la tubería será el primero en saberlo mediante el envío de un aviso.

MLOps/ModelOps

El objetivo principal de MLOps es ayudar a los científicos de datos en la elaboración y entrega rápida de modelos de *machine learning* a sistemas y aplicaciones que se encuentran en producción. Al igual que DataOps, MLOps se basa en la automatización de tareas específicas para el aprendizaje automático (ver Ilustración 21): Ingeniería de características (*feature engineering*), optimización de hiperparámetros, control de versiones, evaluación de modelos y, finalmente, despliegue de los modelos creados en producción.

MLOps toma de DevOps tanto la automatización de tareas como participación de equipos interdisciplinarios de ingenieros de datos, científicos de datos, desarrolladores y operaciones y, al igual que DataOps, emplea metodologías ágiles y monitorización de los procesos.

Si el ámbito de MLOps es la creación de modelos de IA, el de ModelOps es la supervisión del comportamiento de los modelos en producción. Hay que tener en cuenta que, frente al código entregado por DevOps o los datasets producto de DataOps que son invariantes e independientes del contexto, los modelos de IA/*machine learning* tienen la particularidad: se degradan con su uso; es decir, su comportamiento varía al variar el contexto. Si este contexto es cambiante, es obligada la monitorización de los modelos para asegurar que no pierden eficacia, lo que puede requerir reentrenar los modelos y volver a desplegarlos. Este es el motivo de la extensión de MLOps en su primo hermano ModelOps.

1.1.3.9 DATA FABRIC

La última tendencia que se va a analizar en este tema es la del data *fabric*. Se deja para el final porque, en cierta medida, es la integración de la mayoría de las que se han descrito en este apartado.

Justificación del concepto

El data *fabric* es nuevamente un *concepto de arquitectura*¹² de sistema de gestión de datos que da respuesta a tres problemas que se presentan en la actualidad:


1. La diversidad de localizaciones de los datos de las organizaciones. En el ámbito de la UE, hasta un 41% de las empresas hacían uso de servicios en la nube en 2021 según Eurostat [11], de los que un 73% utilizan servicios considerados como "sofisticados" como aplicaciones de seguridad, hosting de bases de datos o plataformas de desarrollo.
2. La falta de eficiencia en la explotación del dato: se estima que sólo un 12% del total del esfuerzo dedicado a extraer valor de datos se dedica a la analítica, frente a las tareas de gobernanza, preparación¹³ y descubrimiento [12].

¹² Gartner lo define como un *concepto de diseño de arquitectura* (*architecture design concept*).

¹³ La preparación de los datos es el proceso de poner a disposición conjuntos de datos válidos para su uso mediante técnicas de ciencia de datos o analítica de negocio. Implica operaciones de

3. Las expectativas no cumplidas sobre los beneficios de la explotación del dato. Un estudio realizado por Gartner en 2022 llegaba a la conclusión de que sólo un 44% de los equipos especializados en explotación de los datos y analíticas proporcionaban valor a sus organizaciones [13].

De lo anterior se deduce la necesidad de una aproximación a la explotación del dato que permita gestionar todos los datos disponibles, estén donde estén, al tiempo que se consigue extraer valor de ellos en menos tiempo y con menos esfuerzo.



Fuente: IDC's Data Integration and integrity End-User Survey, 2019

Ilustración 22. Reparto del esfuerzo en realizar una analítica.

El hecho de que sea un concepto y no una arquitectura definida complica la tarea de establecer fronteras que lo delimiten y la definición de sus componentes y funcionalidades finales. En realidad, el concepto de data *fabric* se encuentra aún en sus primeras etapas de implantación y lejos de la madurez pero, a pesar de lo nebuloso que en ocasiones pueda parecer la idea, es la última tendencia en sistemas de explotación de los datos y los principales suministradores se han apresurado a comunicar que disponen de soluciones data *fabric* plenamente operativas.

Definición de data *fabric*

Forrester define data *fabric* de una manera bastante exhaustiva como [14] «Una plataforma unificada, integrada e inteligente de extremo a extremo que soporta nuevos y emergentes casos de uso. Un data *fabric* automatiza todas las funciones de gestión de datos -incluidas la ingestión, transformación, orquestación, gobernanza, seguridad, preparación, calidad y curación de datos- facilitando el conocimiento y la analítica para acelerar la ejecución de casos de uso rápidamente». En su desarrollo del concepto, Forrester resalta la automatización y la aplicación de IA en todas las funciones de gestión del dato, incluyendo la aplicación de grafos de conocimiento.

Reelaborando la definición anterior se puede concluir que data *fabric* es un concepto de arquitectura que pretende la integración de los datos y la orquestación de sus procesos de gestión de manera automatizada mediante el **uso de IA y la creación de una capa unificada de metadatos por encima de todos los datos** de la organización, independientemente de su tipo (estructurados, no estructurados, semiestructurados) o donde se encuentren (un data *lake*, un repositorio de datos en la nube, los propios sistemas operacionales, un data *warehouse*, etc.)

descubrimiento, perfilado, limpieza, enriquecimiento y aplicación de marcos de gobernanza de forma que se garantice la seguridad y calidad de los datos para su explotación.

Las funcionalidades clave de un data *fabric* son por tanto **la integración de todos los datos y la orquestación y automatización de tareas** pero, para la integración de los datos, no exige que se




Ilustración 23. Esquema de un diseño de data fabric.

ponga a disposición un repositorio específico (tampoco lo prohíbe). En cambio, crea un nivel de abstracción sobre todos los datos, estén donde estén, a partir de la acumulación de metadatos (muchos, muchos metadatos) que los describen a todos y a sus relaciones. Sobre los metadatos reunidos se ofrece a los consumidores funcionalidades propias de los catálogos aumentados como, por ejemplo, autoservicio (por ejemplo, transformaciones y agregaciones), colaboración, búsqueda, recomendaciones, etc.

Data *fabric* y virtualización

En cierto sentido, el data *fabric* recuerda la virtualización de datos, en la que se presenta una capa de metadatos y un catálogo que abstraen para el consumidor la lógica de la ingesta y transformación del dato. Pero, aunque data *fabric* sigue el concepto de abstracción mediante metadatos y el uso de un catálogo propios de la virtualización, además, busca aprovechar al máximo las posibilidades que ofrece la IA/ML para la automatización de tareas y la obtención de metadatos, así como la orquestación de

procesos y la explotación del autoservicio, con el objetivo final de crear productos de calidad, predecibles y reusables con menos esfuerzo y a mayor velocidad.

Componentes de data *fabric*

Debido a que no es más que un concepto de diseño, no hay un documento de referencia que especifique la arquitectura de un data *fabric*; no obstante, a partir de su definición y objetivos y de la oferta de los proveedores, cabe deducir un conjunto de componentes básicos para su implementación. Será responsabilidad del diseñador de data *fabric*s escogerlos (o desarrollarlos) y combinarlos para formar un sistema coherente que cumpla con la definición del concepto y logre sus objetivos.

Estos componentes son:

1. Catálogo aumentado

Es la clave de bóveda de un data *fabric*. El catálogo aumentado (que se describió en el apartado 0) se apoya sobre una montaña de metadatos y descubre, describe, perfila, organiza y categoriza todos los datos del data *fabric*. Es el único punto de entrada para los consumidores a los datos disponibles. El catálogo de un data *fabric* debe escalar para poder registrar todos los datos disponibles, sean estos estructurados, semiestructurados o no estructurados. Debe contar con un glosario de negocio para organizar los datos.

2. Grafos de conocimiento

Ya se comentó en el apartado 1.1.3.5 las características y la importancia de los grafos de conocimiento tanto como ayuda para las herramientas de búsqueda como para el recomendador y para el descubrimiento y perfilado de los datos (por ejemplo, detectando anomalías).

Los grafos de conocimiento aportan valiosos metadatos que el catálogo aumentado gestionará para realizar sus muchas funciones como, por ejemplo, el motor de recomendación.

3. Metadatos activos

Esta tecnología es clave para el enriquecimiento de los datos mediante metadatos que describen el contexto cambiante de los datos. Resulta particularmente útil para el análisis continuo de los datos propio de DataOps y para garantizar la calidad, y aportan una herramienta más para la seguridad y la gobernanza de los datos

4. Motor de recomendación

Ya se habló de esta funcionalidad al hablar del catálogo aumentado porque suele estar integrada en este sistema. El recomendador está basado en AI/ML y no sólo realiza sugerencias a los consumidores sobre los datos que más les pueden interesar en función de los parámetros de búsqueda y su perfil, sino que sirve de ayuda para:

- Mejorar la entrega: incluyendo sugerencias sobre cómo pueden transformarse los [15] datos para mejorar la calidad.
- Interpreta los datos: encontrando relaciones entre conjuntos de datos, clasificándolos y aplicando reglas de calidad si aplica, o aplicando las políticas de gobernanza del dato de la organización.
- Detectando anomalías en la estructura de los datos, avisando a los usuarios de que algo anda mal.

5. Autoservicio

Un data *fabric* permite a los usuarios preparar (mediante transformaciones) los datos para su uso. Es más, la IA puede aprender de las transformaciones realizadas por los usuarios y sugerir la aplicación de una transformación concreta mediante herramientas de autoservicio como, por ejemplo, la normalización de los campos de un dataset.

6. Orquestación y DataOps

Este es uno de los componentes más críticos. Data *fabric* sigue DataOps como aproximación operacional. Esto permite sistematizar las operaciones necesarias para crear los pipelines que transforman y agregan los datos desde sus fuentes y reutilizar las configuraciones utilizadas en el pasado, lo que no deja de ser una forma de reutilizar los propios datos. A esto se debe añadir la colaboración entre los equipos de ingeniería, analítica y ciencia de datos. Las prácticas de DataOps se han descrito en el apartado 1.1.3.8.

1.2 ESPACIOS DE DATOS

1.2.1 Introducción

La creación de un mercado único de datos compartidos constituye un elemento clave en la estrategia de la Comisión Europea definida en su comunicación «*Una estrategia europea de datos*», publicada en febrero de 2020 [16]. El objetivo que se marca la Comisión es el impulso de la economía del dato de una forma tal que se ajuste a los valores europeos de auto determinación en la compartición de datos (soberanía), privacidad, transparencia, seguridad y competencia justa. Esto resulta particularmente crítico en un momento en el que se prevé que la economía del dato alcance el 4,8% del PIB europeo en 2025¹⁴ [17].

La Comisión Europea define los espacios de datos como «*infraestructuras integradas y marcos de gobernanza que reúnen y ponen a disposición datos para su compartición*». Es decir, constituyen el terreno de juego en el que tiene lugar la actividad de compartición de datos y, como tal, su construcción resulta clave para el desarrollo de la economía del dato. Como muestra de su importancia, la construcción de espacios de datos tiene destinada una inversión de 143 millones de euros sólo en la primera fase (2021-2022) del programa de inversiones estratégicas Digital Europe Programme de la Comisión Europea. De igual forma, este tipo de inversiones también está contemplado en el Plan de Recuperación, Transformación y Resiliencia, en sus componentes C.12 (Política Industrial España 2030) y C.14 (Plan de modernización y competitividad del sector turístico).

Aunque la compartición de datos en sí misma no es una actividad que suponga un reto, realizar la actividad manteniendo los valores europeos sí constituye un reto tecnológico y de negocio que requiere de un tipo de infraestructura y de gobernanza muy específica sin la cual no sería posible cumplir con los valores mencionados. Por esta razón, en los últimos años han surgido en el entorno europeo una serie de iniciativas que tienen por objeto la definición de marcos tecnológicos, arquitecturas, componentes, estándares y modelos de gobernanza para la construcción de espacios de datos que cumplan con los requisitos establecidos. Entre estas iniciativas cabe destacar las lideradas por la asociación Gaia-X, la International Data Spaces Association o la Fundación Fiware, junto con otras alternativas más enfocadas a las transacciones como son X-Road o iSHARE.

1.2.2 Espacios de datos y valores europeos

Se han mencionado en el apartado anterior los valores europeos pero ¿qué características debe cumplir un espacio de datos que cumpla estos valores?

¹⁴ Europa de los 27.

De acuerdo con la Comisión Europea, un espacio de datos que cumpla con los valores europeos consiste en una infraestructura que reúne al menos las siguientes características clave [15]:

1. Ofrece una infraestructura segura que preserve la privacidad para agrupar, acceder, compartir, procesar y utilizar datos¹⁵.
2. Cuenta con una estructura para el acceso y uso de datos de manera justa, transparente, proporcionada y no discriminatoria, y cuenta con mecanismos de gobernanza claros y confiables.
3. Respeta los valores y normas europeos; en particular, la protección de datos personales, la legislación de protección al consumidor y la normativa sobre competencia en los mercados.
4. Los titulares de los datos tienen la posibilidad de permitir el acceso o de compartir datos que mantienen bajo su control y que pueden tener o no consideración de datos de carácter personal.
5. Los datos que son puestos a disposición pueden ser reutilizados a cambio de algún tipo de compensación o remuneración, o gratis.
6. La participación permanece abierta a organizaciones y a individuos.

1.2.3 Principales organizaciones, alianzas y proyectos europeos para el impulso de los espacios de datos

Existen numerosas iniciativas europeas para el impulso a la creación de espacios de datos con roles diversos. En este apartado se resumen las más importantes así como los proyectos más significativos.

1.2.3.1 Organizaciones

1.2.3.1.1 Asociación Gaia-X AISBL

La **Gaia-X European Association for Data & Cloud AISBL** [18] (en adelante, **Gaia-X**) es una iniciativa privada fundada como asociación sin ánimo de lucro bajo legislación belga en 2021, que en la actualidad cuenta con más de 350 miembros asociados de todo el mundo. La asociación da continuidad al proyecto **Gaia-X**, impulsado desde octubre de 2019 por los gobiernos de Francia y Alemania¹⁶.

Los miembros de la asociación pertenecen a una gama muy amplia de actividades, sectores y tamaños que van desde la industria a la academia pasando por empresas de I+D y representantes gubernamentales, entre otros. [19]

¹⁵ Nótese que en esta característica queda claro el ámbito de los servicios de un espacio de datos, que trasciende la mera compartición para incluir su procesamiento y utilización. Un espacio de datos no sólo es un entorno destinado a la compartición de datos (aunque sea su objetivo primordial) sino también para ofrecer servicios de datos que van desde procesamiento (por ejemplo, una aplicación para anonimización) a, en general, su utilización (por ejemplo un servicio para generar modelos de *machine learning* a partir de los datos suministrados por un tercero.)

¹⁶ Para una descripción más en profundidad del proyecto inicial de Gaia-X, su alcance y justificación, se recomienda la lectura del documento publicado en octubre de 2019 por el Ministerio de Economía alemán «Project GAIA-X» [19]

La asociación **Gaia-X** define su misión como la «creación de un ecosistema federado, abierto y transparente donde los datos y los servicios asociados cumplen un conjunto de reglas comunes que permiten compartirlos, crearlos y recopilarlos» [20, p. 2]

Gaia-X justifica su actividad debido a, por un lado, «la necesidad de mercado de reducir las barreras para la adopción de los servicios en la nube» que en la actualidad estarían afectados de «falta de confianza y de libertad de elección» y, por el otro lado, a la «necesidad de acelerar la creación de soluciones innovadoras en entornos seguros y confiables para el establecimiento de una economía del dato pujante. [20, p. 9]»

El concepto de ecosistema de datos




Ilustración 24. Paradigma de ecosistema frente a paradigma de plataforma.

Para entender tanto la propuesta de Gaia-X como del resto de las iniciativas encaminadas a la creación de espacios de datos con valores europeos, es preciso entender el concepto de ecosistema digital en general y de ecosistema de datos en particular, porque sobre él pivotan todas las iniciativas e incluso la propia estrategia europea de datos.

En el ámbito de los negocios de compartición de datos, el ecosistema de datos es el modelo preferencial que se deduce de la comunicación de la Comisión Europea «Una estrategia europea de datos» [16] porque previene la creación de silos de datos, fomenta la innovación y la soberanía tecnológica, dificulta la aparición de operadores dominantes y favorece un mercado justo, entre otras ventajas. Un ecosistema de datos es un caso particular del ecosistema digital¹⁷.

¹⁷ A su vez, el concepto de **ecosistema digital** procede del de **ecosistema de negocio**, acuñado en los años 90, que se define como «una comunidad formada por organizaciones e individuos que interaccionan y que producen productos y servicios que aportan valor a clientes que son miembros de dicha comunidad» [44].

En el informe de la Comisión Europea *Digital Business Ecosystems* [45, p. 5], se define **ecosistema digital** como «la infraestructura tecnológica basada en tecnología peer to peer (P2P) que transporta, encuentra y conecta servicios e información sobre enlaces de Internet permitiendo transacciones en la red y la comercialización de todo tipo de objetos digitales presentes en la infraestructura». Es decir, es la particularización de un ecosistema de negocio a mundo de los negocios digitales.

Un común denominador de las muchas definiciones que existen del concepto de ecosistema digital es aquel que lo define como un sistema de información constituido por sus propios participantes al relacionarse entre sí de manera autónoma y de igual a igual (*peer-to-peer*) para la práctica de un negocio en el que no hay actores dominantes que determinen sus reglas. Un ecosistema de datos es un caso particular de ecosistema digital en el que el negocio que tiene lugar es el de compartición de datos.

Dicho de otra forma, en un sistema de información que se base en el paradigma de ecosistema, el sistema en sí lo compone la comunidad formada por los propios actores que compiten y colaboran mutuamente en la provisión y consumo de servicios mediante relaciones de igual a igual, pero partiendo del presupuesto de que, en este tipo de entornos, los participantes disfrutan de una amplia autonomía para crear y desarrollar nuevos servicios y para consumirlos.

Se considera que el paradigma de ecosistema está contrapuesto al de plataforma, en el que hay una clara distinción entre el sistema en sí y sus usuarios. Un ejemplo típico de plataforma es el de las redes sociales tipo Facebook o Twitter. En el modelo de plataforma hay un único actor que lo opera y ejerce un rol dominante que, entre otras cosas, le permite determinar el modelo de negocio, los servicios disponibles y la tecnología, y es responsable de su evolución, tanto desde el punto de vista de negocio como del tecnológico. Otro ejemplo de plataforma es el de los servicios en la nube proporcionados por los denominados hiperescalares¹⁸.

El concepto de federación

Gaia-X define el término federación como «*un grupo de participantes que trabajan juntos y colaboran en igualdad de condiciones. Una federación no tiene dueño; al contrario, en una entidad de este tipo los participantes colaboran tomando como base unas reglas comunes*» [21].

En otras palabras, una federación constituye un concepto muy similar al de ecosistema, aunque hace más hincapié en la comunidad de participantes. Se puede decir que la federación es la comunidad de participantes de un ecosistema digital.

En su documentación, Gaia-X emplea casi con más frecuencia el término federación que el de ecosistema.

Por su parte, Gaia-X distingue un rol particular en una federación: el rol de federador (*federator*). Aunque la prestación de un servicio en una federación requiere siempre una relación de igual a igual (*peer to peer*) entre un proveedor y un consumidor, para el funcionamiento de una federación es necesaria la prestación de una serie de servicios de infraestructura y de intermediación. Por ejemplo, se requiere la existencia de un catálogo de ofertas de servicio disponibles al que se puedan dirigir los consumidores para conocer los servicios puestos a disposición; también se requiere de un mecanismo que garantice la identidad y que permita la autenticación y autorización entre los participantes (IAA). A los proveedores de estos servicios se les denomina federadores. De alguna manera son los responsables de vincular a los participantes de una federación en ausencia de una plataforma. En una federación hay tantos federadores como servicios de federación en funcionamiento.

¹⁸ Se considera hiperescalares a los grandes proveedores de servicios en la nube como Amazon, Microsoft o Google.

Entregas de Gaia-X

Aunque impulsados por el objetivo de negocio mencionado, los trabajos de la asociación son eminentemente técnicos y encaminados desarrollar un **marco tecnológico** con un objetivo doble:

- i. Diseño de una arquitectura de compartición de datos

En primer lugar, **Gaia-X** se propone «*diseñar e implementar una arquitectura de compartición de datos de referencia basada en estándares, buenas prácticas, herramientas y mecanismos de gobernanza*» [22]. La definición de la arquitectura de referencia basada en estándares constituye el punto de partida del marco tecnológico que **Gaia-X** desarrolla.

Sobre las buenas prácticas y mecanismos de gobernanza, la arquitectura de **Gaia-X** está diseñada para la construcción de espacios de datos que cumplan con los valores europeos¹⁹ y **respondan al paradigma de ecosistema digital**. En esto coincide con otras iniciativas europeas para la construcción de espacios de datos que han surgido en Europa en los últimos años²⁰, **pero el planteamiento de Gaia-X es más ambicioso**. Mientras las mencionadas iniciativas están restringidas a la actividad de compartición de datos y servicios relacionados, **Gaia-X** propone una arquitectura orientada a la creación de ecosistemas que incluyen servicios de computación en la nube (*Cloud Computing*).

De acuerdo con lo anterior, una oferta de servicio en **Gaia-X** puede combinar datos, aplicaciones y recursos computacionales en la nube. Sobre el papel, un participante de un ecosistema **Gaia-X** podría adquirir un conjunto de datos de un proveedor de datos, una aplicación para el entrenamiento de modelos mediante técnicas de *machine learning* de un segundo proveedor, y entrenar el modelo usando recursos computacionales y de almacenamiento de un tercero, siempre con cumplimiento de los valores europeos en la compartición de los datos. O también podría contratar a un único proveedor un servicio que integrase todos los recursos necesarios para compartir y explotar datos (datos, modelos de *machine learning* y recursos computacionales para el entrenamiento y la predicción de eventos).

La versión actual de la arquitectura propuesta por Gaia-X se puede encontrar aquí [23]

- ii. Reglas de interoperabilidad y trust framework

En segundo lugar, **Gaia-X** se marca como objetivo «*la definición de un conjunto de reglas comunes que permitan la interoperabilidad de infraestructuras de datos*» [24, p. 94]. En terminología **Gaia-X** se debe entender por "*infraestructuras de datos*" ecosistemas que constituyen tanto espacios de datos como servicios computacionales en la nube que interoperan entre sí en un entorno de confianza que la asociación denomina **Gaia-X Ecosystem**²¹. El uso del término de

¹⁹ Los valores concretos de Gaia-X se encuentran en [20, p. 3]

²⁰ Con alcances y objetivos distintos, cabe destacar la International Data Space Association (IDSA), la comunidad iSHARE, la Fundación Firewall y la solución X-Road (promovida por el Nordic Institute).

²¹ Nótese que **Gaia-X** denomina **Gaia-X Ecosystem**, no a un espacio de datos que siga el paradigma de ecosistema, sino al conjunto de infraestructuras de datos que forman la red descentralizada e

“infraestructura de datos” en vez del de “espacio de datos” está alineado con el alcance de la arquitectura de **Gaia-X** mencionado anteriormente y la posibilidad que ofrece de ofrecer servicios que integran datos y computación en la nube, juntos o por separado.

Este segundo objetivo excede el ámbito de la construcción de ecosistemas de datos particulares. En esencia, el **Gaia-X Ecosystem** pretende crear una red abierta de *infraestructuras de datos* autónomas, que pueden estar especializadas en sectores de actividad distintos (sectoriales) e incluso en servicios distintos (datos, servicios computacionales en la nube o IA), y que está construida bajo el principio de descentralización. **Gaia-X** denomina **Trust Framework** a las reglas de interoperabilidad comunes de obligado cumplimiento para pertenecer al **Gaia-X Ecosystem**. **Estas reglas constituyen, de acuerdo con Gaia-X, el principal foco de actividad de la asociación y su análisis constituye el objeto de este documento.**

1.2.3.1.2 International Data Spaces Association (IDSA)

IDSA es una asociación sin ánimo de lucro fundada en 2017 formada por más de 140 organizaciones que tiene como objeto crear estándares para la compartición de datos como, por ejemplo, protocolos para la negociación automatizada, intercambio de datos y soberanía del dato. Otros ámbitos de actuación de IDSA son los acuerdos legales, operativos, funcionales y técnicos entre las organizaciones que comparten datos en un espacio de datos.

Adicionalmente, IDSA publica y mantiene un modelo de arquitectura de referencia para espacios de datos y certifica los componentes de software construidos bajo sus normas y estándares que se puede encontrar aquí [25].

En la actualidad, la mayoría de los espacios de datos desplegados en Europa cuentan con tecnología IDSA. La asociación mantiene una página con el radar de las iniciativas soportadas por su tecnología en el que se encuentran más de 50 iniciativas de creación de espacios de datos en diferentes estadios de madurez [26].

1.2.3.1.3 FIWARE

FIWARE es una fundación sin ánimo de lucro especialista en el desarrollo de estándares y componentes software abiertos entre los que destaca la norma NGSI-LD²² y su implementación, el componente *Context Broker*. En la misma línea, FIWARE ha lanzado la iniciativa *Smart Data Models* destinada a proporcionar una librería de modelos de datos en formato JSON-LD compatible con la norma NGSI-LD.

FIWARE forma parte de las principales iniciativas encaminadas a ofrecer una solución técnica convergente para la creación de espacios de datos.

1.2.3.2 ALIANZAS

1.2.3.2.1 DATA SPACE BUSINESS ALLIANCE (DSBA)

interoperable según las reglas de interoperabilidad que la asociación define, y que denomina **Trust Framework**.

²² NGSL-LD ha sido adoptado como un estándar del ETSI. En esencia es un formato de datos basado en JSON-LD que permite definir modelos de información complejos y que proporciona un API para el intercambio de objetos definidos mediante esta norma.

Los promotores de las iniciativas mencionadas anteriormente trabajan en la definición de estándares, especificaciones y componentes que ponen a disposición de la comunidad en formato de fuentes abiertas. Sin embargo, esto no ha impedido que los resultados sean poco interoperables entre sí lo que en el medio y largo plazo lleva a la creación de silos de datos.

Por esta razón, han surgido en paralelo iniciativas que buscan la convergencia tecnológica entre las que destaca la **Data Space Business Alliance (DSBA)**. Esta alianza está formada por las asociaciones Gaia-X, International Data Spaces Association (IDSA), Big Data Value Association (BDVA) y la fundación FIWARE, cuatro de las organizaciones que más se han significado en el último lustro en el desarrollo tecnológico de espacios de datos. En paralelo, las mencionadas organizaciones lideran el proyecto europeo Data Space Support Center (DSSC) financiado por la Comisión Europea dentro del programa Digital Europe Programme, que tiene entre sus objetivos la «*definición de requisitos comunes y mejores prácticas para creación de espacios de datos soberanos*» y que en cierta medida continúa el trabajo realizado por la DSBA.

Con el objetivo de definir un marco tecnológico común, la DSBA ha publicado hasta la fecha dos documentos técnicos que profundizan en la convergencia de las distintas soluciones.

1.2.3.3 PROYECTOS

Tanto la Comisión Europea como otros países de la Unión han tratado de impulsar la creación de espacios de datos con valores europeos mediante la financiación de una serie de proyectos con distintos alcances. A continuación se describen los más significativos.

1.2.3.3.1 Open Dei

Open Dei [27] fue un proyecto ejecutado por un consorcio de 10 organizaciones europeas procedentes de diversos sectores que incluyen la industria, la investigación, la academia y organizaciones sin ánimo de lucro. El proyecto estuvo financiado por la Comisión Europea mediante el programa Horizon 2020.

La importancia del proyecto Open Dei radica en que fue pionero en la definición de una serie de principios de diseño de espacios de datos con valores europeos [28] que han sido asumidos por las principales iniciativas en la materia y que por su relevancia se repasan en el apartado 1.2.4. En la actualidad, el proyecto Open Dei ha finalizado sus actividades.

1.2.3.3.2 Gaia-X Federation Services

Los Gaia-X Federation Services (GXFS) son un conjunto de componentes software puestos a disposición en modalidad de software libre que facilitan la construcción de ecosistemas de compartición de datos. En palabras de sus promotores, «*GXFS es una caja de herramientas que complementa el marco propuesto por la asociación Gaia-X mediante la puesta a disposición de implementaciones de referencia de algunos de los componentes necesarios para crear federaciones que cumplen con los estándares de Gaia-X*».

Aunque los servicios de GXFS están alineados con las especificaciones de la asociación Gaia-X, la asociación y el proyecto son formalmente independientes. Los GXFS son un proyecto financiado por el gobierno alemán iniciado antes de la creación de la asociación Gaia-X.

Si, como se vio, Gaia-X proporciona una arquitectura de referencia, unas especificaciones y unas reglas de interoperabilidad para la creación de redes descentralizadas de espacios de datos, GXFS proporciona **componentes software de fuentes abiertas** de referencia

para la creación de ecosistemas o, utilizando el término que GXFS emplea con más frecuencia, para la creación de federaciones.

La descripción de los componentes desarrollados por la GXFS se puede encontrar en [29]. A modo de resumen, los componentes software soportan servicios como:

- i. Identidad y confianza
Soportan la confianza (Identidad, autenticación y autorización) en una federación. Están basados en la aplicación de un sistema Self Sovereign Identity (SSI) y en los estándares para la creación de credenciales verificables proporcionados por el consorcio W3C.
- ii. Catálogo federado y autodescripciones
Repositorio de la oferta de servicios presente en una federación. Permite a los participantes localizar suministradores de servicios de datos y relacionados. Las herramientas de autodescripción permiten a los participantes crear credenciales sobre sus perfiles y productos.
- iii. Herramientas de conveniencia (*tooling*)
Herramientas de conveniencia para la gestión de los servicios de federación.

Desde junio de 2023, el proyecto GXFS pasa a llamarse *Cross Federated Service Components* (XFSC) y es responsabilidad de una comunidad de desarrollo creada bajo el paraguas de la Fundación Eclipse [30].

Los GXFS no proporcionan todos los componentes necesarios para la construcción de espacios de datos, pero sí algunos de los más importantes. Además el uso de estos componentes facilitaría el cumplimiento de las especificaciones de Gaia-X.

1.2.3.3.3 ESPACIO DE DATOS COMUNES EUROPEOS

En concepto de espacios de datos europeos se encuentra definido en el documento de trabajo de la Comisión Europea [15] como *«espacios de datos interoperables de sectores estratégicos que superan las barreras legales y técnicas para la compartición de datos mediante una combinación de infraestructuras de y reglas comunes que aborden la cuestión de la confianza [En la compartición de datos]»*.

Las características clave de estos entorno de compartición se han descrito en el apartado 1.2.2.

La financiación de los espacios de datos europeos se realiza mediante el programa DIGITAL que sólo en los dos primeros años de aplicación contaba con un presupuesto de 410 millones de euros [15].

1.2.3.3.4 DATA SPACE SUPPORT CENTRE (DSSC)

El DSSC es un proyecto financiado por la Comisión Europea mediante el programa DIGITAL con presupuesto de 14 millones de euros que tiene como objetivo establecer y operar un Centro de Apoyo que coordine todas las acciones relacionadas con los espacios de datos sectoriales impulsadas por la Comisión.

Entre sus tareas se encuentra *«la elaboración de modelos de arquitecturas y requisitos de infraestructura de datos para los espacios de datos, incluyendo posibles tecnologías, procesos, estándares y herramientas que permitirán la compartición de datos en espacios de datos sectoriales del sector público y las empresas europeas, en particular las pymes»*.

El proyecto fue adjudicado en febrero de 2022 a un consorcio de organizaciones que incluye a los principales actores en el panorama de los espacios de datos europeos, incluyendo la asociación Gaia-X, IDSA y FIWARE.

El DSSC juega un rol destacado en la definición de modelos de arquitecturas, el establecimiento de requisitos, la especificación de tecnologías y la elección de estándares para la creación de una solución convergente, en general, y para la construcción del middleware SIMPL, en particular, del que se habla a continuación.

1.2.3.3.5 SIMPL

SIMPL es un proyecto financiado por el programa Digital Europe de la Comisión Europea y dotado con 150 M€. Su objetivo es poner a disposición de la sociedad en modalidad de fuentes abiertas un software (middleware) para la construcción de ecosistemas de datos y servicios de infraestructuras en la nube que soporten los valores europeos de soberanía el dato, privacidad y mercado justo. El proyecto tiene una duración de tres años.

SIMPL tiene una orientación práctica, buscando la puesta a disposición de resultados a la mayor brevedad por lo que se pretende que, además de suministrar el software, el contratista preste un servicio de laboratorio para las pruebas y experimentación por terceros, así como la adaptación del software para el despliegue de espacios de datos comunes europeos previstos también en el programa Digital Europe.

Los pliegos de la licitación hacen hincapié en que el adjudicatario debe esforzarse en reutilizar componentes software disponibles bajo licencia de fuentes abiertas, nombrando explícitamente:

- i. *Digital Building Blocks* procedentes de proyectos europeos. Se nombra entre otros el Context Broker que implementa la norma NGSI-LD para gestión y modelado de entidades.
- ii. Componentes y contribuciones procedentes de otros proyectos europeos adyacentes como EIF (European Interoperability Framework), DCAT-AP, European Open Science Cloud o Destination Earth, entre otros.
- iii. Componentes de Gaia-X. Los pliegos indican que tanto las especificaciones de Gaia-X como los componentes incluidos en los *Gaia-X Federation Services* cumplen con los objetivos del proyecto y son susceptibles de reutilizarse para la construcción de Simpl.

El proyecto se adjudicó en octubre de 2023 y se estima que se liberará la primera entrega en el primer cuarto de 2025.

1.2.4 PRINCIPIOS DE DISEÑO DE ESPACIOS DE DATOS

El proyecto [Open Dei](#) [27] tenía como objetivo alinear las diferentes iniciativas de creación de espacios de datos mediante la adopción, entre otros, de unos principios de diseño que respondiesen a los valores europeos.

El consorcio del proyecto estaba integrado por los principales actores en la construcción de estándares para espacios de datos en Europa. El resultado de los trabajos se plasma, entre otros, en el documento «*Design Principles for Data Spaces*» publicado en 2021 [28]. Este documento es fundacional en el sentido de que reúne los principios seguidos por las principales iniciativas que desarrollan tecnologías para la construcción de espacios de datos con valores europeos y ha sido asumido por los proyectos que han dado continuidad a Open Dei.

En este apartado se resumen los mencionados principios.

Principios de diseño de espacios de datos



Ilustración 25. Principios de diseño de espacios de datos según Open-Dei.

1.2.4.1 PRINCIPIO DE DISEÑO 1: SOBERANÍA DEL DATO

Se define soberanía del dato como *«la capacidad de individuos, organizaciones y gobiernos para tener control y ejercer sus derechos sobre los datos, incluyendo su recopilación, almacenamiento, compartición y uso por parte de otros»*²³.

El concepto de soberanía del dato no se restringe por tanto establecer derechos de acceso sino que aplica también al uso de los datos y la manera de tratarlos (por ejemplo, dónde se almacenan)

Un espacio de datos que suministre soberanía del dato debe disponer de herramientas para que el dueño de los datos establezca políticas de acceso y de uso. Estas herramientas se deben basar en estándares para la definición de derechos de uso -por ejemplo, el lenguaje de marcado ODRL-, para definición de políticas de control de acceso -como XACML- y en tecnologías que permitan hacer efectivas las políticas de uso protegiendo la confidencialidad de los datos, como es el caso de las denominadas tecnologías PET (*Privacy Enhancing Technologies*).

Normalmente todas las soluciones software para compartición de datos disponen de algún mecanismo de control de acceso. El control de uso, en cambio, sólo se ofrece en mayor o menor medida en soluciones más avanzadas destinadas a desplegar entornos abiertos de compartición.

1.2.4.2 PRINCIPIO DE DISEÑO 2: IGUALDAD DE CONDICIONES PARA LOS PARTICIPANTES²⁴

Este principio implica que los espacios de datos están diseñados de tal forma que los participantes no encuentren barreras de entrada ni de salida del entorno de compartición de datos y dispongan de

²³ Definición del glosario del Data Space Support Center, plenamente alineada con el proyecto OpenDei. En la medida de lo posible se seguirá este glosario en la definición de conceptos. Para la consulta del glosario: <https://dssc.eu/space/Glossary/176553985/DSSC+Glossary+%7C+Version+2.0+%7C+September+2023>

²⁴ El término en inglés para este principio es *«level playing field»*, que se puede traducir como *terreno de juego nivelado*, *reglas de juego justas* o, como se ha traducido, *igualdad de condiciones para los participantes*.

autonomía para la creación y consumo de servicios de datos. Para ello deben establecerse reglas claras y transparentes para la participación en un espacio de datos y que sean fáciles de cumplir.

Se persigue que los operadores de espacios de datos no puedan constituir un monopolio para la compartición de datos entre consumidores y proveedores y que tanto operadores de espacios de datos como proveedores de datos compitan en calidad de servicio en sus respectivos ámbitos (los espacios de datos y los servicios de datos, respectivamente) y en innovación sin que, a ser posible, existan consumidores cautivos ni silos de datos de acceso restringido.

En la práctica esto se traduce en que la infraestructura de compartición de datos debe estar orientada a **la creación de ecosistemas de datos**.

1.2.4.3 PRINCIPIO DE DISEÑO 3: INFRAESTRUCTURA DESCENTRALIZADA DE ESPACIOS DE DATOS

Una vez aceptado el principio de diseño encaminado a construir espacios de datos que cumplan con el paradigma de ecosistema, se asume como un objetivo deseable la existencia de alternativas para proveedores y consumidores de datos; es decir, que un participante cuente con opciones distintas para adherirse a un ecosistema concreto.

Se debe considerar, además, que la actividad de compartición de datos es, en sí misma, muy genérica por lo que resulta habitual que los espacios de datos se encuentren especializados por sectores (movilidad, salud, automoción, turismo, etc.) soportados por infraestructuras que facilitan la compartición mediante la utilización de modelos de datos específicos y orientados al despliegue de casos de uso propios de cada sector; se habla entonces de espacios de datos sectoriales.

Esta sectorialización de los espacios de datos conlleva un riesgo de fragmentación del mercado que podría desembocar en la creación de silos de datos sectoriales y en una merma de la libertad de elección.

Para prevenir esto, el consorcio Open Dei establece como principio de diseño la apertura de los espacios de datos de forma que interoperen unos con otros y permitan la construcción de redes descentralizadas de espacios de datos. Dicho de otro modo, los espacios de datos deben estar preparados para que los miembros de un ecosistema puedan ofrecer y consumir productos de datos en ecosistemas distintos a aquel en el que se encuentran suscritos.

Para hacer efectiva la apertura es necesario el establecimiento de unas reglas de interoperabilidad legales, organizativas, semánticas y técnicas aceptadas por todos los ecosistemas de la red descentralizada.




Ilustración 26. Ecosistemas de datos interoperables según el principio de diseño de Open Dei.

Se considera que mediante las arquitecturas descentralizadas se evita que la operación de los espacios de datos pueda concentrarse en unas pocas manos que dispongan de una posición dominante en el mercado y que estas redes impiden la aparición de silos aislados de datos. Además, puede darse el caso de que un participante pertenezca simultáneamente a varios ecosistemas sectoriales. La creación de redes descentralizadas interoperables permite a los participantes participar en varios espacios de datos sin necesidad de estar suscrito a todos.

1.2.4.4 PRINCIPIO DE DISEÑO 4: ESTABLECIMIENTO DE UNA GOBERNANZA COMPARTIDA PÚBLICO-PRIVADA

Para creación de un terreno de juego donde los participantes desarrollen su actividad en igualdad de condiciones (principio de diseño 2) y la creación de redes descentralizadas de espacios de datos (principio de diseño 3) Open Dei defiende la creación de una gobernanza en la que participen todos los implicados y que, entre otros, defina y aplique un marco de interoperabilidad que garantice el cumplimiento de ambos principios.

Como implicados en la gobernanza se debe considerar desde proveedores y consumidores de datos hasta proveedores de tecnología y profesionales TIC pasando por los propios negocios y representantes gubernamentales.

En la práctica, este modelo de gobernanza propuesto por Open Dei se traduce en una gobernanza con dos niveles:

- Uno destinado a la gobernanza de cada espacio de datos sectorial.
- Otro destinado a la aplicación del marco de gobernanza sobre la red descentralizada de espacios de datos y a garantizar el cumplimiento de un marco de interoperabilidad que garantiza la existencia de la red.

1.2.5 COMPONENTES DE UN ESPACIO DE DATOS (*BUILDING BLOCKS*)

El *Data Space Support Centre* (DSSC) continuó los trabajos realizados por el proyecto Open Dei con objeto de elaborar un modelo de espacio de datos (*blueprint*) que sirviera de referencia para su organización, construcción y despliegue en el que distinguía dos tipos de componentes: **1. Técnicos** y **2. Organizacionales y de negocio**. A continuación se describen.

1. Componentes técnicos (*technical building blocks*)

Los componentes técnicos se agrupan en tres categorías.



Ilustración 27. Building blocks del modelo (blueprint) de espacio de datos según el DSSC.

Interoperabilidad de datos

La interoperabilidad de datos agrupa las capacidades necesarias para el intercambio de datos y servicios relacionados en el espacio de datos. Incluye:

i. Definición de modelos semánticos

Permiten describir las entidades que forman parte de un espacio de datos, sean estas participantes, conjuntos de datos o servicios relacionados (por ejemplo, un servicio de anonimización). El establecimiento de modelos semánticos es imprescindible para que los participantes intercambien información sobre sus propios perfiles y las características de los servicios ofrecidos.

La definición de modelos semánticos implica la creación de:

- Vocabularios: constituyen el lenguaje común para la definición de entidades en el espacio de datos (participantes, datos y servicios).

- El vocabulario constituye el modelo de información del espacio de datos. Incluye taxonomías, ontologías, modelos de datos y especificaciones de esquemas. Los vocabularios tienen una parte genérica en la que se describen entidades de aplicación en todos los dominios y una parte específica para cada espacio sectorial que aplica a las entidades específicas de cada sector.
- Proceso de gestión del vocabulario. Los vocabularios son recursos vivos que están en permanente actualización. Debe existir el rol de proveedor de vocabulario encargado de la creación, publicación y mantenimiento de los vocabularios en cada espacio de datos.
- Hub de vocabulario. Componente técnico encargado de la publicación, edición y mantenimiento del vocabulario y su correspondiente documentación.

ii. Intercambio de datos

Este componente proporciona mecanismos para que un participante A del espacio de datos pueda compartir datos con un participante B. Para ello se requiere la definición de un API para la compartición del dato y su transferencia.

Las capacidades de intercambio de datos están estrechamente relacionadas con los modelos semánticos definidos anteriormente. Téngase en cuenta que el protocolo para la compartición debe ir más allá de la mera transferencia de datos; debe incluir interfaces para el intercambio previo de información sobre los datos, sobre los perfiles del consumidor y el proveedor y debe ofrecer la posibilidad de negociación de la contraprestación y las condiciones de acceso y uso. Además, esta funcionalidad define el formato en que se intercambiarán los modelos de datos definidos (por ejemplo, JSON)

iii. Procedencia y trazabilidad.

Capacidades para la trazabilidad del proceso de compartición.

Soberanía de datos y confianza

Bajo este epígrafe se agrupan las capacidades que permiten a los participantes identificarse y autenticarse, definir política de acceso y uso:

1. Políticas de acceso, uso y control: capacidad para los participantes de definir políticas de acceso y uso de sus datos y forzar su cumplimiento (soberanía del dato)
2. Gestión de identidad: capacidades de identificación y autenticación de participantes.
3. Confianza: capacidades para verificar que un participante del espacio de datos se adhiere a ciertas reglas.

Creación de valor

Este epígrafe agrupa capacidades necesarias para el descubrimiento de ofertas de servicio y la generación de valor para los participantes. Típicamente se trata de capacidades suministradas por proveedores de servicios de intermediación. Se distinguen tres tipos de capacidades:

- i. Descripción de datos, y servicios. Esta funcionalidad ofrece a los proveedores de datos herramientas para la descripción de servicios de datos de una manera tal que sea comprensible por los participantes. Incluye la definición de políticas de datos y cómo obtener los datos ofrecidos o hacer uso del servicio incluido en la oferta.

- ii. Descubrimiento y publicación. Se trata de funcionalidades típicas de un catálogo de productos y servicios ofrecidos según los principios FAIR (*findable, accessible, interoperable, reusable*).
- iii. Marketplace. Este componente incluye funcionalidades adicionales al mero descubrimiento. Define y habilita relaciones entre proveedor y consumidor que permiten, entre otros, la comercialización de los datos.

2. Componentes organizacionales y de negocio




Ilustración 28. Componentes organizacionales y de negocio según el modelo de la DSSC

Los componentes organizativos y de negocio constituyen una referencia para las iniciativas de creación de espacios de datos; su objetivo es el desarrollo de capacidades de negocio, gobernanza y legales.

Su definición responde al ánimo de ayudar a potenciales emprendedores a poner en marcha iniciativas que sean sostenibles desde las perspectivas mencionadas.

Brevemente se describe cada una de las perspectivas. Para más información sobre el tema se recomienda la lectura de [30].

- i. Perspectiva de negocio. Cubre las capacidades esenciales para definir y poner en marcha el modelo de negocio.
- ii. Perspectiva de gobernanza. Cubre las capacidades para definir y hacer cumplir el marco de gobernanza efectivo que se deduce de los valores europeos y los principios de diseño de espacios de datos.
- iii. Perspectiva legal. Proporciona una guía y los recursos necesarios para asegurar el cumplimiento de marco legal.

1.3 TECNOLOGÍAS PET

Se conoce con el nombre de tecnologías PET (*Privacy-enhancing technologies*) a un conjunto de técnicas que permiten recoger, procesar, analizar y compartir datos al tiempo que se protege su confidencialidad (por ejemplo, datos de carácter personal o material sensible, en general) [32].

Las tecnologías PET permiten, al menos parcialmente, abordar el problema de la explotación de los datos solventando los riesgos de revelación de datos confidenciales poniendo a disposición una gran cantidad de datos que de otra forma permanecerían en silos sin posibilidad de ser explotados.

En este apartado se describirán las principales tecnologías y sus aplicaciones. Existen numerosas clasificaciones para las tecnologías PET que, en muchos casos, difieren del alcance. En este tema se sigue la clasificación realizada por ENISA [33], basada en la finalidad de las tecnologías, por tratarse de la aproximación de más amplio alcance al cubrir todas las actividades relacionadas con el almacenamiento, comunicación, uso y acceso de datos potencialmente confidenciales. La clasificación se completa cuando el caso lo requiera mediante [32] y otras fuentes disponibles.

1.3.1 TÉCNICAS DE ANONIMIZACIÓN Y PSEUDOANONIMIZACIÓN

Aunque en algunos manuales se clasifica la anonimización y la pseudoanonimización como técnicas PET, en realidad son un tipo de tratamiento de datos para el que resulta de utilidad la aplicación de determinadas tecnologías PET.

En concreto, la anonimización es un tipo de tratamiento consistente en **eliminar** elementos de un conjunto de datos para evitar la posible identificación de interesados. Por su parte, la pseudoanonimización se encuentra explícitamente mencionada y definida en el Reglamento Europeo de Protección de Datos (GDPR) como «*un tipo de tratamiento de datos personales de manera tal que ya no puedan atribuirse a un interesado sin utilizar información adicional*». La diferencia entre ambos términos, por tanto, está en que la anonimización no es reversible mientras que la pseudoanonimización puede serlo a partir de información adicional normalmente generada durante el tratamiento. Desde el punto de vista legal, a los datos anonimizados no les son de aplicación la normativa de protección de datos [34], siempre y cuando no exista probabilidad razonable de reidentificación. Con la pseudoanonimización, en cambio, tanto al tratamiento como los datos resultantes les son de aplicación la mencionada normativa.

Técnicamente, la anonimización requiere pérdida de datos consecuencia de la aplicación, bien de técnicas de generalización, bien de la adición de ruido. Cómo se parametrizan las técnicas es un problema de optimización entre dos parámetros: la utilidad de los datos y la protección frente a reidentificaciones. Se trata por tanto de encontrar un equilibrio que depende del uso que se vaya a dar a los datos y de su sensibilidad y, por la misma razón, no existe un único tratamiento de anonimización válido. En todo caso, de acuerdo con [32], el principal reto de estas técnicas es la medida del riesgo de reidentificación, que actualmente se evalúa sólo a posteriori.

A continuación se ven las principales técnicas de anonimización.

1.3.1.1 K-ANONIMATO (K-ANONYMITY)

K-anonimato es un mecanismo de generalización que se basa en la sustitución de valores de atributos por segmentos de valores dentro del rango del atributo en cuestión. De esta manera, no se muestra el valor del atributo sino un conjunto de valores consecutivos posibles entre los que se encuentra el valor del atributo real. Un conjunto de datos se considera que proporciona protección de k-anonimato si la información de cada sujeto de datos contenido en el conjunto resultante no se puede distinguir de al menos k-1 sujetos cuyos datos aparecen en el mismo *dataset*. Lógicamente, cuanto mayor sea el valor k, mayor será la protección frente a reidentificación.

Por ejemplo, supongamos la Tabla 7 tomada de [33]. Esta tabla muestra diagnósticos de pacientes plenamente identificados. Se puede eliminar sin riesgo de perder información útil para una analítica de datos el campo con el nombre pero, si no se hace nada más, el riesgo de reidentificar al paciente es elevado. Para paliar este riesgo con una pérdida asumible de información se pueden agrupar los campos código postal y año de nacimiento. El campo de sexo (*gender*) se mantiene al considerarse crítico para la analítica de datos.

El resultado se puede contemplar en la Tabla 8. Sería un caso de k-anonimato con $k = 2$, dado que

Name	Gender	Zip Code	Year of Birth	Diagnosed Medical Condition
George S.	M	75016	1968	Depression
Martin M.	M	75015	1970	Diabetes
Marie J.	F	69100	1945	Heart rhythm disorders
Claire M.	F	69100	1950	Multiple sclerosis
Amelia F.	F	75016	1968	Nothing
Annes J.	F	75012	1964	Rheumatoid arthritis
Sophia C.	F	75013	1964	Blood Disorder
Simon P.	M	75019	1977	Sarcoidosis
Michael J.	M	75018	1976	Lymphoma

Tabla 7. Conjunto de datos de enfermos sin anonimizar (ENISA)

para cada tripleta de atributos (código postal, año de nacimiento y sexo) existe al menos otra entrada ($k-1 = 1$) con iguales valores. L

a protección garantizada por esta técnica depende del valor de k . Lógicamente, cuanto mayor sea, mayor será la protección a costa de la utilidad de los datos. El valor de k elegido depende del riesgo, de la utilidad de los datos y de su sensibilidad, pero no existe una regla generalmente aceptada para determinarlo por lo que la elección es arbitraria. En el área de la salud se suelen escoger valores de k entre 5 y 15 [33].

13.1.2 PRIVACIDAD DIFERENCIAL (DIFFERENTIAL PRIVACY)

La privacidad diferencial se basa en introducción de ruido estadístico en los datos del *dataset* según un patrón conocido (por ejemplo, distribución de Laplace). El fundamento de esta técnica es que la introducción de ruido no va a afectar la tendencia global del conjunto de datos por lo que sigue resultando útil para la analítica y la aplicación de técnicas de *machine learning*. En algunos casos, conocido el patrón del ruido introducido, el destinatario de los datos puede compensarlo para corregir las desviaciones introducidas pero, como se desconoce exactamente el ruido introducido en cada registro, se evita la reidentificación. Es decir, al tratarse de ruido estadístico imposible de predecir, no es recuperable el conjunto de datos original. Para la introducción de ruido en variables no numéricas se calcula previamente un hash del registro. En sentido estricto, más que una técnica de anonimización

Zip Code	Year of Birth	Gender	Diagnosed Medical Condition
75***	[1960-1970]	M	Depression
			Diabetes
69***	[1940-1950]	F	Heart rhythm disorders
			Multiple sclerosis
75***	[1960-1970]	F	Nothing
			Rheumatoid arthritis
			Blood Disorder
75***	[1970-1980]	M	Sarcoidosis
			Lymphoma

Tabla 8. Tabla de enfermos tras aplicar k-anonimato con $k=2$ (ENISA)

se trata de un mecanismo de enmascaramiento porque no elimina datos del *dataset* sino que los oculta; no obstante, ENISA lo incluye en esta categoría porque se usa habitualmente con este fin.

Nuevamente se debe establecer un compromiso entre el ruido introducido y la utilidad del conjunto de datos porque la utilidad desciende al aumentar el ruido, por lo que se requiere un calibrado.

La privacidad diferencial ofrece la ventaja de hacer posible la cuantificación de la pérdida que el procesamiento causa al conjunto de datos y, en líneas generales, se considera un mecanismo más seguro que el k-anonimato. Por contra, requiere *datasets* grandes para asegurar que se mantienen en el conjunto de datos tratado tanto las tendencias como su representatividad.

1.3.2 TÉCNICAS DE ENMASCARAMIENTO Y DE COMPUTACIÓN CONFIDENCIAL

El enmascaramiento es un término amplio que, aplicado a los datos, se refiere a procesos que esconden su verdadero valor. Tiene aplicación tanto para garantizar la integridad de los datos como la confidencialidad. El caso típico de aplicación es la cesión de datos confidenciales sin revelar precisamente la parte confidencial. El enmascaramiento no elimina datos, sino que los esconden mediante el uso de técnicas muy variadas.

1.3.2.1 CIFRADO HOMOMÓRFICO (*HOMOMORPHIC ENCRYPTION*)

El cifrado homomórfico es el nombre que reciben un conjunto de tecnologías que permiten realizar operaciones sobre datos cifrados sin necesidad de descifrarlos primero.

Existen tres técnicas de cifrado homomórfico:

- a. Cifrado homomórfico parcial (PHE). Se permite una sola operación sobre los datos cifrados (por ejemplo, la suma o multiplicación) un número ilimitado de veces.
- b. Cifrado homomórfico total (FHE). Se soportan múltiples operaciones (típicamente, suma y multiplicación) también de forma ilimitada.
- c. Cifrado homomórfico *hasta cierto punto* (*Somewhat homomorphic encryption* o SHE). Permite varias operaciones pero sólo un número limitado de veces.

Si las técnicas de anonimización tenían que alcanzar un compromiso entre utilidad y protección de datos, el cifrado homomórfico añade además un parámetro adicional: las prestaciones de cómputo exigidas a los sistemas. FHE ofrece altos niveles de protección y utilidad, pero requiere gran capacidad de cómputo para el procesamiento de los conjuntos de datos, mientras que PHE y SHE ofrecen buena protección y prestaciones pero poca utilidad para, por ejemplo, el procesado de los datos mediante técnicas de *machine learning* por limitar el número o el tipo de operaciones que se pueden realizar. Se debe considerar que el procesamiento en la nube es caro, pero es precisamente en ese entorno donde tiene su aplicación la mayoría de los usos de esta tecnología por estar los datos fuera del control de su propietario.

Dados los problemas de prestaciones que esta técnica presenta, se suele emplear para datos que requieren procesamiento sencillos en entornos potencialmente hostiles (por ejemplo, la nube), como limpieza de datos o agregaciones simples.

En líneas generales, y considerando el actual estado del arte, el equilibrio entre eficiencia y privacidad necesario para la aplicación de cifrado homomórfico sólo se justifica en casos en los que los beneficios de privacidad contrapesan los mayores costes asociados al cálculo y al análisis. Por ahora, la mayoría de las aplicaciones de cifrado homomórfico se realizan a pequeña escala.

1.3.2.2 SECURE MULTIPARTY COMPUTATION (SMC)

SMC consiste en un conjunto de herramientas que permite a un grupo de participantes aplicar una función sobre datos puestos en común por todos ellos al tiempo que se mantiene la privacidad sobre esos mismos datos. En esencia es un mecanismo colaborativo de cómputo de datos que no necesita de un tercero de confianza para procesar los datos conjuntos. Los participantes pueden ser individuos, aplicaciones o dispositivos.




Ilustración 29. Ejemplo de aplicación de SMC entre 3 participantes que quieren conocer su edad media sin desvelar la edad de cada uno.

Independientemente de la función, SMC requiere para su aplicación de la ejecución de 4 pasos. Para su mayor comprensión se ilustra con un ejemplo (ver Ilustración 29) en el que 3 participantes con edades de 30, 40 y 20 años, quieren conocer la media conjunta de su edad (función) sin revelar su propia edad a los demás.

1. Cada participante divide arbitrariamente el dato o los datos que va a compartir (en este caso, su edad). Habrá tantas divisiones como participantes (en este caso, 3).
2. Cada participante reparte las divisiones realizadas entre el resto de los participantes dando exactamente una parte a cada uno. Cuando los participantes están en posesión de un dato parcial (y sólo uno) de cada uno de los participantes, se realiza una operación intermedia que agrega todos los datos parciales recibidos (en este caso, los suma).
3. Cada participante envía al resto el resultado de la agregación realizada.
4. Cada participante aplica la función que se quería calcular con los datos recibidos de forma independiente. Todos los resultados deben coincidir.

Se debe diseñar un protocolo ad hoc para toda función SMC que se quiera implementar, incluyendo la definición de los mensajes entre las partes, las agregaciones y el aparato matemático. Pero, si hay una manera en que un conjunto de partes pueda calcular conjuntamente el resultado de la función mediante el intercambio de mensajes y calculando algunos resultados intermedios locales, entonces existirá un protocolo SMC que resuelva ese problema con las garantías de seguridad requeridas. Desafortunadamente, en muchos casos, dicho protocolo SMC puede volverse muy complejo en su aplicación y requerir excesivos recursos de computación y comunicaciones, por lo que en escenarios en que se requiere una respuesta en tiempo real puede no ser la solución adecuada.

SMC no sólo sirve para garantizar la confidencialidad sino que también es de aplicación para garantizar la integridad del resultado final mediante, por ejemplo, acuerdos entre la mayoría de los usuarios. Por otro lado, se puede combinar con otras técnicas como, por ejemplo, cifrado homomórfico, para garantizar la protección de los datos en tránsito o aumentar la garantía de confidencialidad de los datos compartidos.

1.3.2.3 APRENDIZAJE FEDERADO (*FEDERATED LEARNING*)

Modelo centralizado de entrenamiento de modelos de ML

Típicamente, el método tradicional de elaboración de modelos de *machine learning* es centralizado: requiere reunir todos los datos de entrenamiento procedentes de múltiples fuentes en un único conjunto de datos a partir del cual un servidor central elabora el modelo que se desea. Si los *datasets* contienen datos personales o sensibles es necesaria la aplicación de técnicas de anonimización u otras técnicas PET que salvaguarden la confidencialidad.

Por su parte, los modelos de *machine learning* son entidades vivas, sujetas a una constante actualización para evitar que pierdan su valor, por lo que es habitual que los responsables del mantenimiento de las aplicaciones realicen un permanente reentrenamiento de los datos. De esta forma, una aplicación que requiera el uso de un modelo de *machine learning* entrenado de la manera tradicional (por ejemplo, un recomendador de compra), requerirá para su actualización que los usuarios envíen a un servidor centralizado sus datos de uso para su agregación, consolidación, limpieza y, normalmente, anonimización. Una vez reunidos, se entrenará el nuevo modelo y se distribuirá entre todos los usuarios mediante la oportuna actualización de la aplicación.

Los problemas asociados a este modelo centralizado de entrenar y actualizar modelos de *machine learning* son evidentes: no sólo requiere permanentes trabajos de anonimización para evitar la revelación de datos personales sino que, en aplicaciones masivas que cuenten con millones de usuarios, introduce una latencia considerable entre la generación de los datos y la actualización del modelo en la aplicación.

Modelo de aprendizaje federado

El aprendizaje federado, por el contrario, es un modelo descentralizado de entrenamiento en el que los modelos se entrenan en los propios dispositivos de los usuarios (dispositivos *en el borde* o *edge devices*) utilizando su propio historial de datos de uso. Una vez entrenado el modelo, los dispositivos envían a un servidor centralizado *los parámetros del modelo generado localmente*, no los datos de uso. A partir de estos los parámetros recibidos desde los dispositivos se genera centralizadamente un nuevo modelo común promediado y se actualizan las aplicaciones de los usuarios con el nuevo modelo. La generación de un modelo promediado y su actualización en todas las aplicaciones es necesaria para evitar el sesgo de los modelos locales, generados sólo con los datos del usuario.

Google define el funcionamiento del aprendizaje federado en aplicaciones de *smartphones* de la siguiente manera:

«Funciona de la siguiente manera: tu dispositivo descarga el modelo actual, lo mejora aprendiendo de los datos en tu teléfono y luego resume los cambios como una pequeña actualización enfocada. Solo esta actualización del modelo se envía a la nube, utilizando comunicación cifrada, donde se promedia inmediatamente con otras actualizaciones de usuarios para mejorar el modelo compartido. Todos los datos de entrenamiento permanecen en tu dispositivo y ninguna actualización individual se almacena en la nube».

1. Uso de la aplicación




Ilustración 30. Diagrama de aprendizaje federado.

Las tecnologías de aprendizaje federado son de uso generalizado por compañías como Google, que lo emplea, por ejemplo, para su aplicación de texto predictivo, pero resultan también de aplicación en numerosos campos como salud o finanzas, donde la confidencialidad de los datos resulta crítica y la compartición de los datos conlleva un riesgo extra. Como beneficio colateral, permite reaccionar más rápidamente ante sesgos de los modelos de *machine learning* y generan menos tráfico, con los ahorros asociados que esto supone en computación en la nube, donde se paga por el tráfico entrante y saliente.

No obstante, se han levantado algunas voces que reclaman que la información compartida no es inmune en todos los casos a la revelación de datos personales.

1.3.2.4 ENTORNOS DE COMPUTACIÓN DE CONFIANZA (TRUSTED EXECUTION ENVIRONMENTS - TEE)

Los TEE o entornos de computación de confianza son entornos seguros y aislados, habilitados por hardware, que previenen el acceso no autorizado o la modificación de aplicaciones y datos mientras están en uso.

Dicho con otras palabras, se puede pensar en los TEE como un medio para crear una ubicación específica (un enclave, en la terminología empleada) en la memoria de un servidor, donde cualquier

cosa que esté dentro es inaccesible para las entidades fuera de ella. A bajo nivel por tanto, los TEE constituyen una tecnología hardware basada en la partición física de la memoria a nivel de servidor.

Los datos pueden encontrarse en tres estados distintos:

- a. Reposo: almacenados en dispositivos.
- b. En tránsito: siendo transferidos entre entidades.
- c. En ejecución: siendo procesados por aplicaciones, para lo que se transfieren a dispositivos de memoria RAM y son accedidos por los procesadores de los ordenadores.

Para la protección de los datos que se encuentran en reposo o en tránsito se emplean tradicionalmente técnicas de cifrado simétrico o asimétrico. Sin embargo, **la protección de los datos en un entorno de ejecución resulta más compleja** principalmente si, como es habitual, la aplicación que accede a ellos requiere desencriptarlos para su procesamiento. En una situación así, los datos son vulnerables frente a prácticas como, por ejemplo, el volcado de memoria por un tercero.

TEE por tanto es un intento de garantizar la confidencialidad de los datos en estado de ejecución. TEE asume, de hecho, que el entorno de un ordenador, comenzando por su sistema operativo, no es de confianza, por lo que crea una pila hardware/software completa, aislada del resto del ordenador e inaccesible desde el exterior donde sólo aplicaciones de confianza pueden ejecutarse y sólo bajo la autorización previa del titular de los datos. Para ello, se emplean protocolos que permite a los usuarios dar el visto bueno de la aplicación y del entorno de ejecución en el que se van a usar los datos. Una vez ejecutada la aplicación sobre los datos, ésta devuelve el resultado y borra la memoria del enclave. De esta forma se pueden explotar datos (por ejemplo, crear un modelo de *machine learning*) sin exponerlos a terceros.

1.3.2.5 CONSULTA DE INFORMACIÓN PRIVADA (*PRIVATE INFORMATION RETRIEVAL*)

Private Information Retrieval (PIR) es una técnica criptográfica que permite a un usuario obtener una entrada en una base de datos sin revelar qué entrada en concreto se ha solicitado. Es una técnica que trata de minimizar la información que un sujeto revela por el mero hecho de realizar consultas sobre un repositorio de datos.

Supongamos que una empresa desea proporcionar acceso a una base de datos a sus clientes. En una configuración normal, cada vez que un cliente accede a la base de datos, el custodio de datos sabe qué consulta ha realizado el usuario. Con el tiempo, el controlador de datos podrá identificar qué entradas de la base de datos son de interés para cada uno de los clientes. En un sistema que tenga la técnica PIR implementada, el usuario minimiza la cantidad de información revelada sobre lo que se ha accedido, con lo que se evita que se pueda crear, por ejemplo, un perfil del usuario o, simplemente, se salvaguarda la privacidad de sus actividades manteniendo la confidencialidad de las consultas.

1.3.2.6 GENERACIÓN DE DATOS SINTÉTICOS

La generación de datos sintéticos es un nuevo campo de procesamiento de datos en que los datos se sustituyen por otros que se asemejan de forma realista a los originales (tanto personales como no personales), pero que en realidad no hacen referencia a ningún individuo real identificable, ni se trata de observaciones reales registradas por algún sistema. Los datos sintéticos son datos generados por modelos de *machine learning* con iguales propiedades estadísticas que los originales. Al ser sintéticos, no existen a priori problemas de protección de datos ni de confidencialidad aunque, en la práctica, se considera que esta técnica es susceptible de reidentificación.

Entre los beneficios se encuentra el hecho de que, aparte de no causar problemas de confidencialidad, los datos sintéticos son fáciles y baratos de generar. Permiten generar datos de contextos en los que se considera difícil e incluso poco ético la recogida de datos para la generación de modelos de *machine learning*. Permite también realizar experimentos simulados.

No obstante, no se debe perder de vista que en realidad no son datos reales. El riesgo de introducir sesgos producto del modelado mediante *machine learning* es alto.

1.3.3 ACCESO, COMUNICACIÓN Y ALMACENAMIENTO

1.3.3.1 TÉCNICAS PET APLICADAS A LAS COMUNICACIONES

1.3.3.1.1 CIFRADO EXTREMO A EXTREMO (END TO END ENCRYPTION - E2EE)

El cifrado de extremo a extremo (E2EE) es un método para cifrar las comunicaciones entre los participantes de una comunicación desde el momento en que se envían mensajes en la aplicación emisora hasta que el mensaje alcanza su destino en la aplicación del receptor. La implementación de E2EE es una funcionalidad que ha ganado importancia en los últimos años principalmente desde la proliferación de aplicaciones de mensajería o de videoconferencia²⁵.

La principal diferencia entre E2EE y el cifrado en tránsito, que se aplica desde hace décadas, es que, en este último caso, los servidores pueden romper la cadena de cifrado porque, entre otras cosas, disponen de las claves de cifrado de los mensajes. Es el caso, por ejemplo, de los servicios de correo electrónico de Google o Hotmail. La funcionalidad de E2EE elimina, o al menos, dificulta, esta posibilidad porque los únicos que disponen de las claves para descifrar son los propios participantes de la comunicación.

Existen numerosos protocolos para el cifrado extremo a extremo dependiendo del tipo de aplicación que se pueden consultar aquí [35].

²⁵ Como ejemplo, en el área de las aplicaciones de mensajería, WhatsApp o Telegram afirman ofrecer E2EE. En el mercado de los servicios de videoconferencia, Zoom también afirma haber implementado la funcionalidad.

1.3.3.1.2 PROXY & ONION ROUTING




Ilustración 31. Esquema de la red TOR.

Desde hace décadas se aplican en las comunicaciones por internet mecanismos de cifrado a nivel de transporte como el protocolo *Transport Layer Security*, sucesor del actualmente deprecado *Secure Sockets Layer* (SSL). TLS proporciona seguridad, incluyendo confidencialidad, integridad y autenticidad mediante el uso de criptografía (típicamente, certificados y una combinación de criptografía simétrica y asimétrica) entre dos o más aplicaciones. Otra alternativa emergente para el cifrado de las comunicaciones es el cifrado extremo a extremo (E2EE) visto anteriormente.

TLS cifra el contenido de la comunicación a nivel de transporte, es decir, los datos intercambiados entre una aplicación origen y otra destino (por ejemplo, un navegador y un servidor web). Esto incluye el cuerpo del mensaje, archivos adjuntos, formularios web y otros datos de la aplicación. Es decir, todo lo que está en el nivel de aplicación y por encima. Sin embargo, TLS no proporciona cifrado para los metadatos de la comunicación, como la información sobre quién está comunicándose, cuándo se realizó la comunicación, y similares.

Dicho de otra forma, en una comunicación mediante TLS, **los metadatos de la comunicación**, como las direcciones IP origen y destino, los nombres de dominio, las marcas de tiempo y otros detalles relacionados, generalmente **están visibles para los intermediarios** y potencialmente pueden ser observados. Esto también es aplicable a los mecanismos de cifrado extremo a extremo (E2EE).

Debido a esto, han surgido en los últimos años iniciativas encaminadas a facilitar comunicaciones anonimizadas entre aplicaciones que utilizan técnicas consistentes en eliminar la información del remitente y envolver los paquetes de transporte en sucesivas capas de enrutamiento (como en una cebolla, de ahí el símil) que dificultan el rastreo de las comunicaciones. La iniciativa más implantada es The Onion Routing²⁶ (TOR).

²⁶ <https://www.torproject.org/>

TOR es una red de más de 7 mil nodos (transmisores o *relays* en su nomenclatura) que, en conjunto, tienen como objeto ocultar el origen de los paquetes de nivel de transporte, cifrar su contenido y crear sucesivas capas de enrutamiento sobre el paquete de entrada que dificulte su rastreo. En la red TOR, un tipo particular de nodo (*Exit Relay*) saca el paquete de la red TOR y lo encamina a su destino por los mecanismos habituales de Internet pero ya cifrados y sin información sobre el origen del paquete. Solamente el nodo de entrada, que hace las veces de proxy (*Entry Relay*), conoce el origen y solamente el de salida conoce el destino. Pero una vez que el paquete se introduce de nuevo en el circuito de Internet carece de información sobre el origen y sus datos de encaminamiento están envueltos en una maraña de datos que hace complicado seguir su rastro.

1.3.3.2 ALMACENAMIENTO

1.3.3.2.1 ALMACENAMIENTO GARANTE DE LA CONFIDENCIALIDAD (*PRIVACY PRESERVING STORAGE- PPS*)

PPS tiene dos objetivos: proteger la confidencialidad de los datos en reposo e informar a los custodios de los datos de una posible brecha de seguridad.

Para el cumplimiento del primer objetivo se emplean técnicas de cifrado que se pueden emplear a nivel de almacenamiento, a nivel de base de datos o a nivel de aplicación, cada opción con sus pros y sus contras.

Para el aviso de brechas de seguridad se suelen emplear "canarios" que avisan de un posible ataque. Para la implementación de canarios se utilizan datos confidenciales falsos sometidos a una monitorización especial.




Ilustración 32. Opciones de cifrado de datos para preservar la confidencialidad (ENISA)

Para más información sobre técnicas para garantizar la confidencialidad de los datos se recomienda la lectura de [33].

1.3.3.3 TÉCNICAS PET APLICADAS AL CONTROL DE ACCESO, AUTORIZACIÓN Y AUTENTICACIÓN

1.3.3.3.1 CREDENCIALES BASADAS EN ATRIBUTOS CON CONFIDENCIALIDAD MEJORADA (*PRIVACY-ENHANCING ATTRIBUTE-BASED CREDENTIALS - P-ABC*)

Uno de los problemas asociados a la autenticación y control de acceso por atributos es cómo lograr que el autenticado revele estrictamente la información requerida y ni un dato

más. Los documentos acreditativos de atributos de usuario normalmente no permiten la desagregación de atributos singulares con lo que, aunque sólo se requiera demostrar uno de los atributos acreditados por el documento, es necesario entregar al sistema de control de acceso la totalidad del documento (o incluso varios documentos) y revelar todos los atributos del usuario que contienen, incluidos los innecesarios. Piénsese, por ejemplo, en el DNI. Se trata de un documento que, además de la identidad, contiene información sobre la edad, el lugar de nacimiento, el domicilio e incluso el nombre de los padres del sujeto. Sin embargo, para acreditar la mayoría de edad en un bar mediante el DNI es necesario mostrarlo al completo. Esto no sólo aplica a documentos físicos, sino también a electrónicos: los certificados X.509, por ejemplo, no permiten extraer atributos sino que son monolíticos²⁷. Para acreditar un dato respaldado por un certificado es preciso mostrarlo al completo.

Pero incluso si fuera posible desagregar los atributos de un documento electrónico, existe el peligro de que un observador pudiese relacionar unos atributos con otros logrando la identificación de un usuario que accede repetidamente a un sistema que solicitase por separado varios atributos distintos en diferentes escenarios.

Las credenciales P-ABC se proponen como medio para afrontar estos problemas y mejorar la aplicación del principio de minimización de datos en procesos de autenticación y control de acceso basados en atributos. Con credenciales P-ABC se controla el acceso del usuario




Ilustración 33. Control de acceso mediante P-ABC.

mediante atributos que se pueden desagregar de documentos acreditativos de una forma tal que **no pueden relacionarse unos con otros** (*un-linkable*) impidiéndose así la identificación del usuario.

Las credenciales P-ABC parten de la suposición de que el usuario está en posesión de uno o varios documentos acreditativos de un conjunto de atributos emitidos por autoridades de confianza. Típicamente, los documentos son credenciales verificables según la norma del W3C. Pero, en este caso, los documentos acreditativos pueden desagregarse formando credenciales P-ABC en forma de *tokens* que revelen estrictamente lo necesario para la autenticación y el acceso. Además, a menos que el autenticador así lo exija, los *tokens* no revelan la identidad del usuario y resulta imposible saber si dos tokens pertenecen al mismo usuario, con lo que los accesos de un mismo

²⁷ Las autoridades de certificación firman un *hash* que es un resumen de la totalidad del certificado por lo que acreditan el certificado en su conjunto, no partes de él aisladas.

usuario no se pueden relacionar, dificultando la identificación del usuario por acumulación de atributos.

En un escenario así, cuando el usuario solicita el acceso a un recurso, primero recibe del autenticador la política de acceso (por ejemplo: «*se necesita ser mayor de edad y ciudadano de la UE*»). Si el usuario puede acreditar la política crea de forma automatizada un token elaborado a partir de documentos acreditativos que sólo revela la información estrictamente necesaria.

La adopción de credenciales PABC es aún muy limitada aunque se están realizando esfuerzos significativos en su desarrollo y despliegue. Una introducción a esta tecnología se puede encontrar aquí: [36]

1.3.3.3.2 PRUEBA DE CONOCIMIENTO CERO (ZERO KNOWLEDGE PROOF - ZKP)

La idea central de una prueba de conocimiento cero es permitir que un usuario demuestre (por ejemplo, a un autenticador) que conoce un secreto (por ejemplo, su clave) sin revelar nada sobre ese secreto. Se trata de nuevo de una manera de aplicar el principio de minimización de datos. ZKP es un concepto, más que una tecnología; cada caso práctico requiere el desarrollo de sus propios protocolos de intercambio de mensajes, sus algoritmos y su propio aparato matemático. Su aplicación principal se da en el área de la autenticación al permitir esta operación sin necesidad de que el usuario introduzca su nombre/clave.


Existen dos variantes de pruebas de conocimiento cero: interactivas y no interactivas. Las pruebas de conocimiento cero interactivas requieren varias comunicaciones entre el usuario y el servidor. Las pruebas de conocimiento cero no interactivas no requieren ninguna comunicación en absoluto.

Ejemplo de utilización en procesos de autenticación

Para la mejor comprensión del concepto de ZKP, se muestra un ejemplo de aplicación en un escenario de autenticación. En este caso, el verificador (autenticador) conoce el secreto (la clave) pero se quiere que, por seguridad, el probador (autenticado) en vez de mostrar la clave, demuestre que está en posesión de ella.

Supongamos que Ana (probadora) quiere que Carmen (verificadora) le dé acceso a un servicio online. Para evitar que Ana tenga que introducir su clave, han acordado un mecanismo ZKP basado en la función $y = g^x \text{mod}(p)$ de la que ambas comparten los valores g y p . Tanto x como g y p son números naturales y p , además, es primo.

El primer reto que Ana tiene que superar para que le den acceso consiste en calcular y enviar el valor $y = g^x \text{mod}(p)$ a Carmen, **siendo x el valor de su clave**. Un observador



malicioso podría haber investigado y averiguado la función y los valores g y p que Ana y Carmen emplean; puede incluso que, mediante escucha, averigüe el valor y que Ana ha enviado a Carmen, pero no podrá calcular x , porque, aunque llegase a conocer y , p y g , para conocer el valor x se le plantea la resolución de la ecuación $y = g^x \bmod(p)$. Esta ecuación implica entre otras cosas la resolución del *problema del logaritmo discreto* que, si g, x son suficientemente grandes, no es resoluble por fuerza bruta en un periodo de tiempo razonable y que, en todo caso, posee múltiples soluciones en x .

Dejemos al observador frustrado. Carmen verifica que el valor de y que le ha pasado Ana es el que se corresponde para los valores de g , p y x , con lo que la cosa va bien. Dado que el valor y es el resto de la división entera de un número por $p \bmod(p)$, sólo puede tomar como valores números enteros menores que p . Si p es grande, la probabilidad de que Ana haya acertado al azar, sin disponer de x , es pequeña, pero Carmen quiere estar segura, así que da comienzo un proceso iterativo:

- i. Ana escoge un valor $r \in \mathbb{N}$ aleatorio comprendido entre $(0, p-1]$ y envía a Carmen el valor $C = g^r \bmod(p)$.
- ii. Carmen recibe el número C y pide a Ana que le mande ahora un número

$$w = (r + x) \bmod(p-1).$$

Ahora Carmen conoce g, p, y, C y w

Se demuestra matemáticamente que si Ana empleó el mismo valor x para calcular w e y se cumple que:

$$y \cdot C \cdot \bmod(p) = g^x \cdot g^r \cdot \bmod(p) = g^w \cdot \bmod(p)$$

Con lo que nuevamente Carmen puede verificar si Ana posee el valor x . En el caso hipotético de que Ana acertara el valor de y anteriormente por suerte, será muy difícil que vuelva a hacerlo de nuevo. No obstante, Carmen someterá a Ana a este reto tantas veces como sea necesario hasta quedar convencida de que efectivamente, Ana tiene la clave.

Como se puede comprobar, Carmen no tendrá nunca una probabilidad igual a 1 de que Ana tiene la clave x , pero puede reducir la probabilidad de fraude tanto como se quiera hasta alcanzar un valor tan bajo que en la práctica resulte imposible cometer fraude.

Propiedades de las aplicaciones de ZKP


Una aplicación ZKP debe cumplir las siguientes 3 propiedades:


1. **Compleitud (Completeness):** si la afirmación es verdadera, un verificador honrado (es decir, aquel que sigue correctamente el protocolo) quedará convencido de este hecho por un probador honrado (es decir, que esté en posesión de la información y siga el protocolo correctamente).
2. **Solidez (Soundness):** si la afirmación es falsa, ningún probador malicioso puede convencer al verificador honrado de que es verdadera, excepto con alguna pequeña probabilidad.
3. **Conocimiento nulo (Zero Knowledge):** si la afirmación es verdadera, ningún verificador aprende nada más que el hecho de que la afirmación es verdadera.

ZKP supone un aporte importante para aumentar la confidencialidad y la seguridad, pero se trata de una práctica aún incipiente. Se discute la posibilidad de utilizar ZKP en ámbitos como la salud, las elecciones, la verificación de edad y la gestión del tráfico en el futuro pero, hasta la fecha, no ha habido implementaciones a gran escala. Sin embargo, esto podría cambiar, ya que cada vez se considera más el uso de ZKP en la implementación

de sistemas de gestión de identidad digital. Por ejemplo, las ZKP son reconocidas como una de las alternativas para las futuras carteras electrónicas europeas que se están planificando como parte del futuro reglamento de la Unión Europea eIDAS 2.0 sobre identificación electrónica y servicios de confianza para transacciones electrónicas en el mercado interno.

2. RESUMEN ESQUEMÁTICO





3. TEST

1.1 PREGUNTAS DE TEST

Tecnologías de explotación de datos

1. Una de las características de los data lakes es que:
 - a) Soportan datos semiestructurados y no estructurados, pero no estructurados.
 - b) Soportan datos semiestructurados, no estructurados y estructurados.
 - c) Soportan datos semiestructurados y estructurados, pero no los soportan si son no estructurados.
 - d) Soportan datos semiestructurados y estructurados, y pueden soportar datos no estructurados si previamente han sido sometidos a un proceso de estructuración.
2. La ingestión por lotes se diferencia de la ingestión por flujo o *stream* en:
 - a) La ingestión por lotes tiene un comienzo y un final y se aplica cuando existe la necesidad de procesamiento en tiempo real.
 - b) La ingestión por flujos es la más apropiada para la realización de informes periódicos.
 - c) La ingestión por flujos no tiene inicio ni final y está permanentemente preparada para enviar datos para su ingesta mientras que la ingestión por lotes se programa periódicamente.
 - d) La ingestión por lotes se aplica exclusivamente a datos que se encuentran en repositorios OLTP mientras que la ingestión por *stream* o por flujo es más flexible y sirve para todo tipo de datos.
3. Los data lakes:
 - a) Suelen contar con varias zonas de almacenamiento donde se almacenan datos en distintos estadios de madurez.
 - b) Suelen contar con varias zonas de almacenamiento donde se replican datos idénticos como medida de protección frente a incidentes que puedan causar su borrado.
 - c) Cuentan con una única zona de almacenamiento donde se guardan datos transformados y agregados.
 - d) Utilizan exclusivamente datos virtualizados.
4. Un catálogo de datos:
 - a) Es un repositorio de datos curados junto con sus metadatos que se ofrece a los usuarios finales junto con APIs para su descarga.
 - b) Es un repositorio de datos curados junto con sus metadatos que incluye habitualmente herramientas de descubrimiento y perfilado de datos.
 - c) Es una base de datos de metadatos que viene habitualmente acompañado de herramientas para el descubrimiento y la búsqueda de datos.
 - d) Es un repositorio de datos refinados junto con sus metadatos y linaje.
5. Apache Parquet

- a) Es un formato de tablas destinado a almacenar metadatos que ofrecen un nivel de abstracción superior sobre estructuras complejas de datos.
 - b) Es una norma que define un pavimento estándar formado por piezas de madera fina acopladas y dispuestas regularmente de aplicación en centros de datos.
 - c) Es un formato de fichero orientado a filas, binario y que soporta metadatos autodescriptivos.
 - d) Es un formato de fichero columnar que soporta datos anidados.
6. Los sistemas de almacenamiento de objetos:
- a) Soportan POSIX parcialmente y permiten el acceso a los objetos como si se encontrasen en un sistema de ficheros tradicional.
 - b) No soportan POSIX pero están basados en estructuras jerárquicas de carpetas denominadas *buckets*.
 - c) Almacenan objetos que son entidades formadas por un directorio y un nombre de fichero.
 - d) Almacenan objetos que se localizan unívocamente mediante un identificador y un conjunto de metadatos.
7. La arquitectura lambda de data lakes:
- a) Emplea ingestión por streams.
 - b) Emplea ingestión por lotes
 - c) Emplea ingestión por lotes y por streams
 - d) Todas las anteriores son ciertas
8. El data lakehouse:
- a) Somete los datos del data lake a un segundo proceso de ETL para generar las estructuras de las bases de datos relacionales que soportan los cubos OLAP.
 - b) Hace uso intensivo de formatos de datos como Apache Parquet para definir estructuras de datos complejas.
 - c) No ofrecen funcionalidades de inteligencia de negocio por lo que no sustituyen a los data warehouses.
 - d) Integran y unifican las capacidades de los data warehouses con las de los data lakes ofreciendo soporte de inteligencia artificial, inteligencia de negocio e ingeniería de datos en una misma plataforma.
9. La tecnología de virtualización de datos:
- a) Permite consultar datos mediante un catálogo de datos pero no permite su descarga por carecer de APIs.
 - b) Realiza la ingesta y la transformación por lotes por adelantado y deja los datos a disposición para su consulta y descarga como si estuvieran en su repositorio original.
 - c) Permite que múltiples repositorios de datos sean accedidos y vistos desde un único lugar como si se encontrasen en una única base de datos.
 - d) Es adecuada cuando se quieren catalogar y ofrecer estructuras de datos muy complejas y voluminosas.

10. Un data mesh:
- a) Está pensado para crear silos de datos en una organización por líneas de negocio.
 - b) Se basa en el concepto de dominio que son equipos del área de negocio que elaboran potenciales casos de uso mediante técnicas de *brainstorming*.
 - c) Lo dominios conciben e implementan los casos de uso de explotación de datos extremo a extremo gracias a que los constituyen equipos multidisciplinares.
 - d) Está pensado para intercambio de datos entre organizaciones distintas que forman una malla (mesh) de organizaciones de confianza.
11. Se puede decir que los grafos de conocimiento:
- a) Están compuestos por nodos, aristas y etiquetas. Los nodos pueden ser sujetos o predicados.
 - b) Los nodos pueden ser instancias de cualquier tipo de entidad, pero no pueden representar entidades.
 - c) Las relaciones entre instancias de entidades definen la taxonomía.
 - d) Ninguna de las anteriores.
12. DataOps:
- a) Es un conjunto de buenas prácticas para la ejecución de proyectos de ingeniería de datos.
 - b) Incluye la gestión de tareas de creación de modelos típicas de machine learning.
 - c) Se centra en la supervisión del rendimiento de los modelos de machine learning en producción.
 - d) Ninguna de las anteriores.
13. Data fabric y virtualización de datos:
- a) En esencia, son lo mismo con la salvedad de que la virtualización de datos no precisa catálogo.
 - b) La virtualización de los datos se aplica a datos operacionales soportados por tecnología OLTP y es especialmente apropiada para datos voluminosos y estructuras complejas como las manejadas por la tecnología OLAP.
 - c) Data fabric asume la creación de una capa de abstracción basada en metadatos propia de la virtualización pero añade un uso intensivo de IA/ML para automatización de procesos y la orquestación de procesos, entre otros.
 - d) Data fabric se basa en la ingesta de todo tipo de datos (estructurados, semiestructurados y no estructurados) de diversas fuentes (sistemas operacionales, data lakes, repositorios en la nube) en un único repositorio desde donde son transformados y agregados.

Espacios de datos y tecnologías PET

1. Un espacio de datos:
- a) Es un repositorio global de datos estructurados, no estructurados y semiestructurados en la nube donde los datos se ponen a disposición para su explotación.
 - b) Tiene como objetivo la aplicación de técnicas OLAP para la creación de estructuras multidimensionales de hechos que permita obtener informes de negocio mediante consultas SQL sobre grandes cantidades de datos.

- c) Todas las anteriores
 - d) Ninguna de las anteriores.
2. La inversión en espacios de datos está contemplada en el Plan de recuperación, transformación y resiliencia. En concreto en:
- a) En la componente C12 'Política Industrial de España 2030' plan de inversiones I2.
 - b) En la componente C11 'Economía digital y del dato España 2020', plan de inversiones I3.
 - c) En la componente C13 'Impulso a la PYME', plan de inversiones I1.
 - d) No está contemplado explícitamente pero puede deducirse del texto de la componente C14.
3. El documento de trabajo SWD(2022) 45 final de la Comisión Europea sobre espacios de datos europeos establece, entre otras, la siguiente característica para este tipo de infraestructuras:
- a) No se pueden compartir datos de carácter personal.
 - b) No se pueden compartir datos de salud.
 - c) Los datos deben ser puestos a disposición sin compensación ni remuneración.
 - d) La participación debe permanecer abierta a organizaciones e individuos.
4. La asociación Gaia-X AISBL
- a) Tiene como objetivo el fomento de la explotación de los datos mediante infraestructuras tipo data lakes o, su tendencia actual, data fabric.
 - b) Tiene como objetivo la democratización en el uso de la inteligencia artificial con pleno respeto a los valores éticos que se desprenden del Tratado de la Unión Europea.
 - c) Tiene como objetivo la creación de hiperescalares europeos.
 - d) Tiene como misión la creación de un ecosistema federado, abierto y transparente donde los datos y los servicios asociados cumplen un conjunto de reglas comunes.
5. Entre las aportaciones de Gaia-X cabe destacar:
- a) Diseñar una arquitectura de referencia basada en componentes open source para la construcción de data lakes y similares que ofrezcan en abierto herramientas de explotación de datos.
 - b) Diseñar una arquitectura de compartición de datos de referencia basada en estándares, buenas prácticas, herramientas y mecanismos de gobernanza.
 - c) Diseñar una arquitectura centralizada de compartición de datos de referencia basada en estándares, buenas prácticas, herramientas y mecanismos de gobernanza.
 - d) Ninguna de las anteriores.
6. La Data Space Business Alliance
- a) Es un proyecto europeo ya finalizado financiado con cargo al programa Horizon 2020 que tenía como objetivo la especificación de principios de diseños de espacios de datos con valores europeos.
 - b) Tiene entre sus cometidos la convergencia de las especificaciones y tecnologías para la construcción de espacios de datos.

- c) Tiene entre sus objetivos el desarrollo de componentes de referencia para la construcción de espacios de datos con valores europeos.
 - d) Tiene entre sus objetivos definir el data lake del futuro mediante la definición de especificaciones, tecnologías y buenas prácticas.
7. En el documento Open Dei Design Principles publicado por el consorcio del proyecto Open Dei se considera principio de diseño de espacios de datos:
- a) La soberanía digital
 - b) La soberanía del dato
 - c) La Gobernanza centralizada
 - d) Las infraestructuras centralizadas.
8. La técnica de anonimización k-anonimato (k-anonymity):
- a) Está basada en criptografía.
 - b) Se considera que un conjunto de datos ofrece una protección de k-anonimato si la información de cada sujeto del conjunto de datos no se puede distinguir de al menos otros k sujetos.
 - c) Se considera que un conjunto de datos ofrece una protección de k-anonimato si la información de cada sujeto del conjunto de datos no se puede distinguir de al menos otros k-1 sujetos.
 - d) Se considera que un conjunto de datos ofrece una protección de k-anonimato si la información de cada sujeto del conjunto de datos no se puede distinguir de al menos otros k-2 sujetos.
9. La privacidad diferencial o *differential privacy*:
- a) Se basa en introducción de ruido estadístico en los datos del conjunto de datos según un patrón conocido.
 - b) Se basa en calcular la diferencia de los datos numéricos del conjunto de datos respecto de un valor dependiente del número de columna y su posterior reconstrucción.
 - c) No se considera válida para anonimización.
 - d) Funciona mejor con conjuntos de datos pequeños.
10. El cifrado homomórfico:
- a) Supone una reducción de los datos del conjunto de datos.
 - b) Puede ser de tres tipos: total (Full Homomorphic Encryption), parcial (Partial Homomorphic Encryption) y «hasta cierto punto» (Somewhat Homomorphic Encryption).
 - c) Tiene entre sus ventajas su eficiencia desde el punto de vista de los recursos computacionales requeridos para el tratamiento de conjuntos de datos tratados mediante esta técnica.
 - d) Full Homomorphic Encryption ofrece bajos niveles de protección y utilidad pero pocos recursos computacionales.
11. Secure Multiparty Computation (SMC):
- a) Se basa en la existencia de un tercero de confianza al que un grupo de sujetos ceden sus datos para su tratamiento seguro.
 - b) Puede garantizar la confidencialidad pero no la integridad.
 - c) No necesita de un tercero de confianza para el tratamiento de los datos.

- d) Es incompatible con la aplicación de otras técnicas PET.
12. Los entornos de computación de confianza o *Trusted Execution Environments* (TEE):
- a) Son especialmente adecuados para la protección de la confidencialidad de los datos en reposo.
 - b) Son especialmente adecuados para la protección de la confidencialidad de los datos en tránsito.
 - c) Las dos anteriores son ciertas.
 - d) Son especialmente adecuados para la protección de la confidencialidad de los datos en ejecución.
13. Las técnicas denominadas Private Information Retrieval:
- a) Son técnicas para garantizar la confidencialidad de las comunicaciones extremo a extremo.
 - b) Se basan en la creación de enclaves de memoria seguros.
 - c) Permiten mantener la confidencialidad de las consultas a repositorios de datos.
 - d) Todas las anteriores son ciertas.
14. La técnica de generación de datos sintéticos
- a) Evitan la aplicación de sesgos en la transformación de los conjuntos de datos porque garantizan un equilibrio sesgo-varianza inclinado hacia la varianza en la creación de modelos de *machine learning*.
 - b) Se considera que es vulnerable a la reidentificación.
 - c) Entre sus inconvenientes está el coste.
 - d) No es válida para la realización de experimentos simulados.
15. El cifrado extremo a extremo (*End to End Encryption*):
- a) Permite ocultar los metadatos de la comunicación ocultando informaciones como direcciones origen y destino.
 - b) Las claves de la comunicación las custodia el suministrador de la aplicación, como WhatsApp o Zoom.
 - c) No se diferencia del cifrado en tránsito.
 - d) Ninguna de las anteriores.
16. Las credenciales basadas en atributos que mejoran la confidencialidad (*Privacy-enhancing attribute-based credentials* o P-ABC):
- a) Se basan en el envío de los datos estrictamente necesarios para la autenticación.
 - b) Se basan en el envío de atributos que no se pueden relacionar entre sí para evitar la identificación (*un-linkable*).
 - c) Permiten el cumplimiento del principio de minimización de datos.
 - d) Todas son ciertas.

1.2 SOLUCIONES A LAS PREGUNTAS DE TEST

Tecnologías de explotación de datos

PREGUNTA	SOLUCIÓN
1	b
2	c
3	a
4	c
5	d
6	d
7	d
8	d
9	c
10	c
11	d
12	a
13	c

Espacios de datos y tecnologías PET

PREGUNTA	SOLUCIÓN
1	d
2	a
3	d
4	d
5	b
6	b
7	b

8	c
9	a
10	b
11	c
12	d
13	c
14	b
15	d
16	d

2. BIBLIOGRAFÍA

2.1 BIBLIOGRAFÍA BÁSICA

- [1] Gartner, «Gartner Glossary,» [En línea]. Available: <https://www.gartner.com/en/information-technology/glossary/data-lake>.
- [2] Oracle, «What is a Data Lake?,» [En línea]. Available: <https://www.oracle.com/big-data/data-lake/what-is-data-lake/>.
- [3] UNE - Normalización Española, «Especificación UNE sobre el Gobierno del Dato 0077,» 2023.
- [4] O. Olesen-Bagneux, The Enterprise Data Catalog, O'Reilly, 2023.
- [5] Talend, «Definitive Guide to Data Governance».
- [6] Z. Dehghani, «How to Move Beyond a Monolithic Data Lake to a Distributed Data Mesh,» 2019. [En línea]. Available: <https://martinfowler.com/articles/data-monolith-to-mesh.html>.
- [7] IBM, «What is knowledge graph?,» [En línea]. Available: <https://www.ibm.com/topics/knowledge-graph>.
- [8] E. H. et al, Data Fabric and Data Mesh Approaches with AI, New York: Apress, 2023.
- [9] Ethisham Zaidi, Guido De Simoni, «Augmented Data Catalogs: Now an Enterprise Must-Have for Data and Analytics Leaders,» Gartner, 2019.
- [10] Gartner, «Gartner Glossary. DataOps,» [En línea]. Available: <https://www.gartner.com/en/information-technology/glossary/dataops>.
- [11] Eurostat, «Cloud computing - statistics on the use by enterprises,» [En línea]. Available: https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Cloud_computing_-_statistics_on_the_use_by_enterprises#Use_of_cloud_computing:_highlights.
- [12] S. Bond, «Automating Intelligent Data Governance,» IDC Market Spotlight, 2019.
- [13] Gartner, «Gartner Survey Reveals Less Than Half of Data and Analytics Teams Effectively Provide Value to the Organization,» 2023. [En línea]. Available: <https://www.gartner.com/en/newsroom/press-releases/03-21-2023-gartner-survey-reveals-less-than-half-of-data-and-analytics-teams-effectively-provide-value-to-the-organization>.
- [14] Forrester, Yuhanna, N., «The Forrester Wave: Enterprise Data Fabric, Q2 2022,» Forrester, 2022. [En línea]. Available: <https://reprints2.forrester.com/#!/assets/2/73/RES176390/report>.
- [15] Comisión Europea, «Comission Staff Working Document on Common European Data Spaces SWD(2022) 45 final,» Febrero 2022. [En línea]. Available: <https://digital-strategy.ec.europa.eu/en/library/staff-working-document-data-spaces>.
- [16] Comisión Europea, «COM(2020) 66 final. Una estrategia europea de datos,» Febrero 2020. [En línea]. Available: <https://eur-lex.europa.eu/legal-content/ES/TXT/PDF/?uri=CELEX:52020DC0066>.

- [17] IDC, «European Market Study 2021-2023. Second Report on Facts and Figures,» European Commission, 2023.
- [18] Asociación Gaia-X AISBL, [En línea]. Available: <https://gaia-x.eu/>.
- [19] Federal Ministry for Economic Affairs and Energy (BMWi), «Project GAIA-X. A Federated Data Infrastructure as the Cradle of a Vibrant European Ecosystem,» Octubre 2019. [En línea]. Available: <https://www.data-infrastructure.eu/GAIAX/Redaktion/EN/Publications/project-gaia-x.pdf>.
- [20] F. Bonfiglio, «Vision & Strategy,» Gaia-X AISBL, Diciembre 2021. [En línea]. Available: <https://gaia-x.eu/wp-content/uploads/2021/12/Vision-Strategy.pdf>.
- [21] Gaia-X Federation Services, «GXFS Overview,» [En línea]. Available: <https://www.gxfs.eu/gxfs-overview/>.
- [22] Gaia-X European Association for Data and Cloud AISBL, «Gaia-X Architecture Document,» Octubre 2022. [En línea]. Available: <https://gaia-x.gitlab.io/technical-committee/architecture-document/>.
- [23] GAIA-X European Association for Data and Cloud, «Gaia-X Architecture Document - master Release,» 2023. [En línea]. Available: <https://gaia-x.gitlab.io/technical-committee/architecture-document>.
- [24] Data Space Business Alliance., «DSBA. Unleashing the Data Economy. Technical Convergence,» septiembre 2022. [En línea]. Available: https://data-spaces-business-alliance.eu/wp-content/uploads/dlm_uploads/DSBA-Technical-Convergence.pdf.
- [25] International Data Spaces Association, «Reference Architecture Model 4,» 2023. [En línea]. Available: <https://docs.internationaldataspaces.org/ids-knowledgebase/v/ids-ram-4/>.
- [26] International Data Spaces Association, «Data Space Radar,» 2023. [En línea]. Available: <https://internationaldataspaces.org/adopt/data-space-radar/>.
- [27] Open Dei, «About Open Dei,» [En línea]. Available: <https://www.opendei.eu/>.
- [28] L. D. Nagel L., «Design Principles for Data Spaces,» 2021. [En línea]. Available: <https://design-principles-for-data-spaces.org/>.
- [29] Gaia-X Federation Services (GXFS), «Gaia-X Ecosystem Kickstarter,» Diciembre 2021. [En línea]. Available: <https://www.gxfs.eu/download/1703/>.
- [30] Cross Federated Service Components, «Eclipse XFSC (Cross Federation Services Components),» [En línea]. Available: <https://projects.eclipse.org/projects/technology.xfsc>.
- [31] Data Spaces Support Centre, «Blueprint Version 0.5,» 2023.
- [32] OCDE, «Emerging Privacy Enhancing Technologies. Current regulatory and policy approaches,» 2023.
- [33] ENISA, «Data Protection Engineering. From Theory to Practice,» Enero 2022. [En línea]. Available: <https://www.enisa.europa.eu/publications/data-protection-engineering>.

- [34] Agencia Española de Protección de datos, «Anonimización y seudoanonimización,» Octubre 2021. [En línea]. Available: <https://www.aepd.es/prensa-y-comunicacion/blog/anonimizacion-y-seudonimizacion>.
- [35] F. M. H. H. Kseniia Ermoshina, «End-to-End Encrypted Messaging Protocols: An Overview,» *Third International Conference, INSCI 2016 - Internet Science*, 2016.
- [36] R. T. M. e. al., «The OLYMPUS Architecture—Oblivious Identity Management for Private User-Friendly Services,» *Sensors*, 2020.
- [37] A. e. al, «Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics,» de *Annual Conference on Innovative Data Systems Research (CIDR '21)*, 2021.
- [38] P. R. M. D. o. C. S. U. o. Toronto, *Big Data Curation*, Toronto, 2015.
- [39] Ashutosh Gupta, «Data Fabric Architecture is Key to Modernizing Data Management and Integration,» Gartner, 2021. [En línea]. Available: <https://www.gartner.com/smarterwithgartner/data-fabric-architecture-is-key-to-modernizing-data-management-and-integration>.
- [40] Gartner, «Understand the Role of Data Fabric. Guides for Effective Business Decision Making.,» 2022. [En línea].
- [41] VenturaBeat, «Why do 87% of data science projects never make it into production,» [En línea]. Available: <https://venturebeat.com/ai/why-do-87-of-data-science-projects-never-make-it-into-production/>.
- [42] Flexera, «Cloud computing trends and statistics 2023,» 2023. [En línea]. Available: <https://www.flexera.com/blog/cloud/cloud-computing-trends-flexera-2023-state-of-the-cloud-report/>.
- [43] Eurostat, «Cloud computing - statistics on the use by enterprises,» [En línea]. Available: https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Cloud_computing_-_statistics_on_the_use_by_enterprises#Use_of_cloud_computing_highlights. [Último acceso: Noviembre 2022].
- [44] J. F. Moore, *The Death of Competition. Leadership and Strategy in the Age of Business Ecosystems*, Harper Business, 1996.
- [45] Francesco Nachira et al, «Digital Business Ecosystems,» Comisión Europea. Directorate General Information Society and Media, 2007. [En línea]. Available: <https://op.europa.eu/o/opportal-service/download-handler?identifier=53e45e55-4bd2-42a4-ad25-27b339b051e0&format=pdf&language=en&productionSystem=cellar&part=>. [Último acceso: Noviembre 2022].

2.2 BIBLIOGRAFÍA PARA AMPLIAR EL TEMA

- **Sobre data lakes:**
 - Data Engineering with Apache Spark, Delta Lake, and Lakehouse. Manoj Kukreja. Ed. Packt. Birmingham, 2021.
 - *Data lakes for dummies*. Alan Simon. John Wiley & Sons, Inc., 2021.
- **Sobre data warehouses:** el tema 75 del antiguo temario es excelente.
- **Sobre catálogos de datos:**
 - O. Olesen-Bagneux, *The Enterprise Data Catalog*, O'Reilly, 2023.
- **Sobre data mesh y data fabric:**
 - E. H. et al, *Data Fabric and Data Mesh Approaches with AI*, New York: Apress, 2023.

También, leer documentación de los propios suministradores de sistemas de explotación: IBM, Informatica, Databricks, Talend, y de consultoras como Gartner.
- **Sobre espacios de datos:**

Lo mejor es leer la documentación que pone a disposición el Data Space Support Center:
<https://dssc.eu/page/knowledge-base>
- **Sobre tecnologías PET:** lo mejor son los siguientes informes de la OCDE y de ENISA respectivamente. Los dos se encuentran en Internet:
 - OCDE, «Emerging Privacy Enhancing Technologies. Current regulatory and policy approaches.,» 2023.
 - ENISA, «Data Protection Engineering. From Theory to Practice.,» Enero 2022. [En línea]. Available: <https://www.enisa.europa.eu/publications/data-protection-engineering>.