



*Asociación Profesional de Cuerpos Superiores
de Sistemas y Tecnologías de la Información
de las Administraciones Públicas.*

Temas Específicos para la preparación de la Oposición al Cuerpo Superior de Sistemas y Tecnologías de la Información de la Administración del Estado.

TEMAS ESPECÍFICOS III: Ingeniería de los Sistemas de Información

Tema 105. Sistemas de recuperación de la información. Políticas, procedimientos y métodos para la conservación de la información

Editado por ASTIC en 2017 a partir de los temas numerados anteriormente como:

- **Tema 96. Sistemas de recuperación de la información**
Autor: Julio Gilarranz Tejada
Actualización 2007
- **Tema 97. Políticas, procedimientos y métodos para la conservación de la información en soporte electrónico**
AUTOR: Juan Guevara
Actualización 2014

Contenido

1	Introducción	4
2	Conceptos básicos	4
3	Modelos y técnicas de recuperación	6
3.1	Modelos clásicos	7
3.2	Modelos avanzados	10
3.3	Modelos estructurados	13
4	Medidas de evaluación	14
4.1	Enfoque tradicional	14
4.2	Medidas relacionadas con el usuario	16
5	Indexación y recuperación automáticas	17
5.1	Índices invertidos	17
5.2	Aplicación de técnicas de Lenguaje Natural	18
6	Recuperación de información multimedia	19
7	Búsquedas en la Web	20
8	Técnicas relacionadas con la recuperación de información	24
8.1	Extracción de Información (Information Extraction)	24
8.2	Minería de textos (Text Mining)	25
9	Conclusiones	26
	Políticas, procedimientos y métodos para la conservación de la información en soporte electrónico	28
1.	Introducción	28
1.1.	Antecedentes	28
1.2.	Situación en la Administración	29
2.	Aspectos normativos	31
2.1.	Normativa general aplicable a la conservación de la información	31
2.1.1.	Legislación previa a la Ley 39/2015	31
2.1.2.	Ley 39/2015, del Procedimiento Administrativo Común de las Administraciones Públicas	32
2.1.3.	Real Decreto 1671/2009, de 6 de noviembre, por el que se desarrolla parcialmente la Ley 11/2007	32
2.1.4.	La Ley Orgánica 15/1999, de Protección de Datos Personales	34
2.1.5.	El Reglamento de Desarrollo de la Ley Orgánica 15/1999, Real Decreto 1720/2007	34
2.1.6.	El Esquema Nacional de Seguridad, Real Decreto 3/2010	34
2.1.7.	El Esquema Nacional de Interoperabilidad, Real Decreto 4/2010	35
2.1.8.	La Ley 59/2003, de Firma Electrónica	35
2.2.	Normativa específica (legislación médica, judicial, hacienda pública, etc.)	36
2.3.	Estándares	37
3.	Criterios de conservación de la información	38
3.1.	Análisis de riesgos	38

3.2.	Ciclo de vida de la información	39
3.3.	Almacenamiento de la información.....	40
3.4.	Soportes.....	40
3.5.	Formatos	41
3.6.	Seguridad física y lógica de la información.....	41
3.7.	Sistema de archivos.....	42
4.	Medidas organizativas y técnicas de la conservación de la información	43
4.1.	Salv guarda y recuperación de datos	43
4.2.	Replicación de la información	43
4.2.1.	Replicación continua (copia en tiempo real)	44
4.2.2.	Replicación discreta (backups)	45
4.2.3.	Replicación de CPDs (Centros de Proceso de Datos), centros de respaldo	45
4.3.	Política de copias de seguridad	46
4.4.	Políticas de borrado seguro de la información	47
4.5.	Plan de contingencias	48
4.6.	Custodia de la información	49

1 Introducción

Con el surgimiento y rápida expansión de los ordenadores a todos los ámbitos de la actividad diaria, se ha creado en la sociedad una necesidad de consumir gran cantidad de información. Dicha información está actualmente disponible de manera masiva a través de diversos medios, como Internet, pero en su mayor parte está en su formato bruto, datos.

El objetivo de la **Recuperación de la Información** (*Information Retrieval*, **IR**) es permitir gestionar todo este volumen de datos textuales o multimedia de una manera eficiente y efectiva, de manera que se recupere la información pertinente de una manera rápida y sencilla.

La Recuperación de la información es actualmente un campo multidisciplinario en el que investigan, entre otros, bibliotecarios, lingüistas, psicólogos y especialistas en procesamiento de la información. Entre las líneas de trabajo que aborda se encuentran problemáticas documentales tan diversas como análisis de textos, indexación y representación, almacenamiento, compresión, acceso y presentación del conocimiento.

Los **Sistemas de Recuperación de Información** permiten identificar, de entre una colección de documentos, cuáles son relevantes a una consulta realizada por un usuario. Así, suelen estar integrados dentro de Gestores de Bases de Datos Documentales, para poder llevar a cabo las tareas de análisis, resumen, procesamiento requeridas que permitan tratar con textos completos. Estos gestores facilitan la conservación, recuperación y difusión de la información contenida en los mismos.

A diferencia de los Sistemas de Gestión de Bases de Datos Relacionales, orientados al manejo de datos estructurados y que utilizan un lenguaje de búsquedas que permiten concretar exactamente el conjunto de registros deseado, los sistemas de Recuperación de la Información trabajan con información no estructurada, mayoritariamente en formato texto (aunque últimamente se está trabajando también con documentos multimedia). Además, el volumen de información gestionada es muy elevado, del orden de gigabytes y superiores.

Con el advenimiento de Internet y la World Wide Web, los aspectos relativos a la recuperación de documentos relevantes a la información deseada por los usuarios han impulsado aún más si cabe la investigación en las técnicas de recuperación de información. En este sentido, mencionar que los sistemas de Recuperación de Información más difundidos en la actualidad son los buscadores Web como Google™, que tratan de identificar los documentos de la World Wide Web que son de interés en una consulta formada por un conjunto de palabras determinado.

2 Conceptos básicos

Recuperación de Información frente a Recuperación de Datos

La **Recuperación de Información** se ocupa de la representación, almacenamiento, organización y acceso a elementos de información. La forma de representarlos y organizarlos debería proporcionar al usuario una forma sencilla de acceso a la información que le interesa.

Lamentablemente, es muy complicado especificar la *necesidad de información del usuario*. Una consulta realizada en lenguaje natural (por ejemplo, "Recuperar todos los documentos relacionados con artículos publicados por un autor en concreto sobre una materia determinada en los últimos cinco años") no se puede realizar directamente a través de la interfaz de los sistemas de búsqueda actuales. El usuario se ve, en cambio, obligado a convertir su necesidad de información en una consulta (*query*) que pueda ser procesada por estos sistemas.

El objetivo principal de los sistemas de recuperación de información es la obtención de información relevante para el usuario, y se hace énfasis precisamente en *recuperación de información* en contraposición con la *recuperación de datos*:

- La *recuperación de datos* tiene por objetivo la recuperación de todos los objetos de una colección que satisfacen claramente las condiciones contenidas en una expresión regular o algebraica. Los sistemas de recuperación de datos, como las bases de datos relacionales, tratan con datos con una estructura y semántica bien definida.
- La *recuperación de información*, por el contrario, maneja habitualmente textos expresados en lenguaje natural que por su propia esencia no está bien estructurado y puede ser semánticamente ambiguo.

La recuperación de datos no soluciona el problema de recuperar información relativa a un tema determinado. Para ser realmente efectivo, un sistema de recuperación de información debe de alguna manera ser capaz de "interpretar" el contenido de los documentos de una colección y ordenarlos respecto al grado de relevancia respecto a una consulta de usuario.

Diferencia entre búsqueda y ojeo

La interacción del usuario con el sistema de Recuperación de Información se realiza mediante la traducción de su *necesidad de información* en términos del lenguaje de consulta proporcionado por el usuario. Habitualmente esto conlleva la utilización de una serie de palabras que contiene la semántica de la información deseada. Se dice entonces que, cuando el usuario trata de localizar información útil, está llevando a cabo una **búsqueda** (*retrieval*).

Por otro lado, puede darse la circunstancia de que el usuario esté interesado en un tema inherentemente amplio o que no tiene claramente definido. En este caso, la interacción con el sistema suele realizarse mediante el **ojeo** (*browsing*) de documentos con la esperanza de encontrar algo que concrete más su búsqueda. Ahora, aunque sigue siendo un proceso de recuperación de información, los objetivos principales de la búsqueda no están bien definidos y el propósito de la misma puede variar durante la interacción con el sistema.

Los sistemas clásicos de Recuperación de Información están orientados en su mayoría a las acciones de **búsqueda**, mientras que los sistemas basados en hipertextos se ajustan habitualmente a permitir un **ojeo** rápido. Los sistemas modernos y los buscadores Web tratan de combinar ambas acciones del usuario para proporcionar capacidades de recuperación de información mejoradas. En este caso, el sistema de Recuperación de Información realizará una tarea particular de búsqueda que consiste en el **filtrado** de información para su revisión posterior por el usuario y posible refinamiento de la consulta.


Visión lógica de los documentos

Por motivos históricos, los documentos de una colección se representan frecuentemente a través de un conjunto de términos de índice o palabras clave (*keywords*). Dichas palabras clave podrían ser extraídas directamente del texto o ser especificadas por un operador humano, y proporcionan la **visión lógica de los documentos** desde la óptica del sistema de recuperación de información.

Cuando el sistema es capaz de representar un documento a partir del conjunto completo de palabras que contiene se dice que la visión lógica adoptada es de **texto completo** (*full text*). En colecciones muy grandes, no obstante, esta aproximación llega a ser inmanejable y es necesario depurar el conjunto de palabras claves utilizado para reducir su volumen. Esto se puede conseguir a través de alguna de las siguientes **operaciones sobre textos**:

- Eliminación de palabras vacías (*stop words*), como artículos o conjunciones.
- Identificación de la raíz gramatical (*stemming*)
- Identificación de sintagmas nominales
- Compresión de los conjuntos de palabras obtenidos.

La visión lógica de texto completo suele implicar costes computacionales muy elevados. Según las operaciones sobre textos que se realicen se conseguirán visiones lógicas intermedias entre la aproximación anterior y la del conjunto de términos de índice.



Aparte de la adopción de alguna de dichas visiones lógicas, el sistema de recuperación podría identificar también la estructura interna del documento (capítulos, secciones, párrafos, etc.) lo cual puede ser muy útil a la hora de concretar las consultas sobre la colección.

Proceso de recuperación de la información

A continuación se describe de manera general el proceso de recuperación de información. En apartados posteriores se realizará una explicación detallada de las acciones más relevantes.

Antes de poder llevar a cabo labores de búsqueda, es necesario definir la base de datos documental, donde residirá la colección de textos. Para ello, el gestor de la base de datos especifica la colección de textos a utilizar, las operaciones sobre los textos a realizar, y el modelo de texto (es decir, la estructura del texto y qué elementos se pueden recuperar).

Al aplicar las operaciones sobre textos a los documentos originales, se obtiene la visión lógica de los mismos. A partir de la misma, el gestor de bases de datos realiza la **indexación automática de los textos**. Los índices generados en este proceso son estructuras de datos críticas que permiten realizar búsquedas rápidas sobre volúmenes extensos de información. Aunque existen múltiples estructuras de indexación, la más popular es la conocida como **archivo invertido** (*inverted file*).

Una vez obtenida la base de datos indexada, se puede comenzar la realización de búsquedas. Para ello, el usuario debe identificar su *necesidad de información*. Para procesar dicha necesidad, se le podrían aplicar las mismas operaciones sobre textos que a los documentos, y así convertirla al formato de **consulta** (*query*).


Al aplicar la consulta a la base de datos indexada se obtienen los **documentos recuperados**. Antes de mostrárselos al usuario, se les aplica una ordenación acorde a su **relevancia** frente a la consulta realizada. Esta lista de documentos ordenada será revisada por el usuario, que podrá seleccionar un subconjunto de los mismos para que sobre el mismo se proceda a refinar la consulta (**realimentación**) y ajustar así aún más el resultado a su necesidad de información.

3 Modelos y técnicas de recuperación

En líneas generales, existen dos grandes líneas de investigación y tecnología en el campo de la Recuperación de Información: las *aproximaciones semánticas*, y las *estadísticas*.

Las aproximaciones semánticas intentan aplicar cierto grado de análisis sintáctico y semántico que sea de utilidad a la hora de interpretar la necesidad del usuario. Las aproximaciones estadísticas, por otro lado, se basan en la categorización de la importancia de los documentos recuperados para una búsqueda determinada en función de ciertas mediciones estadísticas. Las aproximaciones estadísticas fueron las primeras en desarrollarse, y de ellas surgen los llamados *modelos clásicos*: booleano, vectorial y probabilístico. De estos modelos han surgido otros, denominados a veces *modelos avanzados*, que tratan de desarrollar algunas características novedosas o no tenidas en cuenta por los anteriores, e incluso acercarse a las aproximaciones semánticas.

Por otro lado surgen los modelos estructurados, que tratan de combinar tanto el contenido de los documentos como el conocimiento sobre su estructura.



3.1 Modelos clásicos

En los modelos clásicos, cada documento se representa por un conjunto de palabras claves representativas o *términos de índice*. Un término de índice es una palabra del documento que resulta útil para recordar los principales aspectos del documento. Suelen ser sustantivos porque tienen significado por sí mismos; sin embargo, en ocasiones las máquinas de búsqueda asumen que todas las palabras sirven como términos de índice, lo que como se indicó anteriormente es conocido como *representación de texto completo*.

Habitualmente se asignan pesos relativos a los términos de índice contenidos en un documento o una consulta, para tratar de indicar la efectividad que tendrá dicho término a la hora de distinguir un documento de entre el resto de los que integran la colección, o de la importancia que se asigna a dicho término dentro de una consulta a la hora de calcular la relevancia de los documentos respecto de dicha consulta. Estos pesos suelen estar normalizados entre 0 y 1, y uno de los puntos que diferencian estos modelos entre sí es precisamente el mecanismo para calcularlos.

La extracción de términos de índice y la asignación de pesos a los mismos sientan el marco de referencia para definir la visión lógica de los documentos en los modelos clásicos. Las diferencias fundamentales entre dichos modelos parten, por tanto, no tanto de la visión del documento, sino de cómo aplicar las consultas sobre la colección para identificar los documentos relevantes para una consulta.

3.1.1 Modelo booleano

Este modelo fue el primero en surgir, y por tanto el más utilizado tradicionalmente. Es un modelo bastante simple, basado en teoría de conjuntos, en el cual las consultas se formulan como una combinación booleana de términos. Los operadores utilizados habitualmente son Y, O y NO:

- Un documento satisface la consulta " t_1 Y t_2 " sólo si contiene ambos términos;
- Un documento satisface la consulta " t_1 O t_2 " sólo si contiene alguno de los dos términos (o ambos);
- Un documento satisface la consulta " t_1 Y NO t_2 " sólo si contiene el término t_1 y no contiene t_2 .

A partir de la combinación de estos operadores se pueden construir consultas booleanas complejas que se evalúan siguiendo las reglas clásicas del álgebra booleana. Esto implica que las consultas cumplen una semántica muy precisa, y que requieren seguir un formalismo muy estricto para su formulación.

En el modelo booleano sólo se tiene en cuenta la aparición de un término de índice o su ausencia dentro de un documento. Esto comporta varias consecuencias características de este modelo:

- El peso relativo de un término dentro de un documento sólo será 1 (si está presente en el mismo) ó 0 (si está ausente)
- Respecto a una consulta dada, un documento será relevante si cumple todas las condiciones establecidas en la consulta, o no relevante si no las satisface: no se permiten distintos grados de relevancia.

Los principales inconvenientes de los modelos booleanos surgen precisamente de las características enunciadas hasta el momento:

- Los documentos se recuperan siguiendo un criterio de decisión binario, que no contempla la noción de coincidencia parcial (*partial matching*).
- Al no existir ninguna escala de gradación, no es posible establecer un orden (*ranking*) entre los documentos recuperados.
- La necesidad de información del usuario ha de ser traducida a una expresión booleana, lo cual suele resultar poco intuitivo y complicado para la mayoría de los usuarios: esto provoca bien la realización de consultas imprecisas, que generan gran cantidad de ruido (recuperación de textos no deseados o sin interés) mientras que las muy precisas pueden ignorar textos interesantes. Por lo general, los modelos booleanos suelen recuperar a partes iguales textos interesantes y textos.

Ahondando en este último punto, cada uno de los operadores booleanos implica un riesgo para un usuario poco habituado a ellos:

- la concatenación de muchas cláusulas O implica peligro de mucho ruido;
- las cláusulas Y introducen riesgo de demasiado acotamiento;

- las cláusulas NO, raramente utilizadas, suelen provocar malas construcciones por la aplicación de las leyes de Morgan que originen grandes áreas de sombra no deseadas en la búsqueda.

La construcción de una buena consulta booleana resulta difícil y con frecuencia exige la colaboración de intermediarios expertos, cuya labor consiste en añadir términos no incluidos en principio (dado que el usuario los daba por supuestos), eliminar los generales o demasiado vagos, aportar sinónimos o reducir términos a sus raíces.

En los Sistemas de Recuperación de Información se suelen refinar las consultas booleanas clásicas mediante la incorporación de operadores no booleanos, tales como operadores métricos de proximidad o de contigüidad (distancia de una palabra a otra, pertenencia a una misma frase o párrafo, etc.). Esto permite consultas con mayor precisión, ya que la probabilidad de que dos términos aparezcan contiguos o cercanos en un mismo documento objeto es mucho más baja que la de que simplemente aparezcan.

El proceso de consulta basado en el modelo booleano se caracteriza por ser del tipo "prueba con reintento" con alto grado de retroalimentación hasta obtener una versión definitiva de la consulta que suministre una cantidad razonable de documentos, aunque dicha versión tendrá seguramente al final una sintaxis bastante compleja y una estructura semántica extraña y poco inteligible. Es habitual, una vez construida la consulta, que si ésta se va a repetir periódicamente sea almacenada como un "perfil de búsqueda" para posteriores ocasiones.

3.1.2 Modelo vectorial


Como ya se ha comentado, uno de los mecanismos más extendidos en la indexación y representación de documentos es el identificarlos con un conjunto de términos, extraídos normalmente de forma automática de los propios documentos. Tomando los términos que aparecen en los documentos de una colección, el conjunto de todos ellos se puede ver como un espacio en el que cada término representa una dimensión; para ello se supone que los términos son independientes entre sí, y que por tanto permiten definir un espacio ortonormal.

Esto sienta los cimientos para la **asignación de pesos que no sean únicamente binarios**, como en el caso del modelo booleano, sino que se elijan de forma que representen la utilidad del término al que ponderan para distinguir un documento determinado de otros documentos de la colección. Si un término no aparece en el documento, se le asignará un peso cero. Entre otros beneficios, la utilización de pesos no binarios permite contemplar la opción de coincidencias parciales entre una consulta y un documento.

El modelo vectorial, por tanto, se basa en representar cada documento según un *vector formado por los pesos de sus términos de índices*, y que permite ver a un documento como un punto en el espacio formado por todos los términos de índice.

Las consultas realizadas pueden ser especificadas por el usuario como un conjunto de términos ponderados por sus respectivos pesos, o bien estar expresada en lenguaje natural que se procese como si fuera un documento. De cualquier manera, *la consulta también se podrá representar como otro vector en el espacio de documentos*.

A partir de ambos vectores se calcula numéricamente la similitud entre la consulta y los documentos de la colección. Uno de los métodos utilizados habitualmente es definir la similitud como el coseno del ángulo formado por ambos vectores, aunque existen otros mecanismos más elaborados diseñados para mejorar la relevancia y la ordenación de los documentos recuperados.



El cálculo de los pesos se puede realizar de varias maneras, pero uno de los esquemas más empleado es el conocido como *term frequency x inverse document frequency*, **tf*idf**. Este mecanismo tiene en cuenta tanto la frecuencia de aparición del término en un documento determinado (*term frequency*, **tf**), como la inversa de la frecuencia de aparición del término en el conjunto de documentos de la colección (*inverse document frequency*, **idf**). La idea es que un término que aparece de manera repetida a lo largo de un texto puede ser útil para representarlo; no obstante, si este mismo término es muy común en toda la colección, la utilidad del término disminuye. El cálculo del peso de un término para un documento determinado siguiendo el esquema **tf*idf** indica que los mejores términos para describir un documento son aquellos que aparecen muchas veces en dicho documento, pero apenas se utilizan en el resto de la colección. A veces se incorpora un factor de normalización que tiene en cuenta la longitud de los textos, para evitar que se favorezca la recuperación de textos largos sobre cortos.

El modelo vectorial presenta como ventaja frente al modelo booleano que permite la recuperación de textos aunque la coincidencia con la consulta sea sólo parcial, y que además el mecanismo utilizado para calcular el grado de similitud entre un documento y la consulta realizada proporciona directamente un mecanismo para ordenar los documentos por relevancia.

Uno de los inconvenientes que se le atribuyen a este modelo es que considera que los términos de índice son independientes entre sí; para tratar de solventar este (hipotético) problema se ha extendido el modelo vectorial en el modelo alternativo conocido como "Indexación por Semántica latente" (*Latent Semantic Index*). No obstante, no existe acuerdo sobre si asumir la independencia de los términos introduce realmente errores en la recuperación y *ranking* de los resultados.

3.1.3 Modelo probabilístico

Al igual que los modelos vectoriales, los probabilísticos surgieron de las primeras investigaciones en torno a las propiedades estadísticas de las colecciones de textos. Estos modelos se basan en el teorema de Bayes, al suponer que la importancia de un término puede estimarse comparando las características de aparición en una serie de documentos relevantes con las correspondientes en el resto de la colección.

El **modelo probabilístico**, también conocido como *modelo de recuperación de independencia binaria*, (*Binary Independence Retrieval*, **BIR**) fue definido en la década de los setenta. Según este modelo, para una necesidad informativa del usuario, existe un subconjunto de documentos de la colección que contiene exclusivamente los documentos relevantes en relación con ella, es decir, existe un **resultado ideal**. El objetivo, por tanto, es identificar los términos de indexación que permiten caracterizar tal subconjunto de documentos relevantes, porque aparecen en ellos y no aparecen en el resto de los documentos de la colección.

De lo anterior se extrae una de las premisas del modelo probabilístico, y es que *considera exclusivamente de la presencia o ausencia de los términos* en los documentos de la colección. Se trata pues, de un modelo binario, como el modelo booleano.

El modelo probabilístico **actúa sobre los términos que configuran la consulta del usuario**, asignándoles un peso de manera que se cuanto mejor permita discernir los documentos relevantes de los irrelevantes mayor será, y menor en caso contrario. De esta manera se persigue que el sistema efectúe la recuperación incidiendo sobre todo en los mejores descriptores de entre los empleados por el usuario en la consulta, minimizando la importancia de aquellos otros términos incluidos en ella, pero que son malos descriptores del resultado ideal.

Así, a cada término empleado en la consulta se le asignan dos probabilidades:

- *Probabilidad de ser buen descriptor*: probabilidad de que el término empleado en la consulta esté presente en un documento del conjunto de documentos relevantes en relación con la consulta
- *Probabilidad de ser mal descriptor*: probabilidad de que ese mismo término esté presente en un documento del conjunto de documentos irrelevantes en relación con la consulta.

Dado que estas probabilidades son desconocidas en el momento de formalizar la consulta, este modelo se ve en la necesidad de efectuar una **hipótesis inicial** sobre sus valores. Basándose en estos pesos iniciales, el modelo probabilístico es capaz de calcular el grado de similitud existente entre cada documento de la colección y la consulta ponderada, y así ordenar los documentos de la colección en orden descendente de probabilidad de relevancia en relación con la consulta. Esto implica que, a diferencia del modelo booleano, el probabilístico efectúa equiparación parcial; y lo consigue no mediante la ponderación de los términos de la colección como en el modelo vectorial (ya que es un modelo binario), sino gracias a la ponderación de los términos empleados en la consulta.

Para depurar los resultados, el modelo probabilístico requiere de un aprendizaje en el que haya una intensa interacción con el usuario, lo que se denomina **realimentación por relevancia**. Tras obtener el conjunto inicial de documentos a partir de las hipótesis iniciales, éstas se mejoran por iteración con el usuario, al cual se le solicita que analice los documentos recuperados y juzgue cuáles son relevantes. Con esta información se imponen nuevos valores a las probabilidades de ser buen y mal descriptor para cada término de la consulta, y se obtiene una nueva respuesta de documentos ordenados por su probabilidad de relevancia, ahora mejorada gracias a la información suministrada directamente por el usuario. De esta forma, si se repite el proceso un número suficiente de veces el resultado obtenido se acercará mucho al resultado ideal.

Las críticas al modelo probabilístico se centran en dos cuestiones principales:

- La visión lógica binaria del documento: no tiene en cuenta factores como **tf** e **idf**.
- La obligatoriedad de hacer una hipótesis inicial sobre las "probabilidades de ser buen y mal descriptor" para cada término de la consulta. Esto se ha considerado el principal inconveniente de este modelo, de ahí que siga siendo una de las áreas de investigación más activas entre sus especialistas.

3.1.4 Comparación entre los modelos clásicos

Se han hecho numerosos estudios para determinar qué modelo clásico es superior a los otros. Aunque no existe consenso en cuanto a este tema, ya que cada uno de ellos tiene sus defensores y detractores, y existen líneas de investigación abiertas que tratan de mejorar cada uno de ellos, sí se puede establecer lo siguiente:

- El modelo booleano puro se considera el más débil al no proporcionar coincidencias parciales ni, por tanto, ordenación por relevancia.
- Los experimentos realizados apuntan a que, en general, el modelo vectorial tiene un comportamiento superior al probabilístico cuando se utiliza contra colecciones genéricas de documentos.

3.2 Modelos avanzados

3.2.1 Modelos basados en teoría de conjuntos

Uno de los aspectos más criticados del modelo booleano es la utilización de un criterio binario a la hora de decidir la relevancia de un documento para una consulta determinada. Para tratar de superar este punto, ha habido múltiples líneas de investigación que han intentado extender este modelo para que permita coincidencias parciales y ordenación por relevancia.

Entre estos esfuerzos, cabe destacar las dos aproximaciones siguientes:

- Modelos basados en lógica borrosa
- Modelo booleano extendido

Modelos basados en lógica borrosa

Estos modelos parten de la base de que la representación tanto de consultas como de documentos como un conjunto de términos de índice hace que su coincidencia sea algo *aproximado* desde el primer momento. Esta indefinición puede modelarse dentro de un marco de lógica borrosa, de la siguiente forma:

- Cada término se asocia a un conjunto borroso.
- Cada documento tiene un grado de pertenencia a dicho conjunto borroso (normalizado entre 0 y 1).

Estas bases proporcionan los cimientos para el desarrollo de múltiples modelos de Recuperación de Información que aplican lógica borrosa.

Para calcular la *proximidad* entre dos términos de índice se calcula el *factor de correlación* entre ellos, que depende del número de documentos que contienen cada uno de los términos por separado y el número de documentos que contienen ambos términos. El grado de pertenencia de un documento al conjunto borroso asociado a un término de índice estará en función de los factores de correlación de dicho término con los que representan al documento.

En estos modelos, el usuario realizará sus consultas de un modo similar al modelo booleano; el sistema la recogerá y transformará en una forma normal disjunta. Los operadores Y, O que aparezcan en dicha expresión de la consulta se resuelven a través de:

- Cálculo del mínimo (para Y) o máximo (para O) grado de pertenencia.
- Operaciones matemáticas (sumas, productos) sobre los coeficientes de correlación de los términos para computar el grado de pertenencia de un documento a un conjunto borroso definido para la consulta.


Las pruebas experimentales con sistemas basados en lógica borrosa muestran buenos resultados, aunque su empleo está restringido por el momento al campo de la investigación.

Modelo booleano extendido

En el **modelo booleano extendido** se trata de introducir la ordenación por relevancia relajando las condiciones para pertenecer al conjunto resultado.

Para ello se van a combinar características del modelo vectorial con el álgebra booleana, mediante la incorporación de pesos a los términos índice de cada documento, y la interpretación de conjunciones y disyunciones a través de su evaluación en términos de distancias euclídeas sobre un espacio de n dimensiones, siendo cada dimensión un término índice.

De esta forma, se medirá la similitud de un documento con una consulta basada en la conjunción de n -términos como la distancia entre el punto $(1,1,\dots,1)$ y el que representa al documento en base a sus pesos normalizados. Igualmente, la similitud basada en la disyunción se medirá como la distancia entre el $(0,0,\dots,0)$ y el documento. Esto se puede generalizar para consultas que incorporen tanto conjunciones como disyunciones.



Un refinamiento adicional del modelo booleano extendido permite introducir un mecanismo por el cual es posible modificar el rigor con el que se van a interpretar las conjunciones y disyunciones, suavizando la importancia de dichos operadores. Aunque existen diversos métodos para llevar a cabo dicha modificación, uno de los principales es el que se basa en la utilización de las **normas-p**, investigadas por Salton, Fox y Wu en 1983. Estas normas plantean un mecanismo para generalizar el cálculo de la distancia euclídea a "distancia-p". El parámetro p es un valor comprendido entre 1 e infinito, de manera que cuando vale 2 nos encontramos ante la distancia euclídea, y el sistema se comportará como el modelo vectorial.

$$\begin{aligned} \text{sim}(q_{or}, d_j) &= \left(\frac{x_1^p + x_2^p + \dots + x_n^p}{n} \right)^{\frac{1}{p}} \\ \text{sim}(q_{and}, d_j) &= 1 - \left(\frac{(1-x_1)^p + (1-x_2)^p + \dots + (1-x_n)^p}{n} \right)^{\frac{1}{p}} \end{aligned}$$

El parámetro p indica el grado de intensidad con el que se interpretan los operadores: si $p = 1$ indica la relajación máxima a la hora de interpretar el peso de los operadores en la consulta (se da al operador Y y al operador O la misma relevancia), y $p = \infty$ la interpretación más estricta (cuando O se considera mínimo e Y máximo).

El modelo booleano extendido es bastante potente, con propiedades interesantes que podrían ser muy útiles. En contrapartida su cálculo es bastante complejo, y dificulta la aplicación de la lógica booleana al no mantener la propiedad distributiva a la hora de calcular las relevancias: según el álgebra booleana, si $q1 = (k1 \vee k2) \wedge k3$, se podría expresar también como $q2 = (k1 \wedge k3) \vee (k2 \wedge k3)$, y por tanto las relevancias obtenidas deberían ser iguales. Sin embargo, en el modelo extendido, $\text{sim}(q1, dj) \neq \text{sim}(q2, dj)$.

3.2.2 Modelos algebraicos

Modelo vectorial generalizado

Uno de los puntos criticados al modelo vectorial es la hipótesis de que los términos de índice que representan a un documento son independientes entre sí, y por tanto se puede definir un espacio euclídeo con los mismos como ejes.

La idea del **modelo generalizado**, definido en 1985, es partir de un **grupo de vectores** m_i , denominados *miniterms*, que sí son ortogonales entre sí, para adoptarlo como el conjunto de vectores bases para los subespacios de interés. Los *miniterms* permiten representar la dependencia entre términos al incorporar un mismo *miniterm* varios términos de índice relacionados; en este caso se dice que existe una dependencia inducida entre dichos términos.

Hay que destacar que en este modelo los pesos se aplican a los *miniterms*, no a los términos índice.

A modo de resumen, el modelo vectorial generalizado permite considerar la existencia de correlaciones entre términos de índice. Sin embargo, no se ha demostrado una superioridad clara frente al modelo vectorial clásico, mientras que su coste computacional es mucho más elevado.

Indexación por Semántica Latente (*Latent Semantic Indexing*, LSI)

Del análisis de los sistemas de Recuperación de Información clásicos se puede desprender que su actuación es pobre debido a que dependen de la utilización de términos de índice, lo cual puede ser vago y ruidoso.

Se podría pasar de un enfoque orientado a **conceptos e ideas**, ya que la necesidad de información del usuario está más relacionada con aquellos que con términos de índice. Además, es muy probable que un documento que comparta conceptos (que no términos de índice) con otro del cual se sabe que es relevante sea también interesante.

Por tanto, la idea clave es representar tanto documentos como consultas en un espacio de menos dimensiones, formado por conceptos de más alto nivel y que son un número más reducido que el de términos índice. Los resultados extraídos de este espacio conceptual más reducido deberían ser superiores que si la recuperación se hubiera efectuado sobre el espacio formado por términos índice.

Para la identificación de los conceptos se analizan estadísticamente los patrones de utilización de palabras a lo largo de la colección de documentos.

La utilización de estos modelos permite reducir de manera significativa el número de dimensiones a contemplar para trabajar con otro mucho más razonable. La mayor dificultad surge precisamente en la identificación de los conceptos, para lo cual es necesaria la aplicación de técnicas de aprendizaje automático.

Modelos basados en redes neuronales

Las redes neuronales surgen en el campo de la Inteligencia Artificial como un mecanismo para reproducir el funcionamiento del cerebro humano. Han sido aplicadas con éxito en diversos campos; en particular, es una buena técnica para el reconocimiento de patrones. Esta característica resulta muy útil a la hora de utilizarlas en un sistema de recuperación de información.

Una red neuronal representa el cerebro como un conjunto de neuronas, donde cada neurona se puede entender como una unidad de procesamiento, con una señal de entrada y otra de salida. De esta forma, se puede entender el cerebro como una red de neuronas que interactúan entre sí mediante el intercambio de señales. Su representación gráfica es en forma de grafo, en el que cada nodo es una neurona, y cada arco es una conexión sináptica. Los arcos tienen pesos, y a cada nodo se le asocia un estado de activación.

Según el estado de activación, el nodo A puede enviar una señal al nodo B, con una intensidad que dependerá del peso del arco que une los nodos.


A la hora de aplicar esta técnica a la recuperación de información, se establece una red a tres capas, a través de las cuales se propagan las señales.

El primer nivel de propagación está compuesto por los términos incluidos en la consulta, que los son que lanzan las primeras señales que se propagan a través de la red para alcanzar los nodos que representan a los documentos.

Surge un segundo nivel de propagación, en el cual los nodos de documentos generan nuevas señales que afectan a los nodos de términos de índice. Estos nodos intermedios, a su vez podrían responder con señales propias. Como resultado podrían llegar a obtenerse documentos que no incluyan ningún término de la consulta.

Las señales provenientes de los nodos tienen un peso asignado de 1. Los pesos iniciales que se asocian a los arcos de la red se calculan de manera que, tras la primera activación, el resultado obtenido es similar al modelo vectorial. Las señales generadas a partir del segundo nivel de activación actuarían como un proceso de realimentación.

Este modelo presenta unas características interesantes, aunque no ha sido probado de manera extensiva, y no está claro hasta qué punto resulta una mejora frente a otros modelos.



3.2.3 Modelos bayesianos

Uno de los puntos a favor de los modelos probabilísticos es la claridad de su semántica; la base de su formulación es intuitiva y por tanto fácil de comprender. No obstante, aunque su significado está claro, los cálculos necesarios para su implementación son bastante complejos y engorrosos.

La superación de estos inconvenientes se abordó a través de la utilización de redes bayesianas, que proporcionan un formalismo simple para la modelización de evidencias, y permite modularizar el mundo real a través de la identificación de dependencias entre conceptos.

Las redes bayesianas son grafos acíclicos dirigidos, en los que los nodos representan variables aleatorias, los arcos indican relaciones de causalidad entre dichas variables, y el grado de dicha influencia causal se expresa a través de probabilidades condicionales.

Aplicados a la Recuperación de Información, destacan los siguientes modelos basados en redes bayesianas:

- las Redes de Inferencia (*Inference Networks*)
- las Redes de Confianza (*Belief Networks*), que surgen como generalización de las anteriores.

A diferencia de otros modelos, en estos no se busca la probabilidad de que un documento dado sea relevante para una consulta determinada, $P(\text{Relevancia} \mid \text{documento}, \text{consulta})$, sino que la necesidad de información sea cubierta por un documento determinado, $P(\text{Necesidad de información} \mid \text{documento})$.

Los modelos basados en redes bayesianas se basan en relacionar la probabilidad *a priori* de la relevancia de un documento (es decir, la probabilidad de que un documento elegido al azar sea relevante), con la probabilidad *a posteriori* de la relevancia, dadas las características observadas de dicho documento. Estas características pueden ser los términos de índice, descriptores asociados al mismo de manera manual, estadísticas sobre los términos que incluye, etc.

Es decir, se puede mejorar el modelo de recuperación no solo con la información extraída de forma automática de los documentos sino también de evidencias aportadas de manera externa y que permiten mejorar la ordenación por relevancia.

3.3 Modelos estructurados

La característica principal de los modelos estructurados de recuperación de información es que permiten combinar la especificación de consultas con la de información sobre la estructura del documento.

En estos modelos los documentos se consideran relevantes si satisfacen las condiciones de la consulta; apenas es posible ordenar por relevancia. Por este motivo a la hora de elegir un modelo basado en la estructura hay que estar dispuesto a llegar a un compromiso entre su expresividad y la eficiencia de su estrategia de evaluación de consultas.

Aunque existen numerosos modelos que hacen uso de una forma u otra de la información sobre la estructura del documento, a continuación se mencionan dos grupos principales:


- Modelos basados en listas no superpuestas
- Modelos basados en nodos próximos

En la actualidad se está trabajando en el refinamiento de estos modelos, con la utilización de XML como mecanismo para definir las estructuras.

Modelo de listas no solapadas

La noción tras el modelo de listas no solapadas fue presentada por Burkowski en 1992.

Parte de la idea de la división del modelo en una colección de segmentos disjuntos, que se reúne posteriormente en una **lista no solapada** (*non overlapping list*). En un libro, por ejemplo, la lista podría contener los capítulos del mismo. Dado que no hay una única manera de dividir un documento, no obstante, se generarán múltiples listas atendiendo a diferentes criterios de división; cada lista se almacenará en una estructura de datos diferente. Aunque dentro de una lista no se puedan producir solapes, sí que puede existir solapamiento de regiones en distintas listas.



Para poder buscar sobre las listas se crean *dos ficheros invertidos*. Como se verá más adelante, un fichero invertido es un fichero de índice compuesto de dos partes: el *vocabulario*, que contiene los elementos a indexar, y las *ocurrencias*, que contienen para cada elemento del vocabulario una lista de ocurrencias asociadas al mismo.

En este modelo, el primer fichero invertido utiliza como vocabulario los componentes estructurales de las listas no solapadas, y las ocurrencias indican las regiones de texto asociadas a dichos elementos estructurales. El segundo fichero invertido tiene una estructura más clásica de términos de índice como vocabulario y su posición en el


texto como ocurrencias. Ambos ficheros invertidos se pueden fusionar para permitir búsquedas tanto por términos de índice como por componentes estructurales.

El mayor inconveniente de este modelo es que requiere la formulación de consultas siguiendo la lógica booleana.

Modelo de nodos próximos

Este modelo surge como generalización del de listas no solapadas, y fue propuesto en 1997.

Según este modelo, todo documento de la colección se puede representar a través de una estructura jerárquica de regiones, como por ejemplo capítulos, secciones, subsecciones y así sucesivamente. Cada una de estas partes se representa como un nodo dentro de la estructura jerárquica.



Al igual que en el modelo de listas no solapadas, existen múltiples maneras de construir dicha jerarquía y por tanto se podrán generar múltiples jerarquías. En este caso, no obstante, los resultados de una consulta se extraerán únicamente de una jerarquía determinada, ya que mezclar resultados de diferentes jerarquías reduce la expresividad. Debido a esto, solamente se utiliza un fichero invertido que permite la búsqueda a través de términos de índice y referencias a componentes estructurales.

Las búsquedas sobre las jerarquías se pueden restringir a nodos próximos si se ha encontrado alguna coincidencia previa.

Este modelo tiene los mismos inconvenientes que el de las listas solapadas.

4 Medidas de evaluación

En este apartado se va a realizar una revisión de las medidas de evaluación que habitualmente se aplican a los sistemas de recuperación de la información, siguiendo tanto el enfoque tradicional como aquel que evalúa la satisfacción de los usuarios, para los sistemas online.

4.1 Enfoque tradicional

4.1.1 Relevancia y pertinencia

La relevancia es uno de los conceptos claves en Recuperación de Información, ya que está en la base del resto de las medidas que tradicionalmente se vienen aplicando en estos sistemas.

El concepto de relevancia se ha estudiado desde distintos puntos de vista, que han dado lugar a dos tendencias:


- *La tendencia subjetiva*, que estudia la relevancia como la utilidad, o potencial uso de los materiales recuperados, con relación a la satisfacción de los objetivos, el interés, el trabajo o los problemas intrínsecos del usuario.
- *La tendencia objetiva*, que se centra en el funcionamiento de los sistemas y define cómo la materia de la información recuperada coincide con la de la pregunta realizada.

Algunos autores introducen un concepto muy ligado a la relevancia denominado **pertinencia**. La distinción entre ambos es muy tenue, de tal forma que con frecuencia se entremezclan y confunden. Así, estos autores definen la **relevancia** como la medida de *cómo una pregunta se ajusta a un documento*, (esta visión coincide con el enfoque de la relevancia objetiva) y **pertinencia** es la medida de *cómo un documento se ajusta a una necesidad informativa* (lo que otros autores definen como relevancia subjetiva).

Para calcular la relevancia, lo más habitual es establecer valores binarios: un documento es relevante, es decir, sirve como respuesta a una pregunta determinada – valor 1 – o no sirve – valor 0. También es posible fijar una gradación, y establecer una escala ordinal para medir la relevancia de los documentos. El problema de determinar una escala es que no hay una guía clara para elaborarla, y en la práctica distinguir entre un documento relevante y uno parcialmente relevante es muy difícil.

4.1.2 Principales medidas de evaluación

Los documentos pertenecientes a una colección pueden ser recuperados o rechazados al establecer la comparación entre la pregunta y la base de datos. El conjunto de documentos recuperados se divide, salvo en los sistemas perfectos, en dos grupos: *documentos relevantes recuperados*, aquellos que se han recuperados correctamente y *los no relevantes, recuperados erróneamente* que provocan ruido en la salida. Los documentos no recuperados, se dividen a su vez en los relevantes, rechazados por el sistema de manera errónea y los no relevantes, rechazados de manera correcta por el sistema.



Precisión

Este concepto, también conocido como *factor de pertinencia* o *ratio de aceptación*, indica la proporción de material recuperado realmente relevante, del total de los documentos recuperados. Dado que el resultado de esta operación está entre 0 y 1, la recuperación perfecta es aquella en la que únicamente se recuperan los documentos relevantes y por lo tanto tiene un valor de 1.

$$\text{Precisión} = \frac{\text{Documentos relevantes recuperados}}{\text{Documentos recuperados}}$$

Esta medida está relacionada con el concepto de *ruido*, de modo que cuanto más se acerque el valor de la precisión a 0, mayor será el número de documentos recuperados que no le sirvan al usuario y por lo tanto el ruido que encontrará será mayor.

La salida obtenida en la recuperación se ordena en función de la relevancia, por lo que los documentos más relevantes están al comienzo de la salida, y a medida que avanzamos en el número de documentos recuperados, la precisión decae. Esto significa que cuantos más documentos se recuperen, menor será la precisión.

Exhaustividad (*recall*)

Junto con la precisión, la exhaustividad es el otro concepto más utilizado en la evaluación de los sistemas de recuperación. También se conoce como *índice de retorno* o *sensibilidad*. Esta medida indica la proporción de material relevante recuperado, del total de los documentos que son relevantes en la base de datos, independientemente de que éstos se recuperen o no.

$$\text{Exhaustividad} = \frac{\text{Documentos relevantes recuperados}}{\text{Documentos relevantes}}$$

Si el resultado de este cálculo tiene como valor 1, tendremos la exhaustividad máxima, ya que he habrá encontrado todo lo relevante que había en la base de datos, por lo tanto la recuperación será perfecta.

Esta medida es inversamente proporcional a la precisión, ya que cuanto mayor sea el número de documentos recuperados, mayor será la exhaustividad (suponiendo que la proporción entre documentos recuperados y documentos relevantes recuperados no disminuya). Para alcanzar una exhaustividad alta es necesario utilizar como índice términos generales de alta frecuencia, es decir, que aparezcan en muchos documentos de la colección. Por otro lado, para alcanzar una precisión alta, es necesario que los términos aparezcan con frecuencia alta, pero en pocos documentos y con nula en el resto. Aunque para el usuario la situación ideal es una precisión y exhaustividad alta, esto es imposible.

Un sistema de Recuperación de Información debe mantener la precisión y la exhaustividad compensadas, ya que si se cuenta con una exhaustividad muy alta pero con baja precisión, y viceversa, no será adecuado.

Factor de ruido

Es el complemento del factor de precisión, y se formula así:

$$\text{Factor de ruido} = \frac{\text{Documentos no relevantes recuperados}}{\text{Documentos recuperados}}$$

Como ésta, existen otras medidas que comparan los distintos conjuntos de documentos, pero presentan un interés menor frente a las de precisión y exhaustividad.

Medida-f

La *medida-f* es un valor matemático que trata de evaluar sistemas de Recuperación de Información en los cuales la precisión y la exhaustividad estén muy compensadas. Se calcula como la media armónica ponderada de la exhaustividad (E) y la precisión (P), según la fórmula:

$$F = \frac{(B^2 + 1) P \times R}{B^2 \times P + R}$$

donde B toma valores entre 0 e infinito. Cuando B = 1, la medida-f está dando el mismo peso a la precisión que a la exhaustividad, y se conoce como *medida-f balanceada*. Valores de B inferiores a 1 hacen énfasis en la precisión, mientras que valores superiores a 1 lo hacen en la exhaustividad.

4.2 Medidas relacionadas con el usuario

La precisión y la exhaustividad se basan en que el conjunto de documentos recuperados para una consulta concreta no varía, independientemente del usuario que la haya formulado. Sin embargo, lo habitual es que la valoración de la respuesta obtenida varíe de unos usuarios a otros, o incluso para un mismo usuario dependiendo del momento de la recuperación. Por este motivo son necesarias las medidas orientadas a los usuarios.

La **efectividad de un sistema** es una medida ajena al propio sistema que relaciona la satisfacción del usuario con la salida que el sistema proporciona. Medir la satisfacción del usuario resulta muy importante, pero es complicado y es menos objetivo que las medidas vistas anteriormente, por lo que las medidas basadas en usuarios se han ido dejando de lado.

Otras medidas más fáciles de calcular son las que tienen en cuenta entre documentos relevantes conocidos y no conocidos por el usuario. De esta forma se pueden definir los siguientes ratios:

- **Ratio de cobertura:** es la proporción de documentos relevantes conocidos por el usuario que son recuperados:

$$\text{Cobertura} = \frac{\text{Docs. relevantes conocidos recuperados}}{\text{Documentos relevantes conocidos}}$$

- **Ratio de novedad:** proporción de documentos relevantes recuperados que previamente son conocidos por el usuario.

$$\text{Novedad} = \frac{\text{Docs. relevantes desconocidos recuperados}}{\text{Documentos relevantes recuperados}}$$

También se puede definir otra medida, denominada **exhaustividad relativa**, que indica la proporción de documentos relevantes recuperados que han sido examinados por el usuario, respecto del número total de documentos que el usuario quiere examinar.

Un ratio de cobertura alto puede dar al usuario confianza en que el sistema localice todos los documentos relevantes. También sugiere que el sistema es efectivo en la localización de documentos desconocidos para el usuario. Por otra parte, es bastante probable que al usuario no le interese simplemente el recuperar aquellos documentos que él ya conoce; de esta forma, es deseable que el ratio de novedad sea alto.

En cuanto a la exhaustividad relativa, se refiere más directamente a la cuestión del grado de interés que el usuario tiene en algunos documentos. Suponiendo que el sistema presenta 20 documentos al usuario y que éste quiere 5 documentos relevantes, si solo hay 3 documentos relevantes entre los 20, la exhaustividad relativa será 3/5, es decir, el usuario solo obtiene 3 de los 5 que busca. Si por el contrario, hay 5 ó más documentos relevantes entre los 20, entonces, presumiblemente el usuario podrá abandonar después de encontrar los 5 deseados con una exhaustividad relativa de 5/5, es decir de 1.

Podría ser que el usuario encuentre los documentos entre los primeros 5 ó 6 examinados o podría ser que necesitara examinar los 20. Esto da pie para definir una nueva medida: **esfuerzo de exhaustividad**, que indica la proporción de documentos relevantes deseados partido por el número de documentos que ha de examinarse para localizar los anteriores. Esta medida asume que la colección contiene el número de documentos relevantes deseado y que el sistema de recuperación permite al usuario localizarlos todos, lo cual aunque es deseable no siempre es posible. Este ratio puede ir de 1, si los documentos relevantes deseados son los primeros documentos

examinados por él, a próximo a 0, si el usuario necesita examinar un gran número de documentos para encontrar los pocos que desea.

Otra medida relacionada con el usuario es la **satisfacción**, que hace énfasis entre lo que el usuario quiere y el usuario recibe. De todas las medidas enumeradas, ésta es la más subjetiva, por lo que habrá que valorarla con mucho cuidado.

5 Indexación y recuperación automáticas

5.1 Índices invertidos

Al inicio del tema se indicaron los módulos en los que se descompone normalmente un sistema de recuperación de información. De entre todos ellos, destaca la indexación como una de las partes fundamentales, ya que su diseño e implementación pueden afectar drásticamente al rendimiento global, tanto en lo relativo a la calidad de las búsquedas como a los tiempos de respuesta.

Existen diversas estructuras utilizadas para recoger el resultado de la indexación, de forma que se agilicen las tareas de recuperación. Pese a las diferencias entre ellas, la gran mayoría se basan en el concepto de **fichero índice invertido**, o **fichero inverso**, desarrollado inicialmente para el modelo booleano y extendido posteriormente, con modificaciones, a otros muchos modelos.

La estructura básica de un fichero de índice invertido se compone de dos elementos: *el vocabulario y las ocurrencias*. El **vocabulario**, también denominado **diccionario**, es el conjunto de todos los términos de índice que aparecen en los textos. A cada término de índice se le asocia una lista de los documentos en donde se puede encontrar esa palabra, a la que se le suele añadir la longitud de esta lista (es decir, el número de referencias contenidas). El conjunto de todas esas listas es lo que constituye las **ocurrencias**. La referencia a los documentos suele hacerse a través de un número de documento asignado durante el proceso de indexación.

De forma esquemática, se puede ver el fichero inverso como una tabla como la siguiente, en la que hay una fila por cada término de índice contemplado y una columna por documento de la colección.

	D1	D2		Dn
T1	1	0		1
T2	0	1		0
....				
Tt	0	1		1

El fichero índice así generado responde a la visión lógica del modelo booleano, ya que sólo hace referencia a la aparición o no de un término en un documento. Sobre esta base se pueden construir otros modelos, como el vectorial, simplemente almacenando en las ocurrencias no sólo la aparición del término en el documento, sino además el peso ponderado que se le ha asignado.

Otro refinamiento de este modelo es aquel en el que cada elemento de las listas apunta, no a un documento, sino a la posición concreta del término índice dentro del documento. Esta aproximación permite entonces realizar búsquedas por operadores documentales de proximidad.

Como se ha indicado, los ficheros índices permiten gestionar de manera eficiente grandes volúmenes de información, ya que basta con contrastar la consulta contra las referencias contenidas en las ocurrencias de cada término de índice. Su principal desventaja es la cantidad de espacio necesario para almacenar la estructura del índice, que puede variar entre un 10% y 100% del texto original, o incluso más. Otro problema que surge son las penalizaciones para las inserciones de nuevos documentos y las actualizaciones en los documentos ya existentes, que requieren la revisión completa del fichero invertido para su modificación.

Para tratar de aliviar en alguna medida el problema del volumen, se aplican diversas técnicas tanto de compresión de índices, como de tratamiento de los documentos mediante técnicas de Lenguaje Natural, que veremos en el siguiente punto.

5.2 Aplicación de técnicas de Lenguaje Natural

Tal y como se ha venido comentando a lo largo del tema, el procesamiento automatizado del texto de un documento comienza con la extracción de los términos de índice que van a ser utilizados para describir el contenido del documento.

La posibilidad más simple consiste en considerar todas las palabras aisladas que aparecen en el texto como los términos de índice (enfoque *full text*). En el otro extremo estaría el enfoque de *vocabulario controlado*, en el que sólo se indexan aquellas palabras del texto que pertenecen al vocabulario, y por tanto sólo se podrán realizar búsquedas por dichos términos. En la práctica se opta por un modelo intermedio, en el que se trata de indexar todos aquellos términos que puedan ser de utilidad para identificar el documento frente a una necesidad de información del usuario, y al mismo tiempo reducir el volumen de los archivos a manejar.

Una primera labor que se realiza consiste en preprocesar los textos para identificar los inicios y finales de las palabras, a través de la aplicación de reglas que se encargan del tratamiento de espacios en blanco, signos de puntuación, etc. A partir del resultado del paso anterior, opcionalmente se eliminan algunas palabras, las denominadas *palabras vacías* o *stop words*, entre las que suelen figurar números, preposiciones, conjunciones, verbos ser, haber y estar, al considerar que su indexación no aporta riqueza a la descripción del modelo y que incluso puede llegar a generar mucho ruido.

El resultado obtenido del preprocesamiento anterior suele considerarse aún como modelo de texto completo, y sigue representando un volumen ingente de información. Para llevar a cabo la indexación según el modelo intermedio comentado previamente, en los sistemas de recuperación de información se ha procurado incorporar diversas técnicas provenientes del Procesamiento del Lenguaje Natural. Estas técnicas se pueden aplicar a varios niveles: *morfológico*, *sintáctico* e incluso *semántico*.

Indexación morfológica

Una de las primeras propuestas para reducir el número de términos de índice extraídos de un documento consiste en la indexación tanto de documentos como de consultas por su raíz, lo que se denomina *stemming*. Estas técnicas pueden ser más o menos complejas, dependiendo del grado de aplicación de la morfología derivativa: desde la identificación de singulares y plurales, por ejemplo, a la detección de superlativos o diminutivos.

Los resultados obtenidos con estas técnicas dependen, lógicamente, del lenguaje de la colección documental, ya que los diferentes fenómenos morfológicos no se manifiestan con la misma intensidad en todas las lenguas. Así, mientras que para el inglés apenas aporta mejoras, en el caso del español diversos estudios indican que la aplicación de técnicas morfológicas tiene efectos beneficiosos en la recuperación de documentos.

Indexación sintáctica

Hasta el momento sólo se ha contemplado la indexación por palabras aisladas. Dicha aproximación asume implícitamente la independencia de éstas respecto de los textos de las que se extraen, y, por tanto, obvia varios aspectos lingüísticos relevantes, como conceptos contruidos mediante la concatenación de varias palabras ortográficas, o el orden de las palabras que puede implicar variación de significados (por ejemplo, en inglés no es lo mismo *college junior* que *junior college*). La indexación sintáctica intenta superar este problema mediante la identificación de diferentes estructuras sintagmáticas. De esta forma se puede realizar tanto una indexación multipalabra que solventaría los aspectos lingüísticos comentados, como incluso una normalización de estructuras sintácticas en patrones comunes, como la identificación de oraciones en activa y pasiva.

De los diversos estudios realizados para evaluar las técnicas de indexación sintácticas concluyen que las mejoras sólo son apreciables para consultas largas, y prácticamente inexistentes para consultas cortas. Además se indica que la indexación por sintagmas debe complementar a la indexación por términos simples, y no sustituirla; en este caso se plantea un problema en la determinación de los pesos a asignar a los compuestos detectados.

Indexación basada en el sentido de las palabras

El objetivo de la Recuperación de Información es satisfacer una *necesidad de información* del usuario, plasmada mediante una consulta dirigida contra la colección de documentos que se ha indexado. El tener que expresar dicha consulta mediante unas palabras determinadas puede provocar varios problemas:

- En un gran número de ocasiones los términos empleados son polisémicos, con lo cual se produce una ambigüedad léxica semántica imposible de solucionar en los sistemas de indexación por palabras.

- Pueden existir documentos en la colección que incorporen términos con el mismo significado que los utilizados en la consulta, por lo que serían relevantes para el usuario, y sin embargo no se recuperen al no incorporar la palabra específica utilizada por éste en la formulación de la consulta.

Se han propuesto varios métodos para indexar documentos y consultas de acuerdo no a las palabras concretas que los componen sino al concepto que tratan de representar. Los principales son la utilización de **diccionarios** y la de **redes semánticas**.

La indexación semántica mediante el uso de diccionarios permitirá la representación diferenciada de los diferentes significados de un mismo significante, lo que permitiría el tratamiento de la polisemia y la homonimia.

Por su parte, el empleo de redes semánticas permitiría contemplar también fenómenos como el de la sinonimia, meronimia, e hiponimia. Además podrían emplearse para la identificación de la temática de los documentos mediante el estudio de las relaciones entre los diversos conceptos contenidos en los mismos. Asimismo, si se dispusiese de una red semántica multilingüe se podrían recuperar documentos en diversos idiomas atendiendo a la semántica de la consulta realizada y su cruce con la de los diversos documentos de la colección.

La aplicación de diccionarios y redes semánticas para la sustitución de términos y ampliación de las consultas en modelos como el vectorial eleva el rendimiento de los sistemas de recuperación de información hasta un 60% tanto de exhaustividad como de precisión.

6 Recuperación de información multimedia

Hasta el momento se ha expuesto la problemática de la recuperación de información de documentos en formato texto. Sin embargo, existe hoy en día múltiples fuentes de información basadas en otros medios, como fotografías, dibujos, audio, video, etc. Para conseguir recuperar dicha información ha sido necesario extender las técnicas tradicionales de recuperación de textos con otras conocidas como **Recuperación de Información Multimedia** (*Multiple Media Information Retrieval*).

Entre los problemas que surgen en esta disciplina se puede destacar la dificultad para indexar información contenida en múltiples medios. Los primeros esfuerzos en este sentido se han dedicado a encontrar mecanismos que permitan incorporar anotaciones a los documentos multimedia, a través de las cuales se puedan realizar las consultas. Existe actualmente un campo de investigación muy dinámico en torno al análisis de patrones, visión computerizada, procesamiento de audio e imágenes, y aprendizaje automático aplicado a la extracción de metadatos a partir de documentos no textuales.

Los metadatos necesarios para categorizar colecciones de objetos multimedia se pueden dividir en tres tipos:

- **Metadatos semánticos**, que tratan de caracterizar el asunto o material de la que trata el documento.
- **Metadatos de contexto**, que describen relaciones del documento con objetos externos, como autor, intérprete, etc.
- **Metadatos estructurales**, que describe la estructura interna y modo de presentación del documento.

En este punto es conveniente realizar hincapié en que los datos multimedia a los que se desea acceder suelen ser datos recogidos de diferentes medios, y en algunas ocasiones combinados (como vídeo con audio incluido, o texto con imágenes), aunque también pueden aparecer por separado. Cuando se pretende integrar todo tipo de documentos provenientes de diferentes medios surgen los *Sistemas de Recuperación de Información Multimedia*, que se pueden definir como aquellos dedicados a la gestión (almacenamiento, recuperación y manipulación) de múltiples tipos de documentos multimedia. Un sistema de recuperación de información multimedia permitiría, por tanto, lanzar búsquedas no solo sobre un archivo de imágenes o de video, sino sobre todos ellos al mismo tiempo.

En la práctica, estos sistemas recogen la consulta lanzada por el usuario y la redirigen a sistemas especializados de recuperación de información de medios (bases de datos relacionales, documentales, audio, imágenes, vídeo, etc.), aunque se están especificando modelos alternativos que permitan integrar todos los documentos en un mismo índice sobre el cual realizar la búsqueda, de la forma en que se hace con la recuperación de información textual. Uno de los problemas a los que se enfrentan estos sistemas es la resolución de la *heterogeneidad semántica* que existe entre las bases de datos de medios que los componen. Esta heterogeneidad se presenta tanto entre bases relacionales (con distintos nombres de atributos o estructuras para representar los mismos datos o conceptos) como entre colecciones de datos semi-estructurados o no estructurados (diferencias en la definición de los metadatos o la definición XML).

Uno de los campos en los que más se ha avanzado es en la **gestión de bases de datos de imágenes**, ya que estos bancos de datos documentales son los siguientes en surgir después de los textuales. La estructura habitual de las colecciones de imágenes es similar a la de las colecciones de documentos: a cada imagen se asocia una serie de metadatos descriptivos a través de los cuales realizar labores de recuperación. No obstante, las características de las imágenes son distintas a las de los textos, y puede interesar la realización de búsquedas mediante la *comparación directa de imágenes*. Para ello, los sistemas actuales hacen uso del análisis de características de bajo nivel (*low-level features*) detectadas de manera automática, como colores, distribución de texturas e identificación de formas; a estas técnicas se las denomina Recuperación de Imágenes basadas en Contenidos (*Content Based Image Retrieval*, **CBIR**). El problema de estos sistemas es que la utilización de características de bajo nivel no tiene por qué dar buenos resultados semánticos, ya que objetos de diferente naturaleza pueden tener características de bajo nivel similares.

A la hora de recuperar video o contenido multimedia entramado, los esfuerzos se enfocan a la partición del documento en segmentos con significado propio. Algunos mecanismos se basan en el estudio de la luz o del color, ya que asumen que puede servir como un indicador de cambio de escena. Una vez se dispone de la partición, se extrae una imagen fija de cada segmento y se procesa a través de alguna de las técnicas comentadas en el párrafo anterior. Junto con las dificultades propias de la recuperación de imágenes, por tanto, se unen otras dos: el mecanismo de segmentación y la selección de la imagen representativa de cada segmento.

Dado que los mecanismos completamente automatizados de categorización de imágenes tienen todavía una calidad mediana, otro campo de investigación abierto en la actualidad es la mejora de la capacidad descriptiva de los metadatos asociados a las imágenes. En este sentido se combinan técnicas de indexación manual por operadores humanos, aprendizaje automático y aplicación de tesauros, entre otras. También se explora la aplicación de redes semánticas y conceptuales, para tratar de orientar las búsquedas al concepto buscado y no al idioma en que se expresa.

Para otro tipo de medios, como voz grabada o notas manuscritas, los mecanismos utilizados para caracterizarlos se orientan a la identificación del texto, con la aplicación de reconocedores de voz o de caracteres. Cuando el audio se compone principalmente de sonidos, como melodías, existen diversos enfoques. El principal se basa en la medida de la *similitud acústica* entre el documento y la consulta, como timbre o ritmo. Otro enfoque, que trata de mejorar los resultados obtenidos por el anterior se basa en la *similitud semántica*. En el primer caso, ante el trino de un pájaro el sistema podría recuperar el sonido del timbre de una puerta; en el segundo, otros sonidos de pájaros como graznidos.

7 Búsquedas en la Web

Antes de la aparición de la Web, los sistemas de recuperación de información eran considerados como herramientas útiles únicamente para bibliotecarios, investigadores y expertos en tratamiento de información. Esto cambió, sin embargo, en los años 90 con la universalización de la World Wide Web.

La Web se está convirtiendo rápidamente en el repositorio universal de la cultura y el conocimiento humano, y ha permitido una compartición de ideas e información sin precedentes. Un usuario es capaz de publicar contenidos sin necesidad de conocimientos técnicos, por lo que cualquiera puede diseminar sus ideas, percepciones y creencias a un público global.

La revolución introducida por Internet ha conllevado sus propios problemas. Encontrar información útil resulta una labor tediosa y difícil. Conseguirlo simplemente navegando por los hipervínculos es, directamente, imposible. Esto ha provocado que se haya renovado el interés en las técnicas de Recuperación de Información como soluciones prometedoras.

Evolución de la búsqueda en la Web

La publicación masiva en la Web resulta básicamente inútil si otros usuarios no pueden encontrar y consumir esos contenidos. Las dos primeras aproximaciones para conseguir que la información en Internet fuera "descubrible" fueron:

- Máquinas de búsqueda basadas en la indexación por texto completo, como Altavista o Infoseek;
- Directorios: taxonomías alimentadas con páginas Web por categorías, como Yahoo!

Aunque existen hoy en día diversas iniciativas que tratan de mantener la segunda aproximación, el interés en las taxonomías ha ido desapareciendo con el tiempo.

Las primeras máquinas de búsqueda trataron de aplicar las técnicas clásicas de Recuperación de Información, y enfocaron sus esfuerzos en solventar el reto de la enorme escala a la cual aplicarlas. Para ello se enlazaron decenas de máquinas con las que se consiguió indexar fracciones significativas de la Web al tiempo que se devolvían resultados de búsqueda en tiempos inferiores al segundo. Sin embargo, debido a la idiosincrasia de la creación de contenidos en la Web provocaba que la relevancia y calidad de las respuestas fueran bastante pobres. Para tratar de paliarlo, se tuvieron que desarrollar nuevas técnicas de asignación de relevancia (*ranking*) y *anti-spam*. En el contexto de búsquedas en la Web, el *spam* consiste en la manipulación del contenido creado para forzar que las máquinas de búsqueda asignaran erróneamente una relevancia elevada y así atraer accesos de usuarios, usualmente con fines comerciales o publicitarios.

Junto a los mecanismos ilícitos de obtener preponderancia en una búsqueda concreta, se han desarrollado máquinas de búsqueda específicas para ser patrocinadas, de manera que se presenta primero al mejor postor, y así amortizar los gastos en los que se incurre para cubrir las necesidades crecientes de los buscadores en hardware y ancho de banda. En la actualidad los motores de búsquedas en la web han convergido en un modelo híbrido entre las búsquedas "puras" (también denominadas algorítmicas) y las patrocinadas, mediante la presentación al usuario tanto de los resultados de su búsqueda pura como de los enlaces patrocinados, pero separados claramente en la página Web.

Tipos de consulta

La mayor parte de las consultas que se realizan en la Web se pueden incluir dentro de una de estas categorías:

- *Consultas de información (informational queries)*: se busca conocimiento general respecto a un tema amplio. No suele existir una única página que englobe toda la información deseada, por lo que los usuarios que realizan este tipo de consultas tratan de asimilar el contenido de múltiples páginas Web.
- *Consultas de navegación (navigational queries)*: se busca la página principal de una entidad o compañía que el usuario tiene en mente. En este caso el usuario espera que dicha página sea la que aparezca en primer lugar.
- *Consultas transaccionales (transactional queries)*: aquella que el usuario utiliza como punto de partida para proceder a realizar una transacción por Internet – compra de un producto, descarga de contenidos o realización de una reserva, por ejemplo.

Identificar el qué tipo de consulta se está realizando en una búsqueda determinada es un reto importante, ya que puede afectar no sólo el resultado esperado de una búsqueda algorítmica, sino también los enlaces patrocinados (ya que puede que revele una intención de compra). Esto lleva a su vez al número de páginas Web que el motor de búsqueda es capaz de indexar, ya que puede ser relevante a la hora de las consultas de información (y en menor medida a las transaccionales) por lo que los diferentes buscadores compiten en cuando al porcentaje de contenido estático de Internet que son capaces de incorporar a su banco de datos.

Identificación de duplicados

En la Web existen numerosas páginas que están duplicadas, o su contenido varía entre ellas sólo de manera ligera. Este hecho provoca problemas a las máquinas de búsqueda, ya que la de cara al usuario basta con que se le ofrezca una de ellas, por lo que indexar el resto únicamente sirve como pérdida de tiempo.

Dado que filtrarlas por comparación directa es imposible, debido al volumen de páginas que se maneja (del orden de billones), se utiliza una técnica denominada *shingling*, que se basa en la búsqueda de grupos iguales de k palabras consecutivas dentro de una página (habitualmente $k = 4$). Si el conjunto de grupos localizados en una página es muy parecido al de otra, se puede concluir que las páginas son casi iguales.

Subsistemas de un motor de búsqueda

Aunque los diversos motores de búsqueda existentes en la Web tienen cada uno su arquitectura y estructura específica, en todos ellos es posible encontrar los siguientes subsistemas:

- **Recolector** (*crawler*), que visita una serie de páginas Web con el objeto de incorporarlas a la colección de páginas conocidas (y por tanto recuperables) por el motor de búsqueda;
- **Indexador** (*indexer*), que convierte la colección en una estructura más manejable y pequeña, llamada Índice;
- **Buscador** (*search engine*), encargado propiamente de recuperar ciertas páginas del índice a partir de la consulta realizada por el usuario.

Tanto el indexador como el buscador son módulos que se pueden encontrar en cualquier sistema de Recuperación de Información, aunque como se ha visto hasta el momento tienen sus peculiaridades debido a su orientación al mundo Internet. El recolector, sin embargo, es un subsistema que nace específicamente para la World Wide Web.

Al contrario que en el caso de las máquinas de Recuperación de Información que atacan a bases de datos documentales, la colección de documentos que maneja un buscador en la Web no está definida, ni disponible en una localización específica, sino que se encuentra diseminada por toda la red, y los contenidos aparecen y desaparecen con relativa frecuencia. Esto obliga a definir un software específico que se encargue de montar la colección de páginas conocidas y, cada cierto tiempo, verifique que los enlaces siguen vivos. Esto es lo que hace el recolector, cuyo funcionamiento redescubre con algo más de detalle en el siguiente punto.

Recolección de páginas Web

La recolección de páginas Web, *Web crawling*, es el proceso mediante el cual los motores de búsqueda recogen páginas de la Web con el propósito de indexarlas. El objetivo de la recolección es la recogida rápida y eficiente de tantas páginas útiles como sea posible, junto con la estructura de enlaces que las interconecta.

Las dos características básicas que debe poseer todo recolector de páginas son las siguientes:

- **Robustez:** existen servidores que generan “trampas de araña”, generadores de páginas Web que engañan a los recolectores para que seleccionen un número infinito de páginas de un dominio, por lo que éstos deben estar diseñados para evitar dichas trampas.
- **Educación:** los servidores Web tienen políticas implícitas y explícitas de la profundidad hasta la cual puede visitarlos un recolector, y éste debe respetarlas.

Además, a la hora de diseñar un recolector hay que tratar de que sea distribuido, escalable, eficiente, y capaz de identificar contenido de calidad.

A la hora de realizar una navegación, el proceso básico seguido por un recolector comienza con un conjunto limitado de URLs. Elige la primera URL y recupera la página Web a la que apunta. El texto de esta página se analiza e incorpora a un indexador, mientras que los enlaces que contiene se añaden a la *frontera de URLs*, que indica aquellas direcciones cuyas páginas todavía no ha visitado el recolector. Este proceso se sofisticará con técnicas especiales que permitan conseguir las características deseables reseñadas anteriormente.

Distribución de índices

Dado que los motores de búsqueda Web aspiran a dar un servicio global, requieren tener múltiples máquinas repartidas por diferentes áreas, encargadas de interpretar consultas y devolver resultados. Estas máquinas necesitan para su funcionamiento tener acceso a los índices que se van generando a partir de las páginas recolectadas. Dado que es imposible mantener un único índice centralizado, los buscadores hacen uso de índices distribuidos.

Existen dos posibles técnicas para realizar la distribución:

- *Particionamiento por términos*, también conocida como organización global de índices.
- *Particionamiento por documentos*, también conocida por organización local de índices.

En la primera, el diccionario de términos índices se divide en varios subconjuntos que residen cada uno en una serie de nodos. Aunque en principio parezca que esto puede permitir mayor concurrencia, ya que consultas a diferentes conjuntos de términos se dirigirían a distintos nodos, en la práctica la mayor parte de las búsquedas requerirían hacer uso de varios conjuntos de términos, lo que obligaría a fusionar resultados y reprocesarlos para dar respuesta a la petición concreta.

Esto hace que el mecanismo habitual de particionamiento sea **por documentos**. En este caso, cada nodo contiene el resultado de la indexación de un subconjunto de las páginas Web recolectadas. Al recibir una consulta, ésta se redirige a todos los nodos y el resultado de varios nodos se fusiona antes de presentarlo al usuario.

Aunque existen diversas estrategias para definir las particiones (por ejemplo, todas las páginas de un servidor, a un mismo nodo, o distribuir las URL según un algoritmo *hash* entre todos los nodos) una de las técnicas más empleadas es el particionamiento de la colección de documentos entre grupos que tienen mayor probabilidad de ser más relevantes para la mayor parte de las consultas, y documentos con baja relevancia. Este último grupo se consultaría cuando en el primero se haya recuperado un número muy escaso de páginas.

Servidores de conectividad

Los motores de búsqueda en la Web requieren, para su funcionamiento, utilizar servidores de conectividad que permitan realizar consultas sobre el grafo de la red. Consultas típicas de conectividad son “¿Qué URL está enlazada con una URL determinada?” o “¿A qué URLs se enlaza una URL dada?”. Debido al gran número de enlaces que ha de manejar (del orden de billones), el grafo de la red se representa en forma de *tabla de adyacencia* similar a los índices invertidos: se define una columna por cada URL (representada por un entero), y cada columna contiene la referencia a las URLs que se conectan a dicha URL. Para reducir el volumen de dicha tabla, se aplican distintas técnicas, como detección de columnas similares, o asignar códigos cercanos para páginas cercanas.

Entre los usos más frecuentes de los servidores de conectividad se puede citar: control de recolección, optimización de la recolección, análisis del grafo de la Web, y categorización de los resultados mediante análisis de enlaces.

Categorización mediante el análisis de enlaces

A la hora de establecer el *ranking* de los resultados para una consulta, uno de los factores utilizados por los buscadores es el análisis de los hipervínculos contenidos por una página o que se refieren a ella.

La idea tras el análisis de los enlaces se deriva del *análisis de citas bibliográficas*, técnica que trata de medir la influencia de los artículos científicos mediante el estudio del patrón de citas establecido entre ellos. Así como citar un artículo le confiere autoridad, en el análisis de enlaces Web se entiende el hipervínculo de una página a otra como una concesión de autoridad a esta última: esta es la base del mecanismo conocido como *PageRank*. Aunque esta visión es simplista en muchos casos, proporciona un dato útil que se considera, junto con otros aspectos, a la hora de ordenar páginas para una consulta específica.

Otro aspecto útil del análisis de los enlaces es el estudio del texto que acompaña al hipervínculo (*anchor texts*) hacia una página concreta, ya puede aportar información interesante sobre la página destino, que puede ser utilizada por los motores de búsqueda. Por ejemplo, la página inicial de un portal Web no suele incluir la palabra “portal”; sin embargo, muchos de los hipervínculos a la misma sí que incluirán en sus *anchor texts* una referencia a esta palabra.

Un aspecto interesante del análisis de páginas Web es su comportamiento como **concentradores** o como **autoridades**. Una página actúa de concentrador cuando incluye referencias a otras páginas (por ejemplo, una página de “enlaces de interés”). Por otra parte, el carácter de autoridad de una página viene conferido por haber sido citada desde otra página. La inclusión en los resultados de una búsqueda no solo de buenas páginas concentradoras sobre un tema, sino también las autoridades a las que apuntan enriquece la respuesta, ya que una página autoridad podría no incluir el término de búsqueda y de otro modo no hubiera sido localizada. Además, esto permite Recuperación Multilingüe, ya que los concentradores apuntan no solo a páginas en su mismo idioma, sino a textos relevantes escritos en otro distinto.

Agentes inteligentes

Existen numerosas técnicas que se han desarrollado específicamente para mejorar la calidad de los resultados presentados al usuario ante una consulta determinada. Sin embargo, la experiencia demuestra que la precisión de los motores de búsqueda tradicionales es baja, y la exhaustividad está relativizada al sector explorado, un fragmento más o menos amplio de la Web.

En los últimos años ha surgido la idea de la utilización de **agentes inteligentes** que rastreen la red según las necesidades informativas del usuario. Aunque no existe un consenso general sobre la definición de los agentes generales, sí parece haberlo en cuanto a sus características básicas: son programas que gozan de *autonomía* (actúan sin supervisión humana), con *inteligencia* (toman decisiones razonadas), *cooperan* con otros agentes para completar la misión encomendada, son capaces de *reaccionar* ante diversos eventos, y son *adaptables* (aprenden de experiencias pasadas).

Una de las tareas obvias que podría ser abordada mediante agentes es la exploración automática de la Web, con el fin de recuperar las páginas relevantes a una necesidad informativa determinada. De esta forma, la formulación de tal necesidad sería parte de las especificaciones iniciales proporcionadas al agente; éste exploraría la red, eligiendo los enlaces más prometedores, accediendo a nuevas páginas, recopilando las que pudiesen satisfacer las especificaciones iniciales, y así sucesivamente. Todo ello de forma muy parecida a como lo hacen manualmente las personas, pero de forma automática.

Este tipo de enfoque tiene dos limitaciones básicas:

- Una búsqueda lanzada mediante un agente inteligente no puede tener una respuesta inmediata, ni siquiera con la rapidez suficiente como para permitir interactividad; antes bien, el usuario delegaría en el

agente la realización de la búsqueda, en espera de que tras un plazo razonable entregue las páginas Web útiles para la necesidad de información expresada.

- La utilización de agentes inteligentes implica, necesariamente, renuncia a la exhaustividad. Resulta im- planteable la exploración global de la Web por parte de estos agentes. Se espera, en contrapartida, que con una exploración muy limitada de la Web alcancen una notable precisión.

No obstante, en contrapartida estos agentes podrían tener la inteligencia necesaria para guiar su navegación no de manera ciega, sino siguiendo los enlaces más prometedores que fueran encontrando, e incluso acceder a la "Internet invisible", es decir, aquella formada no por contenido html estático, sino por contenido generado diná- micamente a través de formularios u otros mecanismos.

8 Técnicas relacionadas con la recuperación de información

Existen diversas técnicas que han surgido al amparo de los estudios realizados sobre Recuperación de Informa- ción. Estas técnicas enfocan sus esfuerzos a áreas concretas, como la identificación de datos dentro de un texto, la extracción de nuevo conocimiento o la identificación de conceptos generales, independientes del idioma. A continuación se comentan en detalle dos de las más importantes, tanto por sí mismas como por ser herramientas empleadas para la construcción de funcionalidades más complejas. Se trata de la **Extracción de Información** y la **Minería de Textos**.

8.1 Extracción de Información (*Information Extraction*)

Dentro de las técnicas de lenguaje natural, la **Extracción de Información** (*Information Extraction*, IE) es un tipo de recuperación de información cuyo objetivo es la extracción automática de información estructurada, es decir, datos categorizados y bien definidos tanto semántica como contextualmente, a partir de textos no estructu- rados. Los datos extraídos pueden ser posteriormente volcados a una base de datos para su procesamiento.

La idea de reducir la información contenida en un texto a una estructura de tabla no es nueva. Las primeras aproximaciones se sugirieron en los años 50, aunque no ha sido hasta la última década cuando ha cobrado rele- vancia gracias a las **Conferencias sobre Comprensión de Mensajes** (*Message Understanding Conferences*, MCU).

La extracción de información no busca la comprensión completa del texto, sino que a la hora de definir la tarea a realizar se limita ya el rango semántico del resultado del proceso.

Existe un interés cada vez mayor en el desarrollo de sistemas capaces de realizar extracción de información, ya que la cantidad de información no estructurada disponible es cada vez más elevada, y las soluciones comercial- mente disponibles sólo son capaces ofrecer la localización de fragmentos de texto más o menos relevantes para una consulta dada. La extracción de información persigue la identificación de datos estructurados con una mayor precisión, que puedan posteriormente ser manipulados y analizados, por ejemplo en formato XML o relacional.

El proceso de extracción de información comprende dos fases principales. En primer lugar, el sistema identifica "hechos" aislados del texto de un documento a partir del análisis de cada frase (análisis local, *local text analysis*). En segundo lugar, se integran estos hechos en un análisis global (*discourse analysis*) para obtener hechos más generales o nuevos hechos, mediante correferencialidad e inferencia. Una vez realizados estos pasos, la informa- ción relevante extraída se estructura en el formato de salida requerido.

Como se puede observar en la siguiente secuencia, es necesario seguir una serie de pasos para estructurar la entrada y posteriormente identificar los patrones o *formularios* (*templates*) deseados en base a dicha estructura- ción.

En el **análisis léxico** el texto se divide en frases y fragmentos (*tokens*). Cada fragmento se contrasta contra un diccionario para determinar sus partes de la oración y posibles características.

A continuación se lleva a cabo la **identificación de nombres** propios, organizaciones, lugares, expresiones temporales y ciertas expresiones numéricas y monetarias. Esta tarea es importante ya que estos elementos apa- recen de forma habitual, y una identificación y clasificación correcta de los mismos simplifica los procesamientos posteriores.

La identificación se lleva a cabo contrastando el elemento contra un conjunto de expresiones regulares que des- criben características sintácticas y ortográficas (como mayúsculas, o prefijos tipo Sra., D., etc.).

La identificación de algunos aspectos de la estructura sintáctica puede simplificar la siguiente fase de identificación de hechos (*facts*). Un **análisis sintáctico** completo es demasiado costoso y difícil, por lo que se suele optar por un análisis limitado a ciertas relaciones gramaticales pertinentes para el escenario de extracción.

La **identificación de hechos** (*scenario pattern matching*) permite la extracción de eventos o relaciones relevantes para la búsqueda especificada. El resultado es un texto etiquetado con referencias a la estructura de evento encontrada.

Una vez realizado el análisis local, es necesario proceder al análisis de los hechos identificados en relación con el texto en su conjunto. El primer paso es el **análisis de coreferencialidad**, encargado de la identificación de distintos pronombres y sintagmas nominales que se refieren a un mismo objeto, y resolución de dichas anáforas.

Los hechos así procesados están preparados para la fase de **inferencia e integración de hechos**. Habitualmente, la información sobre un evento determinado está distribuida a lo largo de varias frases, lo cual obliga a combinar esta información antes de poder rellenar un formulario (*template*). En otros casos, parte de la información se encuentra de manera implícita, y es necesario explicitarla mediante un proceso de inferencia (implementado normalmente mediante sistemas de producción de reglas).

Como se ha comentado previamente, uno de los aspectos inusuales relativos a la extracción de la información es el grado en que su desarrollo en la última década ha sido guiado y moldeado por un mecanismo de evaluación concreto, las Conferencias de Comprensión de Mensajes (MUC). El proceso de evaluación consiste en entregar a los participantes una descripción detallada del escenario objetivo de extracción, junto con una serie de documentos (*training corpus*) y los formularios que deben rellenarse a partir de los mismos. Tras conceder un tiempo (de uno a seis meses) para adaptar el sistema de cada participante al escenario concreto, se entrega un nuevo conjunto de documentos (*test corpus*). Los formularios extraídos de este conjunto se entregan al organizador de la conferencia, quien los coteja contra los formularios respuesta (*answer key*) y los puntúa en función de la precisión y el porcentaje de recuperación (*recall*).


La extracción de información, en la actualidad, se encuentra en fase de desarrollo o limitada a aplicaciones muy concretas. Uno de los mayores problemas a los que se enfrenta para poder convertirse en una tecnología práctica es la dificultad de adaptar un sistema de extracción a un nuevo escenario (**portabilidad**). Hoy en día se requieren varios meses de esfuerzo y personal especializado para cada nueva adaptación, lo cual limita el mercado al que se puede optar. El otro problema que se presenta está referido a la necesidad de **mejorar la calidad** de los resultados obtenidos. La precisión de los mejores sistemas actuales está en torno al 60 y el 70 %, y el porcentaje de recuperación varía sobre el 50 y el 55 %.

8.2 Minería de textos (*Text Mining*)

Ante un texto cualquiera, un lector que preste la suficiente atención será capaz de enlazar diferentes aspectos aparentemente inconexos a partir de los cuáles generar nuevas ideas o hipótesis. Esta tarea, no obstante, requiere su tiempo, y es imposible en la práctica que una sola persona pueda procesar los textos que se publican continuamente en un área de actividad, y menos aún los de áreas relacionadas.

La **Minería de Textos**, también conocida como *Text Mining* e incluso *Text Data Mining*, ofrece una solución a este problema mediante la aplicación de procesos informáticos capaces de derivar **información de alta calidad** a partir de textos no estructurados, con o sin asistencia de un operador humano. Dicha información podría consistir en relaciones o patrones escondidos en el cuerpo documental analizado, y que de otra forma sería extremadamente difícil, sino imposible, de descubrir. La calidad de la información extraída se medirá en términos de relevancia, novedad e interés.

Estas técnicas pueden utilizarse para analizar documentos en lenguaje natural relativos a cualquier disciplina. Como se estima que la mayor parte de la información existente sobre cualquier tema (más de un 80%) se en-



cuentra actualmente almacenada como texto, muchos analistas opinan que la minería de textos tiene un gran valor comercial. Entre otras vías de avance, se le presta cada vez un mayor interés a la minería de textos multi-lingüe: la habilidad de ganar información en otros idiomas.

Los primeros esfuerzos desplegados en este tipo de sistemas surgieron en los años 80, con aplicaciones experimentales que requerían una gran cantidad de esfuerzo humano. Sin embargo han sido los avances tecnológicos de la vuelta del siglo los que han permitido su gran progresión en la última década.

La minería de textos es un área multidisciplinaria basada en la recuperación de información, minería de datos, aprendizaje automático, estadísticas y la lingüística computacional. El proceso de minería de textos habitualmente requiere la ejecución de los siguientes pasos:

1. *Estructuración del texto de entrada*: se aplican técnicas de análisis gramatical, junto con la adición y eliminación de ciertas características lingüísticas para posteriormente insertar el resultado en una base de datos.
2. *Extracción de patrones*
3. *Evaluación e interpretación del resultado*

Para llevar a cabo estas tareas, la minería de textos se apoya en técnicas derivadas de la Recuperación de Información, Procesamiento de Lenguaje Natural, Extracción de Información y finalmente Minería de Datos:

- Con las técnicas de **Recuperación de Información** es posible reducir el conjunto de documentos relevantes a un problema en particular. Dado que la minería de textos implica la utilización de algoritmos con una gran carga de computación, la Recuperación de la Información permite acelerar el análisis al limitar el número de documentos a procesar.
- El **Procesamiento del Lenguaje Natural** (*Natural Language Processing*, NLP) es uno de los campos más antiguos y difíciles en el ámbito de la Inteligencia Artificial, y su objetivo es poder analizar el lenguaje humano de manera que los ordenadores sean capaces de entender los lenguajes naturales igual que las personas. Aunque esto está aún lejos de conseguirse, las técnicas de procesamiento de lenguaje natural pueden realizar cierto tipo de análisis con un alto grado de éxito. Entre ellas cabe destacar la *categorización de palabras* (*part-of-speech tagging*) en tipos como sustantivos, verbos o adjetivos; la *desambiguación de términos* (*word sense disambiguation*), que identifica el significado de una palabra a partir del contexto en que se encuentra; o el *análisis gramatical* (*parsing*) de textos.

El papel del Procesamiento del Lenguaje Natural en la minería de textos es proporcionar al sistema los datos lingüísticos necesarios para el procesamiento posterior del documento por herramientas de Extracción de Información.

- A partir de un documento en el cual se han resaltado sus características lingüísticas es posible aplicar técnicas de **Extracción de Información** para rellenar un formulario que permita alimentar una base de datos.
- La **Minería de Datos** (*Data Mining*, DM) también conocida por Descubrimiento de Conocimiento (*Knowledge Discovery*) se refiere al proceso que permite identificar patrones ocultos en conjuntos voluminosos de datos. El objetivo es el descubrimiento de nuevo conocimiento útil. En su aplicación a la minería de textos, la minería de datos se utiliza sobre la base de datos que se ha alimentado con los hechos identificados en la fase de Extracción de Información.
- Finalmente, los resultados de la Minería de Datos se pueden volcar en otra base de datos preparada para ser explotada por el usuario final a través de un interfaz gráfico apropiado. Los datos obtenidos de las consultas sobre dicha base podrían asimismo representarse visualmente.

Aparte del procesamiento de documentos para la extracción de nuevo conocimiento, las técnicas de minería de textos se aplican en la actualidad a diversas actividades, como la categorización de textos, extracción de conceptos (*Concept Mining*), creación de taxonomías, análisis de sentimientos (*Sentiment Analysis*, interpretación de la actitud de un individuo hacia un tema a partir de sus escritos o locuciones), resumen de documentos, y creación de modelos entidad-relación (descubrimiento de relaciones entre entidades identificadas en el proceso de Extracción de Información).

9 Conclusiones

Aunque es una disciplina con una larga trayectoria, el crecimiento espectacular de Internet ha proporcionado un nuevo auge a la Recuperación de Información. Dado que la inmensa colección de documentos contenidos en la

Web carece por completo de organización, la automatización de los procesos de análisis y recuperación de esos billones de documentos se ha convertido en una tarea de importancia capital.

Los programas que rastrean la Web en busca de páginas y los programas que efectúan el proceso de análisis y tratamiento de tales páginas con el objeto de poder recuperarlas ante las consultas de los usuarios, además de muchos otros programas con un objetivo semejante en cualquier ámbito (desde las bibliotecas hasta el comercio electrónico), se siguen basando en los tres modelos clásicos de recuperación de información creados entre los años sesenta y ochenta del siglo XX: los modelos booleano, vectorial y probabilístico. El fenómeno más destacado actualmente en estos sistemas de recuperación de información consiste en el empleo simultáneo de características y algoritmos propios de cada uno de estos modelos: así, lo más frecuente es que los buscadores de Internet se basen en el modelo booleano, pero efectúen la ordenación de los documentos de las respuestas empleando criterios de similitud originarios del modelo vectorial clásico. De igual modo, cada vez emplean en mayor medida una u otra variante de la retroalimentación por relevancia para aumentar la precisión de la respuesta, técnica empleada en sus inicios por el modelo probabilístico.

En consecuencia, con la popularización de Internet han cobrado nuevo auge los modelos clásicos de recuperación de información y sus variantes, tratando de aunar en un mismo programa de recuperación las ventajas primordiales de cada uno de ellos. Hoy en día hay abiertas múltiples líneas de investigación, todas ellas muy activas, que tratan de mejorar la precisión y exhaustividad de los sistemas, pero tratando ahora de incorporar el usuario real y su punto de vista subjetivo en la evaluación de los resultados obtenidos.

Pese a todos los avances experimentados por las técnicas de recuperación de información y disciplinas asociadas, existen todavía múltiples cuestiones que hay que solventar.

En primer lugar, a pesar del alto grado de interactividad conseguido, los usuarios siguen teniendo dificultades para obtener información relevante a sus necesidades. La Web requiere del desarrollo de técnicas que consigan resultados de las búsquedas de mayor calidad.

En segundo lugar, no basta con que las búsquedas tengan mayor calidad, sino que además se necesita que el tiempo de respuesta sea lo menor posible.

En tercer lugar, hay que mejorar el modo de interacción con el usuario, de manera que sea posible incorporar nuevas herramientas que simplifiquen o incluso eliminen la necesidad de traducir la necesidad de información de lenguaje natural a un lenguaje de búsqueda más o menos abstracto. Incluso ser capaces de estudiar el comportamiento del usuario (gustos, hábitos de búsqueda, etc.) para individualizar los mecanismos de asignación de relevancia en base a ese conocimiento.

Políticas, procedimientos y métodos para la conservación de la información en soporte electrónico

1. Introducción

Antes de entrar en materia y con el objetivo de meternos en contexto, lo primero que debemos conocer es la diferencia entre información y datos.

Según la RAE, un dato es el antecedente necesario para llegar al conocimiento exacto de algo o para deducir las consecuencias legítimas de un hecho. Es decir, el dato en sí mismo no tiene ningún significado sino que referencia un atributo o una representación simbólica (alfabética, gráfica, numérica, etc.) como resultado de una observación y requiere su tratamiento o procesamiento para que suministre información que pueda ser utilizada

Por otro lado, se define información como un conjunto organizado de datos con algún significado acerca de un hecho, evento o suceso, que al ser procesados o evaluados mejoran el conocimiento acerca de algo. Es decir, la información tiene un significado preciso y diferente al de los datos y por tanto un valor en la toma de decisiones, mientras que los datos no lo tienen.

¿Por qué es importante aclarar esta diferencia? A lo largo del desarrollo de este tema vamos a ver los mecanismos, procedimientos, normativa, etc. necesarios para la conservación de la información en soporte electrónico, pero no debemos olvidar que dicha información parte de unos datos originales y que, para conseguir su conservación, será necesario que tanto los datos, como todo lo necesario para manejarlos, estén disponibles.

1.1. Antecedentes

La información es uno de los activos más importante de cualquier organización. Esto es así en la actualidad y lo ha sido siempre. Sin embargo, gracias a los avances tecnológicos, la situación ha cambiado mucho. La llegada de Internet ha facilitado que la información sea mucho más accesible y más sencilla de obtener. Por otro lado, la mejora de la tecnología ofrece posibilidades de tratamiento, conservación y acceso que hace unos años eran impensables. Esto ha provocado que los volúmenes de información que se manejan actualmente hayan crecido de forma considerable y que el formato haya cambiado.

Este hecho, que sin duda es muy positivo, hace que aumente de forma exponencial la dependencia de las organizaciones respecto a dicha información y que nadie pueda permitirse el lujo de perderla o manejar información no confiable, ya que en la mayoría de los casos eso supondría la imposibilidad de continuar desarrollando la actividad que se venía desempeñando.

Además, parte de la información que manejan las organizaciones es más sensible que otras, bien por contener datos personales o por contener información estratégica para el negocio (información de clientes, proveedores, referencias de propiedad intelectual, etc.). Por este motivo, es imprescindible llevar a cabo una adecuada gestión de la información que se maneja, con el objetivo de protegerla y así asegurar tanto la continuidad de la actividad como el cumplimiento de los requisitos legales de aplicación.

Según se define en la norma internacional ISO 27001, la seguridad de la información es la preservación de la confidencialidad, la integridad y la disponibilidad de la información, pudiendo además abarcar otras propiedades como la autenticidad, la fiabilidad y el no repudio.



Estos aspectos se verán más en detalle en los temas relacionados con la seguridad, pero no debemos perderlos de vista en el tema que nos compete, la conservación de la información.

1.2. Situación en la Administración

Hasta hace unos años, la mayor parte de la información de las organizaciones se manejaba en papel, pero como ya se ha comentado previamente, la llegada de la tecnología ha facilitado su tratamiento y conservación en formato electrónico. Este cambio a nivel tecnológico lleva también implícito un cambio en la forma de trabajo de la organización.

La Administración no es una excepción, sino más bien un ejemplo de cómo se está realizando dicho cambio, ya que desde hace unos años se está trabajando en la construcción de la *Administración Electrónica*.

La *Administración Electrónica* ha supuesto no solo la mejora tecnológica y organizativa de la Administración, sino que también ha llevado consigo el desarrollo de nueva normativa y la apertura de una nueva vía de relación con el ciudadano.

El impulso definitivo de esta nueva forma de relación con el ciudadano vino de la mano de la aprobación de la *Ley 11/2007 de Acceso Electrónico de los Ciudadanos a los Servicios Públicos*, que se comentará más adelante. Esta ley reconoce el derecho de los ciudadanos a relacionarse con las Administraciones Públicas por medios electrónicos y regula los aspectos básicos de la utilización de las tecnologías de la información en la actividad administrativa, en las relaciones entre las Administraciones Públicas, así como en las relaciones de los ciudadanos con las mismas con la finalidad de garantizar sus derechos, un tratamiento común ante ellas y la validez y eficacia de la actividad administrativa en condiciones de seguridad jurídica.

La ley 11/2007 ha sido derogada por la ley 39/2015, del Procedimiento Administrativo Común de las Administraciones Públicas.

Pero previo a la publicación de la Ley 11/2007, el CSAE (Consejo Superior de Administración Electrónica) ya había detectado la necesidad de establecer unos criterios para manejar la información en el ámbito administrativo. El fruto de ese esfuerzo se plasmó en los *Criterios para la Seguridad, Normalización y Conservación de la información* (Criterios SNC), que nos van a servir como un punto de apoyo importante, aunque no el único, para la elaboración de este tema.

Estos criterios tienen un triple objetivo:

- Proporcionar el conjunto de medidas organizativas y técnicas (seguridad, normalización, conservación) que garanticen el cumplimiento de los requisitos legales para la validez y eficacia de los procedimientos administrativos de la Administración General del Estado, que utilicen los medios electrónicos, informáticos y telemáticos en el ejercicio de sus potestades.
- Facilitar la adopción generalizada por parte de la Administración General del Estado de medidas organizativas y técnicas que aseguren la protección proporcionada a los riesgos de los sistemas y aplicaciones que la manejan.
- Promover el máximo aprovechamiento de las tecnologías de la información y las comunicaciones en la actividad administrativa y asegurar a la vez el respeto de las garantías y derechos de los ciudadanos en sus relaciones con la Administración.

En concreto, el apartado '*Criterios de conservación*' expone los requisitos, criterios y recomendaciones para la conservación de la información en soporte electrónico, haciendo hincapié en que la conservación de la información no debe considerarse de forma aislada, sino que, junto con la utilización y acceso a la información, es una etapa más del ciclo de vida de la misma en soporte electrónico.

Los Criterios de conservación se estructuran en los siguientes puntos:

Criterios de conservación

CONSERVACIÓN DE LA INFORMACIÓN EN SOPORTE ELECTRÓNICO

Documentos administrativos y de los ciudadanos
Almacenamiento de la información en soporte electrónico
Análisis y gestión de riesgos

CICLO DE VIDA DE LA INFORMACIÓN EN SOPORTE ELECTRÓNICO

Ciclo de vida
Análisis del documento electrónico
Diseño de la estrategia de gestión
Creación de la información en soporte electrónico
Gestión de la información en soporte electrónico
Traspaso de la información al archivo
Acceso y difusión a la información de soporte electrónico

FORMATO DE LA INFORMACIÓN EN SOPORTE ELECTRÓNICO

Tipos de formatos de ficheros Juego de caracteres

SOPORTES

Tipos de soportes de almacenamiento de la información

MEDIDAS DE ALMACENAMIENTO Y CONSERVACIÓN

Reescritura de los archivos en soporte electrónico
Protección contra el deterioro físico
Seguridad de la información
Programas y aplicaciones de fuente abierta

SISTEMA DE ARCHIVOS

Archivo de oficina, Archivo central, Archivo intermedio, Archivo histórico

A lo largo del tema se va a intentar dar una visión general de lo que supone la conservación de la información en soporte electrónico que implicarán cambios a tres niveles:

0

- Normativo
- De carácter técnico
- Organizativos

0



2. Aspectos normativos

Como ya se ha visto en la introducción, los Criterios SNC persiguen 3 objetivos entre los que cabe destacar:

- ...el cumplimiento de los requisitos legales para la validez y eficacia de los procedimientos administrativos de la Administración General del Estado, que utilicen los medios electrónicos, informáticos y telemáticos en el ejercicio de sus potestades.
- ...asegurar a la vez el respeto de las garantías y derechos de los ciudadanos en sus relaciones con la Administración.

Aparte de la Ley 39/2015, del Procedimiento Administrativo Común de las Administraciones Públicas, que incide directamente en la conservación de la información, existe un marco legal completo de administración electrónica que va mucho allá de esta ley, incluyendo otras cuestiones como la protección de los datos personales, la legislación en torno al uso de firmas electrónicas, etc.

Dada la envergadura y complejidad de la suma de estas cuestiones es imposible abarcarlas en este tema, pero sí se pretende esbozar, al menos, un pequeño mapa básico de las normas legales más importantes que tienen impacto directo a la hora de definir los aspectos técnicos y organizativos para la conservación de la información.

2.1. Normativa general aplicable a la conservación de la información

2.1.1. Legislación previa a la Ley 39/2015

La parte legal regulada por los reales decretos y la orden ministerial que se indican a continuación, son los antecedentes a la situación actual de la Administración Electrónica y tienen por tanto importancia en el tema que estamos tratando.

Real Decreto 263/1996, de 16 de febrero, por el que se regula la utilización de técnicas electrónicas, informáticas y telemáticas por la Administración General del Estado. Vigente hasta el 19 de noviembre de 2009, fecha de entrada en vigor del **Real Decreto 1671/2009**, de 6 de noviembre, por el que se desarrolla parcialmente la Ley 11/2007, de 22 de junio, de acceso electrónico de los ciudadanos a los servicios públicos. (BOE. núm. 278, de 18 de noviembre de 2009).

Real Decreto 209/2003, de 21 de febrero, por el que se regulan los registros y las notificaciones telemáticas, así como la utilización de medios telemáticos para la sustitución de la aportación de certificados por los ciudadanos.

Orden PRE/1551/2003, de 10 de junio, por la que se desarrolla la Disposición final primera del Real Decreto 209/2003, de 21 de febrero, por el que se regulan los registros y las notificaciones telemáticas, así como la utilización de medios telemáticos para la sustitución de la aportación de certificados por los ciudadanos. Derogada por la disposición derogatoria única de la **Orden PRE/878/2010**, de 5 de abril, por la que se establece el régimen del sistema de dirección electrónica habilitada previsto en el artículo 38.2 del R.D. 1671/2009, de 6 de noviembre («B.O.E.» 12 abril), el 13 de abril de 2010.

En esta normativa se regulaban, y en algunos casos aún regulan, cuestiones como los **Registros telemáticos, Notificaciones telemáticas y Certificaciones electrónicas**, aunque algunos de estos conceptos se han redefinido en la LAECSP que veremos a continuación.

La Ley 11/2007 de acceso electrónico de los ciudadanos a los servicios públicos (LAECSP), junto con la **Ley 59/2003 de firma electrónica**, son algunas de las normativas reguladoras que mayor impacto han tenido en la conservación de la información en formato electrónico. Marcan la pauta en cuan-

to a la validez de los documentos electrónicos, de las copias electrónicas de documentos en papel, de las copias electrónicas, y de todo lo que conduce a la administración sin papeles.

La LAECSP da un nuevo giro de tuerca a los registros telemáticos. Pasa de denominarles de esa forma a hacerlo como registros electrónicos, y se refiere a ellos para asignarles dos modos de funcionamiento. El primero es el mismo que se establecía en el RD 209/2003, destinándolos exclusivamente para los procedimientos publicados explícitamente en las órdenes ministeriales de creación o modificación. Pero en el segundo los extiende para admitir cualquier solicitud, tal y como ahora ocurre con los registros presenciales.

2.1.2. Ley 39/2015, del Procedimiento Administrativo Común de las Administraciones Públicas

Extraemos los puntos más relevantes para el tema que nos compete:

Artículo 17. *Archivo de documentos.*

[...]

Artículo 26. *Emisión de documentos por las Administraciones Públicas*

[...]

Artículo 27. *Validez y eficacia de las copias realizadas por las Administraciones Públicas.*

[...]

Artículo 70. *Expediente administrativo.*

1. *Se entiende por expediente administrativo el conjunto ordenado de documentos y actuaciones que sirven de antecedente y fundamento a la resolución administrativa, así como las diligencias encaminadas a ejecutarla.*

2. *Los expedientes tendrán formato electrónico y se formarán mediante la agregación ordenada de cuantos documentos, pruebas, dictámenes, informes, acuerdos, notificaciones y demás diligencias deban integrarlos, así como un índice numerado de todos los documentos que contenga cuando se remita. Asimismo, deberá constar en el expediente copia electrónica certificada de la resolución adoptada.*

3. *Cuando en virtud de una norma sea preciso remitir el expediente electrónico, se hará de acuerdo con lo previsto en el Esquema Nacional de Interoperabilidad y en las correspondientes Normas Técnicas de Interoperabilidad, y se enviará completo, foliado, autenticado y acompañado de un índice, asimismo autenticado, de los documentos que contenga. La autenticación del citado índice garantizará la integridad e inmutabilidad del expediente electrónico generado desde el momento de su firma y permitirá su recuperación siempre que sea preciso, siendo admisible que un mismo documento forme parte de distintos expedientes electrónicos.*

4. *No formará parte del expediente administrativo la información que tenga carácter auxiliar o de apoyo, como la contenida en aplicaciones, ficheros y bases de datos informáticas, notas, borradores, opiniones, resúmenes, comunicaciones e informes internos o entre órganos o entidades administrativas, así como los juicios de valor emitidos por las Administraciones Públicas, salvo que se trate de informes, preceptivos y facultativos, solicitados antes de la resolución administrativa que ponga fin al procedimiento.*

2.1.3. Real Decreto 1671/2009, de 6 de noviembre, por el que se desarrolla parcialmente la Ley 11/2007

El presente real decreto tiene por objeto desarrollar la LAECSP, en lo relativo a la transmisión de datos, sedes electrónicas y punto de acceso general, identificación y autenticación, registros electrónicos, comunicaciones y notificaciones y documentos electrónicos y copias.

En el Título VI, se regulan todos los aspectos relacionados con los documentos electrónicos y sus copias. Se indican algunos de los puntos más relevantes que deberán ser tenidos en cuenta al definir los aspectos técnicos y organizativos de la conservación de la información en soporte electrónico:

CAPÍTULO I: Disposiciones comunes sobre los documentos electrónicos

Artículo 41. Características del documento electrónico

1. Los documentos electrónicos deberán cumplir los siguientes requisitos para su validez:

- a) Contener información de cualquier naturaleza.*
- b) Estar archivada la información en un soporte electrónico según un formato determinado y susceptible de identificación y tratamiento diferenciado.*
- c) Disponer de los datos de identificación que permitan su individualización, sin perjuicio de su posible incorporación a un expediente electrónico.*

[...]

Artículo 42. Adición de metadatos a los documentos electrónicos

1. Se entiende como metadato, a los efectos de este real decreto, cualquier tipo de información en forma electrónica asociada a los documentos electrónicos, de carácter instrumental e independiente de su contenido, destinada al conocimiento inmediato y automatizable de alguna de sus características, con la finalidad de garantizar la disponibilidad, el acceso, la conservación y la interoperabilidad del propio documento.

[...]

4. Los metadatos mínimos obligatorios asociados a los documentos electrónicos, así como la asociación de los datos de firma o de referencia temporal de los mismos, se especificarán en el Esquema Nacional de Interoperabilidad.

[...]

Artículo 43. Copias electrónicas de los documentos electrónicos realizadas por la Administración General del Estado y sus organismos públicos

[...]

Artículo 44. Copias electrónicas de documentos en soporte no electrónico

[...]

CAPÍTULO V: Archivo electrónico de documentos

Artículo 51. Archivo electrónico de documentos

1. La Administración General del Estado y sus organismos públicos vinculados o dependientes deberán conservar en soporte electrónico todos los documentos electrónicos utilizados en actuaciones administrativas, que formen parte de un expediente administrativo, así como aquellos otros que, tengan valor probatorio de las relaciones entre los ciudadanos y la Administración.

2. La conservación de los documentos electrónicos podrá realizarse bien de forma unitaria, o mediante la inclusión de su información en bases de datos siempre que, en este último caso, contengan los criterios para la reconstrucción de los formularios o modelos electrónicos origen de los documentos, así como para la comprobación de la firma electrónica de dichos datos.

Artículo 52. Conservación de documentos electrónicos

1. Los períodos mínimos de conservación de los documentos electrónicos se determinarán por cada órgano administrativo de acuerdo con el procedimiento administrativo de que se trate, siendo en todo caso de aplicación, con la excepción regulada de la destrucción de documentos en papel copiados electrónicamente, las normas generales sobre conservación del patrimonio documental con valor histórico y sobre eliminación de documentos de la Administración General del Estado y sus organismos públicos.

2. Para preservar la conservación, el acceso y la legibilidad de los documentos electrónicos archivados, podrán realizarse operaciones de conversión, de acuerdo con las normas sobre copiado de dichos documentos contenidas en el presente real decreto.

3. Los responsables de los archivos electrónicos promoverán el copiado auténtico con cambio de formato de los documentos y expedientes del archivo tan pronto como el formato de los mismos deje de figurar entre los admitidos en la gestión pública por el Esquema Nacional de Interoperabilidad.

CAPÍTULO VI: Expediente electrónico

[...]

2.1.4. La Ley Orgánica 15/1999, de Protección de Datos Personales

La Ley Orgánica 15/1999, de 13 de diciembre, de Protección de Datos de Carácter Personal, (LOPD), sustituye a la anterior Ley Orgánica de Tratamiento Automatizado de Datos (LORTAD), precursora en este aspecto. Tiene por objeto garantizar y proteger, en lo que concierne al tratamiento de los datos personales, las libertades públicas y los derechos fundamentales de las personas físicas, y especialmente el derecho de las personas a su honor, intimidad y privacidad personal y familiar, que es uno de los derechos fundamentales que recoge la Constitución española.

Su objetivo principal es regular el tratamiento de los datos y ficheros, de carácter personal, independientemente del soporte en el cual sean tratados, los derechos de los ciudadanos sobre ellos y las obligaciones de aquellos que los crean o tratan. Como curiosidad, reseñar que la LORTAD era de aplicación exclusivamente a los ficheros automatizados de datos, mientras que la que está actualmente en vigor es aplicable a cualquier tipo de fichero, independientemente del soporte en el que esos datos estén almacenados, lo que nos da una indicación del alto nivel de integración de los procedimientos automatizados en la realidad del funcionamiento administrativo cotidiano.

La ley regula derechos como el de información en la recogida de los datos, la necesidad de consentimiento para su tratamiento o el derecho a su rectificación y cancelación en cualquier momento. Se define la categoría de datos especialmente protegidos (datos sobre ideología, afiliación sindical, religión, creencias, origen racial, salud y vida sexual) que gozan de un nivel de protección especialmente reforzado.

2.1.5. El Reglamento de Desarrollo de la Ley Orgánica 15/1999, Real Decreto 1720/2007

El Real Decreto 1720/2007 de desarrollo de la Ley Orgánica 15/1999, sustituye al Real Decreto 994/1999, de medidas de seguridad de los ficheros automatizados que contengan datos personales. En este caso también hay que destacar que a diferencia del anterior, regula además medidas aplicables a los ficheros en papel.

Uno de los puntos principales es la clasificación en tres niveles la información de carácter personal que manejan las entidades en función de la naturaleza de los datos.

El reglamento indica de manera más específica cual es el procedimiento a seguir en materia de seguridad y conservación para los datos en función de su nivel de clasificación (Título VIII).

En dicho título, relativas a la conservación, se establecen medidas para gestionar los soportes de información y documentos, el tiempo que debe guardarse dicha información y la gestión de copias de respaldo y recuperación. Según el nivel de clasificación aplicable a los datos, el reglamento define medidas de seguridad concretas cuyo grado de exigencia crece conforme lo hace el nivel de clasificación.

2.1.6. El Esquema Nacional de Seguridad, Real Decreto 3/2010

Tal y como se indica en el artículo 42 de la Ley 11/2007, en enero del 2010 fueron publicados el Esquema Nacional de Seguridad (ENS) y el Esquema Nacional de Interoperabilidad (ENI).

El Real Decreto 3/2010, de 8 de enero, por el que se regula el Esquema Nacional de Seguridad en el ámbito de la administración electrónica, tiene como objeto establecer la política de seguridad en la utilización de medios electrónicos y está constituido por principios básicos y requisitos mínimos que permitan una protección adecuada de la información.

Cuenta con una serie de precedentes que han inspirado su contenido, documentos de la Administración en materia de seguridad electrónica, tales como los Criterios SNC, las Guías CCN-STIC del Centro Criptológico Nacional, la Metodología de análisis y gestión de riesgos MAGERIT o el Esquema Nacional de Interoperabilidad.

Tiene en cuenta las recomendaciones de la Unión Europea, la situación tecnológica de las diferentes Administraciones Públicas, así como los servicios electrónicos ya existentes y la utilización de estándares abiertos así como, en su caso y de forma complementaria, estándares que sean de uso generalizado por los ciudadanos.

2.1.7. El Esquema Nacional de Interoperabilidad, Real Decreto 4/2010

El Real Decreto 4/2010, de 8 de enero, por el que se regula el Esquema Nacional de Interoperabilidad en el ámbito de la administración electrónica, persigue la creación de las condiciones necesarias para garantizar el adecuado nivel de interoperabilidad técnica, semántica y organizativa de los sistemas y aplicaciones empleados por las Administraciones Públicas, que permita el ejercicio de derechos y el cumplimiento de deberes a través del acceso electrónico a los servicios públicos, a la vez que redunde en beneficio de la eficacia y la eficiencia.

Al igual que ocurre en el ENS, se han tenido en cuenta antecedentes como los Criterios SNC y las recomendaciones de la Unión Europea como lo es el Marco Europeo de Interoperabilidad elaborado por el programa IDABC, así como a otros instrumentos y actuaciones elaborados por este programa y que inciden en alguno de los múltiples aspectos de la interoperabilidad. También se atiende a la Decisión 922/2009 del Parlamento Europeo y del Consejo, de 16 de septiembre de 2009, relativa a las soluciones de interoperabilidad para las administraciones públicas europeas.

En la parte técnica se desarrolla el principio de neutralidad tecnológica de la Ley 11/2007 en aspectos concretos como los documentos electrónicos emitidos por las Administraciones Públicas y se reitera su importancia haciendo hincapié en el uso de estándares abiertos a todos los niveles considerando su aplicación particularmente inexcusable en la relación con los ciudadanos.

Se trata también un aspecto clave relacionado con este tema como es la recuperación y conservación del documento electrónico. En primer lugar, se establecen las condiciones para la recuperación conservación del documento electrónico que prevén, entre otras, cosas como la definición de una política de gestión de documentos por parte de las Administraciones públicas, la identificación única e inequívoca de cada documento o la clasificación de acuerdo con un plan de clasificación.

A continuación se establecen medidas de seguridad para asegurar la conservación de los documentos electrónicos, se reitera la obligación de la adecuada protección de los datos personales y se prevé el uso de formatos de firma longeva y otros mecanismos como metadatos de gestión de documentos que permitan la conservación a largo plazo de los documentos electrónicos.

Por otra parte, se aborda la cuestión del formato de los documentos electrónicos. Se prevén aspectos como el uso preferentemente de formatos basados en estándares abiertos y la elección de formatos de documento electrónico normalizados y perdurables que aseguren la independencia de los datos de sus soportes. Incluso se prevé la posibilidad de copiado auténtico de los documentos ante un posible riesgo de obsolescencia del formato.

Por último se trata la digitalización de documentos en soporte papel indicando que ésta se deberá ajustar a la norma técnica de interoperabilidad correspondiente a los aspectos del formato estándar utilizado, el nivel de resolución, la garantía de imagen fiel e íntegra y los metadatos asociados al proceso de digitalización.

2.1.8. La Ley 59/2003, de Firma Electrónica

La Ley 59/2003, de Firma Electrónica incorpora al derecho español la normativa legal europea en materia de firma electrónica, concretamente la Directiva 1999/93/CE por la que se establece un marco comunitario para la firma electrónica. La ley regula fundamentalmente las siguientes cuestiones: el concepto de firma electrónica, los certificados electrónicos, los prestadores de servicios de certificación, los dispositivos de creación de firma y de verificación de firma, el régimen de supervisión y control, y el régimen de infracciones y sanciones.

La Ley define tres tipos de firma electrónica (firma electrónica, firma electrónica avanzada y firma electrónica reconocida) y se matizan aspectos importantes del uso de la firma electrónica en el ámbito de las Administraciones Públicas.

La regulación del uso de la firma electrónica es la que va a permitir el desarrollo de la Administración Electrónica y la que va a posibilitar que muchos trámites puedan realizarse por vía telemática.

En este aspecto, la parte que más afecta al tema que estamos tratando, que sería la conservación de la información relativa a los certificados digitales, es de suma importancia no por la información final en sí, que se podrá tratar en este aspecto de una forma similar a la que haya llegado por otras vías, si no por los aspectos derivados de la propia naturaleza de los certificados digitales.

Estos tienen un periodo de validez limitado, que entre aquellos más populares oscila entre los dos y los cuatro años. Sin embargo, los documentos que se firman con ellos en muchos casos tendrán una vigencia mucho mayor, como pueden ser contratos, escrituras de propiedades, facturas electrónicas, etc. Hay que asegurar entonces que esos documentos sigan accesibles, y que las firmas puedan continuar verificándose a lo largo de toda su vida útil.

Por otra parte, destacar los artículos 3.5 y 3.8, introducidos como modificaciones a través de la Ley 56/2007, de Medidas de Impulso de la Sociedad de la Información, donde se aclara el concepto de documento electrónico y aspectos relevantes respecto de la admisión de datos firmados electrónicamente como prueba documental en juicio.

2.2. Normativa específica (legislación médica, judicial, hacienda pública, etc.)

Además de la normativa citada hasta ahora, aplicable con carácter general, existe otra de carácter específico para determinados ámbitos. Mostramos a continuación algunos ejemplos.

Ley 41/2002, de 14 de noviembre, básica **reguladora de la autonomía del paciente y de derechos y obligaciones en materia de información y documentación clínica**. En su título V trata sobre la historia clínica. Además de ceñirse a la LOPD, los artículos 14, Definición y archivo de la historia clínica, 17, La conservación de la documentación clínica, y 19, Derechos relacionados con la custodia de la historia clínica, abordan temas relacionados con la conservación de la historia clínica, y de cuestiones relativas a la confidencialidad y a los derechos de acceso. Concretamente establece la obligación de conservar los datos de historia clínica al menos durante cinco años desde que se originaron, ampliándolo al que sea necesario en cada caso.

Ley 25/2007, de 18 de octubre, de **conservación de datos relativos a las comunicaciones electrónicas y a las redes públicas de comunicaciones**. En el capítulo II de conservación y cesión de datos se pone de manifiesto la obligación a los operadores que presten servicios de comunicaciones a conservar los datos de comunicaciones realizadas (art. 4); el periodo de conservación (art. 5) que se establece hasta 12 meses después de producirse con carácter general, si bien puede haber excepciones que los restrinjan sólo a seis meses o que lo amplíen hasta dos años; y la protección y seguridad de los datos (art. 8).

Se indica en su preámbulo que "La naturaleza neutra de los avances tecnológicos en telefonía y comunicaciones electrónicas no impide que su uso pueda derivarse hacia la consecución de fines indeseados, cuando no delictivos.

Precisamente en el marco de este último objetivo se encuadra la **Directiva 2006/24/CE**, del Parlamento Europeo y del Consejo, de 15 de marzo, sobre la conservación de datos generados o tratados en relación con la prestación de servicios de comunicaciones electrónicas de acceso público o de redes públicas de comunicaciones, y por la que se modifica la Directiva 2002/58/CE, del Parlamento Europeo y del Consejo, de 12 de julio, cuya transposición a nuestro ordenamiento jurídico es el objetivo principal de esta Ley." (Ley 25/2007)

La extensa **ley 58/2003 General Tributaria**, de 18 de diciembre, se refiere en varios de sus apartados a la conservación de determinada información, y también hace referencia a la aplicación de las TIC en sus procedimientos.

Orden PRE/2971/2007, de 5 de octubre, sobre la expedición de facturas por medios electrónicos cuando el destinatario de las mismas sea la Administración General del Estado u organismos públicos vinculados o dependientes de aquélla y sobre la presentación ante la Administración General del Estado o sus organismos públicos vinculados o dependientes de facturas expedidas entre particulares. El objeto de la orden es el establecimiento de unos estándares y condiciones técnicas uniformes en la emisión y remisión de facturas. Extiende a toda la AGE la normativa que ya se venía aplicando en la administración tributaria, y que está recogida en www.facturae.es.

Ley 25/2013, de 27 de diciembre, de **impulso de la factura electrónica y creación del registro contable de facturas** en el Sector Público. Esta ley regula en el artículo 4 la obligatoriedad de uso de factura electrónica en el sector público, que entrará en vigor el 15 de enero de 2015, en el artículo 5 el formato de las facturas electrónicas y su firma electrónica, y en el artículo 7 el archivo y custodia de la información.

2.3. Estándares

En este punto se incluyen algunos ejemplos de los estándares que aplican a la conservación de la información en formato electrónico, pero no son los únicos ni se va a entrar al detalle de los mismos.

- ISO/TR 15801:2004: recomendaciones para la veracidad y fiabilidad de información almacenada electrónicamente
- ISO/TR 18492:2005: conservación a largo plazo de información electrónica basada en documentos
- ISO/NP 26102: Requisitos para la conservación a largo plazo de documentos electrónicos
- ISO 19005-1:2005: PDF/A-1 Formato de archivo de documentos electrónicos para conservación a largo plazo

3. Criterios de conservación de la información

La conservación de la información no debe considerarse de forma aislada. Junto con la utilización y acceso a la información, es una etapa más del ciclo de vida de la misma en soporte electrónico.

La gestión de dispositivos, soportes electrónicos y formatos debe ponerse en práctica aplicando procedimientos orientados a la manipulación de datos sensibles, especialmente si son de carácter personal; a la salvaguarda frente a deterioro, daño, robo o acceso no autorizado; a la eliminación o destrucción de soportes; a la gestión de los soportes removibles, etc.

En cualquier caso ha de tenerse en cuenta que la aplicación de las medidas de conservación expuestas en el tema debe realizarse atendiendo, en general, al principio de proporcionalidad que se establece entre la naturaleza de los datos y los tratamientos, los riesgos a los que estén expuestos y el estado de la tecnología, y, en particular, a las medidas exigidas en relación con la normativa vigente (por ejemplo la protección de los datos de carácter personal).

3.1. Análisis de riesgos

La conservación de los documentos en soporte electrónico tiene lugar en un entorno complejo y no exento de riesgos. En primer lugar, la evolución continua de la tecnología hace que sea difícil la selección de soportes y formatos estables y duraderos, por algunos de los siguientes motivos:

- ☐ Aparición constante de nuevas versiones de plataformas, sistemas operativos y programas.
- Introducción de cambios en las características físicas de los soportes (tamaños, densidad de grabación, etc.).
- Algunos soportes pueden tener una mayor vida útil, como objeto físico, pero pueden estar sometidos a una rápida obsolescencia tecnológica.
- ...

La adopción de medidas organizativas y técnicas para la conservación de la información se debe realizar de forma acorde y proporcionada a los riesgos detectados. El proceso de análisis y gestión de riesgos constituye la principal tarea primera ya que permite conocer de manera rigurosa el estado de seguridad y determinar la valoración del riesgo. Es adecuado en las fases y actividades de carácter general (implicación de la dirección, objetivos, políticas) y en las de carácter específico (planificación, organización, implantación de salvaguardas, sensibilización, acción diaria y mantenimiento).

El análisis y gestión de riesgos debe ayudar a formular y responder preguntas claves, como las siguientes:

- ¿Qué información se ha de conservar y proteger?, ¿de qué tipo es? y ¿cuál es su valor?
- ¿De qué tipo es?
- ¿Cuáles son los plazos de conservación?
- ¿En qué soportes y formatos está?
- ¿Qué problemas de durabilidad, longevidad y degradación se plantean?
- ¿Quién tiene acceso, a qué, para qué, cuándo y cómo?
- ¿Qué amenazas afectan a la información?
- ¿Cuáles son las consecuencias si se materializan?
- ¿Qué medidas organizativas y técnicas se deben adoptar?

3.2. Ciclo de vida de la información

Para la conservación de la información en soporte electrónico, es necesario tener en cuenta todo el ciclo de vida de la misma, desde su creación, hasta su conservación, o en su caso destrucción, pasando por las etapas de mantenimiento y gestión. Sólo así se puede adoptar un conjunto coherente de normas y estándares que permita dar respuesta a los requisitos de seguridad y conservación.

La información, al igual que otras cosas, tiene un ciclo de vida en el que pasa por diferentes estados: Recolección o generación, almacenamiento, acceso, disposición y uso.



- **Fase 1: Generación.** Todos los datos que se crean, generan o almacenan se deben identificar y categorizar. Esta clasificación permite conocer con qué datos se cuenta, qué tratamiento darles, dónde almacenarlos, qué jerarquía tienen, cuál es su volumen, cuáles pueden ser eliminados y cómo recuperarlos de nuevo cuando sea necesario volver a trabajar con ellos. Cuando se trata de datos de carácter personal, en esta clasificación es necesario establecer los niveles de seguridad básico, medio o alto, definidos en el reglamento de desarrollo de la LOPD.
- **Fase 2: Almacenamiento.** Inicialmente se deben establecer los requisitos y necesidades de almacenamiento de información de la organización que posteriormente deben alinearse con las opciones de almacenamiento disponible.
- **Fase 3: Acceso.** Una vez almacenada, la información debe estar accesible. Se pueden establecer diferentes privilegios de acceso en función de la criticidad de la misma.
- **Fase 4: Disposición.** La información ha de ser almacenada de manera segura y estar disponible para los usuarios cuando estos la necesiten. La información también debe ser mantenida y utilizada de tal forma que su integridad no se vea comprometida. Hay dos factores principales para asegurar la disponibilidad de la información:
 - *Aseguramiento de la integridad.* Se deberán aplicar mecanismos que proporcionen integridad a la información almacenada, como puede ser aplicar privilegios a cada usuario para acceder únicamente a la información que puede manipular, restricciones de actualización de datos, sistemas redundantes, etc.
 - *Copias de Seguridad.* Son la garantía frente a cualquier fallo en el sistema o pérdida de la información. Estas se pueden hacer de manera planificada o puntual y la frecuencia con que se realizan va a depender de la importancia de la información almacenada y lo crítica que puede ser para las estrategias de la empresa.
- **Fase 5: Uso.** El uso o utilización se lleva a cabo después de que la información esté almacenada, accesible y disponible y puede servir de soporte a la toma de decisiones en las organizaciones, generar acciones o servir a otros fines.
- **Fase 6: Conservación o destrucción.** La información puede ser destruida, cuando deja de generar valor para la empresa, o pasar al archivo histórico cuando debe ser

conservada pero su uso no va variar y solo se requiera para consulta de forma poco frecuente.

Durante todo este tiempo la información se transforma, partiendo de una serie de datos y añadiendo a los mismos unas determinadas formas de proceso, relacionándolos con otros datos, cambiando su formato, transmitiéndolos a otros sistemas, y en cada uno de estos estados quedando almacenada para su consulta y/o modificación.

Cuando la información se encuentra en este proceso decimos que está viva, está siendo utilizada, cambia en función de operaciones y de datos externos, y tiene que ser utilizada por el hardware y el software que maneja los datos correspondientes.

3.3. Almacenamiento de la información

La información se guarda en diferentes dispositivos de almacenamiento de datos, en función de su ciclo de vida y de su valor, teniendo en cuenta que no toda la información es igual de crítica y, por lo tanto, no puede ser tratada de la misma manera.

Para establecer el grado de criticidad de la información se realiza una ponderación en función de parámetros como su uso, antigüedad, valor estratégico, etc. Partiendo de esta definición, se establecerá el nivel de accesibilidad y de disponibilidad requeridos para cada activo de información.

Para conseguir información vamos a tener que partir de unos datos, y estos son la parte más crítica y que tenemos que conservar a toda costa, independientemente de que además unos sean más importantes que otros.

Hay otros datos que nos van a permitir convertir y utilizar los anteriores, y que son los programas, configuración de los mismos o incluso metadatos que nos van a dar la posibilidad de procesar, elaborar, cambiar el formato y transmitir los primeros. En cualquier caso, se supone que si perdiéramos este otro tipo de datos seríamos capaces de volver a regenerarlos de forma más o menos costosa, ya que este tipo de información suele ser más constante en el tiempo, y la fuente de la que proviene suele ser estable (un fabricante, mis propios departamentos, en definitiva, un profesional de la materia).

En función de la criticidad y del tiempo que podamos estar sin realizar esas operaciones tendremos que emplear mayor cantidad de recursos en conservar también esa información. Y, por último, y aunque no sean datos, la parte física, ordenadores, sistemas de almacenamiento, proceso y transmisión contribuyen a transformar los datos en información. Como en el caso anterior, tendremos que dedicar más o menos recursos a conservar estos equipos en función de la criticidad de la necesidad de datos que tengamos y de la facilidad de su reposición en caso de urgencia.

En este capítulo nos vamos a encargar de los datos de usuario, aunque al resto de datos software se les podría dar un tratamiento similar si se considera oportuno.

3.4. Soportes

Los soportes en los que se van a almacenar los datos son un punto que no debe quedar al margen de este tema, ya que desde el punto de vista físico hay que tener en cuenta la posible degradación que se pueda producir y que eventualmente puede llegar a impedir el acceso a los datos, o lo que es lo mismo, provocar su pérdida. Los elementos clave en relación con la conservación de los soportes son la accesibilidad, la legibilidad, la perdurabilidad y la preservación de la autenticidad.

El ejemplo más claro es el del papel, que con el paso del tiempo puede hacer invisible su contenido. Esa pérdida puede también ser producida por las (malas) condiciones de almacenamiento y/o accidentes (humedad, fuego, humo, etc.). El resto de soportes también pueden verse afectados por alteraciones en su entorno o frente a determinadas condiciones ambientales.

A la hora de seleccionar el soporte se deben tener en cuenta los siguientes aspectos y características de algunos soportes:

.

- *Los soportes de almacenamiento magnético* utilizados habitualmente como *backup*, a corto, medio e incluso largo plazo, sólo permiten un acceso secuencial a la información y aunque pueden llegar a tener una capacidad significativa de almacenamiento, se debe tener en cuenta que pueden ser modificados o borrados.
- *El almacenamiento magnético de tipo “storage”* necesita *backup* e igualmente puede ser modificado o borrado.
- *Los soportes de almacenamiento óptico* de tipo única escritura múltiple lectura, no son modificables, por tanto permiten satisfacer requisitos de archivo, constituyen un soporte longevo a medio y largo plazo, tienen gran capacidad de almacenamiento y permiten el acceso directo a la información.
- El *microfilm* no permite modificaciones y la búsqueda de la información resulta complicada. Se ha de tener en cuenta que dependiendo de la calidad del material utilizado pueden surgir incertidumbres sobre su duración a largo plazo.

3.5. Formatos

Como hemos comentado, en los ficheros almacenamos datos, y normalmente son los sistemas de procesamiento los que convierten esos datos en información, relacionándola con otra, mostrándolos en un determinado formato visual o seleccionando sólo lo que nos interesa de un conjunto mucho mayor.

Pero los sistemas cambian y evolucionan, así como los formatos que se utilizan para almacenar y recuperar los datos. Y en este sentido, sobre todo si hablamos de casos en los que se van a almacenar durante largo tiempo, hay que tener en cuenta que, si queremos recuperarlos, tendremos que hacerlo con el sistema original con el que los guardamos, o con algún otro que sea capaz de leer lo que el primero almacenó. Es fundamental en este aspecto migrar los datos cuando se migren los sistemas, y en todo caso buscar un formato de almacenamiento estándar y abierto para que el mayor número de sistemas posibles sean capaz de interpretar lo que tenemos guardado.

Utilizar formatos estándar y libres, usar software libre y facilitar la accesibilidad a este tipo de programas. Todo ello minimiza la dependencia de formatos propietarios y evita que en un momento dado un único proveedor limite la posibilidad de continuar accediendo a la información con normalidad.

Para los ficheros de texto, se recomienda utilizar formatos que conserven la estructura del fichero, puesto que con estructura el fichero es independiente del equipo y de fácil manejo, mientras que sin estructura el fichero es una secuencia de caracteres difícil de manejar.

Utilizar aquellos formatos de datos y programas para los que en la medida se disponga de especificaciones públicas y libres de *royalties* y patentes.

Para ficheros gráficos, lo más recomendable es utilizar un formato cuya relación calidad-pérdida de información sea menos relevante en relación con el mayor grado de compresión obtenido.

Como formato de conservación a largo plazo de los documentos electrónicos se recomienda la utilización del PDF/A.

3.6. Seguridad física y lógica de la información

Siempre hablamos de seguridad en términos de confidencialidad, integridad y disponibilidad de la información. Estos conceptos son difícilmente separables del de conservación, puesto que su finalidad es muy similar, el de mantener la información para que sea utilizada en el momento preciso.

Mediante procedimientos de seguridad, los soportes y dispositivos de almacenamiento se controlan y protegen contra daño, robo, acceso no autorizado, revelación de contenido y mal uso. Los criterios de conservación de soportes, su custodia y accesibilidad, están incluidos en los planes de seguridad y contingencia.

Se debe, por lo tanto, desarrollar y aplicar procedimientos de seguridad que contemplen la autenticidad, confidencialidad, integridad y disponibilidad, el tratamiento de datos de carácter personal, la gestión de soportes removibles, la eliminación y destrucción de soportes y la documentación del sistema de conservación.

También hay que tener en cuenta que se deben aplicar procedimientos en relación con las siguientes cuestiones: biblioteca de soportes, gestión de soportes removibles, manipulación de datos de datos de carácter personal y eliminación de soportes.

En el apartado de legislación hemos visto una serie de normas que implican la implantación de diferentes medidas técnicas y organizativas para garantizar la seguridad de la información: los Criterios SNC, el RD 1720/2007 de desarrollo de la LOPD, el ENS, etc. La seguridad es un tema con una entidad propia y no podemos tratarlo aquí con profundidad, pero a la hora de conservar la información, deberemos tener en cuenta dichas directrices que nos orientan para conseguir unos sistemas TIC suficientemente seguros.

3.7. Sistema de archivos

Igual que la información, la documentación administrativa sigue un proceso con distintas etapas de ciclo de vida, en cada una de las cuales el documento cumple unas funciones específicas y recibe un tratamiento diferente.

El Sistema de Archivos de la Administración define cuatro tipos distintos de archivo que se diferencian entre sí por las funciones específicas que les corresponden:

- Archivo oficina
- Archivo central
- Archivo intermedio
- Archivo histórico

Cada archivo afecta a determinados actores y, en ellos, los requisitos de conservación de la información pueden influir tanto a soportes como a formatos.

4. Medidas organizativas y técnicas de la conservación de la información

Para poder mantener de un modo seguro y eficaz los sistemas de almacenamiento es importante que la organización especifique cuáles son las medidas y las políticas que deben seguir los usuarios para evitar que aumente la capacidad de los mismos de modo desordenado y la consiguiente falta de control o pérdida de información. Así, se identifican varias acciones necesarias en la organización, para que sean conocidas por los propios usuarios y controladas por los responsables:

- Medidas de salvaguarda y recuperación de datos
- Medidas de replicación de la información
- Política de copias de seguridad.
- Política de borrado seguro de la información
- Plan de contingencias

4.1. Salvaguarda y recuperación de datos

Como ya se ha indicado en puntos anteriores, de nada serviría tener la infraestructura (servidores, comunicaciones, aplicaciones, etc.) completamente replicada y disponible si no mantuviésemos la capacidad de acceder a los datos. Toda la infraestructura sería incapaz de proporcionar el servicio si faltasen los datos, que constituyen la esencia de los sistemas de información.

Para mantener los datos disponibles se utilizan las mismas técnicas que para mantener los servidores y las aplicaciones disponibles: por un lado se construyen los dispositivos y sistemas de almacenamiento con la calidad suficiente para garantizar un tiempo de fallo mínimo; y para obtener la máxima disponibilidad que un sistema de almacenamiento puede proporcionar, se hace uso de la redundancia en la forma de replicación de la información.

Todo ello, al igual que en el caso de servidores y aplicaciones, acompañado por los procedimientos adecuados para determinar cuándo deben realizarse las copias y cuando debe hacerse uso de una u otra copia.

Los métodos de recuperación de datos se definen como aquellos procesos llevados a cabo con el objetivo de restablecer el acceso a la información que sigue estando almacenada en los dispositivos, pero que no está disponible por alguna causa. Los métodos de recuperación de datos se agrupan en 2 principales:

- **Métodos de recuperación lógica.** Se utilizan cuando todos los componentes del dispositivo funcionan correctamente y por tanto se puede acceder a todos y cada uno de los sectores donde se almacena la información. La recuperación lógica de datos consiste en analizar la estructura de archivos que permanece, identificar el daño producido y acceder a los datos que aún están en el dispositivo.
- **Métodos de recuperación física.** Si algún componente físico del dispositivo se encuentra dañado, pero el soporte de almacenamiento sigue inalterado, se podrá abordar una recuperación física reparando o sustituyendo el componente dañado y accediendo nuevamente a la información guardada.

4.2. Replicación de la información

Los sistemas de almacenamiento, especialmente los basados en disco, realizan una replicación interna de la información, de forma que se aumenta la disponibilidad del dato en caso de fallo de algún dispositivo.

Los sistemas de almacenamiento basados en disco tienen internamente estructuras RAID (Redundant Array of Independent Disks), en los que la información se reparte entre distintos discos físicos, de forma que ante el fallo de uno de ellos el sistema puede seguir funcionando, la información almacenada en el disco fallido puede ser reconstruida y el disco sustituido por uno nuevo.

Existen multitud de esquemas RAID (descritos en el tema correspondiente), cada uno con sus características específicas y su campo de aplicación más adecuado, pero todos se basan en la introducción de redundancia en la información (mediante duplicación, códigos de control de errores, de paridad, etc.) y la distribución de la misma en distintos dispositivos, de forma que pueda tolerarse el fallo de uno de ellos y recuperar la información perdida a partir de la contenida en el resto.

Los sistemas basados en cintas o dispositivos ópticos también pueden contener mecanismos internos de duplicación de la información contenida en los discos o cintas.

Las cabinas de discos, robots de cintas, etc., además de duplicar la información tienen redundancia a nivel de fuentes de alimentación, conectividad, etc., pero en cualquier caso no dejan de ser sistemas individuales susceptibles de ser redundados como un todo, replicando todos los datos que contienen en otros sistemas distintos.

En función de las características de los sistemas de almacenamiento, frecuencia, etc., podemos diferenciar varios tipos de replicación.

4.2.1. Replicación continua (copia en tiempo real)

Utilizando sistemas de almacenamiento de alta gama, capacidades adicionales de las redes de almacenamiento o aplicaciones específicas ejecutándose en los servidores es posible realizar una réplica de los datos en tiempo real en un sistema de almacenamiento distinto al utilizado para almacenar la copia original de los datos.

De esta forma, cada vez que un dato es almacenado o modificado en un sistema de almacenamiento, este mismo dato es transmitido al dispositivo remoto, en el que se realiza la misma operación que en el original, manteniendo en todo momento una réplica de los datos en dos sistemas de almacenamiento distintos.

Al contrario que en el caso de la redundancia de servidores, en el caso de réplica de datos entre dispositivos de almacenamiento no es posible el “balanceo de carga”. El sistema remoto al que se copian los datos no puede estar en general accesible a los servidores mientras el sistema original esté en funcionamiento. Solo pasaría a poder prestar servicio en caso de fallo del principal o en caso de suspender los mecanismos de copia.

Existen dos modalidades de copia en tiempo real, la copia síncrona y la copia asíncrona.

- En la **copia síncrona** el servidor inicia una escritura en el sistema de almacenamiento y no recibe la confirmación de la escritura hasta que esta no se ha realizado tanto en el sistema principal como en el de respaldo. De esta forma la latencia de las comunicaciones se suma a la de los dispositivos de almacenamiento, ya que de cara al servidor el tiempo de respuesta del sistema de almacenamiento será la suma del tiempo que tarda la información en llegar al dispositivo remoto, el tiempo que tarda en escribirse en el dispositivo remoto y el tiempo que tarda en llegar de vuelta la confirmación de la escritura.

En función de la velocidad de transmisión del medio de comunicaciones utilizado y de la tolerancia a la latencia de la aplicación, existirá un límite de distancia a partir del cual la replicación perjudicará el rendimiento de la aplicación.

- Para poder superar ese límite de distancia entre el sistema principal y el de respaldo se puede hacer uso de **copia asíncrona**. En este tipo de copia el servidor recibe la confirmación de la escritura en cuanto el sistema principal la ha realizado. La información se manda al sistema principal y al de respaldo, pero no se espera la respuesta del sistema de respaldo, por lo que la latencia de la línea no afecta al rendimiento de la aplicación. Como contrapartida, en el caso de fallo en el sistema de almacenamiento principal, no se tendrá la certeza de que las últimas escrituras realizadas hubiesen llegado

al sistema de respaldo. Para evitar la pérdida de datos, los sistemas de copia asíncrona son capaces de situar el sistema remoto en un punto de consistencia anterior al fallo del sistema principal, de forma que aunque se pierdan las escrituras que se estaban realizando en el momento del fallo, el sistema es capaz de recuperar toda la información ya consolidada.

4.2.2. Replicación discreta (backups)

La replicación en tiempo real hace que se disponga en todo momento de la misma información en ambos sistemas de almacenamiento, pero esto por sí solo no garantiza la integridad de la información, ya que al estar duplicada en todo instante, si se produjese una corrupción de la información, un borrado accidental, etc., esta situación se trasladaría automáticamente al sistema de respaldo, perdiendo los datos precisamente por mantener en ambos sistemas los mismos datos.

Además, los sistemas de réplica en tiempo real no permiten en general recuperar la información que existía en momentos anteriores, no siendo posible “retroceder” en el tiempo hasta un punto que se sepa consistente.

Todo esto, junto con el hecho de que la réplica en tiempo real requiere comunicaciones con ancho de banda suficiente y sistemas de almacenamiento, redes o software en servidores con dicha capacidad y el consiguiente coste asociado, hace que en los centros de proceso de datos se utilice además replicación discreta, en la que se replica la información mantenida en los sistemas de información en un momento concreto del tiempo. Esta réplica puede tener la forma de copias instantáneas en disco o de backups de seguridad realizados a disco o a cinta.

Mediante este tipo de réplica se conserva una imagen del estado de los datos en un momento determinado en un soporte distinto del que mantiene los datos que usan las aplicaciones (por ejemplo en cintas). De esta forma es posible mantener múltiples copias de los datos en distintos instantes de tiempo (por ejemplo, mantener un backup del estado del sistema de todas las noches por un periodo de un mes) siendo posible restaurar el sistema con la misma información que existía en uno de dichos instantes en el caso de ser necesario.

Además, en el caso de realizar los backups en dispositivos extraíbles (cintas, discos ópticos, etc.) es posible extraer los soportes y trasladarlos a centros remotos para poder hacer frente a desastres locales sin necesidad de disponer de líneas de comunicaciones de gran ancho de banda entre los centros principales y los centros remotos de respaldo.

4.2.3. Replicación de CPDs (Centros de Proceso de Datos), centros de respaldo

Con los mecanismos expuestos en los apartados anteriores es posible garantizar la disponibilidad del servicio frente a multitud de fallos, al tener redundados los servidores, los sistemas de comunicaciones, de almacenamiento, los propios datos, la alimentación eléctrica, etc., pero no podría hacerse frente a un desastre de gran magnitud (natural o provocado) que inhabilitara completamente un centro de datos.

Para hacer frente a terremotos, inundaciones, atentados terroristas, etc., es necesario replicar todo el centro de datos en centros de respaldo remotos, situados a la distancia necesaria para hacer frente a la magnitud del desastre que se pretenda evitar.

Actualmente, debido a la gran importancia de los sistemas de información, la tendencia es alejar cada vez más los centros de respaldo, llegando a plantearse distancias intercontinentales en los casos más avanzados.

El principal elemento que hay que replicar entre los centros son los propios datos, haciendo uso de las técnicas de replicación en tiempo real, síncrona o asíncrona en función de las distancias a cubrir. En caso de desastre, los servidores, comunicaciones, etc., que no estén redundados podrían comprarse o construirse de nuevo (con pérdida de servicio mientras esto ocurre) pero los datos que se hubiesen perdido no podrían ser recuperados nunca si no estuviesen redundados en el centro de respaldo.

Una vez replicados los datos es necesario replicar los servidores y las aplicaciones, sin olvidar los mecanismos de comunicación de los clientes con el centro de proceso de datos, que deberán poder configurarse para que los clientes accedan al centro de respaldo de forma transparente.

Al igual que existen distintas tipologías de cluster de servidores, existen distintas modalidades de centros de respaldo, siendo la más sencilla aquella en el que los datos están replicados en el centro de respaldo pero los servidores del centro de respaldo no prestan servicio, siendo necesaria su activación manual en el caso de desastre del centro principal.

El siguiente paso hacia un esquema de centros activo-activo es el de un centro de respaldo que no presta servicio pero en el que las aplicaciones están preparadas para hacerse cargo de la producción y se realizan cambios manuales programados en la actividad de los centros, pasando el que era de respaldo a ser el principal y viceversa. En general es recomendable realizar este tipo de cambios de forma periódica (por ejemplo, cada mes) para garantizar el correcto funcionamiento de ambos centros, ya que en el esquema anterior en el que el centro de respaldo solo da servicio en caso de fallo es muy probable que en el momento del desastre haya algún elemento (servidor, aplicación, configuración, etc.) que no haya sido correctamente replicado y el sistema no funcione. Al realizar cambios de rol programados esos fallos pueden detectarse en situaciones en las que el otro centro es funcional y es posible dar "marcha atrás" al cambio, seguir prestando el servicio en el mismo centro en el que se estaba haciendo hasta el momento y corregir el error.

Otra posibilidad, más compleja que la anterior, es mantener ambos centros en funcionamiento, diferenciando entre aplicaciones, siendo uno de ellos el centro principal para una serie de aplicaciones y el de respaldo para otras y teniendo el otro centro el rol complementario. En este esquema se reparte la carga de trabajo entre ambos centros, no teniendo toda la capacidad de proceso del centro de respaldo inutilizada. En caso de desastre el servicio se seguiría prestando aunque con menor capacidad de proceso.

Finalmente, si las aplicaciones lo permitiesen, podrían constituirse cluster distribuidos, en los que todos los centros serían principales, prestando servicio todos simultáneamente de forma coordinada. Al igual que en el caso de cluster "locales", este tipo de configuraciones requiere que tanto los sistemas operativos como las aplicaciones sean capaces de trabajar en configuraciones activo-activo.

A medida que nos acercamos a una configuración activo-activo las exigencias en cuanto a las aplicaciones, configuraciones y sobre todo en lo relativo a los procedimientos de trabajo son mayores, ofreciendo en contrapartida mayores prestaciones.

Actualmente la tendencia es a la constitución de más de dos centros de proceso de datos, siendo factible configuraciones de tres o más centros de datos, replicando los datos y las aplicaciones a todos ellos.

En cualquier caso, la complejidad de replicación de un centro de datos completo hace que se trate de proyectos complicados y costosos, que no son resueltos por ningún producto en concreto, sino por la combinación de muchos de ellos y un diseño detallado tanto de la arquitectura como de los procedimientos asociados a la operación del sistema.

4.3. Política de copias de seguridad

Una copia de seguridad o backup, es un duplicado que se realiza sobre ficheros o aplicaciones contenidas en un ordenador con la finalidad de recuperar los datos en el caso de que el sistema de información sufra daños o pérdidas accidentales de los datos almacenados. Todo plan de contingencia de una empresa requiere contar con una planificación adecuada de las copias de seguridad que se realizan, ya que la pérdida de datos puede poner en peligro la continuidad del negocio.

Algunos de los requisitos que debe cumplir la planificación de copias de seguridad son:

- **Identificar los datos que requieren ser preservados.** Aquellos cuya pérdida afectaría a la continuidad del negocio.
- **Establecer la frecuencia con la que se van a realizar los procesos de copia.** Esta frecuencia influye en la cantidad de información que se puede perder con respecto a la fuente original. Este parámetro es de suma importancia y requiere de un análisis exhaustivo. Por ejemplo, si se realiza una copia cada noche y el soporte se estropea a las 12h toda la información generada desde la noche anterior hasta las 12h no se encontrará en la copia de seguridad.

- **Disponer el almacén físico para las copias.** Este almacén se determina en función de la seguridad que requiere la información entre almacenes en el mismo edificio o remotos en edificios externos. Por ejemplo, si se produce un incendio en el edificio de la empresa, la información almacenada en un edificio externo sigue estando disponible.
- **Buscar una probabilidad de error mínima,** asegurándose que los datos son copiados íntegramente del original y en unos soportes fiables y en buen estado. No se deben utilizar soportes que estén cerca de cumplir su vida útil para evitar que fallen cuando vaya a recuperarse la información que contienen.
- **Controlar los soportes que contienen las copias,** guardándolos en un lugar seguro y restringiendo su acceso sólo a las personas autorizadas.
- **Planificar la restauración de las copias:** Formando a los técnicos encargados de realizarlas.
 - Disponiendo de soportes para restaurar la copia, diferentes de los de producción.
 - Estableciendo los medios para disponer de dicha copia en el menor tiempo posible.
- **Probar el sistema de forma exhaustiva** para comprobar su correcta planificación y la eficacia de los medios dispuestos.
- **Definir la vigencia de las copias,** estableciendo un periodo en el que dicha copia deja de tener validez y puede sustituirse por una copia más actualizada de la información.
- **Controlar la obsolescencia de los dispositivos de almacenamiento.** Para el caso de aquellas copias que almacenan información histórica de la organización, por ejemplo, proyectos ya cerrados, se debe tener en cuenta el tipo de dispositivo en el que se ha realizado la copia, para evitar que en el momento que se requiera la restauración de dicha información no existan ya lectores adecuados para dicho dispositivo.
Cuando se desechen los soportes de almacenamiento, porque hayan llegado al límite de vida útil fijado en la política de copias de seguridad, es importante realizar un proceso de borrado seguro o destrucción para asegurar que la información que contiene no podrá ser recuperada posteriormente.

4.4. Políticas de borrado seguro de la información

Toda organización debe contar con una política de borrado seguro de la información de los dispositivos de almacenamiento con los que trabaja, que contenga al menos los siguientes elementos:

- **Gestión de soportes adecuada:** Realizar un seguimiento de los dispositivos que están en funcionamiento, las personas o departamentos responsables, la información contenida en ellos y su clasificación en función del grado de criticidad para el negocio.
 - Llevar a cabo la supervisión de los dispositivos que almacenan las copias de seguridad de los datos.
 - Controlar cualquier operación realizada sobre un dispositivo: mantenimiento, reparación, sustitución, etc.
 - En los traslados de los dispositivos de almacenamiento a instalaciones externas a las de la empresa, asegurar que se cumple la cadena de custodia de los mismos, para evitar fugas de información.

- **Documentación de las operaciones de borrado realizadas:** Al seleccionar una herramienta de borrado, elegir aquella que permita la obtención de un documento que identifique claramente que el proceso de borrado se ha realizado, detallando cuándo y cómo ha sido realizado.

En el caso de que la destrucción lógica no se realice correctamente por fallo del dispositivo, este hecho debe documentarse claramente y utilizar métodos de destrucción física de dicho soporte, asegurando que se realice de forma respetuosa con el medio ambiente.

4.5. Plan de contingencias

Como ya se ha visto, la complejidad asociada a un escenario en el que se pretende mantener el servicio ante fallos o catástrofes es grande, por lo que para tener ciertas garantías de éxito es necesario que todos los procedimientos se encuentren documentados y difundidos en la organización.

El plan de contingencias es el procedimiento detallado mediante el cual la organización debe hacer frente a los desastres.

Debe partir de un análisis de los riesgos a los que se pretende hacer frente, determinando la influencia que cada uno de ellos pueda tener en el servicio prestado y proponiendo las medidas correctoras más adecuadas. Deberá tenerse en cuenta las interrelaciones entre las distintas aplicaciones, su importancia relativa para la organización, etc., con el fin de organizar temporalmente las acciones de la forma más adecuada. Así mismo debe tenerse en cuenta los objetivos a alcanzar, ya que lógicamente no será lo mismo pretender restaurar el servicio en un intervalo de horas y pretender continuar dando servicio de forma transparente a los usuarios en un intervalo de segundos.

El plan de contingencia debe contener las medidas técnicas, relativas a los mecanismos de redundancia de aplicaciones, servidores o datos, procedimiento de conmutación de unos sistemas a otros o de un centro a otro, así como los procedimientos de marcha atrás una vez solventada la incidencia.

Pero tan importante como las medidas técnicas son las medidas organizativas, ya que al fin y al cabo son las personas las que deben llevar a cabo todas esas acciones técnicas y de nada serviría tener un centro de respaldo con todos los servidores si no se dispone de personal para operarlo o si no está claramente definido el rol de cada empleado en el caso de tener que hacer frente a una incidencia, ya que el tiempo necesario para coordinar a los recursos humanos sería muy probablemente superior al tiempo tolerable de indisponibilidad de servicio.

Según los criterios SNC del CSAE, el plan de contingencias puede consistir en los siguientes apartados:

- Objetivos.
- Criterios para invocar el plan de contingencias.
- Vida del plan de contingencias.
- Papeles y responsabilidades de los distintos actores.
- Procedimientos para invocar la situación de contingencia.
- Procedimientos para operar la situación de contingencia.
- Planificación de recursos cuando se opera en situación de contingencia.
- Criterios para el retorno a explotación normal.
- Procedimientos para el retorno a explotación normal.
- Procedimientos de recuperación de datos perdidos/dañados.
- Coste del plan de contingencias.
- Tratamiento del plan después de la contingencia.

4.6. Custodia de la información

Para finalizar, debemos comentar la existencia de la custodia de información. La custodia de documentos es un paso más en la gestión documental e implica la existencia de un tercero que se responsabiliza de archivar, con garantías técnicas y legales, los documentos de otras organizaciones.

El servicio de custodia de información se basa en el almacenamiento de documentos, tanto firmados digitalmente y/o cifrados como sin firmar y/o cifrar y garantizando que el documento custodiado mantiene a lo largo del tiempo el mismo valor legal.

Para mantener la validez legal en el tiempo se define, en función de los diferentes plazos de custodia (corto, medio y largo plazo), la tecnología y los soportes a utilizar, así como los formatos aceptados y su mantenimiento. Además se incorpora un sellado de tiempo en los documentos firmados que asegura el momento de realización de la firma y la validez del certificado con el que se realizó la misma.

Estos servicios de custodia de la información van a ser cada vez más demandados, ya que aportan transparencia ante la gestión a lo largo de largos periodos de tiempo de los sucesivos certificados digitales que puede haber tenido una persona, del momento en que se firmaron los documentos y el certificado que estaba en vigor en ese momento y de la recuperación de documentos firmados con certificados ya caducados.

En este sentido, y como ejemplo, podemos citar la Orden Ministerial EHA/962/2007 de 10 de abril, sobre facturación electrónica y conservación electrónica de facturas, donde básicamente se habla de la necesidad de conservar las facturas electrónicas en el soporte y formato originales, tanto por parte del emisor como del receptor, aunque también deben ser exportables a un formato estándar.

Además, se manejan los conceptos de copia electrónica y digitalización certificada, y que aporta las garantías necesarias al proceso de paso de papel a soporte electrónico.

Contratos de compraventa, escrituras públicas y privadas, facturas, informes médicos, éstos y otros documentos se emiten y manejan cada vez en mayor medida en formato electrónico. Por tanto es imprescindible que tengan garantizada su validez legal, y tener asegurado su almacenamiento y recuperación.

La forma de conseguirlo es combinar las técnicas de certificación electrónica con las de conservación de la información que hemos visto en este tema.