




Sistemas de Big Data

El nuevo paradigma de los datos masivos

Jordi Casas Roma
Carles Garrigues Olivella

Índice

1. Contextualización
2. Definición de Big Data
3. El Big Data en escenarios de *Business Intelligence*

Índice

1. Contextualización
2. Definición de Big Data
3. El Big Data en escenarios de *Business Intelligence*

Antecedentes (I)

¿Qué inició la revolución de los datos masivos?

- Principios s. XXI...
 - El proyecto *Sloan Digital Sky Survey*
 - El proyecto del genoma humano
- Después...
 - Internet, redes sociales, etc
 - IoT (*Internet Of Things*)

Antecedentes (II)

¿Qué inició la revolución de los datos masivos?

■ Problemas en las empresas de Internet

1. Gran cantidad de datos acumulados hacía inviable su procesamiento en un único ordenador
2. Heterogeneidad de datos. Necesidad de insertar, consultar y procesar datos en diferentes estructuras
3. Necesidad de procesar rápidamente los datos
 - Ejemplo: *queries* del buscador web

El paradigma del Big Data

Causalidad

- Hipótesis
- Muestra aleatoria




- ¿Verificación?

“¿Por qué?”

Correlación

- Toda la población



- Correlación entre variables

“¿Qué?”

Índice

1. Contextualización
2. Definición de Big Data
3. El Big Data en escenarios de *Business Intelligence*

Definición de Big Data (I)

En el 2001, el analista **Doug Laney** de META Group (ahora **Gartner**) utilizaba y definía el término **Big Data** como:

*“el conjunto de **técnicas** y **tecnologías** para el **tratamiento** de datos, en entornos de gran **volumen**, **variedad** de orígenes y en los que la **velocidad** de respuesta es crítica”.*

Definición de Big Data (II)

Podemos definir el término Big Data como:

- Conjunto de **técnicas** y **tecnologías** para
 - el **tratamiento** y **almacenamiento** de datos, en entornos de
 - gran **volumen**,
 - **variedad** de orígenes
 - y en los que la **velocidad** de respuesta es crítica

3 V's del Big Data

Volumen

- Crecimiento **exponencial de datos**
- Gigabytes → Terabytes de información diaria

3 V's del Big Data

Velocidad

- Tiempo de respuesta crítico
 - P.ej. sistemas de tránsito
- Procesado en **tiempo (casi) real**
- Consideramos dos tipos de velocidad:
 - Velocidad de **carga** (procesos ETL)
 - Velocidad de **procesamiento**

3 V's del Big Data

Variedad

- Diferentes **formatos y estructuras** de los datos
 - Orígenes de datos **estructurados**
 - Bases de datos, hojas de cálculo o ficheros CSV
 - Orígenes de datos **semiestructurados**
 - Documentos XML o páginas web
 - Orígenes de datos **no estructurados**
 - Documentos de texto, audio, imágenes o vídeo

4 V's del Big Data

Veracidad

- IBM introdujo una **cuarta V**
- La gran cantidad de datos y la diversidad de orígenes provoca que la **veracidad** debe ser considerada
- 2 tipos:
 - Exactitud del dato
 - Exactitud del cálculo

¡No hay unanimidad sobre esta 4ª V!

Índice

1. Contextualización
2. Definición de Big Data
3. El Big Data en escenarios de *Business Intelligence*

Escenarios de Big Data

¿Cuándo aplicar una solución BI basada en Big Data?

Si existe un gran volumen de datos, alta velocidad de generación de datos o necesidad de tratar todo tipo de datos. **No es necesario que se cumplan las 3 condiciones.**


¿Puede Big Data aplicarse en cualquier proyecto BI?

Big data puede utilizarse en cualquier escenario para analizar información obtenido de diferentes sistemas de información. Hay que tener en cuenta el incremento de complejidad y coste respecto a una solución BI tradicional.

BI tradicional + Big Data

Una solución Big Data debe utilizarse como **complemento** a un sistema BI tradicional.

- Big Data: obtención y análisis de datos basada en 3V's.
- BI tradicional: obtención y análisis de datos no 3V's.



Fuente: "Big Data". Àlex Caminals Sánchez de la Campa - FUOC

Diferencias: BI tradicional y Big Data

Naturaleza de los datos

- Volumen, Variedad y Velocidad.

Granularidad

- BI tradicional datos almacenados en el DW en su mínima granularidad.
- Big Data datos almacenados en el DW son derivados o filtrados.

Tecnología

- Hadoop + base de datos NoSQL
- SGBDR + herramienta BI



Sistemas de Big Data

El nuevo paradigma de los datos masivos

Jordi Casas Roma
Carles Garrigues Olivella