




Sistemas de Big Data

Técnicas y herramientas para el análisis
de datos masivos

Jordi Casas Roma
Carles Garrigues Olivella

Índice

1. El modelo MapReduce
2. Apache Hadoop
3. Apache Spark
4. Bases de datos NoSQL

Índice

1. El modelo MapReduce
2. Apache Hadoop
3. Apache Spark
4. Bases de datos NoSQL

Herramientas de Big Data

Hemos definido Big Data como:

*“el conjunto de técnicas y tecnologías para el **tratamiento** y **almacenamiento** de datos, en entornos de gran volumen, variedad de orígenes y en los que la velocidad de respuesta es crítica”.*

Técnicas/herramientas para:


- **Almacenamiento** datos masivos (distribuido)
- **Procesado** de datos masivos (distribuido)

El modelo MapReduce (I)

Pasos del modelo


- **Map:** La función Map convierte el fichero de información de gran tamaño en una secuencia de pares <clave, valor>
- **Shuffle:** Los resultados son recolectados y ordenados según el valor de la clave
- **Reduce:** combinando todos los valores asociados a la clave de forma específica a cada problema

El modelo MapReduce (II)



Fuente: <http://www.cs.uml.edu/~jlu1/doc/source/report/MapReduce.html>

Ejemplo MapReduce



Índice

1. El modelo MapReduce
2. Apache Hadoop
3. Apache Spark
4. Bases de datos NoSQL

Apache Hadoop

Hadoop distributed file system (HDFS)

- Los datos son distribuidos por diferentes nodos.
- Los datos se pueden tratar en paralelo.
- Existe tolerancia a fallos puesto que existen múltiples copias de los datos en diferentes nodos.

Hadoop MapReduce engine

Por encima del sistema de ficheros, Hadoop incorpora un motor de ejecución de trabajos **MapReduce**. MapReduce permite el procesamiento a gran escala de conjuntos de datos.

Apache Hadoop: ecosistema

Alternativas al modelo MapReduce

- **Apache Storm** es un sistema de computación distribuida en tiempo real
- **Apache Giraph** es un sistema de procesamiento distribuido de grafos

Apache Hadoop: ecosistema

Lenguajes programación

- **Apache Pig** es un lenguaje de programación de alto nivel diseñado y desarrollado para eliminar la complejidad de la codificación de las aplicaciones MapReduce
- **Apache Hive** es una infraestructura de *data warehouse* en entorno distribuido.

Apache Hadoop: ecosistema

Extracción de conocimiento

- **Apache Mahout** es una plataforma de aprendizaje automático y minería de datos construida sobre Hadoop
- **RHadoop** es un conjunto de cuatro paquetes en lenguaje R que permiten analizar y gestionar datos usando Hadoop.

Índice

1. El modelo MapReduce
2. Apache Hadoop
3. Apache Spark
4. Bases de datos NoSQL

Apache Spark

Características básicas

- Enfocado al procesamiento en *streaming*
- MapReduce es ineficiente para procesos de algoritmos iterativos o consultas interactivas.
- Almacenamiento distribuido basado en:
 - *Hadoop Distributed File System* (HDFS)
 - Cassandra
 - etc

Apache Spark

Módulos del sistema

- **Spark Core Engine** es el motor de ejecución de Spark
- **Spark SQL** es el módulo encargado de dar soporte a consultas interactivas
- **Spark Streaming** permite a las aplicaciones procesar y analizarlos datos en tiempo (casi) real
- **MLlib** es la librería de aprendizaje automático
- **GraphX** es un motor para el análisis de grafos
- **SparkR** permite integrar el lenguaje estadístico R

Índice

1. El modelo MapReduce
2. Apache Hadoop
3. Apache Spark
4. Bases de datos NoSQL

Bases de datos NoSQL

¿Qué diferencias hay entre NoSQL y los SGBDR?

- Se almacenan datos de cualquier tipo indexados por una única clave.
- Los datos no son analizados antes de ser almacenados
- No existen procesos para asegurar la integridad


Resultado:

Almacenaje y procesamiento de datos en tiempo muy reducido

Bases de Datos NoSQL

Los datos pueden encontrarse en una BD NoSQL

Los datos procesados mediante trabajos MapReduce pueden almacenarse en bases de datos NoSQL.





Sistemas de Big Data

Técnicas y herramientas para el análisis
de datos masivos

Jordi Casas Roma
Carles Garrigues Olivella