

TEMA 84. RECONOCIMIENTO ÓPTICO DE CARACTERES (OCR, ICR). RECONOCIMIENTO BIOMÉTRICO.

Actualizado a 05/06/2023

1. RECONOCIMIENTO ÓPTICO DE CARACTERES (OCR)

El **reconocimiento óptico de caracteres** (OCR en inglés) es la tecnología que permite el procesado de textos manuscritos o impresos y convertirlos en datos que puedan ser legibles por una máquina.

Tecnologías:

- **Códigos de Barras (Bar Codes):** Son un mecanismo rápido y eficiente de recuperar información. Existen unidimensionales y bidimensionales, que permiten almacenar más información. Algunas evoluciones son los Códigos QR (ISO/IEC 18004) o los PDF 417 (ISO/IEC 15438)
- **OMR (Optical Mark Reader):** Estos sistemas permiten introducir en el ordenador información que se encuentra en forma de marcas en partes predefinidas de un formulario. OMR detecta la existencia o ausencia de una marca en una cierta posición.
- **PCR (Printed Character Recognition):** Este término hace referencia a los sistemas que son capaces de reconocer información textual que ha sido impresa por una máquina.
- **ICR (Intelligent Character Recognition):** Este término hace referencia al reconocimiento de textos manuscritos. Un caso particular es mediante el uso de dispositivos electrónicos donde el usuario escribe y el texto se reconoce en tiempo real. Trabaja a nivel carácter.
- **Procesado automático de formularios:** referente a la captura de la imagen del formulario para ser procesada y capturar la información para finalmente procesar los resultados y validar automáticamente la salida.
- **IWR (Intelligent Word recognition):** puede reconocer y extraer no solo información escrita a mano impresa, sino también escritura cursiva. IWR trabaja con palabras o frases completas, en contraposición a ICR y es capaz de capturar información no estructurada de las páginas.


Tipos de fuentes para OCR:

- **MICR (Magnetic Ink Character Recognition):** desarrollado en los años 50 en el Stanford Research Institute y General Electric Computer Laboratory para el proceso automático de cheques bancarios. Existen dos juegos de caracteres estandarizados: E-13B (ISO 1004-1:2013) y CMC7 (ISO 1004-2:2013).
- **OCR-A:** creado por American Type Founders en 1968. Utilizado fundamentalmente en Estados Unidos para el procesado automático de cheques bancarios. Actualmente estandarizado en el ISO 1073-1:1976.
- **OCR-B:** desarrollado por Arian Frutiger en 1968. Utilizado igualmente en cheques bancarios. Fue el equivalente europeo a OCR-A. Se encuentra recogido en el estándar ISO 1073-2:1976.
- **FE-Schrfit:** introducida para ser utilizada en matriculas vehiculares.
- **SEMI font:** empleada para marcar las obleas de silicia de la industria del semi-conductor.

Terminología:

- **Bloque:** División básica de una página. Pueden ser párrafos, secciones o imágenes.
- **Carácter:** Unidad de reconocimiento básica. Elemento más pequeño en que se puede dividir una página.
- **Espaciado:** Puede ser fijo o proporcional. Si es fijo, todos los caracteres tienen la misma anchura, si es proporcional, depende del ancho de la propia letra, dando por ejemplo más anchura a la M que a la I.
- **Proyecciones o histogramas:** Conteo de píxeles negros en una cierta columna (histograma vertical) o fila (histograma horizontal).
- **Segmentado:** división de los elementos de una página en otros menores hasta llegar al carácter.

- Términos tipográficos:



1.1. FASES DEL PROCESO DE RECONOCIMIENTO

- **Adquisición de la imagen:** Se puede realizar con un escáner, una cámara, una PDA, un fax, ...
- **Preprocesamiento de la imagen:**
 - Pasos básicos: **Normalización** (modificar la relación de aspecto, resolución y escala), **Eliminación de ruido(despeckling)**, **Binarización**(convertir a blanco y negro), **Alineación**
 - **Segmentado en bloques(zoning):** Se separa la hoja en los diferentes bloques que pueden ser de distintos tipos como imágenes, textos, tablas,
 - **Segmentado en líneas:** Se segmenta el bloque en líneas, principalmente mediante histogramas horizontales.
 - **Segmentado en caracteres:** Cada línea se segmenta primero en palabras y después en caracteres. Para esto se usa el vertical.
- **Reconocimiento de caracteres:** Permite determinar el carácter y asignarle una fiabilidad. Algunos métodos que se emplean:
 - **Reconocimiento de patrones:** Aísla una imagen de carácter, llamada **glifo**, y la compara con un glifo almacenado de manera similar.
 - **Redes neuronales.**
 - **Comparación de matrices.**
 - **Vectores de características:** Suelen emplearse métodos estadísticos como KNN (K-Nearest Neighbours) o SVM (Support Vector Machines).

1.2. SOFTWARE

- **Comercial:** Omnipage Ultimate, ABBYY FineReader, PDF Reader, Amazon Textract.
- **Libre:** Ocrad, JOCR, Kooka, Tesseract, ReadIris, FreeOCR, SimpleOCR, Microsoft OneNote.

2. RECONOCIMIENTO BIOMÉTRICO

La biometría es el conjunto de características fisiológicas y de comportamiento que pueden ser utilizadas para verificar la identidad del individuo, lo cual incluye huellas digitales, reconocimiento del iris, geometría de la mano, reconocimiento visual y otras técnicas.

Se distinguen dos tipos fundamentales de rasgos biométricos:

- Rasgos **anatómicos** que se agrupan en lo que se conoce también como **biometría estática** como, por ejemplo: Huella dactilar, sensores de huellas, reconocimiento facial, reconocimiento de iris, reconocimiento de retina, reconocimiento de la geometría de la mano.
- Rasgos **conductuales** que se agrupan en lo que se conoce también como **biometría dinámica** como, por ejemplo: Reconocimiento de firma, reconocimiento de voz, reconocimiento de escritura del teclado, reconocimiento de la forma de andar.

Características de los rasgos biométricos:

- **Universalidad:** Todos los individuos la poseen.
- **Singularidad o univocidad:** Distinguen a cada individuo.
- **Permanencia en el tiempo en distintas condiciones ambientales.**
- **Medibles** cuantitativamente.

Modos de operación de un sistema biométricos:

- **Registro:** Captura de los rasgos biométricos y almacenamiento en una plantilla.
- **Identificación:** Reconocer a un individuo entre varios (1:N).
- **Verificación o autenticación:** Valida la identidad del individuo contra una muestra (1:1).

Parámetros de evaluación del sistema biométrico:

- **Tasa de falsa aceptación** (FAR: False Acceptance Rate).
- **Tasa de falso rechazo** (FRR: False Rejection Rate).
- **Tasa de correcta aceptación** (CAR: Correct Acceptance Rate).
- **Tasa de correcto rechazo** (CRR: Correct Rejection Rate).
- **Tasa e igual error** (ERR, Equal Error Rate): Donde FAR y FRR son iguales.

Ejemplos de software: Smowl eProctoring, Examity, Mettl, ProctorU, Verificent, Proctortrack, RemoteDesk, FreshHire, Veripass,

2.1. ESTÁNDARES

A nivel mundial el principal organismo que coordina las actividades de estandarización biométrica es el Subcomité 17 (SC17) del Joint Technical Committee on Information Technology (ISO/IEC JTC1), del International Organization for Standardization (ISO) y el International Electrotechnical Commission (IEC).

Algunos estándares relevantes ISO relacionados con la biometría son:

- **ISO/IEC 2382-37:** establece una terminología estándar.
- **ISO/IEC 19784:** describe BioAPI, un interfaz estándar (API) para la comunicación con sistemas biométricos en sus diferentes modos de uso.
- **ISO/IEC 19785:** define modelos de datos estándar para el almacenamiento de datos biométricos en general, orientados a la interoperabilidad (Common Biometric Exchange Formats).
- **ISO/IEC 19794:** especifica los formatos de intercambio para los datos capturados.

- **ISO/IEC 39794:** extensión de los formatos de intercambio para los datos capturados.
- **ISO 19092:** describe un modelo de seguridad para el uso de autenticación biométrica en servicios financieros.

2.2. LEGISLACIÓN

REGLAMENTO (UE) 2016/67 (RGPD)

Define los datos biométricos como: datos personales obtenidos a partir de un tratamiento técnico específico, relativos a las características físicas, fisiológicas o conductuales de una persona física que permitan o confirmen la identificación única de dicha persona, como imágenes faciales o datos dactiloscópicos.

En el artículo 9 los considera como una categoría especial de datos personales cuyo tratamiento en general está prohibido.

Orden ETD/465/2021, de 6 de mayo, por la que se regulan los métodos de identificación remota por vídeo para la expedición de certificados electrónicos cualificados.

Habilita a los prestadores de servicios electrónicos de confianza para identificar de forma no presencial, por vídeo, a los solicitantes de certificados cualificados mediante nuevas tecnologías como sistemas biométricos de reconocimiento facial.

RD 311/2022 (ENS)

Introduce el uso del certificado protegido por un segundo factor que puede ser biométrico.

14 equívocos con relación a la identificación y autenticación biométrica (AEPD)

1. “La información biométrica se almacena en un algoritmo”.
2. “El uso de datos biométricos es igual de intrusivo que cualquier otro sistema de identificación/autenticación”.
3. “La identificación/autenticación biométrica es precisa”.
4. “La identificación/ autenticación biométrica es suficientemente precisa para diferenciar siempre entre dos personas”.
5. “La identificación/ autenticación biométrica es adecuada para todas las personas”.
6. “El proceso de identificación/autenticación biométrica no se puede burlar”.
7. “La información biométrica no está expuesta”.
8. “Todo tratamiento biométrico implica identificación/autenticación”.
9. “Los sistemas de identificación/autenticación biométrica son más seguros para los usuarios”.
10. “La autenticación biométrica es fuerte”.
11. “La identificación/autenticación biométrica es más cómoda para el usuario”.
12. “La información biométrica convertida a un hash no es recuperable”.
13. “La información biométrica almacenada no permite reconstruir la información biométrica original de la que se ha extraído”.
14. “La información biométrica no es interoperable”.