



TEMA 71

CIENCIA DE DATOS. CICLO DE VIDA DE LOS PROCESOS DE MODELADO DE DATOS (ETL, PREPROCESADO, MODELADO, VALIDACIÓN, MLOPS). FUNDAMENTOS ESTADÍSTICOS. HERRAMIENTAS Y LENGUAJES. VISUALIZACIÓN DE DATOS.

Versión	30.1
Fecha de actualización	11/09/2024



1. Ciencia de Datos

1.1. Introducción

La **ciencia de datos** es un campo académico interdisciplinario que utiliza estadísticas, computación científica, métodos, procesos, algoritmos y sistemas científicos para extraer o extrapolar conocimientos e ideas a partir de datos ruidosos, estructurados y no estructurados.

Tiene su origen en el año 1962, cuando el estadístico estadounidense **John W. Tukey**. Escribiría así en **El futuro del análisis de datos (1962)**.

En **1974** cuando **Peter Naur** acuña el término que actualmente conocemos.

Por su parte, **William S. Cleveland** introdujo en **2001** a la Ciencia de Datos como una disciplina unificada y con independencia de lo que hasta ese momento se había conocido como Estadística.

La ciencia de datos se utiliza para estudiar los datos de cuatro maneras principales:

- **Análisis descriptivo.**
- **Análisis de diagnóstico.**
- **Análisis predictivo.**
- **Análisis prescriptivo.**

1.2. Tecnologías en la Ciencia de Datos

La ciencia de datos abarca el uso de tecnologías complejas como:

- **Inteligencia artificial.**
- **Computación en la nube y computación en el borde.**
- **Internet de las cosas.**
- **Computación cuántica.**

1.3. Roles

Un equipo de ciencia de datos puede contener una alta cantidad de perfiles, roles y responsabilidades. Algunos de los más importantes son:


- **Data Explorer**
- **Data Architect**
- **Data Steward**
- **Data Engineer**
- **Data Analyst**
- **Data Scientists**
- **Data Translator**
- **Business Analyst**
- **Campaign Experts**



- Data Artist
- Data Hygienists
- Chief Data Officer (CDO)
- Data Visualization Developer
- Machine Learning Engineer
- MLOps Engineer

2.Ciclo de vida de los procesos de modelado de datos

Dentro del área de ciencia de datos, el número de procesos y procedimientos puede ser variable. Incluso algunas etapas pueden englobar y relacionar otras.



El ciclo de vida de los procesos de modelado de datos contiene:

- Obtención de los datos
- Preprocesamiento de los datos
- Transformación e integración
- Análisis de los datos
- Interpretación de los datos
- Ingeniería de características
- Validación de los datos

Diseñar nuevos análisis o experimentos en caso necesario: En el procedimiento científico esta parte es la que se define como “Validar la hipótesis”.

Visualizar y presentar gráficamente los resultados de los datos: Es un proceso fundamental en cualquier trabajo con grandes bases de datos, el graficar de forma completa y con la mayor cantidad de capas posibles la información resultante.

1.4. ETL



La primera parte del proceso se denomina comúnmente ETL (Extract, Transform and Load). Este proceso permite mover datos provenientes de diferentes fuentes, además de formatearlos y limpiarlos, para finalmente guardarlos en otra base de datos, Datamart, Datalake o Datawarehouse.

- **Extracción** de los datos de las fuentes de origen. Éstos pueden provenir de diferentes orígenes como BBDD, plataformas tecnológicas o protocolos de comunicaciones. Es más, estas fuentes tampoco suelen utilizar la misma organización ni formato.
- **Transformación** de los datos, en la que se realizan diferentes pasos como la limpieza, donde los datos se pueden depurar, corregir o estandarizar.
- **Carga** de los datos, que una vez depurados y “limpios”, se incorporan (ej. estructura OLAP), ya sea sobrescribiendo la información antigua con nuevos datos o incorporando a los nuevos.

Algunas de las herramientas más utilizadas para llevar a cabo procesos ETL son:

- Comerciales: Power Center, Oracle Data Integrator (ODI), SAS Data Integrator, Dastage, FME (datos geográficos), Azure Data Factory, SSIS, AWS Glue...
- Open Source: Pentaho, CLOVER ETL, KETL, Talend Open Studio Integration

1.5. Preprocesado

La preparación de datos, también conocida como “preprocesamiento”, es el acto de limpiar y consolidar los datos sin procesar antes de utilizarlos para realizar un análisis de negocio. Esta fase incluye las siguientes actividades:

- **Recopilar/Crear datos.**
- **Descubrimiento.**
- **Limpiar y validar datos.**
- **Reducción de datos.**
- **Enriquecer los datos.**
- **Almacenar los datos.**

Algunas de las principales herramientas para realizar un preprocesamiento de datos son: **Librería Pandas y Numpy de Python, Weka, RapidMiner, R Studio, Azure Machine Learning, IBM Watson Studio.**

1.6. Modelado

El modelado de datos viene con el objetivo de producir datos de mayor calidad, estructurados y consistentes para ejecutar aplicaciones empresariales y lograr resultados consistentes. Existen 3 tipos de modelado:

- **Conceptual**
- **Lógico**
- **Físico**

1.7. Validación

Los métodos de validación, también conocidos como **resampling**, son estrategias que permiten estimar la capacidad predictiva de los modelos cuando se aplican a nuevas observaciones, haciendo uso de los datos de entrenamiento.

Algunas de las estrategias de validación son:



- Validación Simple
- Leave One Out Cross-Validation (LOOCV)
- K-Fold Cross-Validation
- Repeated k-Fold-Cross-Validation
- Bootstrapping.

1.8. MLOPS

Machine Learning Operations (MLOps) es una de las nuevas tendencias en ciencia de datos, una parte de la cultura DevOps. Por ello, está estrechamente relacionada con los modelos de aprendizaje automático (machine learning) y la automatización de procesos.

Algunas de las herramientas más usadas son **Mlflow, DVC, Kubeflow, ONNX, TensorFlow Extended, Apache Airflow, Cookiecutter, Metaflow, Jupyter, PyTorch o Psycasfold**.

3. Fundamentos Estadísticos

Uno de los objetivos de la ciencia de datos y machine learning es crear modelos predictivos a partir de un histórico. Es por ello que la estadística juega un papel clave.

La estadística se divide en dos partes diferenciadas como son la **estadística descriptiva y la inferencia estadística**.

La estadística descriptiva es el conjunto de métodos estadísticos que describen y/o caracterizan un grupo de datos. La estadística inferencial busca deducir y sacar conclusiones acerca de situaciones generales más allá del conjunto de datos obtenidos.

1.9. La estadística descriptiva

La estadística descriptiva es la técnica matemática que obtiene, organiza, presenta y describe un conjunto de datos con el propósito de facilitar el uso, generalmente con el apoyo de tablas, medidas numéricas o gráficas.

Tipos de estadística descriptiva

- Distribución de frecuencias
- Tendencia central
- Variabilidad

1.10. Estadística inferencial

También llamada estadística inductiva. La estadística inferencial es la parte de la estadística que comprende métodos y procedimientos que por medio de la inducción determina propiedades de una población estadística, a partir de una parte de esta.

La estadística inferencial se subdivide a su vez en dos grandes tipos: estadística paramétrica y no paramétrica.



4. Herramientas y Lenguajes

Algunas de las principales técnicas usadas en la ciencia de datos son **clasificación, regresión y agrupación**.

Entre los lenguajes y plataformas más utilizados en la ciencia de datos se encuentran:

- **Phyton**. Algunas de las librerías de Python más utilizadas en ciencias de datos son: **Python Numpy, Python Pandas, Plotly, Scikit-learn, Matplotlib**
- **R**
- **Julia**
- **Scala**
- **Spyder**
- **PyCharm**
- **Jupyter Notebook**
- **Trifacta**

5. Visualización de Datos

La visualización de datos es la representación gráfica de la información. Mediante el uso de elementos visuales, como gráficos, mapas e infografías, las técnicas de visualización permiten comunicar de una manera accesible la información a los diferentes usuarios.

Los datos nos cuentan historias (**Storytelling**), y debemos narrarlas adecuadamente dependiendo de quiénes serán los consumidores de la información.

Los dashboards o paneles de datos consisten en la consolidación de la representación gráfica de todos aquellos indicadores claves de éxito (**KPI**) de una organización, y está orientado a la toma de decisiones estratégicas de una empresa.

- **KGI (Key Goal Indicator)** o "Indicador de objetivo clave".
- **KPI (Key Performance Indicator)** o "Indicador clave de rendimiento".
- **OKR (Objective and Key Result)** significa "Objetivo y resultado clave".
- **KSF (Key Success Factor)** o factor clave de éxito.

Las herramientas más relevantes para la visualización de datos son: Kibana, SpagoBI, Grafana, Tableau, IBM Watson Analytics, MS Power BI, Qlik, Microstrategy, Matplotlib (librería de python para proyectos de visualización), Data Science Notebooks, Zoho Analytics, Domo...

6. Minería de Datos

La minería o explotación de datos es la etapa de análisis de "Knowledge Discovery in Databases" o KDD. Su objetivo es extraer información de un conjunto de datos que de algún modo se encuentra oculta, y transformarla en una estructura comprensible para su uso posterior.

Ejemplos de soluciones de Minería de Datos:

- Libre: Pentaho Data Mining (Weka), JHepWork, Orange Data Mining.
- Propietario: Cubos OLAP Excel, Enterprise Miner, Clementine, SAP Miner, Tableau y ThoughtSpot.

Para la elaboración de cuadros de mando y obtención de indicadores, es aconsejable aplicar la norma **UNE**



66175:2003 Sistemas de gestión de la calidad. Guía para la implantación de sistemas de indicadores.

1.11. Características

Algunas de sus características más relevantes son: trabaja con la información oculta, suelen ser soluciones con una arquitectura cliente-servidor, poseen gran variedad de herramientas para la extracción de la información, es habitual hacer uso de un procesamiento paralelo que acelere el proceso debido a la existencia de una gran cantidad de datos, produce cinco tipos de información (asociaciones, secuencias, clasificaciones, agrupamientos y pronósticos).

1.12. Técnicas

Se basa en el uso de diferentes técnicas de aprendizaje automático:

- **Redes neuronales.**
- **Árboles de decisión.**
- **Reglas de inducción.**
- **Sistemas expertos.**
- **Algoritmos genéticos.**
- **Clustering o agrupamiento.**

Estas técnicas se basan en el uso de algoritmos que se pueden clasificar en:

- **De verificación.**
- **Supervisados**
- **No supervisados.**

7. Big Data

Gartner define al Big Data como: “activos de información caracterizados por su volumen elevado, velocidad elevada y alta variedad, que demandan soluciones innovadoras y eficientes de procesado para la mejora del conocimiento y la toma de decisiones en las organizaciones”.

En la actualidad se han propuesto nuevas Vs al conjunto:

- **Veracidad** de los datos
- **Viabilidad.**
- **Visualización de los datos.**
- **Valor de los datos.**

UIT-T Y.3600 - recomendación UIT que hace referencia a grandes volúmenes de datos - requisitos y capacidades basados en la computación en la nube

8. Entornos Hadoop o Similares

Inspirado en GFS (Google File System) y en el paradigma MapReduce.

Para comprender completamente cómo funciona Hadoop debemos entender sus tres componentes principales: **MapReduce**, **Yarn** (Yet Another Resource Negotiator) y **HDFS** (Hadoop Distributed File System).



Además de estos componentes, el módulo **Hadoop Common** aporta las utilidades y librerías comunes del proyecto que soportan el resto de componentes y permiten desarrollar las aplicaciones.

Hadoop Core está compuesto por: Common (utilidades) + HDFS (BD) + **MapReduce** (Procesado)

- **Hadoop Common.**
- **HDFS.**
- Hadoop **MapReduce**

1.13. Distribuciones Hadoop

Cloudera, HORTONWORKS y MAPR.

1.14. EcosistemaHadoop

CAPTURA Y MANIPULACIÓN DATOS

LUCENE, SQOOP. Sql-to-Hadoop, CHUKWA, FLUME, KAFKA

ALMACENAMIENTO

HIVE, HBASE, IMPALA

TRATAMIENTO DATOS

OOZIE, APACHE PIG, JAQL, STORM, GIRAPH, APACHE MAHOUT, APACHE SPARK

ADMINISTRACIÓN

AMBARI, ZOOKEEPER, YARN, TEZ, AVRO

9. Bases de datos NoSQL

Frente a las bases de datos relacionales aparecen las bases de datos NoSQL que se caracterizan por:

- No utilizar SQL como lenguaje de consultas.
- No utilizan estructuras fijas como tablas para el almacenamiento.
- No permiten operaciones Join.
- Emplean arquitecturas distribuidas con Master-Slave.

Razones para usarlas:

- El volumen de los datos crece muy rápidamente en momentos puntuales.
- La escalabilidad de la solución relacional no es viable.
Elevados picos de uso del sistema por parte de los usuarios en múltiples ocasiones.

9.1. Tipos de Bases de datos NoSQL

Se distinguen principalmente los siguientes tipos de BBDD NoSQL: **Clave-valor**, **Orientadas a Documentos**, **Orientadas a Grafos**, **Orientadas a objetos**, **Orientadas a columnas**, **BD NoSQL Search**.

Algunas de las BBDD NOSQL más extendidas: **REDIS**, **MongoDB**, **Apache Cassandra**, **ELASTICSEARCH**.

